

Introdução à Ciência de Dados

Fundamentos e Aplicações

Versão parcial preliminar

junho 2020

Pedro A. Morettin

Julio M. Singer

Departamento de Estatística
Universidade de São Paulo
Rua do Matão, 1010
São Paulo, SP 05508-090
Brasil

Conteúdo

Prefácio	viii
1 Estatística, Ciência de Dados e Megadados	1
1.1 Introdução	1
1.2 Aprendizado com Estatística	3
1.3 Aprendizado automático	4
1.4 Uma cronologia do Aprendizado com Estatística	6
1.4.1 Probabilidades	6
1.4.2 Estatística	6
1.4.3 Estatística e computação	7
1.5 Notação e tipos de dados	8
1.6 O modelo geral para o Aprendizado Estatístico	9
1.6.1 Regressão	9
1.6.2 Classificação	11
1.7 Este livro	13
1.8 Conjuntos de dados	14
1.9 Notas do Capítulo	17
PARTE I: ANÁLISE EXPLORATÓRIA DE DADOS	19
2 Preparação dos dados	21
2.1 Considerações preliminares	21
2.2 Planilhas de Dados	24
2.3 Construção de tabelas	28
2.4 Construção de gráficos	30
2.5 Notas de capítulo	31
2.6 Exercícios	35
3 Análise de dados de uma variável	39
3.1 Introdução	39
3.2 Distribuições de frequências	40
3.2.1 Variáveis qualitativas	42
3.2.2 Variáveis quantitativas	44
3.3 Medidas resumo	50

3.3.1	Medidas de posição	50
3.3.2	Medidas de dispersão	53
3.3.3	Medidas de assimetria	55
3.4	<i>Boxplots</i>	58
3.5	Modelos probabilísticos	61
3.6	Dados amostrais	63
3.7	Gráficos QQ	63
3.8	Transformação de variáveis	69
3.9	Desvio padrão e Erro padrão	71
3.10	Intervalo de confiança	72
3.11	Notas de capítulo	74
3.12	Exercícios	77
4	Análise de dados de duas variáveis	85
4.1	Introdução	85
4.2	Duas variáveis qualitativas	86
4.3	Duas variáveis quantitativas	98
4.4	Uma variável qualitativa e outra quantitativa	110
4.5	Notas de capítulo	115
4.6	Exercícios	123
5	Análise de dados de várias variáveis	133
5.1	Introdução	133
5.2	Gráficos para três variáveis	134
5.3	Gráficos para quatro ou mais variáveis	147
5.4	Medidas resumo multivariadas	148
5.5	Tabelas de contingência de múltiplas entradas	150
5.6	Notas de capítulo	153
5.7	Exercícios	163
6	Análise de Regressão	171
6.1	Introdução	171
6.2	Regressão Linear Simples	174
6.3	Regressão Linear Múltipla	193
6.4	Regressão para dados longitudinais	205
6.5	Regressão Logística	208
6.6	Notas de capítulo	214
6.7	Exercícios	224
7	Análise de Sobrevida	233
7.1	Introdução	233
7.2	Estimação da função de sobrevida	238
7.3	Comparação de curvas de sobrevida	242
7.4	Regressão para dados de sobrevida	242
7.5	Notas de Capítulo	244
7.6	Exercícios	244

PARTE II: APRENDIZADO SUPERVISIONADO	249
8 Classificação por meio de técnicas clássicas	251
8.1 Introdução	251
8.2 Classificação por regressão logística	252
8.3 Função discriminante linear de Fisher	259
8.4 Classificador bayesiano e do vizinho mais próximo	262
8.5 Notas de capítulo	264
8.6 Exercícios	266
9 Classificação por algoritmos de suporte vetorial	267
9.1 Introdução	267
9.2 Fundamentação dos algoritmos de suporte vetorial	268
9.3 Classificador de margem máxima	270
9.4 Classificador de margem flexível	273
9.5 Classificador de margem não linear	279
9.6 Notas de Capítulo	282
9.7 Exercícios	287
10 Classificação por árvores e florestas	289
10.1 Introdução	289
10.2 Classificação por árvores	290
10.3 Bagging, boosting e florestas	296
10.3.1 Bagging	297
10.3.2 Boosting	299
10.3.3 Florestas aleatórias	301
10.4 Notas de Capítulo	303
10.5 Exercícios	306
11 Previsão	307
11.1 Introdução	307
11.2 Regularização	307
11.2.1 Regularização L_2 (<i>Ridge</i>)	308
11.2.2 Regularização L_1 (<i>Lasso</i>)	309
11.2.3 Outras propostas	310
11.3 Regressão baseada em vetores suporte	314
11.4 Árvores para regressão	318
11.5 Notas de Capítulo	321
11.6 Exercícios	324
PARTE III: APRENDIZADO NÃO SUPERVISIONADO	327
12 Análise de Agrupamentos	329
12.1 Introdução	329
12.2 Estratégias de agrupamento	332
12.3 Algoritmos hierárquicos	332
12.4 Algoritmos de partição: K-médias	335

12.5 Tópicos adicionais	340
12.6 Notas de capítulo	342
12.7 Exercícios	343
13 Redução de Dimensionalidade	345
13.1 Introdução	345
13.2 Componentes Principais	345
13.3 Análise Fatorial	352
13.4 Análise de componentes independentes	361
13.4.1 Preliminares	361
13.4.2 Separação Cega de Fontes	361
13.4.3 Análise de Componentes Independentes	362
13.4.4 Pré-processamento	364
13.5 Notas de Capítulo	369
13.6 Exercícios	376
Referências	377

Prefacio

A ampla divulgação de uma “nova” área de aplicação conhecida como Ciência de Dados (*Data Science*), muitas universidades estrangeiras criaram programas sobre o assunto, primeiramente no formato de MBA e em seguida como mestrados regulares. Atualmente esses cursos incluem programas de doutorado e mesmo de graduação. Surpreendentemente, esses cursos foram introduzidos em escolas de Engenharia, Economia e, em vários casos, em escolas especialmente criadas para abrigar a “nova disciplina” mas não em Departamentos de Estatística. De certa forma, muitos estatísticos se sentiram surpreendidos e imaginaram-se diante de algo totalmente diferente do seu *métier*. No entanto, uma visão mais crítica sobre o assunto, mostra que Ciência de Dados nada mais é que a aplicação de técnicas estatísticas por meio da grande capacidade computacional de que dispomos atualmente. Muitos modelos empregados nessa “nova” área está disponível e esquecidos) na literatura estatística há décadas. Esses modelos não vinham sendo aplicados em grande escala em virtude de limitações computacionais. Por exemplo, árvores de decisão, amplamente utilizadas em Ciência de Dados, foram introduzidas na década de 1980. Outro tópico, conhecido como Algoritmos de Suporte Vetorial (*Support Vector Machines*) não fazia parte das metodologias estudadas pelos estatísticos, por necessitarem de grande capacidade computacional para sua aplicação, apareceram na década de 1990.

Hoje, programas de MBA e cursos de extensão em Ciência de Dados têm surgido no Brasil e atualmente, no IME-USP estuda-se a possibilidade de criar um Mestrado em Estatística, com ênfase em Ciência de Dados. A maior dificuldade é encontrar professores nos vários departamentos de Estatística no país interessados em se readequar a esse novo paradigma.

Originalmente, pretendíamos escrever um texto sobre Análise Exploratória de Dados, para utilização na disciplina de Estatística Descritiva, ministrada no bacharelado em Estatística do Instituto de Matemática e Estatística da Universidade de São Paulo (IME-USP). Tendo em vista essas considerações, decidimos ampliar o escopo da obra para incluir tópicos que normalmente não são abordados nos cursos de graduação e pós-graduação em Estatística. Desta forma, além de apresentar fundamentos de Análise Exploratória de Dados (extremamente importante para quem pretende se aven-

turar em Ciência de Dados), o objetivo do texto inclui o preenchimento da lacuna na formação de alunos de graduação e pós-graduação em Estatística proveniente da falta de exposição a tópicos que envolvem a interação entre Estatística e Computação.

No Capítulo 1 fazemos uma resenha das principais técnicas a serem desenvolvidas no livro. Na Parte 1 incluímos os capítulos referentes à Análise Exploratória de Dados. Na Parte 2 adicionamos capítulos referentes ao chamado Aprendizado Estatístico Supervisionado (que envolve regressão e classificação). Na Parte 3 tratamos do Aprendizado Estatístico Não Supervisionado (que aborda análise de agrupamentos e redução da dimensionalidade). Finalmente, na Parte 4 abordamos tópicos como redes neurais, noções de simulação e otimização.

São Paulo, junho de 2020

Os autores

CAPÍTULO 1

Estatística, Ciência de Dados e Megadados

Statistical learning theory does not belong to any specific branch of science: It has its own goals, its own paradigm, and its own techniques. Statisticians (who have their own paradigm) never considered this theory as part of statistics.

V. Vapnik

1.1 Introdução

Atualmente, os termos *Data Science* (Ciência de Dados) e *Big Data* (Megadados)¹ são utilizados em profusão, como se fossem conceitos novos, distintos daqueles com que os estatísticos lidam há cerca de dois séculos. Na década de 1980, numa palestra na Universidade de Michigan, EUA, C.F. Jeff Wu já sugeria que se adotassem os rótulos *Statistical Data Science*, ou simplesmente, *Data Science*, em lugar de *Statistics*, para dar maior visibilidade ao trabalho dos estatísticos. Talvez seja Tukey (1962, 1977), sob a denominação *Exploratory Data Analysis* (**Análise Exploratória de Dados**), o primeiro a dar importância ao que hoje se chama Ciência de Dados, sugerindo que se desse mais ênfase ao uso de tabelas, gráficos e outros dispositivos para uma análise preliminar de dados, antes que se passasse a uma **análise confirmatória**, que seria a **inferência estatística**. Outros autores, como Chambers (1993), Breiman (2001) e Cleveland (1985, 1993, 2001), também enfatizaram a preparação, apresentação e descrição dos dados como atividades que devem preceder a inferência ou modelagem.

Basta uma procura simples na Internet para identificar novos centros de Ciências de Dados (CD) em várias universidades ao redor do mundo,

¹Para esclarecimento do significado dos termos cunhados em inglês, optamos pela tradução oriunda do **Glossário Inglês-Português de Estatística** produzido pela Associação Brasileira de Estatística e Sociedade Portuguesa de Estatística, disponível em <http://glossario.spestatistica.pt/>. As exceções são as expressões para as quias não há uma tradução oficial (*boxplot*, por exemplo) ou acrônimos usualmente utilizadas por pacotes computacionais (MSE, de *Mean Squared Error*, por exemplo).

com programas de mestrado, doutorado e mesmo graduação. O interessante é que muitos desses programas estão alojados em escolas de Engenharia, Bioestatística, Ciência da Computação, Administração, Economia etc., e não em departamentos de Estatística. Paradoxalmente, há estatísticos que acham que Estatística é a parte menos importante de CD! Certamente isso é um equívoco. Como ressalta Donoho (2017), se uma das principais características de CD é analisar grandes conjuntos de dados (Megadados), há mais de 200 anos os estatísticos têm se preocupado com a análise de vastos conjuntos de dados provenientes de censos, coleta de informações meteorológicas, observação de séries de índices financeiros etc., que têm essa característica.

Outro equívoco consiste em imaginar que a Estatística Clássica (frequentista, bayesiana etc.) trata somente de pequenos volumes de dados, conhecidos como *Small Data*. Essa interpretação errônea vem do fato de que muitos livros didáticos apresentam conjuntos de dados, em geral de pequeno ou médio porte, para que as metodologias apresentadas possam ser aplicadas pelos leitores, mesmo utilizando calculadoras ou aplicativos estatísticos (pacotes). Nada impede que essas metodologias sejam aplicadas a grandes volumes de dados a não ser pelas dificuldades computacionais inerentes. Talvez seja este aspecto computacional, aquele que mascara os demais componentes daquilo que se entende por CD, pois em muitos casos, o interesse é dirigido apenas para o desenvolvimento de algoritmos cuja finalidade é aprender a partir dos dados, omitindo-se características estatísticas.

Em particular, Efron and Hastie (2016) ressaltam que tanto a teoria bayesiana quanto a frequentista têm em comum duas características: a **algorítmica** e a **inferencial**. Como exemplo, citam o caso da média amostral de um conjunto de dados x_1, \dots, x_n , como estimador da média μ de uma população da qual se supõe que a amostra tenha sido obtida. O algoritmo para cálculo é

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i. \quad (1.1)$$

Resta saber quão acurado e preciso é este estimador. Como sabemos, admitindo-se que a amostra tenha sido colhida segundo um procedimento adequado, $E(\bar{x}) = \mu$, ou seja, o estimador \bar{x} é não enviesado e o seu erro padrão é

$$\text{ep} = \left[\frac{1}{n(n-1)} \sum_{i=1}^n (x_i - \bar{x})^2 \right]^{1/2}, \quad (1.2)$$

que mostra a sua consistência e estabelece as bases para uma inferência estatística (frequentista!) adequada. **Esses autores também mencionam que:**

Optimality theory, both for estimating and for testing, anchored statistical practice in the twentieth century. The larger datasets and more complicated inferential questions of the current era have strained the capabilities of that theory. Computer-age statistical inference, as we will see, often displays an unsettling ad hoc character. Perhaps some contemporary Fishers

and Neymans will provide us with a more capacious optimality theory equal to the challenges of current practice, but for now that is only a hope.

Blei and Smyth (2017) discutem Estatística e CD sob três perspectivas: estatística, computacional e humana. Segundo os autores, CD é uma filha da estatística e da ciência da computação. A estatística serviria à CD guiando a coleta e análise de dados complexos. A computação, desenvolvendo algoritmos que distribuem conjuntos enormes de dados por múltiplos processadores (proporcionando velocidade de cálculo) e equipamentos com grande capacidade de memória (permitindo seu armazenamento). Sob a perspectiva humana, a CD contempla modelos estatísticos e métodos computacionais para resolver problemas específicos de outras disciplinas, entender o domínio desses problemas, decidir quais dados obter, como processá-los, explorá-los e visualizá-los, selecionar um modelo estatístico e métodos computacionais apropriados, além de comunicar os resultados da análise de uma forma inteligível para aqueles que propuseram os problemas.

Donoho (2017) discute várias **memes** (uma ideia ou símbolo transmitido pelas chamadas **mídias sociais**) sobre Megadados (MD) e CD. Algumas **memes** são vídeos ou expressões verbais, outras, como MD e CD, são provadas de um conteúdo filosófico mais profundo. Por exemplo, sobre a *Big Data Meme*, diz que se pode rejeitar o termo MD como um critério para uma distinção séria entre Estatística e CD, **o que está de acordo com** o que dissemos acima sobre análise de dados de censos e o fato de pesquisadores na área de inferência estatística terem buscado o entendimento científico de MD por décadas.

Um dos aspectos tradicionalmente negligenciados por estatísticos é aquele em que os dados têm natureza não ortodoxas como imagens, sons etc. Nesse caso, algoritmos computacionais são essenciais para seu tratamento que, por sua vez, não pode prescindir do apoio de um estatístico.

1.2 Aprendizado com Estatística

Alguns termos muito utilizados hoje em dia são *Statistical Learning* (**Aprendizado com Estatística**) e *Machine Learning* (**Aprendizado com Máquina ou Automático**). **Esses termos estão associados à** utilização de modelos estatísticos acoplados a algoritmos computacionais desenvolvidos para extrair informação de conjuntos de dados contendo, em geral, muitas unidades amostrais e muitas variáveis.

No contexto amplo do Aprendizado com Estatística, podemos distinguir dois enfoques: **inferência estatística**, em que se pretende entender como a resposta é afetada pela variação dos preditores ou identificar os mais importantes nessa relação e **previsão**, em que o objetivo é identificar o melhor modelo para prever valores.

No âmbito de previsão, o Aprendizado com Estatística pode ser classificado como **supervisionado** ou **não supervisionado**. No AE supervisionado, o objetivo é prever o valor de uma variável resposta (*output*) a partir

de variáveis preditoras (*input*). A variável resposta pode ser quantitativa ou qualitativa (ver Capítulo 3).

Quando as variáveis respostas são quantitativas, um dos modelos mais utilizados no AE é o de **regressão**; nesse contexto, para variáveis respostas qualitativas, geralmente utilizam-se modelos de **regressão logística** para a análise (ver Capítulo 6). Adicionalmente, para variáveis qualitativas (categóricas ou discretas), podem ser utilizados modelos de classificação baseados em algoritmos de suporte vetorial (*support vector machines*), árvores de decisão, método do k -ésimo vizinho mais próximo, função discriminante linear de Fisher etc. (ver Capítulo 10).

No caso de AE não supervisionado, dispomos apenas um conjunto de variáveis (*inputs*) e o objetivo é descrever associações e padrões entre essas variáveis. Nesse caso, não há uma distinção entre variáveis preditoras e respostas. Dentre as técnicas mais utilizadas com essa finalidade, incluímos a **análise de componentes principais** e a **análise de componentes independentes** (ambas proporcionando a redução da dimensionalidade dos dados) e a análise de conglomerados (ou agrupamentos).

1.3 Aprendizado automático

Inteligência Artificial (IA) é um tópico que aparece frequentemente nas mídias escritas e faladas e que tem gerado amplo interesse de analistas de **dados**. Normalmente o termo suscita questões do tipo: no futuro computadores tornar-se-ão inteligentes e a raça humana será substituída por eles? Todos perderemos nossos empregos, porque seremos substituídos por robôs inteligentes? Pelo menos até o presente esses receios são infundados. Nesse contexto, veja Jordan (2019). Segundo esse autor, o que é hoje rotulado como IA, nada mais é do que aquilo que chamamos de Aprendizado Automático (*machine learning*).

Acredita-se que o artigo de Turing (1950) seja o primeiro a tratar do tema. A primeira frase do artigo diz:

I propose to consider the question, “Can machines think?”

Segue-se discussão sobre o que se entende por “máquina”, por “pensar” e por um jogo, chamado “jogo da imitação”. Turing também discute condições para considerar uma máquina inteligente, as chamadas de *Turing test*. A primeira página do artigo está na Nota de Capítulo 1.

O tópico de IA foi tratado a seguir por McCarthy et al. (1955), na forma de uma proposta para um projeto de pesquisa no Dartmouth College. Cópia da primeira página do original encontra-se na Nota de Capítulo 2. Entre os signatários, encontra-se Shannon, precursor da Teoria da Informação.

De modo informal, a IA é um esforço para automatizar tarefas intelectuais usualmente realizadas por seres humanos (Chollet, 2018). A IA está intimamente ligada ao desenvolvimento da computação (ou programação de computadores) e até a década de 1980, era entendida como programação clássica, baseada em um sistema computacional (SC) (um computador ou

um conglomerado (*cluster*) de computadores ou nuvem etc.) no qual se alimentam dados e uma regra de cálculo para se obter uma resposta. Por exemplo, num problema de regressão a ser resolvido por meio do método de mínimos quadrados para obtenção dos estimadores dos parâmetros, a regra de cálculo é um algoritmo que pode ser programado em alguma linguagem (Fortran, C, R, Python etc.). A maioria dos pacotes computacionais existentes funciona dessa maneira.

A partir da década de 1990, o aprendizado automático (AA) criou um novo paradigma para analisar dados oriundos de reconhecimento de imagens, voz, escrita etc., dificilmente solucionáveis sem o recente avanço na capacidade computacional. A ideia subjacente é **treinar** um SC programando-o para ajustar diferentes modelos por meio dos algoritmos associados (muitas vezes bastante complexos) repetidamente na análise de um conjunto de dados. Nesse processo, diferentes modelos são ajustados a conjuntos de dados (chamados **dados de treinamento**), aplicados a um conjunto de **dados de teste** e comparados segundo algum critério de desempenho com o objetivo de escolher o melhor. Convém ressaltar que o objetivo do aprendizado automático não é o mesmo daquele considerado na análise de regressão usual, em que se pretende entender como cada variável explicativa está associada com a variável resposta. O objetivo do AA é selecionar o modelo que produz melhores previsões, mesmo que as variáveis selecionadas com essa finalidade não sejam aquelas consideradas numa análise padrão. O modelo selecionado deve ser ajustado ao conjunto de dados completo (treinamento e teste) para se obter o ajuste (estimativas dos coeficientes de um modelo de regressão, por exemplo) que será empregado para previsão de novos dados (consistindo apenas dos valores dos preditores).

Quando esses dois conjuntos de dados (treinamento e teste) não estão definidos *a priori*, o que é mais comum, costuma-se dividir o conjunto disponível em dois, sendo um deles destinado ao treinamento do SC com o outro servindo para teste. Calcula-se então alguma medida do erro de previsão obtido ao se aplicar o resultado do ajuste do modelo de treinamento aos dados de teste. Essa subdivisão (em conjuntos de treinamento e de teste diferentes) é repetida várias vezes, ajustando o modelo a cada conjunto de dados de treinamento, utilizando os resultados para previsão com os dados de teste e calculando a medida adotada para o erro de previsão. A média dessa medida é utilizada como avaliação do desempenho do modelo proposto. Para comparar diferentes modelos, repete-se o processo com cada um deles e aquele que produzir a menor média do erro de previsão é o modelo a ser selecionado. Esse processo é conhecido como **validação cruzada** (ver a Nota de Capítulo 2 no Capítulo 8).

Muitos métodos de aprendizado automático são implementados por meios de redes neurais e no Capítulo 13 daremos algumas ideias sobre elas.

1.4 Uma cronologia do Aprendizado com Estatística

Embora a terminologia Aprendizado com Estatística seja recente, a maioria dos conceitos foi desenvolvida a partir do século 19. Essencialmente, AE e AM (ou AA) tratam dos mesmos tópicos, mas utilizaremos o termo AE quando os métodos de AM são tratados com metodologias estatísticas apropriadas.

1.4.1 Probabilidades

As origens da teoria de probabilidades remontam a 1654, com Fermat (1601–1665), Pascal (1632–1662), que trataram de jogos de dados, baralho etc. Huygens (1629–1695) escreveu o primeiro livro sobre probabilidades em 1657. A primeira versão do Teorema de Bayes (Bayes, 1702–1761) foi publicada em 1763.

1.4.2 Estatística

Gauss (1777–1856) propôs o **método de mínimos quadrados** (MQ) na última década do Século 18 (1795) e usou-o regularmente em cálculos astronômicos depois de 1801. Todavia, foi Legendre (1752–1833) quem primeiro publicou sobre o método no apêndice de seu livro “*Nouvelles Methodes pour la Détermination des Orbites des Comètes*”, sem justificação. Gauss (1809) deu a justificativa probabilística do método em “*The Theory of the Motion of Heavenly Bodies*”. Basicamente, eles implementaram o que é hoje chamado de **Régressão Linear**.

Laplace (1749–1761) desenvolveu o Teorema de Bayes independentemente, em 1774. Em 1812 e 1814 deu a interpretação bayesiana para probabilidade e fez aplicações científicas práticas. Há autores que julgam que a chamada Inferência Bayesiana dever-se-ia chamar Inferência Laplaciana, devido às suas contribuições na área (lembremos da aproximação de Laplace, que se usava para obter distribuições a posteriori antes do advento de métodos MCMC e filtros de partículas).

Contribuições de Jeffrey (1939) podem ser consideradas como um reinício da Inferência Bayesiana, juntamente com as obras de Finetti, Savage e Lindley.

A Inferência Frequentista (testes de hipóteses, estimação, planejamento de experimentos e amostragem) foi iniciada por Fisher (1890–1962) e Neyman (1894–981). Fisher, em 1936, propôs a técnica de Análise Discriminante Linear e seus dois livros “*Statistical Methods for Research Workers*”, de 1925 e “*The Design of Experiments*”, de 1935, são marcos da teoria frequentista. Segundo Stigler, o artigo de Fisher (1922), “*On the mathematical foundation of theoretical statistics*”, publicado na *Phil. Trans. Roya Society*, A foi o artigo mais influente sobre Teoria Estatística no Século 20”.

Neyman e Pearson (1933), por sua vez, publicaram os dois artigos fundamentais sobre testes de hipóteses, consubstanciados no excelente livro de Lehmann de 1967.

A partir da década de 1940 começaram a aparecer abordagens alternativas ao modelo de regressão linear, como a **Regressão Logística**, os **Modelos Lineares Generalizados** (Nelder e Wedderburn, 1970), além dos **Modelos Aditivos Generalizados** (Hastie e Tibshirani, 1986).

Em 1969, Efrom introduz a técnica **Bootstrap** e em 1970, Hoerl e Kennard introduzem a **Regressão Ridge**. Até o final da década de 1970, os métodos lineares predominaram. A partir da década de 1980, os avanços computacionais possibilitaram a aplicação de métodos não lineares, como o **CART** (*Classification and Regression Trees*, Friedman et al., 1984). Em 1996, Tibshirani introduz o método de regularização **LASSO**, que juntamente com os métodos **Ridge**, **Elastic Net** e outras extensões passam a ser usados em conjunção com modelos de regressão, por exemplo, com o intuito de prevenir o fenômeno de sobreajuste (*overfitting*), mas que também funcionam como métodos de seleção de modelos.

1.4.3 Estatística e computação

Os avanços no AE estão diretamente relacionados com avanços na área computacional. Até 1960, os métodos estatísticos precisavam ser implementados em máquinas de calcular manuais ou elétricas. A partir de 1960 até 1980, apareceram as máquinas eletrônicas e os **grandes computadores**, como o IBM 1620, CDC 360, VAX etc, que trabalhavam com cartões e discos magnéticos. A linguagem FORTRAN predominava.

A partir de 1980 aparecem os computadores pessoais, supercomputadores, computação paralela, *cloud computation*, linguagens C, C₊, S e os pacotes estatísticos SPSS, BMDP, SAS, SPlus (que utiliza a linguagem S, desenvolvida por Chambers, do Bell Labs), MatLab etc. A partir de 1984 surge a linguagem R (que na realidade é basicamente a linguagem S com algumas modificações) e o repositório CRAN, de onde pacotes para análises estatísticas podem ser obtidos livremente; essa linguagem passa a ser a linguagem preferida dos estatísticos.

Métodos de AE não usualmente considerados em programas de graduação e pós-graduação em Estatística surgiram recentemente (na realidade não tão recentemente; veja a citação de Vapnik no início desse capítulo), estão atraindo a atenção de um público mais amplo e são englobados no que hoje chamamos de Ciência de Dados. Tais métodos incluem **Algoritmos de suporte vetorial** (*Support Vector Machines*), **Árvores de Decisão** (*Decision Trees*), **Florestas Aleatórias** (*Random Forests*), *Bagging*, *Boosting* etc. Outros métodos mais tradicionais que voltaram a estar em evidência, como **Redução da Dimensionalidade** (incluindo **Análise de Componentes Principais**, **Análise Fatorial**, **Análise de Componentes Independentes**) e **Análise de Agrupamentos** já fazem parte de métodos estudados em cursos de estatística.

1.5 Notação e tipos de dados

Vamos introduzir, agora, a notação usada no livro. Denotemos por \mathbf{X} , uma matriz com dimensão $n \times p$, contendo os dados; n indica o número de unidades amostrais (indivíduos, por exemplo) e p o número de variáveis. Especificamente,

$$\mathbf{X} = [x_{ij}] = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}.$$

As linhas de \mathbf{X} são denotadas por $\mathbf{x}_1, \dots, \mathbf{x}_n$, sendo que cada \mathbf{x}_i é um vetor com dimensão $p \times 1$. As colunas de \mathbf{X} são denotadas por $\mathbf{x}_1^*, \dots, \mathbf{x}_p^*$, sendo que cada \mathbf{x}_j^* é um vetor com dimensão $n \times 1$.

Então

$$\mathbf{X} = [\mathbf{x}_1^*, \mathbf{x}_2^*, \dots, \mathbf{x}_p^*] = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix}.$$

Também, denotemos por y_i a i -ésima componente do vetor $\mathbf{y} = (y_1, \dots, y_n)^\top$. No caso de AE supervisionado, y_i é a resposta aos preditores \mathbf{x}_i , num problema de regressão e corresponde ao rótulo da i -ésima classe, num problema de classificação. Consequentemente os dados são os pares $\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$.

Podemos ter as seguintes estruturas de dados:

- a) grande número de unidades amostrais e pequeno número de variáveis, $n \gg p$;
- b) pequeno número de unidades amostrais e grande número de variáveis, $p \gg n$;
- c) grande número de unidades amostrais e grande número de variáveis, n e p grandes.

Todos esses casos podem ser cognominados **megadados** (*big data*). Quando $n \ll p$, os dados têm **alta dimensão** (*high dimension*) e requerem procedimentos especiais. Por outro lado, megadados podem ser classificados como:

- a) **Dados estruturados**: em que a informação se ajusta às estruturas usuais de bases de dados, relativamente fáceis de armazenar e analisar. Exemplos usuais de dados numéricos ou não, que podem ser dispostos em matrizes de dados.
- b) **Dados não estruturados**: tudo o que não se encaixa no item anterior, como arquivos de textos, páginas da *web*, emails, mídias sociais etc.

Os megadados podem ser descritos pelos quatro V sugeridos em <http://www.ibmbigdatahub.com>, nomeadamente, **Volume** (escala dos dados), **Variedade** (formas diferentes de dados), **Velocidade** (análise de *streaming data*) e **Veracidade** (incerteza sobre os dados). Uma representação pictórica dessas estruturas de dados está apresentada na Figura 1.1.

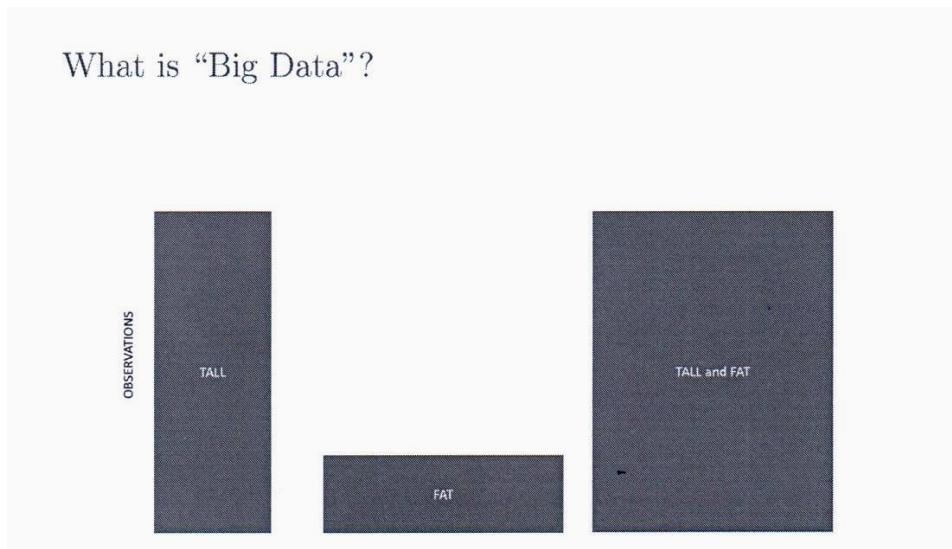


Figura 1.1: Estruturas de dados

Megadados implicam megamodelos, que contêm um grande número de parâmetros a serem estimados, como em modelos de regressão múltipla em que o número de variáveis, p , é grande. O ajuste modelos lineares a dados de alta dimensão pode ser tratado por meio técnicas de redução da dimensionalidade (ACP, AF, ACI), regularização ou métodos bayesianos. Para modelos não lineares, árvores de decisão e redes neurais são técnicas mais adequadas.

1.6 O modelo geral para o Aprendizado Estatístico

1.6.1 Regressão

Dados o vetor \mathbf{y} com os valores da variável resposta e a matriz \mathbf{X} com os correspondentes valores dos preditores, o modelo geral para regressão em AE supervisionado tem a forma

$$y_i = f(\mathbf{x}_i) + e_i, \quad i = 1, \dots, n, \quad (1.3)$$

com $E(e_i) = 0$ e f denotando uma função desconhecida, chamada de **informação sistemática**. O objetivo do AE é encontrar métodos para estimar f .

Estimada f , podemos usar o modelo (1.3) para fazer previsões ou inferência sobre a população de onde os dados foram extraídos. O **previsor**

de y_i é $\hat{y}_i = \hat{f}(\mathbf{x}_i)$ e a acurácia de $\hat{\mathbf{y}}$ como previsor de \mathbf{y} depende dos seguintes dois erros (James et al., 2017):

- a) **erro redutível**, introduzido pelo previsor de f ; assim chamado porque podemos melhorar a acurácia de \hat{f} usando técnicas de AE mais apropriadas;
- b) **erro irredutível**, que depende de e_i e não pode ser previsto por \mathbf{X} , mesmo usando o melhor previsor de f .

Supondo \hat{f} e \mathbf{X} fixos, pode-se verificar que

$$\begin{aligned} E(y_i - \hat{y}_i)^2 &= E[f(\mathbf{x}_i) + e_i - \hat{f}(\mathbf{x}_i)]^2 \\ &= E[f(\mathbf{x}_i) - \hat{f}(\mathbf{x}_i)]^2 + \text{Var}(e_i), \end{aligned} \quad (1.4)$$

para $i = 1, \dots, n$. O primeiro termo do segundo membro de (1.4) mede o efeito do erro redutível e o segundo termo, o efeito do erro irredutível. Consequentemente, o objetivo é minimizar o primeiro.

Para estimar f podemos usar **métodos paramétricos** ou **métodos não paramétricos**.

No primeiro caso, fazemos alguma suposição sobre a forma de f como no modelo de regressão múltipla usual com p variáveis. Nesse caso, o problema é mais simples, pois temos que estimar um número finito de parâmetros. Selecionado o modelo, devemos ajustá-lo aos dados de treinamento, ou seja, devemos **treinar** o modelo. No caso de modelos de regressão, o método mais usado na estimação é o de Mínimos Quadrados (MQ) mas há outros métodos disponíveis, como SVM (support vector machines). O ajuste de um modelo de regressão por MQ, por exemplo, pode ser pobre, como no Exemplo 6.7 do Capítulo 6 (veja a Figura 6.22). Nesse caso, pode-se tentar ajustar modelos mais flexíveis, escolhendo outras formas funcionais para f , incluindo aí modelos não lineares. Todavia, modelos mais flexíveis envolvem a estimação de um número muito grande de parâmetros, o que pode gerar um problema de sobreajuste (*overfitting*).

No segundo caso, não fazemos nenhuma hipótese sobre a forma funcional de f e como o problema envolve a estimação de grande número de parâmetros, necessitamos um número grande de observações para obter estimadores acurados de f . Vários métodos podem ser usados com essa finalidade, dentre os quais destacamos aqueles que utilizam:

- kernels;
- polinômios locais (*e.g.*, Lowess)
- splines
- polinômios ortogonais (*e.g.*, Chebyshev)
- outras bases ortogonais (*e.g.*, Fourier, ondaletas)

Métodos menos flexíveis (*e.g.*, regressão linear) ou mais restritivos em geral são menos acurados e mais fáceis de interpretar. Por outro lado, métodos mais flexíveis (*e.g.*, splines) são mais acurados e mais difíceis de interpretar. Para cada conjunto de dados, um método pode ser preferível a outros, dependendo do objetivo da análise. A escolha do método talvez seja a parte mais difícil do AE.

No caso de modelos de regressão, a medida mais usada para avaliação da qualidade do ajuste é o **Erro Quadrático Médio** (*Mean Squared Error*, MSE), definido por

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n [(y_i - \hat{f}(\mathbf{x}_i))^2], \quad (1.5)$$

em que $\hat{f}(\mathbf{x}_i)$ é o preditor de y para a i -ésima observação. Outra medida comumente utilizada para avaliar o ajuste de modelos de previsão é a **raiz quadrada** do erro quadrático médio (*Root Mean Squared Error*, RMSE). O erro quadrático médio calculado no conjunto de treinamento que produz \hat{f} é chamado **erro quadrático médio de treinamento**. Em geral, estamos mais interessados na acurácia do ajuste para os dados de teste e nesse caso podemos calcular o **erro quadrático médio de teste**,

$$\text{Média}[(y_0 - \hat{f}(\mathbf{x}_0))^2], \quad (1.6)$$

que é o erro de previsão quadrático médio para as observações do conjunto de dados de teste, em que o elemento típico é denotado por (\mathbf{x}_0, y_0) . A ideia é ajustar diferentes modelos aos dados de treinamento, obtendo diferentes estimativas \hat{f} por meio da minimização de (1.5), calcular o correspondente MSE de teste via (1.6) e escolher o modelo para o qual esse valor seja mínimo. Muitas vezes, usa-se **validação cruzada** (VC) nesse processo (veja a Nota de Capítulo 2 do Capítulo 8).

Para os dados do conjunto de teste, (\mathbf{x}_0, y_0) ,

$$\text{E}[y_0 - \hat{f}(\mathbf{x}_0)]^2 = \text{Var}[\hat{f}(\mathbf{x}_0)] + [\text{Vies}(\hat{f}(\mathbf{x}_0))]^2 + \text{Var}(e_0). \quad (1.7)$$

Em resumo, procuramos selecionar o modelo que produza simultaneamente baixo viés e baixa variância que atuam em sentidos opostos. Na prática, podemos estimar (1.7) para os dados do conjunto de teste por meio de (1.6). Também é possível estimar $\text{Var}[\hat{f}(\mathbf{x}_0)]$, mas como f é desconhecida não há como estimar o viés de $\hat{f}(\mathbf{x}_0)$ dado que $\text{Var}(e_0)$ também não é conhecida. Em geral, métodos de AE mais flexíveis têm viés baixo e variância grande. Na maioria dos casos, o MSE de treinamento é menor que o MSE de teste e o gráfico do MSE de teste em função do número de parâmetros de diferentes modelos, em geral, apresenta uma forma de U, resultante da competição entre viés e variância.

1.6.2 Classificação

Problemas de **classificação** são aqueles em que as respostas y_1, \dots, y_n são qualitativas. Formalmente, seja (\mathbf{x}, y) , com $\mathbf{x} \in \mathbb{R}^p$ e $y \in \{-1, 1\}$. Um

classificador é uma função $g : \mathbb{R}^p \rightarrow \{-1, 1\}$ e a **função erro** ou **risco** é a probabilidade de erro, $L(g) = P\{g(X) \neq Y\}$.

Obtendo-se um estimador de g , digamos \hat{g} , sua acurácia pode ser medida pelo estimador de $L(g)$, chamado de **taxa de erro de treinamento**, que é a proporção de erros gerados pela aplicação de \hat{g} às observações de treinamento, ou seja,

$$\hat{L}(\hat{g}) = \frac{1}{n} \sum_{i=1}^n I(y_i \neq \hat{y}_i), \quad (1.8)$$

O interesse está na **taxa de erro de teste**

$$\text{Média}[I(y_0 \neq \hat{y}_0)], \quad (1.9)$$

para as observações de teste (\mathbf{x}_0, y_0) . Um bom classificador tem (1.9) pequeno. Pode-se provar que (1.9) é minimizado, em média, por um classificador que associa cada observação à classe mais provável, dados os preditores; ou seja, por aquele que maximiza

$$P(y = j | \mathbf{x} = \mathbf{x}_0). \quad (1.10)$$

Tal classificador é chamado de **classificador de Bayes**.

No caso de duas classes, a ideia é classificar a observação teste na classe -1 se $P(y = -1 | \mathbf{x} = \mathbf{x}_0) > 0,5$ ou na classe 1, em caso contrário. O classificador de Bayes produz a menor taxa de erro, dada por $1 - \max_j P(y = j | \mathbf{x} = \mathbf{x}_0)$. A taxa de erro de Bayes global é $1 - E(\max_j P(y = j | \mathbf{x} = \mathbf{x}_0))$, em que $E(\cdot)$ é calculada sobre todos os valores de \mathbf{x} . O classificador de Bayes não pode ser calculado na prática, pois não temos conhecimento da distribuição condicional de y , dado \mathbf{x} . Uma alternativa é estimar a distribuição condicional e, então, estimar (1.10).

O classificador do *K*-ésimo vizinho mais próximo (*K*-nearest neighbors, *KNN*) estima tal distribuição por meio do seguinte algoritmo:

- i) Escolha $K > 0$ inteiro e uma observação teste \mathbf{x}_0 .
- ii) Identifique os K pontos do conjunto de treinamento mais próximos de \mathbf{x}_0 ; chame-os de \mathcal{N} .
- iii) Estime a probabilidade condicional da classe j por meio de

$$P(y = j | \mathbf{x} = \mathbf{x}_0) = \frac{1}{K} \sum_{i \in \mathcal{N}} I(y_i = j). \quad (1.11)$$

- iv) Classifique \mathbf{x}_0 na classe com a maior probabilidade condicional.

A escolha de K crucial e o resultado depende dessa escolha. Tratamos desse problema no Capítulo 10.

1.7 Este livro

Um dos maiores problemas oriundos da disseminação indiscriminada das técnicas utilizadas em CD é a confiança exagerada nos resultados obtidos da aplicação de algoritmos computacionais. Embora sejam essenciais em muitas situações, especialmente com megadados, sua utilização sem o concurso dos princípios do pensamento estatístico, fundamentado nas características de aleatoriedade e variabilidade inerentes a muitos fenômenos, pode gerar conclusões erradas ou não sustentáveis. Também lembramos que CD só faz sentido a partir de um problema em que as questões a serem respondidas estejam claramente especificadas.

Independentemente do volume de dados disponíveis para análise, Ciência de Dados é uma atividade multidisciplinar que envolve

- i) um problema a ser resolvido com questões claramente especificadas;
- ii) um conjunto de dados (seja ele volumoso ou não);
- iii) os meios para sua obtenção;
- iv) sua organização;
- v) a especificação do problema original em termos das variáveis desse conjunto de dados;
- vi) a descrição e resumo dos dados à luz do problema a ser resolvido;
- vii) a escolha das técnicas estatísticas apropriadas para a resolução desse problema;
- viii) os algoritmos computacionais necessários para a implementação dessas técnicas;
- ix) a apresentação dos resultados.

Obviamente, a análise de problemas mais simples pode ser conduzida por um estatístico (sempre em interação com investigadores da área em que o problema se insere). Em problemas mais complexos, especialmente aqueles com grandes conjuntos de dados que possivelmente contenham imagens, sons etc., só **uma equipe** com profissionais de diferentes áreas poderá atacá-los adequadamente. Em particular, essa equipe deve ser formada, pelo menos, por um profissional de alguma área do conhecimento em que o problema a ser resolvido se situa, por um estatístico, por um especialista em banco de dados, por um especialista em algoritmos computacionais e possivelmente por um profissional da área de comunicação. Se por um lado os aspectos computacionais são imprescindíveis nesse contexto, por outro, uma compreensão dos conceitos básicos de Estatística deve constar da formação de todos os membros da equipe.

Embora todos os aspectos envolvidos em Ciência dos Dados sejam abordados neste livro, o foco será na metodologia estatística necessária em qualquer análise, envolvendo a coleta, organização, resumo e análise dos dados. Para um melhor entendimento das técnicas apresentadas, em geral, usamos conjuntos de dados não muito volumosos, de modo que os leitores poderão re-analisá-los usando desde uma calculadora até programas sofisticados. Desde

que tenham acesso e aptidão para lidar com *software* adequado, os leitores não terão dificuldades em analisar grandes conjuntos de dados sob as mesmas perspectivas apresentadas no texto.

A (bem-vinda) popularização das técnicas utilizadas naquilo que se chama Ciéncia de Dados não está isenta de problemas. Nem sempre os profissionais que se aventuram por essa seara têm o conhecimento básico dos métodos estatísticos que fundamentam os algoritmos mais empregados na análise de dados. Nossa objetivo é preencher essa lacuna, apresentando conceitos e métodos da Análise Exploratória de Dados necessários para a análise de dados e indicando como são empregados nos problemas práticos com que “cientistas de dados” são usualmente desafiados. O Capítulo 2 é dedicado à preparação dos dados, geralmente obtidos de forma inadequada para análise. Os conceitos subjacentes a esses métodos são detalhados nos Capítulos 3 a 8. A utilização desses métodos no aprendizado estatístico supervisionado ou não é apresentada nos Capítulos 9 a 13.

O texto poderá ser utilizado em programas de bacharelado em Estatística (especialmente na disciplina de Estatística Descritiva com os capítulos 1 a 7 e na disciplina de Estatística Aplicada, com a inclusão dos capítulos restantes). Além disso, servirá para “cientistas de dados” que tenham interesse nos aspectos que fundamentam quaisquer análises de dados.

Embora muitos cálculos necessários para uma análise estatística possam ser concretizados por meio de calculadoras, o recurso a pacotes computacionais é necessário tanto para as análises mais sofisticadas quanto para análises extensas. Neste livro usaremos preferencialmente o repositório de pacotes estatísticos R, obtido livremente em *Comprehensive R Archive Network, CRAN*, no sítio

<http://CRAN.R-project.org>.

Dentre os pacotes estatísticos disponíveis na linguagem R, aqueles mais utilizados neste texto são: *adabag*, *caret*, *cluster*, *e1071*, *forecast*, *ggplot2*, *MASS*, *mgcv*, *nlme*, *randomForests*, *xgboost*. As funções de cada pacote necessárias para a realização das análises serão indicadas ao longo do texto.

Pacotes comerciais alternativos incluem SPlus, Minitab, SAS, MatLab etc.

1.8 Conjuntos de dados

Alguns conjuntos de dados analisados são dispostos ao longo do texto; outros são apresentados em formato Excel em arquivos disponíveis no formato

<http://www.ime.usp.br/~jmsinger/MorettinSinger/arquivo.xls>

Por exemplo, no sitio

<http://www.ime.usp.br/~jmsinger/MorettinSinger/coronarias.xls> encontramos uma planilha com dados de um estudo sobre obstrução coronariana; quando pertinentes, detalhes sobre as variáveis observadas no estudo

estarão na aba intitulada “descrição”; os dados estão dispostos na aba intitulada “dados”. Conjuntos de dados também poderão ser referidos por meio de seus endereços URL. Quando necessário, indicaremos os sítios em que se podem obter os dados utilizados nas análises.

Na Tabela 1.1 listamos os principais conjuntos de dados e uma breve descrição de cada um deles.

Tabela 1.1: Conjuntos de dados para alguns exemplos e exercícios do livro

Rótulo	Descrição
adesivo	Resistência de adesivos dentários
antracose	Dados sobre depósito de fuligem em pulmões
arvores	Concentração de elementos químicos em cascas de árvores
bezerros	Medida longitudinal de peso de bezerros
ceagfgv	Questionário respondido por 50 alunos da FGV-SP
coronarias	Fatores de risco na doença coronariana
cifose	Dados de crianças submetidas a cirurgia de coluna
disco	Deslocamento do disco temporomandibular
distancia	Distância para distinguir objeto em função da idade
empresa	Dados de funcionários de uma empresa
endometriose	Dados de um estudo sobre endometriose
endometriose2	Dados de um estudo sobre endometriose (1500 pacientes)
entrevista	Comparação intraobservadores em entrevista psicológica
esforco	Respostas de cardíacos em esteira ergométrica
esteira	Medidas obtidas em testes ergométricos (parcial)
figado	Relação entre volume e peso do lobo direito de fígados em transplantes intervivos
figadodiag	Medidas radiológicas e intraoperatórias de alterações anatômicas do fígado
hiv	Dados de sobrevivência de pacientes HIV
inibina	Utilização de inibina como marcador de reserva ovariana
iris	Medidas de comprimento e largura de pétalas e sépalas para três espécies de Iris: setosa, virgínica e versicolor
lactato	Concentração de lactato de sódio em atletas
manchas	Número de manchas solares
morfina	Dados de um estudo sobre concentração de morfina em cabelos
municipios	Populações dos 30 maiores municípios do Brasil
neonatos	Pesos de recém nascidos
palato	Dados de um estudo sobre efeito de peróxido de hidrogênio na em palatos de sapos
placa	Índice de remoção de placa dentária
poluicao	Concentração de poluentes em São Paulo
precipitacao	Precipitação em Fortaleza, CE, Brasil
producao	Dados hipotéticos de produção de uma empresa
profilaxia	pH da placa bacteriana sob efeito de enxaguatório
regioes	Dados populacionais de estados brasileiros
rehabcardio	Dados sobre reabilitação de pacientes de infartos
rotarod	Tempo com que ratos permanecem em cilindro rotativo
salarios	Salários de profissionais em diferentes países
sondas	Tempos de sobrevivência de pacientes de câncer com diferentes tipos de sondas
suicidios	Frequência de suicídios por enforcamento em São Paulo
temperaturas	Temperaturas mensais em Ubatuba e Cananéia
tipofacial	Classificação de tipos faciais
veiculos	Características de automóveis nacionais e importados
vento	Velocidade do vento no aeroporto de Philadelphia

1.9 Notas do Capítulo

- 1) Apresentamos, a seguir, a primeira página do artigo de Alan Turing, publicado na revista Mind, em 1950.

VOL. LIX. No. 236.] **[October, 1950]**

M I N D
A QUARTERLY REVIEW
OF
PSYCHOLOGY AND PHILOSOPHY

**I.—COMPUTING MACHINERY AND
INTELLIGENCE**

By A. M. TURING

1. *The Imitation Game.*

I PROPOSE to consider the question, ‘Can machines think?’ This should begin with definitions of the meaning of the terms ‘machine’ and ‘think’. The definitions might be framed so as to reflect so far as possible the normal use of the words, but this attitude is dangerous. If the meaning of the words ‘machine’ and ‘think’ are to be found by examining how they are commonly used it is difficult to escape the conclusion that the meaning and the answer to the question, ‘Can machines think?’ is to be sought in a statistical survey such as a Gallup poll. But this is absurd. Instead of attempting such a definition I shall replace the question by another, which is closely related to it and is expressed in relatively unambiguous words.

The new form of the problem can be described in terms of a game which we call the ‘imitation game’. It is played with three people, a man (A), a woman (B), and an interrogator (C) who may be of either sex. The interrogator stays in a room apart from the other two. The object of the game for the interrogator is to determine which of the other two is the man and which is the woman. He knows them by labels X and Y, and at the end of the game he says either ‘X is A and Y is B’ or ‘X is B and Y is A’. The interrogator is allowed to put questions to A and B thus:

C : Will X please tell me the length of his or her hair ?
Now suppose X is actually A, then A must answer. It is A’s

28 433

Downloaded from https://academic.oup.com/mind/article-abstract/LIX/236/433/986238 by Universidade de São Paulo - IO user on 21 February 2019

- 2) Apresentamos, abaixo, a primeira página do Projeto de IA de Dartmouth, publicado originalmente em 1955, e reproduzido na revista AI Magazine, de 2006.

AI Magazine Volume 27 Number 4 (2006) (© AAAI)
Articles

A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence

August 31, 1955

*John McCarthy, Marvin L. Minsky,
 Nathaniel Rochester,
 and Claude E. Shannon*

■ The 1956 Dartmouth summer research project on artificial intelligence was initiated by this August 31, 1955 proposal, authored by John McCarthy, Marvin Minsky, Nathaniel Rochester, and Claude Shannon. The original typescript consisted of 17 pages plus a title page. Copies of the typescript are housed in the archives at Dartmouth College and Stanford University. The first 5 papers state the proposal, and the remaining pages give qualifications and interests of the four who proposed the study. In the interest of brevity, this article reproduces only the proposal itself, along with the short autobiographical statements of the proposers.

guage, form abstractions and concepts, solve kinds of problems now reserved for humans, and improve themselves. We think that a significant advance can be made in one or more of these problems if a carefully selected group of scientists work on it together for a summer.

The following are some aspects of the artificial intelligence problem:

1. Automatic Computers

If a machine can do a job, then an automatic calculator can be programmed to simulate the machine. The speeds and memory capacities of present computers may be insufficient to simulate many of the higher functions of the human brain, but the major obstacle is not lack of machine capacity, but our inability to write programs taking full advantage of what we have.

2. How Can a Computer be Programmed to Use a Language

It may be speculated that a large part of human thought consists of manipulating words according to rules of reasoning and rules of conjecture. From this point of view, forming a generalization consists of admitting a new

We propose that a 2 month, 10 man study of artificial intelligence be carried out during the summer of 1956 at Dartmouth College in Hanover, New Hampshire. The study to proceed on the basis of the conjecture that every aspect of learning or any other feature of intelligence can in principle be so precisely described that a machine can be made to simulate it. An attempt will be made to find how to make machines use lan-

PARTE I: ANÁLISE EXPLORATÓRIA DE DADOS

A primeira parte deste texto é dedicada à discussão de alguns conceitos básicos, como distribuição de frequências, variabilidade e associação entre variáveis, além de métodos de resumo de dados por meio de tabelas e gráficos. Para efeito didático, discutimos separadamente os casos de uma, duas ou mais que duas variáveis. Consideramos técnicas de regressão, essenciais para o entendimento da associação entre uma ou mais variáveis explicativas e uma variável resposta. Nesse contexto, incluímos análise de sobrevivência, em que a variável resposta é o tempo até a ocorrência de um evento de interesse. Os conceitos e técnicas aqui abordados servem de substrato e são imprescindíveis para a compreensão e aplicação adequada das técnicas estatísticas de análise apresentadas nas Partes II e III.

CAPÍTULO 2

Preparação dos dados

A tarefa de converter observações em números é a mais difícil de todas, a última e não a primeira coisa a fazer, e pode ser feita somente quando você aprendeu bastante sobre as observações.

Lewis Thomas

2.1 Considerações preliminares

Em praticamente todas as áreas do conhecimento, dados são coletados com o objetivo de obtenção de informação. Esses dados podem representar uma população (como o censo demográfico) ou uma parte (amostra) dessa população (como aqueles oriundos de uma pesquisa eleitoral). Eles podem ser obtidos por meio de estudos observacionais (como aqueles em que se examinam os registros médicos de um determinado hospital), de estudos amostrais (como pesquisas de opinião) ou experimentais (como ensaios clínicos).

Mais comumente, os dados envolvem valores de várias variáveis, obtidos da observação de unidades de investigação que constituem uma amostra de uma população. A análise de dados amostrais possibilita que se faça inferência sobre a distribuição de probabilidades das variáveis de interesse, definidas sobre a população da qual a amostra foi (ao menos conceitualmente) colhida. Nesse contexto, a Estatística é uma ferramenta importante para organizá-los, resumi-los, analisá-los e utilizá-los para tomada de decisões. O ramo da Estatística conhecido como **Análise Exploratória de Dados** se ocupa da organização e resumo dos dados de uma amostra ou, eventualmente, de toda a população e o ramo conhecido como **Inferência Estatística** se refere ao processo de se tirar conclusões sobre uma população com base em uma amostra dela.

A abordagem estatística para o tratamento de dados envolve

- i) O planejamento da forma de coleta em função dos objetivos do estudo.
- ii) A organização de uma planilha para seu armazenamento eletrônico; no caso de megadados, a organização de um banco de dados (*data warehouse*) pode ser necessária (ver Nota de Capítulo 1).
- iii) O seu resumo por meio de tabelas e gráficos.

- iv) A identificação e correção de possíveis erros de coleta e/ou digitação.
- v) A proposta de modelos probabilísticos baseados na forma de coleta dos dados e nos objetivos do estudo; a finalidade desses modelos é relacionar a amostra (se for o caso) à população para a qual se quer fazer inferência.
- vi) A proposta de modelos estruturais para os parâmetros do modelo probabilístico com a finalidade de representar relações entre as características (variáveis) observadas.
- vii) A avaliação do ajuste do modelo aos dados por meio de técnicas de diagnóstico e/ou simulação.
- viii) A reformulação e reajuste do modelo à luz dos resultados do diagnóstico e/ou simulação.
- ix) A tradução dos resultados do ajuste em termos não técnicos.

O item i), por exemplo, pode ser baseado em uma hipótese formulada por um cientista. Numa tentativa de comprovar a sua hipótese, ele identifica as variáveis de interesse e planeja um experimento (preferencialmente com o apoio de um estatístico) para a coleta dos dados que serão armazenados numa planilha. Um dos objetivos deste livro é abordar detalhadamente os itens ii), iii), iv) e viii), que constituem a essência da Estatística Descritiva, com referências eventuais aos itens v), vi), vii), viii) e ix), que formam a base da Inferência Estatística. Esses itens servem de fundamento para as principais técnicas utilizadas em Ciência de Dados, cuja apresentação constitui outro objetivo do texto.

Exemplo 2.1: Se quisermos avaliar a relação entre o consumo (variável C) e renda (variável Y) de indivíduos de uma população, podemos escolher uma amostra¹ de n indivíduos dessa população e medir essas duas variáveis nesses indivíduos, obtendo-se o conjunto de dados $\{(Y_1, C_1), \dots, (Y_n, C_n)\}$.

Para saber se existe alguma relação entre C e Y podemos construir um gráfico de dispersão, colocando a variável Y no eixo das abscissas e a variável C no eixo das ordenadas. Obteremos uma nuvem de pontos no plano (Y, C) , que pode nos dar uma ideia de um **modelo** relacionando Y e C . No Capítulo 4 trataremos da análise de duas variáveis e, no Capítulo 6, estudaremos os chamados modelos de regressão, que são apropriados para o exemplo em questão. Em Economia, sabe-se, desde Keynes, que o gasto com o consumo de pessoas (C) é uma função da renda pessoal disponível (Y), ou seja

$$C = f(Y),$$

para alguma função f .

¹Em geral, a amostra deve ser obtida segundo alguns critérios que servirão para fundamentar os modelos utilizados na inferência; mesmo nos casos em que esses critérios não são seguidos, as técnicas abordadas neste texto podem ser utilizadas para o entendimento das relações entre as variáveis observadas. No Capítulo 3 definiremos formalmente o que se chama uma amostra aleatória simples retirada de uma população.

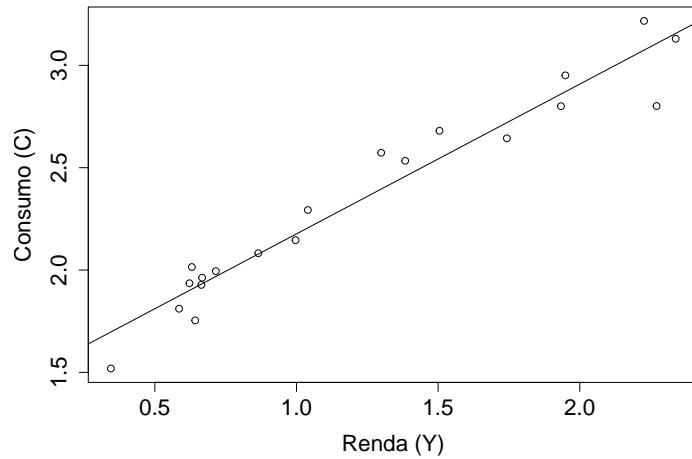


Figura 2.1: Relação entre renda e consumo de 20 indivíduos.

Para se ter uma ideia de como é a função f para essa comunidade, podemos construir um gráfico de dispersão entre Y e C . Com base em um conjunto de dados hipotéticos com $n = 20$, esse gráfico está apresentado na Figura 2.1 e é razoável postular o modelo

$$C_i = \alpha + \beta Y_i + e_i, \quad i = 1, \dots, n, \quad (2.1)$$

em que (Y_i, C_i) , $i = 1, \dots, n$ são os valores de Y e C efetivamente observados e e_i , $i = 1, \dots, n$ são variáveis não observadas, chamadas **erros**. No jargão econômico, o parâmetro α é denominado **consumo autônomo** e β representa a **propensão marginal a consumir**. A reta representada no gráfico foi obtida por meio dos métodos discutidos no Capítulo 6. Nesse caso, obtemos $\alpha = 1,44$ e $\beta = 0,73$, aproximadamente. Para diferentes comunidades (populações) poderemos ter curvas (modelos) diferentes para relacionar Y e C .

Exemplo 2.2: Os dados da Tabela 2.1 foram extraídos de um estudo realizado no Instituto de Ciências Biomédicas da Universidade de São Paulo com o objetivo de avaliar a associação entre a infecção de gestantes por malária e a ocorrência de microcefalia nos respectivos bebês. O dicionário das variáveis observadas está indicado na Tabela 2.1.

Tabela 2.1: Dicionário para as variáveis referentes ao Exemplo 2.2

Rótulos	Variável	Unidade de medida
id	identificador de paciente	
idade	Idade da mãe	anos
nmal	Quantidade de malárias durante a gestação	número inteiro
parasit	Espécie do parasita da malária	0: não infectada 1: P. vivax 2: P. falciparum 3: malária mista 4: indeterminado
ngest	Paridade (quantidade de gestações)	Número inteiro
idgest	Idade gestacional no parto	semanas
sexrn	Sexo do recém-nascido	1: masculino 2: feminino
pesorn	Peso do recém-nascido	g
estrn	Estatura do recém-nascido	cm
pcefal	Perímetro cefálico do recém-nascido	cm
Obs:	Observações omissas são representadas por um ponto	

A disposição dos dados do Exemplo 2.2 no formato de uma planilha está representada na Figura 2.2.²

Neste livro estamos interessados na análise de conjuntos de dados, que podem ser provenientes de populações, amostras ou de estudos observacionais. Para essa análise usamos tabelas, gráficos e diversas medidas de posição (localização), variabilidade e associação, com o intuito de resumir e interpretar os dados.

2.2 Planilhas de Dados

Planilhas (usualmente eletrônicas) são matrizes em que se armazena dados com o objetivo de permitir sua análise estatística. Em geral, cada linha da matriz de dados corresponde a uma unidade de investigação (*e.g.* unidade amostral) e cada coluna, a uma variável. Uma planilha bem elaborada contribui tanto para o entendimento do processo de coleta de dados e especificação das variáveis sob investigação quanto para a proposta de uma análise estatística adequada. A primeira etapa para a construção de uma planilha de dados consiste na elaboração de um dicionário com a especificação das variáveis, que envolve

²Note que representamos tabelas e planilhas de forma diferente. Planilhas são representadas no texto como figuras para retratar o formato com que são apresentadas nos *software* mais utilizados, como o **Excel**. Veja a Seção 2.2.

id	idade	nmal	parasit	ngest	idgest	sexrn	pesorn	estrn	pcefal
1	25	0	0	3	38	2	3665	46	36
2	30	0	0	9	37	1	2880	44	33
3	40	0	0	1	41	1	2960	52	35
4	26	0	0	2	40	1	2740	47	34
5	.	0	0	1	38	1	2975	50	33
6	18	0	0	.	38	2	2770	48	33
7	20	0	0	1	41	1	2755	48	34
8	15	0	0	1	39	1	2860	49	32
9	.	0	0	.	42	2	3000	50	35
10	18	0	0	1	40	1	3515	51	34
11	17	0	0	2	40	1	3645	54	35
12	18	1	1	3	40	2	2665	48	35
13	30	0	0	6	40	2	2995	49	33
14	19	0	0	1	40	1	2972	46	34
15	32	0	0	5	41	2	3045	50	35
16	32	0	0	8	38	2	3150	44	35
17	18	0	0	2	40	1	2650	48	33.5
18	18	0	0	1	41	1	3200	50	37
19	19	0	0	1	39	1	3140	48	32
20	18	0	0	2	40	1	3150	47	35
21	27	0	0	3	40	1	4185	52	35.5
22	26	0	0	3	40	2	4070	52	35
23	.	0	0	.	40	1	3950	50	37
24	19	0	0	1	40	1	3245	51	33
25	23	0	0	.	41	1	3010	49	35
26	.	0	0	.	40	2	3260	50	33
27	20	1	1	2	40	2	3450	49	33
28	19	0	0	3	40	2	2765	48	32
29	22	0	0	4	40	1	4190	50	34
30	32	0	0	4	42	2	4035	51	34
31	33	0	0	5	39	2	3620	51	33
32	30	3	3	5	38	1	3230	48	34
33	36	0	0	7	39	2	3185	50	38
34	.	0	0	.	39	2	2950	47	33

Figura 2.2: Planilha com dados referentes ao Exemplo 2.2.

- i) sua definição operacional (ver Nota de Capítulo 2);
- ii) a atribuição de rótulos (mnemônicos com letras minúsculas e sem acentos para facilitar a digitação e leitura por pacotes computacionais);
- iii) a especificação das unidades de medida ou definição de categorias; para variáveis categorizadas, convém atribuir valores numéricos às categorias com a finalidade de facilitar a digitação e evitar erros (veja a variável “Sexo do recém-nascido” na Tabela 2.1);
- iv) a atribuição de um código para valores omissos (*missing*);
- v) a indicação de como devem ser codificados dados abaixo do limite de detecção (*e.g.*, < 0,05 ou 0,025 se considerarmos que medidas abaixo

- do limite de detecção serão definidas como o ponto médio entre 0,00 e 0,05);
- vi) a especificação do número de casas decimais (correspondente à precisão do instrumento de medida) - ver Notas de Capítulo 3 e 4;
 - vii) quando possível, indicar limites (inferior ou superior) para facilitar a identificação de erros; por exemplo, o valor mínimo para aplicação num fundo de ações é de R\$ 2000,00;
 - viii) mascarar (por meio de um código de identificação, por exemplo) informações sigilosas ou confidenciais como o nome de pacientes de ensaios clínicos.

Algumas recomendações para a construção da planilha de dados são:

- i) não utilizar limitadores de celas (*borders*) ou cores;
- ii) reservar a primeira linha para os rótulos das variáveis;
- iii) não esquecer uma coluna para a variável indicadora das unidades de investigação (evitar informações confidenciais como nomes de pacientes); essa variável é útil para a correção de erros identificados na análise estatística além de servir como elo de ligação entre planilhas com diferentes informações sobre as unidades de investigação;
- iv) escolher ponto ou vírgula para separação de casas decimais³;
- v) especificar o número de casas decimais (ver Nota de Capítulo 3);
- vi) formatar as celas correspondentes a datas para manter a especificação uniforme (dd/mm/aaaa ou mm/dd/aaaa, por exemplo).

Exemplo 2.3: Na Tabela 2.2 apresentamos dados provenientes de um estudo em que o objetivo é avaliar a variação do peso (kg) de bezerros submetidos a uma determinada dieta entre 12 e 26 semanas após o nascimento.

Dados com essa natureza são chamados de dados longitudinais por terem a mesma característica (peso, no exemplo) medida ao longo de uma certa dimensão (tempo, no exemplo). De acordo com nossa especificação, há nove variáveis na Tabela 2.2, nomeadamente, Animal, Peso na 12a semana, Peso na 14a semana etc. Para efeito computacional, no entanto, esse tipo de dados deve ser disposto numa planilha com formato diferente (às vezes chamado de **formato longo**) como indicado na Figura 2.3. Nesse formato apropriado para dados longitudinais (ou mais geralmente, para medidas repetidas), há apenas três variáveis, a saber, Animal, Semana e Peso. Note que a mesma unidade amostral (animal) é repetida na primeira coluna para caracterizar a natureza longitudinal dos dados. Ele é especialmente adequado para casos em que as unidades de investigação são avaliadas em instantes diferentes.

Na Figura 2.4 apresentamos um exemplo em que o diâmetro da aorta (mm) de recém nascidos pré termo, com peso adequado (AIG) ou pequeno

³Embora a norma brasileira ABNT indique a vírgula para separação de casas decimais, a maioria dos pacotes computacionais utiliza o ponto com essa função; por essa razão é preciso tomar cuidado com esse detalhe na construção de planilhas a serem analisadas computacionalmente. Em geral adotaremos a norma brasileira neste texto.

Tabela 2.2: Peso de bezerros (kg)

animal	Semanas após nascimento							
	12	14	16	18	20	22	24	26
1	54.1	65.4	75.1	87.9	98.0	108.7	124.2	131.3
2	91.7	104.0	119.2	133.1	145.4	156.5	167.2	176.8
3	64.2	81.0	91.5	106.9	117.1	127.7	144.2	154.9
4	70.3	80.0	90.0	102.6	101.2	120.4	130.9	137.1
5	68.3	77.2	84.2	96.2	104.1	114.0	123.0	132.0
6	43.9	48.1	58.3	68.6	78.5	86.8	99.9	106.2
7	87.4	95.4	110.5	122.5	127.0	136.3	144.8	151.5
8	74.5	86.8	94.4	103.6	110.7	120.0	126.7	132.2
9	50.5	55.0	59.1	68.9	78.2	75.1	79.0	77.0
10	91.0	95.5	109.8	124.9	135.9	148.0	154.5	167.6
11	83.3	89.7	99.7	110.0	120.8	135.1	141.5	157.0
12	76.3	80.8	94.2	102.6	111.0	115.6	121.4	134.5
13	55.9	61.1	67.7	80.9	93.0	100.1	103.2	108.0
14	76.1	81.1	84.6	89.8	97.4	111.0	120.2	134.2
15	56.6	63.7	70.1	74.4	85.1	90.2	96.1	103.6

animal	semana	peso
1	12	54.1
1	14	65.4
:	:	:
1	24	124.2
1	26	131.3
2	12	91.7
2	14	104.0
:	:	:
2	26	176.8
:	:	:
15	12	56.6
:	:	:
15	26	103.6

Figura 2.3: Planilha computacionalmente adequada para os dados do Exemplo 2.3.

(PIG) para a idade gestacional foi avaliado até a 40a semana pós concepção. Note que o número de observações pode ser diferente para as diferentes unidades de investigação. Esse formato também é comumente utilizado para armazenar dados de **séries temporais**.

grupo	ident	sem	diam
AIG	2	30	7.7
AIG	2	31	8.0
:	:	:	:
AIG	2	36	9.8
AIG	12	28	7.1
AIG	12	29	7.1
:	:	:	:
AIG	12	30	9.4
:	:	:	:
PIG	17	33	7.5
PIG	17	34	7.7
PIG	17	36	8.2
PIG	29	26	6.3
PIG	29	27	6.5
:	:	:	:
PIG	29	31	7.2
PIG	29	32	7.2

Figura 2.4: Planilha com diâmetro da aorta (mm) observado em recém nascidos pré termo.

2.3 Construção de tabelas

A finalidade primordial de uma tabela é resumir a informação obtida dos dados. Sua construção deve permitir que o leitor entenda esse resumo sem a necessidade de recorrer ao texto. Algumas sugestões para construção de tabelas estão apresentadas a seguir.

- 1) Não utilize mais casas decimais do que o necessário para não mascarar as comparações de interesse. A escolha do número de casas decimais depende da precisão do instrumento de medida e/ou da importância prática dos valores representados. Para descrever a redução de peso após um mês de dieta, por exemplo, é mais conveniente representá-lo como 6 kg do que como 6,200 kg. Por outro lado, quanto mais casas decimais forem incluídas, mais difícil é a comparação. Por exemplo, compare a Tabela 2.3 com a Tabela 2.4.

Observe que calculamos porcentagens em relação ao total de cada linha. Poderíamos, também, ter calculado porcentagens em relação ao total de cada coluna ou porcentagens em relação ao total geral (50). Cada uma dessas maneiras pode ser útil em determinada situação; por exemplo, determinar se há alguma dependência entre as duas variáveis estado civil e bebida preferida, avaliada em 50 indivíduos.

Tabela 2.3: Número de alunos

Estado civil	Bebida preferida			Total
	não alcoólica	cerveja	outra alcoólica	
Solteiro	19 (53%)	7 (19%)	10 (28%)	36 (100%)
Casado	3 (25%)	4 (33%)	5 (42%)	12 (100%)
Outros	1 (50%)	0 (0%)	1 (50%)	2 (100%)
Total	23 (46%)	11 (22%)	16 (32%)	50 (100%)

Tabela 2.4: Número de alunos (e porcentagens com duas casas decimais)

Estado civil	Bebida preferida			Total
	não alcoólica	cerveja	outra alcoólica	
Solteiro	19 (52,78%)	7 (19,44%)	10 (27,78%)	36 (100,00%)
Casado	3 (25,00%)	4 (33,33%)	5 (41,67%)	12 (100,00%)
Outros	1 (50,00%)	0 (0,00%)	1 (50,00%)	2 (100,00%)
Total	23 (46,00%)	11 (22,00%)	16 (32,00%)	50 (100,00%)

- 2) Proponha um título autoexplicativo e inclua as unidades de medida. O título deve dizer o que representam os números do corpo da tabela e, em geral, não deve conter informações que possam ser obtidas diretamente dos rótulos de linhas e colunas. Compare o título da Tabela 2.5 com: Intenção de voto (%) por candidato para diferentes meses.
- 3) Inclua totais de linhas e/ou colunas para facilitar as comparações. É sempre bom ter um padrão contra o qual os dados possam ser avaliados.
- 4) Não utilize abreviaturas ou indique o seu significado no rodapé da tabela (*e.g.* Desvio padrão em vez de DP); se precisar utilizar duas linhas para indicar os valores da coluna correspondente.
- 5) Ordene colunas e/ou linhas quando possível. Se não houver impedimentos, ordene-as segundo os valores, crescente ou decrescentemente. Compare a Tabela 2.5 com a Tabela 2.6.

Tabela 2.5: Intenção de voto (%)

Candidato	janeiro	fevereiro	março	abril
Nononono	39	41	40	38
Nananana	20	18	21	24
Nenenene	8	15	18	22

Tabela 2.6: Intenção de voto (%)

Candidato	janeiro	fevereiro	março	abril
Nananana	20	18	21	24
Nononono	39	41	40	38
Nenenene	8	15	18	22

- 6) Tente trocar a orientação de linhas e colunas para melhorar a apresentação. Em geral, é mais fácil fazer comparações ao longo das linhas do que das colunas.
- 7) Altere a disposição e o espaçamento das linhas e colunas para facilitar a leitura. Inclua um maior espaçamento a cada grupo de linhas e/ou colunas em tabelas muito extensas.
- 8) Não analise a tabela descrevendo-a, mas sim comentando as principais tendências sugeridas pelos dados. Por exemplo, os dados apresentados na Tabela 2.3 indicam que a preferência por bebidas alcoólicas é maior entre os alunos casados do que entre os solteiros; além disso, há indicações de que a cerveja é menos preferida que outras bebidas alcoólicas, tanto entre solteiros quanto entre casados.

2.4 Construção de gráficos

A seguir apresentamos algumas sugestões para a construção de gráficos, cuja finalidade é similar àquela de tabelas, ou seja, resumir a informação obtida dos dados; por esse motivo, convém optar pelo resumo em forma de tabela ou de gráfico.

- 1) Proponha um título autoexplicativo.
- 2) Escolha o tipo de gráfico apropriado para os dados.
- 3) Rotule os eixos apropriadamente, incluindo unidades de medida.
- 4) Procure escolher adequadamente as escalas dos eixos para não distorcer a informação que se pretende transmitir. Se o objetivo for comparar as informações de dois ou mais gráficos, use a mesma escala.
- 5) Inclua indicações de “quebra” nos eixos para mostrar que a origem (zero) está deslocada.
- 6) Altere as dimensões do gráfico até encontrar o formato adequado.
- 7) Inclua uma legenda.
- 8) Tome cuidado com a utilização de áreas para comparações, pois elas variam com o quadrado das dimensões lineares.
- 9) Não exagere nas ilustrações que acompanham o gráfico para não o “poluir” visualmente, mascarando seus aspectos mais relevantes.

2.5 Notas de capítulo

1) Bancos de dados

Projetos que envolvem grandes quantidades de dados, em geral provenientes de diversas fontes e com diversos formatos necessitam a construção de bancos de dados (*data warehouses*), cuja finalidade é prover espaço suficiente para sua armazenagem, garantir sua segurança, permitir a inclusão por meio de diferentes meios e proporcionar uma interface que permita a recuperação da informação de forma estruturada para uso por diferentes pacotes de análise estatística.

Bancos de dados têm se tornado cada vez maiores e mais difíceis de administrar em função da crescente disponibilidade de sistemas analíticos em que os dados são oriundos de diferentes sistemas de transações. Em geral, esses bancos de dados envolvem a participação de profissionais de áreas e instituições diversas. Por esse motivo, os resultados de sua implantação são lentos e às vezes inexistentes. Conforme pesquisa elaborada pelo Grupo Gartner (2005), 50% dos projetos de bancos de dados tendem a falhar por problemas em sua construção. Uma das causas para esse problema, é o longo tempo necessário para o seu desenvolvimento, o que gera uma defasagem na sua operacionalidade. Muitas vezes, algumas de suas funcionalidades ficam logo obsoletas enquanto novas demandas estão sendo requisitadas. Duas razões para isso são a falta de sincronização entre os potenciais usuários e os desenvolvedores do banco de dados e o fato de que técnicas tradicionais usadas nesse desenvolvimento não permitem a rápida disponibilidade de suas funções. Para contornar esses problemas, sugere-se uma arquitetura modular cíclica em que o foco inicial é a criação dos principais elementos do sistema, deixando os detalhes das características menos importantes para uma segunda fase em que o sistema se torna operacional. No Módulo 1, são projetados os sistemas para inclusão e armazenagem dos dados provenientes de diferentes fontes. A detecção, correção de possíveis erros e homogeneização dos dados é realizada no Módulo 2. Como esperado, dados obtidos por diferentes componentes do projeto geralmente têm codificação distinta para os mesmos atributos, o que requer uniformização e possível indicação de incongruências que não podem ser corrigidas. No Módulo 3, os dados tratados no módulo anterior são atualizados e inseridos numa base de dados históricos, devidamente padronizada. Nesse módulo, a integridade dos dados recém obtidos é avaliada comparativamente aos dados já existentes para garantir a consistência entre eles. O foco do Módulo 4 é a visualização, análise e exportação dos dados. Esse módulo contém as ferramentas que permitem a geração de planilhas de dados apropriadas para a análise estatística.

Detalhes sobre a construção de bancos de dados podem ser encontrados em Rainardi (2008), entre outros. Para avaliar das dificuldades

de construção de um banco de dados num projeto complexo, o leitor poderá consultar Ferreira et al. (2017).

2) Definição operacional de variáveis

Para efeito de comparação entre estudos, a definição das variáveis envolvidas requer um cuidado especial. Por exemplo em estudos cujo objetivo é avaliar a associação entre renda e gastos com lazer, é preciso especificar se a variável “Renda” se refere à renda familiar total ou *per capita*, se benefícios como vale transporte, vale alimentação ou bônus estão incluídos etc. Num estudo que envolva a variável “Pressão arterial”, um exemplo de definição operacional é: “média de 60 medidas com intervalo de 1 minuto da pressão arterial diastólica (mmHg) obtida no membro superior direito apoiado à altura do peito com aparelho automático de método oscilométrico (Dixtal, São Paulo, Brasil)”. Num estudo cujo objetivo é comparar diferentes modelos de automóveis com relação ao consumo de combustível, uma definição dessa variável poderia ser “número de quilômetros percorridos em superfície plana durante 15 minutos em velocidade constante de 50 km/h e sem carga por litro de gasolina comum (km/L).”

Neste texto, não consideraremos definições detalhadas por razões didáticas.

3) Ordem de grandeza, precisão e arredondamento de dados quantitativos

A precisão de dados quantitativos contínuos está relacionada com a capacidade de os instrumentos de medida distinguirem entre valores próximos na escala de observação do atributo de interesse. O número de dígitos colocados após a vírgula indica a precisão associada à medida que estamos considerando. O volume de um certo recipiente expresso como 0,740 L implica que o instrumento de medida pode detectar diferenças da ordem de 0,001 L (= 1 mL, ou seja 1 mililitro); se esse volume for expresso na forma 0,74 L, a precisão correspondente será de 0,01 L (= 1 cL, ou seja 1 centilitro).

Muitas vezes, em função dos objetivos do estudo em questão, a expressão de uma grandeza quantitativa pode não corresponder à precisão dos instrumentos de medida. Embora com uma balança suficientemente precisa, seja possível dizer que o peso de uma pessoa é de 89,230 kg, para avaliar o efeito de uma dieta, o que interessa saber é a ordem de grandeza da perda de peso após três meses de regime, por exemplo. Nesse caso, saber se a perda de peso foi de 10,230 kg ou de 10,245 kg é totalmente irrelevante. Para efeitos práticos, basta dizer que a perda foi da ordem de 10 kg. A ausência de casas decimais nessa representação indica que o próximo valor na escala de interesse seria 11 kg, embora todos os valores intermediários com unidades de 1 g sejam mensuráveis.

Para efeitos contábeis, por exemplo, convém expressar o aumento das exportações brasileiras num determinado período como R\$ 1 657 235 458,29; no entanto, para efeitos de comparação com outros períodos, é mais conveniente dizer que o aumento das exportações foi da ordem de 1,7 bilhões de reais. Note que nesse caso, as grandezas significativas são aquelas da ordem de 0,1 bilhão de reais (= 100 milhões de reais).

Nesse processo de transformação de valores expressos com uma determinada precisão para outros com a precisão de interesse é preciso arredondar os números correspondentes. Em termos gerais, se o dígito a ser eliminado for 0, 1, 2, 3 ou 4, o dígito precedente não deve sofrer alterações e se o dígito a ser eliminado for 5, 6, 7, 8 ou 9, o dígito precedente deve ser acrescido de uma unidade. Por exemplo, se desejarmos reduzir para duas casas decimais números originalmente expressos com três casas decimais, 0,263 deve ser transformado para 0,26 e 0,267 para 0,27. Se desejarmos uma redução mais drástica para apenas uma casa decimal, tanto 0,263 quanto 0,267 devem ser transformados para 0,3.

É preciso tomar cuidado com essas transformações quando elas são aplicadas a conjuntos de números cuja soma seja prefixada (porcentagens, por exemplo) pois elas podem introduzir erros cumulativos. Discutiremos esse problema ao tratar de porcentagens e tabulação de dados. É interessante lembrar que a representação decimal utilizada nos EUA e nos países da comunidade britânica substitui a vírgula por um ponto. Cuidados devem ser tomados ao se fazerem traduções, embora em alguns casos, esse tipo de representação já tenha sido adotada no cotidiano (veículos com motor 2,0, por exemplo, são veículos cujo volume dos cilindros é de 2,0 L).

Finalmente, convém mencionar que embora seja conveniente apresentar os resultados de uma análise com o número de casas decimais conveniente, os cálculos necessários para sua obtenção devem ser realizados com maior precisão para evitar propagação de erros. O arredondamento deve ser concretizado ao final dos cálculos.

4) Proporções e porcentagens

Uma proporção é um quociente utilizado para comparar duas grandezas através da adoção de um padrão comum. Se 31 indivíduos, num total de 138, são fumantes, dizemos que a proporção de fumantes entre esses 138 indivíduos é de 0,22 (= 31/138). O denominador desse quociente é chamado de base e a interpretação associada à proporção é que 31 está para a base 138 assim como 0,22 está para a base 1,00. Essa redução a uma base fixa permite a comparação com outras situações em que os totais são diferentes. Consideremos, por exemplo, um outro conjunto de 77 indivíduos em que 20 são fumantes; embora o número de fumantes não seja comparável com o do primeiro grupo, dado que as bases são diferentes, pode-se dizer que a proporção de fumantes desse segundo grupo, 0,26 (= 20/77) é maior que aquela associada ao

primeiro conjunto.

Porcentagens, nada mais são do que proporções multiplicadas por 100, o que equivale a fazer a base comum igual a 100. No exemplo acima, podemos dizer que a porcentagem de fumantes é de 22% ($=100 \times 31/138$) no primeiro grupo e de 26% no segundo. Para efeito da escolha do número de casas decimais, note que a comparação entre essas duas porcentagens é mais direta do que se considerássemos suas expressões mais precisas (com duas casas decimais), ou seja 22,46% contra 25,97%.

A utilização de porcentagens pode gerar problemas de interpretação em algumas situações. A seguir consideramos algumas delas. Se o valor do IPTU de um determinado imóvel cobrado foi de R\$ 500,00 em 1998 e de R\$ 700,00 em 1999, podemos dizer que o valor do IPTU em 1999 é 140% ($= 100 \times 700/500$) do valor em 1998, mas o aumento foi de 40% [$= 100 \times (700-500)/500$]. Se o preço de uma determinada ação varia de R\$ 22,00 num determinado instante para R\$ 550,00 um ano depois, podemos dizer que o aumento de seu preço foi de 2400% [$= 100 \times (550-22)/22$] nesse período. É difícil interpretar porcentagens “grandes” como essa. Nesse caso é melhor dizer que o preço dessa ação é 25 ($= 550/22$) vezes seu preço há um ano. Porcentagens calculadas a partir de bases de pequena magnitude podem induzir conclusões inadequadas. Dizer que 43% dos participantes de uma pesquisa preferem um determinado produto tem uma conotação diferente se o cálculo for baseado em 7 ou em 120 entrevistados. É sempre conveniente explicitar a base relativamente à qual se estão fazendo os cálculos.

Para se calcular uma porcentagem global a partir das porcentagens associadas às partes de uma população, é preciso levar em conta sua composição. Suponhamos que numa determinada faculdade, 90% dos alunos que usam transporte coletivo sejam favoráveis à cobrança de estacionamento no campus e que apenas 20% dos alunos que usam transporte individual o sejam. A porcentagem de alunos dessa faculdade favoráveis à cobrança do estacionamento só será igual à média aritmética dessas duas porcentagens, ou seja 55%, se a composição da população de alunos for tal que metade usa transporte coletivo e metade não. Se essa composição for de 70% e 30% respectivamente, a porcentagem de alunos favoráveis à cobrança de estacionamento será de 69% ($= 0,9 \times 70\% + 0,2 \times 30\%$ ou seja, 90% dos 70% que usam transporte coletivo + 20% dos 30% que utilizam transporte individual). Para evitar confusão, ao se fazer referência a variações, convém distinguir porcentagem e ponto percentual. Se a porcentagem de eleitores favoráveis a um determinado candidato aumentou de 14% antes para 21% depois da propaganda na televisão, pode-se dizer que a preferência eleitoral por esse candidato aumentou 50% [$= 100 \times (21-14)/14$] ou foi de 7 pontos percentuais (e não de 7%). Note que o que diferencia esses dois enfoques é a base em relação à qual se calculam as porcentagens;

no primeiro caso, essa base é a porcentagem de eleitores favoráveis ao candidato antes da propaganda (14%) e no segundo caso é o total (não especificado) de eleitores avaliados na amostra (favoráveis ou não ao candidato).

Uma porcentagem não pode diminuir mais do que 100%. Se o preço de um determinado produto decresce de R\$ 3,60 para R\$ 1,20, a diminuição de preço é de 67% [$= 100 \times (3,60 - 1,20)/3,60$] e não de 200% [$= 100 \times (3,60 - 1,20)/1,20$]. Aqui também, o importante é definir a base: a ideia é comparar a variação de preço (R\$ 2,40) com o preço inicial do produto (R\$ 3,60) e não com o preço final (R\$ 1,20). Na situação limite, em que o produto é oferecido gratuitamente, a variação de preço é de R\$ 3,60; consequentemente, a diminuição de preço limite é de 100%. Note que se estivéssemos diante de um aumento de preço de R\$ 1,20 para R\$ 3,60, diríamos que o aumento foi de 200% [$= 100 \times (3,60 - 1,20)/1,20$]].

2.6 Exercícios

- 1) O objetivo de um estudo da Faculdade de Medicina da USP foi avaliar a associação entre a quantidade de morfina administrada a pacientes com dores intensas provenientes de lesões medulares ou radiculares e a dosagem dessa substância em seus cabelos. Três medidas foram realizadas em cada paciente, a primeira logo após o início do tratamento e as demais após 30 e 60 dias. Detalhes podem ser obtidos no documento intitulado “morfina.doc”, disponível no sítio

http:
[//www.ime.usp.br/~jmsinger/MorettinSinger/morfina.doc](http://www.ime.usp.br/~jmsinger/MorettinSinger/morfina.doc).

A planilha morphina.xls, disponível no sítio

http:
[//www.ime.usp.br/~jmsinger/MorettinSinger/morfina.xls](http://www.ime.usp.br/~jmsinger/MorettinSinger/morfina.xls),

foi entregue ao estatístico para análise e contém resumos de características demográficas além dos dados do estudo. Organize-a, construindo tabelas apropriadas para descrever essas características demográficas e uma planilha num formato apropriado para análise estatística.

- 2) A Figura 2.5 foi extraída de um relatório do Centro de Estatística Aplicada do IME/USP [ver Giampaoli et al. (2008) para detalhes]. Critique-a e reformule-a para facilitar sua leitura.
- 3) Utilize as sugestões para construção de planilhas apresentadas na Seção 2.2 com a finalidade de preparar os dados dos diferentes conjuntos do arquivo MorettinSingerDados.xls para análise estatística.

Sheet1

Subprefeitura	Observado	Ajustado	Nota SP
Aricanduva	0,586	0,588	0,396
Butantã	0,483	0,468	0,334
Campo Limpo	0,484	0,526	0,362
Casa Verde/Cachoeirinha	0,558	0,554	0,382
Cidade Tiradentes	0,543	0,540	0,369
Freguesia/Brasilândia	0,545	0,540	0,371
Ipiranga	0,593	0,539	0,368
Itaim Paulista	0,566	0,557	0,374
Itaquera	0,396	0,563	0,383
Jabaquara	0,533	0,533	0,364
M' Boi Mirim	0,566	0,552	0,368
São Mateus	0,523	0,511	0,354
São Miguel	0,601	0,583	0,395
Socorro	0,601	0,523	0,360
V, Prudente/Sapopemba	0,648	0,620	0,413

Figura 2.5: Tabela comparativa das notas médias da avaliação das subprefeituras no modelo padronizado para a escala [0,1]

- 4) A Figura 2.6 contém uma planilha encaminhada pelos investigadores responsáveis por um estudo sobre AIDS para análise estatística. Organize-a de forma a permitir sua análise por meio de um pacote computacional como o R.
- 5) Num estudo planejado para avaliar o consumo médio de combustível de veículos em diferentes velocidades foram utilizados 4 automóveis da marca A e 3 automóveis da marca B selecionados ao acaso das respectivas linhas de produção. O consumo (em L/km) de cada um dos 7 automóveis foi observado em 3 velocidades diferentes (40 km/h, 80 km/h e 110 km/h). Construa uma planilha apropriada para a coleta e análise estatística dos dados, rotulando-a adequadamente.
- 6) A planilha apresentada na Figura 2.7 contém dados de um estudo em que o limiar auditivo foi avaliado nas orelhas direita (OD) e esquerda (OE) de 13 pacientes em 3 ocasiões (Limiar, Teste 1 e Teste 2). Reformate-a segundo as recomendações da Seção 2.3.
- 7) Preencha a ficha de inscrição do Centro de Estatística Aplicada (www.ime.usp.br/~cea) com as informações de um estudo em que você está envolvido.

Grupo I	Tempo de			Ganho de Peso
registro	Diagnóstico	DST	MAC	por Semana
2847111D	pré natal	não	Pílula	11Kg em 37 semanas
3034048F	6 meses	não	pílula	?
3244701J	1 ano	não	Condon	?
2943791B	pré natal	não	não	8 Kg em 39 semanas
3000327F	4 anos	condiloma/ sífilis	não	9Kg em 39 semanas
3232893D	1 ano	não	DIU	3Kg em 39 semanas
3028772E	3 anos	não	não	3 kg em 38 semanas
3240047G	pré natal	não	pílula	9 Kg em 38 semanas
3017222G		HPV	CONDON	falta exame clínico
3015834J	2 anos	não	condon	14 Kg em 40 semanas
Grupo II	Tempo de			Ganho de Peso
registro	Diagnóstico	DST	MAC	por Semana
3173611E	3 meses	abscesso ovariano	condon	15 Kg em 40 semanas
3296159D	pré natal	não	condon	0 Kg em ? semanas
3147820D1	2 anos	não	sem dados	4 Kg em 37 semanas
3274750K	3 anos	não	condon	8 Kg em 38 semanas
3274447H	pré natal	sífilis com 3 meses	condon	
2960066D	5 anos	não	?	13 Kg em 36 semanas
3235727J	7 anos	não	Condon	(-) 2 Kg em 38 semanas
3264897E		condiloma	condon	nenhum Kg
3044120J	5 anos	HPV		3 Kg em 39 semanas 1

Figura 2.6: Planilha com dados de um estudo sobre AIDS.

Limiar	Teste1	Teste2
OD 50 / OE 55	OD/OE 50	OD/OE 80%
OD 41 /OE 40	OD 45/OE 50	OD 68% OE 80%
OD/OE 41,25	OD/OE 45	OD 64% OE 72%
OD 45/OE 43,75	OD 60/OE 50	OD 76%/OE 88%
OD51,25/ OE47,5	OD/OE 50	OD 80%/OE 88%
OD45/ OE 52,5	OD/OE 50	OD 84%/OE 96%
OD 52,5/OE 50	OD55/OE45	OD 40%/OE 28%
OD 42,15/OE48,75	OD 40/OE 50	OD80%/OE76%
OD50/ OE 48,75	OD/OE 50	OD 72%/OE 80%
OD47,5/OE46,25	OD/OE 50	OD/OE 84%
OD55/OE 56,25	OD55/OE60	OD80%/OE 84%
OD/OE 46,25	OD40/OE35	OD72%/OE 84%
OD 50/OE 47,5	OD/OE45	OD/OE 76%

Figura 2.7: Limiar auditivo de pacientes observados em 3 ocasiões.

CAPÍTULO 3

Análise de dados de uma variável

Você pode, certamente, ter um entendimento profundo da natureza por meio de medidas quantitativas, mas você deve saber do que está falando antes que comece a usar os números para fazer previsões.

Lewis Thomas

3.1 Introdução

Neste capítulo consideraremos a análise descritiva de dados provenientes da observação de uma variável. As técnicas utilizadas podem ser empregadas tanto para dados provenientes de uma população quanto para dados oriundos de uma amostra.

A ideia de uma análise descritiva de dados é tentar responder as seguintes questões:

- i) qual a frequência com que cada valor (ou intervalo de valores) aparece no conjunto de dados ou seja, qual a distribuição de frequências dos dados?
- ii) quais são alguns valores típicos do conjunto de dados, como mínimo e máximo?
- iii) qual seria um valor para representar a posição (ou localização) central do conjunto de dados?
- iv) qual seria uma medida da variabilidade ou dispersão dos dados?
- v) existem valores atípicos ou discrepantes (*outliers*) no conjunto de dados?
- vi) os dados podem ser considerados simétricos?

Nesse contexto, um dos objetivos da análise descritiva é organizar e exibir os dados de maneira adequada e para isso utilizamos

- i) gráficos e tabelas;

ii) medidas para resumo de dados.

As técnicas empregadas na análise descritiva dependem do tipo de variáveis que compõem o conjunto de dados em questão. Uma possível classificação de variáveis está representada na Figura 3.1.

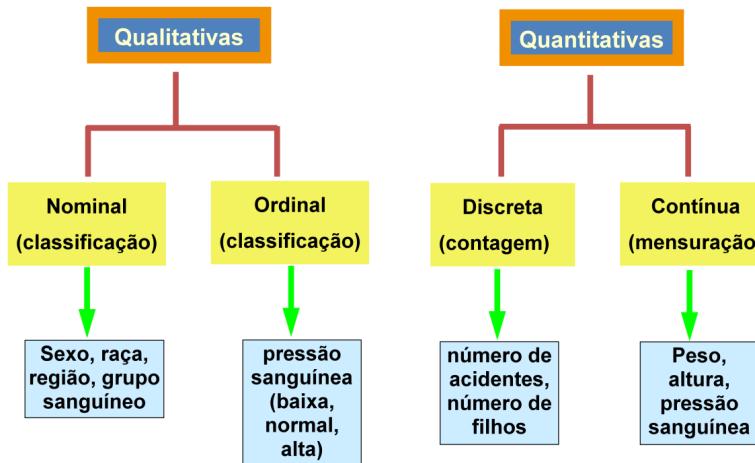


Figura 3.1: Classificação de variáveis.

Variáveis qualitativas são aquelas que indicam um atributo (não numérico) da unidade de investigação (sexo, por exemplo). Elas podem ser ordinais, quando há uma ordem nas diferentes categorias do atributo (tamanho de uma escola: pequena, média ou grande, por exemplo) ou nominais, quando não há essa ordem (região em que está localizada uma empresa: norte, sul, leste ou oeste, por exemplo).

Variáveis quantitativas são aquelas que exibem valores numéricos associados à unidade de investigação (peso, por exemplo). Elas podem ser discretas, quando assumem valores no conjunto dos números naturais (número de gestações de uma paciente) ou contínuas, quando assumem valores no conjunto dos números reais (tempo gasto por um atleta para percorrer 100 m, por exemplo). Ver Nota de Capítulo 1.

3.2 Distribuições de frequências

Exemplo 3.1: Consideremos um conjunto de dados como aquele apresentado na Tabela 3.1 obtido de um questionário respondido por 50 alunos de uma disciplina ministrado na Fundação Getúlio Vargas em São Paulo. Os dados estão disponíveis no arquivo `ceagfgv`.

Em geral, a primeira tarefa de uma análise estatística de um conjunto de dados consiste em resumir os dados. As técnicas disponíveis para essa finalidade dependem do tipo de variáveis envolvidas, tema que discutiremos a seguir.

Tabela 3.1: Dados de um estudo realizado na FGV

ident	Salário (R\$)	Fluência inglês	Anos de formado	Estado civil	Número de filhos	Bebida preferida
1	3500	fluente	12.0	casado	1	outra alcoólica
2	1800	nenhum	2.0	casado	3	não alcoólica
3	4000	fluente	5.0	casado	1	outra alcoólica
4	4000	fluente	7.0	casado	3	outra alcoólica
5	2500	nenhum	11.0	casado	2	não alcoólica
6	2000	fluente	1.0	solteiro	0	não alcoólica
7	4100	fluente	4.0	solteiro	0	não alcoólica
8	4250	algum	10.0	casado	2	cerveja
9	2000	algum	1.0	solteiro	2	cerveja
10	2400	algum	1.0	solteiro	0	não alcoólica
11	7000	algum	15.0	casado	1	não alcoólica
12	2500	algum	1.0	outros	2	não alcoólica
13	2800	fluente	2.0	solteiro	1	não alcoólica
14	1800	algum	1.0	solteiro	0	não alcoólica
15	3700	algum	10.0	casado	4	cerveja
16	1600	fluente	1.0	solteiro	2	cerveja
:	:	:	:	:	:	:
26	1000	algum	1.0	solteiro	1	outra alcoólica
27	2000	algum	5.0	solteiro	0	outra alcoólica
28	1900	fluente	2.0	solteiro	0	outra alcoólica
29	2600	algum	1.0	solteiro	0	não alcoólica
30	3200		6.0	casado	3	cerveja
31	1800	algum	1.0	solteiro	2	outra alcoólica
32	3500		7.0	solteiro	1	cerveja
33	1600	algum	1.0	solteiro	0	não alcoólica
34	1700	algum	4.0	solteiro	0	não alcoólica
35	2000	fluente	1.0	solteiro	2	não alcoólica
36	3200	algum	3.0	solteiro	2	outra alcoólica
37	2500	fluente	2.0	solteiro	2	outra alcoólica
38	7000	fluente	10.0	solteiro	1	não alcoólica
39	2500	algum	5.0	solteiro	1	não alcoólica
40	2200	algum	0.0	casado	0	cerveja
41	1500	algum	0.0	solteiro	0	não alcoólica
42	800	algum	1.0	solteiro	0	não alcoólica
43	2000	fluente	1.0	solteiro	0	não alcoólica
44	1650	fluente	1.0	solteiro	0	não alcoólica
45		algum	1.0	solteiro	0	outra alcoólica
46	3000	algum	7.0	solteiro	0	cerveja
47	2950	fluente	5.5	outros	1	outra alcoólica
48	1200	algum	1.0	solteiro	0	não alcoólica
49	6000	algum	9.0	casado	2	outra alcoólica
50	4000	fluente	11.0	casado	3	outra alcoólica

3.2.1 Variáveis qualitativas

Uma tabela contendo as frequências (absolutas e/ou relativas) de unidades de investigação para cada categoria do atributo avaliado por uma variável qualitativa é chamada de distribuição de frequências dessa variável. As Tabelas 3.2 e 3.3, por exemplo, representam respectivamente as distribuições de frequências das variáveis “Bebida preferida” e “Fluência em inglês” para os dados do Exemplo 3.1.

Tabela 3.2: Distribuição de frequências para a variável Bebida preferida correspondente ao Exemplo 3.1

Bebida preferida	Frequência observada	Frequência relativa (%)
não alcoólica	23	46
cerveja	11	22
outra alcoólica	16	32
Total	50	100

Tabela 3.3: Distribuição de frequências para a variável Fluência em inglês correspondente ao Exemplo 3.1

Fluência em inglês	Frequência observada	Frequência relativa (%)	Frequência acumulada (%)
nenhuma	2	4	4
alguma	26	54	58
fluente	20	42	100
Total	48		100

Obs: dois participantes não forneceram informação.

Note que para variáveis variáveis qualitativas ordinais pode-se acrescentar uma coluna com as frequências relativas acumuladas que são úteis na sua análise. Por exemplo a partir da última coluna da Tabela 3.3 pode-se afirmar que cerca de 60% dos alunos que forneceram a informação tem no máximo alguma fluência em inglês.

O resumo exibido nas tabelas com distribuições de frequências pode ser representado por meio de gráficos de barras ou gráficos do tipo pizza (ou torta). Exemplos correspondentes às variáveis “Bebida preferida” e “Fluência em inglês” são apresentados nas Figuras 3.2, 3.3 e 3.4.

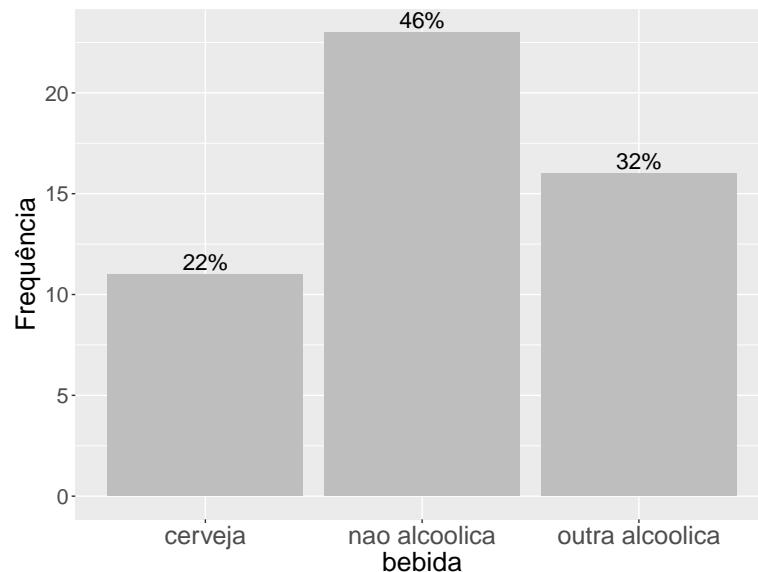


Figura 3.2: Gráfico de barras para Bebida preferida.

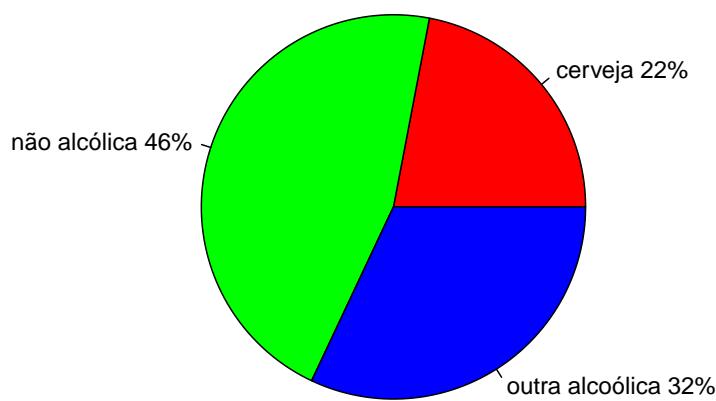


Figura 3.3: Gráfico tipo pizza para Bebida preferida.

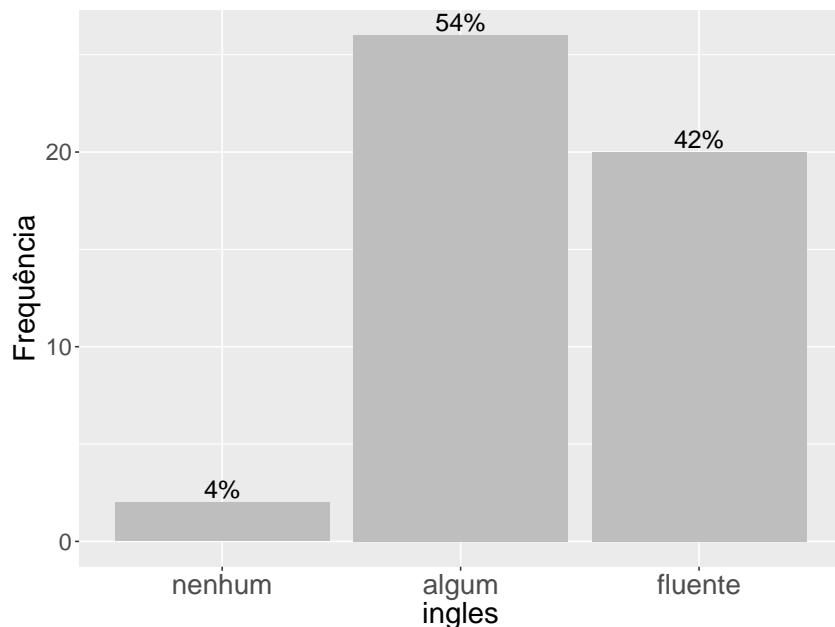


Figura 3.4: Gráfico de barras para Fluência em inglês.

Note que na Figura 3.2 as barras podem ser colocadas em posições arbitrárias; na Figura 3.4, convém colocá-las de acordo com a ordem natural das categorias.

3.2.2 Variáveis quantitativas

Se utilizássemos o mesmo critério adotado para variáveis qualitativas na construção de distribuições de frequências de variáveis quantitativas (especialmente no caso de variáveis contínuas), em geral obteríamos tabelas com frequência muito pequena (em geral 1) para as diversas categorias, deixando de atingir o objetivo de resumir os dados. Para contornar o problema, agrupam-se os valores das variáveis em classes e obtêm-se as frequências em cada classe.

Uma possível distribuição de frequências para a variável “Salário” correspondente ao Exemplo 3.1 está apresentada na Tabela 3.4.

Alternativamente a tabelas com o formato da Tabela 3.4 vários gráficos podem ser utilizados para representar a distribuição de frequências de um conjunto de dados. Os mais utilizados são apresentados a seguir.

Gráfico de dispersão unidimensional (*dotplot*)

Neste tipo de gráfico representamos os valores x_1, \dots, x_n por pontos ao longo de um segmento de reta provido de uma escala. Valores repetidos são empilhados, de modo que possamos ter uma ideia de sua distribuição. O gráfico de dispersão unidimensional para a variável Salário do Exemplo 3.1 está representado na Figura 3.5.

Tabela 3.4: Distribuição de frequências para a variável Salário correspondente ao Exemplo 3.1

Classe de salário (R%)	Frequência observada	Frequência relativa (%)	Frequência relativa acumulada (%)
0 ← 1500	6	12,2	12,2
1500 ← 3000	27	55,1	67,3
3000 ← 4500	12	24,5	91,8
4500 ← 6000	2	4,1	95,9
6000 ← 7500	2	4,1	100,0
Total	49	100,0	100,0

Obs: um dos participantes não informou o salário.

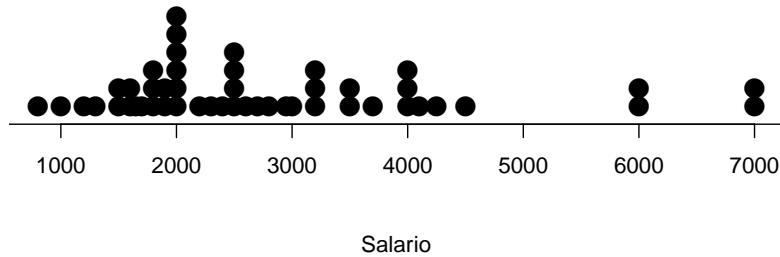


Figura 3.5: Gráfico de dispersão unidimensional para a variável Salário (Exemplo 3.1).

Gráfico Ramo e Folhas (*Stem and leaf*)

Um procedimento alternativo para reduzir um conjunto de dados sem perder muita informação sobre eles consiste na construção de um gráfico chamado ramo-e-folhas. Não há regras fixas para construí-lo, mas a ideia básica é dividir cada observação em duas partes: o **ramo**, colocado à esquerda de uma linha vertical, e a **folha**, colocada à direita.

Considere a variável “Salário” do Exemplo 3.1. Para cada observação, podemos considerar o ramo como sua parte inteira e a folha como sua parte decimal. Com esse procedimento, é fácil ver que obtemos muitos ramos, essencialmente tantos quantos são os dados e não teríamos alcançado o objetivo de resumir-los. Outra possibilidade é arredondar os dados para números inteiros e considerar o primeiro dígito como o ramo e o segundo como folha, no caso de dezenas; os dois primeiros dígitos como o ramo e o terceiro como folha, para as centenas, etc. O gráfico correspondente, apresentado na Figura 3.6 permite avaliar a forma da distribuição das observações; em particular, vemos que há quatro valores atípicos, nomeadamente, dois iguais

a R\$ 6000 (correspondentes aos alunos 22 e 49) e dois iguais a R\$ 7000 (correspondentes aos alunos 11 e 38) respectivamente.

```

1 | 2: representa 1200
unidade da folha: 100
n: 49

0 | 8
1 | 023
1 | 55666788899
2 | 000000234
2 | 55556789
3 | 0222
3 | 557
4 | 00012
4 | 5
5 |
5 |
6 | 00
6 |
7 | 00

```

Figura 3.6: Gráfico ramo-e-folhas para a variável Salário (R\$).

Histograma

O histograma é um gráfico construído a partir da distribuição de frequências dos dados e é composto de retângulos contíguos cuja área total é em geral normalizada para ter valor unitário. A **área** de cada retângulo corresponde à frequência relativa associada à classe definida por sua base.

Um histograma correspondente à distribuição de frequências indicada na Tabela 3.4 está representado na Figura 3.7.

Formalmente, dados os valores x_1, \dots, x_n de uma variável quantitativa X , podemos construir uma tabela contendo

- as frequências absolutas n_k , $k = 1, \dots, K$, que correspondem aos números de elementos cujos valores pertencem às classes $k = 1, \dots, K$;
- as frequências relativas $f_k = n_k/n$, $k = 1, \dots, K$, que são as proporções de elementos cujos valores pertencem às classes $k = 1, \dots, K$;
- as densidades de frequência $d_k = f_k/h_k$, $k = 1, \dots, K$, que representam as proporções de valores pertencentes às classes $k = 1, \dots, K$ por unidade de comprimento h_k de cada classe.

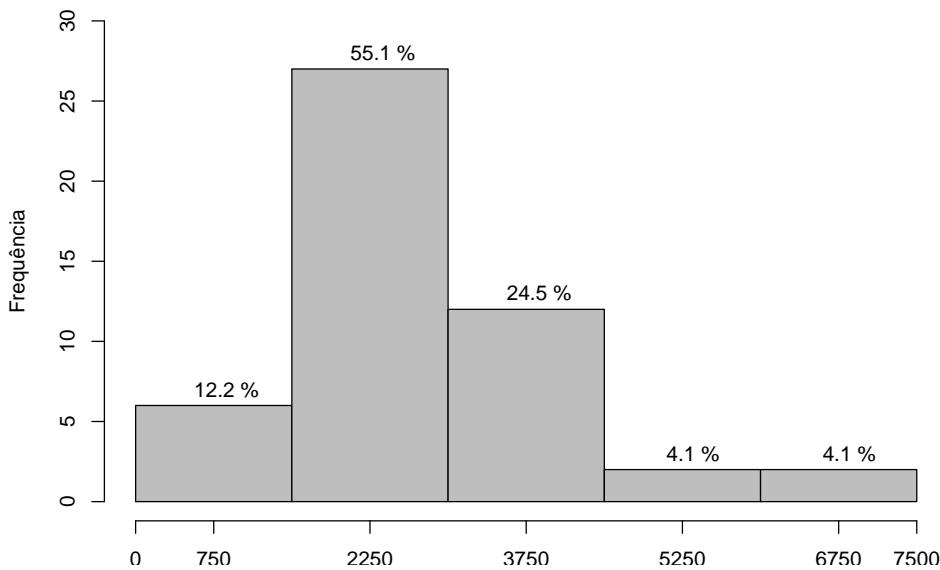


Figura 3.7: Histograma para a variável salário (R\$).

Exemplo 3.2: Os dados correspondentes à população¹ (em 10000 habitantes) de 30 municípios brasileiros (IBGE, 1996) estão dispostos na Tabela 3.5. Os dados estão disponíveis no arquivo `municípios`.

Ordenemos os valores da variável $X =$ população do município $i = 1, \dots, 30$ do menor para o maior e consideremos a primeira classe como aquela com limite inferior igual a 40 e a última com limite superior igual a 1000; para que as classes sejam disjuntas, tomemos por exemplo, intervalos semiabertos. A Tabela 3.6 contém a distribuição de frequências para a variável X . Observemos que as duas primeiras classes têm amplitudes iguais a 100, a terceira tem amplitude 50, a penúltima tem amplitude igual 350 e a última, amplitude igual a 400. Observemos que $K = 5$, $\sum_{k=1}^K n_k = n = 30$ e que $\sum_{k=1}^K f_k = 1$. Quanto maior for a densidade de frequência de uma classe, maior será a concentração de valores nessa classe.

O valor da amplitude de classes h deve ser escolhido de modo adequado. Se h for grande, teremos poucas classes e o histograma pode não mostrar detalhes importantes; por outro lado, se h for pequeno, teremos muitas classes e algumas poderão ser vazias. A escolha do número e amplitude das classes é arbitrária. Detalhes técnicos sobre a escolha do número de classes em casos específicos podem ser encontrados na Nota de Capítulo 2. Uma definição mais técnica de histograma está apresentada na Nota de Capítulo 3.

¹Aqui, o termo “população” se refere ao número de habitantes e é encarado como uma variável. Não deve ser confundido com população no contexto estatístico, que se refere a um conjunto (na maioria das vezes, conceitual) de valores de uma ou mais variáveis medidas. Podemos considerar, por exemplo, a população de pesos de pacotes de feijão produzidos por uma empresa.

Tabela 3.5: População de 30 municípios brasileiros (10000 habitantes)

Município	População	Município	População
São Paulo (SP)	988.8	Nova Iguaçu (RJ)	83.9
Rio de Janeiro (RJ)	556.9	São Luís (MA)	80.2
Salvador (BA)	224.6	Maceió (AL)	74.7
Belo Horizonte (MG)	210.9	Duque de Caxias (RJ)	72.7
Fortaleza (CE)	201.5	S. Bernardo do Campo (SP)	68.4
Brasília (DF)	187.7	Natal (RN)	66.8
Curitiba (PR)	151.6	Teresina (PI)	66.8
Recife (PE)	135.8	Osasco (SP)	63.7
Porto Alegre (RS)	129.8	Santo André (SP)	62.8
Manaus (AM)	119.4	Campo Grande (MS)	61.9
Belém (PA)	116.0	João Pessoa (PB)	56.2
Goiânia (GO)	102.3	Jaboatão (PE)	54.1
Guarulhos (SP)	101.8	Contagem (MG)	50.3
Campinas (SP)	92.4	S. José dos Campos (SP)	49.7
São Gonçalo (RJ)	84.7	Ribeirão Preto (SP)	46.3

Tabela 3.6: Distribuição de frequências para a $X =$ população em dezenas de milhares de habitantes

classes	h_k	n_k	f_k	$d_k = f_k/h_k$
00 ← 100	100	17	0,567	0,00567
100 ← 200	100	8	0,267	0,00267
200 ← 250	50	3	0,100	0,00200
250 ← 600	350	1	0,033	0,00010
600 ← 1000	400	1	0,033	0,00008
Total	—	30	1,000	—

O histograma da Figura 3.8 corresponde à distribuição de frequências da variável X do Exemplo 3.2, obtido usando a função `hist` do R. O gráfico de ramo-e-folhas para os dados da Tabela 3.5 está apresentado na Figura 3.9. Pelo gráfico podemos avaliar a forma da distribuição das observações; em particular, vemos que há dois valores atípicos, 556,9 e 988,8, correspondentes às populações do Rio de Janeiro e São Paulo, respectivamente.

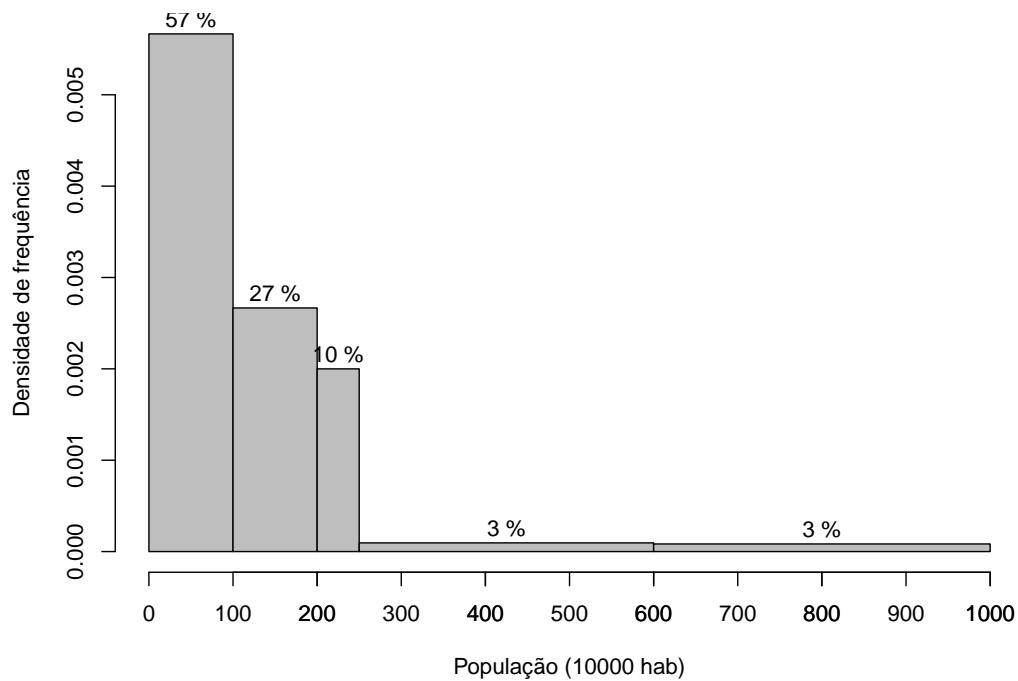


Figura 3.8: Histograma para a variável População (10000 habitantes).

1 | 2: representa 120
 unidade da folha: 10
 n: 30

```

0 | 44555666666778889
1 | 00112358
2 | 012
3 |
4 |
5 | 5
6 |
7 |
8 |
9 | 8
  
```

Figura 3.9: Gráfico ramo-e-folhas para a variável População (10000 habitantes).

Quando há muitas folhas num ramo, podemos considerar ramos subdivididos, como no exemplo a seguir.

Exemplo 3.3: Os dados disponíveis no arquivo `poluicao` correspondem à concentração atmosférica de poluentes ozônio O_3 e monóxido de carbono (CO) além de temperatura média e umidade na cidade de São Paulo entre 1 de janeiro e 30 de abril de 1991. O gráfico de ramo-e-folhas para a concentração de monóxido de carbono pode ser construído com dois ramos, colocando-se no primeiro folhas com dígitos de 0 a 4 e no segundo, folhas com dígitos de 5 a 9. Esse gráfico está apresentado na Figura 3.10

A separação decimal está em |

4	77
5	12
5	55677789
6	111112222222233333444444
6	5666677777899999999
7	00122233444
7	556677778888899999999
8	012334
8	55678999
9	0114
9	557
10	1333
10	8
11	4
11	69
12	0
12	5

Figura 3.10: Gráfico ramo-e-folhas para a variável CO (ppm).

3.3 Medidas resumo

Em muitas situações deseja-se fazer um resumo mais drástico de um determinado conjunto de dados, por exemplo, por meio de um ou dois valores. A renda per capita de um país ou a porcentagem de eleitores favoráveis a um candidato são exemplos típicos. Com essa finalidade podem-se considerar as chamadas medidas de posição (localização ou de tendência central), as medidas de dispersão e medidas de assimetria, entre outras.

3.3.1 Medidas de posição

As medidas de posição mais utilizadas são a média, a mediana, a média aparada e os quantis. Para defini-las, consideremos as observações x_1, \dots, x_n de uma variável X .

A **média aritmética** (ou simplesmente média) é definida por

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i. \quad (3.1)$$

No caso de dados agrupados numa distribuição de frequências de um conjunto com n valores, K classes e n_k valores na classe k , $k = 1, \dots, K$, a média pode ser calculada como

$$\bar{x} = \frac{1}{n} \sum_{k=1}^K n_k \tilde{x}_k = \sum_{k=1}^K f_k \tilde{x}_k, \quad (3.2)$$

em que \tilde{x}_k é o ponto médio correspondente à classe k e $f_k = n_k/n$. Essa mesma expressão é usada para uma variável discreta, com n_k valores iguais a x_k , bastando para isso, substituir com \tilde{x}_k por x_k .

A **mediana** é definida em termos das **estatísticas de ordem**, $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$ por

$$\text{md}(x) = \begin{cases} x_{(\frac{n+1}{2})}, & \text{se } n \text{ for ímpar,} \\ \frac{1}{2}[x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}], & \text{se } n \text{ for par.} \end{cases} \quad (3.3)$$

Dado um número $0 < \alpha < 1$, a **média aparada** de ordem α , $\bar{x}(\alpha)$ é definida como a média do conjunto de dados obtido após a eliminação das $100\alpha\%$ primeiras observações ordenadas e das $100\alpha\%$ últimas observações ordenadas do conjunto original. Uma definição formal é:

$$\bar{x}(\alpha) = \begin{cases} \frac{1}{n(1-2\alpha)} \{ \sum_{i=m+2}^{n-m-1} x_{(i)} + (1+m-n\alpha)[x_{(m+1)} + x_{(n-m)}] \}, & \text{se } m+2 \leq n-m+1 \\ \frac{1}{2}[x_{(m+1)} + x_{(n-m)}] & \text{em caso contrário.} \end{cases} \quad (3.4)$$

em que m é o maior inteiro menor ou igual a $n\alpha$, $0 < \alpha < 0,5$. Se $\alpha = 0,5$, obtemos a mediana. Para $\alpha = 0,25$ obtemos a chamada **meia média**. Observe que se $\alpha = 0$, $\bar{x}(0) = \bar{x}$.

Exemplo 3.4: Consideremos o seguinte conjunto com $n = 10$ valores de uma variável X : $\{14, 7, 3, 18, 9, 220, 34, 23, 6, 15\}$. Então, $\bar{x} = 34,9$, $\text{md}(x) = (14+15)/2 = 14,5$, e $\bar{x}(0,2) = [x_{(3)} + x_{(4)} + \dots + x_{(8)}]/6 = 14,3$. Note que se usarmos (3.4), temos $\alpha = 0,2$ e $m = 2$ obtendo o mesmo resultado. Se $\alpha = 0,25$, então de (3.4) obtemos

$$\bar{x}(0,25) = \frac{x_{(3)} + 2x_{(4)} + 2x_{(5)} + \dots + 2x_{(7)} + x_{(8)}}{10} = 14,2$$

Observe que a média é bastante afetada pelo valor atípico 220, ao passo que a mediana e a média aparada com $\alpha = 0,2$ não o são. Dizemos que essas duas últimas são **medidas resistentes** ou **robustas**.² Se substituirmos o

²Uma medida é dita resistente se ela muda pouco quando alterarmos um número pequeno dos valores do conjunto de dados.

valor 220 do exemplo por 2200, a média passa para 232,9 ao passo que a mediana e a média aparada $\bar{x}(0, 20)$ não se alteram.

As três medidas consideradas acima são chamadas de medidas de posição ou localização central do conjunto de dados. Para variáveis qualitativas também é comum utilizarmos outra medida de posição que indica o valor mais frequente, denominado **moda**. Quando há duas classes com a mesma frequência máxima, a variável (ou distribuição) é dita **bimodal**. A não ser que os dados de uma variável contínua sejam agrupados em classes, caso em que se pode considerar a **classe modal**, não faz sentido considerar a moda, pois em geral, cada valor da variável tem frequência unitária.

Quantis

Consideremos agora medidas de posição úteis para indicar posições não centrais dos dados. Informalmente, um quantil- p ou quantil de ordem p é **um valor da variável** (quando ela é contínua) ou **um valor interpolado entre dois valores da variável** (quando ela é discreta) que deixa $100p\%$ ($0 < p < 1$) das observações à sua esquerda. Formalmente, definimos o quantil- p empírico (ou simplesmente quantil) como

$$Q(p) = \begin{cases} x_{(i)}, & \text{se } p = p_i = (i - 0,5)/n, i = 1, \dots, n \\ (1 - f_i)Q(p_i) + f_iQ(p_{i+1}), & \text{se } p_i < p < p_{i+1} \\ x_{(1)}, & \text{se } 0 < p < p_1 \\ x_{(n)}, & \text{se } p_n < p < 1, \end{cases} \quad (3.5)$$

em que $f_i = (p - p_i)/(p_{i+1} - p_i)$. Ou seja, se p for da forma $p_i = (i - 0,5)/n$, o quantil- p coincide com a i -ésima observação ordenada. Para um valor p entre p_i e p_{i+1} , o quantil $Q(p)$ pode ser definido como sendo a ordenada de um ponto situado no segmento de reta determinado por $[p_i, Q(p_i)]$ e $[p_{i+1}, Q(p_{i+1})]$. Escolhemos p_i como acima (e não como i/n , por exemplo) de forma que se um quantil coincidir com uma das observações, metade dela pertencerá ao conjunto de valores à esquerda de $Q(p)$ e metade ao conjunto de valores à sua direita.

Os quantis amostrais para os dez pontos do Exemplo 3.4 estão indicados na Tabela 3.7. Com essa informação, podemos calcular outros quantis; por

Tabela 3.7: Quantis amostrais para os dados do Exemplo 3.4

i	1	2	3	4	5	6	7	8	9	10
p_i	0,05	0,15	0,25	0,35	0,45	0,55	0,65	0,75	0,85	0,95
$Q(p_i)$	3	6	7	9	14	15	18	23	34	220

exemplo, $Q(0,10) = [x_{(1)} + x_{(2)}]/2 = (3 + 6)/2 = 4,5$ com $f_1 = (0,10 - 0,05)/(0,10) = 0,5$, $Q(0,90) = [x_{(9)} + x_{(10)}]/2 = (34 + 220)/2 = 127$, pois $f_9 = 0,5$ e $Q(0,62) = [0,30 \times x_{(6)} + 0,70 \times x_{(7)}] = (0,3 \times 15 + 0,7 \times 18) = 17,1$ pois $f_6 = (0,62 - 0,55)/0,10 = 0,7$. Note que a definição (3.5) é compatível

com a definição de mediana apresentada anteriormente.

Os quantis $Q(0, 25)$, $Q(0, 50)$ e $Q(0, 75)$ são chamados **quartis** e usualmente são denotados por Q_1 , Q_2 e Q_3 , respectivamente. O quartil Q_2 é a mediana e a proporção dos dados entre Q_1 e Q_3 é 50%.

Outras denominações comumente empregadas são $Q(0, 10)$: primeiro decil, $Q(0, 20)$: segundo decil ou vigésimo percentil, $Q(0, 85)$: octogésimo-quinto percentil etc.

3.3.2 Medidas de dispersão

Duas medidas de dispersão (ou de escala ou de variabilidade) bastante usadas são obtidas tomando-se a média dos desvios das observações em relação à sua média. Considere as observações x_1, \dots, x_n , não necessariamente distintas. A **variância** desse conjunto de dados é definida por

$$\text{var}(x) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2. \quad (3.6)$$

No caso de uma tabela de frequências (com K classes), a expressão para cálculo da variância é

$$\text{var}(x) = \frac{1}{n} \sum_{k=1}^K n_k (\tilde{x}_k - \bar{x})^2 = \sum_{k=1}^K f_k (\tilde{x}_k - \bar{x})^2, \quad (3.7)$$

com a notação estabelecida anteriormente. Para facilitar os cálculos, convém substituir (3.6) pela expressão equivalente

$$\text{var}(x) = n^{-1} \sum_{i=1}^n x_i^2 - \bar{x}^2. \quad (3.8)$$

Analogamente, podemos substituir (3.7) por

$$\text{var}(x) = n^{-1} \sum_{k=1}^K f_k \tilde{x}_k^2 - \bar{x}^2. \quad (3.9)$$

Como a unidade de medida da variância é o quadrado da unidade de medida da variável correspondente, convém definir outra medida de dispersão que mantenha a unidade de medida original. Uma medida com essa propriedade é a raiz quadrada positiva da variância, conhecida por **desvio padrão**, denotado $\text{dp}(x)$.

Para garantir certas propriedades estatísticas úteis para propósitos de inferência, convém modificar as definições acima. Em particular, para garantir que a variância obtida de uma amostra de dados de uma população seja um **estimador não enviesado** da variância populacional basta definir a variância como

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (3.10)$$

em substituição à definição (3.6).

Um estimador (a variância amostral S^2 , por exemplo) de um determinado parâmetro (a variância populacional σ^2 , por exemplo) é dito não enviesado quando seu valor esperado é o próprio parâmetro que está sendo estimado. *Grosso modo*, se um conjunto “infinito” (aqui interpretado como muito grande) de for colhido da população sob investigação e para cada uma delas for calculado o valor desse estimador não enviesado, a média desses valores será o próprio parâmetro (ou estará bem próxima dele). Dizemos que o estimador S^2 tem $n - 1$ **graus de liberdade** pois “perdemos” um grau de liberdade ao estimar a média populacional μ por meio de \bar{x} , ou seja, dado o valor \bar{x} , só temos “liberdade” para escolher $n - 1$ valores da variável X , pois o último valor, digamos x_n , é obtido como $x_n = n\bar{x} - \sum_{k=1}^{n-1} x_i$.

Note que se n for grande (*e.g.*, $n = 100$) (3.10) e (3.6) têm valores praticamente iguais. Para detalhes, veja Bussab e Morettin (2014) entre outros.

Em geral, S^2 é conhecida por **variância amostral**. A **variância populacional** é definida como em (3.10) com o denominador $n - 1$ substituído pelo tamanho populacional N e a média amostral \bar{x} substituída pela média populacional μ . As fórmulas de cálculo acima podem ser modificadas facilmente com essa definição; o desvio padrão amostral é usualmente denotado por S .

O **desvio médio** ou **desvio absoluto médio** é definido por

$$\text{dm}(x) = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|. \quad (3.11)$$

Outra medida de dispersão bastante utilizada é a **distância interquartis** ou **amplitude interquartis**

$$d_Q = Q_3 - Q_1. \quad (3.12)$$

A distância interquartis pode ser utilizada para estimar o desvio padrão conforme indicado na Nota de Capítulo 4.

Podemos também considerar uma medida de dispersão definida em termos de desvios em relação à mediana. Como a mediana é uma medida robusta, nada mais natural que definir o **desvio mediano absoluto** como

$$\text{dma}(x) = \text{md}_{1 \leq i \leq n} |x_i - \text{md}(x)|, \quad (3.13)$$

Finalmente, uma medida correspondente à média aparada é a **variância aparada**, definida por

$$S^2(\alpha) = \begin{cases} \frac{c_\alpha}{n(1-2\alpha)} \left(\sum_{i=m+2}^{n-m-1} [x_{(i)} - \bar{x}(\alpha)]^2 + A \right), & m+2 \leq n-m+1 \\ \frac{1}{2} [(x_{(m+1)} - \bar{x}(\alpha))^2 + (x_{(n-m)} - \bar{x}(\alpha))^2], & \text{em caso contrário,} \end{cases} \quad (3.14)$$

em que

$$A = (1 + m - n\alpha)[(x_{(m+1)} - \bar{x}(\alpha))^2 + (x_{(n-m)} - \bar{x}(\alpha))^2],$$

m é como em (3.4) e c_α é uma constante normalizadora que torna $S^2(\alpha)$ um estimador não enviesado para σ^2 . Para n grande, $c_\alpha = 1,605$. Para amostras pequenas, veja a tabela da página 173 de Johnson e Leone (1964). Em particular, para $n = 10$, $c_\alpha = 1,46$.

A menos do fator c_α , a variância aparada pode ser obtida calculando-se a variância amostral das observações restantes, após a eliminação das $100\alpha\%$ iniciais e finais (com denominador $n - l$ em que l é o número de observações desprezadas).

Considere as observações do Exemplo 3.4. Para esse conjunto de dados as medidas de dispersão apresentadas são $S^2 = 4313,9$, $S = 65,7$, $\text{dm}(x) = 37,0$, $d_Q = 23 - 7 = 16$, $S^2(0,2) = 34,3$, $S(0,20) = 5,9$, e $\text{dma}(x) = 7,0$.

Observemos que as medidas robustas são, em geral, menores do que \bar{x} e S e que $d_Q/1,349 = 11,9$. Se considerarmos que esses dados constituem uma amostra de uma população com desvio padrão σ , pode-se mostrar que, $\text{dma}/0,6745$ é um estimador não enviesado para σ . A constante 0,6745 é obtida por meio de considerações assintóticas. No exemplo, $\text{dma}/0,6745 = 10,4$. Note que esses dois estimadores do desvio padrão populacional coincidem. Por outro lado, S é muito maior, pois sofre bastante influencia do valor 220. Retirando-se esse valor do conjunto de dados, a média dos valores restantes é 14,3 e o correspondente desvio padrão é 9,7.

Uma outra medida de dispersão, menos utilizada na prática é a **amplitude**, definida como $\max(x_1, \dots, x_n) - \min(x_1, \dots, x_n)$.

3.3.3 Medidas de assimetria

Embora sejam menos utilizadas na prática que as medidas de posição e dispersão, as medidas de assimetria (*skewness*) são úteis para identificar modelos probabilísticos para análise inferencial.

Na Figura 3.11 estão apresentados histogramas correspondentes a dados com assimetria positiva (ou à direita) ou negativa (ou à esquerda) e simétrico. O objetivo das medidas de assimetria é quantificar sua magnitude e, em geral, são baseadas na relação entre o segundo e o terceiro **momentos centrados**, nomeadamente

$$m_2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \quad \text{e} \quad m_3 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3.$$

Dentre as medidas de assimetria, as mais comuns são:

- a) o coeficiente de assimetria de Fisher-Pearson: $g_1 = m_3/m_2^{3/2}$
- b) o coeficiente de assimetria de Fisher-Pearson ajustado:

$$\frac{\sqrt{n(n-1)}}{n-1} \sum_{i=1}^n [(x_i - \bar{x})/\sqrt{m_2}]^3.$$

As principais propriedades desses coeficientes são

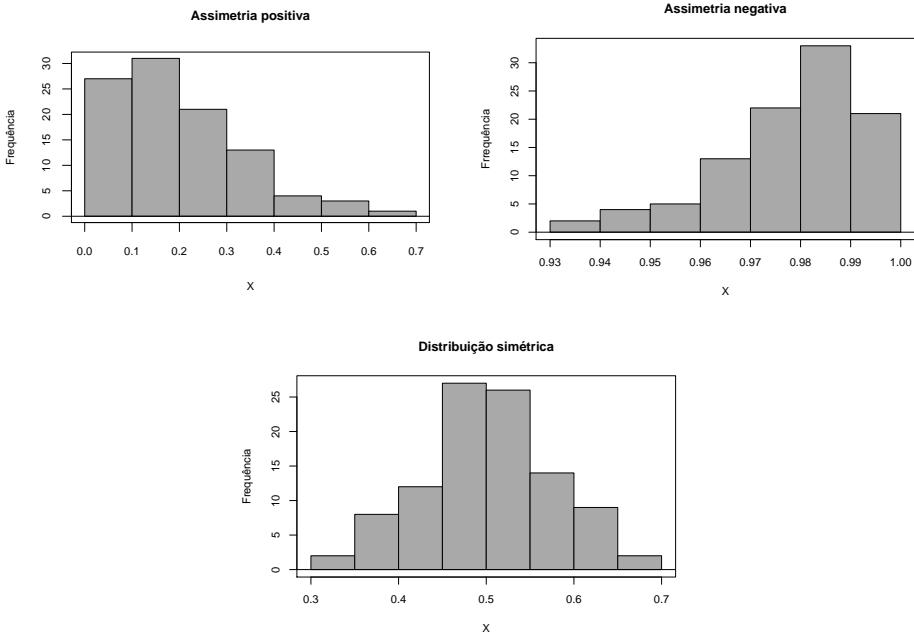


Figura 3.11: Histogramas com assimetria positiva e negativa e simétrico.

- seu sinal reflete a direção da assimetria;
- comparam a assimetria dos dados com aquela da distribuição Normal;
- valores mais afastados do zero indicam maiores magnitudes de assimetria e consequentemente, maior afastamento da distribuição Normal;
- a estatística indicada em b) tem um ajuste para o tamanho amostral;
- esse ajuste tem pequeno impacto em grandes amostras.

Outro coeficiente de assimetria mais intuitivo é o chamado Coeficiente de assimetria de Pearson 2,

$$Sk_2 = 3[\bar{x} - md(x)]/s.$$

A avaliação de assimetria também pode ser concretizada por meios gráficos. Em particular, o gráfico de $Q(p)$ versus p conhecido como **gráfico de quantis** é uma ferramenta importante para esse propósito.

A Figura 3.12 mostra o gráfico de quantis para os dados do Exemplo 3.2. Notamos que os pontos correspondentes a São Paulo e Rio de Janeiro são destacados. Além disso, se a distribuição dos dados for aproximadamente simétrica, a inclinação na parte superior do gráfico deve ser aproximadamente igual àquela da parte inferior, o que não acontece na figura em questão.

Os cinco valores $x_{(1)}, Q_1, Q_2, Q_3, x_{(n)}$, isto é, os extremos e os quartis, são medidas de localização importantes para avaliarmos a simetria dos dados.

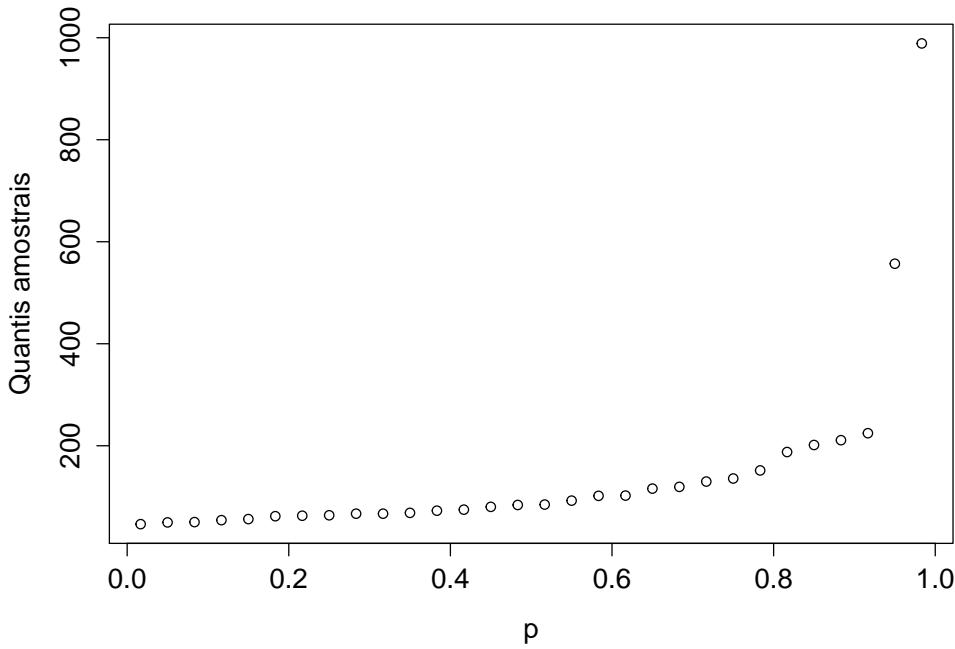


Figura 3.12: Gráfico de quantis para População (10000 habitantes).

Suponha uma distribuição simétrica (ou aproximadamente simétrica). Então,

- a) $Q_2 - x_{(1)} \approx x_{(n)} - Q_2$;
- b) $Q_2 - Q_1 \approx Q_3 - Q_2$;
- c) $Q_1 - x_{(1)} \approx x_{(n)} - Q_3$.

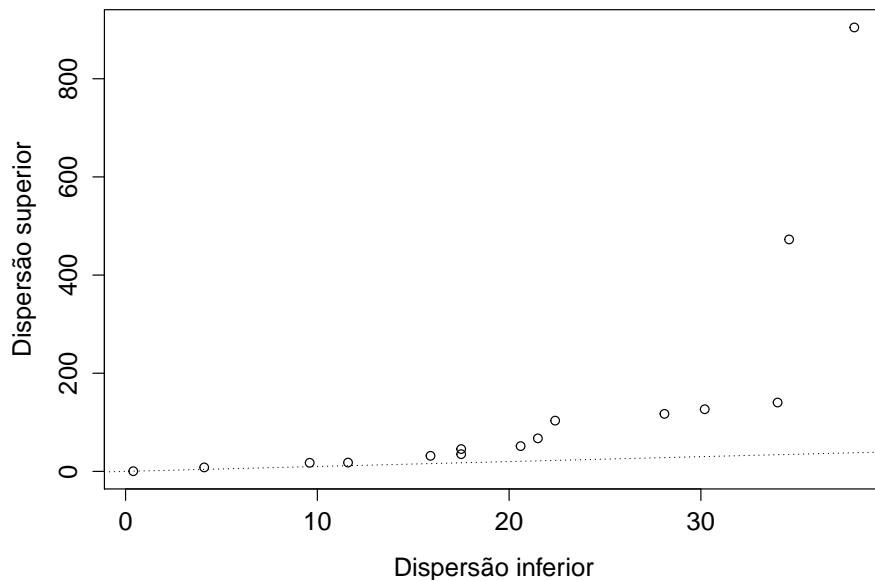
Para distribuições assimétricas à direita, as diferenças entre os quantis situados à direita da mediana e a mediana são maiores que as diferenças entre a mediana e os quantis situados à esquerda da mediana. A condição (a) nos diz que a **dispersão inferior** é igual (ou aproximadamente igual) à **dispersão superior**. Notamos, também, que se uma distribuição for (aproximadamente) simétrica, vale a relação

$$Q_2 - x_{(i)} = x_{(n+1-i)} - Q_2, \quad i = 1, \dots, [(n+1)/2], \quad (3.15)$$

em que $[x]$ representa o maior inteiro contido em x .

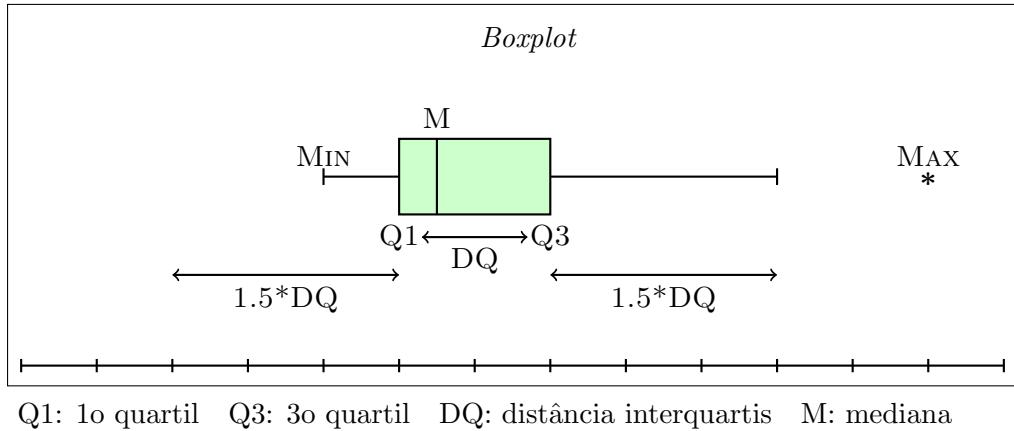
Chamando $u_i = Q_2 - x_{(i)}$, $v_i = x_{(n+1-i)} - Q_2$, podemos considerar um **gráfico de simetria**, no qual colocamos os valores u_i como abscissas e os valores v_i como ordenadas. Se a distribuição dos dados for simétrica, os pontos (u_i, v_i) deverão estar sobre (ou próximos) da reta $u = v$.

O gráfico de simetria para os dados do Exemplo 3.2 está apresentado a Figura 3.13, na qual podemos observar que a maioria dos pontos está acima da reta $u = v$, mostrando a assimetria à direita desses dados.



3.4 Boxplots

O *boxplot* é um gráfico baseado nos quantis que serve como alternativa ao histograma para resumir a distribuição dos dados. Considere um retângulo, com bases determinadas por Q_1 e Q_3 , como indicado na Figura 3.14. Nesse retângulo, insira um segmento de reta correspondente à posição da mediana. Considere dois segmentos de reta denominados bigodes (*whiskers*) colocados respectivamente acima e abaixo de Q_1 e Q_3 com limites dados, respectivamente por $\min[x_{(n)}, Q_3+1, 5*d_Q]$ e $\max[x_{(1)}, Q_1-1, 5*d_Q]$. Pontos colocados acima do limite superior ou abaixo do limite inferior, considerados **valores atípicos** ou **discrepantes** (*outliers*) são representados por algum símbolo (*, por exemplo).

Figura 3.14: Detalhes para a construção de *boxplots*.

Esse gráfico permite que identifiquemos a posição dos 50% centrais dos dados (entre o primeiro e terceiro quartis), a posição da mediana, os valores atípicos, se existirem, assim como permite uma avaliação da simetria da distribuição. *Boxplots* são úteis para a comparação de vários conjuntos de dados, como veremos em capítulos posteriores.

Os *boxplots* apresentados na Figura 3.15 correspondem aos dados do Exemplo 3.2 [painele (a)] e da Temperatura do Exemplo 3.3 [painele (b)].³ A distribuição dos dados de Temperatura tem uma natureza mais simétrica e mais dispersa do que aquela correspondente às populações de municípios. Há valores atípicos no painel (a), representando as populações do Rio de Janeiro e de São Paulo, mas não os encontramos nos dados de temperatura.

Há uma variante dos *boxplots*, denominada ***boxplot dentado*** (*notched boxplot*) que consiste em acrescentar um dente em “v” ao redor da mediana no gráfico. O intervalo determinado pelo dente, dado por

$$Q_2 \pm \frac{1,57d_Q}{\sqrt{n}}.$$

é um intervalo de confiança para a mediana da população da qual supomos que os dados constituem uma amostra. Para detalhes, veja McGill et al. (1978) ou Chambers et al. (1983). Na Figura 3.16 apresentamos *boxplots* correspondentes àqueles da Figura 3.15 com os dentes (*notches*) incorporados.

³Note que tanto a orientação horizontal (como na Figura 3.14) quanto a vertical (como na Figura 3.15) podem ser empregadas na construção dos *boxplots*.

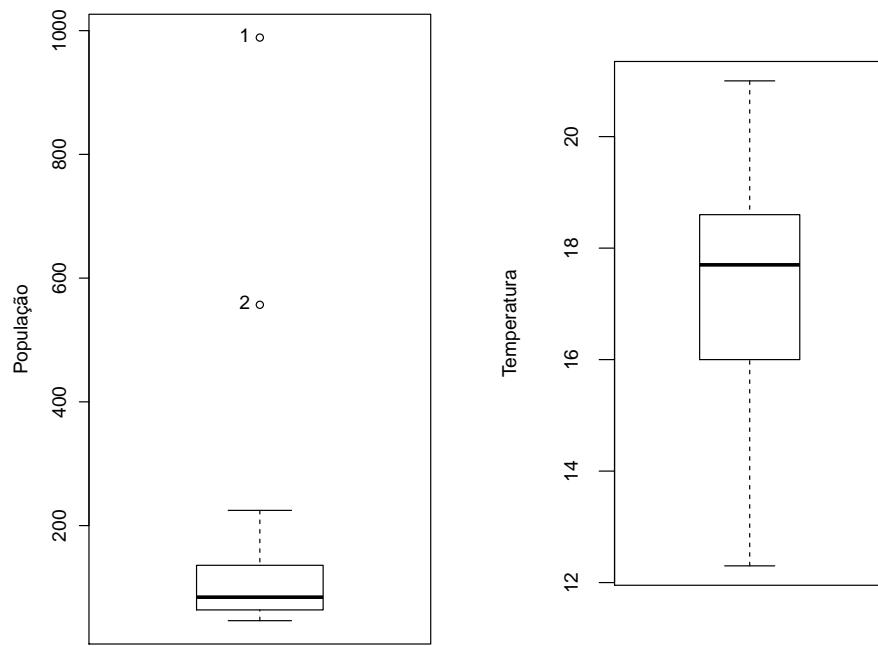


Figura 3.15: *Boxplots* para os dados dos Exemplos 3.2 (População) e 3.3 (Temperatura).

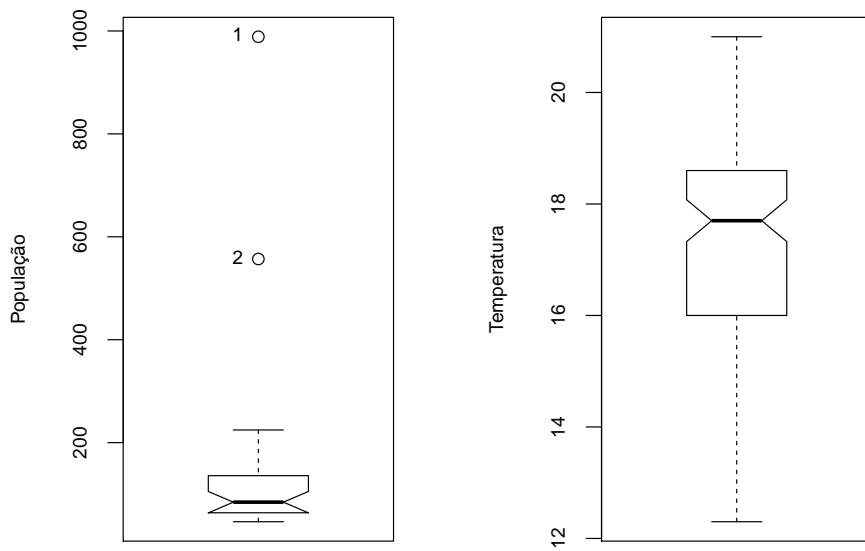


Figura 3.16: *Boxplots* dentados para os dados dos Exemplos 3.2 (População) e 3.3 (Temperatura).

3.5 Modelos probabilísticos

Um dos objetivos da Estatística é fazer inferência (ou tirar conclusões) sobre distribuições de variáveis em populações a partir de dados de uma parte dela, denominada **amostra**. A ligação entre os dados amostrais e a população depende de **modelos probabilísticos** ou seja, de modelos que representem a distribuição (desconhecida) da variável na população. Por exemplo, pode ser difícil obter informações sobre a distribuição dos salários de empregados de uma empresa com 40.000 empregados espalhados por diversos países. Nessa situação, costuma-se recorrer a uma amostra dessa população, obter as informações desejadas a partir dos valores amostrais e tentar tirar conclusões sobre toda a população a partir desses valores com base num modelo probabilístico. Esse procedimento é denominado **inferência estatística**. No exemplo acima, podemos escolher uma amostra de 400 empregados da empresa e analisar a distribuição dos salários dessa amostra.

Muitas vezes, a população para a qual se quer tirar conclusões é apenas conceitual e não pode ser efetivamente enumerada, como o conjunto de potenciais consumidores de um produto ou o conjunto de pessoas que sofrem de uma certa doença. Nesses casos, não se pode obter a correspondente distribuição de frequências de alguma característica de interesse associada a essa população e o recurso a modelos para essa distribuição faz-se necessário; esses são os chamados modelos probabilísticos e as frequências relativas correspondentes são denominadas probabilidades. Nesse sentido, o conhecido gráfico com formato de sino associado à distribuição Normal pode ser considerado como um histograma teórico. Por isso, convém chamar a média da distribuição de probabilidades (que no caso conceitual não pode ser efetivamente calculada) de **valor esperado**.

Se pudermos supor que a distribuição de probabilidades de uma variável X , definida sobre uma população possa ser representada por um determinado modelo probabilístico, nosso problema reduz-se a estimar os parâmetros que caracterizam esse modelo.

Há vários modelos probabilísticos importantes usados em situações de interesse prático. As Tabelas 3.8 e 3.9 trazem um resumo das principais distribuições discretas e contínuas, respectivamente apresentando:

- a) a **função de probabilidade** (f.p.) $p(x) = P(X = x)$, no caso discreto e a **função densidade de probabilidade** (f.d.p.), $f(x)$, no caso contínuo;
- b) os parâmetros que caracterizam cada distribuição;
- c) a média e a variância de cada uma delas.

Detalhes podem ser encontrados em Bussab e Morettin (2017) entre outros. Para muitas dessas distribuições, as probabilidades podem ser encontradas em tabelas apropriadas ou obtidas com o uso de programas de computador.

Tabela 3.8: Modelos probabilísticos para variáveis discretas

Modelo	$P(X = x)$	Parâmetros	$E(X), \text{Var}(X)$
Bernoulli	$p^x(1-p)^{1-x}, x = 0, 1$	p	$p, p(1-p)$
Binomial	$\binom{n}{x} p^x(1-p)^{n-x}, x = 0, \dots, n$	n, p	$np, np(1-p)$
Poisson	$\frac{e^{-\lambda} \lambda^x}{x!}, x = 0, 1, \dots$	λ	λ, λ
Geométrica	$p(1-p)^{x-1}, x = 1, 2, \dots$	p	$1/p, (1-p)/p^2$
Hipergeométrica	$\frac{\binom{r}{x} \binom{N-r}{n-x}}{\binom{N}{n}}, x = 0, 1, \dots$	N, r, n	$nr/N, n \frac{r}{N} (1 - \frac{r}{N}) \frac{N-n}{N-1}$

Tabela 3.9: Modelos probabilísticos para variáveis contínuas

Modelo	$f(x)$	Parâmetros	$E(X), \text{Var}(X)$
Uniforme	$1/(b-a), a < x < b$	a, b	$\frac{a+b}{2}, \frac{(b-a)^2}{12}$
Exponencial	$\alpha e^{-\alpha x}, x > 0$	α	$1/\alpha, 1/\alpha^2$
Normal	$\frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\left(\frac{x-\mu}{\sigma}\right)^2\right\}, -\infty < x < \infty$	μ, σ	μ, σ^2
Gama	$\frac{\alpha}{\Gamma(r)} (\alpha x)^{r-1} e^{-\alpha x}, x > 0$	$\alpha > 0, r \geq 1$	$r/\alpha, r/\alpha^2$
Qui-quadrado	$\frac{2^{-n/2}}{\Gamma(n/2)} x^{n/2-1} e^{-x/2}, x > 0$	n	$n, 2n$
t-Student	$\frac{\Gamma((n+1)/2)}{\Gamma(n/2)\sqrt{\pi n}} \left(1 + \frac{x^2}{n}\right)^{-(n+1)/2}, -\infty < x < \infty$	n	$0, n/(n-2)$

3.6 Dados amostrais

Uma amostra é um subconjunto de uma população e para que possamos fazer inferências, é preciso que ela satisfaça certas condições. O caso mais comum é o de uma amostra aleatória simples (AAS). Dizemos que um conjunto de observações x_1, \dots, x_n constitui uma **amostra aleatória simples** de tamanho n de uma variável X definida sobre uma população \mathcal{P} se as variáveis X_1, \dots, X_n que geraram as observações são independentes e têm a mesma distribuição de X . Como consequência, $E(X_i) = E(X)$ e $\text{Var}(X_i) = \text{Var}(X)$, $i = 1, \dots, n$.

Nem sempre nossos dados representam uma AAS de uma população. Por exemplo, dados observados ao longo de um certo período de tempo são, em geral, correlacionados. Nesse caso, os dados constituem uma amostra de uma trajetória de um **processo estocástico** e a população correspondente pode ser considerada como o conjunto de todas as trajetórias de tal processo [detalhes podem ser encontrados em Morettin e Tolói (2018)].

Também podemos ter dados obtidos de um experimento planejado no qual uma ou mais variáveis são controladas para produzir valores de uma variável resposta. A não ser quando explicitamente indicado, para propósitos inferenciais, neste texto consideraremos os dados como provenientes de uma AAS.

Denotemos por x_1, \dots, x_n os valores efetivamente observados das variáveis X_1, \dots, X_n . Denotemos por $x_{(1)}, \dots, x_{(n)}$ esses valores observados ordenados em ordem crescente, ou seja, $x_{(1)} \leq \dots \leq x_{(n)}$. Esses são os valores das **estatísticas de ordem** $X_{(1)}, \dots, X_{(n)}$.

Muitas vezes não faremos distinção entre a variável e seu valor, ou seja, designaremos, indistintamente, por x a variável e um valor observado dela.

A **função distribuição acumulada** de uma variável X definida como $F(x) = P(X \leq x)$, $x \in \mathcal{R}$ pode ser estimada a partir dos dados amostrais, por meio da **função distribuição empírica** definida por

$$F_e(x) = \frac{n(x)}{n}, \quad \forall x \in \mathcal{R}, \tag{3.16}$$

em que $n(x)$ é o número de observações amostrais menores ou iguais a x .

Considere novamente as observações do Exemplo 3.4 sem o valor 220 para efeito ilustrativo. O gráfico de F_e que é essencialmente uma função em escada, com “saltos” de magnitude $1/n$ em cada $x_{(i)}$, nomeadamente

$$F_e(x_{(i)}) = \frac{i}{n}, \quad i = 1, \dots, n$$

está disposto na Figura 3.17.

3.7 Gráficos QQ

Uma das questões fundamentais na especificação de um modelo para inferência estatística é a escolha de um modelo probabilístico para representar

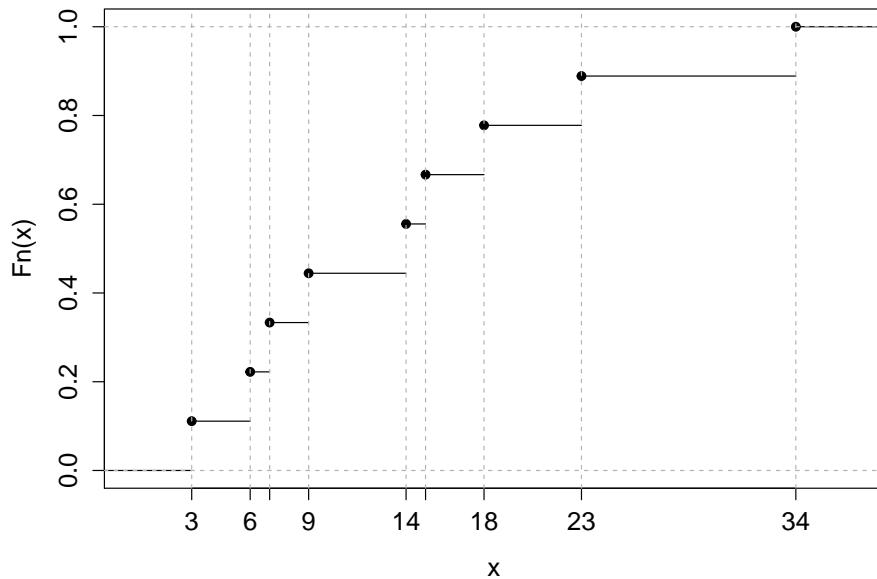


Figura 3.17: Função distribuição empírica para os dados do Exemplo 3.4 (sem o valor 220).

a distribuição (desconhecida) da variável de interesse na população. Uma possível estratégia para isso é examinar o histograma dos dados amostrais e compará-lo com histogramas teóricos associados a modelos probabilísticos candidatos. Alternativamente, os **gráficos QQ** (*QQ plots*) também podem ser utilizados com essa finalidade.

Essencialmente, gráficos QQ são gráficos cartesianos cujos pontos representam os quantis de mesma ordem obtidos das distribuições amostral (empírica) e teórica. Se os dados amostrais forem compatíveis com o modelo probabilístico proposto, esses pontos devem estar sobre uma reta com inclinação unitária quando os quantis forem padronizados, *i.e.*,

$$Q^*(p_i) = [Q(p_i) - (\bar{x})]/dp(x).$$

Para quantis não padronizados, os pontos no gráfico estarão dispostos em torno de uma reta com inclinação diferente de 1.

Como o modelo Normal serve de base para muitos métodos estatísticos de análise, uma primeira tentativa é construir esse tipo de gráfico baseado nos quantis dessa distribuição. Os quantis Normais padronizados $Q_N(p_i)$ são obtidos da distribuição Normal padrão $[N(0, 1)]$ por meio da solução da equação

$$\int_{-\infty}^{Q_N(p_i)} \frac{1}{\sqrt{2\pi}} \exp(-x^2) = p_i, \quad i = 1, \dots, n,$$

cujos resultados estão disponíveis na maioria dos pacotes computacionais destinados à análise estatística. Para facilitar a comparação, convém utilizar

os quantis amostrais padronizados, nos gráficos QQ. Ver a Nota de Capítulo 5 deste capítulo e Nota de Capítulo 5 do Capítulo 4.

Consideremos novamente os dados do Exemplo 3.4. Os quantis amostrais, quantis amostrais padronizados e Normais padronizados estão dispostos na Tabela 3.10. O correspondente gráfico QQ está representado na Figura 3.18.

Tabela 3.10: Quantis amostrais e Normais para os dados do Exemplo 3.4

i	1	2	3	4	5	6	7	8	9	10
p_i	0,05	0,15	0,25	0,35	0,45	0,55	0,65	0,75	0,85	0,95
$Q(p_i)$	3	6	7	9	14	15	18	23	34	220
$Q^*(p_i)$	-0,49	-0,44	-0,42	-0,39	-0,32	-0,30	-0,26	-0,18	-0,14	2,82
$Q_N(p_i)$	-1,64	-1,04	-0,67	-0,39	-0,13	0,13	0,39	0,67	1,04	1,64

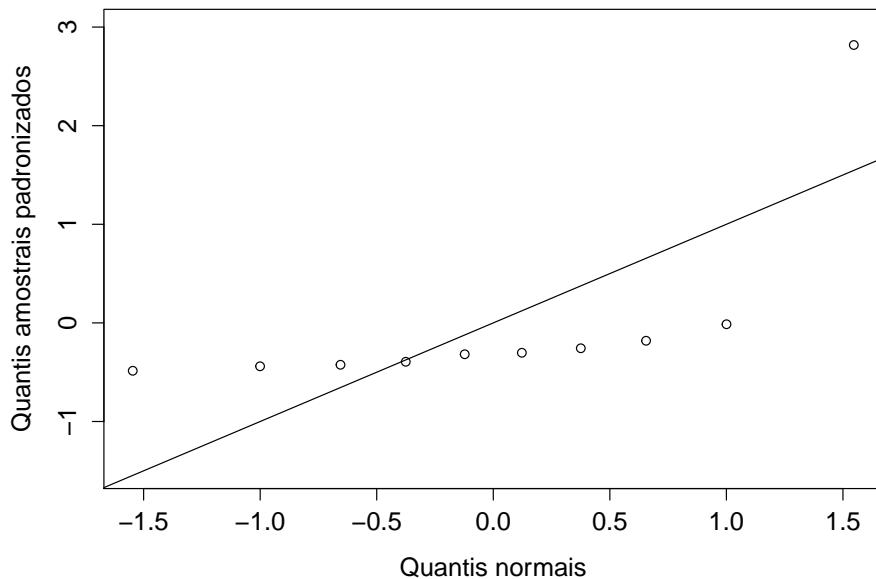


Figura 3.18: Gráfico QQ Normal para os dados do Exemplo 3.4.

Um exame da Figura 3.18 sugere que o modelo Normal não parece ser adequado para os dados do Exemplo 3.4. Uma das razões para isso, é a presença de um ponto atípico (220). Um gráfico QQ Normal para o conjunto de dados obtidos com a eliminação desse ponto está exibido na Figura 3.19 e indica que as evidências contrárias ao modelo Normal são menos aparentes.

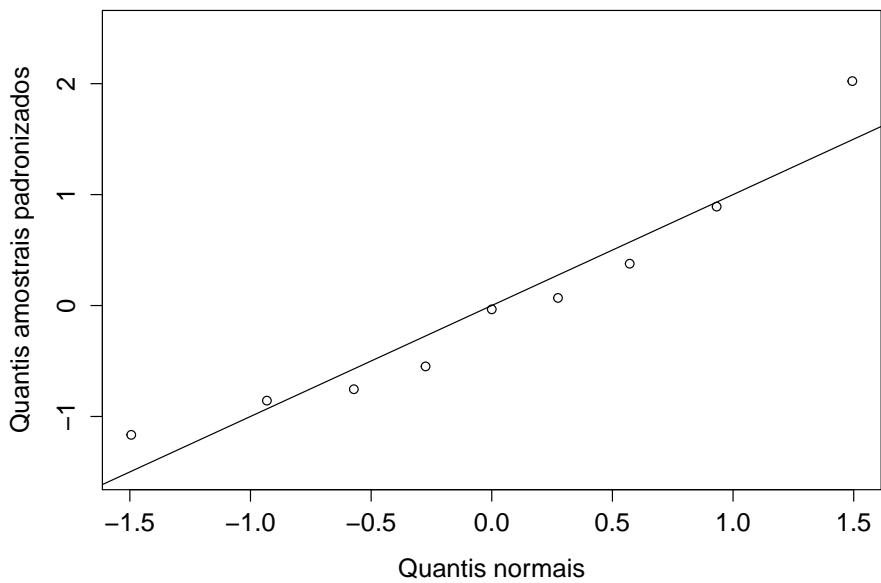


Figura 3.19: Gráfico QQ Normal para os dados do Exemplo 3.4 com a eliminação do ponto 220.

Um exemplo de gráfico QQ para uma distribuição amostral com 100 dados gerados a partir de uma distribuição Normal padrão está apresentado na Figura 3.20.

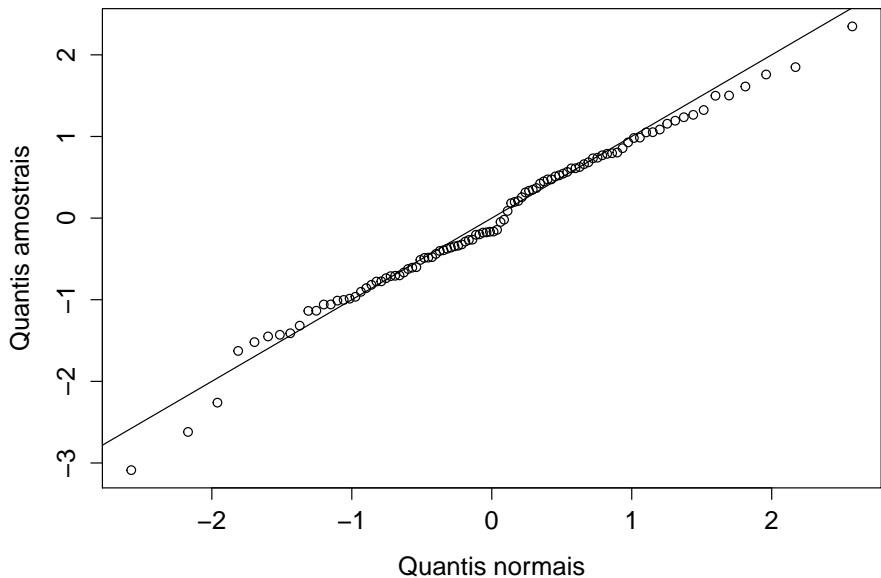


Figura 3.20: Gráfico QQ Normal para 100 dados gerados de uma distribuição Normal padrão.

Embora os dados correspondentes aos quantis amostrais da Figura 3.20 tenham sido gerados a partir de uma distribuição Normal padrão, os pontos não se situam exatamente sobre a reta com inclinação de 45 graus em função de flutuações amostrais. Em geral, a adoção de um modelo probabilístico com base num exame do gráfico QQ tem uma natureza subjetiva, mas é possível incluir bandas de confiança nesse tipo de gráfico para facilitar a decisão. Essas bandas dão uma ideia sobre a faixa de variação esperada para os pontos no gráfico. Detalhes sobre a construção dessas bandas são tratados na Nota de Capítulo 6. Um exemplo de gráfico QQ com bandas de confiança para uma distribuição amostral com 100 dados gerados a partir de uma distribuição Normal padrão está apresentado na Figura 3.21.

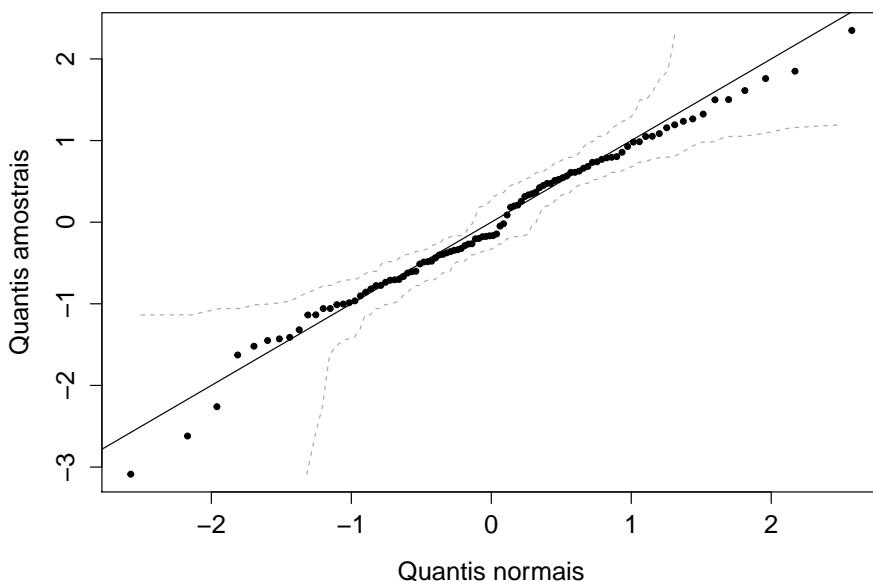


Figura 3.21: Gráfico QQ Normal para 100 dados gerados de uma distribuição Normal padrão com bandas de confiança.

Um exemplo de gráfico QQ em que as caudas da distribuição amostral (obtidas de uma amostra de 100 dados gerados a partir de uma distribuição t com 2 graus de liberdade) são mais pesadas que aquelas da distribuição Normal está apresentado na Figura ??.

Um exemplo de gráfico QQ Normal em que a distribuição amostral (com 100 dados gerados a partir de uma distribuição qui-quadrado com 2 graus de liberdade) é assimétrica está apresentado na Figura ???. O gráfico QQ correspondente, agora obtido por meio dos quantis de uma distribuição qui-quadrado com 2 graus de liberdade é apresentado na Figura 3.24.

”””

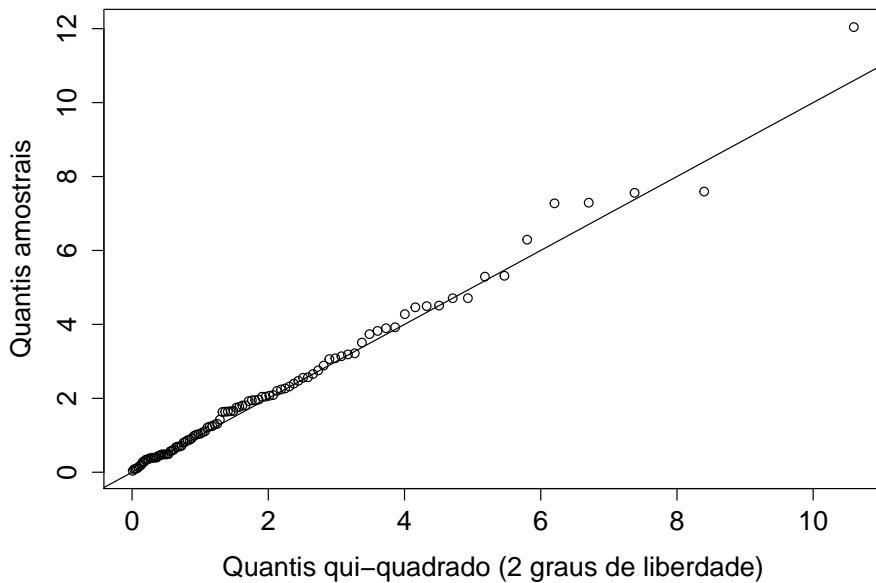


Figura 3.24: Gráfico QQ qui-quadrado para 100 dados gerados de uma distribuição qui-quadrado com 2 graus de liberdade.

,,,,,,

3.8 Transformação de variáveis

Muitos procedimentos empregados em inferência estatística são baseados na suposição de que os valores de uma (ou mais) das variáveis de interesse provêm de uma distribuição Normal, ou seja, de que os dados associados a essa variável constituem uma amostra de uma população na qual a distribuição dessa variável é Normal. No entanto, em muitas situações de interesse prático, a distribuição dos dados na amostra é assimétrica e pode conter valores atípicos, como vimos em exemplos anteriores.

Se quisermos utilizar os procedimentos talhados para análise de dados com distribuição Normal em situações nas quais a distribuição dos dados amostrais é sabidamente assimétrica, pode-se considerar uma transformação das observações com a finalidade de se obter uma distribuição “mais simétrica” e portanto, mais próxima da distribuição Normal. Uma transformação bastante usada com esse propósito é

$$x^{(p)} = \begin{cases} x^p, & \text{se } p > 0 \\ \ln(x), & \text{se } p = 0 \\ -x^p, & \text{se } p < 0. \end{cases} \quad (3.17)$$

Essa transformação com $0 < p < 1$ é apropriada para distribuições as-

simétricas à direita, pois valores grandes de x decrescem mais relativamente a valores pequenos. Para distribuições assimétricas à esquerda, basta tomar $p > 1$.

Normalmente, consideramos valores de p na sequência

$$\dots, -3, -2, -1, -1/2, -1/3, -1/4, 0, 1/4, 1/3, 1/2, 1, 2, 3, \dots$$

e para cada um deles construímos gráficos apropriados (histogramas, *boxplots*) com os dados originais e transformados, com a finalidade de escolher o valor mais adequado para p . Hinkley (1977) sugere que para cada valor de p na sequência acima se calcule a média, a mediana e um estimador de escala (desvio padrão ou algum estimador robusto) e então se escolha o valor que minimiza

$$d_p = \frac{\text{média} - \text{mediana}}{\text{medida de escala}}, \quad (3.18)$$

que pode ser vista como uma medida de assimetria; numa distribuição simétrica, $d_p = 0$.

Exemplo 3.5. Consideremos a variável concentração de Fe obtidas em cascas de árvores da espécie *Tipuana tipu* disponível no arquivo `arvores`. Nas Figuras 3.25 e 3.26 apresentamos, respectivamente *boxplots* e histogramas para os valores originais da variável assim como para seus valores transformados por (3.17) com $p = 0, 1/3$ e $1/2$. Observamos que a transformação obtida com $p = 1/3$ é aquela que gera uma distribuição mais próxima da simetria.

Muitas vezes, (em **Análise de Variância**, por exemplo) é mais importante transformar os dados de modo a “estabilizar” a variância do que tornar a distribuição aproximadamente Normal. Um procedimento idealizado para essa finalidade é detalhado a seguir.

Suponhamos que X seja uma variável com $E(X) = \mu$ e variância dependente da média, ou seja $\text{Var}(X) = h^2(\mu)\sigma^2$, para alguma função $h(\cdot)$. Notemos que se $h(\mu) = 1$, então $\text{Var}(X) = \sigma^2 = \text{constante}$. Procuremos uma transformação $X \rightarrow g(X)$, de modo que $\text{Var}[g(X)] = \text{constante}$. Com esse propósito, consideremos uma expansão de Taylor de $g(X)$ ao redor de $g(\mu)$ até primeira ordem, ou seja

$$g(X) \approx g(\mu) + (X - \mu)g'(\mu).$$

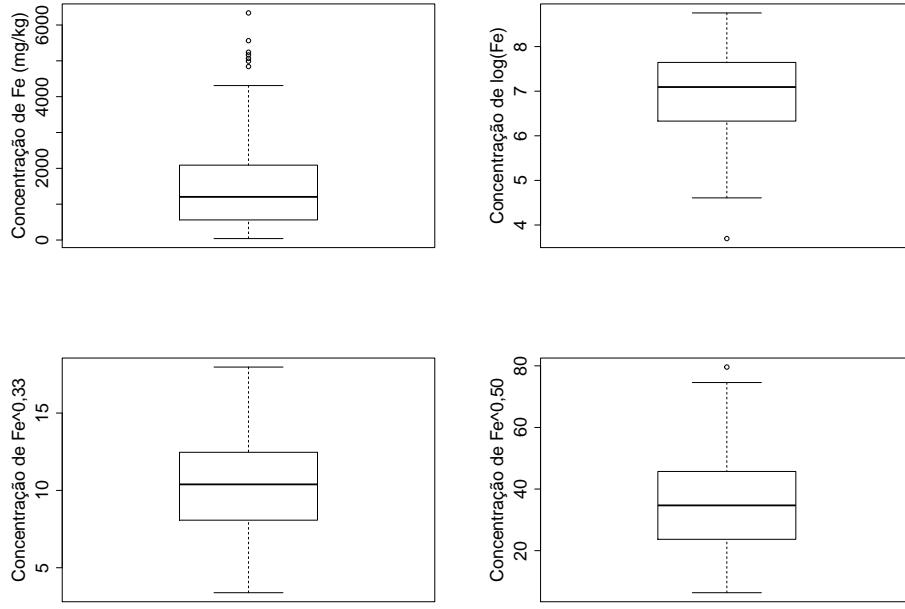
em que g' denota a derivada de g em relação a μ . Então,

$$\text{Var}[g(X)] \approx [g'(\mu)]^2 \text{Var}(X) = [g'(\mu)]^2 [h(\mu)]^2 \sigma^2.$$

Para que a variância da variável transformada seja constante, devemos tomar

$$g'(\mu) = \frac{1}{h(\mu)}.$$

Por exemplo, se o desvio padrão de X for proporcional a μ , tomamos $h(\mu) = \mu$, logo $g'(\mu) = 1/\mu$ e portanto $g(\mu) = \log(\mu)$ e devemos considerar

Figura 3.25: *Boxplots* com variável transformada.

a transformação (3.17) com $p = 0$, ou seja, $y^{(p)} = \log(x)$. Por outro lado, se a variância for proporcional à média, então usando o resultado acima, é fácil ver que a transformação adequada é $g(x) = \sqrt{x}$.

A transformação (3.19) é um caso particular das **transformações de Box-Cox** que são da forma

$$g(x) = \begin{cases} \frac{x^p - 1}{p}, & \text{se } p \neq 0 \\ \log(x), & \text{se } p = 0. \end{cases} \quad (3.19)$$

Veja Box e Cox (1964) para detalhes.

3.9 Desvio padrão e Erro padrão

Considere uma população para a qual a variável X tem média μ e variância σ^2 . Imaginemos que um número grande, digamos M de amostras de tamanho n seja obtido dessa população. Denotemos por X_{i1}, \dots, X_{in} os n valores observados da variável X na i -ésima amostra, $i = 1, \dots, M$. Para cada uma das M amostras, calculemos as respectivas médias, denotadas por $\bar{X}_1, \dots, \bar{X}_M$. Pode-se mostrar que a média e a variância da variável \bar{X} (cujos valores são $\bar{X}_1, \dots, \bar{X}_M$) são respectivamente μ e σ^2/n , i.e., a média do conjunto das médias amostrais é igual à média da variável original X e a sua variância é menor (por um fator $1/n$) que a variância da variável original

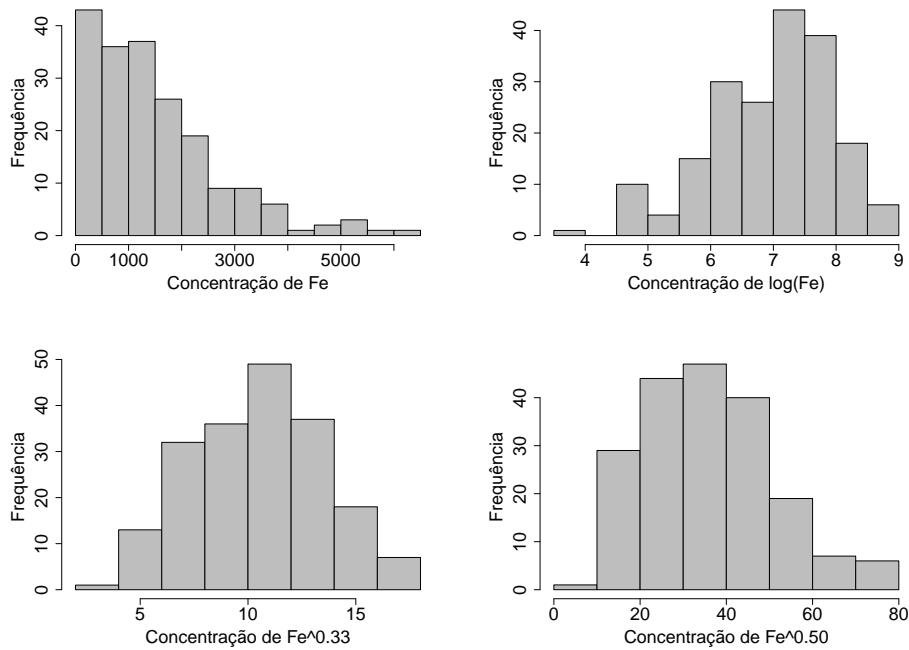


Figura 3.26: Histogramas com variável transformada.

X . Além disso pode-se demonstrar que o histograma da variável \bar{X} tem o formato da distribuição Normal.

Note que a variância σ^2 é uma característica inerente à distribuição da variável original e não depende do tamanho da amostra. A variância σ^2/n da variável \bar{X} , depende do tamanho da amostra; quanto maior esse tamanho, mais concentrada (em torno de sua média, que é a mesma da variável original) será a sua distribuição. O desvio padrão da variável \bar{X} é conhecido como **erro padrão** (da média). Detalhes podem ser obtidos em Bussab e Morettin (2017).

3.10 Intervalo de confiança

Em muitas situações, dados passíveis de análise estatística provêm de variáveis observadas em unidades de investigação (indivíduos, animais, corpos de prova, residências etc.) obtidas de uma população de interesse por meio de um processo de amostragem. Além de descrever e resumir os dados da amostra, há interesse em utilizá-los para fazer inferência sobre as distribuições populacionais dessas variáveis. Essas populações são, em geral, conceituais. Por exemplo, na avaliação de um determinado medicamento para diminuição da pressão arterial (X), a população de interesse não se resume aos pacientes (vivos) de um hospital ou de uma região; o foco é a população de indivíduos (vivos ou que ainda nascerão) que poderão utilizar

essa droga. Nesse contexto, as características populacionais da diminuição da pressão arterial possivelmente provocada pela administração da droga são desconhecidas e queremos estimá-la (ou adivinhá-las) com base nas suas características amostrais.

Não temos dúvidas sobre as características amostrais. Se a droga foi administrada a n pacientes e a redução média da pressão arterial foi de $\bar{X} = 10$ mmHg com desvio padrão $S = 3$ mmHG, não temos dúvida de que “em média” a droga reduziu a pressão arterial em 10 mmHg nos indivíduos da amostra. O problema é saber se o resultado obtido na amostra pode ser extrapolado para a população, ou seja se podemos utilizar \bar{X} para estimar a média populacional (μ), que não conhecemos e que não conheceremos a não ser que seja possível fazer um censo. Obviamente, se foram tomados cuidados na seleção da amostra e se o protocolo experimental foi devidamente adotado, faz sentido supor que a redução média da pressão arterial induzida pela droga na população esteja próxima de 10 mmHg mas precisamos então especificar o que entendemos por “próxima”. Isso pode ser feito por intermédio do cálculo da **margem de erro**, que, essencialmente, é uma medida de nossa incerteza na extração dos resultados obtidos na amostra para a população de onde assumimos que foi obtida.

A margem de erro depende do processo amostral, do desvio padrão amostral S , do tamanho amostral n e é dada por $e = kS/\sqrt{n}$ em que k é uma constante que depende do modelo probabilístico adotado e da confiança com que pretendemos fazer a inferência. No caso de uma **amostra aleatória simples** de uma variável X obtida de uma população para a qual assumimos um modelo Normal, a margem de erro correspondente a um nível de confiança de 95% é $e = 1,96S/\sqrt{n}$. Com base nessa margem de erro, podemos construir um **intervalo de confiança** para a média populacional da variável X . Os limites inferior e superior para esse intervalo são, respectivamente, $\bar{X} - 1,96S/\sqrt{n}$ e $\bar{X} + 1,96S/\sqrt{n}$. Se considerássemos um grande número de amostras dessa população sob as mesmas condições, o intervalo construído dessa maneira conteria o verdadeiro (mas desconhecido) valor da média populacional (μ) em 95% dos casos.

Consideremos uma pesquisa eleitoral em que uma amostra de n eleitores é avaliada quanto à preferência por um determinado candidato. Podemos definir a variável resposta como $X = 1$ se o eleitor apoiar o candidato e $X = 0$ em caso contrário. A média amostral de X é a proporção amostral de eleitores favoráveis ao candidato, que representamos por \hat{p} ; sua variância, $p(1-p)/n$, pode ser estimada por $\hat{p}(1-\hat{p})/n$. Ver Exercício 32. Pode-se demonstrar que os limites inferior e superior de um intervalo de confiança com 95% de confiança para a proporção populacional p de eleitores favoráveis ao candidato são, respectivamente, $\hat{p}-1,96\sqrt{\hat{p}(1-\hat{p})/n}$ e $\hat{p}+1,96\sqrt{\hat{p}(1-\hat{p})/n}$. Se numa amostra de tamanho $n = 400$ obtivermos 120 eleitores favoráveis ao candidato, a proporção amostral será $\hat{p} = 30\%$ e então podemos dizer que com 95% de confiança a proporção populacional p deve estar entre 25,5% e 34,5%.

Detalhes técnicos sobre a construção de intervalos de confiança podem

ser encontrados em Bussab e Morettin (2017) entre outros.

3.11 Notas de capítulo

1) Variáveis contínuas

Conceitualmente existem variáveis que podem assumir qualquer valor no conjunto dos números reais, como peso ou volume de certos produtos. Como na prática, todas as medidas que fazemos têm valores discretos, não é possível obter o valor π (que precisa ser expresso com infinitas casas decimais) por exemplo, para peso ou volume. No entanto, em geral, é possível aproximar as distribuições de frequências de variáveis com essa natureza por funções contínuas (como a distribuição Normal) e é essa característica que sugere sua classificação como variáveis contínuas.

2) Amplitude de classes em histogramas

Nos casos em que o histograma é obtido a partir dos dados de uma amostra de uma população com densidade $f(x)$, Freedman e Diaconis (1981) mostram que a escolha

$$h = 1,349\tilde{s} \left(\frac{\log n}{n} \right)^{1/3} \quad (3.20)$$

minimiza o desvio máximo absoluto entre o histograma e a verdadeira densidade $f(x)$. Em (3.20), \tilde{s} é um estimador “robusto” do desvio padrão de X . Esse conceito será discutido adiante.

O pacote R usa como *default* o valor de h sugerido por Sturges (1926), dado por

$$h = \frac{W}{1 + 3,322 \log(n)}, \quad (3.21)$$

sendo W a amplitude amostral e n o tamanho da amostra,

3) Definição de histograma

Consideremos um exemplo com K classes de comprimentos iguais a h . O número de classes a utilizar pode ser obtido aproximadamente como o quociente $(x_{(n)} - x_{(1)})/h$ em que $x_{(1)}$ é o valor mínimo e $x_{(n)}$, o valor máximo do conjunto de dados. Para que a área do histograma seja igual a 1, a altura do k -ésimo retângulo deve ser igual a f_k/h . Chamando \tilde{x}_k , $k = 1, \dots, K$, os pontos médios dos intervalos das classes, o histograma pode ser construído a partir da seguinte função

$$\tilde{f}(x) = \frac{1}{nh} \sum_{i=1}^n I(x - \tilde{x}_i; h/2), \quad (3.22)$$

em que $I(z; h)$ é a função indicadora do intervalo $[-h, h]$, ou seja,

$$I(z; h) = \begin{cases} 1, & \text{se } -h \leq z \leq h \\ 0, & \text{em caso contrário.} \end{cases}$$

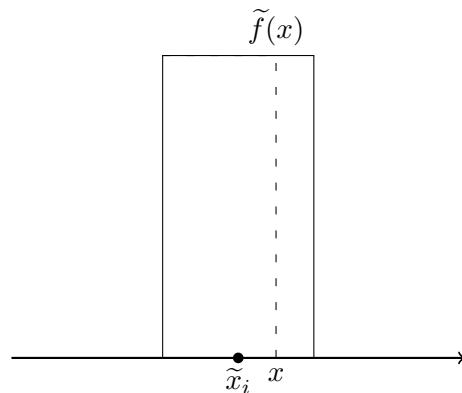


Figura 3.27: Detalhe para a construção de histogramas.

Para representar essa construção, veja a Figura 3.27.

4) Um estimador alternativo para o desvio padrão

Pode-se verificar que, para uma distribuição Normal,

$$d_Q = 1,349\sigma$$

com σ^2 representando a variância. Logo, um estimador do desvio padrão populacional é

$$\tilde{s} = \frac{d_Q}{1,349}.$$

Observe que substituindo \tilde{s} em (3.20), obtemos

$$h \approx d_Q \left(\frac{\log n}{n} \right)^{1/3},$$

que também pode ser utilizado para a determinação do número de classes de um histograma.

5) Padronização de variáveis

Para comparação de gráficos QQ, por exemplo, convém transformar variáveis com diferentes unidades de medida para deixá-las adimensionais, com a mesma média e mesma variância. Para esse efeito pode-se padronizar uma variável X com média μ e desvio padrão σ por meio da transformação $Z = (X - \mu)/\sigma$. Pode-se mostrar (ver Exercício 15) que a variável padronizada Z tem média 0 e desvio padrão 1, independentemente dos valores de μ e σ . Esse tipo de padronização também é útil em Análise de Regressão (ver Capítulo 6) quando se deseja avaliar a importância relativa de cada variável por meio dos coeficientes do modelo linear adotado.

6) Bandas de confiança para gráficos QQ

Seja $\{X_1, \dots, X_n\}$ uma amostra aleatória de uma variável com função distribuição F desconhecida. A estatística de Kolmogorov-Smirnov [ver Wayne (1990, páginas 319-330), por exemplo], dada por

$$S = \sup_x |F_n(x) - F_0(x)|$$

em que F_n é correspondente função distribuição empírica, serve para testar a hipótese $F = F_0$. A distribuição da estatística S é tabelada de forma que se pode obter o valor crítico s tal que $P(S \leq s) = 1 - \alpha$, $0 < \alpha < 1$. Isso implica que para qualquer valor x temos $|F_n(x) - F_0(x)| \leq s = 1 - \alpha$ ou seja, que com probabilidade $1 - \alpha$ temos $F_n(x) - s \leq F_0(x) \leq F_n(x) + s$. Consequentemente, os limites inferior e superior de um intervalo de confiança com coeficiente de confiança $1 - \alpha$ para F são respectivamente, $F_n(x) - s$ e $F_n(x) + s$. Essas bandas conterão a função distribuição Normal $N(\mu, \sigma^2)$ se

$$F_n(x) - s \leq \Phi[(x - \mu)/\sigma] \leq F_n(x) + s$$

o que equivale a ter uma reta contida entre os limites da banda definida por

$$\Phi^{-1}[F_n(x) - s] \leq (x - \mu)/\sigma \leq \Phi^{-1}[F_n(x) + s].$$

Para a construção do gráfico QQ esses valores são calculados nos pontos X_1, \dots, X_n .

7) Curtose

Seja X uma variável aleatória qualquer, com média μ e variância σ^2 . A **curtose** de X é definida por

$$K(X) = E \left[\frac{(X - \mu)^4}{\sigma^4} \right]. \quad (3.23)$$

Para uma distribuição Normal, $K = 3$, razão pela qual a quantidade $e(X) = K(X) - 3$ é chamada de **excesso de curtose**. Distribuições com caudas pesadas têm curtose maior do que 3, podendo ser infinita.

Para uma amostra $\{X_1, \dots, X_n\}$ de X , considere o r -Ésimo momento amostral

$$m_r = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^r,$$

em que $\hat{\mu} = \bar{X}$. Substituindo os momentos verdadeiros de X pelos respectivos momentos amostrais, obtemos um estimador da curtose, nomeadamente

$$\hat{K}(X) = \frac{m_4}{m_2^2} = \frac{1}{n} \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\hat{\sigma}} \right)^4, \quad (3.24)$$

em que $\hat{\sigma}^2 = \sum_{i=1}^n (X_i - \bar{X})^2/n$. Então um estimador para o excesso de curtose é $\hat{e}(X) = \hat{K}(X) - 3$. Pode-se provar que, para uma amostra suficientemente grande de uma distribuição Normal,

$$\hat{K} \sim \mathcal{N}(3, 24/n). \quad (3.25)$$

3.12 Exercícios

- 1) O arquivo `rehabcardio` contém informações sobre um estudo de reabilitação de pacientes cardíacos. Elabore um relatório indicando possíveis inconsistências na matriz de dados e faça uma análise descritiva de todas as variáveis do estudo.
- 2) Considere um conjunto de dados $\{X_1, \dots, X_n\}$.
 - a) Calcule a média e a variância de W_1, \dots, W_n em que $W_i = X_i + k$ com k denotando uma constante.
 - b) Calcule a média e a variância de V_1, \dots, V_n em que $V_i = kX_i$ com k denotando uma constante.
- 3) Calcule as medidas de posição e dispersão estudadas para os dados apresentados na Tabela 3.1 cujos dados estão disponíveis no arquivo `ceagfgv`.
- 4) Determine o valor de h dado por (3.20) para os dados do Exemplo 3.4.
- 5) Prove que S^2 dado por (3.10) é um estimador não enviesado da variância populacional.
- 6) Considere do arquivo `vento`. Observe o valor atípico 61,1, que na realidade ocorreu devido a forte tempestade no dia 2 de dezembro. Calcule as medidas de posição e dispersão dadas na Seção 3.3. Comente os resultados.
- 7) Construa gráficos ramo-e-folhas e *boxplot* para os dados do Exercício 6.
- 8) Usando o pacote R, analise a variável “Temperatura” do arquivo `poluicao`.
- 9) Idem, para a variável “Salário de administradores”, disponível no arquivo `salarioso`.
- 10) Construa um gráfico ramo-e-folhas e um *boxplot* para os dados de precipitação atmosférica de Fortaleza disponíveis no arquivo `precipitacao`.
- 11) Transforme os dados do Exercício 6 por meio de (3.17) com $p = 0, 1/4, 1/3, 1/2, 3/4$ e escolha a melhor alternativa de acordo com a medida d_p dada em (3.18).

12) Construa gráficos de quantis e simetria para os dados de manchas solares disponíveis no arquivo `manchas`.

13) Prove a relação (3.8). Como ficaria essa expressão para S^2 ?

14) Uma outra medida de assimetria é

$$A = \frac{(Q_3 - Q_2) - (Q_2 - Q_1)}{Q_3 - Q_1},$$

que é igual a zero no caso de uma distribuição simétrica. Calcule-a para os dados do Exercício 6.

15) Considere os valores X_1, \dots, X_n de uma variável X , com média \bar{X} e desvio padrão S . Mostre que a variável Z , cujos valores são $Z_i = (X_i - \bar{X})/S$, $i = 1, \dots, n$ tem média 0 e desvio padrão 1.

16) Os dados disponíveis no arquivo `endometriose` são provenientes de um estudo sobre endometriose onde o objetivo é verificar se existe diferença entre os grupos de doentes e controle quanto a algumas características observadas.

a) O pesquisador responsável pelo estudo tem a seguinte pergunta: as pacientes doentes apresentam mais dor na menstruação do que as pacientes não doentes? Que tipo de análise você faria para responder essa pergunta? Faça-a e tire suas conclusões.

b) Compare as distribuições das variáveis idade e concentração de PCR durante a menstruação (PCRa) para indivíduos dos grupos controle e doente utilizando medidas resumo (mínimo, máximo, quartis, mediana, média, desvio padrão, etc), *boxplots*, histogramas, gráficos de médias e gráficos QQ. Como você considerou os valores $< 0,5$ da variável PCRa nesses cálculos? Você sugeriria uma outra maneira para considerar tais valores?

c) Compare a distribuição da variável número de gestações para os dois grupos por intermédio de uma tabela de frequências e do teste qui-quadrado de Pearson. Utilize um método gráfico para representar essa tabela.

17) Os dados apresentados na Figura 3.28 referem-se aos instantes nos quais o centro de controle operacional de estradas rodoviárias recebeu chamados solicitando algum tipo de auxílio em duas estradas num determinado dia.

a) Construa um histograma para a distribuição de frequências de chamados em cada uma das estradas.

b) Calcule os intervalos de tempo entre as sucessivas chamadas e descreva-os, para cada uma das estradas, utilizando medidas resumo gráficos do tipo *boxplot*. Existe alguma relação entre o tipo de estrada e o intervalo de tempo entre as chamadas?

Estrada 1	12:07:00 AM	12:58:00 AM	01:24:00 AM	01:35:00 AM	02:05:00 AM
	03:14:00 AM	03:25:00 AM	03:46:00 AM	05:44:00 AM	05:56:00 AM
	06:36:00 AM	07:26:00 AM	07:48:00 AM	09:13:00 AM	12:05:00 PM
	12:48:00 PM	01:21:00 PM	02:22:00 PM	05:30:00 PM	06:00:00 PM
	07:53:00 PM	09:15:00 PM	09:49:00 PM	09:59:00 PM	10:53:00 PM
	11:27:00 PM	11:49:00 PM	11:57:00 PM		
Estrada 2	12:03:00 AM	01:18:00 AM	04:35:00 AM	06:13:00 AM	06:59:00 AM
	08:03:00 AM	10:07:00 AM	12:24:00 PM	01:45:00 PM	02:07:00 PM
	03:23:00 PM	06:34:00 PM	07:19:00 PM	09:44:00 PM	10:27:00 PM
	10:52:00 PM	11:19:00 PM	11:29:00 PM	11:44:00 PM	

Figura 3.28: Planilha com instantes de realização de chamados solicitando auxílio em estradas.

- c) Por intermédio de um gráfico do tipo QQ, verifique se a distribuição da variável “Intervalo de tempo entre as chamadas” / em cada estrada é compatível com um modelo Normal. Faça o mesmo para um modelo exponencial. Compare as distribuições de frequências correspondentes às duas estradas.
- 18) As notas finais de um curso de Estatística foram: 7, 5, 4, 5, 6, 3, 8, 4, 5, 4, 6, 4, 5, 6, 4, 6, 6, 3, 8, 4, 5, 4, 5, 5 e 6.
- Determine a mediana, os quartis e a média.
 - Separar o conjunto de dados em dois grupos denominados **aprovados**, com nota pelo menos igual a 5, e **reprovados**. Compare a variância desses dois grupos.
- 19) Considere o seguinte resumo descritivo da pulsação de estudantes com atividade física intensa e fraca:

Atividade	N	Média	Mediana	DP	Min	Max	Q1	Q3
Intensa	30	79,6	82	10,5	62	90	70	79
Fraca	30	73,1	70	9,6	58	92	63	77

DP: desvio padrão

Q1: primeiro quartil

Q3: terceiro quartil

Qual das seguintes afirmações está correta:

- 5% e 50% dos estudantes com atividade física intensa e fraca, respectivamente, tiveram pulsação inferior a 70.
- A pulsação de um estudante com fraca atividade física é provavelmente inferior a 63.
- A atividade física não tem efeito na média da pulsação dos estudantes.
- Quaisquer 15 estudantes com fraca atividade física têm pulsação inferior a 70.
- Nenhuma das respostas anteriores.

- 20) Considere os gráficos *boxplot* da Figura 3.29. Quais deles correspondem às pulsações dos estudantes submetidos a atividade física intensa e fraca? a) A e B b) B e D c) A e C d) B e C

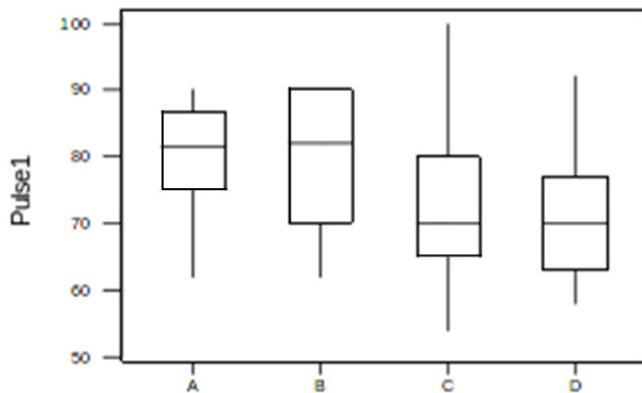


Figura 3.29: *Boxplots* para o Exercício 20.

- 21) Os histogramas apresentados na Figura 3.30 mostram a distribuição das temperaturas ($^{\circ}\text{C}$) ao longo de vários dias de investigação para duas regiões (R1 e R2). Podemos dizer que:

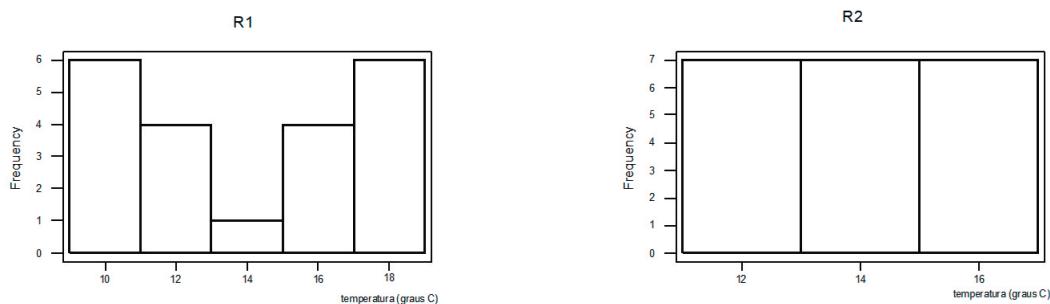


Figura 3.30: Histogramas para o Exercício 20.

- a) As temperaturas das regiões R1 e R2 têm mesma média e mesma variância.
 b) Não é possível comparar as variâncias.
 c) A temperatura média da região R2 é maior que a de R1.
 d) As temperaturas das regiões R1 e R2 têm mesma média e variância diferentes.
 e) Nenhuma das respostas anteriores.
- 22) Na companhia A, a média dos salários é 10000 unidades e o 3º quartil é 5000.

- a) Se você se apresentasse como candidato a funcionário nessa firma e se o seu salário fosse escolhido ao acaso entre todos os possíveis salários, o que seria mais provável: ganhar mais ou menos que 5000 unidades?
- b) Suponha que na companhia B a média dos salários seja 7000 unidades, a variância praticamente zero e o salário também seja escolhido ao acaso. Em qual companhia você se apresentaria para procurar emprego, com base somente no salário?
- 23) Num conjunto de dados, o primeiro quartil é 10, a mediana é 15 e o terceiro quartil é 20. Indique quais das seguintes afirmativas são verdadeiras, justificando sua resposta:
- A distância interquartil é 5.
 - O valor 32 seria considerado *outlier* segundo o critério utilizado na construção do *boxplot*.
 - A mediana ficaria alterada de 2 unidades se um ponto com valor acima do terceiro quartil fosse substituído por outro 2 vezes maior.
 - O valor mínimo é maior do que zero.
 - Nenhuma das respostas anteriores.
- 24) A bula de um medicamento A para dor de cabeça afirma que o tempo médio para que a droga faça efeito é de 60 seg com desvio padrão de 10 seg. A bula de um segundo medicamento B afirma que a média correspondente é de 60 seg com desvio padrão de 30 seg. Sabe-se que as distribuições são simétricas. Indique quais das seguintes afirmativas são verdadeiras, justificando sua resposta:
- Os medicamentos são totalmente equivalentes com relação ao tempo para efeito pois as médias são iguais.
 - Com o medicamento A, a probabilidade de cura de sua dor de cabeça antes de 40 seg é maior do que com o medicamento B.
 - Com o medicamento B, a probabilidade de você ter sua dor de cabeça curada antes de 60 seg é maior que com o medicamento A.
- 25) Na tabela abaixo estão indicadas as durações de 335 lâmpadas.

Duração (horas)	Número de lâmpadas
0 ⊢ 100	82
100 ⊢ 200	71
200 ⊢ 300	68
300 ⊢ 400	56
400 ⊢ 500	43
500 ⊢ 800	15

- a) Esboce o histograma correspondente.
- b) Calcule os quantis de ordem $p=0,1, 0,3, 0,5, 0,7$ e $0,9$.
- 26) A tabela abaixo representa a distribuição do número de dependentes por empregados da Empresa Mirante.

Dependentes	Empregados
1	40
2	50
3	30
4	20
5	10
Total	150

A mediana, média e moda são, respectivamente:

- a) 50; 15; 50 b) 1; 2,1; 1 c) 50,5; 50; 50 d) 1; 1; 1
- 27) Com relação ao Exercício 26, qual a porcentagem de empregados da Empresa Mirante com 2 ou mais dependentes?
- a) 40,1% b) 50,1% c) 60,3% d) 73,3%
- 28) Os dados encontrados no arquivo `esforco` são provenientes de um estudo sobre teste de esforço cardiopulmonar em pacientes com insuficiência cardíaca. As variáveis medidas durante a realização do teste foram observadas em quatro momentos distintos: repouso (REP), limiar anaeróbio (LAN), ponto de compensação respiratório (PCR) e pico (PICO). As demais variáveis são referentes às características demográficas e clínicas dos pacientes e foram registradas uma única vez.
- a) Descreva a distribuição da variável consumo de oxigênio (VO2) em cada um dos quatro momentos de avaliação utilizando medidas resumo (mínimo, máximo, quartis, mediana, média, desvio padrão, etc), *boxplots* e histogramas. Você identifica algum paciente com valores de consumo de oxigênio discrepantes? Interprete os resultados.
- b) Descreva a distribuição da classe funcional NYHA por meio de uma tabela de frequências. Utilize um método gráfico para representar essa tabela.
- 29) Num estudo na área de Oncologia, o número de vasos que alimentam o tumor está resumido na seguinte tabela.

Tabela 3.11: Distribuição de frequências do número de vasos que alimentam o tumor

Número de vasos	Frequência
0 ⊢ 5	8 (12%)
5 ⊢ 10	23 (35%)
10 ⊢ 15	12 (18%)
15 ⊢ 20	9 (14%)
20 ⊢ 25	8 (12%)
25 ⊢ 30	6 (9%)
Total	66 (100%)

Indique a resposta correta.

- a) O primeiro quartil é 25%.
 - b) A mediana está entre 10 e 15.
 - c) O percentil de ordem 10% é 10.
 - d) A distância interquartis é 50.
 - e) Nenhuma das respostas anteriores.
- 30) Utilizando o mesmo enunciado da questão anterior, indique a resposta correta:
- a) Não é possível estimar nem a média nem a variância com esses dados.
 - b) A variância é menor que 30.
 - c) A média estimada é 12.8.
 - d) Em apenas 35% dos casos, o número de vasos é maior que 10.
 - e) Nenhuma das anteriores.
- 31) Em dois estudos realizados com o objetivo de estimar o nível médio de colesterol total para uma população de indivíduos saudáveis observaram-se os dados indicados na tabela seguinte:

Tabela 3.12: Medidas descritivas dos estudos A e B

Estudo	n	Média	Desvio padrão
A	100	160 mg/dL	60 mg/dL
B	49	150 mg/dL	35 mg/dL

- Indique a resposta correta:

- a) Não é possível estimar o nível médio de colesterol populacional só com esses dados.

- b) Se os dois estudos foram realizados com amostras da mesma população não deveria haver diferença entre os desvios padrões amostrais.
- c) Com os dados do estudo B, o colesterol médio populacional pode ser estimado com mais precisão do que com os dados do estudo A.
- d) Ambos os estudos sugerem que a distribuição do colesterol na população é simétrica.
- e) Nenhuma das respostas anteriores.
- 32) Considere uma amostra aleatória simples X_1, \dots, X_n de uma variável X que assume o valor 1 com probabilidade $0 < p < 1$ e o valor 0 com probabilidade $1 - p$. Seja $\hat{p} = n^{-1} \sum_{i=1}^n X_i$. Mostre que
- $E(X_i) = p$ e $\text{Var}(X_i) = p(1 - p)$.
 - $E(\hat{p}) = p$ e $\text{Var}(\hat{p}) = p(1 - p)/n$.
 - $0 < \text{Var}(X_i) < 0,25$.

Com base nesses resultados, utilize o Teorema Limite Central [ver Sen et al. (2009), por exemplo] para construir um intervalo de confiança aproximado conservador (*i.e.* com a maior amplitude possível) para p . Utilize o Teorema de Sverdrup [ver Sen et al. (2009), por exemplo] para construir um intervalo de confiança aproximado para p com amplitude menor que a do intervalo mencionado acima.

- 33) Com a finalidade de entender a diferença entre “desvio padrão” e “erro padrão”,
- simule 10000 dados de uma distribuição normal com média 12 e desvio padrão 4. Construa o histograma correspondente, calcule a média e o desvio padrão amostrais e compare os valores obtidos com aqueles utilizados na geração dos dados;
 - simule 500 amostras de tamanho $n = 4$ dessa população. Calcule a média amostral de cada amostra, construa o histograma dessas médias e estime o correspondente desvio padrão (que é o erro padrão da média);
 - Repita os passos a) e b) com amostras de tamanhos $n = 9$ e $n = 100$; comente os resultados comparando-os com aqueles preconizados pela teoria.
 - Repita os passos a) - c) simulando amostras de uma distribuição qui-quadrado com 3 graus de liberdade.

Análise de dados de duas variáveis

Não é a linha reta que me atrai. Dura, inflexível, criada pelo homem. O que me atrai é a curva livre e natural.

Oscar Niemeyer

4.1 Introdução

Neste capítulo trataremos da análise descritiva da **associação** entre duas variáveis. *Grosso modo*, dizemos que existe associação entre duas variáveis, se o conhecimento do valor de uma delas nos dá alguma informação sobre a distribuição da outra. Podemos estar interessados, por exemplo, na associação entre o grau de instrução e o salário de um conjunto de indivíduos. Nesse caso, esperamos que quanto maior seja o nível educacional de um indivíduo, maior deve ser o seu salário. Como na análise de uma única variável, também discutiremos o emprego de tabelas e gráficos para representar a distribuição conjunta das variáveis de interesse além de medidas resumo para avaliar o tipo e a magnitude da associação. Podemos destacar três casos:

- i) as duas variáveis são qualitativas;
- ii) as duas variáveis são quantitativas;
- iii) uma variável é qualitativa e a outra é quantitativa.

As técnicas para analisar dados nos três casos acima são distintas. No primeiro caso, a análise é baseada no número de unidades de investigação (amostrais, por exemplo) em cada cela de uma tabela de dupla entrada. No segundo caso, as observações são obtidas por mensurações, e técnicas envolvendo gráficos de dispersão ou de quantis são apropriadas. Na terceira situação, podemos comparar as distribuições da variável quantitativa para cada categoria da variável qualitativa.

Aqui, é importante considerar a classificação das variáveis segundo outra característica, intimamente ligada à forma de coleta dos dados. **Variáveis**

explicativas são aquelas cujas categorias ou valores são fixos, seja por planejamento ou seja por condicionamento. **Variáveis respostas** são aquelas cujas categorias ou valores são aleatórios.

Num estudo em que se deseja avaliar o efeito da quantidade de aditivo adicionado ao combustível no consumo de automóveis, cada um de 3 conjuntos de 5 automóveis (de mesmo modelo) foi observado sob o tratamento com uma de 4 quantidades de aditivo. O consumo (em km/L) foi avaliado após um determinado período de tempo. Nesse contexto, a variável qualitativa “Quantidade de aditivo” (com 4 categorias) é considerada como explicativa e a variável quantitativa “Consumo de combustível” é classificada como resposta.

Num outro cenário, em que se deseja estudar a relação entre o nível sérico de colesterol (mg/dL) e o nível de obstrução coronariana (em %), cada paciente de um conjunto de 30 selecionados de um determinado hospital foi submetido a exames de sangue e tomográfico. Nesse caso, tanto a variável “Nível sérico de colesterol” quanto a variável “Nível de obstrução coronariana” devem ser encaradas como respostas. Mesmo assim, sob um **enfoque condicional**, em que se deseja avaliar o “Nível de obstrução coronariana” para pacientes com um determinado “Nível sérico de colesterol” a primeira é encarada como variável resposta e a segunda, como explicativa.

4.2 Duas variáveis qualitativas

Nessa situação, as classes das duas variáveis podem ser organizadas numa tabela de dupla entrada, em que as linhas correspondem aos níveis de uma das variáveis e as colunas, aos níveis da outra.

Exemplo 4.1. Os dados disponíveis no arquivo **coronarias** contém dados do projeto “Fatores de risco na doença aterosclerótica coronariana”, coordenado pela Dra. Valéria Bezerra de Carvalho (INTERCOR). O arquivo contém informações sobre cerca de 70 variáveis observadas em 1500 indivíduos.

Para fins ilustrativos, consideramos apenas duas variáveis qualitativas nominais, a saber, hipertensão arterial (X) e insuficiência cardíaca (Y), ambas codificadas com os atributos 0=não tem e 1=tem observadas em 50 pacientes. Nesse contexto, as duas variáveis são classificadas como respostas. A Tabela 4.1 contém a **distribuição de frequências conjunta** das duas variáveis. Essa distribuição indica, por exemplo, que 12 indivíduos têm hipertensão arterial e insuficiência cardíaca, ao passo que 4 indivíduos não têm hipertensão e têm insuficiência cardíaca. Para efeito de comparação com outros estudos envolvendo as mesmas variáveis mas com número de pacientes diferentes, convém expressar os resultados na forma de porcentagens. Com esse objetivo, podemos considerar porcentagens em relação ao total da tabela, em relação ao total de suas linhas ou em relação ao total de suas colunas. Na Tabela 4.2 apresentamos as porcentagens correspondentes à Tabela 4.1 calculadas em relação ao seu total. Os dados da Tabela 4.2

Tabela 4.1: Distribuição conjunta das variáveis X = hipertensão arterial e Y = insuficiência cardíaca

Insuficiência cardíaca	Hipertensão arterial		Total
	Tem	Não tem	
Tem	12	4	16
Não tem	20	14	34
Total	32	18	50

Tabela 4.2: Porcentagens para os dados da Tabela 4.1 em relação ao seu total

Insuficiência cardíaca	Hipertensão		Total
	Tem	Não tem	
Tem	24%	8%	32%
Não tem	40%	28%	68%
Total	64%	36%	100%

permitem-nos concluir que 24% dos indivíduos avaliados têm hipertensão e insuficiência cardíaca, ao passo que 36% dos indivíduos avaliados não sofrem de hipertensão.

Também podemos considerar porcentagens calculadas em relação ao total das colunas como indicado na Tabela 4.3. Com base nessa tabela, po-

Tabela 4.3: Porcentagens com totais nas colunas

Insuficiência cardíaca	Hipertensão		Total
	Tem	Não tem	
Tem	37,5%	22,2%	32%
Não tem	62,5%	77,8%	68%
Total	100,0%	100,0%	100,0%

demos dizer que independentemente do *status* desses indivíduos quanto à presença de hipertensão, 32% têm insuficiência cardíaca. Esse cálculo de porcentagens é mais apropriado quando uma das variáveis é considerada explicativa e a outra, considerada resposta.

No exemplo, apesar de o planejamento do estudo indicar que as duas variáveis são respostas (a frequência de cada uma delas não foi fixada *a priori*), para efeito da análise, uma delas (Hipertensão arterial) será considerada explicativa. Isso significa que não temos interesse na distribuição de frequências de hipertensos ou não dentre os 50 pacientes avaliados apesar de ainda querermos avaliar a associação entre as duas variáveis. Nesse caso, dizemos que a variável “Hipertensão arterial” é considerada explicativa **por condicionamento**. Se houvéssemos fixado *a priori* um certo número de hipertensos e outro de não hipertensos e então observado quantos dentre cada um desses dois grupos tinham ou não insuficiência cardíaca, diríamos

que a variável “Hipertensão arterial” seria considerada explicativa **por planejamento**. Nesse caso, apenas as porcentagens calculadas como na Tabela 4.3 fariam sentido. Uma enfoque análogo poderia ser adotado se fixássemos as frequências de “Insuficiência cardíaca” e considerássemos “Hipertensão arterial” como variável resposta. Nesse caso, as porcentagens deveriam ser calculadas em relação ao total das linhas da tabela.

Tabelas com a natureza daquelas descritas acima são chamadas de **tabelas de contingência** ou **tabelas de dupla entrada**. Essas tabelas são classificadas como tabelas $r \times c$ em que r é o número de linhas e c é o número de colunas. As tabelas apresentadas acima são, portanto, tabelas 2×2 . Se a variável X tiver 3 categorias e a variável Y , 4 categorias, a tabela de contingência correspondente será uma tabela 3×4 .

Suponha, agora, que queiramos verificar se as variáveis X e Y são associadas. No caso da Tabela 4.2 (em que as duas variáveis são consideradas respostas), dizer que as variáveis não são associadas corresponde a dizer que essas variáveis são (estatisticamente) independentes. No caso da Tabela 4.3 (em que uma variável é explicativa, quer por condicionamento, quer por planejamento e a outra é considerada resposta), dizer que as variáveis não são associadas corresponde a dizer que as distribuições de frequências da variável resposta (“Insuficiência cardíaca”) para indivíduos classificados em cada categoria da variável explicativa (“Hipertensão arterial”) são homogêneas.

Nas Tabelas 4.2 ou 4.3, por exemplo, há diferenças, que parecem não ser “muito grandes”, o que nos leva a conjecturar que **para a população de onde esses indivíduos foram extraídos**, as duas variáveis não são associadas. Para avaliar essa conjectura, pode-se construir um **teste formal** para essa **hipótese de inexistência de associação** (independência ou homogeneidade), nomeadamente

$$H : X \text{ e } Y \text{ são não associadas.}$$

Convém sempre lembrar que a hipótese H refere-se à associação entre as variáveis X e Y na população (geralmente conceitual) de onde foi extraída uma amostra cujos dados estão dispostos na tabela. Não há dúvidas de que na tabela, as distribuições de frequências correspondentes às colunas rotuladas por “Tem” e “Não tem” hipertensão são diferentes.

Se as duas variáveis não fossem associadas, deveríamos ter porcentagens iguais nas colunas da Tabela 4.3 rotuladas “Tem” e “Não tem”. Podemos então calcular as frequências esperadas nas celas da tabela admitindo que a hipótese H seja verdadeira. Por exemplo, o valor 10,2 corresponde a 32% de 32, ou ainda, $10,2 = (32 \times 16)/50$. Observe que os valores foram arredondados segundo a regra usual e que as somas de linhas e colunas são as mesmas da Tabela 4.1.

Tabela 4.4: Valores esperados das frequências na Tabela 4.3 sob H

Insuficiência Cardíaca	Hipertensão		Total
	Tem	Não Tem	
Tem	10,2	5,8	16
Não Tem	21,8	12,2	34
Total	32	18	50

Chamando os valores observados por o_i e os esperados por e_i , $i = 1, 2, 3, 4$, podemos calcular os **resíduos** $r_i = o_i - e_i$ e verificar que $\sum_i r_i = 0$. Uma medida da discrepância entre os valores observados e aqueles esperados sob a hipótese H é a chamada estatística ou **qui-quadrado** de Pearson, dada por

$$\chi^2 = \sum_{i=1}^4 \frac{(o_i - e_i)^2}{e_i}. \quad (4.1)$$

No nosso exemplo, $\chi^2 = 1,3$. Quanto maior esse valor, maior a **evidência** de que a hipótese H não é verdadeira, ou seja de que as variáveis X e Y são associadas (na população de onde foi extraída a amostra que serviu de base para os cálculos). Resta saber se o valor observado é suficientemente grande para concluirmos que H não é verdadeira. Com essa finalidade, teríamos que fazer um teste formal, o que não será tratado nesse texto. Pode-se mostrar que sob a hipótese H , a estatística (4.1) segue uma distribuição qui-quadrado com número de graus de liberdade igual a $(r - 1)(c - 1)$ de forma que a decisão de rejeitar ou não a hipótese pode ser baseada nessa distribuição. Veja Bussab e Morettin (2017), entre outros, para detalhes.

A própria estatística de Pearson poderia servir como medida da intensidade da associação mas o seu valor aumenta com o tamanho da amostra; uma alternativa para corrigir esse problema é o **coeficiente de contingência de Pearson**, dado por

$$C = \sqrt{\frac{\chi^2}{\chi^2 + n}}. \quad (4.2)$$

Para o Exemplo 4.1, temos que $C = \sqrt{1,3/(1,3 + 50)} = 0,16$, que é um valor pequeno. Esse coeficiente tem interpretação semelhante à do **coeficiente de correlação**, a ser tratado na próxima seção. Mas enquanto esse último varia entre -1 e $+1$, o coeficiente C , como definido acima, não varia entre 0 e 1 (em módulo). O valor máximo de C depende do número de linhas, r , e do número de colunas, c , da tabela de contingência. Uma modificação de C é o **coeficiente de Tschuprov**,

$$T = \sqrt{\frac{\chi^2/n}{\sqrt{(r-1)(c-1)}}, \quad (4.3)}$$

que atinge o valor máximo igual a 1 quando $r = c$. No Exemplo 4.1, $T = 0,16$.

Em estudos que envolvem a mesma característica observada sob duas condições diferentes (gerando duas variáveis, X e Y , cada uma correspondendo à observação da característica sob uma das condições), sabe-se *a priori* que elas são associadas e o interesse recai sobre a avaliação da **concordância** dos resultados em ambas as condições. Nesse contexto, consideremos um exemplo em que as redações de 445 alunos são classificadas por cada um de dois professores (A e B) como “ruim”, “média” ou “boa” com os resultados resumidos na Tabela 4.5.

Tabela 4.5: Frequências de redações classificadas por dois professores

		Professor B		
		ruim	média	boa
Professor A	ruim	192	1	5
	média	2	146	5
	boa	11	12	71

Se todas as frequências estivessem dispostas ao longo da diagonal principal da tabela, diríamos que a haveria completa concordância entre os dois professores com relação ao critério de avaliação das redações. Como em geral isso não acontece, é conveniente construir um índice para avaliar a magnitude da concordância. O índice

$$\kappa = \frac{\sum_{i=1}^3 p_{ii} - \sum_{i=1}^3 p_{i+}p_{+i}}{1 - \sum_{i=1}^3 p_{i+}p_{+i}},$$

denominado κ de Cohen (1960) é o mais utilizado com esse propósito. Nessa expressão, p_{ij} representa frequência relativa associada à cela correspondente à linha i e coluna j da tabela e p_{i+} e p_{+j} representam a soma das frequências relativas associadas à linha i e coluna j , respectivamente. O numerador corresponde à diferença entre a soma das frequências relativas correspondentes à diagonal principal da tabela e a soma das frequências relativas que seriam esperadas se as avaliações dos dois professores fossem independentes. Portanto, quando há concordância completa, $\sum_{i=1}^3 p_{ii} = 1$, o numerador é igual ao denominador e o valor do índice de Cohen é $\kappa = 1$. Quando os dois professores não concordam em nenhuma das avaliações, $\kappa < 0$. Para os dados da Tabela 4.5 temos $\kappa = 0.87$ sugerindo uma “boa” concordância entre as avaliações dos dois professores. Embora o nível de concordância medido pelo índice κ seja subjetivo e dependa da área em que se realiza o estudo gerador dos dados, há autores que sugerem modelos de classificação, como aquele proposto por Viera and Garrett (2005) e reproduzido na Tabela 4.6

Tabela 4.6: Níveis de concordância segundo o índice κ de Cohen

κ de Cohen	Nível de concordância
< 0	Menor do que por acaso
0,01–0,20	Leve
0,21–0,40	Razoável
0,41–0,60	Moderado
0,61–0,80	Substancial
0,81–0,99	Quase perfeito

Para salientar discordâncias mais extremas como no exemplo, um professor classifica a redação como “ruim” e o outro como “boa”, pode-se considerar o índice κ ponderado, definido como

$$\kappa_p = \frac{\sum_{i=1}^3 \sum_{j=1}^3 w_{ij} p_{ij} - \sum_{i=1}^3 \sum_{j=1}^3 w_{ij} p_i + p_{+j}}{1 - \sum_{i=1}^3 \sum_{j=1}^3 w_{ij} p_i + p_{+j}},$$

em que $w_{ij}, i, j = 1, 2, 3$ é um conjunto de pesos convenientes. Por exemplo, $w_{ii} = 1$, $w_{ij} = 1 - (i - j)/(I - 1)$ em que I é o número de categorias em que a característica de interesse é classificada. Para o exemplo, $w_{12} = w_{21} = w_{23} = w_{32} = 1 - 1/2 = 1/2$, $w_{13} = w_{31} = 1 - 2/2 = 0$.

Exemplo 4.2. A Tabela 4.7 contém dados sobre o tipo de escola cursada por alunos aprovados no vestibular da USP em 2018.

Tabela 4.7: Frequências de alunos aprovados no vestibular de 2018 na USP

Tipo de escola frequentada	Área do conhecimento			Total
	Biológicas	Exatas	Humanas	
Pública	341	596	731	1668
Privada	1327	1957	2165	5449
Principalmente pública	100	158	178	436
Principalmente privada	118	194	196	508
Total	1886	2905	3270	8061

O valor da estatística de Pearson (4.1) correspondente aos dados da Tabela 4.7 é $\chi^2 = 15$; com base na distribuição χ^2 com $6 = (4 - 1)(3 - 1)$ graus de liberdade obtemos $p = 0,02$ o que sugere uma associação entre as duas variáveis (tipo de escola e área do conhecimento). No entanto, essa conclusão não tem significância prática, pois a estatística de Pearson terá um valor tanto maior quanto maior for o total da tabela, mesmo que a associação entre as variáveis seja muito tênue. Nesse contexto, convém avaliar essa associação por intermédio dos coeficientes de contingência de

Pearson (4.2) ou de Tschuprov (4.3), entre outros. Para o exemplo, seus valores são, respectivamente, 0,043 e 0,027, sugerindo uma associação de pequena intensidade.

Para comparar as preferências de formação profissional entre alunos que frequentaram diferentes tipos de escola, consideramos as frequências relativas tomando como base os totais das linhas; os resultados estão dispostos na Tabela 4.8.

Tabela 4.8: Frequências relativas de preferências por área de conhecimento (por tipo de escola)

Tipo de escola frequentada	Área do conhecimento			Total
	Biológicas	Exatas	Humanas	
Pública	20,5%	35,7%	43,8%	100,0%
Privada	24,4%	35,9%	39,7%	100,0%
Principalmente pública	23,0%	36,2%	40,8%	100,0%
Principalmente privada	23,2%	38,2%	38,6%	100,0%
Total	23,4%	36,0%	40,6%	100,0%

Grosso modo podemos dizer que cerca de 40% dos alunos que frequentaram escolas públicas ou privadas, mesmo que parcialmente, matricularam-se em cursos de Ciências Humanas, cerca de 36% de alunos com as mesmas características matricularam-se em cursos de Ciências Exatas e os demais 24% em cursos de Ciências Biológicas. Note que foi necessário um ajuste em algumas frequências relativas (por exemplo, o valor correspondente à cela Escola Pública/Ciências Biológicas deveria ser 20,4% e não 20,5%) para que o total somasse 100% mantendo a aparência da tabela com apenas uma casa decimal.

Se, por outro lado, o objetivo for avaliar o tipo de escola frequentado por alunos matriculados em cada área do conhecimento, devemos calcular as frequências relativas tomando como base o total da colunas; os resultados estão dispostos na Tabela 4.9 e sugerem que dentre os alunos que optaram por qualquer das três áreas, cerca de 21% são oriundos de escolas públicas, cerca de 68% de escolas privadas com os demais 11% tendo cursado escolas públicas ou privadas parcialmente.

Tabela 4.9: Frequências relativas tipo de escola cursada (por área do conhecimento)

Tipo de escola frequentada	Área do conhecimento			Total
	Biológicas	Exatas	Humanas	
Pública	18,1%	20,5%	22,4%	20,7%
Privada	70,3%	67,4%	66,2%	67,6%
Principalmente pública	5,3%	5,4%	5,4%	5,4%
Principalmente privada	6,3%	6,7%	6,0%	6,3%
Total	100,0%	100,0%	100,0%	100,0%

Risco atribuível, risco relativo e razão de chances

Em muitas áreas do conhecimento há interesse em avaliar a associação entre um ou mais **fatores de risco** e uma variável resposta. Num estudo epidemiológico, por exemplo, pode haver interesse em avaliar a associação entre o hábito tabagista (fator de risco) e a ocorrência de algum tipo de câncer pulmonar (variável resposta). Um exemplo na área de Seguros pode envolver a avaliação da associação entre estado civil e sexo (considerados como fatores de risco) e o envolvimento em acidente automobilístico (variável resposta).

No primeiro caso, os dados obtidos de uma amostra de 50 fumantes e 100 não fumantes, por exemplo, para os quais se observa a ocorrência de câncer pulmonar após um determinado período podem ser dispostos no formato da Tabela 4.10. Esse tipo de estudo em que se fixam os níveis do fator de risco (hábito tabagista) e se observa a ocorrência do evento de interesse (câncer pulmonar) após um determinado tempo é conhecido como **estudo prospectivo**.

Tabela 4.10: Frequências de doentes observados num estudo prospectivo

Hábito tabagista	Câncer pulmonar		Total
	sem	com	
não fumante	80	20	100
fumante	35	15	50

Para a população da qual essa amostra é considerada oriunda (e para a qual se quer fazer inferência), a tabela correspondente pode ser expressa como na Tabela 4.11.

Tabela 4.11: Probabilidades de ocorrência de doença

Hábito tabagista	Câncer pulmonar		Total
	sem	com	
não fumante	$1 - \pi_0$	π_0	1
fumante	$1 - \pi_1$	π_1	1

O parâmetro π_0 corresponde à proporção (ou probabilidade) de indivíduos que contraem câncer pulmonar dentre os que **sabemos** ser não fumantes; analogamente, π_1 corresponde à proporção (ou probabilidade) de indivíduos que contraem câncer pulmonar dentre os que **sabemos** ser fumantes.

Nesse contexto podemos definir algumas medidas de associação (entre o fator de risco e a variável resposta).

- Risco atribuível:** $d = \pi_1 - \pi_0$ que corresponde à diferença entre as probabilidades de ocorrência do evento de interesse para expostos e não expostos ao fator de risco.

- ii) **Risco relativo:** $r = \pi_1/\pi_0$ que corresponde ao quociente entre as probabilidades de ocorrência do evento de interesse para expostos e não expostos ao fator de risco.
- iii) **Razão de chances (odds ratio)¹:** $\omega = [\pi_1/(1 - \pi_1)]/[\pi_0/(1 - \pi_0)]$ que corresponde ao quociente entre as chances de ocorrência do evento de interesse para expostos e não expostos ao fator de risco.

No exemplo da Tabela 4.10 essas medidas de associação podem ser estimadas como

- i) Risco atribuível: $d = 0,30 - 0,20 = 0,10$ (o risco de ocorrência de câncer pulmonar aumenta de 10% para fumantes relativamente aos não fumantes).
- ii) Risco relativo: $r = 0,30/0,20 = 1,50$ (o risco de ocorrência de câncer pulmonar para fumantes é 1,5 vezes o risco correspondente para não fumantes).
- iii) Chances: a chance de ocorrência de câncer pulmonar para fumantes é $0,429 = 0,30/0,70$; a chance de ocorrência de câncer pulmonar para não fumantes é $0,250 = 0,20/0,80$.
- iv) Razão de chances: $\omega = 0,429/0,250 = 1,72$ (a chance de ocorrência de câncer pulmonar para fumantes é 1,71 vezes a chance correspondente para não fumantes).

Em geral, a medida de associação de maior interesse prático pela facilidade de interpretação, seja o risco relativo, a razão de chances talvez seja a mais utilizada na prática. Primeiramente, observemos que

$$\omega = \frac{\pi_1/(1 - \pi_1)}{\pi_0/(1 - \pi_0)} = r \frac{1 - \pi_0}{1 - \pi_1} \rightarrow r, \text{ quando } \pi_0 \text{ e } \pi_1 \rightarrow 0$$

ou seja, para eventos raros [cujas probabilidade π_1 ou π_0 são muito pequenas], a razão de chances serve como uma boa aproximação do risco relativo.

Em geral, estudos prospectivos com a natureza daquele que motivou a discussão acima não são praticamente viáveis em função do tempo decorrido até o diagnóstico da doença. Uma alternativa é a condução de **estudos retrospectivos** em que, por exemplo, são selecionados 35 pacientes com e 115 pacientes sem câncer pulmonar e se determinam quais dentre eles eram fumantes e não fumantes. Nesse caso, os papéis das variáveis explicativa e resposta se invertem, sendo o *status* relativo à presença da moléstia encarado

¹Lembremos que **probabilidade** é uma medida de frequência de ocorrência de um evento (quanto maior a probabilidade de um evento, maior a frequência com que ele ocorre) cujos valores variam entre 0 e 1 (ou entre 0% e 100%). Uma medida de frequência equivalente mas com valores entre 0 e ∞ é conhecida como **chance (odds)**. Por exemplo, se um evento ocorre com probabilidade 0.8 (80%), a chance de ocorrência é 4 (= 80% / 20%) ou mais comumente de 4 para 1, indicando que em cinco casos, o evento ocorre em 4 e não ocorre em 1.

como variável explicativa e o hábito tabagista, como variável resposta. A Tabela 4.12 contém dados hipotéticos de um estudo retrospectivo planejado com o mesmo intuito do estudo prospectivo descrito acima, ou seja, avaliar a associação entre tabagismo e ocorrência de câncer de pulmão.

Tabela 4.12: Frequências de fumantes observados num estudo retrospectivo

Hábito tabagista	Câncer pulmonar	
	sem	com
não fumante	80	20
fumante	35	15
Total	115	35

A Tabela 4.13 representa as probabilidades pertinentes.

Tabela 4.13: Probabilidades de hábito tabagista

Hábito tabagista	Câncer pulmonar	
	sem	com
não fumante	$1 - p_0$	$1 - p_1$
fumante	p_0	p_1
Total	1	1

O parâmetro p_0 corresponde à proporção (ou probabilidade) de fumantes **dentre** os indivíduos que **sabemos** não ter câncer pulmonar; analogamente, p_1 corresponde à proporção (ou probabilidade) de não fumantes **dentre** os indivíduos que **sabemos** ter câncer pulmonar. Nesse caso, não é possível calcular nem o risco atribuível nem o risco relativo, pois não se conseguem estimar as probabilidades de ocorrência de câncer pulmonar, π_1 ou π_0 . No entanto, pode-se demonstrar (ver Nota de Capítulo 1) que a razão de chances obtida por meio de um estudo retrospectivo é igual àquela que seria obtida por intermédio de um estudo prospectivo correspondente ou seja

$$\omega = \frac{p_1/(1-p_1)}{p_0/(1-p_0)} = \frac{\pi_1/(1-\pi_1)}{\pi_0/(1-\pi_0)}.$$

Num estudo retrospectivo, pode-se afirmar que a chance de ocorrência do evento de interesse (câncer pulmonar, por exemplo) para indivíduos expostos ao fator de risco é ω vezes a chance correspondente para indivíduos não expostos, embora não se possa estimar quanto valem essas chances.

Detalhes sobre estimativas e intervalos de confiança para o risco relativo e razão de chances são apresentados na Nota de Capítulo 7.

A partir das frequências da Tabela 4.12 podemos estimar a chance de um indivíduo ser fumante dado que tem câncer pulmonar como $0,751 = 0,429/0,571$ e a chance de um indivíduo ser fumante dado que não tem câncer pulmonar como $0,437 = 0,304/0,696$; a razão de chances correspondente é $\omega = 0,751/0,437 = 1,72$. Essas chances não são aquelas de

interesse pois gostaríamos de conhecer as chances de ter câncer pulmonar para indivíduos fumantes e não fumantes. No entanto a razão de chances tem o mesmo valor que aquela calculada por meio de um estudo prospectivo, ou seja, a partir da análise dos dados da Tabela 4.12, não é possível calcular a chance de ocorrência de câncer pulmonar nem para fumantes nem para não fumantes mas podemos concluir que a primeira é 1,72 vezes a segunda.

Avaliação de testes diagnósticos

Dados provenientes de estudos planejados com o objetivo de avaliar a capacidade de testes laboratoriais ou exames médicos para diagnóstico de alguma doença envolvem a classificação de indivíduos segundo duas variáveis; a primeira corresponde ao verdadeiro *status* relativamente à presença da moléstia (doente ou não doente) e a segunda ao resultado do teste (positivo ou negativo). Dados correspondentes aos resultados de um determinado teste aplicado a n indivíduos podem ser dispostos no formato da Tabela 4.14.

Tabela 4.14: Frequência de pacientes submetidos a um teste diagnóstico

Verdadeiro status	Resultado do teste		Total
	positivo (T+)	negativo (T-)	
doente (D)	n_{11}	n_{12}	n_{1+}
não doente (ND)	n_{21}	n_{22}	n_{2+}
Total	n_{+1}	n_{+2}	n

Aqui, n_{ij} corresponde à frequência de indivíduos com o i -ésimo *status* relativo à doença ($i = 1$ para doentes e $i = 2$ para não doentes) e j -ésimo *status* relativo ao resultado do teste ($j = 1$ para resultado positivo e $j = 2$ para resultado negativo). Além disso, $n_{i+} = n_{i1} + n_{i2}$ e $n_{+j} = n_{1j} + n_{2j}$, $i, j = 1, 2$. As seguintes características associadas aos testes diagnóstico são bastante utilizadas na prática.

- i) **Sensibilidade:** corresponde à probabilidade de resultado positivo para pacientes doentes [$S = P(T+|D)$] e pode ser estimada por $s = n_{11}/n_{1+}$;
- ii) **Especificidade:** corresponde à probabilidade de resultado negativo para pacientes não doentes [$E = P(T-|ND)$] e pode ser estimada por $e = n_{22}/n_{2+}$;
- iii) **Falso positivo:** corresponde à probabilidade de resultado positivo para pacientes não doentes [$FP = P(ND|T+)$] e pode ser estimada por $fp = n_{21}/n_{+1}$;
- iv) **Falso negativo:** corresponde à probabilidade de resultado negativo para pacientes doentes [$FN = P(D|T-)$] e pode ser estimada por $fn = n_{12}/n_{+2}$;
- v) **Valor preditivo positivo:** corresponde à probabilidade de que o paciente seja doente dado que o resultado do teste é positivo [$VPP =$

- $P(D|T+)$] e pode ser estimada por $vpp = n_{11}/n_{+1}$;
- vi) **Valor preditivo negativo:** corresponde à probabilidade de que o paciente não seja doente dado que o resultado do teste é negativo [$VPN = P(ND|T-)$] e pode ser estimada por $vpn = n_{22}/n_{+2}$;
- vii) **Acurácia:** corresponde à probabilidade de resultados corretos [$AC = P\{(D \cap T+) \cup (ND \cap T-)\}$] e pode ser estimada por $ac = (n_{11} + n_{22})/n$.

A sensibilidade de um teste corresponde à proporção de doentes identificados por seu intermédio, ou seja, é um indicativo da capacidade de o teste detectar a doença. Por outro lado, a especificidade de um teste corresponde à sua capacidade de identificar indivíduos que não têm a doença.

Quanto maior a sensibilidade de um teste, menor é a possibilidade de que indique falsos positivos. Um teste com sensibilidade de 95%, por exemplo, consegue identificar um grande número de pacientes que realmente têm a doença e por esse motivo testes com alta sensibilidade são utilizados em triagens. Quanto maior a especificidade de um teste, maior é a probabilidade de apresentar um resultado negativo para pacientes que não têm a doença. Se, por exemplo, a especificidade de um teste for de 99% dificilmente um paciente que não tem a doença terá um resultado positivo. Um bom teste é aquele que apresenta alta sensibilidade e alta especificidade, mas nem sempre isso é possível.

O valor preditivo positivo indica a probabilidade de um indivíduo ter a doença dado que o resultado do teste é positivo e valor preditivo negativo indica a probabilidade de um indivíduo não ter a doença dado um resultado negativo no teste.

Sensibilidade e especificidade são características do teste, mas tanto o valor preditivo positivo quanto o valor preditivo negativo dependem da **prevalência** (porcentagem de indivíduos doentes) da doença. Consideremos um exemplo em que o mesmo teste diagnóstico é aplicado em duas comunidades com diferentes prevalências de uma determinada doença. A Tabela 4.15 contém os dados da comunidade em que a doença é menos prevalente e a Tabela 4.16 contém os dados da comunidade em que a doença é mais prevalente.

Tabela 4.15: Frequência de pacientes submetidos a um teste diagnóstico (prevalência da doença = 15%)

Verdadeiro status	Resultado do teste		Total
	positivo (T+)	negativo (T-)	
doente (D)	20	10	30
não doente (ND)	80	90	170
Total	100	100	200

Tabela 4.16: Frequência de pacientes submetidos a um teste diagnóstico (prevalência da doença = 30%)

Verdadeiro status	Resultado do teste		Total
	positivo (T+)	negativo (T-)	
doente (D)	40	20	60
não doente (ND)	66	74	140
Total	106	94	200

Os valores estimados para a sensibilidade, especificidade, valores preditivo positivo e negativo além da acurácia estão dispostos na Tabela 4.17

Tabela 4.17: Características do teste aplicado aos dados das Tabelas 4.15 e 4.16

Característica	População com doença	
	menos prevalente	mais prevalente
Sensibilidade	67%	67%
Especificidade	53%	53%
VPP	20%	38%
VPN	90%	79%
Acurácia	55%	57%

4.3 Duas variáveis quantitativas

Uma das principais ferramentas para avaliar a associação entre duas variáveis quantitativas é o **gráfico de dispersão**. Consideremos um conjunto de n pares de valores (x_i, y_i) de duas variáveis X e Y ; o gráfico de dispersão correspondente é um gráfico cartesiano em que os valores de uma das variáveis são colocados no eixo das abscissas e os da outra, no eixo das ordenadas.

Exemplo 4.3 Os dados contidos na Tabela 4.18, disponíveis no arquivo `figado`, correspondem a um estudo cujo objetivo principal era avaliar a associação entre o volume (cm^3) do lobo direito de fígados humanos medido ultrassonograficamente e o seu peso (g). Um objetivo secundário era avaliar a concordância de medidas ultrassonográficas do volume (Volume1 e Volume2) realizadas por dois observadores. O volume foi obtido por meio da média das duas medidas ultrassonográficas. Detalhes podem ser obtidos em Zan (2005).

O gráfico de dispersão correspondente às variáveis Volume e Peso está apresentado na Figura 4.1. Nesse gráfico pode-se notar que a valores menores do volume correspondem valores menores do peso e a valores maiores do volume correspondem valores maiores do peso, sugerindo uma associação positiva e possivelmente linear entre as duas variáveis. Além disso, o gráfico permite identificar um possível ponto discrepante (*outlier*) correspondente à

Tabela 4.18: Peso e volume do lobo direito de enxertos de fígado

Volume1 (cm^3)	Volume2 (cm^3)	Volume (cm^3)	Peso (g)
672,3	640,4	656,3	630
686,6	697,8	692,2	745
583,1	592,4	587,7	690
850,1	747,1	798,6	890
729,2	803,0	766,1	825
776,3	823,3	799,8	960
715,1	671,1	693,1	835
634,5	570,2	602,3	570
773,8	701,0	737,4	705
928,3	913,6	920,9	955
916,1	929,5	922,8	990
983,2	906,2	944,7	725
750,5	881,7	816,1	840
571,3	596,9	584,1	640
646,8	637,4	642,1	740
1021,6	917,5	969,6	945

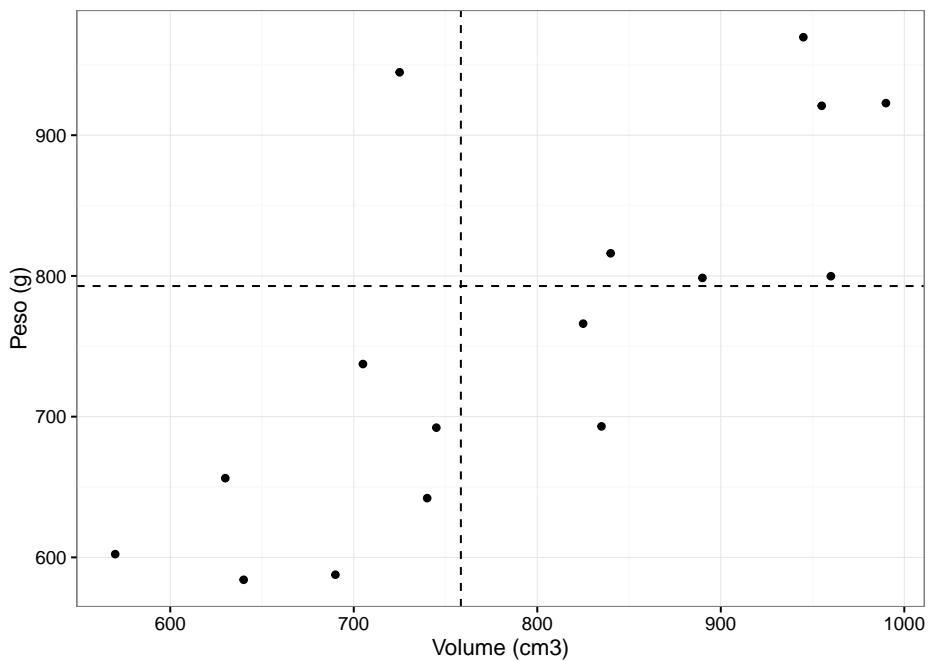


Figura 4.1: Gráfico de dispersão entre peso e volume do lobo direito de enxertos de fígado.

unidade amostral em que o volume é 725cm^3 e o peso é $944,7\text{g}$. A utilização dessas constatações para a construção de um modelo que permita estimar o peso como função do volume é o objeto da técnica conhecida como **Análise de Regressão** que será considerada no Capítulo 6.

Dado um conjunto de n pares (x_i, y_i) , a associação (linear) entre as variáveis quantitativas X e Y pode ser quantificada por meio do **coeficiente de correlação (linear)** de Pearson, definido por

$$r_P = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{[\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2]^{1/2}}. \quad (4.4)$$

Pode-se mostrar que $-1 \leq r_P \leq 1$ e, na prática, se o valor r_P estiver próximo de -1 ou $+1$, pode-se dizer que as variáveis são fortemente associadas ou (linearmente) correlacionadas; por outro lado, se o valor de r_P estiver próximo de zero, dizemos que as variáveis são não correlacionadas. Quanto mais próximos de uma reta estiverem os pontos (x_i, y_i) , maior será a intensidade da correlação (linear) entre elas.

Não é difícil mostrar que

$$r_P = \frac{\sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}}{[(\sum_{i=1}^n x_i^2 - n\bar{x}^2)(\sum_{i=1}^n y_i^2 - n\bar{y}^2)]^{1/2}}. \quad (4.5)$$

Essa expressão é mais conveniente que (4.4), pois basta calcular: (a) as médias amostrais \bar{x} e \bar{y} ; (b) a soma dos produtos $x_i y_i$ e (c) a soma dos quadrados dos x_i e a soma dos quadrados dos y_i .

Para os dados do Exemplo 4.3, o coeficiente de correlação de Pearson é 0,76. Se excluirmos o dado discrepante identificado no gráfico de dispersão, o valor do coeficiente de correlação de Pearson é 0,89, evidenciando a falta de robustez desse coeficiente relativamente a observações com essa natureza. Nesse contexto, uma medida de associação mais robusta é o coeficiente de correlação de Spearman, cuja expressão é similar à (4.4) com os valores das variáveis X e Y substituídos pelos respectivos postos.² Mais especificamente, o coeficiente de correlação de Spearman é

$$r_S = \frac{\sum_{i=1}^n (R_i - \bar{R})(S_i - \bar{S})}{[\sum_{i=1}^n (R_i - \bar{R})^2 \sum_{i=1}^n (S_i - \bar{S})^2]^{1/2}}, \quad (4.6)$$

em que R_i corresponde ao posto da i -ésima observação da variável X entre seus valores e \bar{R} à média desses postos e S_i e \bar{S} têm interpretação similar para a variável Y . Para efeito de cálculo pode-se mostrar que a expressão (4.6) é equivalente a

$$r_S = 1 - 6 \sum_{i=1}^n (R_i - S_i)^2 / [n(n^2 - 1)]. \quad (4.7)$$

²O posto de uma observação x_i é o índice correspondente à sua posição no conjunto ordenado $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$. Por exemplo, dado o conjunto de observações $x_1 = 4$, $x_2 = 7$, $x_3 = 5$, $x_4 = 13$, $x_5 = 6$, $x_6 = 5$, o posto correspondente à x_5 é 4. Quando há observações com o mesmo valor, o posto correspondente a cada uma delas é definido como a média dos postos correspondentes. No exemplo, os postos das observações x_3 e x_6 são iguais a $2,5 = (2 + 3)/2$.

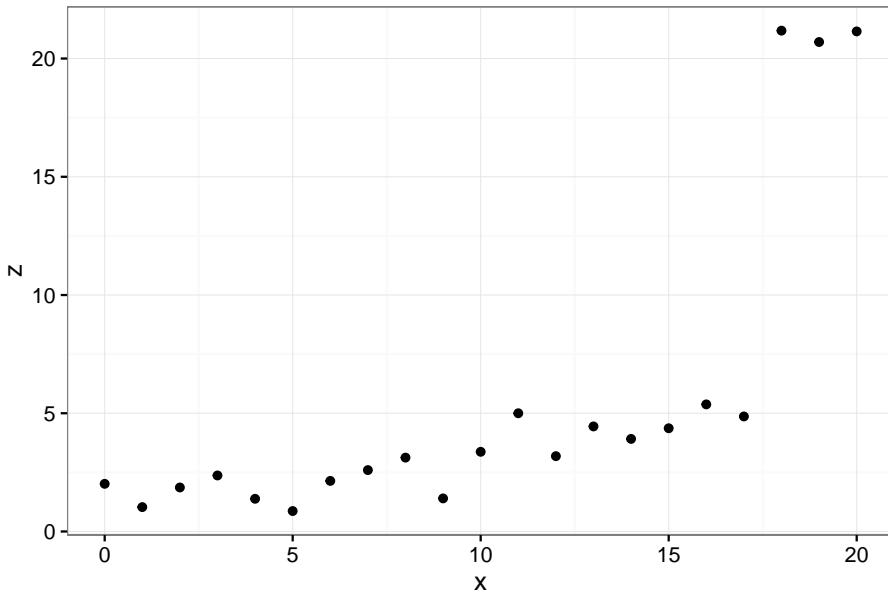


Figura 4.2: Gráfico de dispersão entre valores de duas variáveis X e Z .

Os dados correspondentes à Figura 4.2 foram gerados a partir da expressão $z_i = 1 + 0,25x_i + e_i$ com e_i simulado a partir de uma distribuição Normal padrão e com as três últimas observações acrescidas de 15. Para esses dados obtemos $r_P = 0.73$ e $r_S = 0.90$. Eliminando as três observações com valores discrepantes, os coeficientes de correlação correspondentes são $r_P = 0.85$ e $r_S = 0.84$, indicando que o primeiro é mais afetado do que o segundo.

Além disso, o coeficiente de correlação de Spearman também é mais apropriado para avaliar associações não lineares, desde que sejam monotônicas, *i.e.*, em que os valores de uma das variáveis só aumentam ou só diminuem conforme a segunda variável aumenta (ou diminui). Os dados representados na Figura 4.3 foram gerados a partir da expressão $y_i = \exp(0.4x_i)$, $i = 1, \dots, 20$.

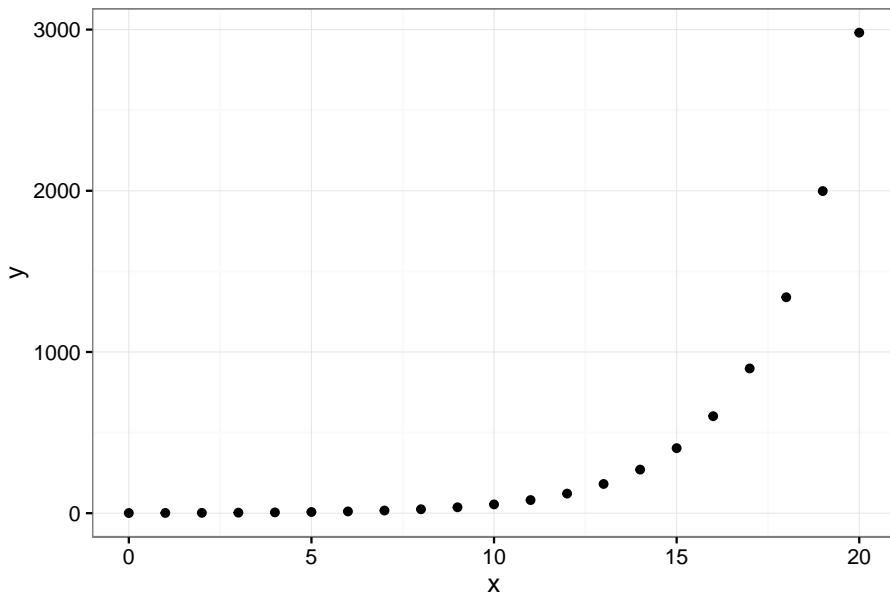


Figura 4.3: Gráfico de dispersão entre valores de duas variáveis X e Y .

Nesse caso, os valores dos coeficientes de correlação de Pearson e de Spearman são, respectivamente, $r_P = 0.75$ e $r_S = 1$ indicando que apenas este último é capaz de realçar a associação perfeita entre as duas variáveis.

Gráficos de perfis individuais

Para dados longitudinais, *i.e.*, aqueles em que a mesma variável resposta é observada em cada unidade amostral mais do que uma vez ao longo do tempo (ou de outra escala ordenada, como distância de uma fonte poluidora, por exemplo), uma das ferramentas descritivas mais importantes são os chamados **gráficos de perfis individuais**. Eles são essencialmente gráficos de dispersão (com o tempo na abscissa e a resposta na ordenada) em que os pontos associados a uma mesma unidade amostral são unidos por segmentos de reta. Em geral, os perfis médios são sobrepostos a eles. Esse tipo de gráfico pode ser utilizado para sugerir modelos de regressão (ver Capítulo 6) construídos para modelar o comportamento temporal da resposta esperada e também para identificar possíveis unidades ou observações discrepantes.

Exemplo 4.4. Os dados do arquivo `lactato` foram obtidos de um estudo realizado na Escola de Educação Física da Universidade de São Paulo com o objetivo de comparar a evolução da concentração sérica de lactato de sódio (mmol/L) como função da velocidade de dois grupos de atletas: 14 fundistas e 12 triatletas. A concentração sérica de lactato de sódio tem sido utilizada como um indicador da condição física de atletas. Nesse estudo, cada atleta correu durante certos períodos com velocidades pré-estabelecidas e a concentração de lactato de sódio foi registrada logo após cada corrida. A observação repetida da resposta em cada atleta caracteriza a natureza

longitudinal dos dados. Por meio dos comandos

```
> library(gdata)
> library(ggplot2)
> library(reshape2)
> library(dplyr)
>
> lactato <- read.xls("/home/jmsinger/Desktop/lactato.xls",
+                       sheet='dados', method="tab")
> fundistas <- lactato[which(lactato$group == 0), ]
> fundistas1 <- fundistas[-1]
> fundistas2 <- melt(fundistas1, id.vars = "ident")
> fundistaslong <- group_by(fundistas2, ident)
>
> g1 <- ggplot(fundistaslong) +
+   geom_line(aes(variable, value, group = ident))
> g2 <- g1 + theme_bw() + annotate("text", x = 5, y = 5,
+                                   label = "atleta 9")
> g3 <- g2 + labs(x="velocidade",
+                   y="Concentração de lactato de sódio")
> g4 <- g3 + theme(text=element_text(size=18))
> g4
```

obtemos o gráfico de perfis individuais para os fundistas que está representado na Figura 4.4 e sugere que i) a relação entre a concentração esperada de lactato de sódio pode ser representada por uma curva quadrática no intervalo de velocidades considerado e ii) o atleta 9 é um possível *outlier*. Na realidade, verificou-se que esse atleta era velocista e não fundista.

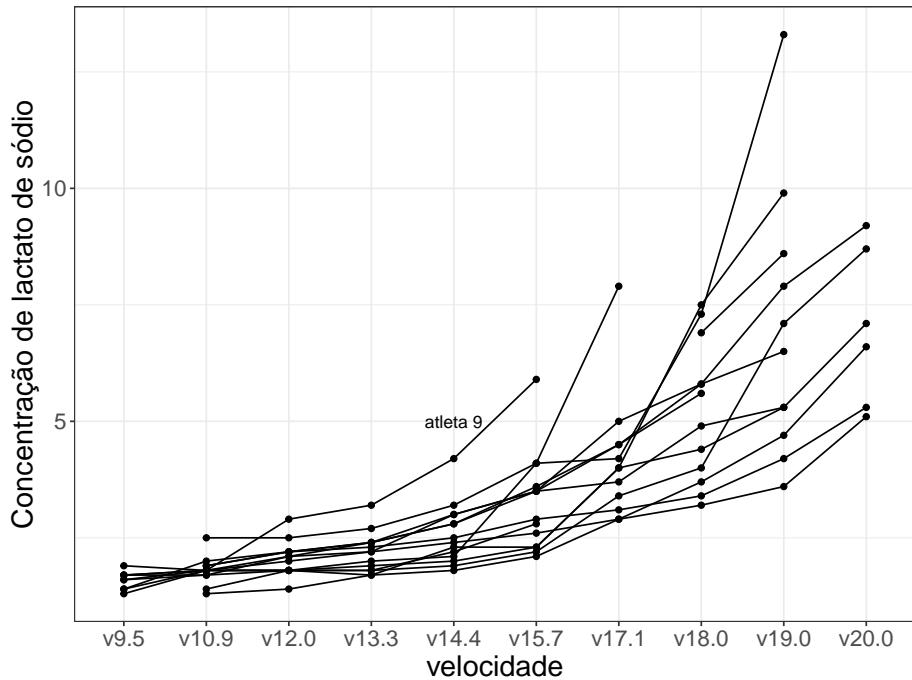


Figura 4.4: Gráfico de perfis individuais para os dados do Exemplo 4.4 (atletas fundistas).

Gráficos QQ para comparação de duas distribuições amostrais

Uma ferramenta adequada para comparar as distribuições de uma característica observada sob duas condições diferentes é o gráfico QQ utilizado na Seção 3.7 para a comparação de uma distribuição empírica com uma distribuição teórica. Um exemplo típico é aquele referente ao objetivo secundário mencionado na descrição do Exemplo 4.3, em que se pretende avaliar a concordância entre as duas medidas ultrassonográficas do volume do lobo direito do fígado.

Denotando por X uma das medidas e por Y , a outra, sejam $Q_X(p)$ e $Q_Y(p)$ os quantis de ordem p das duas distribuições que pretendemos comparar. O gráfico QQ é um gráfico cartesiano de $Q_X(p)$ em função de $Q_Y(p)$ (ou vice-versa) para diferentes valores de p . Se as distribuições de X e Y forem iguais, os pontos nesse gráfico devem estar sobre a reta $x = y$. Se uma das variáveis for uma função linear da outra, os pontos também serão dispostos sobre uma reta, porém com intercepto possivelmente diferente de zero e com inclinação possivelmente diferente de 1.

Quando os números de observações das duas variáveis for igual, o gráfico QQ é essencialmente um gráfico dos dados ordenados de X , ou seja $x_{(1)} \leq \dots \leq x_{(n)}$, *versus* os dados ordenados de Y , nomeadamente, $y_{(1)} \leq \dots \leq y_{(n)}$.

Quando os números de observações das duas variáveis forem diferentes,

digamos $m > n$, calculam-se os quantis amostrais referentes àquela variável com menos observações utilizando $p_i = (i-0,5)/n$, $i = 1, \dots, n$ e obtêm-se os quantis correspondentes à segunda variável por meio de interpolações como aquelas indicadas em (3.5). Consideremos, por exemplo os conjuntos de valores $x_{(1)} \leq \dots \leq x_{(n)}$ e $y_{(1)} \leq \dots \leq y_{(m)}$. Primeiramente, determinemos $p_i = (i - 0,5)/n$, $i = 1, \dots, n$ para obter os quantis $Q_X(p_i)$; em seguida, devemos obter índices j tais que

$$\frac{j - 0,5}{m} = \frac{i - 0,5}{n} \text{ ou seja } j = \frac{m}{n}(i - 0,5) + 0,5.$$

Se j obtido dessa forma for inteiro, o ponto a ser disposto no gráfico QQ será $(x_{(i)}, y_{(j)})$; em caso contrário, teremos $j = [j] + f_j$ em que $[j]$ é o maior inteiro contido em j e $0 < f_j < 1$ é a correspondente parte fracionária ($f_j = j - [j]$). O quantil correspondente para a variável Y será:

$$Q_Y(p_i) = (1 - f_j)y_{([j])} + f_jy_{([j]+1)}.$$

Por exemplo, sejam $m = 45$ e $n = 30$; então, para $i = 1, \dots, 30$ temos

$$p_i = (i - 0,5)/30 \text{ e } Q_X(p_i) = x_{(i)}$$

logo $j = 45/30(i - 0,5) + 0,5 = 1,5i - 0,25$ e $[j] = [1,5i - 0,25]$. Consequentemente, no gráfico QQ, o quantil $Q_X(p_i)$ deve ser pareado com o quantil $Q_Y(p_i)$ conforme o seguinte esquema

i	p_i	j	$[j]$	$j - [j]$	$Q_X(p_i)$	$Q_Y(p_i)$
1	0,017	1,25	1	0,25	$x_{(1)}$	$0,75y_{(1)} + 0,25y_{(2)}$
2	0,050	2,75	2	0,75	$x_{(2)}$	$0,25y_{(2)} + 0,75y_{(3)}$
3	0,083	4,25	4	0,25	$x_{(3)}$	$0,75y_{(4)} + 0,25y_{(5)}$
4	0,117	5,75	5	0,75	$x_{(4)}$	$0,25y_{(5)} + 0,75y_{(6)}$
5	0,150	7,25	7	0,25	$x_{(5)}$	$0,75y_{(7)} + 0,25y_{(8)}$
6	0,183	8,75	8	0,75	$x_{(6)}$	$0,25y_{(8)} + 0,75y_{(9)}$
7	0,216	10,25	10	0,25	$x_{(7)}$	$0,75y_{(10)} + 0,25y_{(11)}$
8	0,250	11,75	11	0,75	$x_{(8)}$	$0,25y_{(11)} + 0,75y_{(12)}$
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots
30	0,983	44,75	44	0,75	$x_{(30)}$	$0,25y_{(44)} + 0,75y_{(45)}$

Suponha, por exemplo, que duas variáveis, X e Y , sejam tais que $Y = aX + b$, indicando que suas distribuições são iguais, exceto por uma transformação linear. Então,

$$p = P[X \leq Q_X(p)] = P[aX + b \leq aQ_X(p) + b] = P[Y \leq Q_Y(p)],$$

ou seja, $Q_Y(p) = aQ_X(p) + b$, indicando que o gráfico QQ correspondente mostrará uma reta com inclinação a e intercepto b .

Para a comparação das distribuições do volume ultrassonográfico do lobo direito do fígado medidas pelos dois observadores mencionados no Exemplo 4.3, o gráfico QQ está disposto na Figura 4.5.

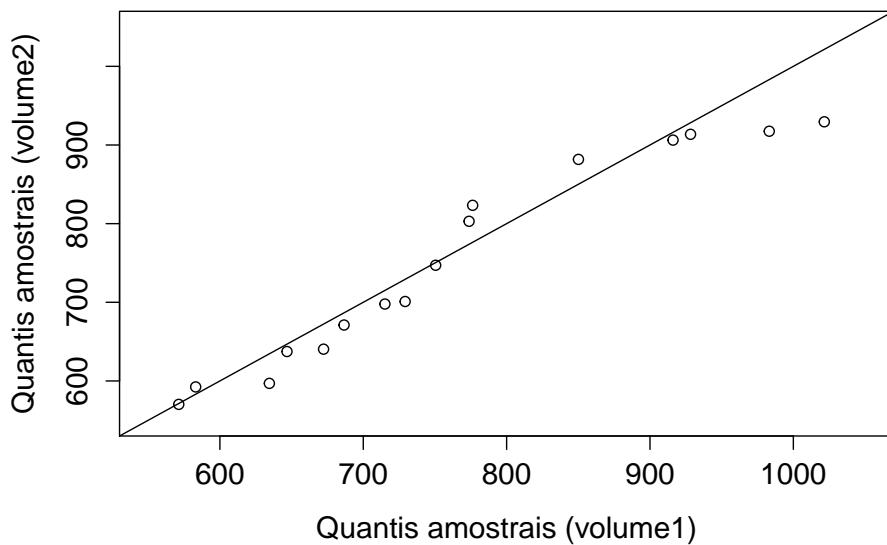


Figura 4.5: Gráfico QQ para avaliação da concordância de duas medidas ultrassonográficas do lobo direito do fígado.

Os pontos distribuem-se em torno da reta $x = y$ sugerindo que as medidas realizadas pelos dois observadores tendem a ser similares. Em geral os gráficos QQ são mais sensíveis a diferenças nas caudas das distribuições, se estas forem aproximadamente simétricas e com a aparência de uma distribuição Normal. Enquanto os diagramas de dispersão mostram uma relação sistemática global entre X e Y , os gráficos QQ relacionam valores pequenos de X com valores pequenos de Y , valores medianos de X com valores medianos de Y e valores grandes de X com valores grandes de Y .

Uma ferramenta geralmente utilizada para avaliar concordância entre as distribuições de duas variáveis contínuas com o mesmo espírito da estatística κ é o **gráfico de médias/diferenças** originalmente proposto por Tukey e popularizado como **gráfico de Bland-Altman**. Essencialmente, essa ferramenta consiste num gráfico das diferenças entre as duas observações pareadas ($X_{2i} - X_{1i}$) em função das médias correspondentes $[(X_{1i} + X_{2i})/2]$, $i = 1, \dots, n$. Esse procedimento transforma a reta com coeficiente angular igual 1 apresentada no gráfico QQ numa reta horizontal passando pelo ponto zero no gráfico de médias/diferenças de Tukey e facilita a percepção das diferenças entre as duas medidas da mesma característica.

Note que enquanto gráficos QQ são construídos a partir do quantis amostrais, gráficos de Bland-Altman baseiam-se no próprios valores das variáveis em questão. Por esse motivo, para a construção de gráficos de Bland-Altman as observações devem ser pareadas ao passo que gráficos QQ podem ser construídos a partir de conjuntos de dados desbalanceados (com número diferentes de observações para cada variável).

O gráfico de médias/diferenças de Tukey (Bland-Altman) correspondente aos volumes medidos pelos dois observadores e indicados na Tabela 4.18 está

apresentado na Figura 4.6.

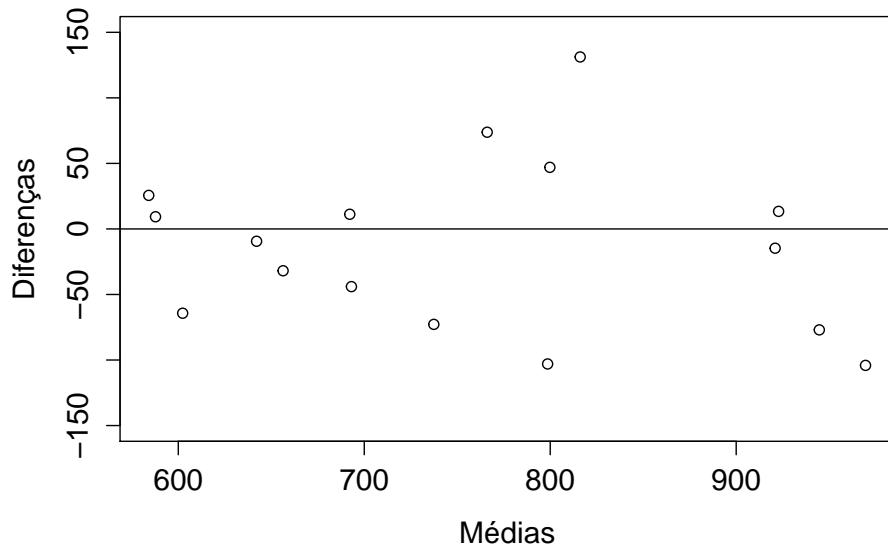


Figura 4.6: Gráfico de médias/diferenças de Tukey (Bland-Altman) para avaliação da concordância de duas medidas ultrassonográficas do lobo direito do fígado.

Os pontos no gráfico de médias/diferenças de Tukey distribuem-se de forma não regular em torno do valor zero e não sugerem evidências de diferenças entre as distribuições correspondentes. Por essa razão, para diminuir a variabilidade, decidiu-se adotar a média das medidas obtidas pelos dois observadores como volume do lobo direito do fígado para avaliar sua associação com o peso correspondente.

Exemplo 4.5 Os dados contidos na Tabela 4.19 foram extraídos de um estudo para avaliação de insuficiência cardíaca e correspondem à frequência cardíaca em repouso e no limiar anaeróbio de um exercício em esteira para 20 pacientes. O conjunto de dados completos está disponível no arquivo `esforco`.

Tabela 4.19: Frequência cardíaca em repouso (fcrep) e no limiar anaeróbio (fclan) de um exercício em esteira

paciente	fcrep	fclan	paciente	fcrep	fclan
1	89	110	11	106	157
2	69	100	12	83	127
3	82	112	13	90	104
4	89	104	14	75	82
5	82	120	15	100	117
6	75	112	16	97	122
7	89	101	17	76	140
8	91	135	18	77	97
9	101	131	19	85	101
10	120	129	20	113	150

Os gráficos QQ e de médias/diferenças de Tukey correspondentes aos dados da Tabela 4.19 estão apresentados nas Figuras 4.7 e 4.8.

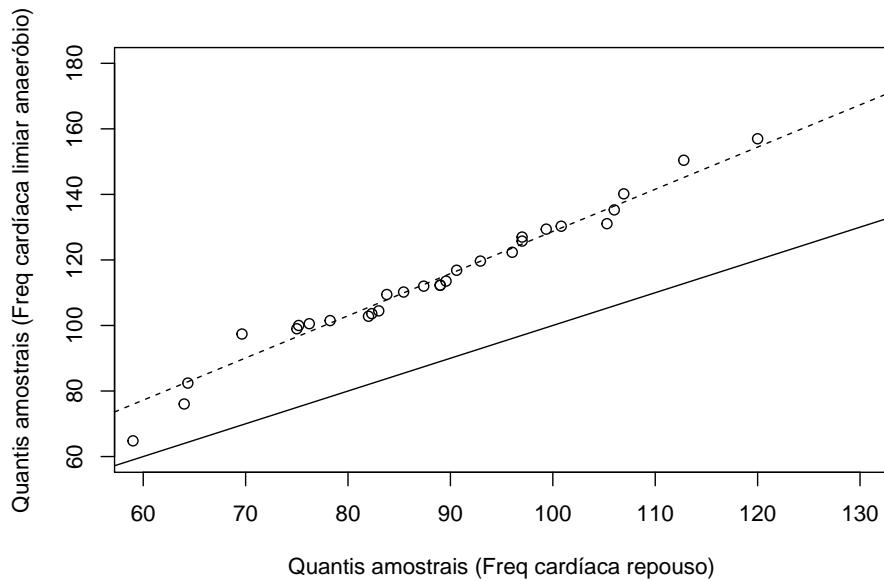


Figura 4.7: Gráfico QQ para comparação das distribuições de frequência cardíaca em repouso e no limiar anaeróbio.

Na Figura 4.7, a curva pontilhada corresponde à reta $Q_Y(p) = 1.29Q_X(p)$ sugerindo que a frequência cardíaca no limiar anaeróbio (Y) tende a ser cerca de 30% maior que aquela em repouso (X) em toda faixa de variação. Isso também pode ser observado, embora com menos evidência, no gráfico de Bland-Altman da Figura 4.8.

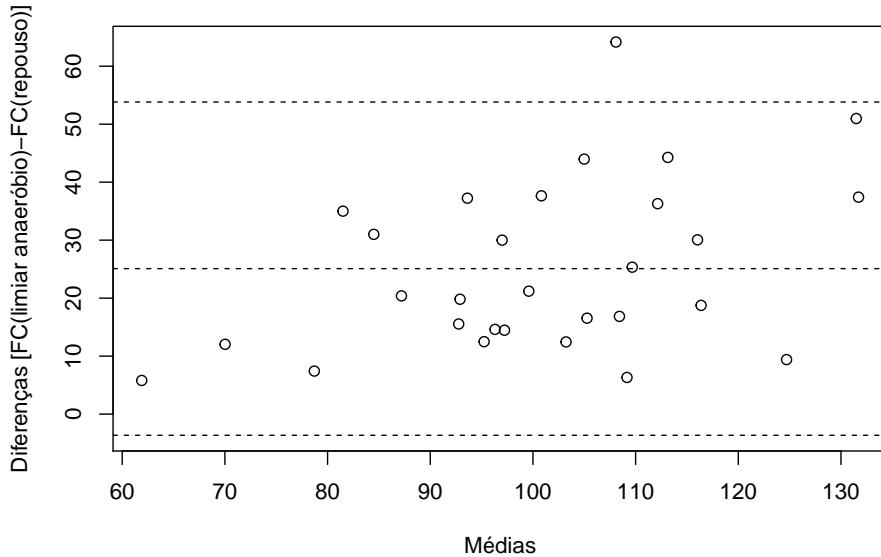


Figura 4.8: Gráfico de médias/diferenças de Tukey (Bland-Altman) para comparação das distribuições de frequência cardíaca em repouso e no limiar anaeróbio.

Exemplo 4.6. Considere o arquivo `temperaturas`, contendo dados de temperatura para Ubatuba e Cananéia. O gráfico QQ correspondente está apresentado na Figura 4.9. Observamos que a maioria dos pontos está acima da reta $y = x$, mostrando que as temperaturas de Ubatuba são em geral maiores do que as de Cananeia para valores maiores do que 17 graus.

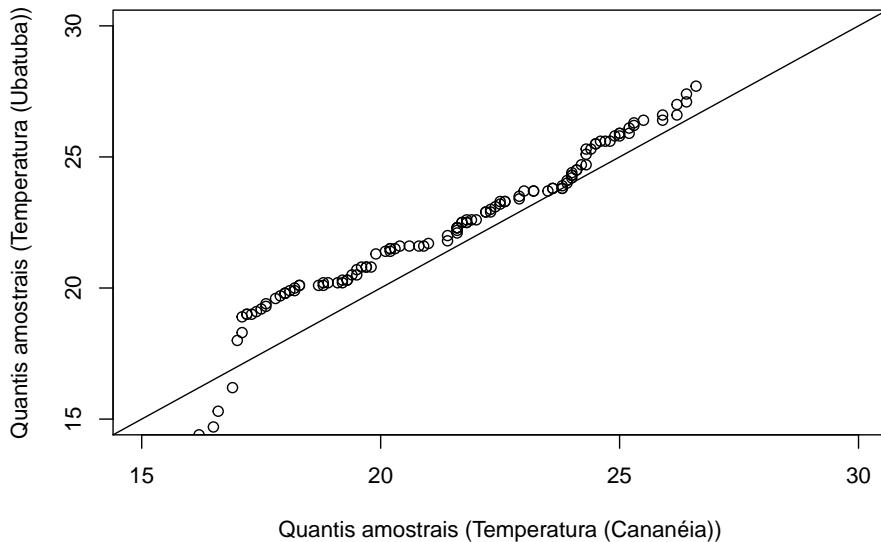


Figura 4.9: Gráfico QQ para comparação das distribuições de temperaturas de Ubatuba e Cananéia.

O gráfico de Bland-Altman correspondente, apresentado na Figura 4.10, sugere que acima de 17 graus, em média Ubatuba tende a ser 1 grau mais quente que Cananéia.

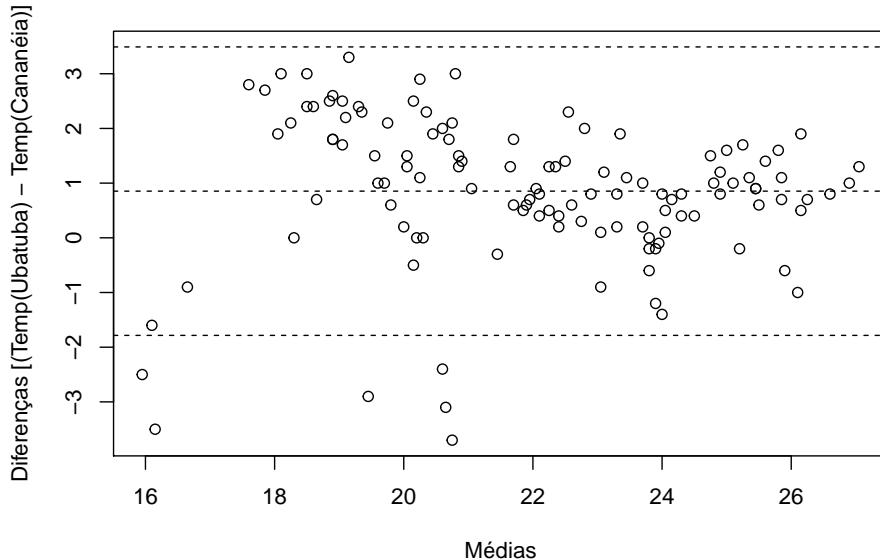


Figura 4.10: Gráfico de médias/diferenças de Tukey (Bland-Altman) para comparação das distribuições de temperaturas de Ubatuba e Cananéia.

4.4 Uma variável qualitativa e outra quantitativa

Um estudo da associação entre uma variável quantitativa e uma qualitativa consiste essencialmente na comparação das distribuições da primeira nos diversos níveis da segunda. Essa análise pode ser conduzida por meio de medidas resumo, histogramas, *boxplots* etc.

Exemplo 4.7. Num estudo coordenado pelo Laboratório de Poluição Atmosférica Experimental da USP, foram colhidos dados de concentração de vários elementos captados nas cascas de árvores em diversos pontos do centro expandido do município de São Paulo com o intuito de avaliar sua associação com a poluição atmosférica oriunda do tráfego. Os dados disponíveis no arquivo `arvores` foram extraídos desse estudo e contêm a concentração de Zn (ppm) em 497 árvores classificadas segundo a espécie (*alfeneiro*, *sibipiruna* e *tipuana*) e a localização em termos da proximidade do tipo de via (arterial, coletora, local I, local II, em ordem decrescente da intensidade de tráfego). Para efeito didático, consideramos primeiramente as 193 *tipuanas*. Medidas resumo para a concentração de Zn segundo os níveis de espécie e tipo de via estão indicadas na Tabela 4.20.

Tabela 4.20: Medidas resumo para a concentração de Zn (ppm) em cascas de *tipuanas*

Tipo de via	Desvio							
	Média	padrão	Min	Q1	Mediana	Q3	Max	n
Arterial	199,4	110,9	29,2	122,1	187,1	232,8	595,8	59
Coletora	139,7	90,7	35,2	74,4	127,4	164,7	385,5	52
Local I	100,6	73,4	20,1	41,9	73,0	139,4	297,7	48
Local II	59,1	42,1	11,0	31,7	45,7	79,0	206,4	34

Min: mínimo

Max: máximo

Q1: primeiro quartil Q3: terceiro quartil

Os resultados indicados na Tabela 4.20 mostram que tanto a concentração média e mediana de Zn quanto o correspondente desvio padrão decrescem à medida que a intensidade de tráfego diminui, sugerindo que essa variável pode ser utilizada como um indicador da poluição produzida por veículos automotores. Os *boxplots* apresentados na Figura 4.11 confirmam essas conclusões e também indicam que as distribuições apresentam uma leve assimetria, especialmente para as vias coletoras e locais I além de alguns pontos discrepantes.

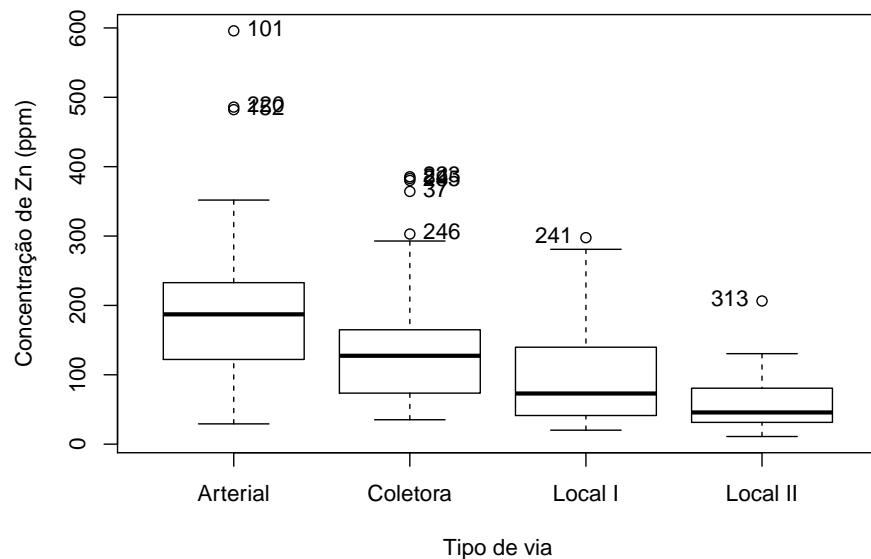


Figura 4.11: *Boxplots* para comparação das distribuições da concentração de Zn nas cascas de *tipuanas*.

Outro tipo de gráfico útil para avaliar a associação entre a variável quantitativa (concentração de Zn, no exemplo) e a variável qualitativa (tipo de via, no exemplo) especialmente quando esta tem níveis ordinais (como no exemplo) é o **gráfico de perfis médios**. Nesse gráfico cartesiano as médias

(e barras representando desvios padrões, erros padrões ou intervalos de confiança)³ da variável quantitativa são representadas no eixo das ordenadas e os níveis da variável quantitativa, no eixo das abscissas. O gráfico de perfis médios para a concentração de Zn medida nas cascas de *Tipuanas* está apresentado na Figura 4.12 e reflete as mesmas conclusões obtidas com as análises anteriores.

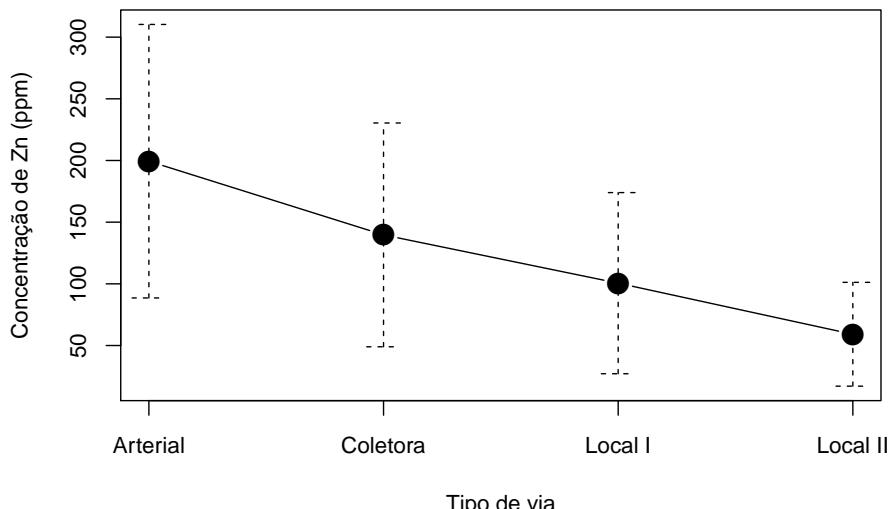


Figura 4.12: Gráfico de perfis médios (com barras de desvios padrões) para comparação das distribuições da concentração de Zn nas cascas de *tipuanas*.

No título do gráfico, deve-se sempre indicar o que representam as barras; desvios padrões são úteis para avaliar como a dispersão dos dados em torno da média correspondente varia com os níveis da variável quantitativa (e não dependem do número de observações utilizadas para o cálculo da média); erros padrões são indicados para avaliação da precisão das médias (e dependem do número de observações utilizadas para o cálculo delas); intervalos de confiança servem para comparação das médias populacionais correspondentes e dependem de suposições sobre a distribuição da variável quantitativa.

Uma análise similar para os 76 *alfeneiros* está resumida na Tabela 4.21, e Figuras 4.13 e 4.14.

³Ver Nota de Capítulo 6

Tabela 4.21: Medidas resumo para a concentração de Zn (ppm) em cascas de *alfeneiros*

Tipo de via	Desvio							n
	Média	padrão	Min	Q1	Mediana	Q3	Max	
Arterial	244,2	102,4	58,5	187,4	244,5	283,5	526,0	19
Coletora	234,8	102,7	15,6	172,4	231,6	311,0	468,6	31
Local I	256,3	142,4	60,0	154,9	187,0	403,7	485,3	19
Local II	184,4	96,4	45,8	131,1	180,8	247,6	306,6	7

Min: mínimo

Max: máximo

Q1: primeiro quartil Q3: terceiro quartil

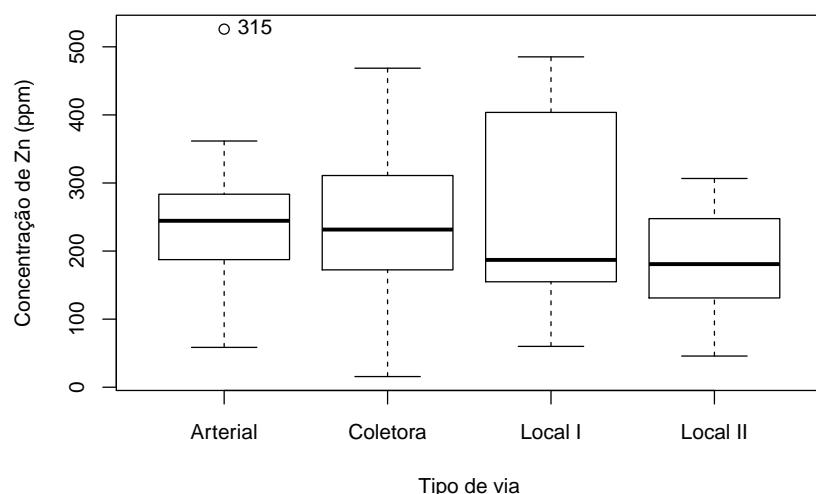


Figura 4.13: *Boxplots* para comparação das distribuições da concentração de Zn nas cascas de *alfeneiros*.

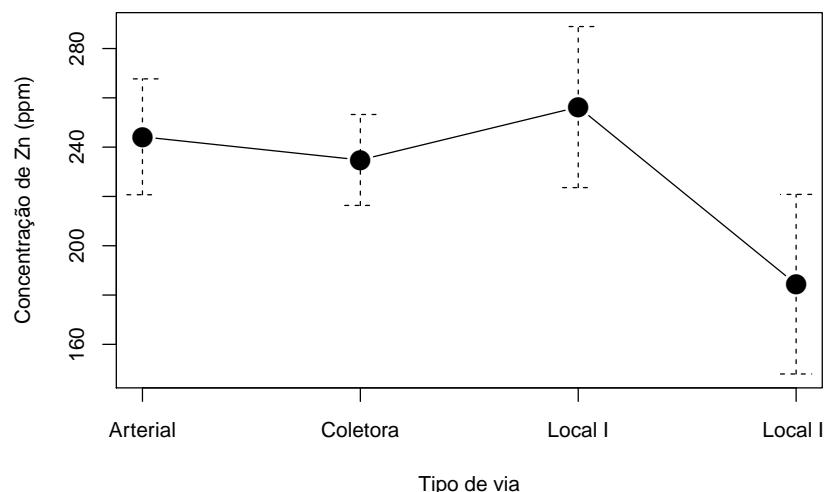


Figura 4.14: Gráfico de perfis médios (com barras de desvios padrões) para comparação das distribuições da concentração de Zn nas cascas de *alfeneiros*.

Os valores dispostos na Tabela 4.21 e as Figuras 4.13 e 4.14 indicam que as concentrações de Zn em *alfeneiros* tendem a ser maiores do que aquelas encontradas em *tipuanas* porém são menos sensíveis a variações na intensidade de tráfego com exceção de vias locais II; no entanto, convém lembrar que apenas 7 *alfeneiros* foram avaliados nas proximidades desse tipo de via.

Exemplo 4.8. Consideremos os dados do arquivo `empresa`, referentes à informações sobre 36 funcionários de uma certa empresa. Nossa objetivo é avaliar a associação entre as variáveis “Salário” (S) expressa em número de salários mínimos e “Grau de instrução” (GI), com a classificação “fundamental”, “médio” ou “superior”.

Medidas resumo para “Salário” em função dos níveis de “Grau de instrução” são apresentadas na Tabela 4.22.

Tabela 4.22: Medidas resumo para a variável “Salário” (número de salários mínimos)

Grau de instrução	n	Média	Variância	Min	Q1	Q2	Q3	Max
		\bar{S}	$var(S)$					
Fundam	12	7,84	7,77	4,00	6,01	7,13	9,16	13,65
Médio	18	11,54	13,10	5,73	8,84	10,91	14,48	19,40
Superior	6	16,48	16,89	10,53	13,65	16,74	18,38	23,30
Todos	36	11,12	20,46	4,00	7,55	10,17	14,06	23,30

Min: mínimo Max: máximo
 Q1: primeiro quartil Q2: mediana Q3: terceiro quartil

A leitura desses resultados sugere associação entre salários e grau de instrução: o salário médio tende a aumentar conforme aumenta o grau de instrução. O salário médio dos 36 funcionários é 11,12 salários mínimos; para funcionários com curso superior, o salário médio é de 16,48 salários mínimos, enquanto que funcionários com primeiro grau completo recebem, em média, 7,82 salários mínimos.

Embora nos dois exemplos apresentados a variável qualitativa seja ordinal, o mesmo tipo de análise pode ser empregado no caso de variáveis qualitativas nominais, tendo o devido cuidado na interpretação, pois não se poderá afirmar que a média da variável quantitativa aumenta com o aumento dos níveis da variável quantitativa.

Como nos casos anteriores, é conveniente poder contar com uma medida que quantifique o grau de associação entre as duas variáveis. Com esse intuito, convém observar que as variâncias podem ser usadas como insumos para construir essa medida. A variância da variável quantitativa (“Salário”) para todos os dados, *i.e.*, calculada sem usar a informação da variável qualitativa (“Grau de instrução”), mede a dispersão dos dados em torno da média global (média salarial de todos os funcionários). Se as variâncias da variável “Salário” calculadas dentro de cada categoria da variável qualita-

tiva forem pequenas (comparativamente à variância global), essa variável pode ser usada para melhorar o conhecimento da distribuição da variável quantitativa, sugerindo a existência de uma associação entre ambas.

Na Tabela 4.22 pode-se observar que as variâncias do salário dentro das três categorias são menores do que a variância global e além disso, que aumentam com o grau de instrução. Uma medida resumo da variância **entre** as categorias da variável qualitativa é a média das variâncias ponderada pelo número de observações em cada categoria, ou seja,

$$\overline{\text{Var}(S)} = \frac{\sum_{i=1}^k n_i \text{Var}_i(S)}{\sum_{i=1}^k n_i}, \quad (4.8)$$

em que k é o número de categorias ($k = 3$ no exemplo) e $\text{Var}_i(S)$ denota a variância de S dentro da categoria i , $i = 1, \dots, k$. Pode-se mostrar que $\overline{\text{Var}(S)} \leq \text{Var}(S)$, de modo que podemos definir o grau de associação entre as duas variáveis como o ganho relativo na variância obtido pela introdução da variável qualitativa. Explicitamente,

$$R^2 = \frac{\text{Var}(S) - \overline{\text{Var}(S)}}{\text{Var}(S)} = 1 - \frac{\overline{\text{Var}(S)}}{\text{Var}(S)}. \quad (4.9)$$

Além disso, pode-se mostrar que $0 \leq R^2 \leq 1$.

Quando as médias da variável resposta (salário, no exemplo) nas diferentes categorias da variável explicativa forem iguais, $\overline{\text{Var}(S)} = \text{Var}(S)$ e $R^2 = 0$, indicando a inexistência de associação entre as duas variáveis relativamente às suas médias. Esse é o princípio que norteia a técnica conhecida por Análise de Variância, cuja finalidade é comparar médias (populacionais) de distribuições Normais independentes com mesma variância. O leitor deve consultar Kutner et al. (2004), por exemplo, para detalhes sobre essa técnica. A estatística R^2 também é utilizada para avaliar a qualidade do ajuste de modelos de regressão, o tópicos abordado no Capítulo 6.

Para os dados do Exemplo 4.8, temos

$$\overline{\text{Var}(S)} = \frac{12 \times 7,77 + 18 \times 13,10 + 6 \times 16,89}{12 + 18 + 6} = 11,96.$$

Como $\text{Var}(S) = 20,46$, obtemos $R^2 = 1 - (11,96/20,46) = 0,415$, sugerindo que 41,5% da variação total do salário é **explicada** pelo grau de instrução.

4.5 Notas de capítulo

1) Probabilidade condicional e razões de chances

Considere a seguinte tabela 2x2

	Doente (D)	Não doentes (\bar{D})	Total
Exposto (E)	n_{11}	n_{12}	n_{1+}
Não exposto (\bar{E})	n_{21}	n_{22}	n_{2+}
Total	n_{+1}	n_{+2}	n_{++}

correspondente a um estudo em que o interesse é avaliar a associação entre a exposição de indivíduos a um certo fator de risco e a ocorrência de uma determinada moléstia. Em **estudos prospectivos** (*prospective, follow-up, cohort*) o planejamento envolve a escolha de amostras de tamanhos n_{1+} e n_{2+} de indivíduos respectivamente expostos e não expostos ao fator de risco e a observação da ocorrência ou não da moléstia após um certo intervalo de tempo. A razão de chances (de doença entre indivíduos expostos e não expostos) é definida como:

$$\omega_1 = \frac{P(D|E)P(\bar{D}|\bar{E})}{P(\bar{D}|E)P(D|\bar{E})}.$$

Em **estudos retrospectivos** ou **caso-controle**, o planejamento envolve a escolha de amostras de tamanhos $n_{\bullet 1}$ e $n_{\bullet 2}$ de indivíduos não doentes (controles) e doentes (casos), respectivamente e a observação retrospectiva de sua exposição ou não ao fator de risco. Nesse caso, a razão de chances é definida por:

$$\omega_2 = \frac{P(E|D)P(\bar{E}|\bar{D})}{P(\bar{E}|D)P(E|\bar{D})}.$$

Utilizando a definição de probabilidade condicional [ver Bussab e Morettin (2017), por exemplo], temos

$$\begin{aligned}\omega_1 &= \frac{[P(D \cap E)/P(E)][P(\bar{D} \cap \bar{E})/P(\bar{E})]}{[P(\bar{D} \cap E)/P(E)][P(D \cap \bar{E})/P(\bar{E})]} = \frac{P(D \cap E)P(\bar{D} \cap \bar{E})}{P(\bar{D} \cap E)P(D \cap \bar{E})} \\ &= \frac{[P(E|D)/P(D)][P(\bar{E}|\bar{D})/P(\bar{D})]}{[P(E|\bar{D})/P(\bar{D})][P(\bar{E}|D)/P(D)]} = \omega_2\end{aligned}$$

Embora não se possa calcular o risco relativo de doença em estudos retrospectivos, a razão de chances obtida por meio desse tipo de estudo é igual àquela que seria obtida por intermédio de um estudo prospectivo, que em muitas situações práticas não pode ser realizado devido ao custo.

2) Medidas de dependência entre duas variáveis

Dizemos que X e Y são **comonotônicas** se Y (ou X) for uma função estritamente crescente de X (ou Y) e são **contramonotônicas** se a função for estritamente decrescente.

Consideremos duas variáveis X e Y e seja $\delta(X, Y)$ uma medida de dependência entre elas. As seguintes propriedades são desejáveis para δ (Embrechts et al., 2003):

- (i) $\delta(X, Y) = \delta(Y, X);$
- (ii) $-1 \leq \delta(X, Y) \leq 1;$
- (iii) $\delta(X, Y) = 1$ se X e Y são comonotônicas e $\delta(X, Y) = -1$ se X e Y são contramonotônicas;

(iv) Se T for uma transformação monótona,

$$\delta(T(X), Y) = \begin{cases} \delta(X, Y), & \text{se } T \text{ for crescente,} \\ -\delta(X, Y), & \text{se } T \text{ for decrescente.} \end{cases}$$

(v) $\delta(X, Y) = 0$ se e somente se X e Y são independentes.

O **coeficiente de correlação (linear)** entre X e Y é definido por

$$\rho = \frac{\text{Cov}(X, Y)}{DP(X)DP(Y)} \quad (4.10)$$

com $\text{Cov}(X, Y) = E(XY) - E(X)E(Y)$, $DP(X) = E\{[X - E(X)]^2\}$ e $DP(Y) = E\{[Y - E(Y)]^2\}$. Pode-se provar que $-1 \leq \rho \leq 1$ e que satisfaz as propriedades (i)-(ii). Além disso, ρ requer que as variâncias de X e Y sejam finitas e $\rho = 0$ não implica independência entre X e Y , a não ser que (X, Y) tenha uma distribuição Normal bivariada. Também, mostra-se que ρ não é invariante sob transformações não lineares estritamente crescentes.

3) Dependência linear entre duas variáveis

Convém reafirmar que $\rho(X, Y)$ mede dependência linear entre X e Y e não outro tipo de dependência. De fato, suponha que uma das variáveis possa ser expressa linearmente em termos da outra, por exemplo $X = aY + b$, e seja $d = E(|X - aY - b|^2)$. Então, pode-se provar (veja Exercício 13) que o mínimo de d ocorre quando

$$a = \frac{\sigma_X}{\sigma_Y} \rho(X, Y), \quad b = E(X) - aE(Y), \quad (4.11)$$

e é dado por

$$\min d = \sigma_X^2 [1 - \rho(X, Y)^2]. \quad (4.12)$$

Portanto, quanto maior o valor absoluto do coeficiente de correlação entre X e Y , melhor a acurácia com que uma das variáveis pode ser representada como uma combinação linear da outra. Obviamente, este mínimo se anula se e somente se $\rho = 1$ ou $\rho = -1$. Então de (4.12) temos

$$\rho(X, Y) = \frac{\sigma_X^2 - \min_{a,b} E(|X - aY - b|^2)}{\sigma_X^2}, \quad (4.13)$$

ou seja, $\rho(X, Y)$ mede a redução relativa na variância de X por meio de uma regressão linear de X sobre Y .

4) Medidas de dependência robustas

O coeficiente de correlação não é uma medida robusta. Uma alternativa robusta para a associação entre duas variáveis quantitativas pode ser construída como indicamos na sequência. Considere as variáveis padronizadas

$$\tilde{x}_k = \frac{x_k}{S_x(\alpha)}, \quad \tilde{y}_k = \frac{y_k}{S_y(\alpha)}, \quad k = 1, \dots, n,$$

em que $S_x^2(\alpha)$ e $S_y^2(\alpha)$ são as variâncias α -aparadas para os dados x_i e y_i , $i = 1, \dots, n$, respectivamente. Um coeficiente de correlação robusto é definido por

$$r(\alpha) = \frac{S_{\tilde{x}+\tilde{y}}^2(\alpha) - S_{\tilde{x}-\tilde{y}}^2(\alpha)}{S_{\tilde{x}+\tilde{y}}^2(\alpha) + S_{\tilde{x}-\tilde{y}}^2(\alpha)}, \quad (4.14)$$

em que, por exemplo, $S_{\tilde{x}+\tilde{y}}^2(\alpha)$ é a variância α -aparada da soma dos valores padronizados de x_i e y_i , $i = 1, \dots, n$. Pode-se mostrar que $r(\alpha) = r_P$ se $\alpha = 0$. Esse método é denominado de **método de somas e diferenças padronizadas**.

Exemplo 4.9. Consideremos os dados (x_i, y_i) , $i = 1, \dots, n$ apresentados na Tabela 4.23 e dispostos num diagrama de dispersão na Figura 4.15.

Tabela 4.23: Valores hipotéticos de duas variáveis X e Y

x	y	x	y
20,2	24,0	19,3	18,5
50,8	38,8	19,3	18,5
12,0	11,5	19,3	18,5
25,6	25,8	10,2	11,1
20,2	24,0	12,0	12,9
7,2	7,2	7,2	7,2
7,2	7,2	13,5	12,9
7,2	7,2		

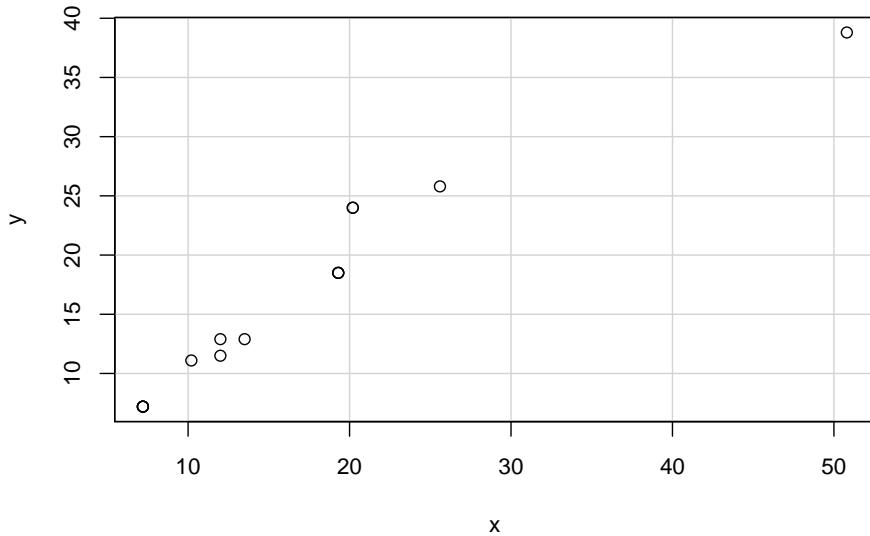


Figura 4.15: Gráfico de dispersão para os dados do Exemplo 4.9.

Para $\alpha = 0,05$, obtemos:

$$\bar{x}(\alpha) = 14,86, \quad \bar{y}(\alpha) = 15,33, \quad S_x(\alpha) = 5,87, \quad S_y(\alpha) = 6,40,$$

$$(\tilde{x} + \tilde{y})(\alpha) = 4,93, \quad (\tilde{x} - \tilde{y})(\alpha) = 0,14,$$

$$S_{\tilde{x}+\tilde{y}}^2(\alpha) = 3,93, \quad S_{\tilde{x}-\tilde{y}}^2(\alpha) = 0,054.$$

Então de (4.14) obtemos $r(\alpha) = 0,973$, o que indica uma alta correlação entre as duas variáveis.

5) Gráficos PP

Na Figura 4.16, observe que $p_x(q) = P(X \leq q) = F_X(q)$ e que $p_y(q) = P(Y \leq q) = F_Y(q)$. O gráfico cartesiano com os pares $[p_x(q), p_y(q)]$, para qualquer q real, é chamado de gráfico de probabilidades ou gráfico PP. O gráfico cartesiano com os pares $(Q_X(p), Q_Y(p))$, para $0 < p < 1$, é o gráfico de quantis *versus* quantis (gráfico QQ).

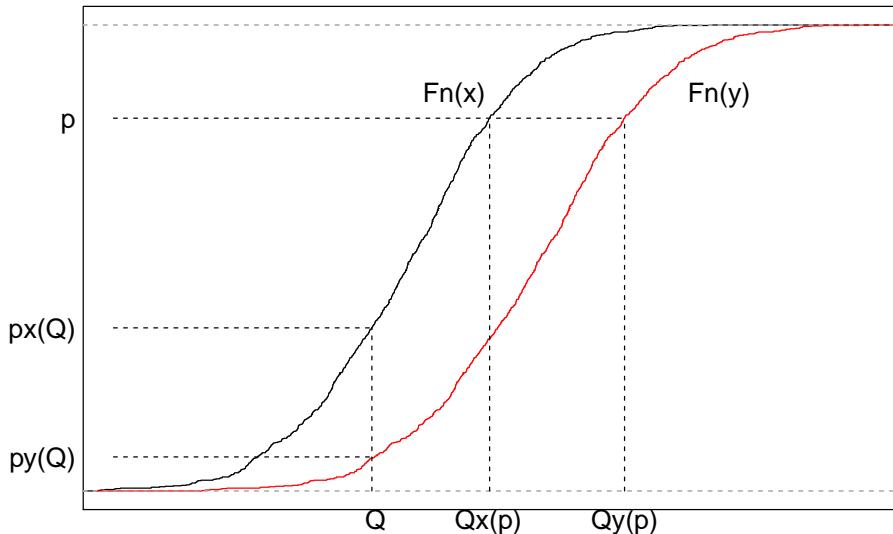


Figura 4.16: Quantis e probabilidades associados a duas distribuições.

Se as distribuições de X e Y forem iguais, então $F_X = F_Y$ e os pontos dos gráficos PP e QQ se situam sobre a reta $x = y$. Em geral os gráficos QQ são mais sensíveis a diferenças nas caudas das distribuições se estas forem aproximadamente simétricas e com a aparência de uma distribuição Normal. Suponha que $Y = aX + b$, ou seja, que as

distribuições de X e Y são as mesmas, exceto por uma transformação linear. Então,

$$p = P(X \leq Q_X(p)) = P(aX + b \leq aQ_X(p) + b) = P(Y \leq Q_Y(p)),$$

ou seja,

$$Q_Y(p) = aQ_X(p) + b.$$

O gráfico QQ correspondente será representado por uma reta com inclinação a e intercepto b . Essa propriedade não vale para gráficos PP.

Gráficos PP e QQ para a distribuição da concentração de Zn em cascas de árvores da espécie *Tipuana*, disponíveis no arquivo `arvores` estão dispostos na Figura 4.17 e salientam a maior capacidade dos últimos para detectar assimetrias em distribuições de frequência.

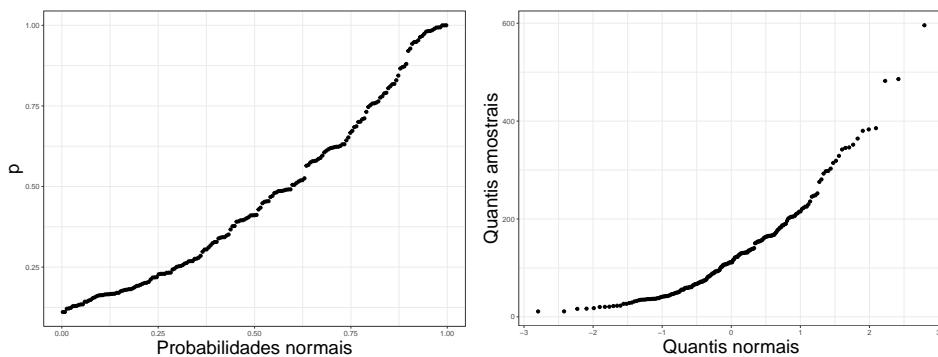


Figura 4.17: Gráficos PP e QQ para concentração de Zn em cascas de árvores da espécie *Tipuana*.

6) Diferenças significativas

Consideremos a distribuição de uma variável X (pressão arterial, por exemplo) em duas populações, A e B e admitamos que as médias de X sejam μ_A e μ_B (desconhecidas), respectivamente. Além disso, admitamos que ambas as distribuições tenham desvios padrões iguais a $\sigma = 10$ (conhecido). Nossa objetivo é saber se existem evidências de que $\mu_A = \mu_B$ com base em amostras aleatórias X_{A1}, \dots, X_{An} da população A e X_{B1}, \dots, X_{Bn} da população B . Admitamos que $n = 100$ e que as correspondentes médias amostrais sejam $\bar{X}_A = 13$ e $\bar{X}_B = 10$, respectivamente. Nesse caso, dizemos que a diferença $|\bar{X}_A - \bar{X}_B| = 3$ é **significativa** com $p < 0,05$, concluindo que há evidências de que para acreditar que $\mu_A \neq \mu_B$. Consideremos agora uma amostra de tamanho $n = 25$ de cada população, com médias $\bar{X}_A = 15$ e $\bar{X}_B = 10$. Nesse caso, dizemos que a diferença $|\bar{X}_A - \bar{X}_B| = 5$ **não é significativa** com $p > 0,05$, concluindo que não há razão para acreditar que $\mu_A \neq \mu_B$, embora a diferença entre as médias amostrais \bar{X}_A e

\bar{X}_B seja maior que no primeiro caso. Essencialmente, queremos saber qual é a interpretação da expressão “a diferença entre as médias é significativa”.

O cerne do problema é que não queremos tirar conclusões sobre as médias amostrais, \bar{X}_A e \bar{X}_B (cuja diferença é evidente, pois a conhecemos) e sim sobre as médias populacionais μ_A e μ_B , que desconhecemos. Para associar as amostras às populações, precisamos de um modelo probabilístico. No caso do exemplo, um modelo simples supõe que as distribuições de frequências da variável X nas populações A e B são Normais, independentes com médias μ_A e μ_B , respectivamente e desvio padrão comum $\sigma = 10$.

No primeiro caso ($n = 100$), admitindo que as duas distribuições têm médias iguais ($\mu_A = \mu_B$), a probabilidade de que a diferença (em valor absoluto) entre as médias amostrais seja maior ou igual a 3 é

$$P(|\bar{X}_A - \bar{X}_B| \geq 3) = P(|Z| > 3 / (\sqrt{2}\sigma / \sqrt{100})) = P(|Z| \geq 2,82) < 0,05$$

em que Z representa uma distribuição Normal padrão, *i.e.*, com média zero e variância 1. Em outras palavras, se as médias populacionais forem iguais, a probabilidade de se obter uma diferença de magnitude 3 entre as médias de amostras de tamanho $n = 100$ é menor que 5% e então dizemos que a diferença (entre as médias amostrais) é significativa ($p < 0,05$), indicando que a evidência de igualdade entre as médias populacionais μ_A e μ_B é pequena.

No segundo caso ($n = 25$), temos

$$P(|\bar{X}_A - \bar{X}_B| \geq 5) = P(|Z| > 5 / (\sigma / \sqrt{25})) = P(|Z| > 1,76) > 0,05,$$

e então dizemos que a diferença (entre as médias amostrais) não é significativa ($p > 0,05$), indicando que não há evidências fortes o suficiente para acreditarmos que as médias populacionais μ_A e μ_B sejam diferentes.

Apesar de que no segundo caso, a diferença amostral é maior do que aquela do primeiro caso, concluímos que a evidência de diferença entre as médias populacionais é menor. Isso ocorre porque o tamanho amostral desempenha um papel importante nesse processo; quanto maior o tamanho amostral, mais fácil será detectar diferenças entre as médias populacionais em questão.

Grosso modo, afirmar que uma diferença entre duas médias amostrais é significativa é dizer que as médias das populações de onde as amostras forma extraídas não devem ser iguais; por outro lado, dizer que a diferença entre as médias amostrais não é significativa é dizer que não há razões para acreditar que exista diferença entre as médias populacionais correspondentes.

7) Intervalos de confiança para o risco relativo e razão de chances

Consideremos a seguinte tabela 2×2

Tabela 4.24: Frequência de pacientes

Fator de risco	Status do paciente		Total
	doente	são	
presente	n_{11}	n_{12}	n_{1+}
ausente	n_{21}	n_{22}	n_{2+}
Total	n_{+1}	n_{+2}	n

Estimativas dos riscos de doença para pacientes expostos e não expostos ao fator de risco são, respectivamente, $p_1 = n_{11}/n_{1+}$ e $p_2 = n_{21}/n_{2+}$. Sob a suposição de que as distribuições de n_{11} e n_{21} são binomiais, as variâncias de p_1 e p_2 são respectivamente estimadas por $\text{Var}(p_1) = p_1(1 - p_1)/n_{1+}$ e $\text{Var}(p_2) = p_2(1 - p_2)/n_{2+}$.

Em vez de calcular a variância associada à estimativa do risco relativo, $rr = p_1/p_2$, é mais conveniente calcular a variância de $\log(rr)$. Com essa finalidade, recorremos ao **método Delta**⁴, obtendo

$$\begin{aligned}\text{Var}[\log(rr)] &= \text{Var}[\log(p_1) - \log(p_2)] = \text{Var}[\log(p_1)] + \text{Var}[\log(p_2)] \\ &= \frac{p_1(1 - p_1)}{p_1^2 n_{1+}} + \frac{p_2(1 - p_2)}{p_2^2 n_{2+}} = \frac{1 - p_1}{p_1 n_{1+}} + \frac{1 - p_2}{p_2 n_{2+}} \\ &= \frac{1 - p_1}{n_{11}} + \frac{1 - p_2}{n_{21}} \\ &= \frac{1}{n_{11}} - \frac{1}{n_{1+}} + \frac{1}{n_{21}} - \frac{1}{n_{2+}}\end{aligned}$$

Os limites inferior e superior de um intervalo de confiança com coeficiente de confiança aproximado de 95% para o logaritmo do risco relativo (populacional) RR são obtidos de

$$\log(p_1/p_2) \pm 1.96 \sqrt{\frac{1}{n_{11}} - \frac{1}{n_{1+}} + \frac{1}{n_{21}} - \frac{1}{n_{2+}}}. \quad (4.15)$$

Os limites do intervalo de confiança correspondente para o risco relativo podem ser obtidos exponenciando-se os limites indicados em 4.15.

A razão de chances RC de doença entre indivíduos expostos e não expostos ao fator de risco é estimada por $rc = p_1(1 - p_2)/p_2(1 - p_1)$.

⁴O método Delta é utilizado para calcular a variância de funções de variáveis aleatórias. Essencialmente, se x é tal que $E(X) = \mu$ e $\text{Var}(X) = \sigma^2$, então sob certas condições de regularidade (em geral satisfeitas nos casos mais comuns), $\text{Var}[g(X)] = [g'(\mu)]^2 \sigma^2$ em que g é uma função com derivada $g'(z)$ no ponto z . Para detalhes, o leitor poderá consultar Sen et al. (2009).

Como no caso do risco relativo é mais conveniente estimar a variância de $\log(rc)$, que é

$$\text{Var}[\log(rc)] = \frac{1}{n_{11}} + \frac{1}{n_{12}} + \frac{1}{n_{21}} + \frac{1}{n_{22}}.$$

Os limites inferior e superior de um intervalo de confiança com coeficiente de confiança aproximado de 95% para o logaritmo do razão de chances (populacional) RC são obtidos de

$$\log[p_1(1 - p_2)/p_2(1 - p_1)] \pm 1.96 \sqrt{\frac{1}{n_{11}} + \frac{1}{n_{12}} + \frac{1}{n_{21}} + \frac{1}{n_{22}}}. \quad (4.16)$$

Assim como no caso do risco relativo, os limites do intervalo de confiança correspondente para a razão de chances pode ser obtido por meio da exponenciação dos limites indicados em (4.16).

4.6 Exercícios

- 1) Considere o conjunto de dados disponível no arquivo **empresa**. Compare as distribuições de frequências de cada variável para indivíduos residentes na capital, interior e outros.
- 2) Considere o conjunto de dados disponível no arquivo **regioes**. Avalie a relação entre as variáveis “Região” e “Densidade populacional”.
- 3) Considere o conjunto de dados disponível no arquivo **salarios**.
 - a) Construa um gráfico QQ para comparar as distribuições das variáveis “Salário de professor secundário” e “Salário de administrador”.
 - b) Calcule o coeficiente de correlação de Pearson, r_P e o coeficiente de correlação robusto, $r(\alpha)$ com $\alpha = 0,10$ entre essas duas variáveis.
- 4) Considere o conjunto de dados disponível no arquivo **coronarias**.
 - a) Construa gráficos QQ para comparar as distribuições das variáveis **imc** e **idade** de pacientes masculinos (=1) e femininos (=0) e discuta os resultados.
 - b) Calcule o coeficiente de correlação de Pearson e o coeficiente de correlação de Spearman entre as variáveis “Altura” e “Peso”.
 - c) Construa uma tabela de contingência para avaliar a distribuição conjunta das variáveis “Tabagismo” (com 6 níveis) e “Arteriopatia” (com 4 níveis) e calcule a intensidade de associação entre elas utilizando a estatística de Pearson, o coeficiente de contingência de Pearson e o coeficiente de “Tschuprov”.
- 5) Considere o conjunto de dados disponível no arquivo **esforco**.

- a) Compare as distribuições de frequências da variável “VO2” em repouso e no pico do exercício para pacientes classificados em cada um dos níveis da variável “Etiologia” por meio de gráficos QQ e de medidas resumo. Comente os resultados.
- b) Repita o item a) utilizando gráficos de Bland-Altman.
- c) Utilize *boxplots* e gráficos de perfis médios para comparar as distribuições da variável “Frequência cardíaca” correspondentes a pacientes nos diferentes níveis da variável “NYHA”. Comente os resultados.
- 6) Para os dados do arquivo **salarios**, considere a variável “Região”, com as classes “América do Norte”, “América Latina”, “Europa” e “Outros” e a variável “Salário de professor secundário”. Avalie a associação entre essas duas variáveis.
- 7) Considere os dados do arquivo **figadoddiag**. Calcule a sensibilidade, especificidade, taxas de falsos positivos e falsos negativos, valores preditivos positivos e negativos e acurácia das técnicas radiológicas para detecção de alterações anatômicas tendo os resultados intraoperatórios como padrão áureo.
- 8) Analise a variável “Preço de veículos” segundo as categorias N (nacional) e I (importado) para o conjunto de dados disponíveis no arquivo **veiculos**.
- 9) Utilizando a definição da Nota de Capítulo 4, prove que se $\alpha = 0$, então $r(\alpha) = r$.
- 10) Prove que (4.1) pode ser escrita como

$$\chi^2 = \sum_{i=1}^r \sum_{j=1}^s \frac{(n_{ij} - n_{ij}^*)^2}{n_{ij}^*},$$

em que n_{ij} é a frequência absoluta observada na linha i e coluna j e n_{ij}^* é a respectiva frequência esperada.

- 11) Prove que (4.1) pode ser escrita em termos de frequências relativas como

$$\chi^2 = n \sum_{i=1}^r \sum_{j=1}^s \frac{(f_{ij} - f_{ij}^*)^2}{f_{ij}^*},$$

com notação similar à do problema anterior.

- 12) Prove que (4.4) e (4.5) são equivalentes.
- 13) Prove as relações (4.11)-(4.13).

- 14) Os dados da Tabela 4.25 são provenientes de um estudo em que um dos objetivos era avaliar o efeito da dose de radiação gama (em centigrays) na formação de múltiplos micronúcleos em células de indivíduos normais. Analise os dados descritivamente, calculando o risco relativo de ocorrência de micronúcleos para cada dose tomando como base a dose nula. Repita a análise calculando as razões de chances correspondentes. Quais as conclusões de suas análises?

Tabela 4.25: Número de células

Dose de radiação gama (cGy)	Frequência de células com múltiplos micronúcleos	Total de células examinadas
0	1	2373
20	6	2662
50	25	1991
100	47	2047
200	82	2611
300	207	2442
400	254	2398
500	285	1746

- 15) De uma tabela construída para avaliar a associação entre tratamento (ativo e placebo) e cura (sim ou não) de uma certa moléstia obteve-se uma razão de chances igual a 2,0. Explique por que não se pode concluir daí que a probabilidade de cura para pacientes submetidos ao tratamento ativo é 2 vezes a probabilidade de cura para pacientes submetidos ao placebo.
- 16) Um criminologista desejava estudar a relação entre: X (densidade populacional = número de pessoas por unidade de área) e Y (índice de assaltos = número de assaltos por 100000 pessoas) em grandes cidades. Para isto sorteou 10 cidades observando em cada uma delas os valores de X e Y. Os resultados obtidos estão dispostos na Tabela 4.26

Tabela 4.26: Densidade populacional e índice de assaltos em grandes cidades

Cidade	1	2	3	4	5	6	7	8	9	10
X	59	49	75	65	89	70	54	78	56	60
Y	190	180	195	186	200	204	192	215	197	208

- a) Classifique as variáveis envolvidas.
- b) Calcule a média, mediana, desvio-padrão e a distância interquartis para cada variável.
- c) Construa o diagrama de dispersão entre Y e X e faça comentários sobre a relação entre as duas variáveis.

17) Considere a seguinte tabela.

X	1	3	4	6	8	9	11	14
Y	1	2	4	4	5	7	8	9

O que se pode dizer sobre a relação entre as variáveis X e Y?

- a) Não há associação entre X e Y.
 - b) Há relação linear positiva.
 - c) Há relação linear negativa.
 - d) Há relação quadrática.
- 18) Em um teste de esforço cardiopulmonar aplicado a 55 mulheres e 104 homens, foram medidas entre outras, as seguintes variáveis:

- Grupo: Normais, Cardiopatas ou DPOC (portadores de doença pulmonar obstrutiva crônica).
- VO2MAX: consumo máximo de O₂ (ml/min).
- VCO2MAX: consumo máximo de CO₂ (ml/min).

Algumas medidas descritivas e gráficos são apresentados abaixo nas Tabelas 4.27 e 4.28 e Figura 4.18

Tabela 4.27: VO2MAX

Grupo	n	Média	Mediana	Desvio Padrão
Normais	56	1845	1707	795
Cardiopatas	57	1065	984	434
DPOC	46	889	820	381

Tabela 4.28: VCO2MAX

Grupo	n	Média	Mediana	Desvio Padrão
Normais	56	2020	1847	918
Cardiopatas	57	1206	1081	479
DPOC	46	934	860	430

Coeficiente de correlação entre VO2MAX e VCO2MAX = 0,92.

- a) Que grupo tem a maior variabilidade?
- b) Compare as médias e as medianas dos 3 grupos.
- c) Compare as distâncias interquartis dos 3 grupos para cada variável.
Você acha razoável usar a distribuição normal para esse conjunto de dados?

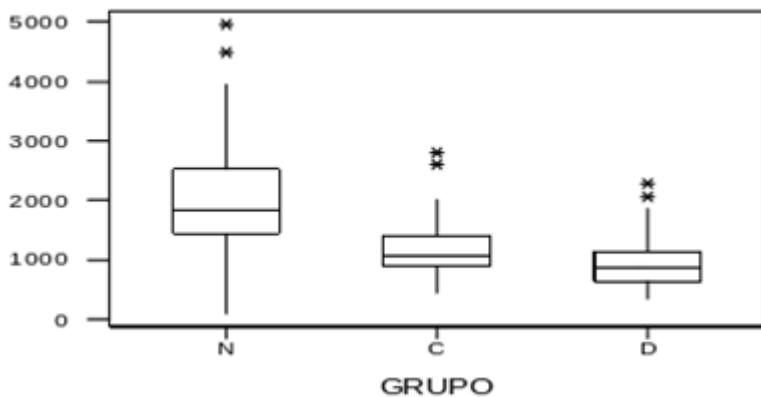
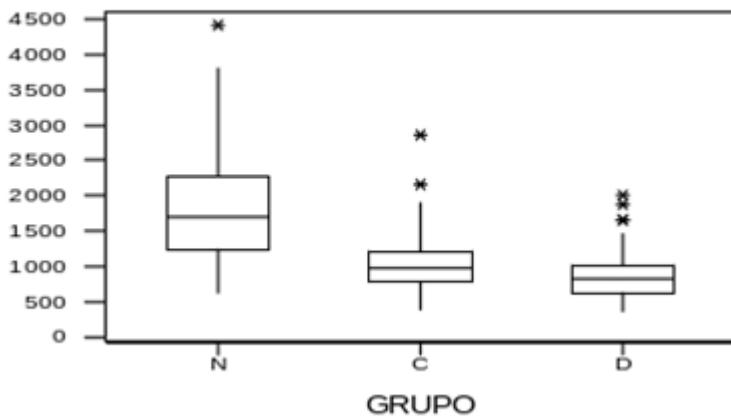
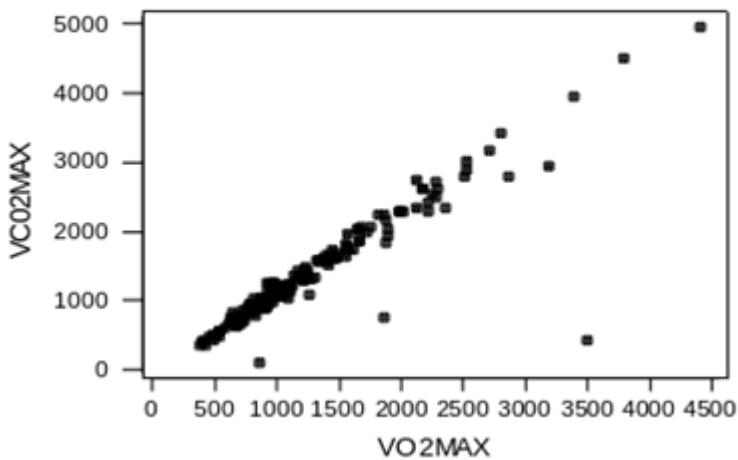
Boxplot para VCO₂MAX**Boxplot para VO₂MAX****Diagrama de Dispersão VO₂MAX x VCO₂MAX**

Figura 4.18: Gráficos para o Exercício 18.

- d) O que representam os asteriscos nos *boxplots*?
- e) Que tipo de função você ajustaria para modelar a relação entre o consumo máximo de CO₂ e o consumo máximo de O₂? Por quê?
- f) Há informações que necessitam verificação quanto a possíveis erros? Quais?
- 19) Para avaliar a associação entre a persistência do canal arterial (PCA) em recém-nascidos pré-termo (RNPT) e óbito ou hemorragia intracraniana, um pesquisador obteve os dados dispostos na seguinte tabela

Frequências absolutas e relativas de óbitos e hemorragia intracraniana em recém-nascidos

PCA	Óbito			Hemorragia intracraniana		
	Sim	Não	Total	Sim	Não	Total
Presente	8	13	21	7	14	21
Ausente	1	39	40	7	33	40
Total	9	52	61	14	44	61

Um resumo das análises para óbitos e hemorragia intracraniana está disposto na tabela seguinte

Variável	valor p	Razão de chances e Intervalo de confiança (95%)		
		Estimativa	Lim inf	Lim sup
Óbito	0,001	24,0	2,7	210,5
Hemorragia intracraniana	0,162	2,4	0,7	8,0

- a) Interprete as estimativas das razões de chances, indicando claramente a que pacientes elas se referem.
- b) Analogamente, interprete os intervalos de confiança correspondentes, indicando claramente a que pacientes eles se referem.
- c) Com base nos resultados anteriores, o que você pode concluir sobre a associação entre persistência do canal arterial e óbito para RNPT em geral? E sobre a associação entre a persistência do canal arterial e a ocorrência de hemorragia interna? Justifique suas respostas.
- d) Qual a hipótese nula testada em cada caso?
- e) Qual a interpretação dos níveis descritivos (p-value) em cada caso?

Detalhes podem ser obtidos em Afiune (2000).

- 20) Em um estudo comparativo de duas drogas para hipertensão os resultados indicados nas Tabelas 4.29, 4.30 e 4.31 e Figura 4.19 foram usados para descrever a eficácia e a tolerabilidade das drogas ao longo de 5 meses de tratamento.

Tabela 4.29: Frequências absoluta e relativa do efeito colateral para as duas drogas

Efeito Colateral	Droga 1		Droga 2	
	n	%	n	%
não	131	61,22	144	65,45
sim	83	38,79	76	34,54

Tabela 4.30: Distribuição de frequências para as drogas 1 e 2

Variação	Droga 1		Droga 2	
	n	%	n	%
Pressão				
0 - 5	9	4,20561	5	2,27273
5 - 10	35	16,3551	29	13,1818
10 - 20	115	53,7383	125	56,8181
20 - 30	54	25,2336	56	25,4545
30 - 40	1	0,46729	5	2,27273

Tabela 4.31: Medidas resumo das drogas 1 e 2

Droga	Média	DP	Mediana
1	15,58	6,09	15,49
2	16,82	6,37	17,43

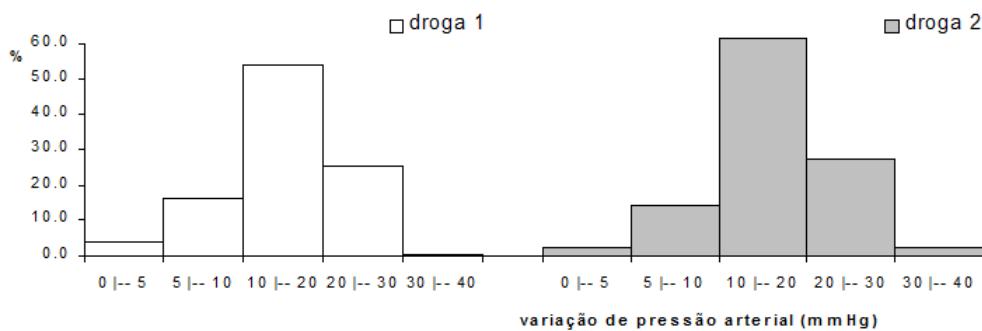


Figura 4.19: Histogramas para a variação de pressão arterial.

- a) Com a finalidade de melhorar a apresentação dos resultados, faça as alterações que você julgar necessárias em cada uma das tabelas

e figura.

- b) Calcule a média, o desvio padrão e a mediana da variação de pressão arterial para cada uma das duas drogas por meio do histograma.
- c) Compare os resultados obtidos no item b) com aqueles obtidos diretamente dos dados da amostra (Tabela 4.31).
- 21) Numa cidade A em que não foi veiculada propaganda, a porcentagem de clientes que desistem do plano de TV a cabo depois de um ano é 14%. Numa cidade B, em que houve uma campanha publicitária, essa porcentagem é de 6%. Então, considerando uma aproximação de 2 casas decimais, podemos dizer a razão de chances (rc) de desistência entre as cidades A e B é
- a) $rc = 2,33$ b) $rc = 2,55$ c) $rc = 8,00$ d) $rc = 1,75$ e) Nenhuma das respostas anteriores está correta.
- 22) Em um estudo realizado para avaliar o efeito do tabagismo nos padrões de sono foram consideradas amostras de tamanhos 12 e 15 de duas populações: Fumantes e Não Fumantes, respectivamente. A variável observada foi o tempo, em minutos, que se leva para dormir. Os correspondentes *boxplots* e gráficos de probabilidade Normal são apresentados nas Figuras 4.20 e 4.21.

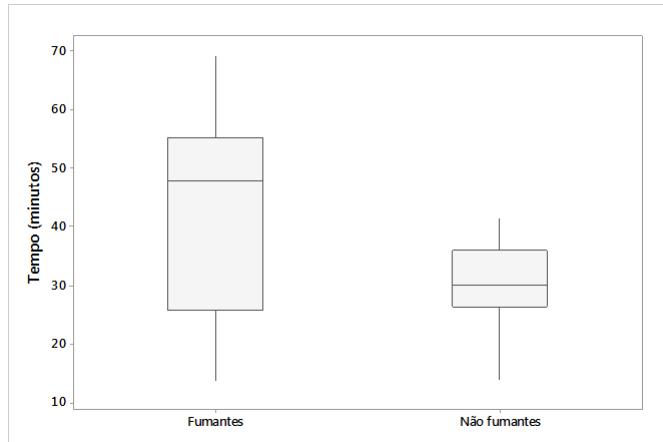


Figura 4.20: *Boxplots* do tempo até dormir nas populações Fumantes e Não Fumantes.

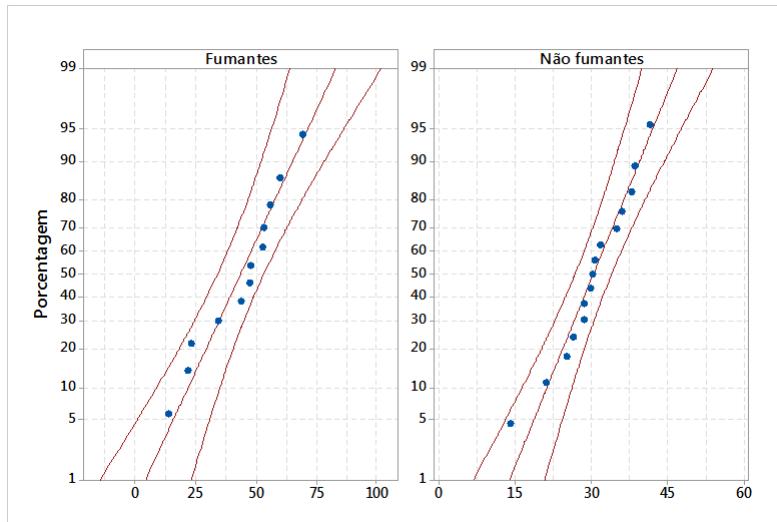


Figura 4.21: Gráfico QQ para as populações Fumantes e Não Fumantes.

Esses gráficos sugerem que:

- a) a variabilidade do tempo é a mesma nas duas populações estudadas;
 - b) as suposições para a aplicação do teste t-Student para comparar as médias dos tempos nas duas populações estão válidas;
 - c) os fumantes tendem a apresentar um tempo maior para dormir do que os não fumantes;
 - d) as informações fornecidas permitem concluir que o estudo foi bem planejado;
 - e) nenhuma das respostas anteriores está correta.
- 23) Considere os dados do arquivo **entrevista**. Calcule estatísticas κ sem e com ponderação para quantificar a concordância entre as duas observadoras (G e P) para as variáveis “Impacto” e “Independência” e comente os resultados.
- 24) Considere os dados do arquivo **endometriose**. Construa um gráfico QQ para comparar as distribuições da variável “Idade” de pacientes dos grupos Controle e Doente.
- 25) Considere duas amostras de uma variável X com n unidades amostrais cada. Utilize a definição (4.8) para mostrar que $\overline{\text{Var}(X)} = \text{Var}(X)$ quando as médias das duas amostras são iguais.
- 26) Utilize o método Delta para calcular uma estimativa da variância da razão de chances (ver Nota de Capítulo 7).

- 27) Considere os dados do arquivo **neonatos** contendo pesos de recém nascidos medidos por via ultrassonográfica (antes do parto) e ao nascer. Construa gráficos QQ e gráficos Bland-Altman para avaliar a concordância entre as duas distribuições. Comente os resultados.

Análise de dados de várias variáveis

Nothing would be done at all if a man waited til he could do it so well that no one could find fault with it.

John Henry Newman

5.1 Introdução

Em várias situações práticas, os valores de mais de duas variáveis são observados em cada unidade amostral (ou populacional). Por exemplo, o conjunto de dados disponível no arquivo `veiculos` corresponde a uma amostra de 30 veículos fabricados no Brasil ou importados em cada qual foram observadas 4 variáveis: “Preço” (`preco`), “Comprimento” (`comp`), “Potência do motor” (`motor`) e “Procedência” (`proc`). As três primeiras são variáveis quantitativas contínuas e a quarta é uma variável qualitativa nominal. O conjunto de dados disponível no arquivo `poluicao` contém 4 variáveis quantitativas contínuas, nomeadamente, concentrações atmosféricas de CO (monóxido de carbono) e O₃ (ozônio), além de temperatura (`temp`) e umidade do ar (`umid`) observadas ao longo de 120 dias.

Modelos probabilísticos para esse tipo de dados envolvem distribuições conjuntas para as p variáveis, digamos X_1, \dots, X_p , sob investigação. No caso discreto, eles envolvem funções de probabilidade $P(X_1 = x_1, \dots, X_p = x_p)$, e no caso contínuo, funções densidade de probabilidade, $f(x_1, \dots, x_p)$. Medidas resumo (média, variância, correlação etc.) são extensões daquelas estudadas no Capítulo 3 e são abordadas na Seção 5.4.

Quando todas as p variáveis são observadas em cada uma de n unidades amostrais, podemos dispor-las em uma matriz com dimensão $n \times p$, chamada **matriz de dados**. No exemplo dos veículos, essa matriz tem dimensão 30×4 e nem todos os seus elementos são numéricos. No conjunto de dados de poluição, a matriz de dados correspondente tem dimensão 120×4 .

A análise de dados com essa estrutura deve levar em consideração a provável correlação (intraunidades amostrais) entre as variáveis estudadas.

Em geral, as observações realizadas em duas unidades amostrais diferentes não são correlacionadas embora haja exceções. No exemplo de dados de poluição, as unidades amostrais são os n diferentes dias e o conjunto das n observações de cada variável corresponde a uma série temporal. Nesse contexto, também se esperam correlações entre as observações realizadas entre unidades amostrais diferentes.

Embora seja possível considerar cada variável separadamente e aplicar as técnicas do Capítulo 3, a análise da relação entre elas precisa ser avaliada de forma conjunta. Muitas análises desse tipo de dados consistem na redução de sua dimensionalidade, considerando algum tipo de transformação que reduza o número de variáveis mas conserve a maior parte da informação do conjunto original. Com essa finalidade, uma técnica de análise de dados multivariados (dados de várias variáveis) bastante utilizada é a **Análise de Componentes Principais**, também conhecida por Análise de Funções Empíricas Ortogonais em muitas ciências físicas. Esse tópico será discutido no Capítulo 12.

Recursos gráficos para representar as relações entre as variáveis são mais complicados quando temos mais de duas variáveis. Neste livro trataremos apenas de alguns casos, com ênfase em três variáveis. Mais opções e detalhes podem ser encontrados em Chambers et al. (1983).

5.2 Gráficos para três variáveis

Gráfico do desenhista (*Draftsman's display*)

Esse tipo de gráfico consiste de uma matriz (ou dos componentes situados abaixo ou acima da diagonal principal) cujos elementos são gráficos de dispersão para cada par de variáveis. Muitas vezes incluem-se coeficientes de correlação de Pearson entre os diferentes pares de variáveis nos painéis situados acima ou abaixo da diagonal.

Exemplo 5.1. O gráfico do desenhista para as variáveis Preço, Comprimento e Potência do motor do arquivo `veiculos` está apresentado na Figura 5.1. Observam-se associações positivas tanto entre Potência do motor e Comprimento quanto entre potência do motor e preço: maiores potências do motor estão associadas tanto com maiores comprimentos quanto com preços maiores. Esse tipo de relação não está tão aparente quanto consideramos as variáveis Preço e Comprimento: para comprimentos entre 3,5 m e 4 m, os preços situam-se entre 5,000 e 15,000 enquanto os preços para veículos com comprimentos entre 4 e 5 metros distribuem-se entre 5,000 e 40,000. A Figura 5.2 contém o mesmo tipo de gráfico para as variáveis CO, O3 e temp do arquivo `poluicao` e não mostra evidências de associação entre cada par dessas variáveis.

Gráfico de dispersão simbólico

Gráficos de dispersão simbólicos ou estéticos (*aesthetic*) são essen-

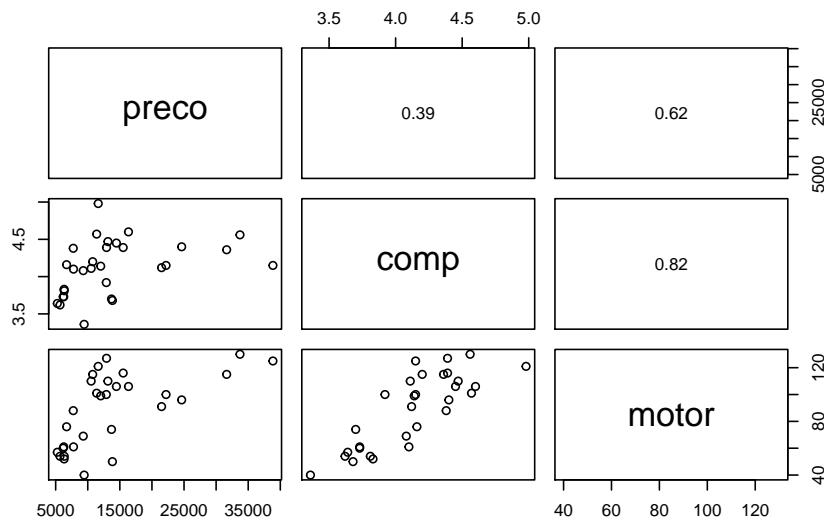


Figura 5.1: Gráfico do desenhista para os dados do arquivo `veiculos`.

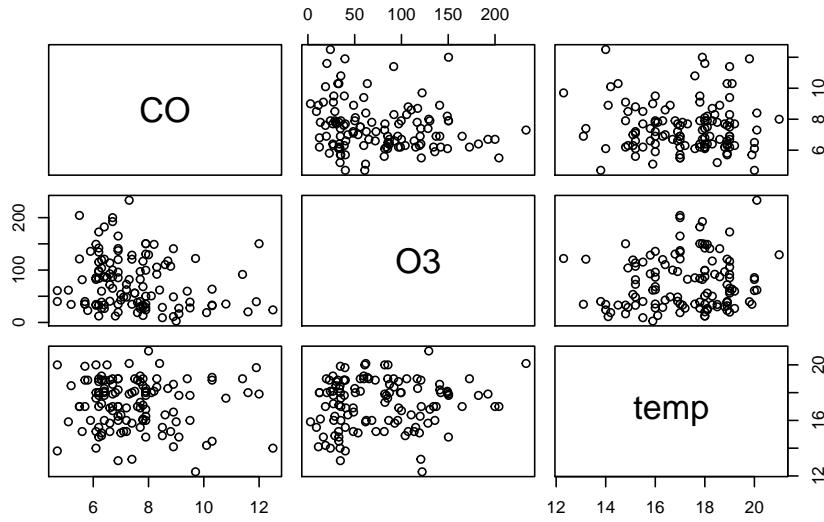


Figura 5.2: Gráfico do desenhista para os dados do arquivo `poluicao`.

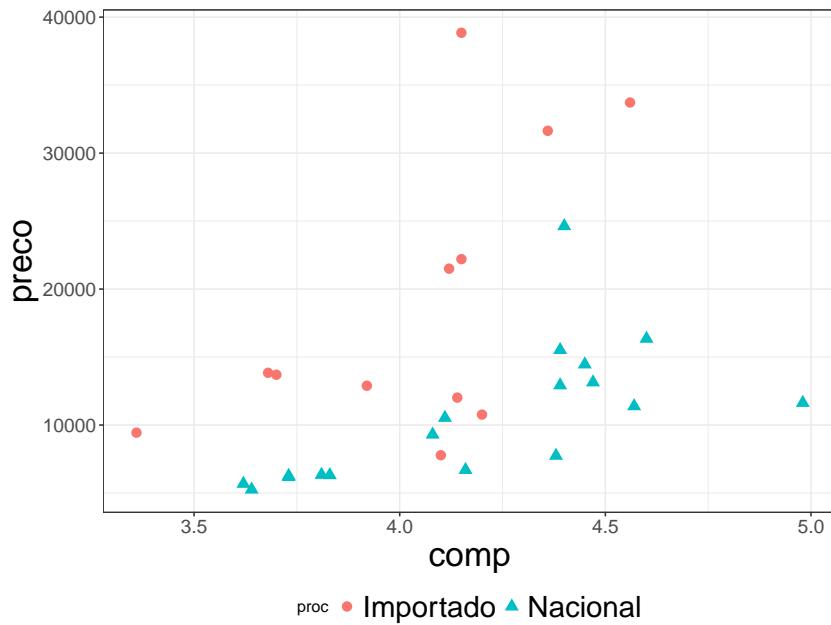


Figura 5.3: Gráfico de dispersão simbólico para os dados do arquivo `veiculos`.

cialmente gráficos de dispersão em que mais do que duas variáveis são representadas. Para distingui-las usam-se diferentes símbolos, cores ou formas dos pontos.

Exemplo 5.2. Consideremos novamente os dados do arquivo `veiculos`, concentrando a atenção em duas variáveis quantitativas [Preço (y) e Comprimento (x)] e em uma terceira variável qualitativa [Procedência (nacional ou importado)]. Para cada par (x, y) , usamos um símbolo, como Δ , para representar a categoria “nacional” e \circ , para indicar a categoria “importado”. Essa escolha permite-nos construir o gráfico de dispersão disposto na Figura 5.3, em que se pode notar que os preços maiores correspondem, de modo geral, a carros importados, o que era esperado. Os carros nacionais pequenos têm os menores preços. Os comandos do pacote `ggplot2` do R utilizados para a construção do gráfico disposto na Figura 5.3 são

```
library(ggplot2)
library(gdata)

veiculos<-read.xls("/dados/veiculos.xls",sep=",",dec=",",h=T)
g1 <- ggplot(veiculos,aes(comp,preco))
  + geom_point(aes(shape=proc, colour=proc), size=3)
  + theme_bw()
g2 <- g1 + theme(axis.title = element_text(size=23))
g3 <- g2 + theme(legend.position="bottom",
                 legend.direction="horizontal",
```

```

    legend.text=element_text(size=20))
g4 <- g3 + theme(axis.text.x = element_text(face="plain", size=13),
                  axis.text.y = element_text(face="plain", size=13))

```

Outra alternativa para a representação gráfica das associações entre três variáveis quantitativas desse conjunto de dados consiste em adotar um símbolo com diferentes tamanhos para representar cada uma delas. Por exemplo, na Figura 5.4, apresentamos o gráfico de dispersão de Preço versus Comprimento, com a variável Potência do Motor representada por círculos com tamanhos variando conforme a potência: círculos menores para potências entre 40 e 70, círculos médios para potências entre 70 e 100 e círculos maiores para potências entre 100 e 130. O gráfico permite evidenciar que carros com maior potência do motor são em geral mais caros e têm maior comprimento.

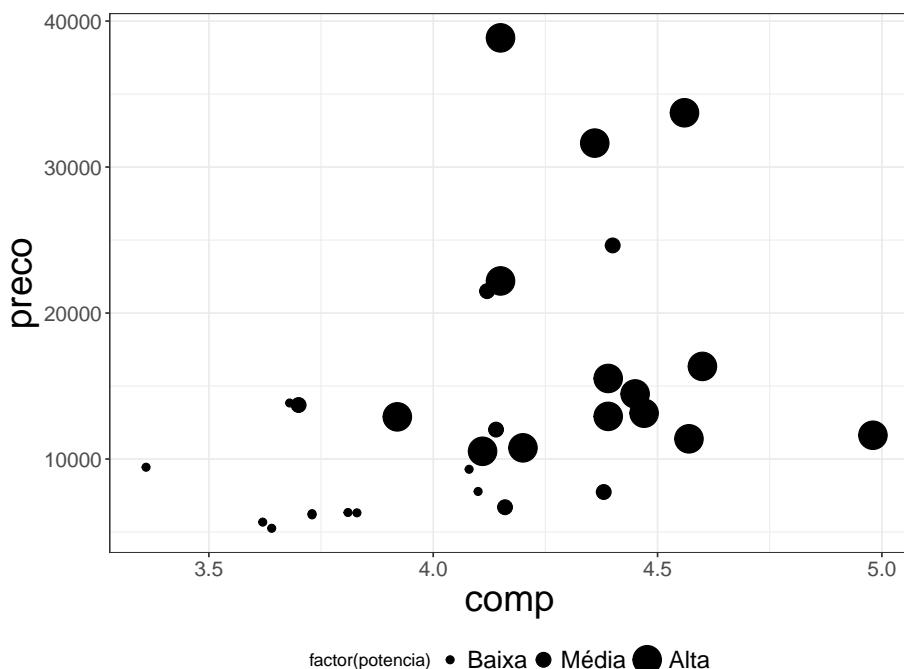


Figura 5.4: Gráfico de dispersão simbólico para os dados do CD-veículos com potência do motor.

Os comandos do pacote `ggplot2` do R utilizados para a construção do gráfico disposto na Figura 5.4 são

```

library(ggplot2)
library(gdata)

veiculos<-read.table("/dados/veiculos.xls", sep=",", dec=",", h=T)
categ_motor=rep(NA,length(motor))
categ_motor[motor>=40 & motor<70]="Baixa Potencia"

```

```

categ_motor[motor>=70 & motor<100]="Media Potencia"
categ_motor[motor>=100 & motor<=130]="Alta Potencia"
categ_motor=factor(categ_motor)
potencia = 2*c(categ_motor == "Baixa Potencia")+
  4*c(categ_motor == "Media Potencia")+
  8*c(categ_motor== "Alta Potencia")

ggplot(veiculos, aes(comp,preco))
  + geom_point(aes(size = factor(potencia)))

g1 <- ggplot(veiculos,aes(comp,preco))
  + geom_point(aes(size = factor(potencia))) + theme_bw()
g2 <- g1 + theme(axis.title = element_text(size=23))
g3 <- g2 + theme(legend.position="bottom",
  legend.direction="horizontal",
  legend.text=element_text(size=15))
g4 <- g3 + theme(axis.text.x = element_text(face="plain",
  size=13), axis.text.y = element_text(face="plain",
  size=13))
g5 <- g4 + scale_size_manual(labels = c("Baixa", "Media",
  "Alta"), values = c(2, 4, 8))

```

Exemplo 5.3. No pacote `ggplot2` encontramos o conjunto de dados `mpg`, que consiste de observações de 38 modelos de carros nos EUA, com várias variáveis, dentre as quais destacamos: `displ` = potência do motor, `hwy` = eficiência do carro em termos de gasto de combustível, `class` = tipo do carro (duas portas, compacto, SUV etc.) e `drv` = tipo de tração (4 rodas, rodas dianteiras e rodas traseiras).

Consideremos o comando

```

ggplot(data=mpg)
  + geom_point(mapping=aes(x=displ,y=hwy,color=drv))
  + geom_smooth(mapping=aes(x=displ,y=hwy,color=drv))

```

que usa a opção `geom_smooth` para ajustar curvas suaves aos dados (usando o procedimento de suavização `lowess`) de cada conjunto de pontos da variável `drv` (*drive*), ou seja uma curva para os pontos com o valor 4 (*four-wheel drive*), outra para os pontos com o valor f (*front-wheel drive*) e uma curva para os pontos com valor r (*rear-wheel drive*). O resultado está apresentado na Figura 5.5. As curvas lowess são úteis para identificar possíveis modelos de regressão que serão discutidos no Capítulo 6. Detalhes sobre curvas lowess podem ser obtidos na Nota de Capítulo 2.

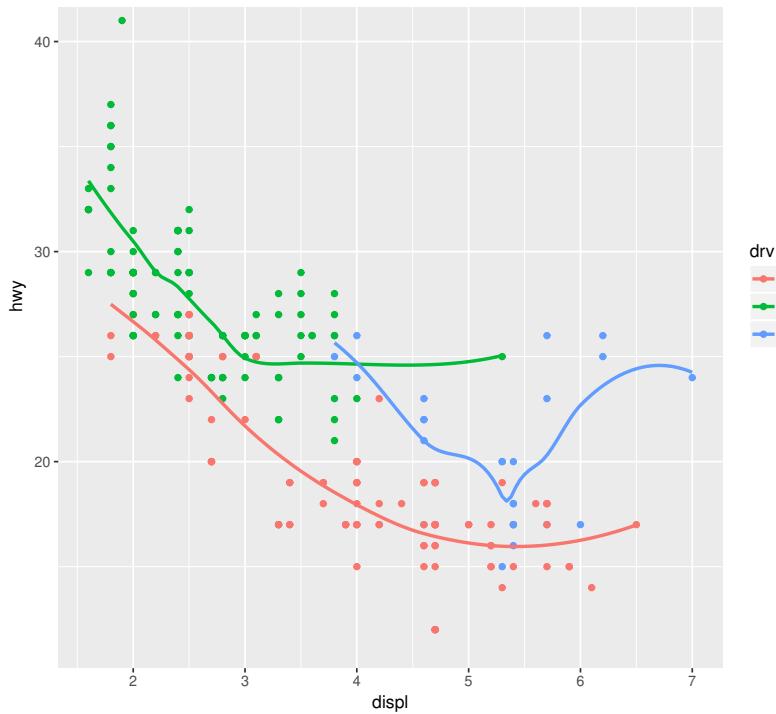


Figura 5.5: Gráfico de dispersão simbólico das variáveis `hwy` versus `displ`, categorizado pela variável `drv` com pontos e curvas.

Partição e Janelamento

Uma abordagem alternativa aos gráficos de dispersão simbólicos consiste em dividir as n observações disponíveis em subconjuntos de acordo com os valores de uma das variáveis e construir um gráfico de dispersão envolvendo as outras duas variáveis para cada subconjunto.

Por exemplo, para os dados do arquivo `veiculos`, podemos construir gráficos de dispersão para as variáveis Preço e Comprimento de acordo com a Procedência (nacional ou importado), como na Figura 5.3 ou construir gráficos de dispersão para Preço e Comprimento segundo as classes em que foram divididas as unidades amostrais com base na variável quantitativa Potência de motor. Esse gráfico está apresentado na Figura 5.6.

Figura 5.6: Janelamento para as variáveis Preço versus Comprimento, categorizado pela variável Potência do motor.

Gráfico de perfis médios

Os gráficos de perfis médios considerados no Capítulo 4 para duas variáveis podem ser facilmente estendidos para acomodar situações com duas variáveis explicativas categorizadas, usualmente denominadas **fatores** e uma variável

resposta. Como ilustração, consideremos o conjunto de dados `arvores` com o objetivo de comparar as concentrações médias de Mg obtidas nas cascas de três espécies de árvores localizadas nas proximidades de vias com diferentes intensidades de tráfego. Nesse contexto, estamos diante de um problema com dois fatores, nomeadamente, “Espécie de árvores” e “Tipo de via” e uma variável resposta contínua, “Concentração de Mg”. O gráfico de perfis médios correspondente, apresentado na Figura 5.7 pode ser obtido por intermédio dos seguintes comandos

```
> library(gdata)
> library(ggplot2)
> library(plyr)
>
> arvores <- read.xls("/home/jmsinger/Desktop/arvores.xls",
+                         sheet='dados', method="tab")
> resumo <- ddply(arvores, c("especie", "tipovia"), summarise,
+ +   N      = sum(!is.na(Mg)),
+ +   mean   = mean(Mg, na.rm=TRUE),
+ +   sd     = sd(Mg, na.rm=TRUE),
+ +   se     = sd / sqrt(N)
+ )
>
> pd <- position_dodge(0.1)
> ggplot(resumo, aes(x=tipovia, y=mean, colour=especie)) +
+   geom_errorbar(aes(ymin=mean-se, ymax=mean+se), width=.1,
+                 position=pd) +
+   geom_line(aes(group = especie)) + geom_point(position=pd) +
+   theme_bw() + labs(x="Tipo de via", y="Concentração de Mg") +
+   theme(text=element_text(size=18))
```

O gráfico permite concluir que as concentrações médias Mg nas Tipuanas são mais elevadas que aquelas obtidas em Alfeneiros, cujas concentrações médias de Mg são mais elevadas que aquelas obtidas em Sibipirunas. Além disso, nota-se que a variação das concentrações médias de Mg são similares para Tipuanas e Alfeneiros para os quatro tipos de vias considerados. As concentrações médias de Mg em Sibipirunas, por outro lado, seguem um padrão diferente.

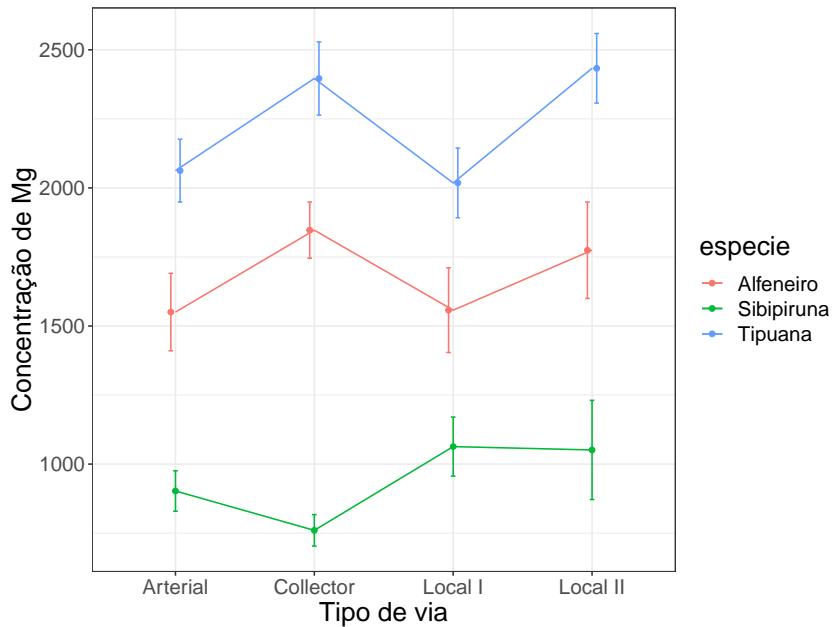


Figura 5.7: Gráfico de perfis médios para a concentração de Mg em cascas de árvores (as barras correspondem a erros padrões).

Nesse tipo de estudo, o objetivo inferencial é avaliar o “efeito” de cada fator e de sua “interação” na distribuição de uma variável resposta quantitativa contínua. Os termos “efeito” e “interação” estão entre aspas porque precisam ser definidos. Quando as observações são independentes e a distribuição (populacional) da variável resposta é Normal com a mesma variância para todas as combinações dos níveis dos fatores, as comparações de interesse restringem-se aos correspondentes valores esperados. Esse é o típico figurino dos problemas analisados por meio da técnica conhecida como **Análise de Variância**, comumente cognominada ANOVA (do inglês, *ANalysis Of VAriance*).

Com o objetivo de definir os “efeitos” dos fatores e sua “interação”, consideremos um exemplo simples em que cada um dos dois fatores tem dois níveis. Um dos fatores, que representamos por A , por exemplo, pode ser o tipo de droga (com níveis ativa e placebo) e o outro, digamos B , pode ser faixa etária (com níveis < 60 anos e ≥ 60 anos) e a variável resposta poderia ser pressão diastólica.

De uma forma geral, admitamos que m unidades amostrais tenham sido observadas sob cada tratamento, *i.e.*, para cada combinação dos a níveis do fator A e dos b níveis do fator B e que a variável resposta seja denotada por y . A estrutura de dados coletados sob esse esquema está apresentada na Figura 5.1.

Tabela 5.1: Estrutura de dados para ANOVA com dois fatores

Droga	Idade	Paciente	PDiast	Droga	Idade	Paciente	PDiast
Ativa	< 60	1	y_{111}	Placebo	< 60	1	y_{211}
Ativa	< 60	2	y_{112}	Placebo	< 60	2	y_{212}
Ativa	< 60	3	y_{113}	Placebo	< 60	3	y_{213}
Ativa	≥ 60	1	y_{121}	Placebo	≥ 60	1	y_{221}
Ativa	≥ 60	2	y_{122}	Placebo	≥ 60	2	y_{222}
Ativa	≥ 60	3	y_{123}	Placebo	≥ 60	3	y_{223}

O “efeito” de cada um dos fatores e da “interação” entre eles podem ser definidos em termos dos valores esperados das distribuições da resposta sob os diferentes tratamentos (combinações dos níveis dos dois fatores). Um modelo comumente considerado para análise inferencial de dados com essa estrutura é

$$y_{ijk} = \mu_{ij} + e_{ijk}, \quad (5.1)$$

$i = 1, \dots, a$, $j = 1, \dots, b$, $k = 1, \dots, m$, em que $E(e_{ijk}) = 0$, $\text{Var}(e_{ijk}) = \sigma^2$ e $E(e_{ijk}e_{i'j'k'}) = 0$, $i \neq i'$ ou $j \neq j'$ ou $k \neq k'$, ou seja, os e_{ijk} são erros não correlacionados. Aqui, y_{ijk} denota a resposta observada para a k -ésima unidade amostral submetida ao tratamento definido pela combinação do nível i do fator A e nível j do fator B .

Esta é a **parametrização** conhecida como de **parametrização de médias de celas** pois o **parâmetro de localização** μ_{ij} corresponde ao valor esperado (médio) da resposta de unidades amostrais submetidas ao tratamento correspondente à combinação do nível i do fator A e nível j do fator B . Outra parametrização bastante utilizada está discutida na Nota de Capítulo 3.

Fazendo $a = b = 2$ para facilidade de exposição, o **efeito** do fator A (droga) para unidades amostrais no nível j do fator B (faixa etária) pode ser definido como a diferença $\mu_{1j} - \mu_{2j}$, que, por exemplo, corresponde à diferença entre o valor esperado da pressão diastólica de unidades amostrais na faixa etária j submetidas à droga 1 (ativa) e o valor esperado da pressão diastólica de unidades amostrais na mesma faixa etária submetidas à droga 2 (placebo). Analogamente, o **efeito** do fator B (faixa etária) para unidades amostrais no nível i do fator A (droga) pode ser definido como a diferença $\mu_{i1} - \mu_{i2}$.

A **interação** entre os fatores A e B pode ser definida como a diferença entre o efeito do fator A para unidades amostrais no nível 1 do fator B e o efeito do fator A para unidades amostrais no nível 2 do fator B , nomeadamente, $(\mu_{11} - \mu_{21}) - (\mu_{12} - \mu_{22})$. Outras definições equivalentes, como $(\mu_{22} - \mu_{12}) - (\mu_{21} - \mu_{11})$, também podem ser utilizadas. A escolha entre as alternativas deve ser feita em função dos detalhes do problema; por exemplo, se a droga 1 for uma droga padrão e a faixa etária 1 corresponder a indivíduos mais jovens, esta última proposta pode ser mais conveniente.

Quando a interação é nula, o efeito do fator A é o mesmo para unidades amostrais submetidas a qualquer um dos níveis do fator B e pode-se definir o **efeito principal** do fator A como $(\mu_{11} + \mu_{12})/2 - (\mu_{21} + \mu_{22})/2$, que corresponde à diferença entre o valor esperado da resposta para unidades amostrais submetidas ao nível 1 do fator A e o valor esperado da resposta para unidades amostrais submetidas ao nível 2 do fator A (**independentemente** do nível do fator B). Similarmente, o efeito principal do fator B pode ser definido como $(\mu_{11} + \mu_{21})/2 - (\mu_{12} + \mu_{22})/2$.

Em muitos casos, essas definições de efeitos principais podem ser consideradas mesmo na presença de interação, desde que ela seja **não essencial**. A interação entre os fatores A e B é não essencial quando as diferenças $\mu_{11} - \mu_{21}$ e $\mu_{12} - \mu_{22}$ têm o mesmo sinal, mas magnitudes diferentes. Por exemplo, se $\mu_{11} - \mu_{21} = K_1 > 0$ e $\mu_{12} - \mu_{22} = K_2 > 0$ com $K_1 \neq K_2$, a resposta esperada sob o nível 1 do fator A é maior que a resposta esperada sob o nível 2 do fator A tanto no nível 1 quanto no nível 2 do fator B , embora as magnitudes das diferenças não sejam iguais. Se essas magnitudes tiverem sinais diferentes, a interação é essencial. Por outro lado, se $K_1 = K_2$, não há interação. O leitor pode consultar Kutner et al. (2004) para uma discussão sobre a consideração de efeitos principais em situações com interação não essencial. Na Figura 5.8 apresentamos gráficos de perfis médios (populacionais) com interações essencial e não essencial entre dois fatores, A e B , cada um com dois níveis.

Na prática, tanto a interação entre os fatores bem como seus efeitos (que são parâmetros populacionais) são estimados pelas correspondentes funções das médias amostrais $\bar{y}_{ij} = m^{-1} \sum_{k=1}^m y_{ijk}$. Os correspondentes gráficos de perfis médios são construídos com essas médias amostrais e desvios padrões (ou erros padrões) associados e servem para sugerir uma possível interação entre os fatores envolvidos ou os seus efeitos.

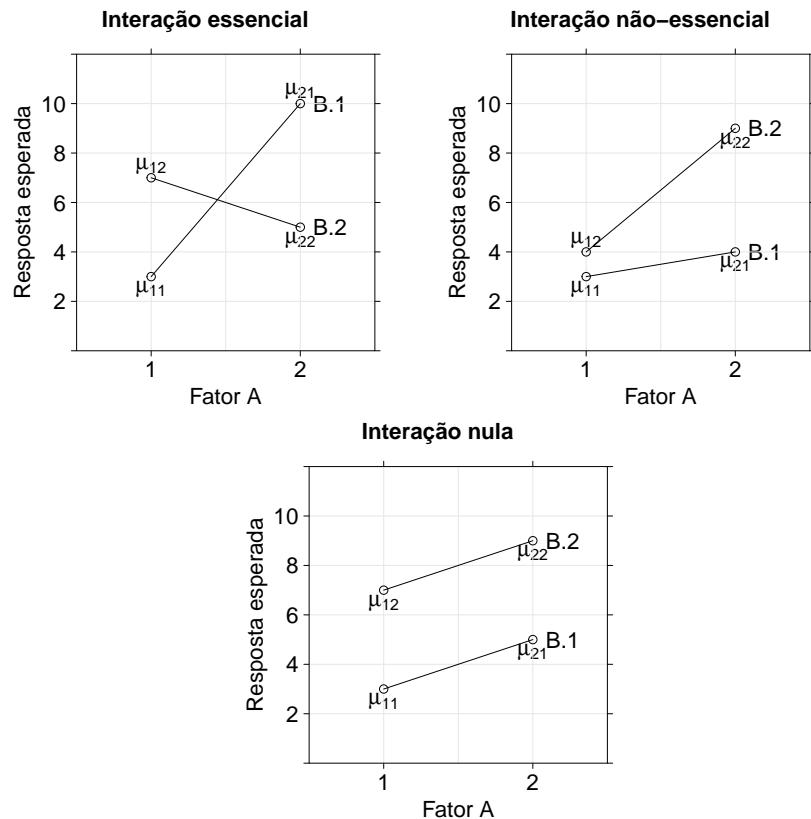


Figura 5.8: Gráfico de perfis médios (populacionais) com diferentes tipos de interação.

Exemplo 5.4. Consideremos um estudo cujo objetivo é avaliar o efeito de dois fatores, a saber, tipo de adesivo odontológico e instante em que foi aplicada uma carga cíclica na resistência à tração de corpos de prova odontológicos (variável resposta). O fator **Adesivo** tem três níveis (CB, RX e RXQ) e o fator **Instante** tem três níveis (início, após 15 minutos e após 2 horas) para os adesivos CB e RXQ e quatro níveis (após fotoativação além de início, após 15 minutos e após 2 horas) para o cimento RX. Os dados, disponíveis no arquivo **adesivo** estão dispostos na Tabela 5.2 e contêm omissões causadas pela quebra accidental dos corpos de prova. Detalhes sobre o estudo podem ser encontrados em Witzel et al. (2000).

Tabela 5.2: Resistência à tração de corpos de prova de um estudo sobre cimentos odontológicos

Adesivo	Instante				Instante			
	carga	Repet	Resist	Adesivo	carga	Repet	Resist	
CB	inic	1	8,56	RX	2h	1	16,76	
CB	inic	2	5,01	RX	2h	2	16,80	
CB	inic	3	2,12	RX	2h	3	13,07	
CB	inic	4	1,70	RX	2h	4	11,47	
CB	inic	5	4,78	RX	2h	5	15,86	
CB	15min	1	5,67	RX	fativ	1	13,42	
CB	15min	2	4,07	RX	fativ	2	13,82	
CB	15min	3	5,99	RX	fativ	3	19,63	
CB	15min	4	5,52	RX	fativ	4	15,60	
CB	15min	5		RX	fativ	5	17,87	
CB	2h	1	8,57	RXQ	inic	1	3,95	
CB	2h	2	6,94	RXQ	inic	2	6,49	
CB	2h	3		RXQ	inic	3	4,60	
CB	2h	4		RXQ	inic	4	6,59	
CB	2h	5		RXQ	inic	5	4,78	
RX	inic	1	20,81	RXQ	15min	1	8,14	
RX	inic	2	12,14	RXQ	15min	2	3,70	
RX	inic	3	9,96	RXQ	15min	3		
RX	inic	4	15,95	RXQ	15min	4		
RX	inic	5	19,27	RXQ	15min	5		
RX	15min	1	14,25	RXQ	2h	1	4,39	
RX	15min	2	14,21	RXQ	2h	2	6,76	
RX	15min	3	13,60	RXQ	2h	3	4,81	
RX	15min	4	11,04	RXQ	2h	4	10,68	
RX	15min	5	21,08	RXQ	2h	5		

Médias e desvios padrões da resistência à tração para as observações realizadas sob cada tratamento (correspondentes ao cruzamento dos níveis de cada fator) estão apresentados na Tabela 5.3.

O gráfico de perfis médios correspondente está apresentado na Figura 5.9.

Tabela 5.3: Estatísticas descritivas para os dados da Tabela 5.2

Adesivo	Instante	n	Média	Desvio Padrão
CB	0 min	5	4,43	2,75
	15 min	4	5,31	0,85
	120 min	2	7,76	1,15
RXQ	0 min	5	5,28	1,19
	15 min	2	5,92	3,14
	120 min	4	6,66	2,87
RX	0 min	5	15,63	4,60
	15 min	5	14,84	3,73
	120 min	5	14,79	2,40
	fativ	5	16,07	2,66

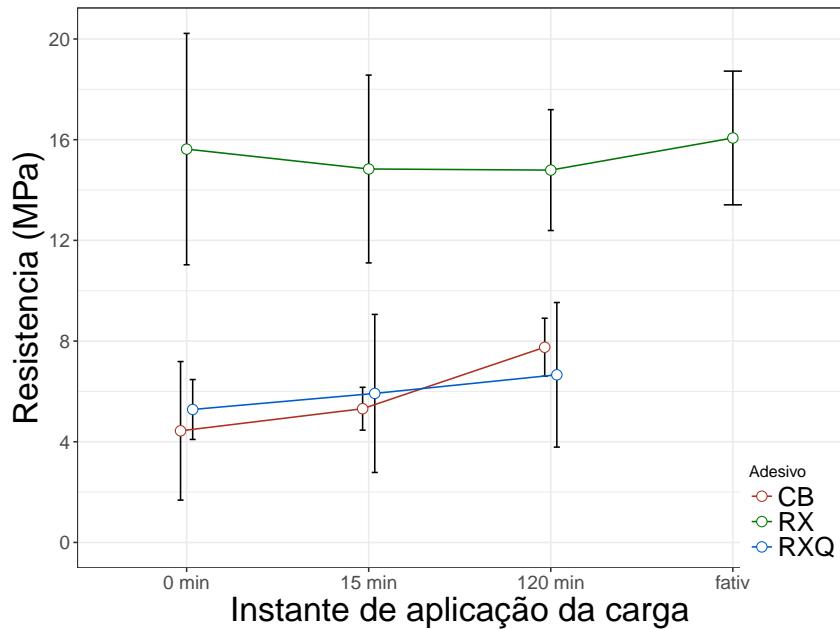


Figura 5.9: Gráfico de perfis de médias (com barras de desvios padrões) para os dados da Tabela 5.2.

Esse gráfico sugere que não existe interação entre os dois fatores (pois os perfis são “paralelos” (lembremos que os perfis apresentados são amostrais e que servem apenas para sugerir o comportamento dos perfis populacionais correspondentes). Além disso, a variabilidade dos dados (aqui representada pelas barras de desvios padrões) deve ser levada em conta para avaliar as possíveis diferenças. Nesse contexto, podemos esperar um efeito principal do fator Adesivo, segundo o qual, os adesivos CB e RXQ têm valores esperados iguais, mas menores que valor esperado do adesivo RX. Também é razoável

esperar que não exista um efeito principal de Instante de aplicação, dado que os três perfis são “paralelos” ao eixo das abscissas. Finalmente, convém reafirmar que as conclusões acima são apenas exploratórias precisam ser confirmadas por técnicas de ANOVA para efeitos inferenciais. Os seguintes comandos R geram a tabela ANOVA apresentada em seguida.

```
library(gdata)
adesivo<-read.xls("/dados/adesivo.xls", sheet='dados',
                   method="tab")
adesivo.anova <- aov(resistencia ~ adesivo + instante +
adesivo*instante, data=adesivo)
summary(adesivo.anova)

Df Sum Sq Mean Sq F value    Pr(>F)
adesivo          2   987.8   493.9  59.526 1.65e-11 ***
instante        3     9.3     3.1   0.373   0.773
adesivo:instante 4    16.5     4.1   0.498   0.737
Residuals       32   265.5     8.3
```

O resultado não sugere evidências nem de interação entre Adesivo e Instante de aplicação ($p = 0,737$) nem de efeito principal de Instante de aplicação ($p = 0,773$), mas sugere forte evidência de efeito de Adesivo ($p < 0,001$).

Comparações múltiplas entre os níveis de Adesivo realizadas por meio da técnica de Tukey a partir do comando

```
TukeyHSD(adesivo.anova, which = "adesivo")
```

corroboram a sugestão de que os efeitos dos adesivos CB e RXQ são iguais ($p < 0,899$), porém diferentes do efeito do adesivo RXQ ($p < 0,001$).

	diff	lwr	upr	p	adj
RX-CB	9.9732273	7.316138	12.630317	0.0000000	
RXQ-CB	0.5418182	-2.476433	3.560069	0.8986306	
RXQ-RX	-9.4314091	-12.088499	-6.774319	0.0000000	

5.3 Gráficos para quatro ou mais variáveis

Os mesmos tipos de gráficos examinados na seção anterior podem ser considerados para a análise conjunta de quatro ou mais variáveis. Como ilustração, consideremos dados de concentração de elementos químicos observados em cascas de diferentes espécies de árvores na cidade de São Paulo, utilizados para avaliar os níveis de poluição. Os dados estão disponíveis no arquivo `arvores`.

Exemplo 5.5. Na Figura 5.10 apresentamos um gráfico do desenhista com $\binom{4}{2} = 6$ painéis correspondentes aos elementos Mn, Fe, Cu e Zn observados em árvores da espécie *Tipuana* localizadas junto a vias coletoras. Aqui também observam-se evidências de correlações moderadas entre as variáveis.

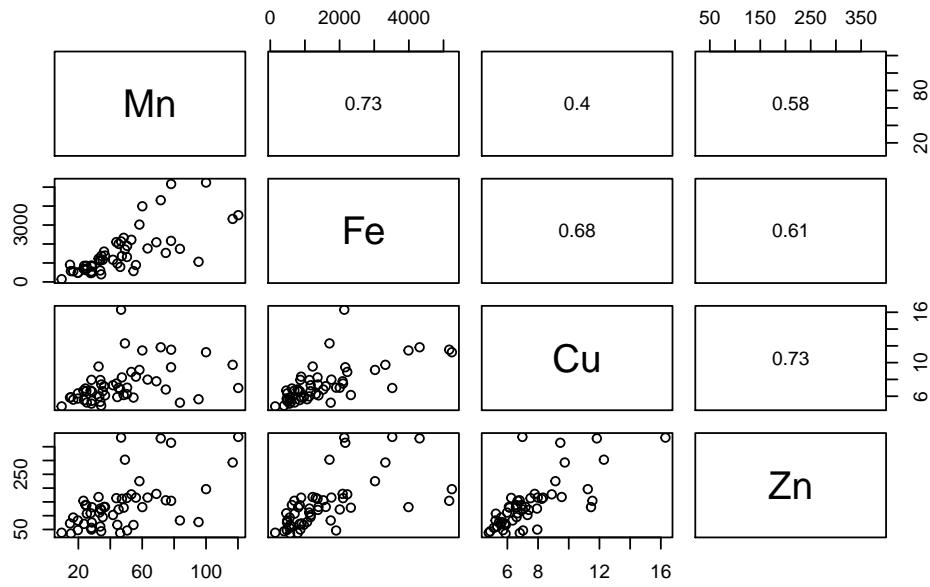


Figura 5.10: Gráfico do desenhista para os dados da concentração de elementos químicos em cascas de árvores.

Outros tipos de gráficos podem ser encontrados em Cleveland (1979) e Chambers et al. (1983), entre outros.

5.4 Medidas resumo multivariadas

Consideremos valores de p variáveis X_1, \dots, X_p , medidas em n unidades amostrais dispostos na forma de uma matriz de dados \mathbf{X} , de ordem $n \times p$, i.e.,

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1v} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2v} & \cdots & x_{2p} \\ \vdots & \vdots & & \vdots & & \vdots \\ x_{ii} & x_{i2} & \cdots & x_{iv} & \cdots & x_{ip} \\ \vdots & \vdots & & \vdots & & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nv} & \cdots & x_{np} \end{bmatrix}. \quad (5.2)$$

Para cada variável X_i podemos considerar as medidas resumo já estudadas no Capítulo 3 (média, mediana, quantis, variância etc.). Para cada par de variáveis, X_i e X_j , também podemos considerar as medidas de correlação (linear) já estudadas no Capítulo 4, a saber, covariância e coeficiente de correlação. O vetor de dimensão $p \times 1$ contendo as p médias é chamado de **vetor de médias**. Similarmente, a matriz simétrica com dimensão $p \times p$

contendo as variâncias ao longo da diagonal principal e as covariâncias dispostas acima e abaixo dessa diagonal é chamada de **matriz de covariâncias** de X_1, \dots, X_p ou, equivalentemente, do vetor $\mathbf{X} = (X_1, \dots, X_p)^\top$. Tanto o vetor de médias quanto a matriz de covariâncias (ou de correlações) correspondentes ao vetor de variáveis podem ser facilmente calculados por meio de operações matriciais como detalhado na Nota de Capítulo 1.

Exemplo 5.6 Consideremos as variáveis CO, O3, Temp e Umid do arquivo *poluicao*. A matriz de covariâncias correspondente é

	CO	O3	Temp	Umid
CO	2.38	-14.01	-0.14	1.46
O3	-14.01	2511.79	9.43	-239.02
Temp	-0.14	9.43	3.10	0.14
Umid	1.46	-239.02	0.14	153.63

Note que $\text{Cov}(\text{CO}, \text{O3}) = -14.01 = \text{Cov}(\text{O3}, \text{CO})$ etc. Para obter a correspondente **matriz de correlações**, basta usar a definição (4.10) para cada par de variáveis, obtendo-se a matriz

	CO	O3	Temp	Umid
CO	1.00	-0.18	-0.05	0.08
O3	-0.18	1.00	0.11	-0.38
Temp	-0.05	0.11	1.00	0.01
Umid	0.08	-0.38	0.01	1.00

As correlações entre as variáveis são irrelevantes, exceto para O3 e Umid.

Exemplo 5.7 Consideremos agora os dados do arquivo *iris*. A matriz de correlações correspondente é

	i1	i2	i3	i4
i1	1.00	-0.12	0.87	0.82
i2	-0.12	1.00	-0.43	-0.37
i3	0.87	-0.43	1.00	0.96
i4	0.82	-0.37	0.96	1.00

em que i1=Sepal.Length, i2=Sepal.Width, i3=Petal.Length e i4=Petal.Width.

Na Figura 5.11 dispomos o gráfico do desenhista para as quatro variáveis, com o acréscimo dos coeficientes de correlação de Pearson na parte superior, confirmando a relevância das associação positiva observada entre os pares de variáveis (i1,i3), (i1,i4) e (i3,i4).

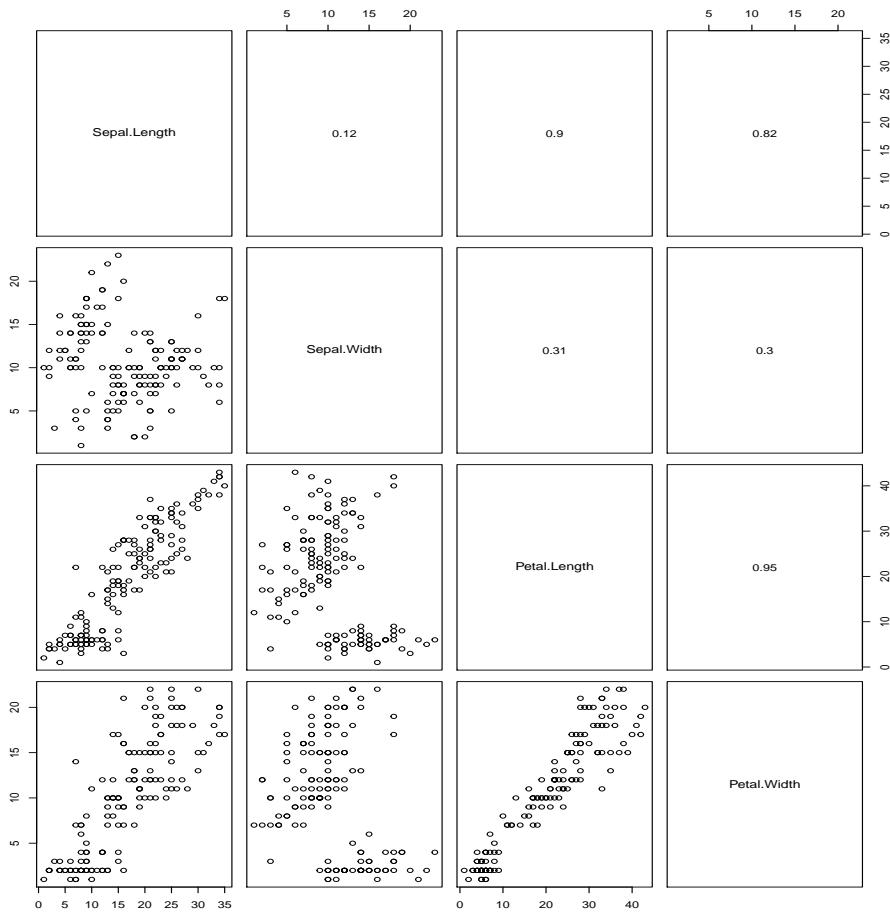


Figura 5.11: Gráfico do desenhista para os dados do CD-iris.

5.5 Tabelas de contingência de múltiplas entradas

A análise de dados de três ou mais variáveis qualitativas (ou quantitativas categorizadas) pode ser realizada nos moldes daquela abordada na Seção 4.2 para duas variáveis. A distribuição de frequências conjunta correspondente pode ser representada por meio de tabelas de contingência de múltiplas entradas. Nesse contexto, as frequências de um conjunto de dados com três variáveis qualitativas com 3, 3 e 2 níveis, respectivamente, são representadas numa tabela $3 \times 3 \times 2$. Como ilustração, consideremos o seguinte exemplo.

Exemplo 5.8 Consideremos as variáveis `dismenorreia`, `esterelidade` e `endometriose` do arquivo `endometrise2`. A tabela de frequências conjunta pode ser obtida por meio dos seguintes comandos

```
> endomet1 <- read.xls("/home/jmsinger/Desktop/endometrise2.xls",
  sheet='dados', method="tab")
> endomet1$dismenorreia <- reorder(endomet1$dismenorreia,
```

```

new.order=c("nao", "leve", "moderada",
           "intensa", "incapacitante"))

> attach(endomet1)
> tab <- ftable(dismenorreia, esterelidade, endometriose)
> tab
            endometriose nao sim
dismenorreia esterelidade
nao          nao        482 36
                  sim        100 27
leve          nao        259 31
                  sim        77 14
moderada      nao        84 71
                  sim        31 45
intensa       nao        160 134
                  sim        52 67
incapacitante nao        106 43
                  sim        28 24

```

Quando o objetivo é estudar as relações de dependência entre as três variáveis encaradas como resposta, as frequências relativas calculadas em relação ao total de pacientes é obtida por meio do comando

```

> tabprop <- prop.table(tab)
> tabprop <- round(tabprop, 2)
> tabprop
            endometriose  nao   sim
dismenorreia esterelidade
nao          nao        0.26 0.02
                  sim        0.05 0.01
leve          nao        0.14 0.02
                  sim        0.04 0.01
moderada      nao        0.04 0.04
                  sim        0.02 0.02
intensa       nao        0.09 0.07
                  sim        0.03 0.04
incapacitante nao        0.06 0.02
                  sim        0.01 0.01

```

Nesse caso, as análises de interesse geralmente envolvem hipóteses de independência conjunta, independência marginal e independência condicional e são estudadas com técnicas de análise de dados categorizados, por meio de modelos log-lineares.

Alternativamente, o interesse pode recair na avaliação do efeito de duas das variáveis (encaradas como fatores) e de sua interação na distribuição da outra variável, encarada como variável resposta, como o mesmo espírito daquele envolvendo problemas de ANOVA. As frequências relativas correspondentes devem ser calculadas em relação ao total das linhas da tabela. Com essa finalidade, consideremos os comandos

```

> tabprop12 <- prop.table(tab,1)
> tabprop12 <- round(tabprop12,2)
> tabprop12
            endometriose  nao  sim
dismenorreia  esterelidade
  nao          nao           0.93 0.07
              sim           0.79 0.21
  leve          nao           0.89 0.11
              sim           0.85 0.15
  moderada     nao           0.54 0.46
              sim           0.41 0.59
  intensa      nao           0.54 0.46
              sim           0.44 0.56
  incapacitante nao           0.71 0.29
              sim           0.54 0.46

```

Medidas de associação entre **esterelidade** e **endometriose** podem ser obtidas para cada nível de **dismenorreia** por meio das tabelas marginais, com os seguintes comandos do pacote vcd

```

> nao <- subset(endomet1, dismenorreia == "nao", na.rm=TRUE)
> attach(nao)
> tab1 <- ftable(esterelidade, endometriose)
> tab1
            endometriose  nao  sim
esterelidade
  nao           482   36
  sim           100   27
> assocstats(tab1)
      X^2 df    P(> X^2)
Likelihood Ratio 19.889  1 8.2064e-06
Pearson          23.698  1 1.1270e-06

Phi-Coefficient : 0.192
Contingency Coeff.: 0.188
Cramer's V       : 0.192

```

Razões de chances (e intervalos de confiança) correspondentes às variáveis **esterelidade** e **endometriose** podem ser obtidas para cada nível de **dismenorreia** são obtidas com os seguintes comandos do pacote epiDisplay

```

> endomet1 %$% mhor(esterelidade, endometriose, dismenorreia,
                     graph = F)

Stratified analysis by  dismenorreia
                                         OR lower lim. upper lim.  P value
dismenorreia  nao                 3.61        2.008      6.42 7.73e-06
dismenorreia  leve                1.52        0.708      3.12 2.63e-01

```

dismenorreia moderada	1.71	0.950	3.12	6.86e-02
dismenorreia intensa	1.54	0.980	2.42	5.11e-02
dismenorreia incapacitante	2.10	1.042	4.25	2.69e-02
M-H combined	1.91	1.496	2.45	1.36e-07

M-H Chi2(1) = 27.77 , P value = 0

Homogeneity test, chi-squared 4 d.f. = 6.9 , P value = 0.141

O resultado obtido por meio da razão de chances combinada pelo **método de Mantel-Haenszel** sugerem que a chance de endometriose para pacientes com sintomas de esterilidade é 1,91 (IC95%: 1,5 - 2,45) vezes a chance de endometriose para pacientes sem esses sintomas, independentemente da intensidade da dismenorreia. Detalhes sobre a técnica de Mantel-Haenszel são apresentados na Nota de Capítulo 4.

5.6 Notas de capítulo

1) Notação matricial para variáveis multivariadas

Nesta seção iremos formalizar a notação matricial usualmente empregada para representar medidas resumo multivariadas.

Denotemos cada coluna da matriz de dados \mathbf{X} por \mathbf{x}_j , $j = 1, \dots, p$, com elementos x_{ij} , $i = 1, \dots, n$. Então, definindo $\bar{x}_j = n^{-1} \sum_{i=1}^n x_{ij}$, o vetor de médias é expresso como $\bar{\mathbf{x}} = (\bar{x}_1, \dots, \bar{x}_p)^\top$.

Se denotarmos por $\mathbf{1}_n$ o vetor coluna de ordem $n \times 1$ contendo todos os elementos iguais a um, podemos escrever o vetor de médias como

$$\bar{\mathbf{x}}^\top = \frac{1}{n} \mathbf{1}_n^\top \mathbf{X} = [\bar{x}_1, \dots, \bar{x}_p]. \quad (5.3)$$

A matriz de desvios de cada observação em relação à média correspondente é

$$\mathbf{Y} = \mathbf{X} - \mathbf{1}_n \bar{\mathbf{x}}^\top \quad (5.4)$$

de forma que a matriz de covariâncias pode ser expressa como

$$\mathbf{S} = \frac{1}{n-1} \mathbf{Y}^\top \mathbf{Y}. \quad (5.5)$$

Na diagonal principal de \mathbf{S} constam as variâncias amostrais s_{jj} , $j = 1, \dots, p$ e nas demais diagonais temos as covariâncias amostrais

$$s_{uv} = \frac{1}{n-1} \sum_{i=1}^n (x_{iu} - \bar{x}_u)(x_{iv} - \bar{x}_v), \quad u, v = 1, \dots, p,$$

em que $s_{uv} = s_{vu}$, para todo u, v . Ou seja, podemos escrever

$$\mathbf{S} = \begin{bmatrix} s_{11} & s_{12} & \cdots & s_{1p} \\ s_{21} & s_{22} & \cdots & s_{2p} \\ \vdots & \vdots & & \vdots \\ s_{p1} & s_{p2} & \cdots & s_{pp} \end{bmatrix}.$$

O desvio padrão amostral da j -ésima componente é $s_j = (s_{jj})^{1/2}$, $j = 1, \dots, p$. Denotando por \mathbf{D} a matriz diagonal de ordem $p \times p$ com o j -ésimo elemento da diagonal igual a s_j , a **matriz de correlações** é definida por

$$\mathbf{R} = \mathbf{D}^{-1} \mathbf{SD}^{-1} = [r_{uv}]. \quad (5.6)$$

em que $r_{vv} = r_v = 1$, $v = 1, \dots, p$ e $r_v \geq r_{uv}$ para todo $u \neq v$.

O coeficiente de correlação amostral entre as variáveis X_u e X_v é dado por

$$r_{uv} = \frac{s_{uv}}{\sqrt{s_u s_v}}, \quad (5.7)$$

com $-1 \leq r_{uv} \leq 1$ e $r_{uv} = r_{vu}$ para todo u, v .

Em muitas situações também são de interesse as somas de quadrados de desvios, nomeadamente

$$W_{vv} = \sum_{i=1}^n (x_{iv} - \bar{x}_v)^2, \quad v = 1, \dots, p \quad (5.8)$$

e as somas dos produtos de desvios, a saber,

$$W_{uv} = \sum_{i=1}^n (x_{iu} - \bar{x}_u)(x_{iv} - \bar{x}_v), \quad u, v = 1, \dots, p. \quad (5.9)$$

Exemplo 5.9. Os dados dispostos na Tabela 5.4 correspondem a cinco agentes de seguros para os quais foram observados os valores das variáveis X_1 = número de anos de serviço e X_2 = número de clientes.

Tabela 5.4: Número de anos de serviço e número de clientes para cinco agentes de seguros

Agente	X_1	X_2
A	2	48
B	4	56
C	5	64
D	6	60
E	8	72

Para os dados da Tabela 5.4, a matriz de dados é

$$\mathbf{X}^\top = \begin{bmatrix} 2 & 4 & 5 & 6 & 8 \\ 48 & 56 & 64 & 60 & 72 \end{bmatrix},$$

de modo que

$$\bar{x}_1 = \frac{1}{5} \sum_{i=1}^5 x_{i1} = \frac{1}{5}(2 + 4 + 5 + 6 + 8) = 5,$$

$$\bar{x}_2 = \frac{1}{5} \sum_{i=1}^5 x_{i2} = \frac{1}{5}(48 + 56 + 64 + 60 + 72) = 60$$

e o vetor de médias é

$$\bar{\mathbf{x}} = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \end{bmatrix} = \begin{bmatrix} 5 \\ 60 \end{bmatrix}.$$

A matriz de desvios em relação às médias é

$$\mathbf{Y} = \begin{bmatrix} 2 & 48 \\ 4 & 56 \\ 5 & 64 \\ 6 & 60 \\ 8 & 72 \end{bmatrix} - \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} [5 \quad 60] = \begin{bmatrix} 2-5 & 48-60 \\ 4-5 & 56-60 \\ 5-5 & 64-60 \\ 6-5 & 60-60 \\ 8-5 & 72-60 \end{bmatrix} = \begin{bmatrix} -3 & -12 \\ -1 & -4 \\ 0 & 4 \\ 1 & 0 \\ 3 & 12 \end{bmatrix}$$

e as correspondentes matrizes de covariâncias e correlações são, respectivamente,

$$\mathbf{S} = \frac{1}{5-1} \mathbf{Y}^\top \mathbf{Y} = \begin{bmatrix} 5 & 19 \\ 19 & 80 \end{bmatrix} \quad \text{e} \quad \mathbf{R} = \begin{bmatrix} 1 & 0,95 \\ 0,95 & 1 \end{bmatrix}.$$

As variâncias e covariâncias amostrais são respectivamente,

$$s_{11} = \frac{1}{4} \sum_{i=1}^5 (x_{i1} - \bar{x}_1)^2 = 5, \quad s_{22} = \frac{1}{4} \sum_{i=1}^5 (x_{i2} - \bar{x}_2)^2 = 80,$$

$$s_{12} = s_{21} = \frac{1}{4} \sum_{i=1}^5 (x_{i1} - \bar{x}_1)(x_{i2} - \bar{x}_2) = 19$$

ao passo que as correlações amostrais são dadas por

$$r_{11} = r_{22} = 1 \quad \text{e} \quad r_{12} = r_{21} = \frac{s_{12}}{\sqrt{s_{11}s_{22}}} = \frac{19}{\sqrt{5 \times 80}} = 0,95.$$

2) Lowess

Muitas vezes, gráficos de dispersão (simbólicos ou não) são utilizados para a identificação de curvas que possam representar a relação entre as variáveis sob avaliação. Por exemplo, pode haver interesse em saber se uma variável é uma função linear ou quadrática da outra. O ajuste de uma curva suave aos dados pode ser realizado or meio da técnica conhecida como **lowess** (*locally weighted regression scatterplot smoothing*). Essa técnica de **suavização** é realizada por meio de sucessivos ajustes de retas por mínimos quadrados ponderados (ver Capítulo 6) a subconjuntos dos dados.

Consideremos, as coordenadas (x_j, y_j) , $j = 1, \dots, n$ de um conjunto de dados, por exemplo, correspondentes aos pontos associados aos veículos `drv=4` na Figura 5.5. O ajuste de uma curva suave a esses pontos por meio da técnica lowess é baseado na substituição da coordenada y_j por um valor suavizado \hat{y}_j obtido segundo os seguintes passos:

- i) Escolha uma faixa vertical centrada em (x_j, y_j) contendo q pontos conforme ilustrado na Figura 5.12 (em que $q = 9$). Em geral, escolhemos $q = [n \times p]$ em que $0 < p < 1$, tendo em conta que quanto maior for p , maior será o grau de suavização.

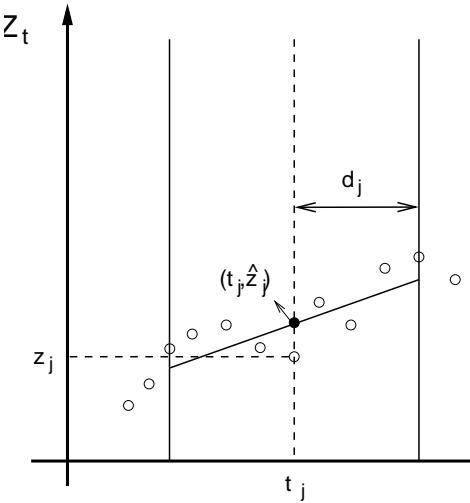


Figura 5.12: Faixa centrada em (x_j, y_j) para suavização por lowess.

- ii) Use uma função simétrica em torno de x_j para atribuir pesos aos pontos na vizinhança de (x_j, y_j) . Essa função é escolhida de forma que o maior peso seja atribuído a (x_j, y_j) e que os demais pesos diminuam à medida que x se afasta de x_j . Com essa finalidade, utiliza-se a **função tricúbica**

$$h(u) = \begin{cases} (1 - |u|^3)^3, & \text{se } |u| < 1 \\ 0, & \text{em caso contrário.} \end{cases}$$

O peso atribuído a (x_k, y_k) é $h[(x_j - x_k)/d_j]$ em que d_j é a distância entre x_j e seu vizinho mais afastado dentro da faixa selecionada em i) conforme ilustrado na Figura 5.13.

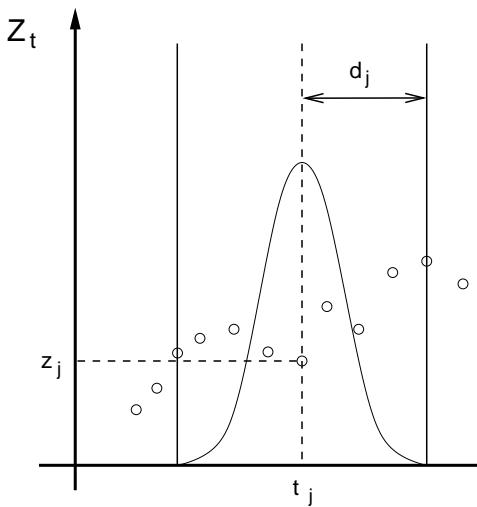


Figura 5.13: Atribuição de pesos para suavização por lowess.

- iii) Ajuste uma reta $y = \alpha + \beta x + e$ aos q pontos da faixa centrada em x_j , por meio da minimização de

$$\sum_{k=1}^q h_j(x_k)(y_k - \alpha - \beta x_k)^2,$$

obtendo os estimadores $\hat{\alpha}$ e $\hat{\beta}$. O valor suavizado de y_k é $\hat{y}_k = \hat{\alpha} + \hat{\beta}x_k$, $k = 1, \dots, q$.

- iv) Calcule os resíduos $\hat{e}_k = y_k - \hat{y}_k$, $k = 1, \dots, q$ e por meio de um gráfico de dispersão, por exemplo, identifique possíveis pontos discrepantes (*outliers*). Quando existirem, refaça os cálculos, atribuindo pesos menores aos maiores resíduos, por meio da **função biquadrática**

$$g(u) = \begin{cases} (1 - |u|^2)^2, & \text{se } |u| < 1 \\ 0, & \text{em caso contrário.} \end{cases}$$

O peso atribuído ao ponto (x_k, y_k) é $g(x_k) = g(\hat{e}_k/6m)$ em que m é a mediana dos valores absolutos dos resíduos ($|\hat{e}_k|$). Se o resíduo \hat{e}_k for muito menor do que $6m$, o peso a ele atribuído será próximo de 1; em caso contrário, será próximo de zero. A razão pela qual utilizamos o denominador $6m$ é que se os resíduos tiverem uma distribuição Normal com variância σ^2 , então $m \approx 2/3$ e $6m \approx 4\sigma$. Isso implica que para resíduos Normais, raramente teremos pesos pequenos.

- v) Finalmente, ajuste uma nova reta aos pontos (x_k, y_k) com pesos $h(x_k)g(x_k)$. Se (x_k, y_k) corresponder a um ponto discrepante, o resíduo \hat{e}_k será grande, mas o peso atribuído a ele será pequeno.

- vi) Repita o procedimento duas ou mais vezes, observando que a presença de pontos discrepantes exige um maior número de iterações.

Gráficos das funções tricúbica [$h(u)$] e biquadrática [$g(u)$] estão exibidos na Figura 5.14.

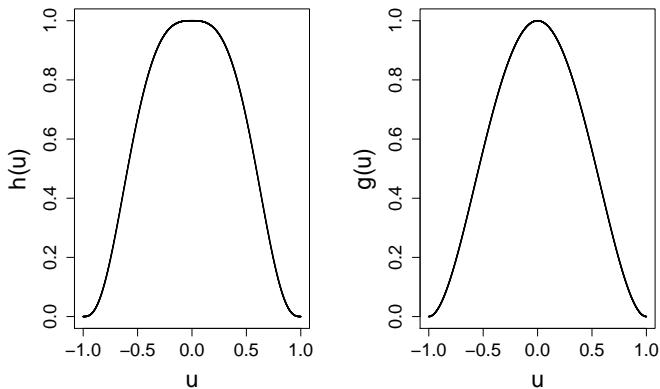


Figura 5.14: Gráficos das funções tricúbica [$h(u)$] e biquadrática [$g(u)$].

Para mais detalhes sobre o método lowess bem como sobre outros métodos de suavização o leitor poderá consultar Morettin e Tolói (2018), por exemplo.

Por meio dos comandos

```
> rotarod<-read.xls("/home/jmsinger/Desktop/rotarod.xls",
+ sheet = 'dados', method = "tab")
> par(mar=c(5.1,5.1,4.1,2.1))
> plot(rotarod$tempo, rotarod$rotarod, type='p',
+ xlab = "Tempo", ylab ="Rotarod",
+ cex.axis = 1.3, cex.lab = 1.6)
> lines(lowess(rotarod$rotarod ~ rotarod$tempo, f=0.1),
+ col=1, lty=2, lwd =2)
> lines(lowess(rotarod$rotarod ~ rotarod$tempo, f=0.4),
+ col=2, lty=1, lwd =2)
```

podemos obter o gráfico disposto na Figura 5.15, em que apresentamos curvas lowess (com dois níveis de suavização) ajustadas aos pontos de um conjunto de dados obtidos de um estudo cujo objetivo era propor um modelo para avaliar a evolução de uma variável ao longo do tempo. O gráfico sugere um modelo de **regressão segmentada**, *i.e.* em que a resposta média assume um valor constante até um ponto de mudança, a partir do qual a uma curva quadrática pode representar a sua variação temporal.

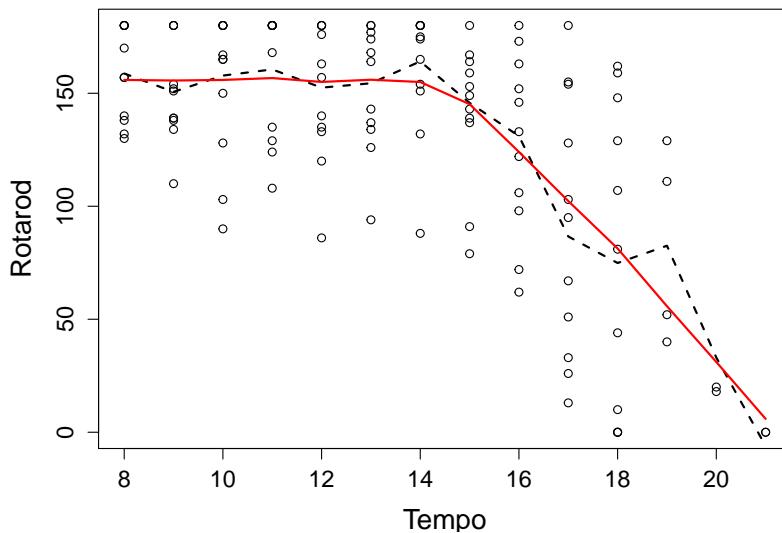


Figura 5.15: Curvas lowess com diferentes parâmetros de suavização ajustadas a um conjunto de dados.

3) Parametrização de desvios médios

Com a finalidade de explicitar efeitos principais e interação no modelo, é comum considerar-se a reparametrização $\mu_{ij} = \mu + \alpha_i + \beta_j + \alpha\beta_{ij}$, que implica o modelo

$$y_{ijk} = \mu + \alpha_i + \beta_j + \alpha\beta_{ij} + e_{ijk}, \quad (5.10)$$

$i = 1, \dots, a$, $j = 1, \dots, b$, $k = 1, \dots, m$. Muitos autores, como Nelder et al. (1988), interpretam erroneamente os parâmetros μ , α_i , β_j , $\alpha\beta_{ij}$, respectivamente, como “média geral”, “efeito principal do nível i do fator A ”, “efeito principal do nível j do fator B ” e “interação entre os níveis i do fator A e j do fator B ”. Esse modelo também é **inidentificável**¹ e seus parâmetros são não estimáveis e as restrições de identificabilidade mais frequentemente utilizadas e correspondentes às parametrizações de desvios de médias e cela de referência são, respectivamente,

$$\sum_{i=1}^a \alpha_i = \sum_{j=1}^b \beta_j = \sum_{i=1}^a \alpha\beta_{ij} = \sum_{j=1}^b \alpha\beta_{ij} = 0 \quad (5.11)$$

¹Um modelo $F(\theta)$, dependendo do parâmetro $\theta \subset \Theta$, é identificável se para todo $\theta_1, \theta_2 \subset \Theta$, $\theta_1 \neq \theta_2$ temos $F(\theta_1) \neq F(\theta_2)$. Em caso contrário, o modelo é dito inidentificável. Por exemplo, consideremos o modelo $y_i \sim N(\mu + \alpha_i, \sigma^2)$, $i = 1, 2$ em que y_1 e y_2 são independentes. Tomando $\boldsymbol{\theta} = (\mu, \alpha_1, \alpha_2)^\top$ como parâmetro, o modelo é inidentificável, pois tanto para $\boldsymbol{\theta}_1 = (5, 1, 0)^\top$ quanto para $\boldsymbol{\theta}_2 = (4, 2, 1)^\top \neq \boldsymbol{\theta}_1$, a distribuição conjunta de (y_1, y_2) é $N_2([(6, 6)^\top, \sigma^2 \mathbf{I}_2])$. O leitor poderá consultar Bickel e Doksum (2001), entre outros, para detalhes.

e

$$\alpha_1 = \beta_1 = \alpha\beta_{11} = \dots = \alpha\beta_{1b} = \alpha\beta_{21} = \dots = \alpha\beta_{a1} = 0 \quad (5.12)$$

Sob as restrições (5.11), pode-se mostrar que

$$\mu = (ab)^{-1} \sum_{i=1}^a \sum_{j=1}^b \mu_{ij}, \quad \alpha_i = b^{-1} \sum_{j=1}^b \mu_{ij} - \mu, \quad \beta_j = a^{-1} \sum_{i=1}^a \mu_{ij} - \mu$$

e que

$$\alpha\beta_{ij} = \mu_{ij} - b^{-1} \sum_{j=1}^b \mu_{ij} - a^{-1} \sum_{i=1}^a \mu_{ij}.$$

Sob as restrições (5.12), temos

$$\mu = \mu_{11}, \quad \alpha_i = \mu_{ij} - \mu_{1j}, \quad i = 2, \dots, a, \quad \beta_j = \mu_{ij} - \mu_{i1}, \quad j = 2, \dots, b,$$

e que

$$\alpha\beta_{ij} = \mu_{ij} - (\mu_{11} + \alpha_i + \beta_j), \quad i = 2, \dots, a, \quad j = 2, \dots, b,$$

de forma que os parâmetros α_i , $i = 2, \dots, a$ podem ser interpretados como efeitos diferenciais entre as respostas esperadas das unidades amostrais submetidas ao nível i do fator A relativamente àquelas obtidas por unidades amostrais submetidas ao tratamento associado ao nível 1 do fator A , mantido fixo o nível correspondente ao fator B . Analogamente, os parâmetros β_j , $j = 2, \dots, b$ podem ser interpretados como efeitos diferenciais entre as respostas esperadas das unidades amostrais submetidas ao nível j do fator B relativamente àquelas obtidas por unidades amostrais submetidas ao tratamento associado ao nível 1 do fator B , mantido fixo o nível correspondente do fator A . Os parâmetros $\alpha\beta_{ij}$, $i = 2, \dots, a$, $j = 2, \dots, b$ podem ser interpretados como diferenças entre as respostas esperadas das unidades amostrais submetidas ao tratamento correspondente à cela (i, j) e aquela esperada sob um modelo sem interação.

4) A estatística de Mantel-Haenszel

A estatística de Mantel-Haenszel é utilizada para avaliar a associação em conjuntos de tabelas 2×2 obtidas de forma estratificada segundo o paradigma indicado na Tabela 5.5, com apenas dois estratos, para simplificação.

Tabela 5.5: Frequência de pacientes

Estrato	Fator de risco	Status do paciente		Total
		doente	são	
1	presente	n_{111}	n_{112}	n_{11+}
	ausente	n_{121}	n_{122}	n_{12+}
		n_{1+1}	n_{1+2}	n_{1++}
2	presente	n_{211}	n_{212}	n_{21+}
	ausente	n_{221}	n_{222}	n_{22+}
		n_{2+1}	n_{2+2}	n_{2++}

Uma estimativa da razão de chances para o estrato h é

$$rc_h = \frac{n_{h11}n_{h22}}{n_{h12}n_{h21}}.$$

A estimativa da razão de chances comum proposta por Mantel e Haenszel (1959) é uma média ponderada das razões de chances de cada um dos H estratos com pesos

$$w_h = \frac{n_{h12}n_{h21}}{n_{h++}} / \sum_{h=1}^H \frac{n_{h12}n_{h21}}{n_{h++}},$$

ou seja

$$\begin{aligned} rc_{MH} &= \sum_{h=1}^H w_h rc_h = \sum_{h=1}^H \frac{n_{h12}n_{h21}}{n_{h++}} \times \frac{n_{h11}n_{h22}}{n_{h12}n_{h21}} / \sum_{h=1}^H \frac{n_{h12}n_{h21}}{n_{h++}} \\ &= \sum_{h=1}^H \frac{n_{h11}n_{h22}}{n_{h++}} / \sum_{h=1}^H \frac{n_{h12}n_{h21}}{n_{h++}} \end{aligned}$$

Consideremos, por exemplo, os dados dispostos na Tabela 5.6 provenientes de um estudo cujo objetivo é avaliar a associação entre um fator de risco e a ocorrência de uma determinada moléstia com dados obtidos em três clínicas diferentes.

Tabela 5.6: Frequências de pacientes em um estudo com três estratos

Clínica	Fator de risco	Doença		Razão de chances
		sim	não	
A	presente	5	7	12
	ausente	2	8	10
B	presente	3	9	12
	ausente	1	6	7
C	presente	3	4	7
	ausente	2	7	9

A estimativa da razão de chances proposta por Mantel-Haenszel é

$$rc_{MH} = \frac{(5 \times 8)/22 + (3 \times 6)/19 + (3 \times 7)/16}{(7 \times 2)/22 + (9 \times 1)/19 + (4 \times 2)/16} = 2,53.$$

Uma das vantagens da razão de chances de Mantel-Haenszel é que ela permite calcular a razão de chances comum mesmo quando há frequências nulas. Vamos admitir que uma das frequências da Tabela 5.6, fosse nula, como indicado na Tabela 5.7

Tabela 5.7: Tabela com frequência nula

Clínica	Fator de risco	Doença		Total	Razão de chances
		sim	não		
A	presente	5	7	12	∞
	ausente	0	10	10	
B	presente	3	9	12	2,00
	ausente	1	6	7	
C	presente	3	4	7	2,63
	ausente	2	7	9	

Embora a razão de chances para o estrato A seja “infinita”, a razão de chances de Mantel-Haenszel pode ser calculada,

$$rc_{MH} = \frac{(5 \times 10)/22 + (3 \times 6)/19 + (3 \times 8)/16}{(7 \times 0)/22 + (9 \times 1)/19 + (4 \times 2)/16} = 6,56.$$

Outra vantagem da estatística de Mantel-Haenszel é que ela não é afetada pelo **Paradoxo de Simpson**, que ilustramos por meio de um exemplo em que a opinião sobre um determinado projeto foi avaliada com moradores de duas regiões, obtendo-se os dados apresentados na Tabela 5.8.

Tabela 5.8: Tabela com frequências relacionadas com a preferência por dois projetos

Região	Projeto	Opinião		Total	Razão de chances
		favorável	desfavorável		
1	A	50	950	1000	0,47
	B	1000	9000	10000	
	Total	1050	9950	10000	
2	A	5000	5000	1000	0,05
	B	95	5	100	
	Total	5095	5005	10100	

Segundo a Tabela 5.8, em ambas as regiões, há uma preferência pelo Projeto B ou seja, a chance de preferência pelo projeto B é pelo menos o dobro daquela de preferência pelo Projeto A. Se agruparmos os dados somando os resultados de ambas as regiões, obteremos as frequências dispostas na Tabela 5.9.

Tabela 5.9: Frequências agrupadas correspondentes à Tabela 5.8

Projeto	Opinião		Total	Razão de chances
	favorável	desfavorável		
A	5050	5950	11000	6,98
B	1095	9005	10100	
Total	6145	9950	21100	

A razão de chances obtida com os dados agrupados indicam que a chance de preferência pelo Projeto A é cerca de 7 vezes aquela de preferência pelo Projeto B. Essa aparente incongruência é conhecida como o Paradoxo de Simpson e pode ser explicado por uma forte associação (com $rc = 0,001$) entre a variável Região e Projeto como indicado na Tabela 5.10.

Tabela 5.10: Frequências de pacientes favoráveis a cada projeto

Projeto	Região		Total	Razão de chances
	1	2		
A	1000	10000	11000	0,001
B	10000	100	10100	
Total	11000	10100	21100	

A estatística de Mantel-Haenszel correspondente é

$$rc_{MH} = \frac{(50 \times 9000)/11000 + (5000 \times 5)/10100}{(950 \times 1000)/11000 + (5000 \times 95)/10100} = 0,33$$

preservando a associação entre as duas variáveis de interesse. Detalhes sobre o Paradoxo de Simpson podem ser encontrados em Paulino e Singer (2006).

5.7 Exercícios

- 1) Um laboratório de pesquisa desenvolveu uma nova droga para febre tifóide com a mistura de duas substâncias químicas (A e B). Foi realizado um ensaio clínico com o objetivo de estabelecer as dosagens

adequadas (baixa ou alta, para a substância A, e baixa, média ou alta, para a substância B) na fabricação da droga. Vinte e quatro voluntários foram aleatoriamente distribuídos em 6 grupos de 4 indivíduos e cada grupo foi submetido a um dos 6 tratamentos. A resposta observada foi o tempo para o desaparecimento dos sintomas (em dias). Os resultados obtidos estão dispostos na Tabela 5.11

Tabela 5.11: Tempo para o desaparecimento dos sintomas (dias)

Dose da substância A	Dose da substância B		
	baixa	média	alta
baixa	10,4	8,9	4,8
baixa	12,8	9,1	4,5
baixa	14,6	8,5	4,4
baixa	10,5	9,0	4,6
alta	5,8	8,9	9,1
alta	5,2	9,1	9,3
alta	5,5	8,7	8,7
alta	5,3	9,0	9,4

- a) Faça uma análise descritiva dos dados com o objetivo de avaliar qual a combinação de dosagens das substâncias faz com que os sintomas desapareçam em menos tempo.
- b) Especifique o modelo para a comparação dos 6 tratamentos quanto ao tempo para o desaparecimento dos sintomas. Identifique os fatores e seus níveis.
- c) Construa o gráfico dos perfis médios e interprete-o. Com base nesse gráfico, você acha que existe interação entre os fatores? Justifique sua resposta.
- d) Confirme suas conclusões do item c) por meio de uma ANOVA com dois fatores.

- 2) Um experimento foi realizado em dois laboratórios de modo independente com o objetivo de verificar o efeito de três tratamentos (A1, A2 e A3) na concentração de uma substância no sangue de animais (dados hipotéticos). As concentrações observadas nos dois laboratórios são apresentadas na Tabela 5.12.

Tabela 5.12: Concentração de uma substância no sangue de animais

Laboratório 1			Laboratório 2				
A1	A2	A3	A1	A2	A3		
8	4	3	4	6	5		
3	8	2	5	7	4		
1	10	8	3	7	6		
4	6	7	5	8	5		
Total	16	28	20	Total	16	28	20

- a) O que você pode comentar sobre as médias dos três tratamentos nos dois laboratórios?
- b) Sem nenhum cálculo, apenas olhando os dados, em qual dos dois laboratórios será observado o maior valor da estatística F na análise de variância?
- 3) Um estudo foi realizado com o objetivo de avaliar a influência da exposição ao material particulado fino (MP2,5) na capacidade vital forçada (% do predito) em indivíduos que trabalham em ambiente externo. Deseja-se verificar se o efeito da exposição depende da ocorrência de hipertensão ou diabetes. Os 101 trabalhadores na amostra foram classificados quanto à exposição e presença de diabetes ou hipertensão. As médias da capacidade vital forçada em cada combinação das categorias de diabetes ou hipertensão e exposição estão representadas na Figura 5.16.

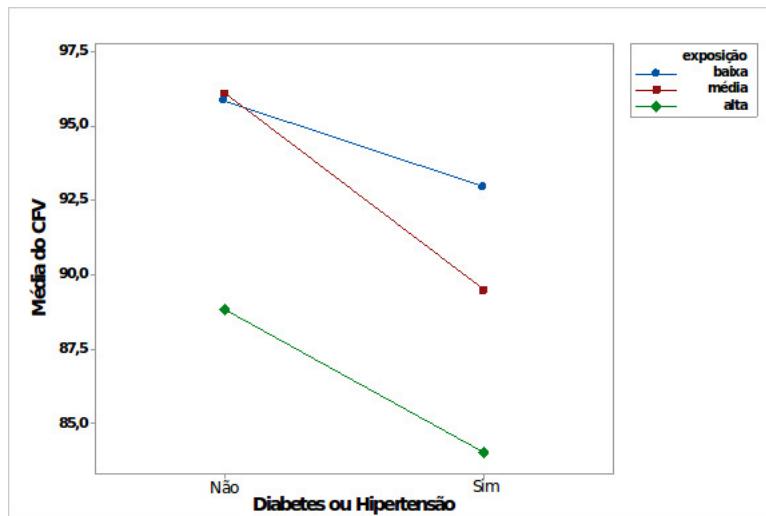


Figura 5.16: Capacidade vital forçada (% do predito).

- a) Comente descritivamente os resultados obtidos, discutindo a interação entre diabetes e exposição ao material particulado.
- b) Que comparações você faria para explicar a interação?

- 4) Considere os dados do arquivo **esforco**.
- a) Para cada etiologia (CH, ID e IS), construa gráficos do desenhista (*draftman's plots*) para avaliar a associação entre os consumos de oxigênio (VO₂) medidos nos três momentos de exercício (LAN, PCR e Pico) e indique os coeficientes de correlação de Pearson e de Spearman correspondentes.
- b) Para cada um dos quatro níveis de avaliação (Repouso, LAN, PCR e Pico), construa gráficos de perfis médios da frequência cardíaca para as diferentes combinações dos níveis de etiologia (CH, ID e IS) e gravidade da doença avaliada pelo critério NYHA. Em cada caso, avalie descritivamente as evidências de efeitos dos fatores Etiologia e Gravidade da doença e de sua interação.
- c) Utilize ANOVA para avaliar se as conclusões descritivas podem ser extrapoladas para a população de onde a amostra foi obtida.
- 5) Considere os dados do arquivo **arvores**. Obtenha os vetores de médias e matrizes de covariâncias e correlações entre as concentrações dos elementos Mn, Fe, Cu, Zn, Sr, Ba, Mg, Al, P, S, Cl e Ca para cada combinação dos níveis de espécie e tipo de via.
- 6) Um novo tipo de bateria está sendo desenvolvido. Sabe-se que o tipo de material da placa e a temperatura podem afetar o tempo de vida da bateria. Há três materiais possíveis a testar em três temperaturas escolhidas de forma a serem consistentes com o ambiente de uso do produto: -9 °C, 21 °C e 50 °C. Quatro baterias foram testadas em cada combinação de material e temperatura em ordem aleatória. As médias observadas do tempo de vida (h) e intervalos de confiança de 95% para as médias populacionais em cada combinação de temperatura e material estão representados no gráfico da Figura 5.17 .

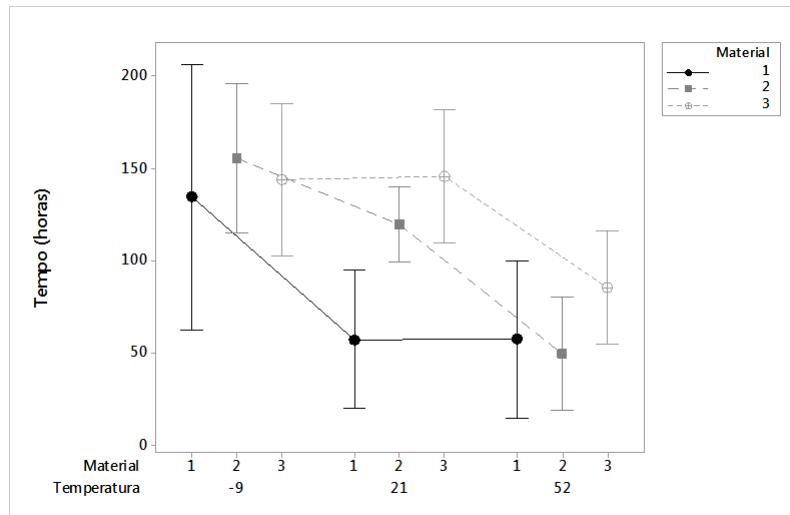


Figura 5.17: Gráfico das médias observadas do tempo de vida (h) e intervalos de confiança de 95% para as médias populacionais em cada combinação de temperatura e material.

Com base nesse gráfico pode-se conjecturar que:

- a) a escolha do material com o qual é obtida a maior média do tempo de vida independe da temperatura;
 - b) as menores médias de tempo de vida foram observadas quando foi utilizado o material 1;
 - c) a temperatura em que foram observadas as maiores médias do tempo de vida é a de 21 °C;
 - d) há interação entre Temperatura e Tempo de vida;
 - e) nenhuma das alternativas acima é correta.
- 7) O gráfico apresentado na Figura 5.18 considera a associação entre as variáveis pressão sistólica e idade de imigrantes com menos de dez anos (Migra1) e com mais de dez anos (Migra2) desde a migração.

A dispersão dos pontos indica que:

- a) existem muitos pontos aberrantes.
- b) existe correlação linear positiva entre as variáveis para o grupo Migra2.
- c) independentemente do tempo desde a migração as variáveis são altamente correlacionadas.
- d) existe correlação linear positiva entre as variáveis para o grupo Migra1.

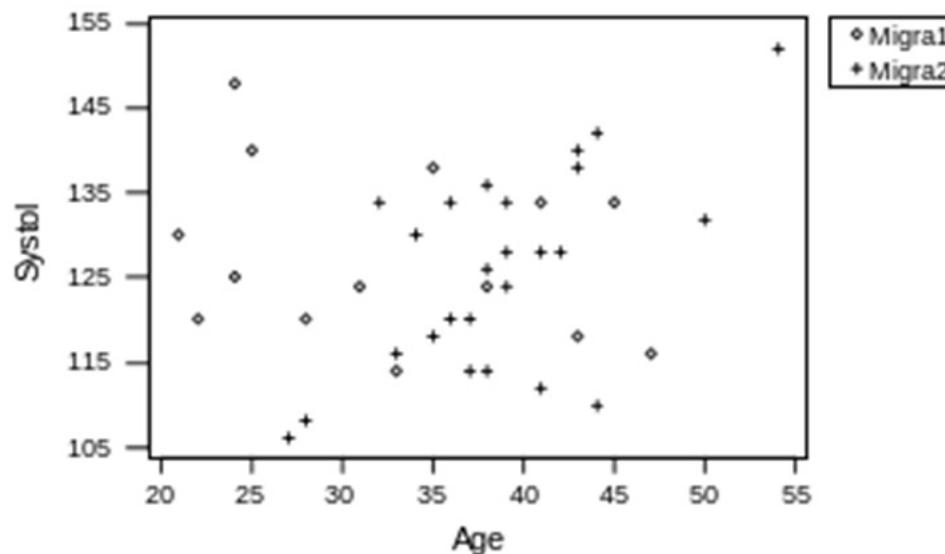


Figura 5.18: Gráfico de Pressão sistólica *versus* Idade para imigrantes.

- 8) Os dados do arquivo `palato` provêm de um estudo realizado no Laboratório Experimental de Poluição Atmosférica da Faculdade de Medicina da Universidade de São Paulo para avaliar os efeitos de agentes oxidantes no sistema respiratório. Espera-se que a exposição a maiores concentrações de agentes oxidantes possa causar danos crescentes às células ciliares e excretoras de muco, que constituem a principal defesa do sistema respiratório contra agentes externos. Cinquenta e seis palatos de sapos foram equitativamente e aleatoriamente alocados a um de seis grupos; cada grupo de 8 palatos foi imerso por 35 minutos numa solução de peróxido de hidrogênio numa concentração especificada, nomeadamente 0, 1, 8, 16, 32 ou 64 μM . A variável resposta de interesse é a velocidade de transporte mucociliar relativa (mm/s), definida como o quociente entre a velocidade de transporte mucociliar num determinado instante e aquela obtida antes da intervenção experimental. Essa variável foi observada a cada cinco minutos após a imersão.
- Obtenha os vetores de médias e matrizes de covariâncias/correlações para os dados correspondentes aos diferentes níveis do fator interunidades amostrais (concentração de peróxido de hidrogênio).
 - Construa gráficos de perfis individuais com perfis médios e curvas lowess sobrepostas para os diferentes níveis da concentração de peróxido de hidrogênio.
 - Compare os resultados obtidos com os diferentes níveis do fator interunidades amostrais.
- 9) Os dados abaixo reportam-se a uma avaliação do desempenho de um

conjunto de 203 estudantes universitários em uma disciplina introdutória de Álgebra e Cálculo. Os estudantes, agrupados segundo os quatro cursos em que estavam matriculados, foram ainda aleatoriamente divididos em dois grupos por curso, a cada um dos quais foi atribuído um de dois professores que lecionaram a mesma matéria. O desempenho de cada aluno foi avaliado por meio da mesma prova.

Frequências de aprovação/reprovação de estudantes.

Curso	Professor	Desempenho	
		Aprovado	Reprovado
Ciências Químicas	A	8	11
	B	11	13
Ciências Farmacêuticas	A	10	14
	B	13	9
Ciências Biológicas	A	19	25
	B	20	18
Bioquímica	A	14	2
	B	12	4

- a) Para valiar a associação entre Professor e Desempenho, calcule a razão de chances em cada estrato.
 - b) Calcule a razão de chances de Mantel-Haenszel correspondente.
 - c) Expresse suas conclusões de forma não técnica.
- 10) Com base nos dados do arquivo **coronarias**, construa uma tabela de contingência $2 \times 2 \times 2 \times 2$ envolvendo os fatores sexo (**SEXO**), idade (**IDA55**) e hipertensão arterial (**HA**) e a variável resposta lesão obstrutiva coronariana $\geq 50\%$ (**L03**). Obtenha as razões de chances entre cada fator e a variável resposta por meio das correspondentes distribuições marginais. Comente os resultados, indicando possíveis problemas com essa estratégia.

Análise de Regressão

Models are, for the most part, caricatures of reality, but if they are good, like good caricatures, they portray, though perhaps in a disturbed manner, some features of the real world.

Mark Kač

6.1 Introdução

Neste capítulo estaremos interessados em avaliar, de modo exploratório, um dos modelos estatísticos mais utilizados na prática, conhecido como **modelo de regressão**. O exemplo mais simples serve para a análise de dados pareados $(x_1, y_1), \dots, (x_n, y_n)$ de duas variáveis contínuas X e Y num contexto em que sabemos a priori que a distribuição de frequências de Y pode depender de X , ou seja, na linguagem introduzida no Capítulo 4, em que X é a variável explicativa e Y é a variável resposta.

Exemplo 6.1: Para efeito de ilustração, considere os dados apresentados na Tabela 6.1 (disponíveis no arquivo `distancia`), oriundos de um estudo cujo objetivo é avaliar como a distância com que motoristas conseguem distinguir um determinado objeto (doravante indicada simplesmente como distância) varia com a idade. Aqui, a variável resposta é a distância e a variável explicativa é a idade. O gráfico de dispersão correspondente está apresentado na Figura 6.1 e mostra uma tendência decrescente da distância com a idade. O objetivo da análise de regressão é quantificar essa tendência. Como a resposta para motoristas com a mesma idade (ou com idades bem próximas) varia, o foco da análise é a estimativa de uma tendência média (representada pela reta sobreposta aos dados na Figura 6.1).

No caso geral em que temos n pares de dados, o modelo de regressão utilizado para essa quantificação é

$$y_i = \alpha + \beta x_i + e_i, \quad i = 1, \dots, n, \tag{6.1}$$

em que α e β são coeficientes (usualmente chamados de **parâmetros**) desconhecidos (e que se pretende estimar com base nos dados) e e_i são erros

Tabela 6.1: Distância com que motoristas conseguem distinguir certo objeto

Ident	Idade (anos)	Distância (m)	Ident	Idade (anos)	Distância (m)
1	18	170	16	55	140
2	20	197	17	63	117
3	22	187	18	65	140
4	23	170	19	66	100
5	23	153	20	67	137
6	25	163	21	68	100
7	27	187	22	70	130
8	28	170	23	71	107
9	29	153	24	72	123
10	32	137	25	73	93
11	37	140	26	74	140
12	41	153	27	75	153
13	46	150	28	77	120
14	49	127	29	79	103
15	53	153	30	82	120

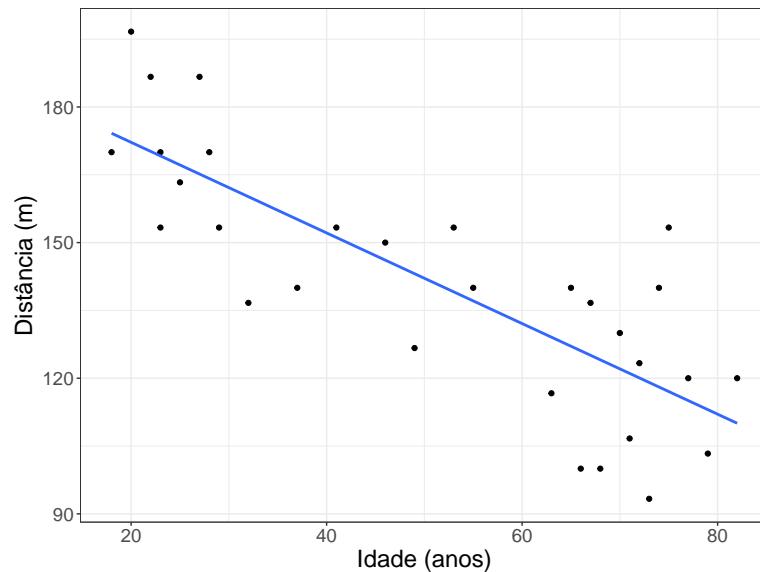


Figura 6.1: Gráfico de dispersão para os dados da Tabela 6.1.

(aleatórios) que representam desvios entre as observações y_i e a reta $\alpha + \beta x$ que corresponde à tendência esperada.¹ Em geral, supõe-se que a média (ou valor esperado) dos erros é nula, o que significa, *grosso modo*, que existe uma compensação entre erros positivos e negativos e que, consequentemente, o objetivo da análise é modelar o valor esperado da variável resposta

$$\text{E}(y_i) = \alpha + \beta x_i.$$

Nesse contexto, podemos interpretar o parâmetro α como a distância esperada com que um recém-nascido, *i.e.*, um motorista com idade $x = 0$, consegue distinguir o determinado objeto e o parâmetro β como a diminuição esperada nessa distância para cada aumento de um ano na idade. Como a interpretação de α não faz muito sentido nesse caso, um modelo mais adequado é

$$y_i = \alpha + \beta(x_i - 18) + e_i, \quad i = 1, \dots, n. \quad (6.2)$$

Para esse modelo, parâmetro α corresponde à distância esperada com que um motorista com idade $x = 18$ anos consegue distinguir o determinado objeto e o parâmetro β tem a mesma interpretação apresentada para o modelo (6.1).

O modelo (6.1) é chamado de **regressão linear simples** e o adjetivo **linear** refere-se ao fato que os parâmetros α e β são incluídos de forma linear. Nesse sentido, o modelo

$$y_i = \alpha + \exp(\beta x_i) + e_i, \quad i = 1, \dots, n \quad (6.3)$$

seria um **modelo não linear**. Por outro lado, o modelo

$$y_i = \alpha + \beta x_i + \gamma x_i^2 + e_i, \quad i = 1, \dots, n, \quad (6.4)$$

é também um modelo linear, pois embora a variável explicativa x esteja elevada ao quadrado, os parâmetros α , β e γ aparecem de forma linear. Modelos como esse, que envolvem funções polinomiais da variável explicativa, são conhecidos como **modelos de regressão polinomial** e serão analisados na Seção 6.3.

Nosso principal objetivo não é discutir em detalhes o problema da estimação dos parâmetros desses modelos, mas considerar métodos gráficos que permitam avaliar se eles são ou não adequados para descrever conjuntos de dados com a estrutura descrita. Infelizmente não poderemos prescindir de apresentar alguns detalhes técnicos. Um tratamento mais aprofundado sobre o ajuste de modelos lineares e não lineares pode ser encontrado em inúmeros textos, dentre os quais destacamos Kutner et al. (2004) para uma primeira abordagem.

Vários pacotes computacionais dispõem de códigos que permitem ajustar esses modelos. Em particular, mencionamos a função `lm()` do R. Na Seção

¹Uma notação mais elucidativa para (6.1) é $y_i|x_i = \alpha + \beta x_i + e_i$, cuja leitura como “valor observado y_i da variável resposta Y para um dado valor da variável x_i da variável explicativa X ” deixa claro que o interesse da análise está centrado na distribuição de Y e não naquela de X .

6.2, discutiremos, com algum pormenor, o ajuste de modelos da forma (6.1) e depois indicaremos como o caso geral de uma regressão linear múltipla (com mais de duas variáveis) pode ser abordado.

6.2 Regressão Linear Simples

Consideramos o modelo (6.1), supondo que os erros e_i são não correlacionados, tenham média 0 e variância σ^2 . Nossa primeira objetivo é estimar os parâmetros α e β . Um possível método para obtenção dos estimadores consiste em determinar $\hat{\alpha}$ e $\hat{\beta}$ que minimizem a distância entre cada observação a a reta definida por $E(y_i) = \alpha + \beta x_i$. Com esse objetivo, consideremos a soma dos quadrados dos erros e_i ,

$$Q(\alpha, \beta) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \alpha - \beta x_i)^2. \quad (6.5)$$

Os **estimadores de mínimos quadrados** são obtidos minimizando-se (6.5) com relação a α e β . Com essa finalidade, derivamos $Q(\alpha, \beta)$ em relação a esses parâmetros e obtemos as **equações de estimação** igualando as expressões resultantes a zero. A solução dessas equações são os estimadores de mínimos quadrados,

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad (6.6)$$

e

$$\hat{\alpha} = \bar{y} - \hat{\beta} \bar{x} \quad (6.7)$$

em que $\bar{x} = n^{-1} \sum_{i=1}^n x_i$ e $\bar{y} = n^{-1} \sum_{i=1}^n y_i$. Um estimador não enviesado de σ^2 é

$$S^2 = \frac{1}{n-2} Q(\hat{\alpha}, \hat{\beta}) = \frac{1}{n-2} \sum_{i=1}^n \hat{e}_i^2 = \frac{1}{n-2} \sum_{i=1}^n (y_i - \hat{\alpha} - \hat{\beta} x_i)^2, \quad (6.8)$$

em que onde $Q(\hat{\alpha}, \hat{\beta})$ é a **soma dos quadrados dos resíduos**, abreviadamente, *SQRes*. Note que no denominador de (6.8) temos $n-2$, pois perdemos dois graus de liberdade em função da estimação de dois parâmetros (α e β). Alguns resultados referentes à inferência baseada nesse tipo de modelos são apresentados na Nota de Capítulo 1.

Os valores ajustados, $\hat{y}_i = \hat{\alpha} + \hat{\beta} x_i$, são utilizados para obtenção dos **resíduos**

$$\hat{e}_i = y_i - \hat{y}_i = y_i - (\hat{\alpha} + \hat{\beta} x_i), \quad i = 1, \dots, n.$$

Num contexto inferencial, ou seja, em que os dados correspondem a uma amostra de uma população (geralmente conceitual), os valores dos parâmetros α , β e σ^2 não podem ser conhecidos, a menos que toda a população seja avaliada. Consequentemente, os erros e_i não são conhecidos, mas os resíduos \hat{e}_i podem ser calculados e correspondem a estimativas desses erros.

A proposta de um modelo de regressão linear simples pode ser baseada em argumentos teóricos, como no caso em que dados são coletados para a avaliação do espaço percorrido num movimento uniforme ($s = s_0 + vt$) ou num gráfico de dispersão entre a variável resposta e a variável explicativa como aquele da Figura 6.1 em que parece razoável representar a variação esperada da distância com a idade por meio de uma reta.

Uma vez ajustado o modelo, convém avaliar a qualidade do ajuste e um dos indicadores mais utilizados para essa finalidade é o **coeficiente de determinação** definido como

$$R^2 = \frac{SQTot - SQRes}{SQTot} = \frac{SQReg}{SQTot} = 1 - \frac{SQRes}{SQTot}$$

em que a soma de quadrados total é $SQTot = \sum_{i=1}^n (y_i - \bar{y})^2$, a soma de quadrados dos resíduos é $SQRes = \sum_{i=1}^n (y_i - \hat{y}_i)^2$ e a soma de quadrados da regressão é $SQReg = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$. Para mais detalhes, ver a Nota de Capítulo 3. Em essência, esse coeficiente mede a porcentagem da variação total dos valores da variável resposta (y_i) em relação à sua média (\bar{y}) explicada pelo modelo de regressão.

O coeficiente de determinação deve ser acompanhado de outras ferramentas para a avaliação do ajuste, pois não está direcionado para identificar se todas as suposições do modelo são compatíveis com os dados sob investigação. Em particular, mencionamos os gráficos de resíduos, gráficos de Cook e gráficos de influência local. Tratamos dos dois primeiros na sequência e remetemos os últimos para as Notas de Capítulo 4 e 5.

Resultados do ajuste do modelo de regressão linear simples $distancia_i = \alpha + \beta(idade_i - 18) + e_i$, $i = 1, \dots, n$ aos dados da Tabela 6.1 por meio da função `lm()` do pacote MASS estão apresentados abaixo. Note que a variável preditora está especificada como `id = idade - 18`.

```
> lm(formula = distancia ~ id, data = distancia)
Residuals:
    Min      1Q  Median      3Q     Max 
-26.041 -13.529   2.388  11.478  35.994 
Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 174.2296    5.5686 31.288 < 2e-16 ***
id          -1.0039    0.1416 -7.092 1.03e-07 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1 

Residual standard error: 16.6 on 28 degrees of freedom
Multiple R-squared:  0.6424, Adjusted R-squared:  0.6296 
F-statistic: 50.29 on 1 and 28 DF,  p-value: 1.026e-07
```

As estimativas dos parâmetros α (distância esperada para motoristas com 18 anos) e β (diminuição esperada da distância para cada ano adicional)

na idade) com erros padrões entre parênteses são, respectivamente, $\hat{\alpha} = 174,2$ (5,6) e $\hat{\beta} = -1,004$ (0,14).

A estimativa do desvio padrão dos erros (σ) é $S = 16,6$, com $30 - 2 = 28$ graus de liberdade e o coeficiente de determinação é $R^2 = 0,63$. Se usássemos o modelo (6.1), a estimativa de α seria 192,3 (7,8) e a de β seria a mesma.

Uma das ferramentas mais úteis para a avaliação da qualidade do ajuste de modelos de regressão é o **gráfico de resíduos** em que os resíduos (\hat{e}_i) são dispostos no eixo das ordenadas e os correspondentes valores da variável explicativa (x_i), no eixo das abscissas.

O gráfico de resíduos correspondente ao modelo ajustado aos dados da Tabela 6.1 está apresentado na Figura 6.2.

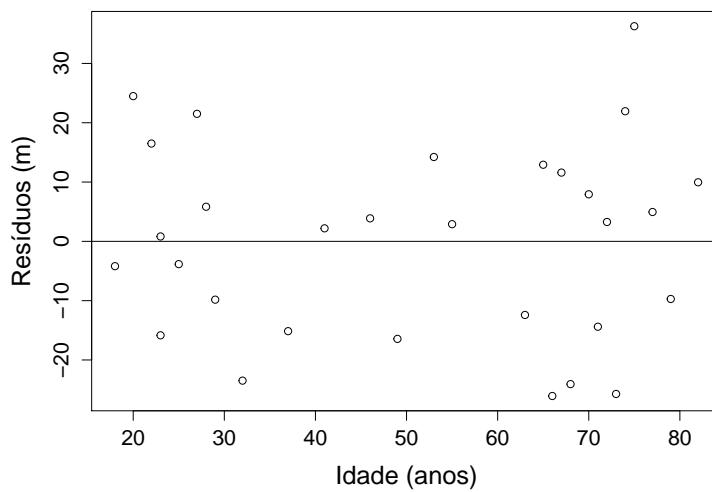


Figura 6.2: Gráfico de resíduos para o ajuste do modelo de regressão linear simples aos dados da Tabela 6.1.

Para facilitar a visualização em relação à dispersão dos resíduos e para efeito de comparação entre ajustes de modelos em que as variáveis respostas têm unidades de medida diferentes, convém padronizá-los, *i.e.*, dividi-los pelo respectivo desvio padrão para que tenham variância igual a 1. Como os resíduos (ao contrário dos erros) são correlacionados, pode-se mostrar que

$$DP(\hat{e}_i) = \sigma \sqrt{1 - h_{ii}} \text{ com } h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2},$$

de forma que os **resíduos padronizados**, também chamados de **resíduos studentizados** são definidos por

$$\hat{e}_i^* = \hat{e}_i / (S \sqrt{1 - h_{ii}}). \quad (6.9)$$

Os resíduos padronizados são adimensionais e têm variância igual a 1, independentemente da variância da variável resposta (σ^2). Além disso, para

erros com distribuição Normal, cerca de 99% dos resíduos padronizados têm valor entre -3 e +3.

O gráfico de resíduos padronizados correspondente àquele da Figura 6.2 está apresentado na Figura 6.3.

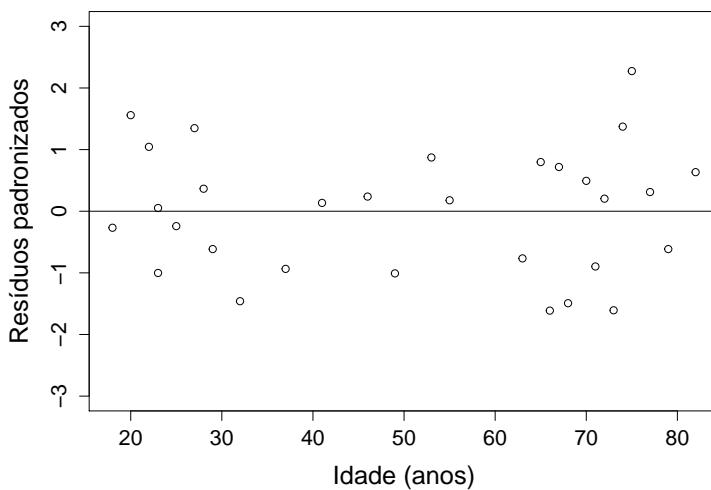


Figura 6.3: Gráfico de resíduos padronizados para o ajuste do modelo de regressão linear simples aos dados da Tabela 6.1.

Na Figura 6.3, nota-se que resíduos positivos e negativos estão distribuídos sem algum padrão sistemático e que sua variabilidade é razoavelmente uniforme ao longo dos diferentes valores da variável explicativa, sugerindo que relativamente à suposição de **homocedasticidade** (variância constante) o modelo adotado é (pelo menos, aproximadamente) adequado.

Exemplo 6.2: Os gráficos de dispersão e de resíduos padronizados correspondentes ao ajuste do modelo $CO_i = \alpha + \beta \text{tempo}_i + e_i$, $i = 1, \dots, n$ em que CO representa a concentração atmosférica de monóxido de carbono no dia i contado a partir de 1 de janeiro de 1991 (arquivo [poluicao](#)) estão apresentados nas Figuras 6.4 e 6.5. Ambos sugerem uma deficiência no ajuste: no primeiro, observa-se uma curvatura não compatível com o ajuste de uma reta; no segundo, nota-se um padrão na distribuição dos resíduos, que são positivos nos primeiros dias, negativos em seguida e espalhados ao final das observações diárias. Além disso, a dispersão dos resíduos varia com o tempo.

A saída da aplicação da função `lm()` está abaixo. Na fórmula, t indica o dia, $t = 1, \dots, 120$.

```

> lm(formula = co ~ t, data = poluicao)
Residuals:
    Min      1Q  Median      3Q     Max 
-3.7655 -0.9157 -0.1788  0.6613  4.5104 

Coefficients:
                Estimate Std. Error t value Pr(>|t|)    
(Intercept)  1.000e+00  1.000e-01  1.000e+00  1.000e+00    
t            -1.000e-01  1.000e-01 -1.000e-01  1.000e-01    
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.000e-01 on 9 degrees of freedom

```

```
(Intercept) 6.264608   0.254847  24.582 < 2e-16 ***
t          0.019827   0.003656   5.424 3.15e-07 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.387 on 118 degrees of freedom
Multiple R-squared:  0.1996, Adjusted R-squared:  0.1928
F-statistic: 29.42 on 1 and 118 DF,  p-value: 3.148e-07
```

O coeficiente de determinação correspondente é 0,19, sugerindo que o modelo de regressão explica apenas uma pequena parcela da variabilidade dos dados. Um modelo (linear) de regressão polinomial alternativo em que termos quadrático e cúbico são incluídos, *i.e.*, $CO_i = \alpha + \beta tempo_i + \gamma tempo_i^2 + \delta tempo_i^3 + e_i$, $i = 1, \dots, n$ tem um melhor ajuste, como se pode notar tanto pelo acréscimo no coeficiente de determinação cujo valor é 0,35 para o modelo alternativo quanto pelo gráfico de resíduos padronizados disposto na Figura 6.6. Detalhes sobre o ajuste de modelos de regressão polinomial como esse, serão apresentados na Seção 6.3.

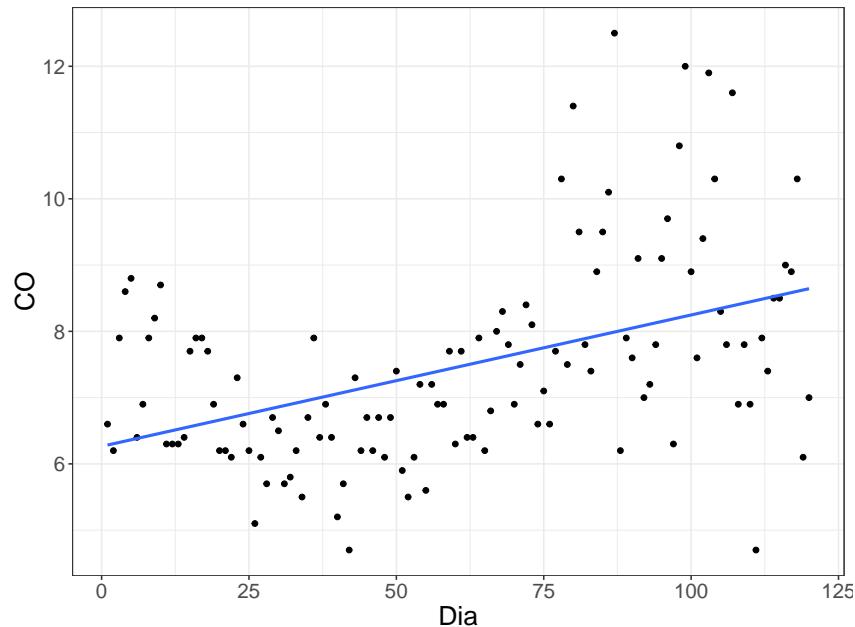


Figura 6.4: Gráfico de dispersão para os dados de monóxido de carbono.

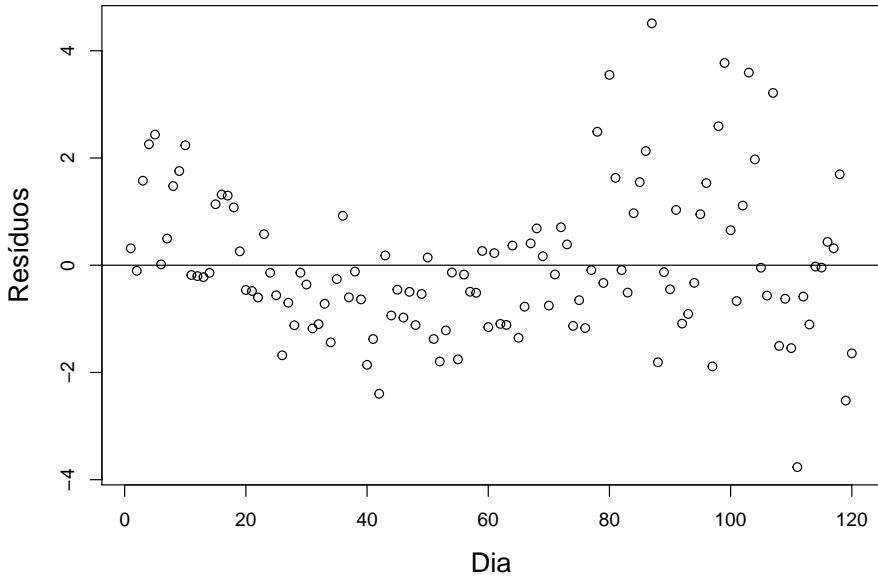


Figura 6.5: Gráfico de resíduos padronizados para o ajuste do modelo de regressão linear simples aos dados da concentração de CO.

Ainda assim, esse modelo polinomial não é o mais adequado em virtude da presença de **heterocedasticidade**, ou seja, de variâncias que não são constantes ao longo do tempo. Há modelos que incorporam heterogeneidade de variâncias, mas estão fora do objetivo deste texto. Para detalhes, pode-se consultar Kutner et al. (2004), por exemplo.

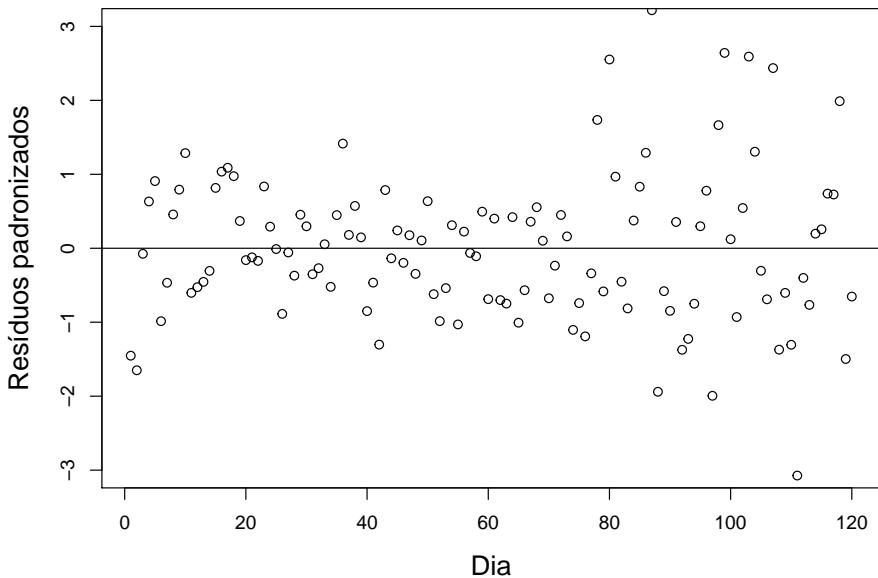


Figura 6.6: Gráfico de resíduos padronizados para o ajuste do modelo de regressão linear polinomial aos dados da concentração de CO.

Exemplo 6.3: Os dados da Tabela 6.2 são provenientes da mensuração da velocidade do vento no aeroporto de Philadelphia (EUA), sempre à uma hora da manhã, para os primeiros 15 dias de dezembro de 1974 (Graedel e Kleiner, 1985). Esses dados estão disponíveis no arquivo `vento`.

Tabela 6.2: Velocidade do vento no aeroporto de Philadelphia (v_t), com os resíduos obtidos do ajuste de modelos resistentes

t	v_t	$\hat{r}_t^{(0)}$	$\hat{r}_t^{(1)}$
1	22,2	1,56	-1,11
2	61,1	41,38	38,90
3	13,0	-5,80	-8,10
4	27,8	9,92	7,81
5	22,2	5,24	3,31
6	7,4	-8,64	-10,39
7	7,4	-7,72	-9,28
8	7,4	-6,80	-8,18
9	20,4	7,12	5,93
10	20,4	8,04	7,03
11	20,4	8,96	8,13
12	11,1	0,58	-0,06
13	13,0	3,40	2,94
14	7,4	-1,28	-1,55
15	14,8	7,04	6,95

O diagrama de dispersão dos dados no qual está indicada a reta obtida pelo ajuste de um modelo linear simples, nomeadamente,

$$\hat{v}_t = 30,034 - 1,454t, \quad t = 1, \dots, 15$$

e o correspondente gráfico de resíduos padronizados estão apresentados nas Figuras 6.7 e 6.8. Nesses gráficos pode-se notar que tanto a observação associada ao segundo dia ($t = 2$, com $v_t = 61,1$) quanto o resíduo correspondente destoam dos demais, gerando estimativas dos coeficientes da reta diferentes daqueles que se espera. Essa é uma **observação discrepante** (*outlier*). Na Nota de Capítulo 8, apresentamos um modelo alternativo com a finalidade de obter estimativas “resistentes” (também chamadas de “robustas”) a pontos desse tipo.

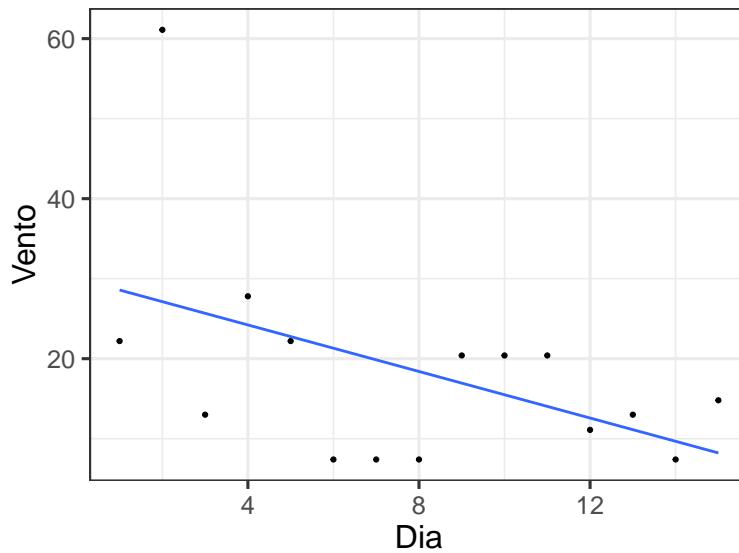


Figura 6.7: Gráfico de dispersão para os dados da Tabela 6.2 com reta de mínimos quadrados sobreposta.

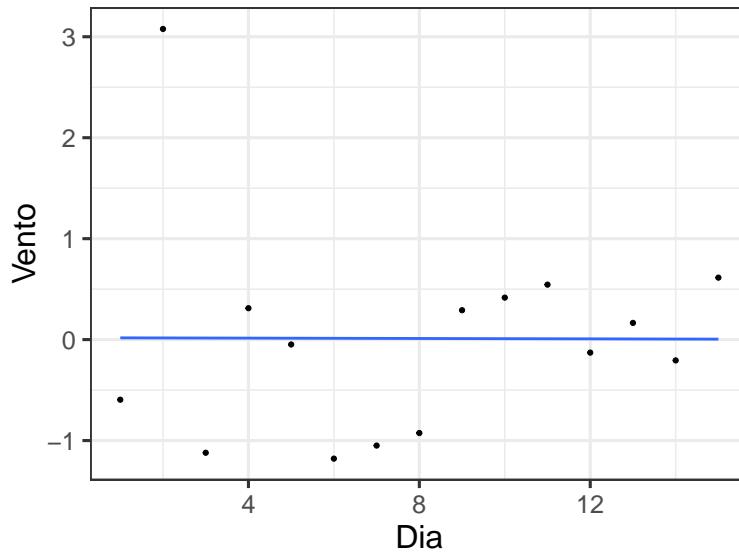


Figura 6.8: Gráfico de resíduos padronizados para o ajuste do modelo de regressão linear aos dados da Tabela 6.2.

Exemplo 6.4: Consideremos agora os dados (hipotéticos) dispostos na Tabela 6.3 aos quais ajustamos um modelo de regressão linear simples.

O gráfico de dispersão (com os dados representados por círculos e com a reta de regressão representada pela linha sólida) e o correspondente gráfico de resíduos padronizados estão apresentados nas Figuras 6.9 e 6.10.

Tabela 6.3: Dados hipotéticos

X	10	8	13	9	11	14	6	4	12	7	5	18
Y	8,04	6,95	7,58	8,81	8,33	9,96	7,24	4,26	10,84	4,82	5,68	6,31

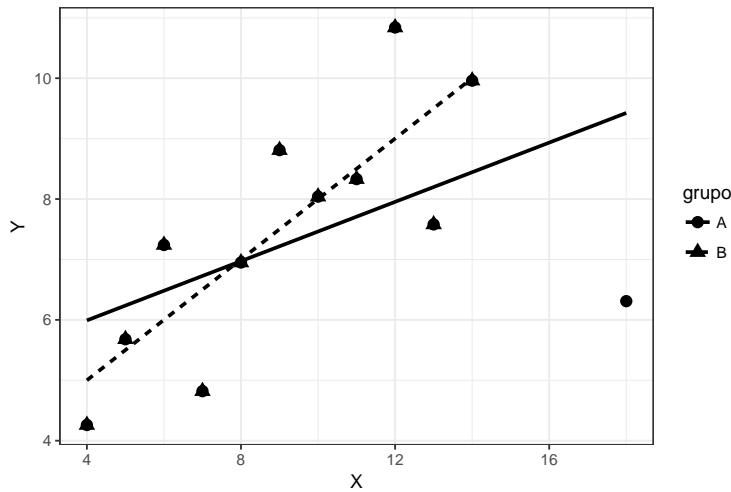


Figura 6.9: Gráfico de dispersão (com retas de regressão sobrepostas) para os dados da Tabela 6.3; curva sólida para dados completos e curva interrompida para dados com ponto influente eliminado.

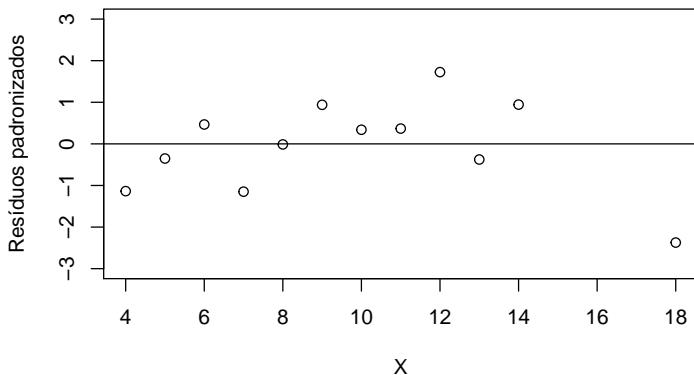


Figura 6.10: Gráfico de resíduos padronizados para o ajuste do modelo de regressão linear aos dados da Tabela 6.3.

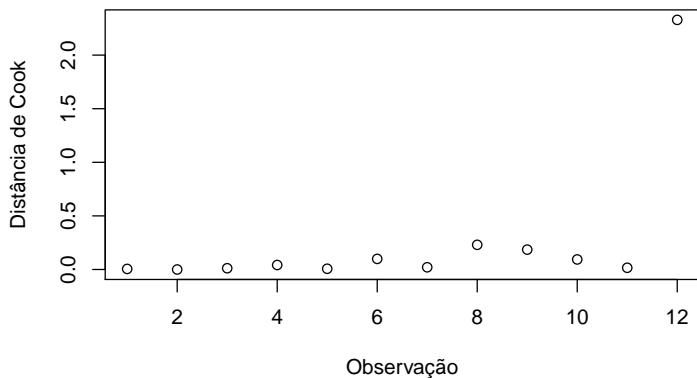


Figura 6.11: Gráfico de Cook correspondente ao ajuste do modelo de regressão linear aos dados da Tabela 6.3.

Os dois gráficos contêm indicações de que o ponto associado aos valores ($X = 18, Y = 6.31$) pode ser um ponto discrepante. Isso fica mais evidente quando consideramos outra ferramenta diagnóstica conhecida como **gráfico de Cook** apresentado na Figura 6.11. Esse gráfico é baseado na chamada **distância de Cook** (ver Nota de Capítulo 4) que serve para indicar as observações que têm grande influência em alguma característica do ajuste do modelo. Em particular, salienta os pontos [chamados de **pontos influentes** ou **pontos alavancas** (*high leverage points*)] que podem alterar de forma relevante as estimativas dos parâmetros. Em geral, como no caso estudado aqui, esses pontos apresentam valores das respectivas abscissas afastadas daquelas dos demais pontos do conjunto de dados. Neste exemplo, a eliminação do ponto mencionado altera as estimativas do intercepto [de 5,01 (1,37) para 3,00 (1,12)] e da inclinação [de 0,25 (0,13) para 0,50 (0,12)] da reta ajustada. A reta correspondente ao ajuste quando o ponto ($X = 18, Y = 6.31$) é eliminado do conjunto de dados está representada na Figura 6.9 pela curva interrompida.

Nos casos em que se supõe que os erros têm distribuição Normal, pode-se utilizar gráficos QQ com o objetivo de avaliar se os dados são compatíveis com essa suposição. É importante lembrar que esses gráficos QQ devem ser construídos com os quantis amostrais baseados nos resíduos e não com as observações da variável resposta, pois apesar de suas distribuições também serem normais, suas médias variam com os valores associados da variável explicativa, ou seja, a média da variável resposta correspondente a y_i é $\alpha + \beta x_i$. Convém observar que sob normalidade dos erros, os resíduos padronizados seguem uma distribuição t com $n - 2$ graus de liberdade e é dessa distribuição que se devem obter os quantis teóricos para a construção do gráfico QQ. Também deve-se lembrar que para valores de n maiores que 20 ou 30, os quantis da distribuição t se aproximam daqueles da distribuição Normal, tornando-as intercambiáveis para a construção do correspondente gráfico

QQ.

Gráficos QQ (com bandas de confiança) correspondentes aos ajustes de modelos de regressão linear simples aos dados das Tabelas 6.1 e 6.3 (com e sem a eliminação da observação influente) estão respectivamente apresentados nas Figuras 6.12, 6.13 e 6.14.

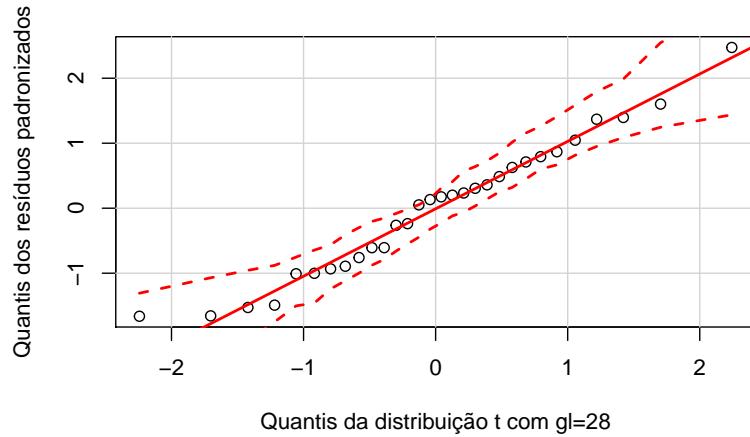


Figura 6.12: Gráfico QQ correspondente ajuste do modelo de regressão linear aos dados da Tabela 6.1.

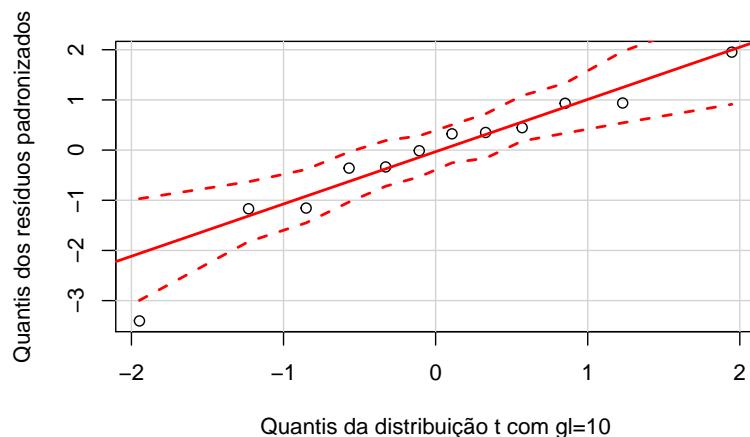


Figura 6.13: Gráfico QQ correspondente ajuste do modelo de regressão linear aos dados da Tabela 6.3 (com todas as observações).

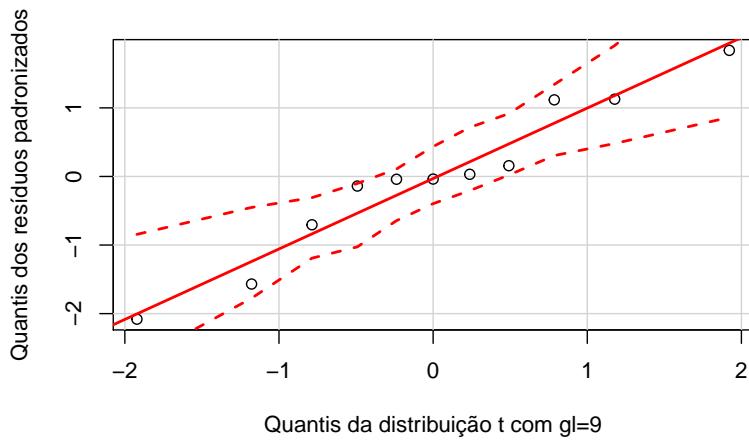


Figura 6.14: Gráfico QQ correspondente ajuste do modelo de regressão linear aos dados da Tabela 6.3 (sem a observação influente).

Nos três casos, não há evidências fortes contra a suposição de normalidade dos erros (apesar do ponto fora da banda de confiança salientado na Figura 6.13). Em geral, especialmente com poucos dados, é difícil observar casos em que essa suposição não parece razoável.

Convém lembrar que se o objetivo for avaliar a inclinação da reta de regressão (β), ou seja, avaliar a taxa com que a resposta esperada muda por unidade de variação da variável explicativa, essa suposição de normalidade da variável resposta tem efeito marginal na distribuição do estimador de mínimos quadrados desse parâmetro ($\hat{\beta}$). Pode-se mostrar que esse estimador segue uma distribuição **aproximadamente** Normal quando o tamanho da amostra é suficientemente grande, por exemplo, 30 ou mais, mesmo quando a suposição de normalidade para a variável resposta não for verdadeira. Mais detalhes e uma referência estão apresentados na Nota de Capítulo 1.

Em geral, a suposição de que os erros do modelo linear são não correlacionados deve ser questionada com base no procedimento de coleta de dados. Como ilustração, consideramos dois exemplos nos quais essa característica justifica a dúvida. O primeiro exemplo é um caso simples dos problemas abordados pelas técnicas de análise de séries cronológicas; o segundo exemplo é o caso típico de análise de **dados longitudinais** e será apresentado na Seção 6.4. Ambos são apresentados aqui com a finalidade de mostrar como as técnicas de análise de regressão podem ser empregadas para analisar modelos mais gerais do que aqueles governados pelo paradigma de Gauss-Markov (ver Nota de Capítulo 1).

Exemplo 6.5: Na Tabela 6.4 apresentamos valores do peso de um bezerro observado a cada duas semanas após o nascimento com o objetivo de avaliar seu crescimento nesse período. O gráfico de dispersão correspondente está

disposto na Figura 6.15.

Tabela 6.4: Peso (kg) de um bezerro nas primeiras 26 semanas após o nascimento

Semana	Peso	Semana	Peso
0	32,0	14	81,1
2	35,5	16	84,6
4	39,2	18	89,8
6	43,7	20	97,4
8	51,8	22	111,0
10	63,4	24	120,2
12	76,1	26	134,2

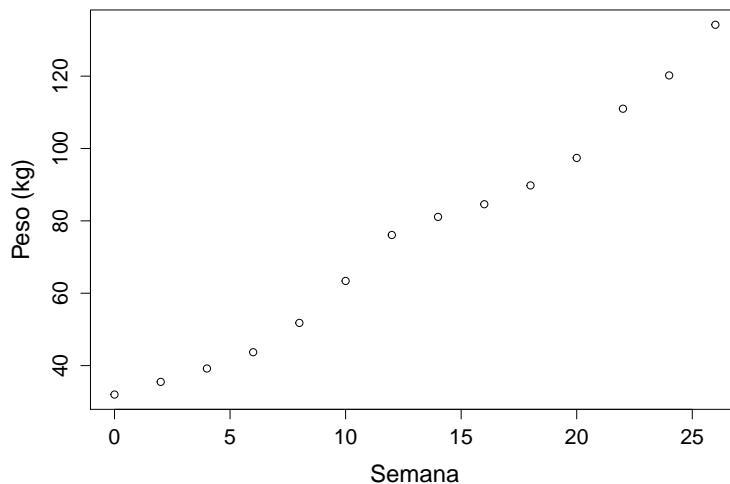


Figura 6.15: Gráfico de dispersão para os dados da Tabela 6.4

Tendo em vista o gráfico de dispersão apresentado na Figura 6.15, um possível modelo seria

$$y_t = \alpha + \beta t + \gamma t^2 + e_t, \quad (6.10)$$

$i = 1, \dots, 14$ em que y_t representa o peso do bezerro no instante t , α denota o valor esperado de seu peso ao nascer, β e γ representam os coeficientes dos termos linear e quadrático da curva que rege a variação temporal do peso esperado no intervalo de tempo estudado e e_t denota um erro aleatório com média 0 e variância σ^2 . Utilizamos t como índice para salientar que as observações são colhidas sequencialmente ao longo do tempo.

O coeficiente de determinação ajustado, $R_{aj}^2 = 0,987$ indica que o ajuste (por mínimos quadrados) do modelo com $\hat{\alpha} = 29,9$ (2,6), $\hat{\beta} = 2,7$ (2,5) e $\hat{\gamma} = 0,05$ (0,02) é excelente (sob essa ótica, obviamente). Por outro lado, o gráfico de resíduos apresentado na Figura 6.16 mostra sequências de

resíduos positivos seguidas de sequências de resíduos negativos, sugerindo uma possível correlação positiva entre eles (autocorrelação).

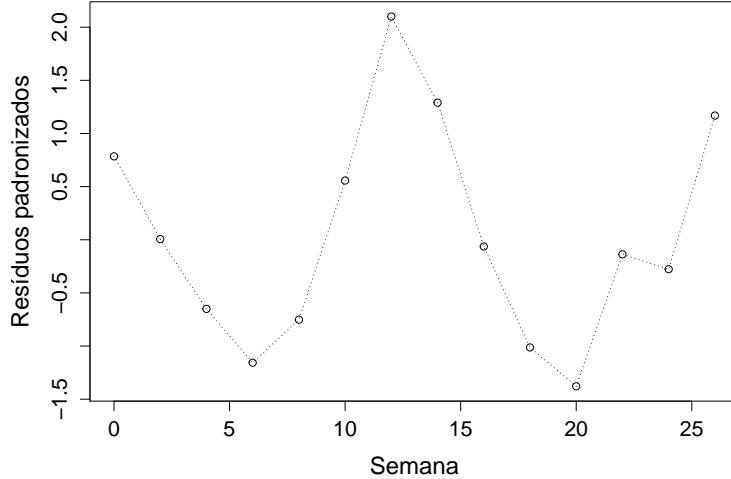


Figura 6.16: Resíduos studentizados obtidos do ajuste do modelo (6.10)

Uma maneira de contornar esse problema, é modificar os componentes aleatórios do modelo para incorporar essa possível autocorrelação nos erros. Nesse contexto, podemos considerar o modelo (6.10) com

$$e_t = \rho e_{t-1} + u_t, \quad t = 1, \dots, n \quad (6.11)$$

em que $u_t \sim N(0, \sigma^2)$, $t = 1, \dots, n$, independentes e e_0 é uma constante (geralmente igual a zero). Essas suposições implicam que $\text{Var}(e_t) = \sigma^2/(1 - \rho^2)$ e que $\text{Cov}(e_t, e_{t-s}) = \rho^s[\sigma^2/(1 - \rho^2)]$.

Para testar a hipótese de que os erros são não correlacionados pode-se utilizar a **estatística de Durbin-Watson**:

$$D = \sum_{t=2}^n (\hat{e}_t - \hat{e}_{t-1})^2 / \sum_{t=1}^n \hat{e}_t^2, \quad (6.12)$$

em que \hat{e}_t , $t = 1, \dots, n$ são os resíduos obtidos do ajuste do modelo (6.10) por mínimos quadrados. Expandindo (6.12) obtemos

$$\begin{aligned} D &= \frac{\sum_{t=2}^n \hat{e}_t^2}{\sum_{t=1}^n \hat{e}_t^2} + \frac{\sum_{t=2}^n \hat{e}_{t-1}^2}{\sum_{t=1}^n \hat{e}_t^2} - 2 \frac{\sum_{t=2}^n \hat{e}_t \hat{e}_{t-1}}{\sum_{t=1}^n \hat{e}_t^2} \\ &\approx 2 - 2 \frac{\sum_{t=2}^n \hat{e}_t \hat{e}_{t-1}}{\sum_{t=1}^n \hat{e}_t^2}, \end{aligned} \quad (6.13)$$

Se os resíduos não forem correlacionados, então $\sum_{t=2}^n \hat{e}_t \hat{e}_{t-1} \approx 0$ e consequentemente, $D \approx 2$; se, por outro lado, os resíduos forem altamente

correlacionados, esperamos que $\sum_{t=2}^n \hat{e}_t \hat{e}_{t-1} \approx \sum_{t=2}^n \hat{e}_t^2$ e então $D \approx 0$; finalmente, se os resíduos tiverem uma grande correlação negativa, esperamos que $\sum_{t=2}^n \hat{e}_t \hat{e}_{t-1} \approx -\sum_{t=2}^n \hat{e}_t^2$ e nesse caso, $D \approx 4$. Durbin and Watson (1950, 1951, 1971) produziram tabelas da distribuição da estatística D que podem ser utilizados para avaliar a suposição de que os erros não são correlacionados.

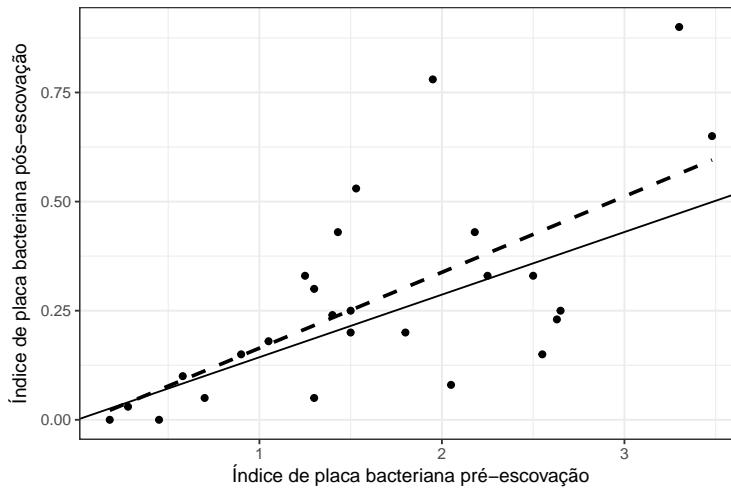
O valor da estatística de Durbin-Watson para os dados do Exemplo 6.5 sob o modelo (6.10) é $D = 0,91$ ($p < 0,0001$), sugerindo um alto grau de autocorrelação dos resíduos. Uma estimativa do coeficiente de autocorrelação ρ é 0,50. Nesse caso, o modelo (6.10) - (6.11) poderá ser ajustado pelo **método de mínimos quadrados generalizados** ou por métodos de **Séries Temporais**.

Exemplo 6.6: Os dados dispostos na Tabela 6.5 são extraídos de um estudo conduzido na Faculdade de Odontologia da Universidade de São Paulo e correspondem a medidas de um índice de placa bacteriana obtidas de 26 crianças em idade pré-escolar, antes e depois do uso de uma escova de dentes experimental (Hugger) e de uma escova convencional (dados disponíveis no arquivo `placa`). O objetivo do estudo era comparar os dois tipos de escovas com respeito à eficácia na remoção da placa bacteriana. Os dados do estudo foram analisados por Singer and Andrade (1997) e são apresentados aqui apenas com intuito didático para mostrar a flexibilidade dos modelos de regressão. Analisamos somente os dados referentes à escova experimental e não incluímos a variável sexo dado que a análise completa não indicou diferenças entre meninas e meninos com relação à remoção da placa bacteriana.

Tabela 6.5: Índices de placa bacteriana antes e depois da escovação com uma escova de dentes experimental

ident	antes	depois	ident	antes	depois
1	2,18	0,43	14	1,40	0,24
2	2,05	0,08	15	0,90	0,15
3	1,05	0,18	16	0,58	0,10
4	1,95	0,78	17	2,50	0,33
5	0,28	0,03	18	2,25	0,33
6	2,63	0,23	19	1,53	0,53
7	1,50	0,20	20	1,43	0,43
8	0,45	0,00	21	3,48	0,65
9	0,70	0,05	22	1,80	0,20
10	1,30	0,30	23	1,50	0,25
11	1,25	0,33	24	2,55	0,15
12	0,18	0,00	25	1,30	0,05
13	3,30	0,90	26	2,65	0,25

Embora as duas variáveis, índices de placa bacteriana antes e depois da escovação correspondam essencialmente a variáveis respostas, é possível



Note que y/x denota a taxa de redução do índice de placa e $E(y)/x$ denota a taxa esperada de redução do índice de placa. Por (6.14), temos

$$\frac{E(y_i)}{x_i} = \frac{\beta x_i^\gamma E(e_i)}{x_i} = \beta x_i^{\gamma-1} E(e_i),$$

lembrando que $E(e_i) > 0$. Logo, se $\gamma = 1$, essa taxa de redução esperada é constante; se $\gamma > 1$ a taxa de redução esperada aumenta e se $\gamma < 1$, ela diminui com o aumento do índice de placa x_i . Por outro lado, quanto menor for β (por exemplo, se $0 < \beta < 1$), maior será a redução do índice de placa.

Na Figura 6.18 apresentamos o histograma de X e o respectivo *boxplot*, mostrando que a distribuição do índice de placa pré escovação é moderadamente assimétrica à direita. Embora não faça sentido construir o histograma e o *boxplot* correspondente ao índice de placa bacteriana pós escovação Y (pois sob o modelo, sua média depende de X), é razoável supor que a distribuição condicional de Y dado X também seja assimétrica.

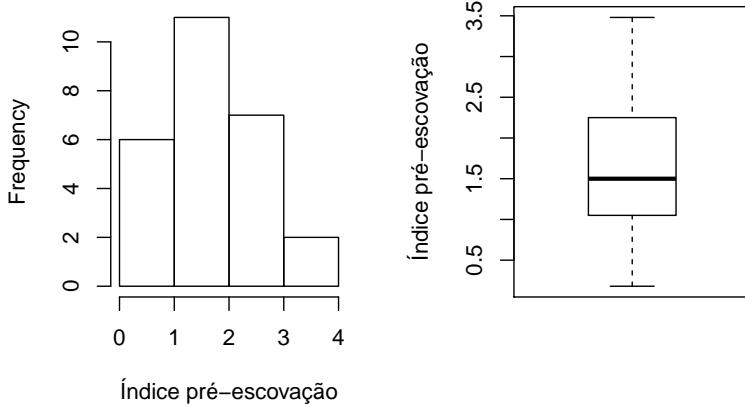


Figura 6.18: Histograma e *boxplot* para o índice de placa bacteriana pré escovação.

Esses resultados sugerem que uma transformação da forma $z^{(\theta)}$, com $0 \leq \theta < 1$ pode ser adequada para tornar os dados mais simétricos e estabilizar a variância (consulte a Seção 3.8 para detalhes sobre transformações de variáveis). Podemos considerar, por exemplo, os casos $\theta = 0$, ou seja, a transformação logarítmica, $\theta = 1/3$ (raiz cúbica) ou $\theta = 1/2$ (raiz quadrada). A transformação logarítmica é mais conveniente, pois permite a **linearização** do modelo, deixando-o no formato de um modelo de regressão linear simples para o qual dispomos de técnicas padrão de ajuste. Esse modelo, no entanto, exige que eliminemos os dois pares para os quais $Y = 0$, reduzindo para 24 o número de observações. O modelo resultante obtido com a transformação logarítmica é

$$y_i^* = \beta^* + \gamma x_i^* + e_i^*, \quad i = 1, \dots, 24, \quad (6.15)$$

em que $y_i^* = \log(y_i)$, $x_i^* = \log(x_i)$, parâmetros γ , $\beta^* = \log\beta$ e erros $e_i^* = \log(e_i)$, que supomos ter média 0 e variância σ^2 . Se, adicionalmente, supusermos que e_i^* tem distribuição Normal, os erros originais, e_i terão distribuição Log-normal, definida apenas para valores positivos, o que é compatível com as suposições adotadas para o modelo (6.14).

Na Figura 6.19 apresentamos o diagrama de dispersão entre $\log x_i$ e $\log y_i$ sugerindo que a transformação induz uma menor dispersão dos dados, embora ainda haja um maior acúmulo de pontos para valores “grandes” de X .

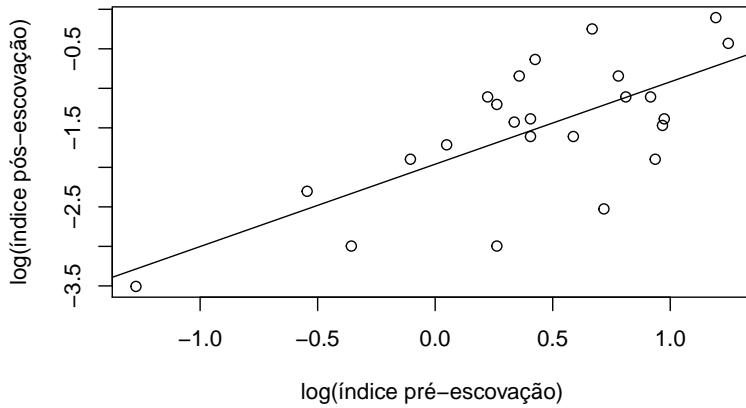


Figura 6.19: Gráfico de dispersão para os dados da Tabela 6.5 sob transformação logarítmica.

Usando o método de mínimos quadrados, a reta ajustada é

$$\hat{y}_i^* = -1,960 + 1,042x_i^*. \quad (6.16)$$

que corresponde a

$$\hat{y}_i = 0,141x_i^{1,042}, \quad (6.17)$$

na concepção original, já que $\hat{\beta} = \exp(\hat{\beta}^*) = \exp(-1,960) = 0.141$. Note que $\hat{\beta} < 1$ e $\hat{\gamma}$ tem valor muito próximo de 1. Podemos testar a hipótese $\gamma = 1$, para avaliar se esse resultado traz evidência suficiente para concluir que a taxa de redução do índice de placa bacteriana na população para a qual se deseja fazer inferência é constante. Para testar $H_0 : \gamma = 1$ contra a alternativa $H_A : \gamma > 1$ usamos a estatística

$$t = \frac{\hat{\gamma} - 1}{S/\sqrt{\sum(x_i^* - \bar{x}^*)^2}}$$

cuja distribuição sob H_0 é t com $n - 2$ graus de liberdade (veja a Seção 5.2 e Bussab e Morettin, 2017). O valor-p correspondente ao valor observado da estatística t é

$$p = P(\hat{\gamma} > 1,042) = P \left[t_{22} > \frac{1,042 - 1}{S} \sqrt{\sum(x_i^* - \bar{x}^*)^2} \right].$$

Como $\sum_i x_i^* = 10,246$, $\bar{x}^* = 0,427$, $\sum_i y_i^* = -36,361$, $\bar{y}^* = -1,515$, $\sum_i (x_i^* - \bar{x}^*)^2 = \sum_i (x_i^*)^2 - 24(\bar{x}^*)^2 = 12,149 - 24 \times 0,182 = 7,773$, obtemos $S^2 = 7,773/22 = 0,353$ e $S = 0,594$. Então

$$p = P[t_{22} > 0,42 \times 2,788/0,594] = P[t_{22} > 1,971] \approx 0,06$$

indicando que não há evidências fortes para rejeitar H_0 . Como consequência, podemos dizer que a taxa esperada de redução da placa é

$$\text{E}(y_i)/x_i = \beta \text{E}(e_i),$$

que é constante. Como concluímos que $\gamma = 1$, o modelo linear nos logaritmos das variáveis (6.15) fica reduzido a

$$y_i^* = \beta^* + x_i^* + e_i^*, \quad (6.18)$$

e para estimar β^* basta considerar a soma de quadrados dos erros

$$Q(\beta^*) = \sum_i (y_i^* - \beta^* - x_i^*)^2,$$

derivá-la em relação a β^* e obter o estimador de mínimos quadrados de β^* como

$$\widehat{\beta}^* = \bar{y}^* - \bar{x}^*.$$

No nosso caso, $\widehat{\beta}^* = -1,515 - 0,427 = -1,942$, e o modelo ajustado é

$$\widehat{y}_i^* = -1,942 + x_i^* \quad (6.19)$$

que em termos das variáveis originais corresponde a

$$\widehat{y}_i = 0,1434x_i, \quad i = 1, \dots, 24. \quad (6.20)$$

Esse modelo é representado por uma reta que passa pela origem e está representada por meio de uma linha sólida na Figura 6.17.

Os resíduos dos modelos (6.14) e (6.15) estão representados nas Figuras 6.20 e 6.21, respectivamente. Esses gráficos sugerem que os resíduos dos dois modelos estão aleatoriamente distribuídos em torno de zero, mas não são totalmente compatíveis com a distribuição adotada, pois sua variabilidade não é constante. Para uma análise do conjunto de dados do qual este exemplo foi extraído e em que a suposição de heterocedasticidade é levada em conta, o leitor deve consultar Singer and Andrade (1997).

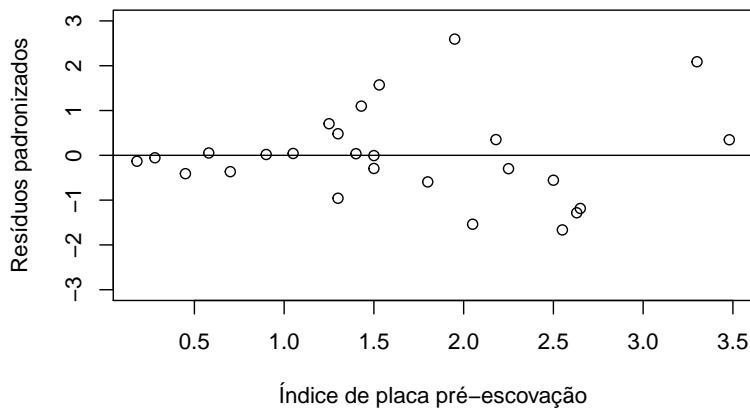


Figura 6.20: Gráfico de resíduos padronizados para o ajuste do modelo de regressão linear aos dados da Tabela 6.5.

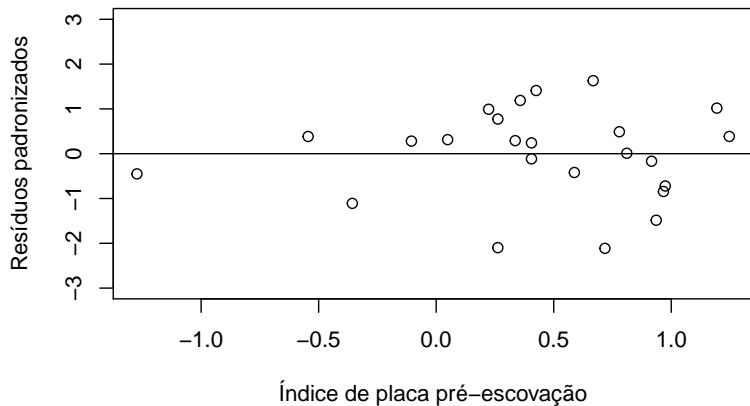


Figura 6.21: Gráfico de resíduos padronizados para o ajuste do modelo de regressão linear aos dados logaritmizados da Tabela 6.5.

6.3 Regressão Linear Múltipla

Com p variáveis explicativas X_1, \dots, X_p e uma variável resposta Y , o **modelo de regressão linear múltipla** é expresso como

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip} + e_i, \quad i = 1, \dots, n. \quad (6.21)$$

O coeficiente β_0 é o chamado **intercepto** e a variável explicativa associada a ele, x_{i0} , tem valor constante igual a 1. Para completar a especificação do modelo, supõe-se que os erros e_i são não correlacionados, tenham média zero e variância comum (desconhecida) σ^2 .

Se quisermos testar hipóteses a respeito dos coeficientes do modelo ou construir intervalos de confiança para eles por meio de estatísticas com distribuições exatas, a suposição de que a distribuição de frequências dos erros é Normal deve ser adicionada. O modelo (6.21) tem $p + 2$ parâmetros desconhecidos, a saber, $\beta_0, \beta_1 \dots, \beta_p$ e σ^2 , que precisam ser estimados com base nos dados observados.

Definindo $x_{i0} = 1$, $i = 1, \dots, n$, podemos escrever (6.21) na forma

$$y_i = \sum_{j=0}^p \beta_j x_{ij} + e_i, \quad i = 1, \dots, n.$$

Minimizando a soma dos quadrados do erros e_i , *i.e.*,

$$Q(\beta_0, \dots, \beta_p) = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n [y_i - \sum_{j=0}^p \beta_j x_{ij}]^2,$$

em relação a β_0, \dots, β_p obtemos os **estimadores de mínimos quadrados** (EMQ) $\hat{\beta}_j$, $j = 1, \dots, p$, de modo que

$$\hat{y}_i = \sum_{j=0}^p \hat{\beta}_j x_{ij}, \quad i = 1, \dots, n$$

são os **valores estimados** (sob o modelo). Os termos

$$\hat{e}_i = y_i - \hat{y}_i, \quad i = 1, \dots, n \tag{6.22}$$

são os **resíduos**, cuja análise é fundamental para avaliar se modelos da forma (6.21) se ajustam bem aos dados.

Para efeitos computacionais os dados correspondentes a problemas de regressão linear múltipla devem ser dispostos como indicado na Tabela 6.6.

Tabela 6.6: Matriz de dados

Y	X_1	X_2	\dots	X_p
y_1	x_{11}	x_{12}	\dots	x_{1p}
y_2	x_{21}	x_{22}	\dots	x_{2p}
\vdots	\vdots	\vdots		\vdots
y_n	x_{n1}	x_{n2}	\dots	x_{np}

Em geral, a variável correspondente ao intercepto (que é constante e igual a um) não precisa ser incluída na matriz de dados; os pacotes computacionais incluem-na naturalmente no modelo a não ser que se indique o contrário.

Para facilitar o desenvolvimento metodológico, convém expressar o modelo na forma matricial

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}. \tag{6.23}$$

em que $\mathbf{y} = (y_1, \dots, y_n)^\top$ é o vetor cujos elementos são os valores da variável resposta Y , $\mathbf{X} = (\mathbf{1}, \mathbf{x}_1, \dots, \mathbf{x}_p)$ é a matriz cujos elementos são os valores das variáveis explicativas, com $\mathbf{x}_j = (x_{1j}, \dots, x_{nj})^\top$ contendo os valores da variável X_j , $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_p)^\top$ contém os respectivos coeficientes e $\mathbf{e} = (e_1, \dots, e_n)^\top$ é o vetor de **erros aleatórios**.

Exemplo 6.7 : Os dados da Tabela 6.7 (disponíveis no arquivo **esteira** são provenientes de um estudo cujo objetivo é avaliar o efeito do índice de massa corpórea (IMC) e da carga aplicada numa esteira ergométrica no consumo de oxigênio (VO2) numa determinada fase do exercício. Para associar a

Tabela 6.7: VO2, IMC e carga na esteira ergométrica para 28 indivíduos

ident	VO2 (mL/kg/min)	IMC (kg/m ²)	carga (W)	ident	VO2 (mL/kg/min)	IMC (kg/m ²)	carga (W)
1	14,1	24,32	71	15	22,0	22,45	142
2	16,3	27,68	91	16	13,2	30,86	62
3	9,9	23,93	37	17	16,2	25,79	86
4	9,5	17,50	32	18	13,4	33,56	86
5	16,8	24,46	95	19	11,3	22,79	40
6	20,4	26,41	115	20	18,7	25,65	105
7	11,8	24,04	56	21	20,1	24,24	105
8	29,0	20,95	104	22	24,6	21,36	123
9	20,3	19,03	115	23	20,5	24,48	136
10	14,3	27,12	110	24	29,4	23,67	189
11	18,0	22,71	105	25	22,9	21,60	135
12	18,7	20,33	113	26	26,3	25,80	189
13	9,5	25,34	69	27	20,3	23,92	95
14	17,5	29,93	145	28	31,0	24,24	151

distribuição do consumo de oxigênio (Y) com as informações sobre IMC (X_1) e carga na esteira ergométrica (X_2), consideramos o seguinte modelo de regressão linear múltipla:

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + e_i, \quad (6.24)$$

$i = 1, \dots, 28$ com as suposições usuais sobre os erros (média zero, variância constante σ^2 e não correlacionados). Aqui, o parâmetro β_1 representa a variação no VO2 esperada por unidade do IMC para indivíduos com a mesma carga na esteira. O parâmetro β_2 tem interpretação semelhante com a substituição de IMC por carga na esteira e carga na esteira por IMC. Como não temos dados para indivíduos com IMC menor que 17,50 e carga menor que 32, o parâmetro β_0 deve ser interpretado como um fator de ajuste do plano que aproxima a verdadeira função que relaciona o valor esperado da variável resposta com as variáveis explicativas na região em que há dados disponíveis. Se substituíssemos X_1 por $X_1 - 17,50$ e X_2 por $X_2 - 32$, o termo β_0 corresponderia ao VO2 esperado para um indivíduo com IMC = 17,50 submetido a uma carga igual a 32 na esteira ergométrica.

O modelo (6.24) pode ser expresso na forma matricial (6.23) com

$$\mathbf{y} = \begin{bmatrix} 14,1 \\ 16,3 \\ \vdots \\ 31,0 \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & 24,32 & 71 \\ 1 & 27,68 & 91 \\ \vdots & \vdots & \vdots \\ 1 & 24,34 & 151 \end{bmatrix}, \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix}, \quad \mathbf{e} = \begin{bmatrix} e_1 \\ e_2 \\ \vdots \\ e_{28} \end{bmatrix}.$$

Para problemas com diferentes tamanhos de amostra (n) e diferentes números de variáveis explicativas (p), basta alterar o número de elementos do vetor de respostas \mathbf{y} e do vetor de coeficientes $\boldsymbol{\beta}$ e modificar a matriz com os valores das variáveis explicativas, alterando o número de linhas e colunas convenientemente. Note que o modelo de regressão linear simples também pode ser expresso em notação matricial; nesse caso, a matriz \mathbf{X} terá 2 colunas e o vetor $\boldsymbol{\beta}$, dois elementos (α e β). Uma das vantagens da expressão do modelo de regressão linear múltipla em notação matricial é que o método de mínimos quadrados utilizado para estimar o vetor de parâmetros $\boldsymbol{\beta}$ no modelo (6.23) pode ser desenvolvido de maneira universal e corresponde à minimização da forma quadrática

$$Q(\boldsymbol{\beta}) = \mathbf{e}^\top \mathbf{e} = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}) = \sum_{i=1}^n e_i^2. \quad (6.25)$$

Por meio da utilização de operações matriciais, obtém-se a seguinte expressão para os estimadores de mínimos quadrados

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}. \quad (6.26)$$

Sob a suposição de que $E(\mathbf{e}) = \mathbf{0}$ e $\text{Var}(\mathbf{e}) = \sigma^2 \mathbf{I}_n$, em que \mathbf{I}_n denota a matriz identidade de dimensão n , temos

- i) $E(\hat{\boldsymbol{\beta}}) = \boldsymbol{\beta}$,
- ii) $\text{Var}(\hat{\boldsymbol{\beta}}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$.

Além disso, se adicionarmos a suposição de que os erros têm distribuição Normal, pode-se mostrar que o estimador (6.26) tem uma distribuição Normal multivariada, o que permite a construção de intervalos de confiança para ou testes de hipóteses sobre os elementos (ou combinações lineares delas) de $\boldsymbol{\beta}$ por meio de estatísticas com distribuições exatas. Mesmo sem a suposição de normalidade para os erros, um recurso ao **Teorema Limite Central** (ver Nota de Capítulo 1) permite mostrar que a distribuição aproximada do estimador (6.26) é Normal, com média a $\boldsymbol{\beta}$ e matriz de covariâncias $\sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}$.

Um estimador não enviesado de σ^2 é

$$\begin{aligned} s^2 &= [n - (p + 1)]^{-1} (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}})^\top (\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) \\ &= [n - (p + 1)]^{-1} \mathbf{y}^\top [\mathbf{I}_n - \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top] \mathbf{y}. \end{aligned}$$

Com duas variáveis explicativas, o gráfico de dispersão precisa ser construído num espaço tridimensional, que ainda pode ser representado em duas dimensões; para mais que 2 variáveis explicativas, o gráfico de dispersão requer um espaço com mais do que três dimensões que não pode ser representado no plano. Por isso, uma alternativa é construir gráficos de dispersão entre a variável resposta e cada uma das variáveis explicativas.

Para os dados da Tabela 6.7, o gráfico de dispersão com três dimensões incluindo o plano correspondente ao modelo de regressão múltipla ajustado está disposto na Figura 6.22. Os gráficos de dispersão correspondentes a cada uma das duas variáveis explicativas estão dispostos na Figura 6.23 e indicam que a distribuição do VO₂ varia positivamente com a carga na esteira e negativamente com o IMC.

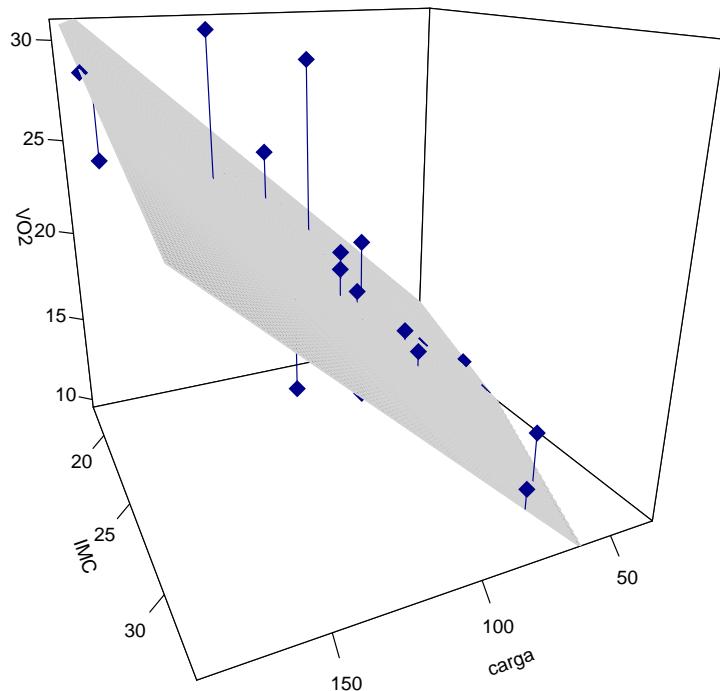


Figura 6.22: Gráficos de dispersão tridimensional para os dados da Tabela 6.7.

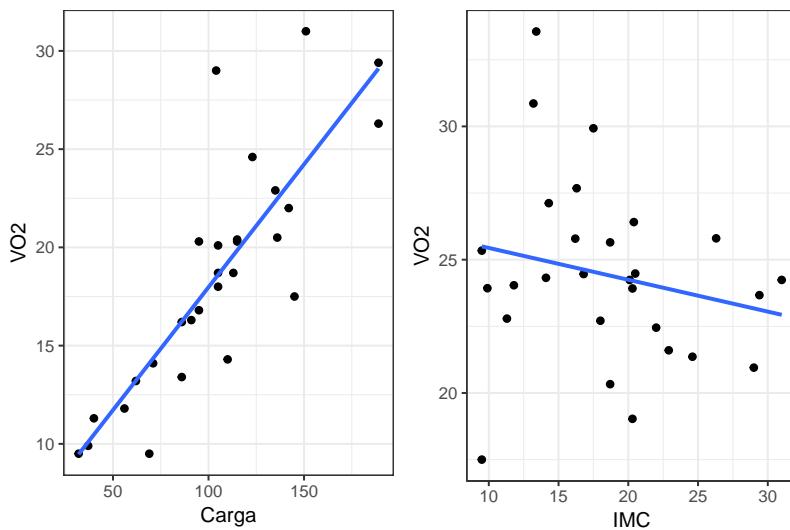


Figura 6.23: Gráficos de dispersão para os dados da Tabela 6.7.

O uso da função `lm()` conduz aos seguintes resultados.

```
Call:
lm(formula = VO2 ~ IMC + carga, data = esteira)
Residuals:
    Min      1Q  Median      3Q     Max 
-4.1834 -2.0162 -0.2929  1.0646  9.0868 
Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 15.44726   4.45431   3.468  0.00191 ** 
IMC        -0.41317   0.17177  -2.405  0.02389 *  
carga       0.12617   0.01465   8.614 5.95e-09 *** 
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1 

Residual standard error: 3.057 on 25 degrees of freedom
Multiple R-squared:  0.759, Adjusted R-squared:  0.7397 
F-statistic: 39.36 on 2 and 25 DF,  p-value: 1.887e-08
```

Essa saída nos diz que os coeficientes (erro padrão) correspondentes ao ajuste do modelo (6.24) aos dados da Tabela 6.7 são $\hat{\beta}_0 = 15,45$ (4,45), $\hat{\beta}_1 = 0,13$ (0,01) e $\hat{\beta}_2 = -0,41$ (0,17). Então, segundo o modelo, o valor esperado do VO2 para um indivíduo (IMC fixado) aumenta de 0,13 unidades para cada aumento de uma unidade da carga na esteira; similarmente, o valor esperado do VO2 para indivíduos submetidos à mesma carga na esteira diminui de 0,41 unidades com o aumento de uma unidade no IMC.

Embora o coeficiente de determinação $R_{aj}^2 = 0,74$ sugira a adequação do modelo, convém avaliá-la por meio de outras ferramentas diagnósticas. No caso de regressão linear múltipla, gráficos de resíduos podem ter cada

uma das variáveis explicativas ou os valores ajustados no eixo das abscissas. Para o exemplo, esses gráficos estão dispostos na Figura 6.24 juntamente com o gráfico contendo as distâncias de Cook.

Os gráficos de resíduos padronizados não indicam um comprometimento da hipótese de homoscedasticidade embora seja possível suspeitar de dois ou três pontos discrepantes (correspondentes aos indivíduos com identificação 4, 8 e 28) que também são salientados no gráfico das distâncias de Cook. A identificação desses pontos está baseada num critério bastante utilizado (não sem controvérsias) na literatura em que resíduos associados a distâncias de Cook maiores que $4/n$ [ou $4/(n-p)$] são considerados “influentes”. Em todo o caso, convém lembrar que o propósito dessas ferramentas é essencialmente exploratório e que as decisões sobre a exclusão de pontos discrepantes ou a escolha do modelo dependem de outras considerações. Esses pontos também fazem com que a suposição de normalidade possa ser posta em causa como se observa pelo painel esquerdo da Figura 6.25.

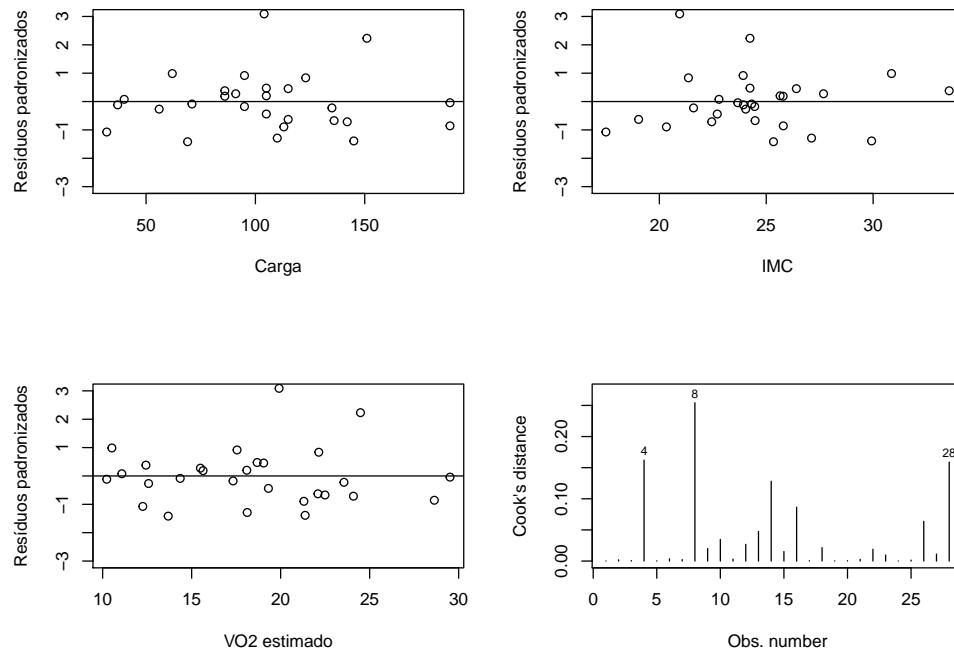


Figura 6.24: Gráficos de resíduos padronizados e distâncias de Cook para o ajuste do modelo (6.24) aos dados da Tabela 6.7.

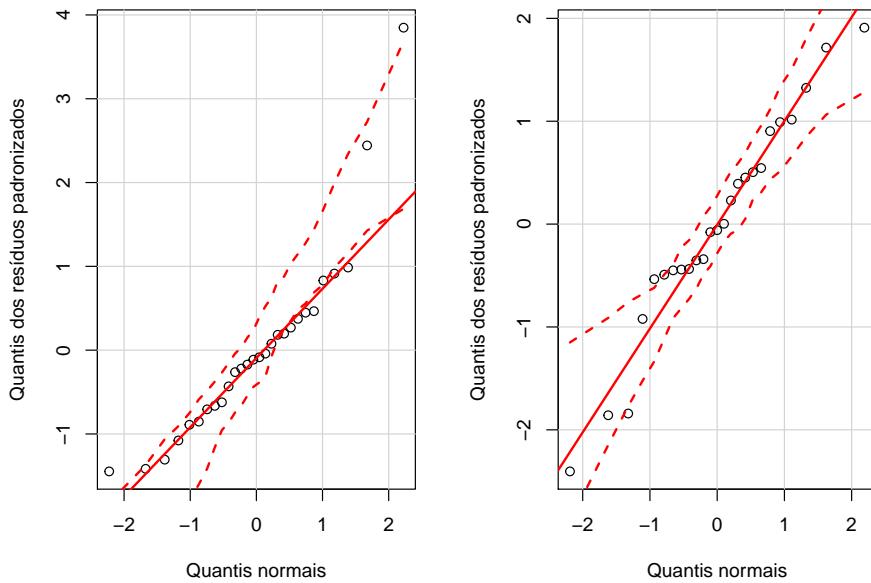


Figura 6.25: Gráficos QQ correspondentes ao ajuste do modelo (6.24) aos dados da Tabela 6.7 com (painel esquerdo) e sem (painel direito) os pontos com identificação 4, 8 e 28.

O ajuste do modelo aos 25 dados obtidos com a exclusão dos pontos identificados pelos códigos 4, 8 e 28 é obtido por meio dos comandos

```
esteirasem <- subset(dados, (dados$ident!=4 & dados$ident!=8 &
                           dados$ident!=28))
esteirasem.fit <- lm(V02 ~ IMC + carga, data = esteirasem)
summary(esteirasem.fit)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	14.89307	3.47071	4.291	0.000296 ***
IMC	-0.35631	0.12606	-2.827	0.009823 **
carga	0.11304	0.01052	10.743	3.23e-10 ***

Residual standard error: 1.987 on 22 degrees of freedom
 Multiple R-squared: 0.8581, Adjusted R-squared: 0.8452

O coeficiente de determinação correspondente é $R_{aj}^2 = 0,85$. Os gráficos de dispersão, resíduos padronizados e de distâncias de Cook correspondentes estão dispostos na Figura 6.26 e também sugerem um ajuste melhor.

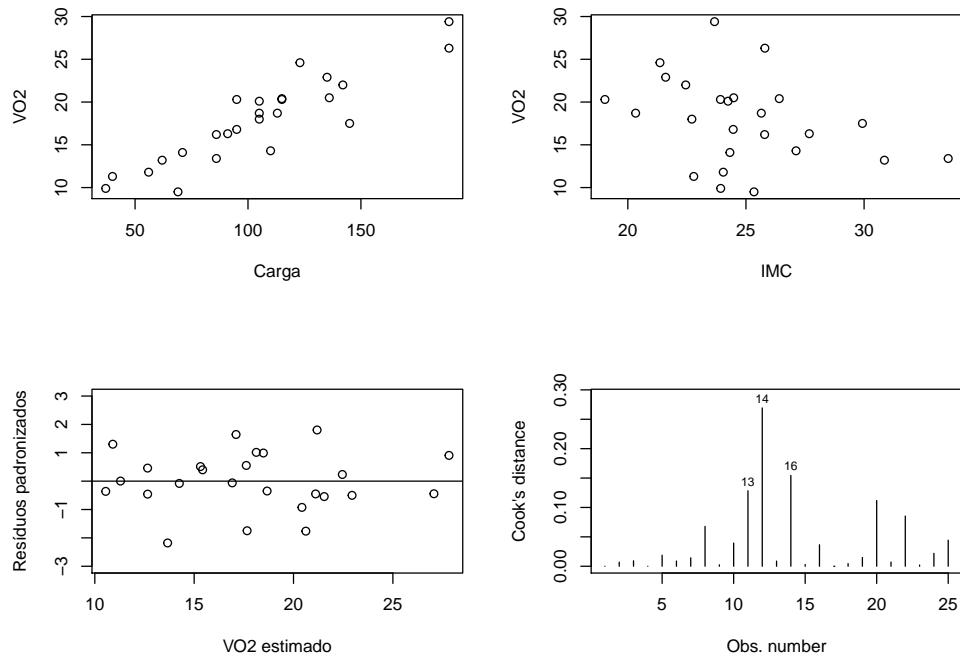


Figura 6.26: Gráficos de dispersão, resíduos padronizados e de distância de Cook correspondentes ao ajuste do modelo (6.24) aos dados da Tabela 6.7 sem os pontos com identificação 4, 8 e 28.

Uma estimativa do valor esperado do VO2 para indivíduos com IMC = 25 submetido a uma carga na esteira igual a 100 e o correspondente intervalo de confiança podem ser obtidos por meio dos comandos

```
> beta0 <- esteirasem.fit$coefficients[1]
> beta1 <- esteirasem.fit$coefficients[2]
> beta2 <- esteirasem.fit$coefficients[3]
>
> yestim <- beta0 + beta1*25 + beta2*100
> round(yestim, 2)
    17.29
>
> s <- summary(esteirasem.fit)$sigma
> xtxinv <- summary(esteirasem.fit)$cov.unscaled
> s
[1] 1.987053
> xtxinv
            (Intercept)           IMC           carga
(Intercept) 3.050826884 -1.044085e-01 -3.970913e-03
IMC         -0.104408474  4.024411e-03  4.174432e-05
carga        -0.003970913  4.174432e-05  2.804206e-05

> xval <- c(1, 25, 100)
```

```

> varyestim <- s^2*xval%*%xtxinv%*%xval

> liminfic95 <- yestim - 1.96**sqrt(varyestim)
> limsupic95 <- yestim + 1.96**sqrt(varyestim)
> round(liminfic95, 2)
15.98
> round(limsupic95, 2)
18.6

```

A previsão para o valor do VO₂ **de um indivíduo** é a mesma que aquela obtida para a estimação do correspondente valor esperado, ou seja 17,29. No entanto ao intervalo de previsão associado deve ser acrescentada a variabilidade da resposta relativa à sua média (ver Nota de Capítulo 2). Esse intervalo é obtido com os comandos

```

> liminfip95 <- yestim - 1.96*sqrt(varyestim + s^2)
> limsupip95 <- yestim + 1.96*sqrt(varyestim + s^2)
> round(liminfip95, 2)
[,1]
[1,] 13.32
> round(limsupip95, 2)
[,1]
[1,] 21.26

```

Exemplo 6.8: Os dados dispostos na Tabela 6.8 (disponíveis no arquivo producao) contêm informações sobre a produção (ton), potência instalada (1000 kW) e área construída (m^2) de 10 empresas de uma certa indústria. O objetivo é avaliar como a produção média varia em função da potência instalada e área construída. Os gráficos de dispersão entre a variável resposta (produção) e cada uma das variáveis explicativas estão dispostos na Figura 6.27 e sugerem que essas duas variáveis são linearmente associadas com a produção.

Tabela 6.8: Produção (ton), potência instalada (1000 kW) e área construída ($100 m^2$) de empresas de uma certa indústria

Produção	4,5	5,9	4,2	5,2	8,1	9,7	10,7	11,9	12,0	12,3
Potência	0,9	2,5	1,3	1,8	3,1	4,6	6,1	6,0	5,9	6,1
Área	7,1	10,4	7,2	8,2	8,5	11,9	12,1	12,5	12,0	11,3

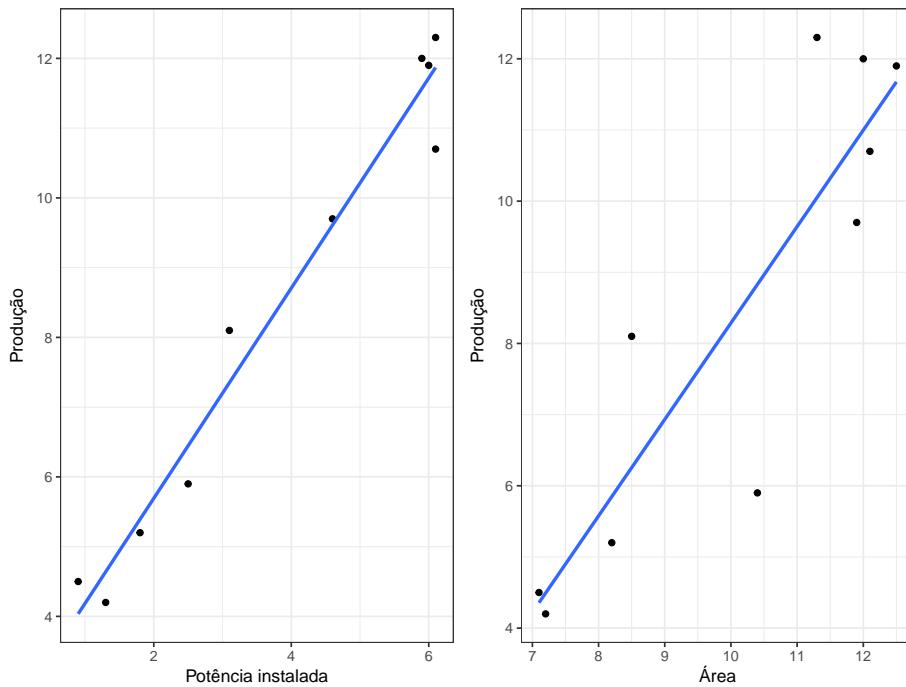


Figura 6.27: Gráficos de dispersão correspondentes aos dados da Tabela 6.8.

Estimativas dos coeficientes (com erros padrões entre parênteses) correspondentes ao intercepto, potência instalada e área construída, de um modelo de regressão linear múltipla ajustado aos dados são, respectivamente, $\hat{\beta}_0 = 4,41 (1,74)$, $\hat{\beta}_1 = 1,75 (0,26)$ e $\hat{\beta}_2 = -0,26 (0,26)$. O coeficiente de determinação associado é $R^2 = 0,972$. Chama a atenção, o valor negativo do coeficiente relativo à área construída, pois o gráfico de dispersão da Figura 6.27 sugere uma associação positiva. A justificativa está no fato de as duas variáveis explicativas serem altamente correlacionadas (coeficiente de correlação de Pearson = 0,93) de forma que a contribuição de uma delas não acrescenta poder de explicação da produção média na presença da outra. Um teste da hipótese de que $\beta_2 = 0$ produz $p = 0,34$ sugerindo que esse coeficiente pode ser considerado nulo. Em particular, a potência instalada é suficiente para explicar a variação da produção média.

O ajuste de um modelo de regressão linear simples tendo unicamente a potência instalada como variável explicativa indica que o intercepto e o coeficiente associado à essa variável são estimados, respectivamente, por $\hat{\beta}_0 = 2,68 (0,42)$ e $\hat{\beta}_1 = 1,50 (0,10)$ com um coeficiente de determinação $R^2 = 0,9681$. Gráficos de resíduos padronizados correspondentes aos dois modelos estão apresentados na Figura 6.28 e corroboram a conclusão de que apenas a variável potência instalada é suficiente para a explicação da variação da produção média.

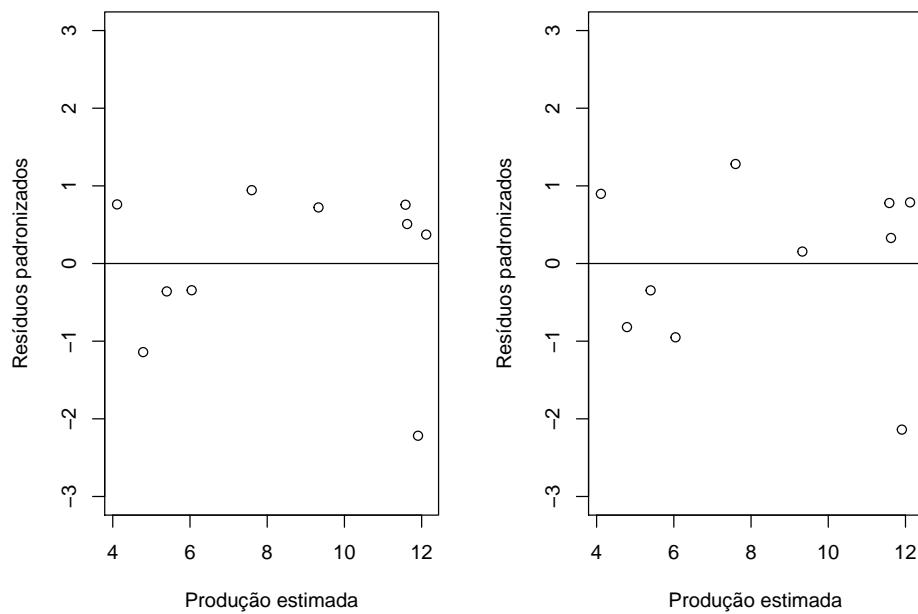


Figura 6.28: Gráficos de resíduos padronizados correspondentes aos modelos ajustados aos dados da Tabela 6.8 com duas (painele esquerdo) ou uma (painele direito) variável explicativa.

Note que o valor do coeficiente de determinação do modelo com duas variáveis explicativas $R^2 = 0,9723$ é maior do que aquele correspondente ao modelo que inclui apenas uma delas $R^2 = 0,9681$. Pela definição desse coeficiente, quanto mais variáveis forem acrescentadas ao modelo, maior será ele. Por esse motivo, convém utilizar o **coeficiente de determinação ajustado** que inclui uma penalidade pelo acréscimo de variáveis explicativas. Para o exemplo, temos $R_{aj}^2 = 0,9644$ quando duas variáveis explicativas são consideradas e $R_{aj}^2 = 0,9641$ quando apenas uma delas é incluída no modelo (ver Nota de Capítulo 3 para detalhes).

Uma outra ferramenta útil para avaliar a importância marginal de uma variável na presença de outras é o **gráfico da variável adicionada**. Consideraremos o modelo de regressão linear múltipla

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + e_i, \quad i = 1, \dots, n$$

com as suposições usuais. Para avaliar a importância marginal da variável X_2 na presença da variável X_1 , o gráfico da variável adicionada é obtido por meio dos seguintes passos

- i) Obtenha os resíduos \hat{e}_{1i} do modelo $y_i = \beta_0 + \beta_1 x_{1i} + e_i$;
- ii) Obtenha os resíduos \hat{d}_{1i} do modelo $x_{2i} = \gamma_0 + \gamma_1 x_{1i} + d_{1i}$;
- iii) Construa o gráfico de dispersão de \hat{e}_{1i} em função de \hat{d}_{1i} .

Uma tendência “relevante” nesse gráfico indica que a variável X_2 contribui para explicar a variação na média da variável resposta. Na realidade, a inclinação de uma reta ajustada aos valores de \hat{e}_{1i} em função de \hat{d}_{1i} é exatamente o coeficiente de X_2 no modelo original.

Para o exemplo da Tabela 6.8 o gráfico da variável adicionada está apresentado na Figura 6.29. O coeficiente da reta ajustada ($-0,26$) é não significativo, sugerindo que a variável X_2 não precisa ser utilizada para explicar a variação na média da variável resposta. Compare a inclinação (negativa) da reta representada nessa figura com aquela (positiva) da reta representada no painel direito da Figura 6.27.

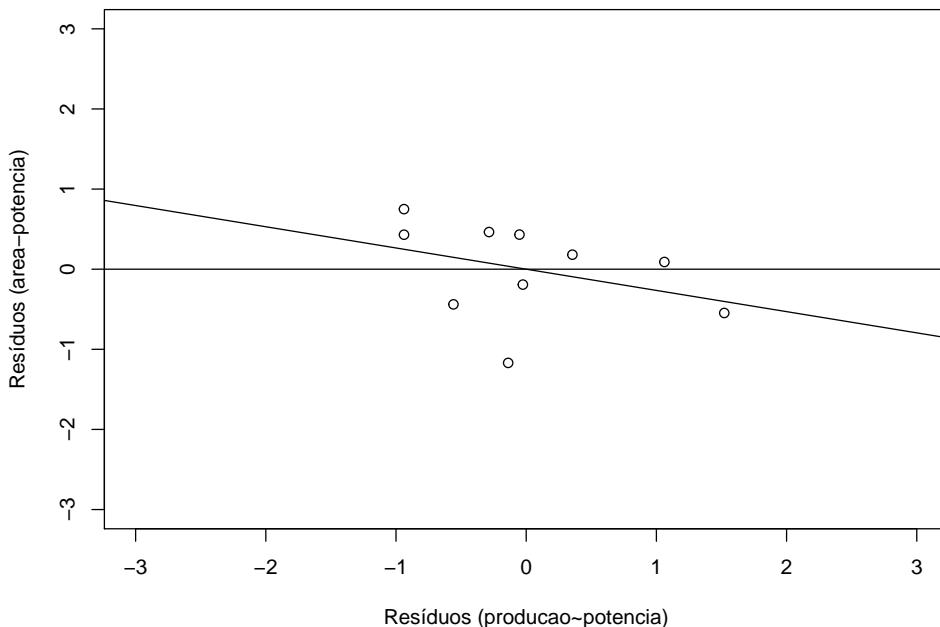


Figura 6.29: Gráfico da variável adicionada correspondente ao modelo ajustado aos dados da Tabela 6.8.

6.4 Regressão para dados longitudinais

Consideremos os dados do Exemplo 2.3, dispostos na Tabela 2.2 (disponíveis no arquivo **bezerros**) correspondentes a um estudo cujo objetivo é avaliar a variação de peso de bezerros entre a 12^a e 26^a semanas após o nascimento. Como cada animal é avaliado em 8 instantes (semanas 12, 14, 16, 18, 20, 22, 24 e 26), convém dispor os dados no formato da planilha 2.3 em que ficam caracterizadas tanto a variável resposta (peso) quanto a variável explicativa (tempo). O gráfico de dispersão correspondente está apresentado na Figura 6.30.

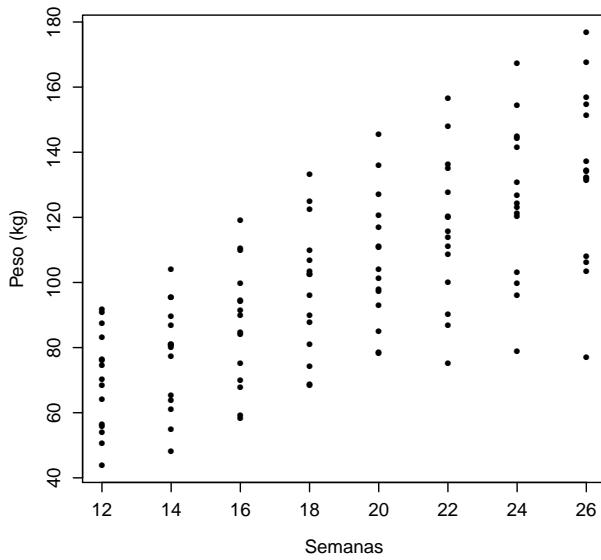


Figura 6.30: Gráfico de dispersão para os dados da Tabela 2.2.

Esse gráfico sugere que o crescimento dos animais pode ser representado pelo seguinte modelo de regressão:

$$y_{ij} = \alpha + \beta(x_j - 12) + e_{ij} \quad (6.27)$$

em que y_{ij} corresponde ao peso do i -ésimo animal no j -ésimo instante de observação, x_j corresponde ao número de semanas pós nascimento no j -ésimo instante de observação e e_{ij} têm média zero, variância constante σ^2 e são não correlacionados. Aqui o parâmetro α denota o peso esperado para animais na 12a semana pós nascimento e β corresponde ao ganho esperado de peso por semana.

Como cada animal é pesado várias vezes, a suposição de que os erros e_{ij} não são correlacionados pode não ser adequada, pois animais com peso acima ou abaixo da média na 12a semana tendem a manter esse padrão ao longo das observações. Para avaliar esse aspecto, convém construir um **gráfico de perfis** em que as observações realizadas num mesmo animal são ligadas por segmentos de reta, como indicado na Figura 6.31. A correlação entre as observações realizadas no mesmo animal fica evidenciada no gráfico do desenhista disposto na Figura 6.32.

Como no gráfico de perfis a variabilidade da resposta é similar em todos os instantes de observação e os perfis individuais têm aproximadamente as mesmas inclinações e além disso, no gráfico do desenhista podem-se notar correlações lineares com magnitudes semelhantes entre as medidas realizadas em cada par de instantes de observação, um modelo alternativo que

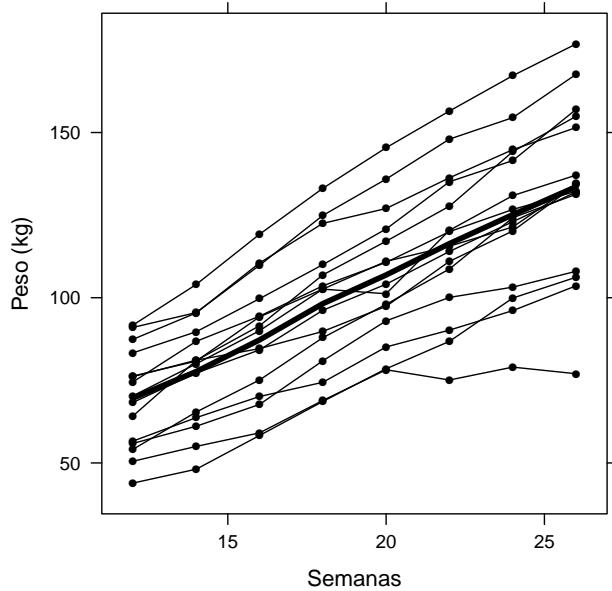


Figura 6.31: Gráfico de perfis para os dados da Tabela 2.2.

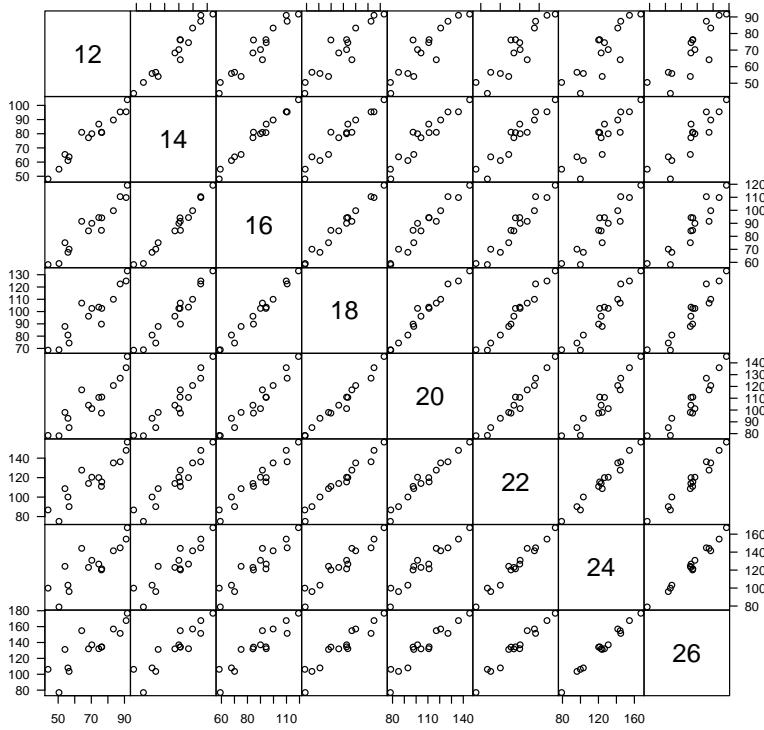


Figura 6.32: Gráfico do desenhista para os dados da Tabela 2.2.

incorpora essas características é um **modelo linear misto** dado por

$$y_{ij} = \alpha + \beta(x_j - 12) + a_i + e_{ij}, \quad (6.28)$$

em que os termos y_{ij} , x_j , α , β e e_{ij} são definidos como no modelo (6.27) e a_i é um **efeito aleatório** com média zero e variância σ_a^2 , independente de e_{ij} . Esse modelo é homoscedástico, com variância de y_{ij} igual a $\sigma_a^2 + \sigma^2$ e covariância entre y_{ij} e y_{ik} , $j \neq k$ igual a σ_a^2 . Essencialmente, esse modelo considera que o crescimento de cada bezerro pode ser modelado por uma reta com a mesma inclinação β , porém com intercepto $\alpha + a_i$ que varia de bezerro para bezerro. O intercepto tem um componente aleatório porque os animais constituem uma amostra de uma população para a qual se quer fazer inferência. Os parâmetros α e β constituem as características populacionais de interesse.

As estimativas dos parâmetros α e β obtidas do ajuste dos modelos (6.27) e (6.28) são iguais $\hat{\alpha} = 69,9$ e $\hat{\beta} = 4,7$, porém os erros padrões correspondentes são menores sob o modelo (6.28), nomeadamente, 5,6 *versus* 7,8 para $\hat{\alpha}$ e 0,1 *versus* 0,4 para $\hat{\beta}$.

Como existem três tipos de resíduos para essa classe de modelos, ferramentas diagnósticas são bem mais complexas do que aquelas apropriadas para os modelos lineares usais. Detalhes sobre a análise de modelos mistos podem ser obtidos em Singer et al. (2018).

6.5 Regressão Logística

Exemplo 6.9. O conjunto de dados apresentado na Tabela 6.9 (disponível no arquivo *inibina*) foi obtido de um estudo cuja finalidade era avaliar a utilização da inibina B como marcador da reserva ovariana de pacientes submetidas à fertilização *in vitro*. A variável explicativa é a diferença entre a concentração sérica de inibina B após estímulo com o hormônio FSH e sua concentração sérica pré estímulo e a variável resposta é a classificação das pacientes como boas ou más respondedoras com base na quantidade de óócitos recuperados. Detalhes podem ser obtidos em Dzik et al. (2000).

A diferença entre esse problema e aqueles estudados nas seções anteriores está no fato de a variável resposta ser dicotômica e não contínua. Se definirmos a variável Y com valor igual a 1 no caso de resposta positiva e igual a zero no caso de resposta negativa, a resposta média será igual à proporção $p = E(Y)$ de pacientes com resposta positiva. Essencialmente, o objetivo da análise é modelar essa proporção como função da variável explicativa. Em vez de modelar essa resposta média, convém modelar uma função dela, a saber o logaritmo da chance de resposta positiva (ver Seção 4.2) para evitar estimativas de proporções com valores fora do intervalo (0, 1). O modelo correspondente pode ser escrito como

$$\log \frac{P(Y_i = 1|X = x)}{P(Y_i = 0|X = x)} = \alpha + \beta x_i, \quad i = 1, \dots, n. \quad (6.29)$$

Tabela 6.9: Concentração de inibina B antes e após estímulo hormonal em pacientes submetidas a fertilização *in vitro*

ident	resposta	inibpre	inibpos	ident	resposta	inibpre	inibpos
1	pos	54,03	65,93	17	pos	128,16	228,48
2	pos	159,13	281,09	18	pos	152,92	312,34
3	pos	98,34	305,37	19	pos	148,75	406,11
4	pos	85,30	434,41	20	neg	81,00	201,40
5	pos	127,93	229,30	21	neg	24,74	45,17
6	pos	143,60	353,82	22	neg	3,02	6,03
7	pos	110,58	254,07	23	neg	4,27	17,80
8	pos	47,52	199,29	24	neg	99,30	127,93
9	pos	122,62	327,87	25	neg	108,29	129,39
10	pos	165,95	339,46	26	neg	7,36	21,27
11	pos	145,28	377,26	27	neg	161,28	319,65
12	pos	186,38	1055,19	28	neg	184,46	311,44
13	pos	149,45	353,89	29	neg	23,13	45,64
14	pos	33,29	100,09	30	neg	111,18	192,22
15	pos	181,57	358,45	31	neg	105,82	130,61
16	pos	58,43	168,14	32	neg	3,98	6,46

pos: resposta positiva

neg: resposta negativa

ou equivalentemente (ver Exercício 20), como

$$P(Y_i = 1|X = x) = \frac{\exp(\alpha + \beta x_i)}{1 + \exp(\alpha + \beta x_i)}, \quad i = 1, \dots, n. \quad (6.30)$$

Neste contexto, o parâmetro α é interpretado como o logaritmo da chance de resposta positiva para pacientes com $x_i = 0$ (concentrações de inibina pré e pós estímulo iguais) e o parâmetro β corresponde ao logaritmo da razão entre a chance de resposta positiva para pacientes com diferença de uma unidade na variável explicativa (ver Exercício 21).

O ajuste desse modelo é realizado pelo método de máxima verossimilhança. A função de verossimilhança a ser maximizada é

$$\ell(\alpha, \beta | \mathbf{x}, \mathbf{y}) = \prod_{i=1}^n [p(x_i)]^{y_i} [1 - p(x_i)]^{1-y_i}$$

$$p(x_i) = \frac{\exp(\alpha + \beta x_i)}{1 + \exp(\alpha + \beta x_i)}.$$

Sua maximização pode ser concretizada por meio da maximização de seu

logaritmo

$$L(\alpha, \beta | \mathbf{x}, \mathbf{y}) = \sum_{i=1}^n \left\{ y_i \log[p(x_i)] + (1 - y_i) \log[1 - p(x_i)] \right\}.$$

Os estimadores de máxima verossimilhança de α e β correspondem à solução das **equações de estimação**

$$\sum_{i=1}^n \left\{ y_i - \frac{\exp(\hat{\alpha} + \hat{\beta}x_i)}{1 + \exp(\hat{\alpha} + \hat{\beta}x_i)} \right\} = 0 \quad \text{e} \quad \sum_{i=1}^n x_i \left\{ y_i - \frac{\exp(\hat{\alpha} + \hat{\beta}x_i)}{1 + \exp(\hat{\alpha} + \hat{\beta}x_i)} \right\} = 0.$$

Como esse sistema de equações não tem solução explícita, deve-se recorrer a métodos iterativos como os métodos **Newton-Raphson** ou **Fisher scoring**. Para detalhes o leitor poderá consultar Paulino e Singer (2006), por exemplo.

O uso da função `glm()` produz os resultados a seguir:

```
> modelo1 <- glm(formula = resposta ~ difinib, family = binomial,
                  data = dados)

Deviance Residuals:
    Min      1Q   Median      3Q      Max 
-1.9770 -0.5594  0.1890  0.5589  2.0631 

Coefficients:
            Estimate Std. Error z value Pr(>|z|)    
(Intercept) -2.310455  0.947438 -2.439  0.01474 *  
inib        0.025965  0.008561  3.033  0.00242 ** 
---
(Dispersion parameter for binomial family taken to be 1)
Null deviance: 43.230 on 31 degrees of freedom
Residual deviance: 24.758 on 30 degrees of freedom
AIC: 28.758
Number of Fisher Scoring iterations: 6
```

As estimativas dos parâmetros (com erro padrão entre parênteses) α e β correspondentes ao modelo ajustado aos dados da Tabela 6.9 são, respectivamente, $\hat{\alpha} = -2,310455$ (0,947438) e $\hat{\beta} = 0,025965$ (0,008561). Consequentemente, a chance de resposta positiva para pacientes com mesmo nível de inibina B pré e pós estímulo hormonal é $\exp(\hat{\alpha}) = 0,09921612$ (0,09400113). Essa chance fica multiplicada por $\exp(\hat{\beta}) = 1,026305$ (0,008786143) para cada aumento de uma unidade na diferença entre os níveis de inibina B pré e pós estímulo hormonal.²

²Os erros padrões de $\exp(\hat{\alpha})$ e $\exp(\hat{\beta})$ são calculados por meio do **método Delta**. Ver Nota de Capítulo 6.

Dada a natureza não linear do modelo adotado, intervalos de confiança para essa chance e para essa razão de chances devem ser calculados a partir da exponenciação dos limites dos intervalos de confiança associados aos parâmetros α e β . Para os dados do exemplo em análise, esses intervalos de confiança podem ser obtidos como

```
> ic95chance0 <- exp(modelo1$coefficients[1] +
  c(-1, 1) * 1.96*sqrt(summary(modelo1)$cov.scaled[1,1]))
> ic95chance0
[1] 0.01549197 0.63541545
> ic95razaochances <- exp(modelo1$coefficients[2] +
  c(-1, 1) * 1.96*sqrt(summary(modelo1)$cov.scaled[2,2]))
> ic95razaochances
[1] 1.009228 1.043671
```

A função `predict.glm()` pode ser usada para estimar a probabilidade de que a resposta seja positiva, dados valores da variável explicativa. Os dados da Tabela 6.10 indicam diferentes níveis da diferença inibina B pré e pós estímulo hormonal e as correspondentes probabilidades de resposta positiva prevista pelo modelo.

Tabela 6.10: Diferenças inibina B pré e pós estímulo hormonal e probabilidades de resposta positiva previstas

Difinib	10	50	100	200	300	400	500
Prob	0.11	0.27	0.57	0.95	0.99	1.00	1.00

Por exemplo, o valor 0,57 correspondente a uma diferença inibina B pré e pós igual a 100 foi obtido calculando-se

$$\hat{P}(X = 1|X = 100) = \frac{\exp\{-2,310455 + (0,025965)(100)\}}{1 + \exp\{-2,310455 + (0,025965)(100)\}}. \quad (6.31)$$

Para classificar a resposta como positiva ou negativa, é preciso converter essas probabilidades previstas em rótulos de classes, “positiva” ou “negativa”. Considerando respostas positivas como aquelas cuja probabilidade seja maior do que 0,7, digamos, podemos utilizar a função `table()` para obter a seguinte tabela:

```
table(glm.pred, resposta)
      resposta
glm.pred negativa positiva
negativa     11      5
positiva      2     14
```

Os elementos da diagonal dessa tabela indicam os números de observações corretamente classificadas. Ou seja, a proporção de respostas corretas será $(11+14)/32 = 78\%$. Esse valor depende do limiar fixado, 0,7, no caso. Um

default usualmente fixado é 0,5, e nesse caso, a proporção de respostas corretas pode diminuir.

A utilização de Regressão Logística nesse contexto de classificação será detalhada no Capítulo 10.

Uma das vantagens do modelo de regressão logística é que, com exceção do intercepto, os coeficientes podem ser interpretados como razões de chances e suas estimativas são as mesmas independentemente de os dados terem sido obtidos prospectiva ou retrospectivamente (ver Seção 4.2).

Quando todas as variáveis envolvidas são categorizadas, é comum apresentar os dados na forma de uma tabela de contingência e nesse caso, as estimativas também podem ser obtidas pelo método de **mínimos quadrados generalizados**.

Exemplo 6.10: Num estudo epidemiológico, 1448 pacientes com problemas cardíacos foram classificados segundo o sexo (feminino ou masculino), idade (< 55 anos ou ≥ 55 anos) e status relativo à hipertensão arterial (sem ou com). Por meio de um procedimento de cineangiocoronariografia, o grau de lesão das artérias coronarianas foi classificado como $< 50\%$ ou $\geq 50\%$. Os dados estão resumidos na Tabela 6.11.

Tabela 6.11: Frequência de pacientes avaliados em um estudo epidemiológico

Sexo	Idade	Hipertensão arterial	Grau de lesão	
			$< 50\%$	$\geq 50\%$
Feminino	< 55	sem	31	17
Feminino	< 55	com	42	27
Feminino	≥ 55	sem	55	42
Feminino	≥ 55	com	94	104
Masculino	< 55	sem	80	112
Masculino	< 55	com	70	130
Masculino	≥ 55	sem	74	188
Masculino	≥ 55	com	68	314

Fonte: Singer, J.M. e Ikeda, K. (1996).

Nesse caso, um modelo de regressão logística apropriado (escrito de forma geral) para a análise é

$$\log\{P(Y_{ijk} = 1)/[1 - P(Y_{ijk} = 1)]\} = \alpha + \beta x_i + \gamma v_j + \delta w_k, \quad (6.32)$$

$i = 1, \dots, I$, $j = 1, \dots, J$, $k = 1, \dots, K$, em que $Y_{ijk} = 1$ se um paciente do sexo i ($i = 1$: feminino, $i = 2$: masculino), idade j ($j = 1$: < 55 , $j = 2$: ≥ 55) e status relativo à hipertensão k ($k = 1$: sem, $k = 2$: com) tiver lesão coronariana $\geq 50\%$ e $Y_{ijk} = 0$ em caso contrário. Aqui, I , J e K são iguais a 2 e $x_1 = 0$ e $x_2 = 1$ para pacientes femininos ou masculinos, respectivamente, $v_1 = 0$ e $v_2 = 1$ para pacientes com idades < 55 ou ≥ 55 , respectivamente e $w_1 = 0$ e $w_2 = 1$ para pacientes sem ou com hipertensão,

Tabela 6.12: Estimativas (e intervalos de confiança de 95%) para a chance e razões de chances associadas aos dados da Tabela 6.11

	Estimativa	Limite inferior	Limite superior
Chance de lesão $\geq 50\%$ mulheres < 55 não hipertensas	0,40	0,30	0,54
Razão de chances para sexo masculino	3,43	2,69	4,38
Razão de chances para idade ≥ 55	1,95	1,55	2,48
Razão de chances para hipertensão	1,51	1,20	1,89

respectivamente. O parâmetro α corresponde ao logaritmo da chance de lesão coronariana $\geq 50\%$ para mulheres não hipertensas com menos de 55 anos (consideradas como referência); o parâmetro β corresponde ao logaritmo da razão entre a chance de lesão coronariana $\geq 50\%$ para homens não hipertensas com menos de 55 anos e a chance correspondente para mulheres com as mesmas características (de idade e de hipertensão); o parâmetro γ corresponde ao logaritmo da razão entre a chance de lesão coronariana $\geq 50\%$ para pacientes com 55 anos ou mais e a chance correspondente para pacientes com as mesmas características (sexo e hipertensão) e menos de 55 anos; o parâmetro δ corresponde ao logaritmo da razão entre a chance de lesão coronariana $\geq 50\%$ para pacientes hipertensos e a chance correspondente para pacientes com as mesmas características (de sexo e de idade) não hipertensos.

Usando-se o pacote ACD e a função `loglinWLS()`, as estimativas dos parâmetros obtidas pelo método de mínimos quadrados generalizados (com erros padrões entre parênteses) são: $\hat{\alpha} = -0,91(0,15)$, $\hat{\beta} = 1,23(0,13)$, $\hat{\gamma} = 0,67(0,12)$, $\hat{\delta} = 0,41(0,12)$. Um intervalo de confiança aproximado com coeficiente de confiança de 95% correspondente à chance de lesão coronariana $\geq 50\%$ para mulheres não hipertensas com menos de 55 anos pode ser obtido por meio da exponenciação dos limites de um intervalo de confiança para o parâmetro α ; o mesmo procedimento pode ser empregado para a obtenção de intervalos de confiança para as razões de chances associadas ao sexo, idade e status de hipertensão. Esses intervalos estão dispostos na Tabela 6.12.

Se os 1448 pacientes avaliados no estudo puderem ser considerados como uma amostra aleatória de uma população de interesse, a chance de lesão coronariana $\geq 50\%$ para uma mulher não hipertensa com idade < 55 é de 0,40 [IC(95%) = 0,30 a 0,54]. Independentemente dessa suposição, *i.e.*, mesmo que essa chance tenha um valor R desconhecido, ela fica multiplicada por 3,43 [IC(95%) = 2,69 a 4,38] para homens não hipertensos e de mesma idade,

Tabela 6.13: Estimativas das chances de lesão coronariana para $\geq 50\%$ para pacientes com diferentes níveis dos fatores de risco obtidas com os dados da Tabela 6.11

Sexo	Idade	Hipertensão	Chance
			$(\text{lesão} \geq 50\%) / (\text{lesão} < 50\%)$
Fem	< 55	sem	R
Fem	< 55	com	$R \times 1,51$
Fem	≥ 55	sem	$R \times 1,95$
Fem	≥ 55	com	$R \times 1,51 \times 1,95$
Masc	< 55	sem	$R \times 3,43$
Masc	< 55	com	$R \times 3,43 \times 1,51$
Masc	≥ 55	sem	$R \times 3,43 \times 1,95$
Masc	≥ 55	com	$R \times 3,43 \times 1,95 \times 1,51$

por 1,95 [IC(95%) = 1,55 a 2,48] para mulheres não hipertensas com idade ≥ 55 ou por 1,51 [IC(95%) = 1,20 a 1,89] para mulheres hipertensas com idade < 55 . O modelo ainda permite estimar as chances para pacientes com diferentes níveis dos três fatores, conforme indicado na Tabela 6.13. Quando o estudo não permite estimar a chance de lesão coronariana $\geq 50\%$ para o grupo de referência (neste caso, mulheres não hipertensas com idade < 55) como em estudos retrospectivos, as razões de chances estimadas continuam válidas. Nesse contexto, por exemplo, a chance de lesão coronariana $\geq 50\%$ para homens hipertensos com idade ≥ 55 é $1,95 \times 1,51$ a chance correspondente para homens não hipertensos com idade < 55 . O cálculo do erro padrão dessa razão de chances depende de uma estimativa da matriz de covariâncias dos estimadores dos parâmetros do modelo e está fora do escopo deste texto. O leitor pode consultar Paulino e Singer (2006) para detalhes.

A avaliação da qualidade do ajuste de modelos de regressão é baseada em resíduos da forma $y_i - \hat{y}_i$ em que y_i é a resposta observada para a i -ésima unidade amostral e \hat{y}_i é o correspondente valor ajustado, *i.e.* predito pelo modelo. Para regressão logística a avaliação do ajuste é mais complexa, pois os resíduos podem ser definidos de diferentes maneiras. Apresentamos alguns detalhes na Nota de Capítulo 7.

6.6 Notas de capítulo

1) Inferência baseada em modelos de regressão linear simples.

Para o modelo (6.1) fizemos a suposição de que os erros são não correlacionados, têm média 0 e variância constante σ^2 . Geralmente, também se supõe que a variável explicativa X seja fixa. Se quisermos testar hipóteses sobre os parâmetros α e β ou construir intervalos de confiança para eles por meio de estatísticas com distribuições exatas,

devemos fazer alguma suposição adicional sobre a distribuição dos erros. Usualmente, supõe-se que os e_i têm uma distribuição Normal. Se a distribuição dos erros tiver caudas mais longas (pesadas) do que a da distribuição Normal, os estimadores de mínimos quadrados podem se comportar de forma inadequada e estimadores robustos devem ser usados.

Como

$$\hat{\beta} = \frac{\sum_{i=1}^n (x_i - \bar{x})y_i}{\sum_{i=1}^n (x_i - \bar{x})^2} = \sum_{i=1}^n w_i y_i,$$

com $w_i = (x_i - \bar{x}) / \sum_{i=1}^n (x_i - \bar{x})^2$, o estimador $\hat{\beta}$ é uma função linear das observações y_i . O mesmo vale para $\hat{\alpha}$. Utilizando esse resultado, pode-se demonstrar (veja a seção de exercícios) que

- a) $E(\hat{\alpha}) = \alpha$ e $E(\hat{\beta}) = \beta$, ou seja, os EMQ são não enviesados.
- b) $\text{Var}(\hat{\alpha}) = \sigma^2 \sum_{i=1}^n x_i^2 / [n \sum_{i=1}^n (x_i - \bar{x})^2]$.
- c) $\text{Var}(\hat{\beta}) = \sigma^2 / \sum_{i=1}^n (x_i - \bar{x})^2$.
- d) $\text{Cov}(\hat{\alpha}, \hat{\beta}) = -\sigma^2 \bar{x} / \sum_{i=1}^n (x_i - \bar{x})^2$.

Com a suposição adicional de normalidade, pode-se mostrar que

- e) $y_i \sim N(\alpha + \beta x_i, \sigma^2)$

- f) as estatísticas

$$t_{\hat{\alpha}} = \frac{\hat{\alpha} - \alpha}{S} \sqrt{\frac{n \sum (x_i - \bar{x})^2}{\sum x_i^2}}$$

e

$$t_{\hat{\beta}} = \frac{\hat{\beta} - \beta}{S} \sqrt{\sum (x_i - \bar{x})^2}$$

têm distribuição t de Student com $(n - 2)$ graus de liberdade.

Nesse contexto, os resíduos padronizados, definidos em (6.9) também seguem uma distribuição t de Student com $(n - 2)$ graus de liberdade. Daí a denominação alternativa de resíduos studentizados.

Com esses resultados é possível testar as hipóteses $H_0 : \alpha = 0$ e $H_0 : \beta = 0$, bem como construir intervalos de confiança para esses parâmetros.

Um teorema importante conhecido como **Teorema de Gauss-Markov** (e que não depende da suposição de normalidade dos erros) afirma que os EMQ têm variância mínima na classe dos estimadores não enviesados que sejam funções lineares das observações y_i .

Quando os erros não seguem uma distribuição Normal, mas o tamanho da amostra é suficientemente grande, pode-se mostrar com o auxílio do **Teorema Limite Central** que sob certas condições de regularidade (usualmente satisfeitas na prática), os estimadores $\hat{\alpha}$ e $\hat{\beta}$ têm distribuições aproximadamente normais com variâncias que podem ser

estimadas pelas expressões indicadas nos itens b) e c) indicados anteriormente. Detalhes podem ser obtidos em Sen et al. (2009).

2) Estimação e previsão sob modelos de regressão linear simples.

Um dos objetivos da análise de regressão é fazer previsões sobre a variável resposta com base em valores das variáveis explicativas. Por simplicidade trataremos do caso de regressão linear simples. Uma estimativa para o valor esperado $E(Y|X = x_0)$ da variável resposta Y dado um valor x_0 da variável explicativa é $\hat{y} = \hat{\alpha} + \hat{\beta}x_0$ e com base nos resultados apresentados na Nota de Capítulo 1 pode-se mostrar que a variância de \hat{y} é

$$\text{Var}(\hat{y}) = \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right].$$

Então os limites superior e inferior para um **intervalo de confiança** aproximado com coeficiente de confiança de 95% para o **valor esperado** de Y dado $X = x_0$ são

$$\hat{y} \pm 1,96S \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}$$

com S^2 denotando uma estimativa de σ^2 . *Grosso modo*, podemos dizer que esse intervalo deve conter o verdadeiro valor esperado de $E(Y|X = x)$, i.e., a média de Y para todas as observações em que $X = x_0$. Isso não significa que esperamos que o intervalo contenha o verdadeiro valor de Y , digamos Y_0 para uma unidade de investigação para a qual $X = x_0$. Nesse caso precisamos levar em conta a variabilidade de $Y|X = x_0$ em torno de seu valor esperado $E(Y|X = x_0)$.

Como $Y_0 = \hat{y} + e_0$ sua variância é

$$\text{Var}(Y_0) = \text{Var}(\hat{y}) + \text{Var}(e_0) = \sigma^2 \left[\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right] + \sigma^2$$

Então os limites superior e inferior de um **intervalo de previsão** (aproximado) para Y_0 são

$$\hat{y} \pm 1,96S \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}}.$$

Note que se aumentarmos indefinidamente o tamanho da amostra, a amplitude do intervalo de confiança para o valor esperado tenderá para zero, porém a amplitude do intervalo de previsão correspondente a uma unidade específica tenderá para $2 \times 1,96 \times \sigma$.

3) Coeficiente de determinação.

Consideremos um conjunto de dados pareados $(x_1, y_1), \dots, (x_n, y_n)$ de duas variáveis contínuas X e Y . Se não levarmos em conta a variável X para explicar a variabilidade da variável Y como no modelo de regressão linear simples, a melhor previsão para Y é \bar{y} e uma estimativa da variância de Y é dada por $S^2 = \sum_{i=1}^n (y_i - \bar{y})^2 / (n - 1)$. Para relacionar esse resultado com aquele obtido por meio de um modelo de regressão linear para os mesmos dados, podemos escrever

$$y_i - \bar{y} = (y_i - \hat{y}_i) + (\hat{y}_i - \bar{y}).$$

Uma representação gráfica dessa relação está apresentada na Figura 6.33.

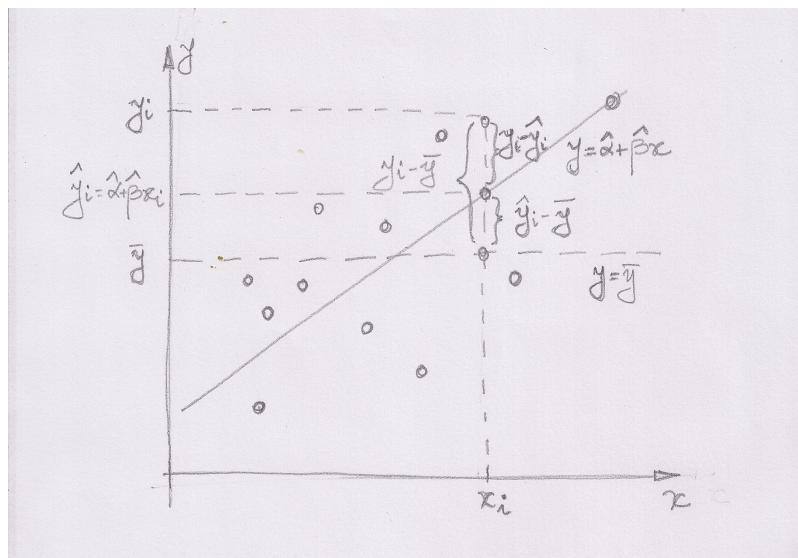


Figura 6.33: Representação gráfica da decomposição da soma de quadrados.

Pode-se mostrar (ver Exercício 15) que

$$\sum_{i=1}^n (y_i - \bar{y})^2 = \sum_{i=1}^n \hat{e}_i^2 + \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

ou, de forma abreviada,

$$SQTot = SQRes + SQReg.$$

Esse resultado indica que a soma de quadrados total ($SQTot$) pode ser decomposta num termo correspondente à variabilidade dos resíduos ($SQRes$) e em outro correspondente à regressão ($SQReg$). Quanto maior for esse último termo, maior é a evidência de que a variável X

é útil para explicar a variabilidade da variável Y . Tendo em vista a expressão (6.6), é fácil ver que

$$SQReg = \hat{\beta}^2 \sum_{i=1}^n (x_i - \bar{x})^2.$$

Nesse contexto, a estatística $R^2 = SQReg/SQTot$ corresponde à porcentagem da variabilidade de Y explicada pelo modelo, ou seja, pela introdução da variável X no modelo mais simples, $y_i = \mu + e_i$.

Como a soma de quadrados $SQReg$ (e consequentemente, o coeficiente R^2) sempre aumenta quando mais variáveis explicativas são introduzidas no modelo, convém considerar uma penalidade correspondente ao número de variáveis explicativas. Nesse sentido, para comparação de modelos com números diferentes de variáveis explicativas, costuma-se utilizar o **coeficiente de determinação ajustado**

$$R_{aj}^2 = 1 - (1 - R^2) \frac{n - 1}{n - p - 1} = 1 - \frac{SQRes/(n - p - 1)}{SQTot/(n - 1)}$$

em que p é o número de variáveis explicativas do modelo. Lembrando que

$$R^2 = 1 - \frac{SQRes}{SQTot} = 1 - \frac{SQRes/n}{SQTot/n},$$

o coeficiente R_{aj}^2 é obtido por meio de um aumento maior no numerador do que no denominador de R^2 , com mais intensidade quanto maior for o número de variáveis explicativas.

4) Distância de Cook.

A distância de Cook é uma estatística que mede a mudança nos valores preditos pelo modelo de regressão quando eliminamos uma das observações. Denotando por $\hat{\mathbf{y}}$ o vetor (de dimensão n) com os valores preditos obtidos do ajuste do modelo baseado nas n observações e por $\hat{\mathbf{y}}^{(-i)}$ o correspondente vetor com valores preditos (de dimensão n) obtido do ajuste do modelo baseado nas $n - 1$ observações restantes após a eliminação da i -ésima, a distância de Cook é definida como

$$D_i = \frac{(\hat{\mathbf{y}} - \hat{\mathbf{y}}^{(-i)})^\top (\hat{\mathbf{y}} - \hat{\mathbf{y}}^{(-i)})}{(p + 1)S}$$

em que p é o número de coeficientes de regressão e S é uma estimativa do desvio padrão. É possível mostrar que a distância de Cook (D_i) pode ser calculada sem a necessidade de ajustar o modelo com a omissão da i -ésima observação por meio da expressão

$$D_i = \frac{1}{p + 1} \hat{e}_i^2 \frac{h_{ii}}{(1 - h_{ii})^2}$$

lembrando que

$$h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum_{i=1}^n x_i^2 - n\bar{x}^2}.$$

Para o modelo de regressão linear simples, $p = 2$. Detalhes podem ser obtidos em Kutner et al. (2004).

5) Influência local.

Influência local é o efeito de uma pequena variação no valor da variável resposta nas estimativas dos parâmetros do modelo. Consideremos uma observação (x_j, y_j) e quantifiquemos o efeito de uma mudança de y_j para $y_j + \Delta y_j$ nos valores de $\hat{\alpha}$ e $\hat{\beta}$. Com esse propósito, observando que

$$\hat{\beta} + \Delta\hat{\beta}(y_j) = \frac{\sum_{i \neq j} (x_i - \bar{x})y_i + (x_j - \bar{x})(y_j + \Delta y_j)}{\sum_{i=1}^n (x_i - \bar{x})^2},$$

podemos concluir que

$$\Delta\hat{\beta}(y_j) = \frac{(x_j - \bar{x})\Delta y_j}{\sum_{i=1}^n (x_i - \bar{x})^2}. \quad (6.33)$$

Este resultado indica que, fixado Δy_j , a variação em $\hat{\beta}$ é diretamente proporcional a $x_j - \bar{x}$ e inversamente proporcional a $(n - 1)S^2$. Portanto, o efeito da variação no valor de y_j será grande se x_j estiver bastante afastado da média dos x_i e se a variabilidade dos x_i for pequena.

Para o intercepto, temos

$$\hat{\alpha} = \bar{y} - \hat{\beta}\bar{x} = \frac{\sum_i y_i}{n} - \hat{\beta}\bar{x},$$

logo, quando y_j é substituído por $y_j + \Delta y_j$, teremos

$$\hat{\alpha} + \Delta\hat{\alpha}(y_j) = \frac{\sum_{i \neq j} y_i + (y_j + \Delta y_j)}{n} - (\hat{\beta} + \Delta\hat{\beta})\bar{x},$$

e portanto

$$\Delta\hat{\alpha}(y_j) = \frac{\Delta y_j}{n} - (\Delta\hat{\beta})\bar{x},$$

ou ainda

$$\Delta\hat{\alpha}(y_j) = \left[\frac{1}{n} - \frac{\bar{x}(x_j - \bar{x})}{\sum_i (x_i - \bar{x})^2} \right] \Delta y_j. \quad (6.34)$$

Se $x_j = \bar{x}$, então $\Delta\hat{\beta} = 0$, mas $\Delta\hat{\alpha} = \Delta y_j/n$, ou seja, Δy_j não afeta a inclinação mas afeta o intercepto. Gráficos de (6.33) e (6.34) em função dos índices de cada observação indicam para que pontos a variação nos valores da variável resposta tem maior influência nas estimativas dos parâmetros.

6) Método Delta.

Considere um parâmetro β para o qual se dispõe de um estimador $\hat{\beta}$ cuja variância é $\sigma_{\hat{\beta}}^2$ e suponha que haja interesse em obter a variância de uma transformação $g(\hat{\beta})$. Por meio de uma expansão de Taylor, pode-se mostrar que

$$\text{Var}[g(\hat{\beta})] = [g'(\hat{\beta})]^2 \sigma_{\hat{\beta}}^2$$

em que $g'(\hat{\beta})$ denota a primeira derivada de g calculada no ponto $\hat{\beta}$. Detalhes podem ser obtidos em Sen et al. (2009).

7) Análise do ajuste de modelos de regressão logística.

Nos casos em que todas as variáveis explicativas utilizadas num modelo de regressão logística são categorizadas, podemos agrupar as respostas y_i segundo os diferentes padrões definidos pelas combinações dos níveis dessas variáveis. Quando o modelo envolve apenas uma variável explicativa dicotômica (Sexo, por exemplo), há apenas dois padrões, nomeadamente, M e F). Se o modelo envolver duas variáveis explicativas dicotômicas (Sexo e Faixa etária com dois níveis, ≤ 40 anos e > 40 anos, por exemplo), estaremos diante de uma situação com quatro padrões, a saber, (F e ≤ 40), (F e > 40), (M e ≤ 40) e (M e > 40). A introdução de uma ou mais variáveis explicativas contínuas no modelo, pode gerar um número de padrões igual ao número de observações.

Consideremos um caso com p variáveis explicativas $\mathbf{x} = (x_1, \dots, x_p)^\top$ e sejam M o número de padrões (correspondente ao número de valores distintos de \mathbf{x}) e m_j , $j = 1, \dots, M$, o número de observações com o mesmo valor \mathbf{x}_j de \mathbf{x} . Note que no caso mais comum, em que existe pelo menos uma variável contínua, $m_j \approx 1$ e $M \approx n$. Além disso, seja \tilde{y}_j o número de respostas $Y = 1$ entre as m_j unidades amostrais com o mesmo valor \mathbf{x}_j . O valor ajustado \hat{y}_j correspondente a \tilde{y}_j é

$$\hat{y}_j = m_j \hat{p}_j = m_j \frac{\exp(\mathbf{x}_j^\top \hat{\beta})}{1 + \exp(\mathbf{x}_j^\top \hat{\beta})}$$

em que $\hat{\beta}$ é o estimador do vetor de parâmetros de modelo.

O **resíduo de Pearson** é definido como

$$\hat{e}_j = \frac{\tilde{y}_j - m_j \hat{p}_j}{\sqrt{m_j \hat{p}_j (1 - \hat{p}_j)}}$$

e uma medida resumo para a avaliação do ajuste do modelo é a **estatística de Pearson**

$$Q_p = \sum_{j=1}^M \hat{e}_j^2.$$

Para M suficientemente grande, a estatística Q_P tem distribuição assintótica χ^2 com $M - (p + 1)$ graus de liberdade quando o modelo está bem ajustado.

Para evitar problemas com a distribuição assintótica de Q_P quando $M \approx n$, convém agrupar os dados de alguma forma. Hosmer and Lemeshow (1980) e Lemeshow e Hosmer (1982) sugerem que os dados sejam agrupados segundo percentis das probabilidades \hat{p}_i , $i = 1, \dots, n$ estimadas sob o modelo. Por exemplo, podem-se considerar $g = 10$ grupos, sendo o primeiro formado pelas unidades amostrais com os 10% menores valores das probabilidades estimadas (ou seja, aquelas para as quais \hat{p}_i sejam menores ou iguais ao primeiro decil; o segundo grupo deve conter as unidades amostrais para as quais \hat{p}_i estejam entre o primeiro e o segundo decil etc. O último grupo conterá as unidades amostrais cujas probabilidades estimadas sejam maiores que o nono decil. Com esse procedimento, cada grupo deverá conter $n_j^* = n/10$ unidades amostrais. A estatística proposta por esses autores é

$$\hat{C} = \sum_{j=1}^g \frac{(o_j - n_j^* \bar{p}_j)^2}{n_j^* \bar{p}_j (1 - \bar{p}_j)}$$

com $o_j = \sum_{i=1}^{c_j} y_i$ denotando o número de respostas $Y = 1$ dentre as unidades amostrais incluídas no j -ésimo grupo (c_j representa o número de padrões de covariáveis encontrados no j -ésimo grupo) e $\bar{p}_j = \sum_{i=1}^{c_j} m_i \hat{p}_i / n_j^*$ denota a média das probabilidades estimadas no j -ésimo grupo. A estatística \hat{C} tem distribuição aproximada χ^2 com $g - 2$ graus de liberdade quando o modelo estiver correto.

Os chamados **resíduos da desviância** (*deviance residuals*) são definidos a partir da logaritmo da função de verossimilhança e também podem ser utilizados com o propósito de avaliar a qualidade do ajuste de modelos de regressão logística. O leitor poderá consultar Hosmer and Lemeshow (2000) para detalhes.

8) Regressão resistente.

Os estimadores $\hat{\alpha}$ e $\hat{\beta}$ em (6.7) e (6.6) considerados para o ajuste do modelo (6.1) a um conjunto de dados (x_i, y_i) , $i = 1, \dots, n$ são baseados em \bar{x}, \bar{y} e nos desvios em relação a essas médias. Esses estimadores podem ser severamente afetados pela presença de observações discrepantes (*outliers*). Como alternativa, podemos considerar modelos de **regressão resistente**, em que os estimadores são baseados em medianas.

Para o ajuste desses modelos, inicialmente, dividimos o conjunto de n pontos em três grupos de tamanhos aproximadamente iguais. Chamemos esses grupos de E, C e D. Se $n = 3k$, cada grupo terá k pontos. Se $n = 3k + 1$, colocamos k pontos nos grupos E e D e $k + 1$ pontos

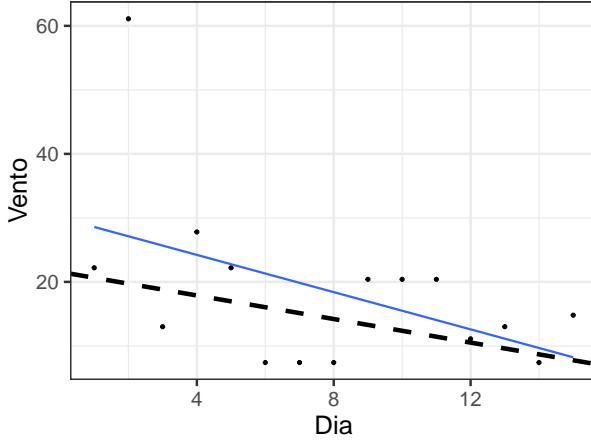


Figura 6.34: Gráfico de dispersão com retas de mínimos quadrados (linha cheia) e resistente (linha tracejada) correspondentes ao ajuste do modelo de regressão linear simples aos dados da Tabela 6.3.

no grupo C. Finalmente, se $n = 3k + 2$, colocamos $k + 1$ pontos nos grupos E e D e k pontos no grupo C.

Para cada grupo, obtemos um **ponto resumo**, cujas coordenadas são a mediana dos x_i e a mediana dos y_i naquele grupo. Denotemos esses pontos por $(x_E, y_E), (x_C, y_C), (x_D, y_D)$.

Os estimadores resistentes de β e α são dados por

$$b_0 = \frac{y_D - y_E}{x_D - x_E}, \quad (6.35)$$

e

$$a_0 = \frac{1}{3} [(y_E - b_0 x_E) + (y_C - b_0 x_C) + (y_D - b_0 x_D)]. \quad (6.36)$$

Convém notar as diferenças entre b_0 e (6.6) e entre a_0 e (6.7). A correspondente reta resistente ajustada é

$$\tilde{y}_i = a_0 + b_0 x_i, \quad i = 1, \dots, n. \quad (6.37)$$

Exemplo 6.11 Consideremos novamente os dados da Tabela 6.2 aos quais um modelo de regressão linear simples foi ajustado; tanto o gráfico de dispersão apresentado na Figura 6.7 quanto o gráfico de resíduos (Figura 6.8) revelam um ponto discrepante, $(2; 61, 1)$ que afeta as estimativas dos parâmetros do modelo. O gráfico de dispersão com a reta de mínimos quadrados e com a reta resistente está disposto na Figura 6.34.

Como nesse caso, como $n = 3 \times 5$, consideramos os grupos E, C e D com 5 pontos cada. Os pontos resumo são $(x_E, y_E) = (3, 0; 22, 2)$, $(x_C, y_C) = (8, 0; 7, 4)$ e $(x_D, y_D) = (13, 0; 13, 0)$ e as correspondentes

estimativas resistentes são $b_0 = -0,92$ e $a_0^* = 21,56$. Portanto, a reta resistente estimada ou ajustada é

$$\tilde{v}_t = 21,56 - 0,92t. \quad (6.38)$$

Esta reta não é tão afetada pelo ponto discrepante (que não foi eliminado da análise).

9) Formulação geral do modelo de regressão

O modelo de regressão múltipla (6.21) pode ser escrito na forma

$$y_i = f(\mathbf{x}_i, \boldsymbol{\beta}) + e_i, \quad i = 1, \dots, n, \quad (6.39)$$

em que

$$f(\mathbf{x}_i, \boldsymbol{\beta}) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \dots + \beta_p x_{ip}, \quad (6.40)$$

com $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})^\top$ e $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_p)^\top$.

Esse modelo pode ser generalizado como

$$f(\mathbf{x}, \boldsymbol{\beta}) = \sum_{j=0}^{M-1} \beta_j \phi_j(\mathbf{x}), \quad (6.41)$$

em que $\phi_j(\cdot)$, $j = 0, \dots, M-1$ com $\phi_0(x) = 1$ são funções pertencentes a uma base de funções. Essa formulação é útil no contexto de **redes neurais** (ver Capítulo ??).

Em notação matricial, temos

$$f(\mathbf{x}, \boldsymbol{\beta}) = \boldsymbol{\beta}^\top \boldsymbol{\phi}(\mathbf{x}), \quad (6.42)$$

com $\boldsymbol{\phi} = (\phi_0, \dots, \phi_{M-1})^\top$.

O caso $\boldsymbol{\phi}(\mathbf{x}) = \mathbf{x}$ corresponde ao modelo de regressão linear múltipla. Outras bases comumente usadas são:

- a) polinômios [$\phi_j(x) = x^j$];
- b) *splines*;
- c) gaussiana [$\phi_j(x) = \exp\{-(x - \mu_j)/(2s)\}$], com μ_j denotando parâmetros de posição e s denotando o parâmetro de dispersão;
- d) sigmoide [$\phi_j(x) = \sigma\{(x - \mu_j)/s\}$] em que, $\sigma(a)$ pode ser qualquer uma das funções (a)–(d) da Seção 13.3.
- e) Fourier [$\phi_j(x)$] é uma cossenoide [ver Morettin (2014)].
- f) ondaletas [$\phi_j(x)$] é uma ondaleta [ver Morettin (2014)].

Toda a teoria de mínimos quadrados assim como as técnicas de regularização (ver Capítulo 11) podem ser aplicados a essa formulação mais geral.

6.7 Exercícios

- 1) Considere o modelo

$$y_i = \beta x_i + e_i, \quad i = 1, \dots, n$$

em que $E(e_i) = 0$ e $\text{Var}(e_i) = \sigma^2$ são erros aleatórios não correlacionados.

- a) Obtenha o estimador de mínimos quadrados de β e proponha um estimador não enviesado para σ^2 .
 - b) Especifique a distribuição aproximada do estimador de β .
 - c) Especifique um intervalo de confiança aproximado para o parâmetro β com coeficiente de confiança γ , $0 < \gamma < 1$.
- 2) Considere o modelo especificado no Exercício 1 e mostre que o parâmetro β corresponde à variação esperada para a variável Y por unidade de variação da variável X .

Sugestão: Subtraia $E(y_i|x_i)$ de $E(y_i|x_i + 1)$.

- 3) Para investigar a associação entre tipo de escola (particular ou pública), cursada por calouros de uma universidade e a média no curso de Cálculo I, obtiveram-se os seguintes dados:

Escola	Média no curso de Cálculo I								
	Particular	8,6	8,6	7,8	6,5	7,2	6,6	5,6	5,5
Pública	5,8	7,6	8,0	6,2	7,6	6,5	5,6	5,7	5,8

Seja y_i a nota obtida pelo i -ésimo aluno, $x_i = 1$ se o aluno cursou escola particular e $x_i = -1$ se o aluno cursou escola pública, $i = 1, \dots, 18$. Considere o modelo $y_i = \alpha + \beta x_i + e_i$, $i = 1, \dots, 18$ em que os e_i são erros aleatórios não correlacionados com $E(e_i) = 0$ e $\text{Var}(e_i) = \sigma^2$.

- i) Interprete os parâmetros α e β .
 - ii) Estime α e β pelo método de mínimos quadrados. Obtenha também uma estimativa de σ^2 .
 - iii) Avalie a qualidade do ajuste do modelo por meio de técnicas de diagnóstico.
 - iv) Construa intervalos de confiança para α e β .
 - v) Com base nas estimativas obtidas no item ii), construa intervalos de confiança para os valores esperados das notas dos alunos das escolas particulares e públicas.
 - vi) Ainda utilizando o modelo proposto, especifique e teste a hipótese de que ambos os valores esperados são iguais.
 - vii) Repita os itens i)-vi) definindo $x_i = 1$ se o aluno cursou escola particular e $x_i = 0$ se o aluno cursou escola pública, $i = 1, \dots, 18$.
- 4) Num estudo realizado na Faculdade de Medicina da Universidade de São Paulo foram colhidos dados de 16 pacientes submetidos a transplante intervivos e em cada um deles obtiveram-se medidas tanto do peso (g) real do lobo direito do fígado quanto de seu volume (cm^3) previsto pré operatoriamente por métodos ultrassonográficos. O objetivo é estimar o peso real por meio do volume previsto. Os dados estão dispostos na Tabela 6.14.

- i) Proponha um modelo de regressão linear simples para analisar os dados e interprete seus parâmetros.
- ii) Construa um gráfico de dispersão apropriado.
- iii) Ajuste o modelo e utilize ferramentas de diagnóstico para avaliar a qualidade do ajuste.
- iv) Construa intervalos de confiança para seus parâmetros.
- v) Construa uma tabela com intervalos de confiança para o peso esperado do lobo direito do fígado correspondentes a volumes (estimados ultrassonograficamente) de 600, 700, 800, 900 e 1000 cm^3 .
- vi) Repita os itens anteriores considerando um modelo linear simples sem intercepto. Qual dos dois modelos você acha mais conveniente? Justifique a sua resposta.

Tabela 6.14: Peso (g) real e volume (cm^3) obtido ultrassonograficamente do lobo direito do fígado de pacientes submetidos a transplante

Volume USG (cm^3)	Peso real (g)	Volume USG (cm^3)	Peso real (g)
656	630	737	705
692	745	921	955
588	690	923	990
799	890	945	725
766	825	816	840
800	960	584	640
693	835	642	740
602	570	970	945

- 5) Os dados da Tabela 6.15 são provenientes de uma pesquisa cujo objetivo é propor um modelo para a relação entre a área construída de um determinado tipo de imóvel e o seu preço.

Tabela 6.15: Área (m^2) e Preço (R\$) de imóveis

Imóvel	Área (m^2)	Preço (R\$)
1	128	10.000
2	125	9.000
3	200	17.000
4	4.000	200.000
5	258	25.000
6	360	40.000
7	896	70.000
8	400	25.000
9	352	35.000
10	250	27.000
11	135	11.000
12	6.492	120.000
13	1.040	35.000
14	3.000	300.000

- i) Construa um gráfico de dispersão apropriado para o problema.
- ii) Ajuste um modelo de regressão linear simples e avalie a qualidade do ajuste (obtenha estimativas dos parâmetros e de seus erros padrões, calcule o coeficiente de determinação e construa gráficos de resíduos e um gráfico do tipo QQ).
- iii) Ajuste o modelo linearizável (por meio de uma transformação logarítmica)

$$y = \beta x^\gamma e$$

em que y representa o preço e x representa a área e avalie a qualidade do ajuste comparativamente ao modelo linear ajustado no item ii); construa um gráfico de dispersão com os dados transformados.

- iv) Utilizando o modelo com o melhor ajuste, construa intervalos de confiança com coeficiente de confiança (aproximado) de 95% para os preços esperados de imóveis com $200m^2$, $500m^2$ e $1000m^2$.
- 6) Os dados abaixo correspondem ao faturamento de empresas similares de um mesmo setor industrial nos últimos 15 meses.

mês	jan	fev	mar	abr	mai	jun	jul	ago
vendas	1,0	1,6	1,8	2,0	1,8	2,2	3,6	3,4

mês	set	out	nov	dez	jan	fev	mar
vendas	3,3	3,7	4,0	6,4	5,7	6,0	6,8

Utilize técnicas de análise de regressão para quantificar o crescimento do faturamento de empresas desse setor ao longo do período observado. Com essa finalidade:

- a) Proponha um modelo adequado, interpretando todos os parâmetros e especificando as suposições.
- b) Estime os parâmetros do modelo e apresente os resultados numa linguagem não técnica.

- c) Utilize técnicas de diagnóstico para avaliar o ajuste do modelo.
- 7) A Tabela 6.16 contém dados obtidos de diferentes institutos de pesquisa coletados entre fevereiro de 2008 e março de 2010 e correspondem às porcentagens de eleitores favoráveis a cada um dos dois principais candidatos à presidência do Brasil.
- Construa um diagrama de dispersão apropriado, evidenciando os pontos correspondentes a cada um dos candidatos.
 - Especifique um modelo polinomial de segundo grau, homocedástico, que represente a variação da preferência eleitoral de cada candidato ao longo do tempo.
 - Ajuste o modelo especificado no item anterior.
 - Avalie o ajuste do modelo e verifique, por meio de testes de hipóteses adequadas, se ele pode ser simplificado; em caso afirmativo, ajuste o modelo mais simples.
 - Com base no modelo escolhido, estime a porcentagem esperada de eleitores favoráveis a cada um dos candidatos em 3 de outubro de 2010 e construa um intervalo de confiança para a diferença entre essas porcentagens esperadas.
 - Faça uma crítica da análise e indique o que poderia ser feito para melhorá-la (mesmo não que não saiba implementar suas sugestões).

Tabela 6.16: Porcentagem de eleitores favoráveis

Fonte	Data	Dilma	Serra	Fonte	Data	Dilma	Serra
sensus	16/02/2008	4,5	38,2	sensus	13/08/2009	19	39,5
dataf	27/03/2008	3	38	ibope	04/09/2009	14	34
sensus	25/04/2008	6,2	36,4	sensus	14/09/2009	21,7	31,8
sensus	19/09/2008	8,4	38,1	ibope	20/11/2009	17	38
dataf	28/11/2008	8	41	vox	30/11/2009	17	39
sensus	30/11/2008	10,4	46,5	vox	07/12/2009	18	39
ibope	12/12/2008	5	42	dataf	14/12/2009	23	37
sensus	14/12/2008	13,3	42,8	vox	18/12/2009	27	34
dataf	30/01/2009	11	41	sensus	17/01/2010	27	33,2
sensus	19/03/2009	16,3	45,7	ibope	29/01/2010	25	36
dataf	27/03/2009	16	38	dataf	06/02/2010	28	32
sensus	28/05/2009	23,5	40,4	ibope	25/02/2010	30	35
ibope	29/05/2009	18	38	dataf	27/03/2010	27	36
dataf	01/06/2009	17	36	vox	31/03/2010	31	34

- 8) Uma fábrica de cadeiras dispõe dos seguintes dados sobre sua produção mensal:

Número de cadeiras produzidas	105	130	141	159	160	172
Custos fixos e variáveis (R\$)	1700	1850	1872	1922	1951	1970

- Proponha um modelo de regressão linear simples para a relação entre o custo e o número de cadeiras produzidas e interprete os parâmetros.
- Utilize um intervalo de confiança com coeficiente de confiança de 95% para estimar o custo esperado de produção para 200 cadeiras.
- Admitindo que o preço de venda é de R\$ 20,00 por unidade, qual a menor quantidade de cadeiras que deve ser produzida para que o lucro seja positivo?

- 9) Considere a seguinte reta de regressão ajustada a um conjunto de dados em que se pretendia estimar o volume de certos recipientes (V) a partir de seus diâmetros (D): $E(V) = 7,68 + 0,185D$

Podemos dizer que:

- a) O volume esperado não pode ser estimado a partir do diâmetro.
 - b) O coeficiente de correlação linear entre as duas variáveis é nulo.
 - c) Há um aumento médio de 0,185 unidades no volume com o aumento de uma unidade de diâmetro.
 - d) O valor estimado do volume é 7,68 unidades para diâmetros iguais a 1 unidade.
- 10) No artigo intitulado “Estimativas do Valor Energético a partir de Características Químicas e Bromatológicas dos Alimentos” (Rev. Bras. Zootec., 30: 1837-1856, 2001) estudou-se a disponibilidade de energia de alimentos considerando os nutrientes digestíveis totais (NDT) e também as análises químicas e metabólicas das dietas. Nele se apresentam os gráficos apresentados nas Figuras 6.35 e 6.36:

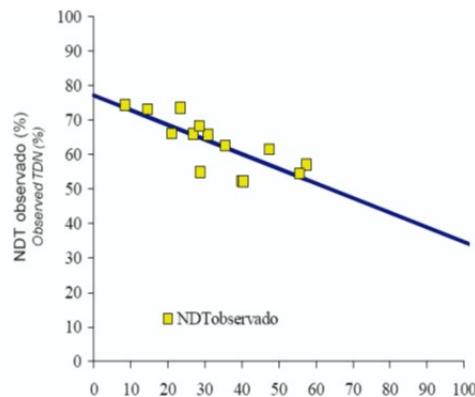


Figura 6.35: Relação entre o NDT e a fibra em detergente ácido (FDA) nas dietas totais. A linha contínua representa a reta obtida pela equação de regressão $NDT=77,13-0,4250FDA$ ($r^2=0,59$; $P<0,01$).

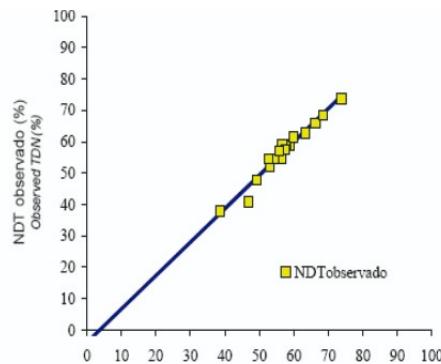


Figura 6.36: Relação entre o NDT e a digestibilidade da matéria seca (DMS) nas dietas totais. A linha contínua representa a reta obtida pela equação de regressão $NDT=3,84+1,064DMS$ ($r^2=0,96$; $P<0,01$).

- a) Qual variável (FDA ou DMS) tem maior correlação linear com o NDT?
Justifique.
- b) Calcule o valor esperado de NDT para porcentagem da digestibilidade da matéria seca igual a 47.
- 11) Para avaliar o efeito da dose (D) de uma certa droga na redução da pressão arterial ($RedPA$) controlando o sexo (S) do paciente, o seguinte modelo de regressão foi ajustado a um conjunto de dados:
- $$E(RedPA) = 2 + 0.3S + 1.2(D - 10)$$
- em que $S = 0$ (Masculino) e $S = 1$ (Feminino). Indique a resposta correta:
- a) A redução esperada da PA (mmHg) para uma dose de 20 mg é igual para homens e mulheres.
 - b) Com dose de 10 mg, a redução de PA esperada para mulheres é menor do que para homens.
 - c) O coeficiente da variável Sexo não poderia ser igual a 0.3.
 - d) Uma dose de 20 mg reduz a PA esperada para homens de 12 mmHg
 - e) Nenhuma das anteriores.
- 12) O gráfico QQ da Figura 6.40 corresponde ao ajuste de um modelo de regressão linear múltipla.

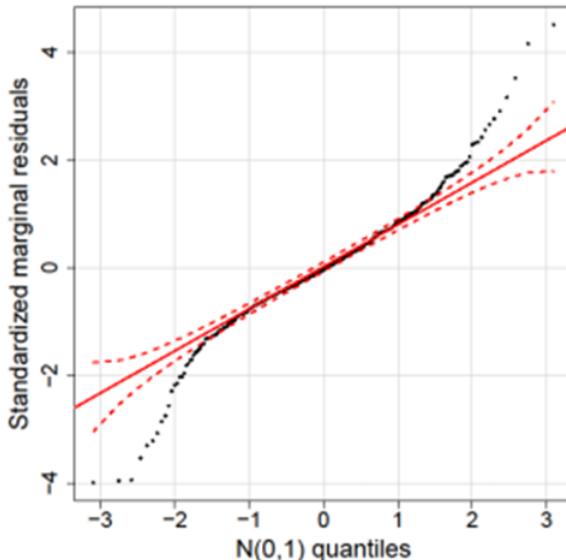


Figura 6.37: Gráfico QQ correspondente ajuste de um modelo de regressão linear múltipla.

Pode-se afirmar que:

- a) Há indicações de que a distribuição dos erros é Normal.
- b) Há evidências de que a distribuição dos erros é assimétrica.
- c) Há evidências de que a distribuição dos erros tem caudas mais leves do que aquelas da distribuição Normal.

- d) Há evidências de que a distribuição dos erros tem caudas mais pesadas que aquelas da distribuição Normal.
- e) Nenhuma das anteriores.
- 13) Para o Exemplo 6.2, use a função `lm()` do R para ajustar o modelo contendo termos quadrático e cúbico.
- 14) Obtenha o modelo ajustado para o Exemplo 6.3, usando a função `lm()` e avalie a qualidade do ajuste utilizando todas as técnicas de diagnóstico discutidas neste capítulo.
- 15) Mostre que $SQTot = SQRes + SQReg$.
- 16) Os dados disponíveis no arquivo `profilaxia` são provenientes de um estudo realizado na Faculdade de Odontologia da Universidade de São Paulo para avaliar o efeito do uso contínuo de uma solução para bochecho no pH da placa bacteriana dentária. O pH da placa dentária retirada de 21 voluntários antes e depois de um período de uso de uma solução para bochecho foi avaliado ao longo de 60 minutos após a adição de sacarose ao meio em que as unidades experimentais foram colocadas.
- Construa um gráfico de perfis para os dados obtidos antes do período de uso da solução para bochecho. Obtenha a matriz de covariâncias bem como o gráfico do desenhistador correspondente.
 - Concretize as solicitações do item a) para os dados obtidos após a utilização da solução para bochecho.
 - Construa gráficos de perfis médios para os dados obtidos antes e depois da utilização da solução para bochecho colocando-os no mesmo painel.
 - Com base nos resultados dos itens a)-c), proponha um modelo de regressão polinomial que permita a comparação dos parâmetros correspondentes.
- 17) Os dados disponíveis no arquivo `esforco` são oriundos de um estudo realizado na Faculdade de Medicina da Universidade de São Paulo para avaliar pacientes com insuficiência cardíaca. Foram estudados 87 pacientes com algum nível de insuficiência cardíaca avaliada pelo critério NYHA, além de 40 pacientes controle (coluna K). Para cada paciente foram registradas algumas características físicas (altura, peso, superfície corporal, idade, sexo). Eles foram submetidos a um teste de esforço cardiopulmonar em cicloergômetro em que foram medidos a frequência cardíaca, o consumo de oxigênio, o equivalente ventilatório de oxigênio, o equivalente ventilatório de dióxido de carbono, o pulso de oxigênio e a pressão parcial de dióxido de carbono ao final da expiração, em três momentos diferentes: no limiar anaeróbico, no ponto de compensação respiratória e no pico do exercício.
- Ajuste um modelo linear tendo como variável resposta o consumo de oxigênio no pico do exercício (coluna AW) e como variáveis explicativas a carga na esteira ergométrica (coluna AU), a classificação NYHA (coluna K) além de frequência cardíaca (coluna AV), razão de troca respiratória (coluna AX), peso (coluna H), sexo (coluna D) e idade (coluna F). Com essa finalidade, você deve:
- Construir gráficos de dispersão convenientes.
 - Interpretar os diferentes parâmetros do modelo.
 - Estimar os parâmetros do modelo e apresentar os respectivos erros padrões.

- d) Avaliar a qualidade de ajuste do modelo por meio de gráficos de diagnóstico (resíduos, QQ, distância de Cook, etc).
 - e) Identificar as variáveis significativas.
 - f) Reajustar o modelo com base nas conclusões do item (e) e avaliar o seu ajuste.
 - g) Apresentar conclusões evitando jargão técnico.
- 18) Para estudar a associação entre gênero (1=Masc, 0=Fem) e idade (anos) e a preferência (1=sim, 0=não) pelo refrigerante Kcola, o seguinte modelo de regressão logística foi ajustado aos dados de 50 crianças escolhidas ao acaso:

$$\log \left\{ \frac{\pi_i(x_i, w_i)}{1 - \pi_i(x_i, w_i)} \right\} = \alpha + \beta x_i + \gamma(w_i - 5),$$

em que x_i (w_i) representa o gênero (idade) da i -ésima criança e $\pi_i(x_i, w_i)$ a probabilidade de uma criança do gênero x_i e idade w_i preferir Kcola. As seguintes estimativas para os parâmetros foram obtidas:

Parâmetro	Estimativa	Erro padrão	Valor p
α	0,69	0,12	< 0,01
β	0,33	0,10	< 0,01
γ	-0,03	0,005	< 0,01

- a) Interprete os parâmetros do modelo por intermédio de chances e razões de chances,
 - b) Com as informações acima, estime a razão de chances de preferência por Kcola correspondente à comparação de crianças do mesmo gênero com 10 e 15 anos,
 - c) Construa intervalos de confiança (com coeficiente de confiança aproximado de 95%) para $\exp(\beta)$ e $\exp(\gamma)$ e traduza o resultado em linguagem não técnica,
 - d) Estime a probabilidade de meninos com 15 anos preferirem Kcola.
- 19) Mostre que as expressões (6.29) e (6.30) são equivalentes e que garantem que a probabilidade de que $Y = 1$ estará no intervalo $(0, 1)$ independentemente dos valores de α , β e x_i .
- 20) Mostre que o parâmetro β no modelo (6.29) corresponde ao logaritmo da razão de chances de resposta positiva para pacientes com diferença de uma unidade na variável explicativa.
- 21) Os dados da Tabela 6.17 contêm dados de uma investigação cujo objetivo era estudar a relação entre a duração de diabete e a ocorrência de retinopatia (uma moléstia dos olhos). Ajuste um modelo de regressão logística para avaliar a intensidade dessa relação.

Sugestão: Considere o ponto médio de cada intervalo como valor da variável explicativa.

Tabela 6.17: Frequências de retinopatia

Duração da Diabete (anos)	Retinopatia	
	Sim	Não
0 - 2	17	215
3 - 5	26	218
6 - 8	39	137
9 - 11	27	62
12 - 14	35	36
15 - 17	37	16
18 - 20	26	13
21 - 23	23	15

- 22) Considere os dados do arquivo `endometriose2`. Com objetivo inferencial, ajuste um modelo de regressão logística, tendo `endometriose` como variável resposta e `idade`, `dormenstrual`, `dismenorreia` e `tipoesteril` como variáveis explicativas. Interprete os coeficientes do modelo em termos de chances e razões de chances.

Análise de Sobrevivência

All models are wrong, but some are useful.

George Box

7.1 Introdução

Análise de Sobrevivência lida com situações em que o objetivo é avaliar o tempo decorrido até a ocorrência de um evento, como a morte ou cura de pacientes submetidos a um certo tratamento, a quebra de um equipamento mecânico ou o fechamento de uma conta bancária. Em Engenharia, esse tipo de problema é conhecido sob a denominação de **Análise de Confiabilidade**.

Nesse contexto, duas características são importantes: a definição do tempo de sobrevivência e do evento, também chamado de **falla**.¹ Nossa objetivo aqui é apresentar os principais conceitos envolvidos nesse tipo de análise. O leitor pode consultar Colosimo e Giolo (2006) ou Lee and Wang (2003) entre outros para uma exposição mais detalhada.

Exemplo 7.1: Num estudo realizado no Instituto de Ciências Biológicas (ICB) da Universidade de São Paulo, o objetivo era verificar se lesões em áreas do sistema nervoso de ratos influenciam o padrão de memória. Com essa finalidade, três grupos de ratos foram submetidos a diferentes tipos de cirurgias, a saber,

GRUPO 1: em que lesões pequenas foram induzidas no giro denteadoo dorsal (região supostamente envolvida com memória espacial);

GRUPO 2: em que lesões pequenas foram induzidas no giro denteadoo ventral;

GRUPO 3: (controle) em que apenas o trauma cirúrgico (sem lesões induzidas) foi aplicado.

Após a recuperação da cirurgia, os ratos foram submetidos a um treinamento em que eram deixados em uma piscina de água turva contendo uma plataforma fixa. Se não encontrasse a plataforma em 2 minutos, o rato era conduzido até ela. Após uma semana, mediu-se o tempo até o rato encontrar a plataforma. Nesse estudo, a variável resposta é o tempo até o encontro da plataforma (evento ou falha). A origem do tempo é o instante em que o animal é colocado na piscina.

¹Apesar dessa terminologia, falha pode ter tanto uma conotação negativa, como a morte de um paciente, quanto positiva, como a sua cura.

Um dos problemas encontrados em estudos de sobrevivência é que nem sempre o instante de ocorrência do evento e consequentemente, o tempo exato de sobrevivência são conhecidos. Essa característica é conhecida como **censura**. No entanto, sabe-se que o tempo é maior que um determinado valor chamado de **tempo de censura**. Ver Nota de Capítulo 1. No caso de estudos na área de saúde, possíveis razões para censura são

- i) o evento não ocorre antes do fim do estudo;
- ii) há perda de contacto com o paciente durante o estudo;
- iii) o paciente sai do estudo por outros motivos (morte por outra razão/fim do tratamento devido a efeitos colaterais etc.).

No Exemplo 7.1, a censura ocorreu para os animais que não encontraram a plataforma em 2 minutos.

Por esse motivo, a variável resposta de estudos de sobrevivência é definida pelo par (T, δ) em que T é o tempo associado a cada unidade amostral e δ é um indicador de censura, com valor 1 quando ocorre a falha e 0 em caso contrário (censura). Um exemplo de organização de dados dessa natureza está apresentado na Tabela 7.1.

Tabela 7.1: Modelo para organização de dados censurados

Unidade amostral	Tempo	Censura
A	5.0	1
B	12.0	0
C	3.5	0
D	8.0	0
E	6.0	0
F	3.5	1

Um esquema indicando a estrutura de dados de sobrevivência está disposto na Figura 7.1 em que t_0 e t_c indicam, respectivamente, os instantes de início e término do estudo. Os casos com $\delta = 1$ indicam falhas e aqueles com $\delta = 0$ indicam censuras.

Para caracterizar a variável resposta (que é positiva) usualmente emprega-se a **função de sobrevivência** definida como

$$S(t) = P(T > t) = 1 - P(T \leq t) = 1 - F(t)$$

em que $F(t)$ é a função distribuição acumulada da variável T . Essencialmente, a função de sobrevivência calculada no instante t é a probabilidade de sobrevivência por mais do que t . Uma representação gráfica da função de sobrevivência está apresentada na Figura 7.2.

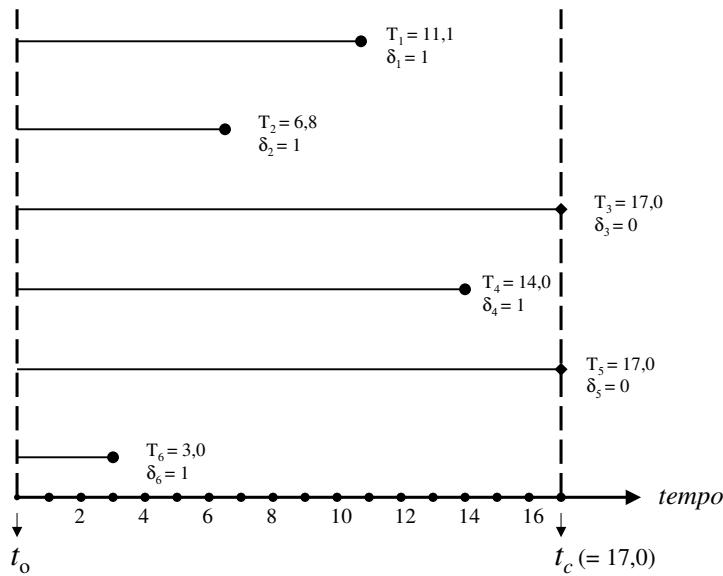


Figura 7.1: Representação esquemática de dados de sobrevivência.

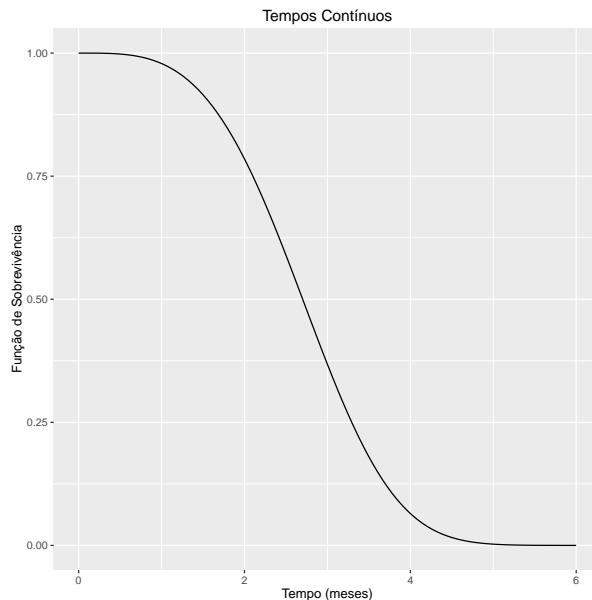


Figura 7.2: Função de sobrevivência teórica.

Na prática, como os tempos em que ocorrem falhas são medidos como variáveis discretas, a função de sobrevivência tem o aspecto indicado na Figura 7.3.

Outra função de interesse na análise de dados de sobrevivência é a **função de**

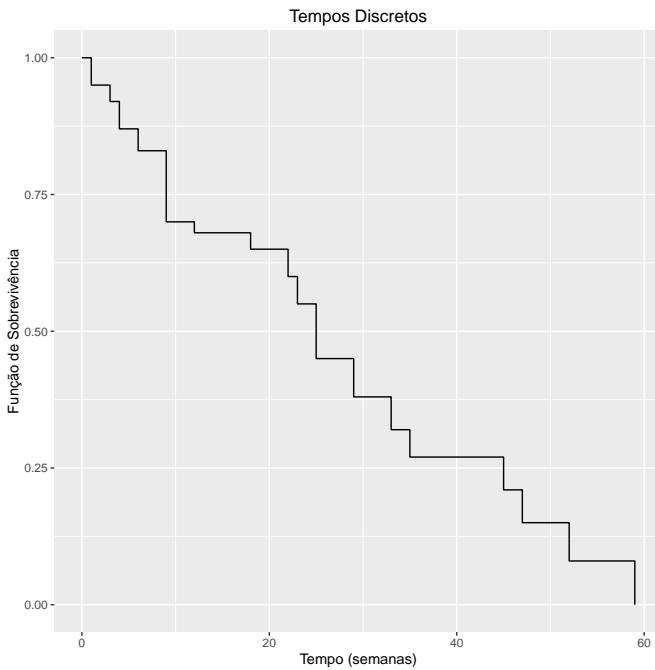


Figura 7.3: Função de sobrevivência observada.

risco (*hazard function*) definida como

$$h(t) = \lim_{dt \rightarrow 0} \frac{P(t \leq T < t + dt) | T \geq t}{dt} \approx \frac{P(T = t)}{P(T \geq t)}.$$

Essencialmente, essa função corresponde ao “potencial instantâneo de ocorrência do evento de interesse por unidade de tempo, dado que a falha não ocorreu até o instante t ”, ou seja, “ao risco de ocorrência do evento de interesse no instante t para uma unidade amostral ainda não sujeita ao evento”. Note que $h(t) \geq 0$ e não tem um valor máximo (pode ser infinito). Na prática, essa função dá uma ideia do comportamento da taxa condicional de falha e fornece informação para a escolha de um modelo probabilístico adequado ao fenômeno estudado.

Exemplos de funções de risco com diferentes padrões estão apresentados na Figura 7.4. No painel a), o risco de falha é constante e corresponde ao risco para pessoas sadias, por exemplo; nesse caso, um modelo probabilístico adequado é o **modelo exponencial**. No painel b), o risco de falha cresce com o tempo e usualmente é empregado para representar o risco para pacientes com alguma doença grave; um modelo probabilístico adequado é o **modelo Weibull**. No painel c), o risco de falha decresce com o tempo e usualmente é empregado para representar riscos pós cirúrgicos; um modelo probabilístico adequado nesse caso também é um modelo Weibull. No painel d), inicialmente o risco de falha cresce e posteriormente decresce, sendo adequado para situações em que um tratamento tem um certo tempo para fazer efeito, por exemplo; um modelo probabilístico adequado nesse caso, é o **modelo log normal**.

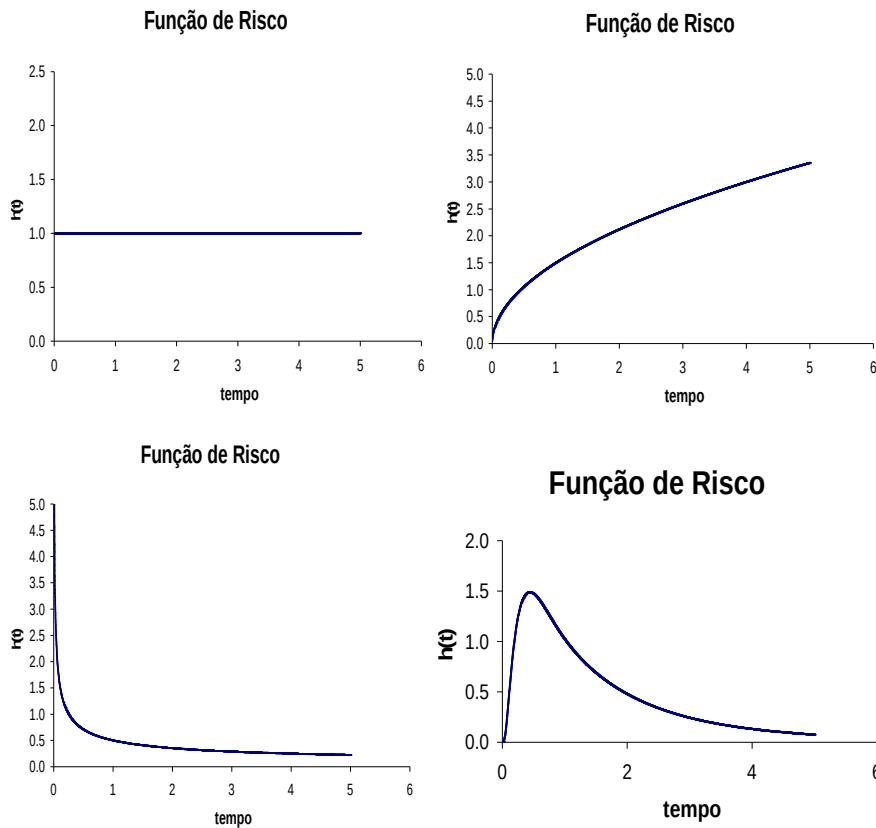


Figura 7.4: Exemplos de funções de risco

As funções de sobrevivência e de risco contêm a mesma informação e cada uma delas pode ser obtida a partir da outra por meio das relações

$$h(t) = -\frac{S'(t)}{S(t)} \text{ e } S(t) = \exp\left[-\int_0^t h(s)ds\right]$$

em que $S'(t)$ indica a derivada de S calculada no instante t .

Os objetivos operacionais da Análise de Sobrevivência são:

- estimar e interpretar a função de sobrevivência;
- interpretar funções de risco;
- comparar funções de sobrevivência (ou funções de risco);
- averiguar a contribuição de fatores de interesse (variáveis explicativas) para a ocorrência de falhas.

7.2 Estimação da função de sobrevivência

Para dados não censurados, a função distribuição empírica da variável T é

$$\hat{F}(t) = \frac{\text{número de observações} \leq t}{\text{número de observações}}$$

e consequentemente, um estimador da função de sobrevivência é $\hat{S}(t) = 1 - \hat{F}(t)$. Para dados censurados, o **estimador de Kaplan-Meier** também conhecido como **estimador do limite de produtos** (*product limit estimator*) é o mais utilizado na prática e é baseado na representação da sobrevivência num instante t como um produto de probabilidades de sobrevivência a intervalos de tempo disjuntos anteriores a t . Consideremos um exemplo em que o tempo até a cura de uma moléstia é medido em dias e que ocorreram falhas nos instantes $t = 2, t = 5$ e $t = 8$; a função de sobrevivência calculada no dia 10 (aqui interpretada como a probabilidade de cura após o décimo dia) pode ser calculada a partir de

$$\begin{aligned} S(10) &= P(T > 10) = P(T > 10 \cap T > 8) = P(T > 10|T > 8)P(T > 8) \\ &= P(T > 10|T > 8)P(T > 8|T > 5)P(T > 5) \\ &= P(T > 10|T > 8)P(T > 8|T > 5)P(T > 5|T > 2)P(T > 2). \end{aligned}$$

Lembrando que $t_{(0)} = t_0 = 0$ corresponde ao início do estudo, e que $S(0) = P(T > 0) = 1$, podemos generalizar esse resultado, obtendo

$$S[t_{(j)}] = \prod_{i=1}^j P[T > t_{(i)}|P(T > t_{(i-1)})].$$

Na prática, para a estimação da função de sobrevivência, os instantes $t_{(j)}$ de interesse são aqueles em que ocorreram falhas ou censuras. Definindo $R[t_{(i)}]$ como o número de unidades em risco no instante $t_{(i)}$ e M_i como o número de falhas ocorridas exatamente nesse instante, uma estimativa da probabilidade de que uma unidade sobreviva ao instante $t_{(i)}$ é

$$P(T > t_{(i)}) = \{R[t_{(i)}] - M_i\}/R[t_{(i)}] = 1 - M_i/R[t_{(i)}].$$

Nesse contexto, o estimador de Kaplan-Meier é definido como

$$\hat{S}(t) = 1 \text{ se } t < t_{(1)}$$

ou

$$\hat{S}(t) = \prod_{t_{(i)} < t} \{1 - M_i/R[t_{(i)}]\} \text{ se } t_{(i)} < t.$$

A variância desse estimador pode ser estimada como

$$\text{Var}[\hat{S}(t)] = [\hat{S}(t)]^2 \sum_{t_{(i)} < t} \frac{M_i}{R[t_{(i)}]\{R[t_{(i)}] - M_i\}}.$$

Exemplo 7.2: Consideremos um conjunto de $n = 21$ unidades para as quais os tempos de falhas ou censuras (representadas por +) são 6, 6, 6, 7, 10, 13, 16, 22, 23, 6+, 9+, 10+, 11+, 17+, 19+, 20+, 25+, 32+, 32+, 34+, 35+. Para efeito do cálculo do estimador de Kaplan-Meier, convém dispor os dados no formato da Tabela 7.2.

Tabela 7.2: Formato apropriado para cálculo do estimador de Kaplan-Meier (Exemplo 7.2)

j	Tempo $t_{(j)}$	Falhas em $t_{(j)}$	Censuras em $(t_{(j-1)}, t_{(j)})$	Unidades em risco ($R[t_{(j)}]$)	$\hat{S}[t_{(j)}]$
0	0	0	0	21	1
1	6	3	1	21	$1 \times 18/21 = 0,86$
2	7	1	1	$17 = 21-(3+1)$	$0,86 \times 16/17 = 0,81$
3	10	1	2	$15 = 17-(1+1)$	$0,81 \times 14/15 = 0,75$
4	13	1	0	$12 = 15-(1+2)$	$0,75 \times 11/12 = 0,69$
5	16	1	3	$11 = 12-(1+0)$	$0,69 \times 10/11 = 0,63$
6	22	1	0	$7 = 11-(1+3)$	$0,63 \times 6/7 = 0,54$
7	23	1	5	$6 = 7-(1+0)$	$0,54 \times 5/6 = 0,45$

Um gráfico da função de sobrevivência estimada pelo método de Kaplan-Meier está apresentado na Figura 7.5. Os “saltos” representam as falhas e as cruzes representam as censuras. Esse gráfico pode ser obtido por meio das funções `Surv`, `survfit` e `ggsurvplot` dos pacotes `survival` e `survminer` do repositório R.

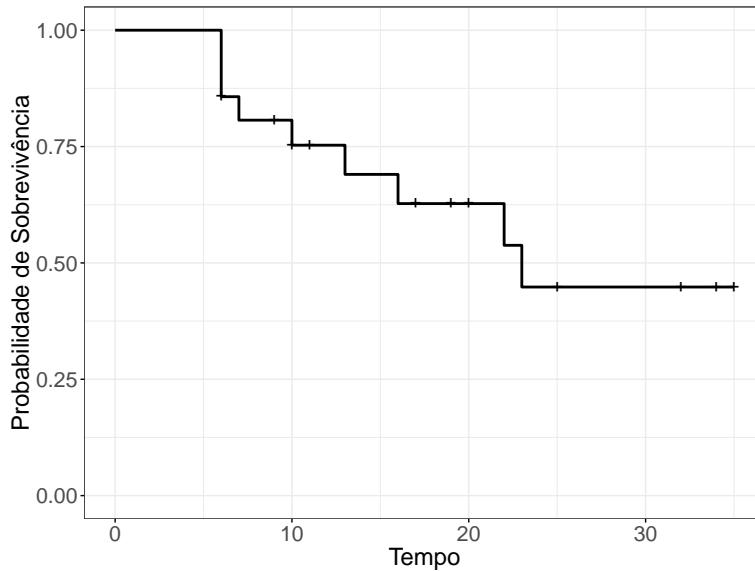


Figura 7.5: Curva de sobrevivência estimada para o Exemplo 7.2.

A área sob a curva baseada no estimador de Kaplan-Meier é um estimador do **tempo médio de acompanhamento** limitado à duração do estudo e definido como

$$\mu = \int_0^{t_c} S(t) dt.$$

Além disso, um estimador do **tempo mediano de sobrevivência** é

$$T_{med} = \{\inf t : S(t) \leq 0.5\}$$

ou seja, é o menor valor de t para o qual o valor da função de sobrevivência é menor ou igual a 0,5. De uma forma mais geral, um estimador do p -ésimo quantil ($0 < p < 1$) do tempo de sobrevivência é $T_p = \{\inf t : S(t) \leq 1 - p\}$. Para o Exemplo 7.2, o tempo médio de acompanhamento é 23,29 (com erro padrão 2,83) e o tempo mediano de sobrevivência é 23,00 (com erro padrão 5,26).

Estimativas para as curvas de sobrevivência referentes ao Exemplo 7.1 estão dispostas na Figura 7.6 e estatísticas daí decorrentes, na Tabela 7.3

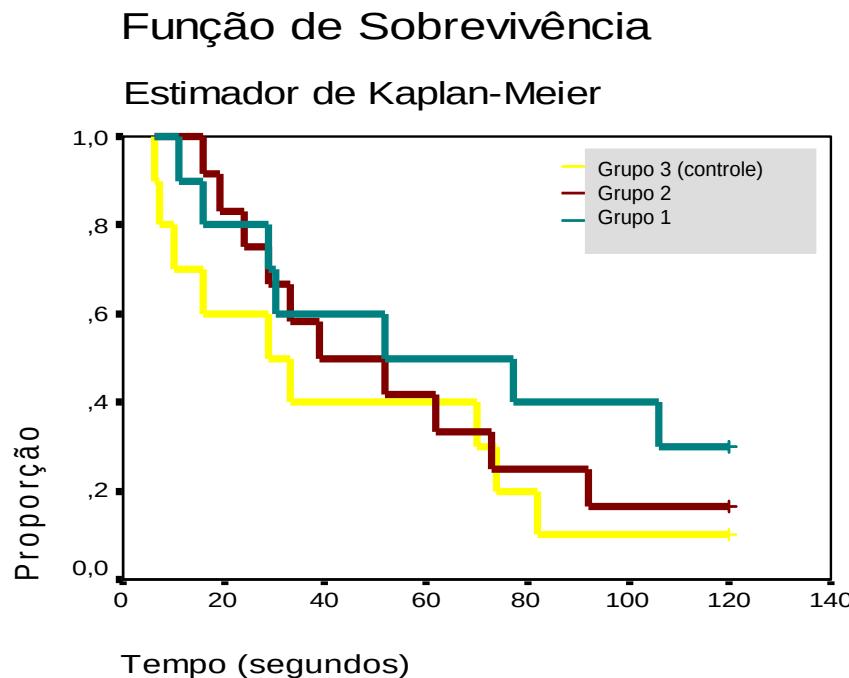


Figura 7.6: Curva de sobrevivência estimada para o Exemplo 7.1.

Tabela 7.3: Estatísticas descritivas com erros padrões entre parênteses (Exemplo 7.1)

Tratamento	Censuras	Tempo Médio	Primeiro Quartil	Tempo Mediano	Terceiro Quartil
Grupo 1	30%	68,1 (13,7)	-	52,0 (37,2)	29,0 (18,8)
Grupo 2	17%	56,6 (10,3)	73,0 (22,5)	39,0 (16,5)	24,0 (7,5)
Grupo 3	10%	44,7 (11,8)	74,0 (5,1)	29,0 (13,4)	10,0 (4,4)

Em muitos casos, os arquivos com dados de sobrevivência contêm as datas de início do estudo e ocorrência do evento de interesse ou de censura e essas datas precisam ser transformadas em intervalos de tempo.

Exemplo 7.3: Os dados disponíveis no arquivo `hiv` foram obtidos de um estudo cujo objetivo era avaliar o efeito do uso de drogas intravenosas no tempo de sobrevivência de pacientes HIV positivos e têm o formato indicado na Tabela 7.4.

Tabela 7.4: Formato dos dados correspondentes ao Exemplo 7.3

ident	datainicio	datafim	idade	droga	delta
1	15mai90	14out90	46	0	1
2	19set89	20mar90	35	1	0
3	21abr91	20dez91	30	1	1
4	03jan91	04abr91	30	1	1
:	:	:	:	:	:
98	02abr90	01abr95	29	0	0
99	01mai91	30jun91	35	1	0
100	11mai89	10jun89	34	1	1

Nesse exemplo, a variável `delta` = 1 indica a ocorrência do evento e `delta` = 0, uma censura.

No exemplo, a primeira dificuldade é ler as datas no formato indicado utilizando alguma função do repositório R. Uma sugestão é utilizar o comando `find/replace` ou equivalente na própria planilha em que os dados estão disponíveis e substituir `jan` por `/01/`, por exemplo. Em seguida pode-se utilizar a função `as.Date` para transformar as datas no formato `dd/mm/aa` no número de dias desde 01 de janeiro de 1970, com datas anteriores assumindo valores negativos. Consequentemente, o intervalo de tempo entre as datas de início do estudo e aquela de ocorrência do evento ou de censura pode ser calculada por diferença, deixando os dados no formato indicado na Tabela 7.1. A partir daí podem-se utilizar as mesmas funções empregadas para análise dos dados do Exemplo 7.2 para gerar as curvas de Kaplan-Meier dispostas na Figura 7.7.

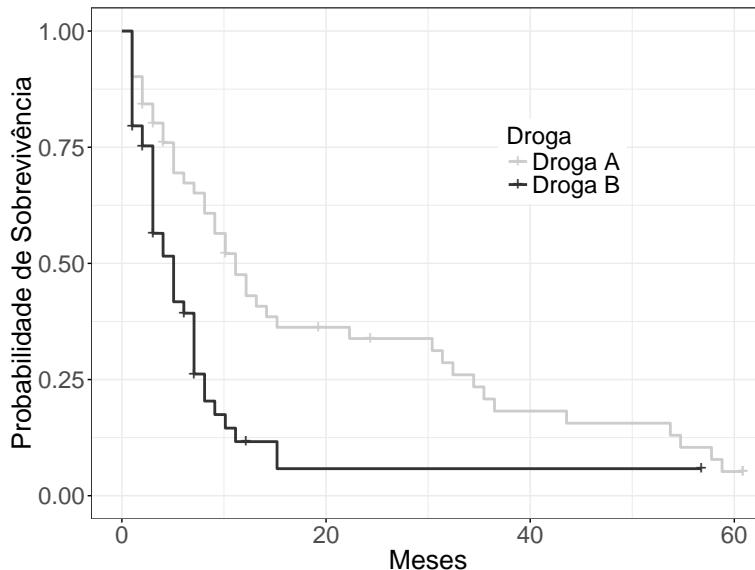


Figura 7.7: Curvas de sobrevida estimadas para o Exemplo 7.3.

7.3 Comparação de curvas de sobrevivência

Um dos problemas oriundos de estudos como aquele descrito no Exemplo 7.1 é a comparação das curvas de sobrevivência associadas aos tratamentos. Para efeito didático, simplifiquemos o problema, restringindo-nos à comparação das curvas de sobrevivência de dois grupos. Essencialmente, queremos saber se, com base nas curvas de Kaplan-Meier, $\hat{S}_1(t)$ e $\hat{S}_2(t)$ obtidas de duas amostras podemos concluir que as curvas de sobrevivência $S_1(t)$ e $S_2(t)$, associadas às populações de onde as amostras foram selecionadas, são iguais. Uma alternativa disponível para esse propósito é o teste *log rank*, baseado na comparação de valores esperados e observados.

Sejam t_j , $j = 1, \dots, J$ os tempos em que ocorreram falhas em qualquer dos dois grupos. Para cada um desses tempos, sejam R_{1j} e R_{2j} os números de unidades em risco nos grupos 1 e 2, respectivamente e seja $R_j = R_{1j} + R_{2j}$. Similarmente, sejam O_{1j} e O_{2j} , respectivamente, os números de falhas nos grupos 1 e 2 no tempo t_j e seja $O_j = O_{1j} + O_{2j}$. Dado o número de falhas (em ambos os grupos) ocorridas no tempo t_j é O_j , a estatística O_{1j} tem uma distribuição hipergeométrica quando a hipótese de igualdade das funções de sobrevivência é verdadeira. Sob essas condições, o valor esperado e a variância de O_{1j} são, respectivamente,

$$\mathbb{E}(O_{1j}) = E_{1j} = O_{1j} \frac{O_j}{R_j} \text{ e } \text{Var}(O_{1j}) = V_j = \frac{O_j(R_{1j}/R_j)(R_j - O_j)}{R_j - 1}.$$

A estatística *log rank* de teste,

$$LR = \frac{\sum_{j=1}^J [O_{1j} - E_{1j}]^2}{\sum_{j=1}^J V_j}$$

tem uma distribuição aproximada χ_1^2 (qui quadrado com um grau de liberdade) sob a hipótese nula.

Extensões desse teste para a comparação de três ou mais curvas de sobrevivência assim como outros testes construídos para os mesmos propósitos podem ser encontrados nas referências citadas no início deste capítulo.

7.4 Regressão para dados de sobrevivência

Problemas em que o objetivo é avaliar o efeito de variáveis explicativas na distribuição do tempo de falhas (sobrevivência) são similares àqueles tratados no Capítulo 6 com a diferença de que a variável resposta (tempo) só pode assumir valores positivos. A distribuição adotada deve ser escolhida entre aquelas que têm essa característica como as distribuições exponencial, Weibull, log normal ou Birnbaum-Saunders entre outras. Modelos nessa classe são chamados **modelos paramétricos** e geralmente são expressos na forma do **modelo de tempo de falha acelerado** (*accelerated failure time models*),

$$\log(T) = \alpha + \mathbf{x}^\top \boldsymbol{\beta} + \sigma e$$

em que α e $\boldsymbol{\beta}$ são parâmetros, \mathbf{x} é um vetor com valores de variáveis explicativas, $\sigma > 0$ é uma constante conhecida e e é um erro aleatório com distribuição de forma conhecida. Com uma única variável explicativa dicotômica com valores 0 ou 1, o modelo é

$$\log(T) = \alpha + \beta x + \sigma e.$$

O tempo de falha para uma unidade com $x = 0$ é $T_0 = \exp(\alpha + \sigma e)$; para uma unidade com $x = 1$, o tempo de falha é $T_1 = \exp(\alpha + \beta + \sigma e)$. Então, se $\beta > 0$, teremos $T_1 > T_0$; por outro lado, se $\beta < 0$, teremos $T_1 < T_0$ o que implica que a covariável **x acelera** ou **desacelera** o tempo de falha. A relação entre algumas distribuições para T e $\log(T)$ está indicada na Tabela 7.5.

Tabela 7.5: Relação entre algumas distribuições para T e $\log(T)$

Distribuição de	
T	$\log(T)$
exponencial	Valores extremos
Weibull	Valores extremos
logística	logística
log normal	normal

Esses modelos podem ser ajustados por meio do método da máxima verossimilhança. Detalhes podem ser obtidos nas referências citadas no início do capítulo.

Uma alternativa são os **modelos semiparamétricos** em que se destaca o **modelo de riscos proporcionais** (*proportional hazards model*) também conhecidos como **modelos de regressão de Cox** e expressos como

$$h(t|\mathbf{X} = \mathbf{x}) = h_0(t) \exp(\boldsymbol{\beta}^\top \mathbf{x})$$

em que $h_0(t)$ representa a função de risco basal, *i.e.*, para $\mathbf{X} = \mathbf{0}$ e $\exp(\boldsymbol{\beta}^\top \mathbf{x})$ é a **função de risco relativo** com parâmetros $\boldsymbol{\beta}$ e cujo valor no ponto \mathbf{x} corresponde ao quociente entre o risco de falha para uma unidade com variáveis explicativas iguais a \mathbf{x} e o o risco de falha para uma unidade com variáveis explicativas iguais a $\mathbf{0}$.

Essa classe de modelos é uma das mais utilizadas na análise de dados de sobrevivência e tem as seguintes vantagens

- i) não requer a especificação da forma da função de risco;
- ii) os resultados obtidos por meio da formulação mais simples (com apenas dois grupos) são equivalentes àqueles obtidos com o teste *log rank*;
- iii) permite a avaliação de várias variáveis explicativas simultaneamente.

Consideremos um estudo em que pacientes com as mesmas características são submetidos de forma aleatória a dois tratamentos: placebo ($x = 0$) e ativo ($x = 1$). Então, sob o modelo de Cox temos:

$$\frac{h(t|x=1)}{h(t|x=0)} = \frac{h_0(t) \exp(\alpha + \beta)}{h_0(t) \exp(\alpha)} = \exp(\beta)$$

indicando que para qualquer valor de t o risco relativo de falha é constante. Daí a denominação de riscos proporcionais. Por essa razão, o modelo de Cox só deve ser considerado nessa situação. Ver Nota de Capítulo 2. Uma ferramenta útil para avaliação dessa suposição é o gráfico das curvas de sobrevivência obtido por intermédio do estimador de Kaplan-Meier. Análise de resíduos também pode ser utilizada com esse propósito.

7.5 Notas de Capítulo

1) Tipos de censura

Três tipos de censura podem ser consideradas em estudos de sobrevivência:

- a) **censura à direita**, para a qual se conhece o instante em que uma característica de interesse (por exemplo, contaminação pelos vírus HIV) ocorreu porém a falha (por exemplo, morte do paciente) não foi observada após a inclusão da unidade no estudo.
 - b) **censura à esquerda**, para a qual não se conhece o instante de ocorrência da característica de interesse porém a falha foi observada após a inclusão da unidade no estudo.
 - c) **censura intervalar**, para a qual não se conhece o instante em que a falha ocorreu, mas sabe-se que ocorreu num intervalo de tempo conhecido.
- 2) Para situações em que os riscos não são proporcionais, algumas alternativas podem ser consideradas para o modelo de Cox, lembrando que não são isentas de dificuldades de interpretação. Entre elas, destacamos
- a) Determinar instantes de tempo em que ocorre mudança no padrão da sobrevivência.
 - b) Ajustar modelos diferentes para intervalos de tempo distintos.
 - c) Refinar o modelo com a inclusão de variáveis explicativas dependentes do tempo.

7.6 Exercícios

- 1) Num estudo realizado no Instituto do Coração da FMUSP, candidatos a transplante foram acompanhados durante o período de espera por um coração. O tempo até o evento de interesse (aqui chamado de tempo de sobrevivência) foi definido como o número de dias decorridos entre a primeira consulta de avaliação e o procedimento cirúrgico. Para detalhes, consulte Pedroso de Lima et al. (2000). Entre possíveis fatores que poderiam influenciar o tempo até o transplante está a presença de insuficiência tricúspide. Para avaliar a importância desse fator, foram construídas curvas de sobrevivência pelo método de Kaplan-Meier e realizada uma análise baseada no modelo de riscos proporcionais de Cox, com ajuste por sexo, idade e etiologia. Os resultados estão indicados na Figura 7.8 e na Tabela 7.6.

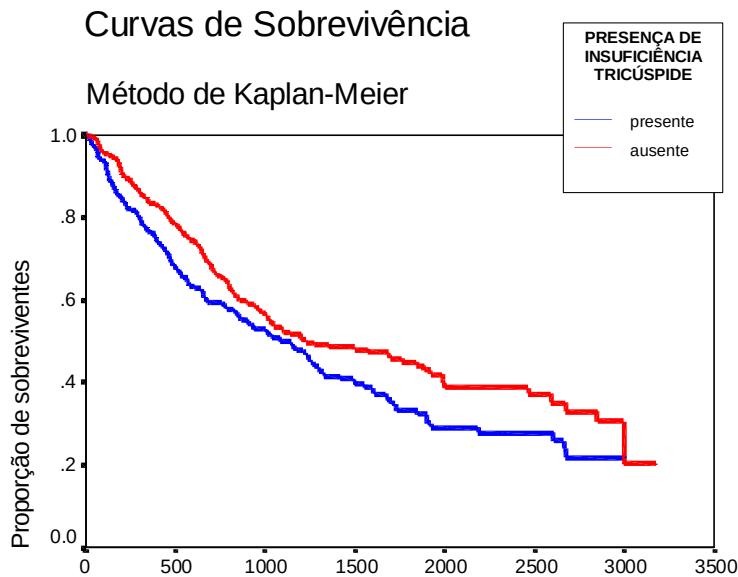


Figura 7.8: Curva de sobrevivência estimada para o estudo de transplante cardíaco

Tabela 7.6: Resultados para a variável explicativa “Insuficiência tricúspide” obtidos por meio do modelo de Cox para o estudo de transplante cardíaco.

Número de casos	Valor p	Risco	Intervalo de confiança (95%)	
		relativo	lim inferior	lim superior
868	0,039	1,25	1,01	1,54

- a) Estime descritivamente a proporção de pacientes com e sem insuficiência tricúspide cujo tempo até a ocorrência do transplante é de 1500 dias.
 - b) Existem evidências de que a presença de insuficiência tricúspide contribui para um pior prognóstico? Justifique sua resposta.
 - c) Interprete o risco relativo apresentado na Tabela 7.6.
 - d) Qual a razão para se incluir um intervalo de confiança na análise.
- 2) Os dados da Tabela 7.7 foram extraídos de um estudo cuja finalidade era avaliar o efeito da contaminação de um estuário por derramamento de petróleo na fauna local. Cada um de oito grupos de 32 siris (*Calinectes danae*) foi submetido a um tratamento obtido da classificação cruzada dos níveis de dois factores, a saber, Contaminação por petróleo (sim ou não) e Salinidade de aclimatação (0.8%, 1.4%, 2.4%, 3.4%). Os animais foram observados por setenta e duas horas e o número de sobreviventes foi registado a cada 12 horas. Detalhes podem ser encontrados em Paulino e Singer (2006).

Tabela 7.7: Dados de sobrevivência de siris

Grupo	Salinidade	Tempo (horas)					
		12	24	36	48	60	72
Petróleo	0.8%	30	26	20	17	16	15
	1.4%	32	31	31	29	27	22
	2.4%	32	30	29	26	26	21
	3.4%	32	30	29	27	27	21
Controle	0.8%	31	27	25	19	18	18
	1.4%	32	31	31	31	31	30
	2.4%	32	31	31	28	27	26*
	3.4%	32	32	30	30	29*	28

* = um animal foi retirado do estudo

- a) Para cada um dos oito tratamentos, construa tabelas com o formato da Tabela 7.8.

Tabela 7.8: Dados de sobrevivência de siris do grupo Controle submetido à salinidade 3,4% no formato de tabela atuarial

Intervalo	Em risco	Sobre-viventes	Mortos	Retirados do estudo
0 - 12	32	32	0	0
12 - 24	32	32	0	0
24 - 36	32	30	2	0
36 - 48	30	30	0	0
48 - 60	30	29	0	1
60 - 72	29	28	1	0

- b) Construa curvas de sobrevivência obtidas por meio do estimador de Kaplan-Meier.
- c) Utilize testes *log-rank* para avaliar o efeito da contaminação por petróleo e da salinidade na sobrevivência dos siris.
- 3) O arquivo **sondas** contém dados de pacientes com câncer que recebem um de dois tipos de sondas (protpla e WST) para facilitar o fluxo de fluidos do órgão. Uma possível complicação do uso dessas sondas é que após algum tempo pode ocorrer obstrução. O número de dias até a obstrução (ou censura devido ao término do estudo/óbito - informação dada na coluna evento) é apresentado na coluna rotulada “evento”.
- a) Construa curvas de sobrevivência para pacientes submetidos a cada um dos tipos de sonda. Coloque as curvas em um mesmo gráfico e, a partir delas, obtenha o tempo médio e o tempo mediano para obstrução em cada tipo de sonda. Comente os resultados.
- b) Utilize o teste *log-rank* para comparar as duas curvas.
- c) Defina dois grupos de pacientes com base na idade mediana denotando-os “jovens” e “idosos”. Construa 4 estratos, formados pela combinação

dos níveis de idade e tipo de sonda e obtenha as curvas de sobrevivência correspondentes.

- 4) O arquivo **rehabcardio** contém dados de um estudo cujo objetivo era avaliar a sobrevivência de pacientes infartados submetidos ou a tratamento clínico ou a um programa de exercícios. Com essa finalidade, considere que
 - i) o evento de interesse é definido como revascularização miocárdica, ocorrência de um segundo infarto ou óbito pós admissão no estudo;
 - ii) os pacientes foram acompanhados até 31/12/2000;
 - iii) datas incompatíveis com a data de nascimento devem ser descartadas.

Construa curvas de Kaplan-Meier para comparar o padrão de sobrevivência dos pacientes submetidos a cada grupo e com base nelas, estime o primeiro quartil e o tempo médio de sobrevivência correspondentes.

PARTE II: APRENDIZADO SUPERVISIONADO

A ideia fundamental do aprendizado supervisionado é utilizar preditores (variáveis explicativas, dados de entrada ou *inputs*) para **prever** valores de uma ou mais respostas (dados de saída ou *outputs*), que podem ser quantitativas ou qualitativas (categorias, atributos ou fatores). O caso de respostas qualitativas corresponde a problemas de **classificação** e aquele de respostas quantitativas, a problemas de **previsão**.

Em ambos os casos, a estratégia do aprendizado consiste em ajustar muitos modelos a um conjunto de dados de treinamento e avaliá-los em um conjunto de teste ou de validação por meio de algum critério. Como, em geral não se dispõe de um conjunto de treinamento e de um conjunto de teste, costuma-se recorrer à **validação cruzada** em que o único conjunto de dados disponível é repetidamente dividido em dois subconjuntos, um deles servindo para treinamento e o outro para teste (ver Nota de Capítulo 1 do Capítulo 8).

Para previsão os critérios usualmente adotados para a seleção do melhor modelo são o **erro quadrático médio** [*Mean Squared Error* (MSE)] ou sua raiz quadrada [*Root Mean Squared Error* (RMSE)] e o **coeficiente de determinação**. Para classificação, o critério mais comum é a **taxa de classificações erradas**.

Nos Capítulos 8, 9 e 10, consideramos métodos utilizados para a classificação de unidades de investigação em dois ou mais grupos (cujos elementos são de alguma forma parecidos entre si) com base em preditores. Por exemplo, pode-se querer classificar clientes de um banco como bons ou maus pagadores de um empréstimo com base nos salários, idades, classe social etc. Esses métodos envolvem tanto técnicas clássicas de regressão logística, função discriminante linear, método do vizinho mais próximo, quanto aqueles baseados em árvores e em algoritmos de suporte vetorial (*support vector machines*).

Problemas de classificação envolvem **fronteiras de decisão** que servem para delimitar regiões no espaço dos preditores que determinam as classes em que as unidades amostrais são classificadas. No caso linear, as fronteiras de decisão podem ser uma retas ou, em geral, hiperplanos. Há diversas maneiras pelas quais essas fronteiras podem ser obtidas, dentre as quais destacamos:

- i) Utilização de regressão logística (ver Capítulo 6) em que as unidades amostrais \mathbf{x} são associadas à classe para a qual a probabilidade obtida pelo modelo de regressão logística é maior de que um certo limiar.
- ii) Utilização de funções lineares conhecidas como **funções discriminantes**

$\delta_k(\mathbf{x})$ em que k denota o rótulo de uma classe. As unidades amostrais \mathbf{x} são associadas à classe com o maior valor da função discriminante. Uma dessas funções é a *função discriminante linear de Fisher*.

- iii) Utilização de métodos que calculam a probabilidade a posteriori $P(G = k|\mathbf{X} = \mathbf{x})$, em que $G(\mathbf{x})$ é uma função com valores num conjunto discreto \mathcal{G} . Se essa probabilidade for uma função linear, obteremos uma fronteira de decisão linear.

O Capítulo 11 é dedicado a problemas de previsão, ou seja, em que se pretende prever o **valor esperado** de uma variável resposta ou o **valor específico** para uma unidade amostral. Por exemplo, pode haver interesse em prever o saldo médio de clientes de um banco com base em salários, idades, classe social etc. A previsão pode ser concretizada seja por meio de técnicas de regressão, seja por meio de métodos baseados em árvores ou em algoritmos de suporte vetorial.

Classificação por meio de técnicas clássicas

8.1 Introdução

De modo genérico, vamos designar a variável preditora por X (que pode ser escalar ou vetorial) e a resposta (indicadora de uma classe) por Y . Os dados serão indicados por (x_i, y_i) , $i = 1, \dots, n$. A ideia é usar os dados para obter agrupamentos cujos elementos sejam de alguma forma parecidos entre si (com base em alguma medida obtida a partir da variável preditora) e depois utilizar essa medida para classificar um ou mais novos elementos (para os quais dispomos apenas dos valores da variável preditora) em uma das classes. Esse é o conjunto de **dados para previsão**. Se tivermos d variáveis preditoras e uma resposta dicotómica (*i.e.*, duas classes), um **classificador** é uma função que mapeia um espaço d -dimensional sobre $\{-1, 1\}$.

Formalmente, seja (X, Y) um vetor aleatório, de modo que $X \in \mathbb{R}^d$ e $Y \in \{-1, 1\}$. Então, um classificador é uma função $g : \mathbb{R}^d \rightarrow \{-1, 1\}$ e a **função erro** ou **risco** é a probabilidade de erro, $L(g) = P\{g(X) \neq Y\}$.

A acurácia de um estimador de g , digamos \hat{g} , pode ser medida pelo estimador de $L(\hat{g})$, chamado de **taxa de erros**, que é a proporção de erros gerados pela aplicação de \hat{g} às observações do conjunto de dados, ou seja,

$$\widehat{L}(\hat{g}) = \frac{1}{n} \sum_{i=1}^n I(y_i \neq \hat{y}_i), \quad (8.1)$$

com $\hat{y}_i = \hat{g}(x_i)$ indicando o rótulo (-1 ou 1) da classe prevista por meio de \hat{g} . Se $I(y_i \neq \hat{y}_i) = 0$, a i -ésima observação estará classificada corretamente.

Sob o enfoque de aprendizado automático (AA), o objetivo é comparar diferentes modelos para identificar aquele com menor taxa de erros. Nesse contexto, dispomos de um conjunto de **dados de treinamento** (x_i, y_i) , $i = 1, \dots, n$ e de um conjunto de dados de teste, cujo elemento típico é (x_0, y_0) . O interesse é minimizar a **taxa de erro de teste** associada ao conjunto de observações teste que pode ser estimada por

$$\text{Média}[I(y_0 \neq \hat{y}_0)],$$

em que a média é calculada relativamente aos elementos do conjunto de dados de teste. O classificador (ou modelo) ótimo é aquele que minimiza (8.1). Com o objetivo de classificar os elementos do conjunto de dados classificação deve-se ajustar o classificador ótimo ao conjunto de dados disponíveis (treinamento e teste)

e utilizar a estimativa \hat{g} daí obtida para classificar os elementos do conjunto de dados para classificação.

Quando dispomos de apenas um conjunto de dados, podemos recorrer ao processo de validação cruzada (ver Nota de Capítulo 2) para dividi-lo em conjuntos de dados de treinamento e de dados de teste.

Neste capítulo, concretizaremos o processo de classificação por meio de técnicas clássicas como regressão logística, o método da função discriminante linear de Fisher e o método do vizinho mais próximo com o objetivo de classificação. Outras técnicas serão consideradas nos capítulos subsequentes.

8.2 Classificação por regressão logística

Juntamente com os modelos de regressão múltipla, os modelos de **regressão logística** estudados no Capítulo 6 estão entre os mais utilizados com o objetivo de classificação. Para ilustrá-los, consideremos o seguinte exemplo.

Exemplo 8.1: Os dados da Tabela 8.1 são extraídos de um estudo realizado no Hospital Universitário da Universidade de São Paulo com o objetivo de avaliar se algumas medidas obtidas ultrassonograficamente poderiam ser utilizadas como substitutas de medidas obtidas por métodos de ressonância magnética, considerada como padrão áureo, para avaliação do deslocamento do disco da articulação temporomandibular (doravante referido simplesmente como disco). Distâncias cápsula-côndilo (em mm) com boca aberta ou fechada (referidas, respectivamente, como distância aberta ou fechada no restante do texto) foram obtidas ultrassonograficamente de 104 articulações e o disco correspondente foi classificado como deslocado (1) ou não (0) segundo a avaliação por ressonância magnética. A variável resposta é o *status* do disco (1 = deslocado ou 0 = não). Mais detalhes podem ser obtidos em Elias et al. (2006).

Com intuito didático, voltemos aos dados da Tabela 8.1 e consideremos um modelo logístico para a chance de deslocamento do disco, tendo apenas a distância aberta como variável explicativa. Nesse contexto, o modelo (6.29) corresponde a

$$\log[\theta(x_i; \alpha, \beta)]/[1 - \theta(x_i; \alpha, \beta)] = \alpha + x_i\beta \quad (8.2)$$

$i = 1, \dots, 104$ em que $\theta(x_i; \alpha, \beta)$ representa a probabilidade de deslocamento do disco quando o valor da distância aberta é x_i , α denota o logaritmo da chance de deslocamento do disco quando a distância aberta tem valor $x_i = 0$ e β é interpretado como a variação no logaritmo da chance de deslocamento do disco por unidade de variação da distância aberta. Consequentemente, a razão de chances do deslocamento do disco correspondente a uma diferença de d unidades da distância aberta será $\exp(d \times \beta)$. Como não temos dados correspondentes a distâncias abertas menores que 0,5, convém substituir os valores x_i por valores “centrados”, ou seja por $x_i^* = x_i - x_0$. Uma possível escolha para x_0 é o mínimo de x_i , que é 0,5. Essa transformação na variável explicativa altera somente a interpretação do parâmetro α que passa a ser o logaritmo da chance de deslocamento do disco quando a distância aberta tem valor $x_i = 0,5$.

Usando a função `glm()` obtemos os seguintes resultados:

```
> glm(formula = deslocamento ~ (distanciaAmin), family = binomial,
      data = disco)
```

Tabela 8.1: Dados de um estudo odontológico

Dist aberta	Dist fechada	Desloc disco	Dist aberta	Dist fechada	Desloc disco	Dist aberta	Dist fechada	Desloc disco
2.2	1.4	0	0.9	0.8	0	1.0	0.6	0
2.4	1.2	0	1.1	0.9	0	1.6	1.3	0
2.6	2.0	0	1.4	1.1	0	4.3	2.3	1
3.5	1.8	1	1.6	0.8	0	2.1	1.0	0
1.3	1.0	0	2.1	1.3	0	1.6	0.9	0
2.8	1.1	1	1.8	0.9	0	2.3	1.2	0
1.5	1.2	0	2.4	0.9	0	2.4	1.3	0
2.6	1.1	0	2.0	2.3	0	2.0	1.1	0
1.2	0.6	0	2.0	2.3	0	1.8	1.2	0
1.7	1.5	0	2.4	2.9	0	1.4	1.9	0
1.3	1.2	0	2.7	2.4	1	1.5	1.3	0
1.2	1.0	0	1.9	2.7	1	2.2	1.2	0
4.0	2.5	1	2.4	1.3	1	1.6	2.0	0
1.2	1.0	0	2.1	0.8	1	1.5	1.1	0
3.1	1.7	1	0.8	1.3	0	1.2	0.7	0
2.6	0.6	1	0.8	2.0	1	1.5	0.8	0
1.8	0.8	0	0.5	0.6	0	1.8	1.1	0
1.2	1.0	0	1.5	0.7	0	2.3	1.6	1
1.9	1.0	0	2.9	1.6	1	1.2	0.4	0
1.2	0.9	0	1.4	1.2	0	1.0	1.1	0
1.7	0.9	1	3.2	0.5	1	2.9	2.4	1
1.2	0.8	0	1.2	1.2	0	2.5	3.3	1
3.9	3.2	1	2.1	1.6	1	1.4	1.1	0
1.7	1.1	0	1.4	1.5	1	1.5	1.3	0
1.4	1.0	0	1.5	1.4	0	0.8	2.0	0
1.6	1.3	0	1.6	1.5	0	2.0	2.1	0
1.3	0.5	0	4.9	1.2	1	3.1	2.2	1
1.7	0.7	0	1.1	1.1	0	3.1	2.1	1
2.6	1.8	1	2.0	1.3	1	1.7	1.2	0
1.5	1.5	0	1.5	2.2	0	1.6	0.5	0
1.8	1.4	0	1.7	1.0	0	1.4	1.1	0
1.2	0.9	0	1.9	1.4	0	1.6	1.0	0
1.9	1.0	0	2.5	3.1	1	2.3	1.6	1
2.3	1.0	0	1.4	1.5	0	2.2	1.8	1
1.6	1.0	0	2.5	1.8	1			

Dist aberta: distância cápsula-côndilo com boca aberta (mm)

Dist fechada: distância cápsula-côndilo com boca fechada (mm)

Desloc disco: deslocamento do disco da articulação temporomandibular (1=sim, 0=não)

```
Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept) -5.8593     1.1003  -5.325 1.01e-07 ***
distanciaAmin 3.1643     0.6556   4.827 1.39e-06 ***
---
(Dispersion parameter for binomial family taken to be 1)
Null deviance: 123.11 on 103 degrees of freedom
Residual deviance: 71.60 on 102 degrees of freedom
AIC: 75.6
Number of Fisher Scoring iterations: 6
```

Estimativas (com erros padrões entre parênteses) dos parâmetros desse modelo ajustado por máxima verossimilhança aos dados da Tabela 8.1, são, $\hat{\alpha} = -5,86$ (1,10) e $\hat{\beta} = 3,16$ (0,66) e então, segundo o modelo, uma estimativa da chance de deslocamento do disco para articulações com distância aberta $x = 0,5$ (que corresponde à distância aberta transformada $x^* = 0,0$ é $\exp(-5,86) = 0,003$; um intervalo de confiança (95%) para essa chance pode ser obtido exponenciando os limites (LI e LS) do intervalo para o parâmetro α , nomeadamente,

$$\begin{aligned} LI &= \exp[\hat{\alpha} - 1,96EP(\hat{\alpha})] = \exp(-5,86 - 1,96 \times 1,10) = 0,000 \\ LS &= \exp[\hat{\alpha} + 1,96EP(\hat{\alpha})] = \exp(-5,86 + 1,96 \times 1,10) = 0,025. \end{aligned}$$

Os limites de um intervalo de confiança para a razão de chances correspondentes a um variação de uma unidade no valor da distância aberta podem ser obtidos de maneira similar e são 6,55 e 85,56.

Substituindo os parâmetros α e β por suas estimativas $\hat{\alpha}$ e $\hat{\beta}$ em (8.2) podemos estimar a probabilidade de sucesso (deslocamento do disco, no exemplo sob investigação); por exemplo, para uma articulação cuja distância aberta seja 2,1 (correspondente à distância aberta transformada igual a 1,6), a estimativa dessa probabilidade é

$$\hat{\theta} = \exp(-5,86 + 3,16 \times 1,6) / [1 + \exp(-5,86 + 3,16 \times 1,6)] = 0,31.$$

Lembrando que o objetivo do estudo é substituir o processo de identificação de deslocamento do disco realizado via ressonância magnética por aquele baseado na medida da distância aberta por meio de ultrassonografia, podemos estimar as probabilidades de sucesso para todas as articulações e identificar um **ponto de corte** d_0 segundo o qual, distâncias abertas com valores acima dele sugerem decidirmos pelo deslocamento do disco e distâncias abertas com valores abaixo dele sugerem a decisão oposta. Obviamente, não esperamos que todas as decisões tomadas dessa forma sejam corretas e consequentemente, a escolha do ponto de corte deve ser feita com o objetivo de minimizar os erros (decidir pelo deslocamento quando ele não existe ou *vice versa*).

Nesse contexto, um contraste entre as decisões tomadas com base em um determinado ponto de corte d_0 e o padrão áureo definido pela ressonância magnética para todas as 104 articulações pode ser resumido por meio da Tabela 8.2 em que as frequências da diagonal principal correspondem a decisões corretas e aquelas da diagonal secundária às decisões erradas.

O quociente $n_{11}/(n_{11} + n_{21})$ é conhecido como **sensibilidade** do processo de decisão e é uma estimativa da probabilidade de decisões corretas quando o disco está realmente deslocado (ver Seção 4.2 para mais detalhes). O quociente $n_{22}/(n_{12}+n_{22})$ é conhecido como **especificidade** do processo de decisão e é uma estimativa da probabilidade de decisões corretas quando o disco realmente não está deslocado.

Tabela 8.2: Frequência de decisões para um ponto de corte d_0

Decisão baseada na distância aberta d_0	Deslocamento real do disco	
	sim	não
sim	n_{11}	n_{12}
não	n_{21}	n_{22}

A situação ideal é aquela em que tanto a sensibilidade quanto a especificidade do processo de decisão são iguais a 100%.

O problema a resolver é determinar o ponto de corte d_{max} que gere o melhor equilíbrio entre sensibilidade e especificidade. Com essa finalidade, podemos construir tabelas com o mesmo formato da Tabela 8.2 para diferentes pontos de corte e um gráfico cartesiano entre a sensibilidade e especificidade obtida de cada uma delas. Esse gráfico, conhecido como **curva ROC** (do termo inglês *Receiver Operating Characteristic*) gerado para os dados da Tabela 8.1 por meio dos comandos

```
g <- roc(deslocamento ~ distanciaAmin, data = disco)
plot(g, print.thres=T, xlab = "Especificidade",
      ylab = "Sensibilidade")
```

está apresentado na Figura 8.1.

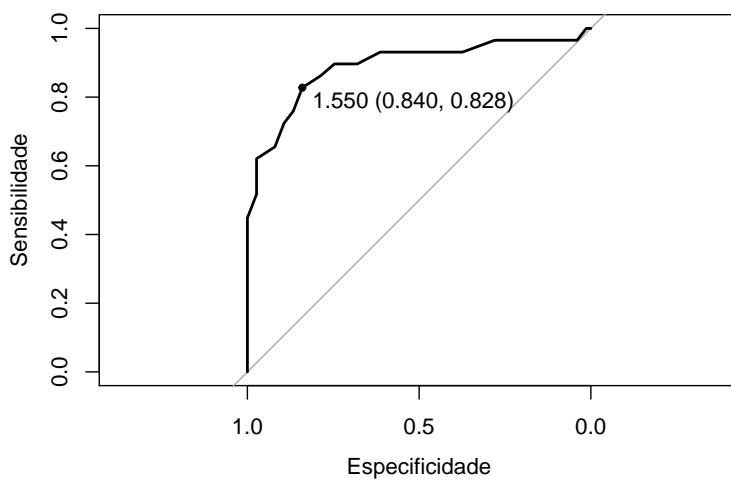


Figura 8.1: Curva ROC para os dados da Tabela 8.1 baseada no modelo (8.2) com distância aberta como variável explicativa.

O ponto de corte ótimo é aquele mais próximo do vértice superior esquerdo (em tanto a sensibilidade quanto a especificidade seriam iguais a 100%. Para o exemplo, esse ponto está salientado na Figura 8.1 e corresponde à distância aberta com valor $d_{max} = 2,05 (= 1,55 + 0,5)$. A sensibilidade e a especificidade associadas à decisão baseada nesse ponto de corte, são, respectivamente, 83% e 84% e as frequências de decisões corretas estão indicadas na Tabela 8.3.

Tabela 8.3: Frequência de decisões para um ponto de corte para distância aberta $d_{max} = 2,05$

		Deslocamento real do disco	
		sim	não
Decisão baseada na distância aberta $d_{max} = 2,05$	sim	24	12
	não	5	63

Com esse procedimento de decisão a porcentagem de acertos (**acurácia**) é 84% [= (24 + 63)/104]. A porcentagem de **falsos positivos** é 16% [= 12/(12 + 63)] e a porcentagem de **falsos negativos** é 17% [= 5/(24 + 5)].

Um gráfico de dispersão com o correspondente ponto de corte baseado apenas na distância aberta está apresentado na Figura 8.2 com símbolos vermelhos indicando casos com deslocamento do disco e em preto indicando casos sem deslocamento. Os valores de ambas as distâncias foram ligeiramente alterados para diminuir a superposição nos pontos.

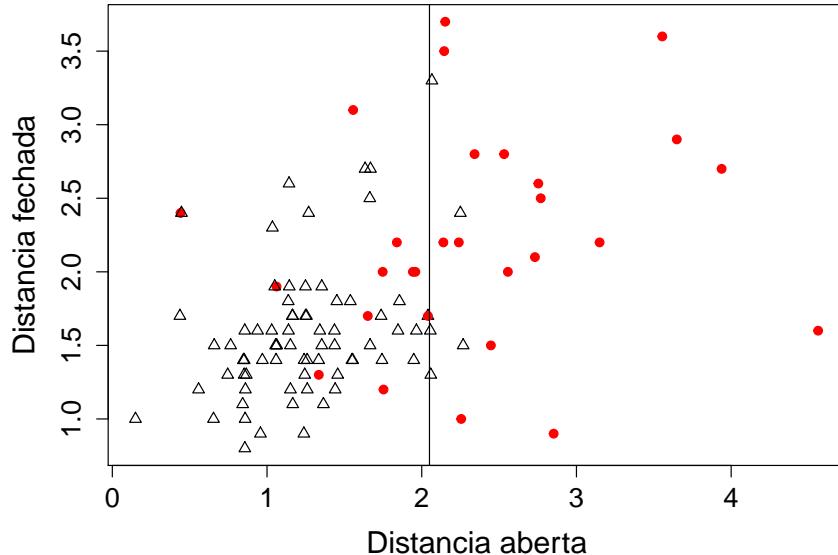


Figura 8.2: Gráfico de dispersão para os dados da Tabela 8.1 com ponto de corte baseado apenas na distância aberta.

Uma análise similar, baseada na distância fechada (transformada por meio da subtração de seu valor mínimo (0,4) gera a curva ROC apresentada na Figura 8.3 e frequências de decisões apresentada na Tabela 8.4.

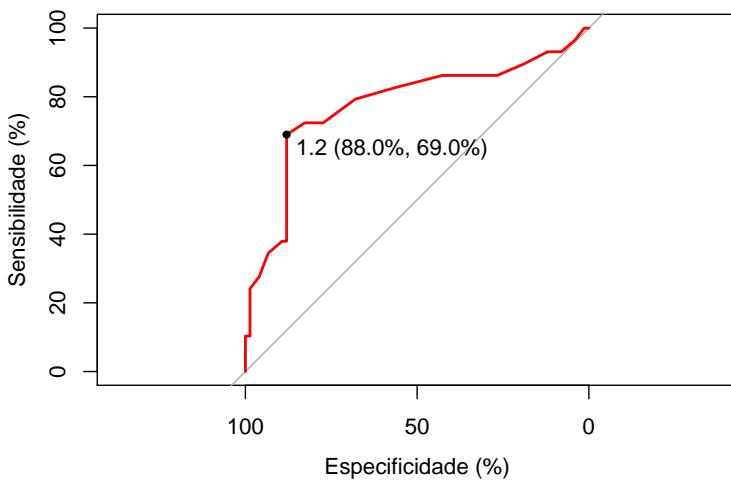


Figura 8.3: Curva ROC para os dados da Tabela 8.1 baseada no modelo (8.2) com distância fechada como variável explicativa.

Tabela 8.4: Frequência de decisões para um ponto de corte para distância fechada $d_{max} = 1,6$

	Deslocamento real do disco	
	sim	não
Decisão baseada na	sim	20
distância fechada $d_{max} = 1,6$	não	66

A acurácia associada a processo de decisão baseado apenas na distância fechada, 83% [= $(20 + 66)/104$] é praticamente igual àquela obtida com base apenas na distância aberta; no entanto aquele processo apresenta um melhor equilíbrio entre sensibilidade e especificidade (83% e 84%, respectivamente, *versus* 69% e 88%).

Se quisermos avaliar o processo de decisão com base nas observações das distâncias aberta e fechada simultaneamente, podemos considerar o modelo

$$\log[\theta(x_i; \alpha, \beta, \gamma)]/[1 - \theta(x_i; \alpha, \beta, \gamma)] = \alpha + x_i\beta + w_i\gamma \quad (8.3)$$

$i = 1, \dots, 104$ em que w_i corresponde à distância fechada observada na i -ésima articulação. Neste caso, γ corresponde à razão entre a chance de deslocamento do disco para articulações com distância fechada $w+1$ e a chance de deslocamento do disco para articulações com distância fechada w para aquelas com mesmo valor da distância aberta; uma interpretação similar vale para o parâmetro β . Estimativas dos parâmetros (com erros padrões entre parênteses) do modelo (8.3) obtidas após a transformação das variáveis explicativas segundo o mesmo figurino adotado nas análises univariadas são $\hat{\alpha} = -6,38 (1,19)$, $\hat{\beta} = 2,83 (0,67)$ e $\hat{\gamma} = 0,98 (0,54)$. A estimativa do parâmetro γ é apenas marginalmente significativa, ou seja a inclusão da variável explicativa distância fechada não acrescenta muito poder de discriminação além daquele correspondente à distância aberta. Uma das razões para isso é que as

duas variáveis são correlacionadas (com coeficiente de correlação de Pearson igual a 0,46).

A determinação de pontos de corte para modelos com duas ou mais variáveis explicativas é bem mais complexa do que no caso univariado e não será abordada neste texto. Para efeito de comparação com as análises anteriores, as frequências de decisões obtidas com os pontos de corte utilizados naquelas estão dispostas na Tabela 8.5, e correspondem a uma sensibilidade de 62%, especificidade de 97% e acurácia de 88%.

Tabela 8.5: Frequência de decisões correspondentes a pontos de corte $d_{max} = 2,05$ para distância aberta e $d_{max} = 1,6$ para distância fechada

		Deslocamento real do disco	
		sim	não
Decisão baseada em ambas as distâncias	sim	18	2
	não	11	73

Numa segunda análise, agora sob o paradigma de aprendizado automático (AA), a escolha do modelo ótimo é baseada apenas nas porcentagens de classificação correta (acurácia) obtidas por cada modelo num conjunto de dados de teste a partir de seu ajuste a um conjunto de dados de treinamento. Como neste caso não dispomos desses conjuntos *a priori*, podemos recorrer à técnica de **validação cruzada** mencionada na Seção 1.3 e detalhada na Nota de Capítulo 2. Neste exemplo, utilizamos validação cruzada de ordem 5 com 5 repetições (VC5/5), em que o conjunto de dados é dividido em dois, cinco vezes, gerando cinco conjuntos de dados de treinamento e de teste. A análise é repetida cinco vezes em cada conjunto e a acurácia média obtida das 25 análises serve de base para a escolha do melhor modelo. Comparamos quatro modelos de regressão logística, os dois primeiros com apenas uma das variáveis preditoras (distância aberta ou distância fechada), o terceiro com ambas incluídas aditivamente e o último com ambas as distâncias e sua interação. Esse tipo de análise pode ser concretizado por meio dos pacotes **caret** e **proc**. Os comandos para o ajuste do modelo com apenas a distância aberta como variável explicativa são

```
> set.seed(369321)
> train_control = trainControl(method="repeatedcv", number=5,
+                                 repeats=5)
> model1 = train(deslocamento ~ distanciaAmin, data=disco,
+                  method="glm", family=binomial, trControl=train_control)
> model1
Generalized Linear Model
104 samples
 1 predictor
 2 classes: '0', '1'

No pre-processing
Resampling: Cross-Validated (5 fold, repeated 5 times)
Summary of sample sizes: 83, 83, 83, 83, 84, 84, ...
Resampling results:
  Accuracy    Kappa
```

```

0.8410476 0.5847185
> disco$predito1 = predict(model1, newdata=disco, type="raw")
> table(disco$deslocamento, disco$predito1)
  0  1
0 69  6
1 10 19

```

A estatística *Kappa* apresentada juntamente com a acurácia serve para avaliar a concordância entre o processo de classificação e a classificação observada (veja a Seção 4.2). Para o ajuste com o método LOOCV, basta substituir a especificação `method="repeatedcv"` por `method="LOOCV"`.

Os resultados correspondentes aos ajustes obtidos por validação cruzada VC5/5 e por validação cruzada LOOCV estão dispostos na Tabela 8.6.

Tabela 8.6: Acurácia obtida por validação cruzada para as regressões logísticas ajustados as dados do Exemplo 8.1

Modelo	Variáveis	Acurácia VC5/5	Acurácia LOOCV
1	Distância aberta	84,8 %	84,6 %
2	Distância fechada	75,2 %	74,0 %
3	Ambas (aditivamente)	85,7 %	85,6 %
4	Ambas + Interação	83,6 %	83,6 %

Com ambos os critérios, o melhor modelo é aquele que inclui as duas variáveis preditoras de forma aditiva. Para efeito de classificar uma nova observação (para a qual só dispomos dos valores das variáveis preditoras, o modelo selecionado deve ser ajustado ao conjunto de dados original (treinamento + teste) para obtenção dos coeficientes do classificador.

A seleção obtida por meio do AA corresponde ao modelo (8.3). Embora a variável Distância fechada seja apenas marginalmente significativa, sua inclusão aumenta a proporção de acertos (acurácia) de 84% no modelo que inclui apenas Distância aberta para 86%.

Como a divisão do conjunto original nos subconjuntos de treinamento e de teste envolve uma escolha aleatória, os resultados podem diferir (em geral de forma desprezável) para diferentes aplicações dos mesmos comandos, a não ser que se especifique a semente do processo aleatório de divisão por meio do comando `set.seed()`.

8.3 Função discriminante linear de Fisher

Consideremos novamente o caso de duas classes (ou populações), \mathcal{G}_1 e \mathcal{G}_2 para as quais pretendemos obter um classificador com base em um vetor de variáveis preditoras, $\mathbf{X} = (X_1, \dots, X_p)^\top$.

A ideia de Fisher é considerar uma combinação linear $Y = \boldsymbol{\ell}^\top \mathbf{X}$, com $\boldsymbol{\ell} = (\ell_1, \dots, \ell_p)^\top$ de modo que o conjunto de variáveis preditoras seja transformado numa variável escalar Y . Sejam μ_{1Y} e μ_{2Y} , respectivamente, as médias de Y obtidas dos valores de \mathbf{X} associadas aos dados \mathcal{G}_1 e \mathcal{G}_2 . A regra para classificação consiste em selecionar a combinação linear que maximiza a distância quadrática entre essas duas médias, relativamente à variabilidade dos valores de Y .

Uma suposição adicional e, às vezes, irrealista, é que as matrizes de covariâncias

$$\boldsymbol{\Sigma}_i = \mathbb{E}(\mathbf{X} - \boldsymbol{\mu}_i)(\mathbf{X} - \boldsymbol{\mu}_i)^\top, \quad (8.4)$$

$i = 1, 2$, em que $\boldsymbol{\mu}_1 = \mathbb{E}(\mathbf{X}|\mathcal{G}_1)$ e $\boldsymbol{\mu}_2 = \mathbb{E}(\mathbf{X}|\mathcal{G}_2)$, sejam iguais para as duas classes, isto é, $\boldsymbol{\Sigma}_1 = \boldsymbol{\Sigma}_2 = \boldsymbol{\Sigma}$. Consequentemente,

$$\sigma_Y^2 = \text{Var}(\boldsymbol{\ell}^\top \mathbf{X}) = \boldsymbol{\ell}^\top \boldsymbol{\Sigma} \boldsymbol{\ell}$$

é igual para ambas as classes. Então

$$\mu_{1Y} = \mathbb{E}(Y|\mathcal{G}_1) = \boldsymbol{\ell}^\top \boldsymbol{\mu}_1 \quad \text{e} \quad \mu_{2Y} = \mathbb{E}(Y|\mathcal{G}_2) = \boldsymbol{\ell}^\top \boldsymbol{\mu}_2$$

e a razão

$$\begin{aligned} \frac{(\mu_{1Y} - \mu_{2Y})^2}{\sigma_Y^2} &= \frac{(\boldsymbol{\ell}^\top \boldsymbol{\mu}_1 - \boldsymbol{\ell}^\top \boldsymbol{\mu}_2)^2}{\boldsymbol{\ell}^\top \boldsymbol{\Sigma} \boldsymbol{\ell}} = \frac{\boldsymbol{\ell}^\top (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^\top \boldsymbol{\ell}}{\boldsymbol{\ell}^\top \boldsymbol{\Sigma} \boldsymbol{\ell}} \\ &= \frac{(\boldsymbol{\ell}^\top \boldsymbol{\delta})^2}{\boldsymbol{\ell}^\top \boldsymbol{\Sigma} \boldsymbol{\ell}}, \end{aligned} \quad (8.5)$$

com $\boldsymbol{\delta} = \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2$ é maximizada se

$$\boldsymbol{\ell} = c\boldsymbol{\Sigma}^{-1}\boldsymbol{\delta} = c\boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) \quad (8.6)$$

para todo $c \neq 0$. No caso $c = 1$, obtemos a **função discriminante linear de Fisher**

$$Y = \boldsymbol{\ell}^\top \mathbf{X} = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^\top \boldsymbol{\Sigma}^{-1} \mathbf{X}. \quad (8.7)$$

e o valor máximo da razão (8.5) é $\boldsymbol{\delta}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\delta}$.

Para uma nova observação \mathbf{x}_0 , sejam $y_0 = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^\top \boldsymbol{\Sigma}^{-1} \mathbf{x}_0$ e

$$\mu = \frac{\mu_{1Y} + \mu_{2Y}}{2} = \frac{1}{2}(\boldsymbol{\ell}^\top \boldsymbol{\mu}_1 + \boldsymbol{\ell}^\top \boldsymbol{\mu}_2) \quad (8.8)$$

(o ponto médio entre as médias univariadas associadas às duas classes). Em virtude de (8.7), esse ponto médio pode ser expresso como

$$\mu = \frac{(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)^\top \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)}{2}, \quad (8.9)$$

Consequentemente (veja o Exercício 8.1)

$$\mathbb{E}(Y_0|\mathcal{G}_1) - \mu \geq 0 \quad \text{e} \quad \mathbb{E}(Y_0|\mathcal{G}_2) - \mu < 0.$$

e uma **regra de classificação** é

Classifique \mathbf{x}_0 em \mathcal{G}_1 se $y_0 \geq \mu$,
Classifique \mathbf{x}_0 em \mathcal{G}_2 se $y_0 < \mu$.

Normalmente, $\boldsymbol{\mu}_1$, $\boldsymbol{\mu}_2$ e $\boldsymbol{\Sigma}$ são desconhecidas e têm que ser estimadas a partir de amostras de \mathcal{G}_1 e \mathcal{G}_2 , denotadas por $\mathbf{X}_1 = [\mathbf{x}_{11}, \dots, \mathbf{x}_{1,n_1}]$, uma matriz com dimensão $p \times n_1$ e $\mathbf{X}_2 = [\mathbf{x}_{21}, \dots, \mathbf{x}_{2,n_2}]$, uma matriz com dimensão $p \times n_2$. Com os dados dessas amostras, podemos obter estimativas $\bar{\mathbf{x}}_1, \bar{\mathbf{x}}_2, \mathbf{S}_1$ e \mathbf{S}_2 , das médias e da matriz de covariâncias comum $\boldsymbol{\Sigma}$, para a qual um estimador não enviesado é

$$\mathbf{S}_p = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}. \quad (8.10)$$

A função discriminante estimada é $\hat{\boldsymbol{\ell}}^\top \mathbf{x} = (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)^\top \mathbf{S}_p \mathbf{x}$ e a regra de classificação é:

Classifique a observação \mathbf{x}_0 em \mathcal{G}_1 se $y_0 - \hat{\mu} \geq 0$,
Classifique a observação \mathbf{x}_0 em \mathcal{G}_2 se $y_0 - \hat{\mu} < 0$,

em que $\hat{\mu} = (\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)^\top \mathbf{S}_p^{-1}(\bar{\mathbf{x}}_1 + \bar{\mathbf{x}}_2)$. Nas demais expressões, os parâmetros são substituídas pelas respectivas estimativas.

Outra suposição comumente adotada é que as variáveis preditoras têm distribuição Normal multivariada. Nesse caso, a solução encontrada por meio da função discriminante linear de Fisher é ótima. A técnica aqui abordada pode ser generalizada para três ou mais classes.

Exemplo 8.2: Consideremos os dados do arquivo `inibina`, analisados por meio de regressão logística no Exemplo 6.9. Um dos objetivos é classificar as pacientes como tendo resposta positiva ou negativa ao tratamento com inibina. A análise por meio da função discriminante linear de Fisher pode ser concretizada por meio da função `lda()` do pacote MASS. Os comandos e resultados da aplicação dessa função estão indicados abaixo

```
lda(inibina$resposta ~ inibina$difinib, data = inibina)
Prior probabilities of groups:
negativa positiva
0.40625 0.59375
Group means:
    inibina$difinib
negativa      49.01385
positiva     202.70158

Coefficients of linear discriminants:
            LD1
inibina$difinib 0.007050054
```

O resultado indica que 41% das observações correspondem a respostas negativas e 59% a respostas positivas. As médias dos grupos são as médias do preditor (diferença entre as concentrações de inibpre e inibpos) em cada classe, 49.0 e 202.7 respectivamente usadas como estimativas de μ_1 e μ_2 .

O coeficiente da função discriminante corresponde à combinação linear de `difinib` = `inibpos-inibpre` usada na função de decisão de forma que se $0.00705 \times \text{difinib}$ for grande, o classificador linear preverá uma resposta positiva e se for pequeno, preverá uma resposta negativa.

Uma tabela relacionando a classificação predita com os valores reais da resposta e o gráfico da Figura 8.4 com os valores da função discriminante calculada para cada uma das observações podem ser obtidos por meio dos comandos

```
> predito <- predict(fisher)
> table(predito$class, inibina$resposta)

        negativa positiva
negativa      9      2
positiva      4     17
> ldahist(predito$x[,1], g=inibina$resposta)
```

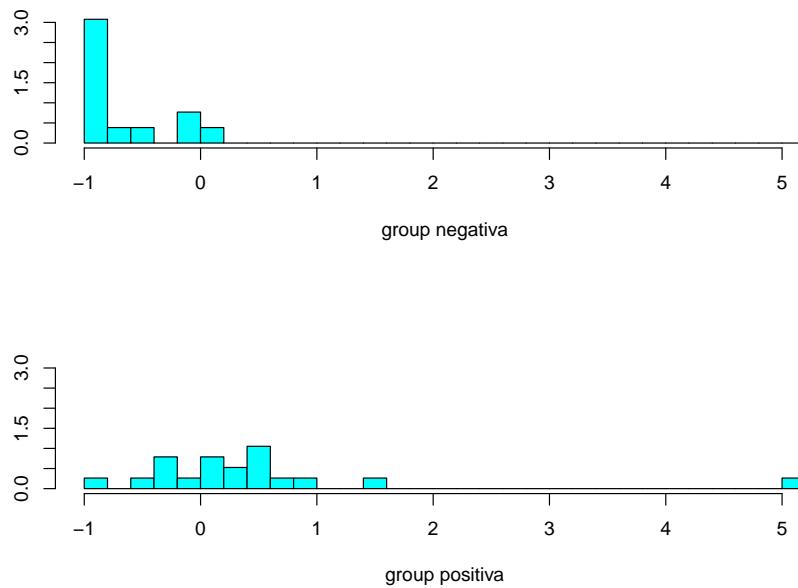


Figura 8.4: Gráfico de classificação para cada grupo

indicando que a probabilidade de classificação correta é 81%, ligeiramente superior ao que foi conseguido com o emprego de regressão logística (ver Exemplo 6.9).

8.4 Classificador bayesiano e do vizinho mais próximo

Pode-se mostrar que (8.5) é minimizada por um classificador que associa cada observação à classe mais provável, dados os valores dos preditores. O **classificador de Bayes** associa cada observação de teste com o valor do preditor x_0 à classe j de forma que

$$P(Y = j|X = x_0) \quad (8.11)$$

seja a maior possível. No caso de duas classes, a observação será associada à Classe 1 se $P(Y = 1|X = x_0) > 0,5$ e à Classe 2, se $P(Y = 0|X = x_0) < 0,5$. A **fronteira de Bayes** é $P(Y = 1|X = x_0) = 0,5$.

O classificador de Bayes produz a menor taxa de erro de teste possível, dada por $1 - \max_j P(Y = j|X = x_0)$. A **taxa de erro de Bayes global** é $1 - E(\max_j P(Y = j|X))$, obtida com base na média de todas as taxas de erro sobre todos os valores possíveis de j .

Na prática como não conhecemos a distribuição condicional de Y , dado X , precisamos estimar essa probabilidade condicional, o que pode ser efetivado por meio de um método conhecido por **K -ésimo vizinho mais próximo** (*K-nearest neighbor*, KNN). O algoritmo associado a esse método é:

- i) Fixe K e uma observação teste x_0 ;
- ii) Identifique K pontos do conjunto de dados de treinamento que sejam os mais próximos de x_0 segundo alguma medida de distância; denote esse conjunto por \mathcal{V}_0 ;

- iii) Estime a probabilidade condicional de que a observação teste pertença à Classe j como a fração dos pontos de \mathcal{V}_0 cujos valores de Y sejam iguais a j , ou seja, como

$$P(Y = j|X = x_0) = \frac{1}{K} \sum_{i \in \mathcal{V}_0} I(y_i = j). \quad (8.12)$$

- iv) classifique x_0 na classe associada à maior probabilidade.

A função `knn()` do pacote `caret` pode ser utilizada com essa finalidade.

Exemplo 8.3. Consideremos, novamente, os dados do arquivo `inibina` utilizando a variável `difinib` como preditora e adotemos a estratégia de validação cruzada por meio do método LOOCV. Além disso, avaliemos o efeito de considerar entre 1 e 5 vizinhos mais próximos no processo de classificação. Os comandos necessários para a concretização da análise são

```
set.seed(2327854)
trControl <- trainControl(method = "LOOCV")

fit <- train(resposta ~ difinib,
             method      = "knn",
             tuneGrid    = expand.grid(k = 1:5),
             trControl   = trControl,
             metric      = "Accuracy",
             data        = inibina)

fit
```

Os resultados correspondentes são

k-Nearest Neighbors

```
32 samples
 1 predictor
 2 classes: 'negativa', 'positiva'

No pre-processing
Resampling: Leave-One-Out Cross-Validation
Summary of sample sizes: 31, 31, 31, 31, 31, 31, ...
Resampling results across tuning parameters:
```

k	Accuracy	Kappa
1	0.71875	0.4240000
2	0.78125	0.5409836
3	0.81250	0.6016598
4	0.78125	0.5409836
5	0.81250	0.6016598

Accuracy was used to select the optimal model using the largest value.
The final value used for the model was k = 5.

Segundo o esse processo, o melhor resultado (com K=5 vizinhos) gera uma acurácia (média) de 81.3%. A tabela de classificação obtida por meio do ajuste do modelo final ao conjunto de dados original, juntamente com estatísticas descritivas pode ser obtida por meio dos comandos

```
predito <- predict(fit)
confusionMatrix(predito, inibina$resposta)
```

que geram os seguintes resultados

```
Confusion Matrix and Statistics
Reference
Prediction negativa positiva
negativa      9      1
positiva      4     18

Accuracy : 0.8438
95% CI  : (0.6721, 0.9472)
No Information Rate : 0.5938
P-Value [Acc > NIR] : 0.002273
Kappa : 0.6639
McNemar's Test P-Value : 0.371093

Sensitivity : 0.6923
Specificity : 0.9474
Pos Pred Value : 0.9000
Neg Pred Value : 0.8182
Prevalence : 0.4062
Detection Rate : 0.2812
Detection Prevalence : 0.3125
Balanced Accuracy : 0.8198

'Positive' Class : negativa
```

8.5 Notas de capítulo

1) Validação cruzada

Validação cruzada é a denominação atribuída a um conjunto de técnicas utilizadas para avaliar o erro de previsão de modelos estatísticos. O erro de previsão é uma medida da precisão com que um modelo pode ser usado para prever o valor de uma nova observação *i.e.*, uma observação diferente daquelas utilizados para o ajuste do modelo.

Em modelos de regressão o erro de previsão é definido como $EP = E(y - \hat{y})^2$ em que y representa uma nova observação e \hat{y} é a previsão obtida pelo modelo. O **erro quadrático médio (MSE)** dos resíduos pode ser usado como uma estimativa do erro de previsão (EP), mas tende, em geral, a ser muito otimista, ou seja, a subestimar o seu verdadeiro valor. Uma razão é que os mesmos dados são utilizados para ajustar e avaliar o modelo.

No processo de validação cruzada, o modelo é ajustado a um subconjunto dos dados (**dados de treinamento**) e o resultado é empregado num outro subconjunto (**dados de teste**) ou de validação para avaliar se ele tem um bom desempenho ou não.

O seguinte algoritmo (Efron e Tibshirani, 1993), conhecido por **LOOCV** (*Leave-One-Out Cross Validation*) bastante utilizado nesse processo é o seguinte:

- 1) Dadas n observações, y_1, \dots, y_n , o modelo é ajustado n vezes, em cada uma delas eliminando uma observação e o valor previsto para essa observação, denotado por \hat{y}_{-i} , é calculado com base no resultado obtido com as demais $n - 1$.
- 2) O erro de previsão é estimado por

$$MSE_{(-i)} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_{-i})^2. \quad (8.13)$$

Como alternativa para (8.13) pode-se considerar

$$MSE_{(-i)} = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_{-i}}{1 - h_i} \right)^2, \quad (8.14)$$

em que h_i é a **alavanca** (*leverage*), definida por

$$h_i = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{\sum_{j=1}^n (x_j - \bar{x})^2}. \quad (8.15)$$

Na chamada **validação cruzada de ordem k** (*k -fold cross validation*) o conjunto de dados original é subdividido em dois, sendo um deles utilizado como conjunto de treinamento e o segundo como conjunto de teste (ou validação). Esse processo é repetido k vezes (usualmente, considera-se $k = 5$ ou $k = 10$) com conjuntos de treinamento e validação diferentes como mostra o esquema indicado na Figura 8.5 para o caso $k = 5$.

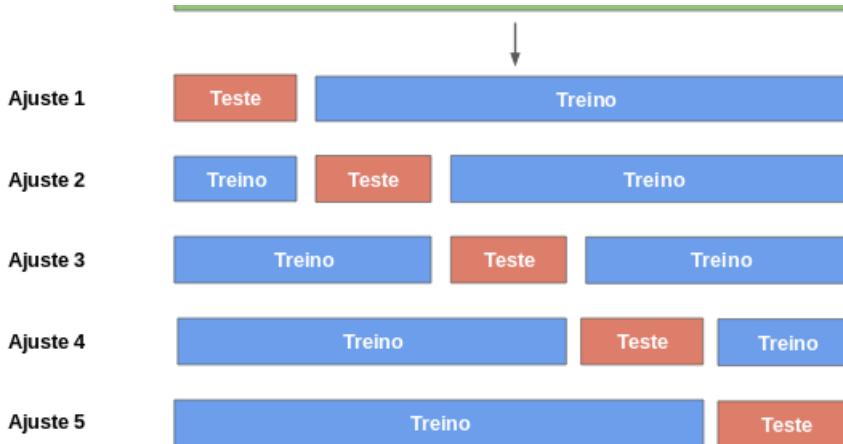


Figura 8.5: Representação esquemática da divisão dos dados para validação cruzada de ordem $k = 5$.

O correspondente erro de previsão é estimado por

$$MSE_{(k-fold)} = \frac{1}{k} \sum_{i=1}^k MSE_i. \quad (8.16)$$

em que o erro quadrático médio (MSE) obtido no i -ésimo ajuste, $i = 1, \dots, k$, $MSE_i = \sum(y_j - \hat{y}_j)^2/n_i$ com y_j , \hat{y}_j e n_i denotando, respectivamente os valores observado e predito para a j -ésima observação e o número de observações no i -ésimo conjunto de teste.

Nos casos em que o interesse é classificação, o MSE é substituído pela **taxa de erros** obtida quando o classificador \hat{g} obtido do ajuste do modelo aos dados de treinamento $\mathcal{T} = \{(\mathbf{x}_1^{(\mathcal{T})}, y_1^{(\mathcal{T})}), \dots, (\mathbf{x}_t^{(\mathcal{T})}, y_t^{(\mathcal{T})})\}$ é utilizado nas observações do conjunto de dados de teste, calculada como

$$TE = \frac{1}{t} \sum_{i=1}^t I[y_i^{(\mathcal{T})} \neq \hat{y}_i^{(\mathcal{T})}] \quad (8.17)$$

em que $y_t^{(\mathcal{T})}$ denota uma observação do conjunto de dados de teste e $\hat{y}_t^{(\mathcal{T})}$ o valor predito por meio do classificador \hat{g} e a média é calculada em relação a todos os dados desse conjunto.

8.6 Exercícios

- 1) Prove a relação (8.9).
- 2) Reanalise os dados do Exemplo 8.2 por meio da função discriminante linear de Fisher incluindo ambas as variáveis preditoras.
- 3) Reanalise os dados do Exemplo 8.3 considerando duas variáveis preditoras `inibpre` e `inibpos` e validação cruzada de ordem k com diferentes valores de k . Avalie o efeito da semente nos resultados.
- 4) Analise os dados do arquivo `endometriose2` por meio das três técnicas de classificação descritas neste capítulo, utilizando validação cruzada com diferentes parâmetros. Compare-as e discuta o resultado.
- 5) Considere os dados do arquivo `endometriose2`. Com propósitos de previsão ajuste modelos de regressão logística com validação cruzada de ordem 5 tendo `endometriose` como variável resposta e
 - i) `idade`, `dormenstrual`, `dismenorreia` ou `tipoesteril` separadamente como variáveis explicativas (4 modelos).
 - ii) cada par das variáveis do item i) como variáveis explicativas (6 modelos).
 - iii) cada trio das variáveis do item i) como variáveis explicativas (4 modelos).
 - iv) as quatro variáveis do item i) como variáveis explicativas (1 modelo).

Escolha o melhor modelo com base na acurácia.

- 6) Use os métodos discutidos nesse capítulo (regressão logística, função discriminante linear de Fisher e KNN) para os dados do arquivo `iris`.
- 7) Use os métodos discutidos nesse capítulo (regressão logística, função discriminante linear de Fisher e KNN) para os dados do arquivo `cifose`.

Classificação por algoritmos de suporte vetorial

Life is complicated, but not uninteresting.

Jerzy Neyman

9.1 Introdução

Algoritmos de Suporte Vetorial (ASV), conhecidos na literatura anglo-saxônica como *Support Vector Machines* (SVM) foram introduzidas por V. Vapnik e co-autores trabalhando no AT & T Bell Laboratories e englobam técnicas úteis para classificação, com inúmeras aplicações, dentre as quais, destacamos reconhecimento de padrões, classificação de imagens, reconhecimentos de textos escritos à mão, expressão de genes em DNAs etc.¹ Em particular, Cortes and Vapnik (1995) desenvolveram essa classe de algoritmos para classificação binária.

Vapnik and Chervonesky (1964, 1974) foram, talvez, os primeiros a usar o termo **Aprendizado com Estatística** (*Statistical Learning*) em conexão com problemas de reconhecimento de padrões e inteligência artificial. Algoritmos de suporte vetorial são generalizações não lineares do algoritmo *Generalized Portrait*, desenvolvido por Vapnik e Chervonesky (1964). Um excelente tutorial sobre o tema pode ser encontrado em Smola and Schölkopf (2004). Outras referências importantes são Vapnik (1995, 1998), Hastie et al. (2017) e James et al. (2017).

Os algoritmos de suporte vetorial competem com outras técnicas bastante utilizadas, como Modelos Lineares Generalizados (MLG), Modelos Aditivos Generalizados (MAG), Redes Neurais, modelos baseados em árvores etc. A comparação com esses métodos é baseada em três fatores: interpretabilidade do modelo usado, desempenho na presença de valores atípicos e poder preditivo. Por exemplo, os MLG têm baixo desempenho na presença de valores atípicos, valor preditivo moderado e boa interpretabilidade. Por outro lado, os ASV têm desempenho moderado na presença de valores atípicos, alto poder preditivo e baixa interpretabilidade.

A abordagem de Cortes and Vapnik (1995) para o problema de classificação baseia-se nas seguintes premissas (Meyer, 2018):

¹Embora a tradução literal do termo proposto por Vapnik seja **Máquinas** de Suporte Vetorial, optamos por utilizar **Algoritmos** de Suporte Vetorial para que o leitor não pense que algum tipo de máquina esteja ligado a essas técnicas. Aparentemente, Vapnik utilizou esse termo para enfatizar o aspecto computacional intrínseco à aplicação dos algoritmos.

- a) **Separação de classes:** procura-se o melhor hiperplano separador (ver Nota de Capítulo 1) entre as classes, maximizando-se a **margem** entre os pontos mais próximos das duas classes. Os pontos sobre as fronteiras dessas classes são chamados **vetores suporte** (*support vectors*).
- b) **Superposição de classes:** pontos de uma classe que estão no outro lado do hiperplano separador são ponderados com baixo peso para reduzir sua influência.
- c) **Não linearidade:** quando não pudermos encontrar um separador linear, utilizamos um **kernel**² para mapear os dados de entrada em um espaço de dimensão mais alta [chamado de **espaço característico**, (*feature space*)] de tal forma que nesse espaço, são construídos os hiperplanos separadores. O sucesso das aplicações dos ASV depende da escolha desse *kernel*. Os *kernels* mais populares são: Gaussiano, polinomial, de base exponencial (*exponential radial basis*), *splines* e, mais recentemente, aqueles baseados em ondaletas. Veja a Nota de Capítulo 5.
- d) **Solução do problema:** o problema envolve otimização quadrática e pode ser resolvido com técnicas conhecidas.

Essencialmente, um ASV é implementado por um código computacional que realiza essas tarefas. No repositório R há pacotes como o **e1071** e a função **svm** desenvolvidos com essa finalidade. Outras alternativas são o pacote **kernlab** e a função **ksvm**.

9.2 Fundamentação dos algoritmos de suporte vetorial

Nesta seção, apresentaremos as ideias básicas sobre algoritmos de suporte vetorial (ASV), concentrando-nos no problema de classificação dicotômica, *i.e.*, em que as unidades amostrais devem ser classificadas em uma de duas classes possíveis. Para ideias sobre o caso de mais de duas classes, veja a Nota de Capítulo 6. Adotaremos uma abordagem heurística, mais próxima daquela usualmente empregada no Aprendizado com Estatística ou Aprendizado Automático, deixando para as Notas de Capítulo 3, 4 e 5 a abordagem original (e mais formal) dos ASV.

Seja \mathcal{X} o **espaço dos dados (ou dos padrões)**; em geral, $\mathcal{X} = \mathbb{R}^d$ e seja a resposta $y \in \{-1, 1\}$. Por exemplo, podemos ter dados de várias variáveis explicativas (idade, peso, taxa de colesterol etc.) e uma variável resposta (doença cardíaca, com $y = 1$ em caso afirmativo e $y = -1$ em caso negativo) observadas em vários indivíduos (o **conjunto de treinamento**). Nesse caso, o problema de classificação consiste na determinação de dois subconjuntos (classes) de \mathcal{X} , um dos quais estará associado a indivíduos com doença cardíaca. O classificador indicará em qual das classes deveremos incluir novos indivíduos (o **conjunto de previsão**) para os quais conhecemos os valores das variáveis explicativas. A escolha do classificador é feita com base em seu desempenho num **conjunto de dados de teste**. Quando esse conjunto não está disponível, costuma-se usar a técnica de **validação cruzada**. Ver Nota de Capítulo 2 do Capítulo 8).

Vamos considerar três situações:

²Optamos por manter a palavra em inglês em vez de utilizar núcleo, que é a tradução em português.

- 1) As classes são perfeitamente separáveis por uma fronteira linear; nesse caso, o separador (hiperplano) é conhecido como **classificador de margem máxima** (CMM). Para duas variáveis, o separador é uma reta; para três variáveis, o separador é um plano. No caso de p variáveis, o separador é um **hiperplano** de dimensão $p - 1$. A Figura 9.1 é um exemplo. Note que podemos ter mais de uma reta separando as duas classes.
- 2) Não há um hiperplano que separe as duas classes, como no exemplo apresentado na Figura 9.2, que corresponde à Figura 9.1 com pontos trocados de lugar. O separador, neste caso é o **classificador de margem flexível** (CMF).
- 3) Um separador linear não conduz a resultados satisfatórios exigindo a definição de fronteiras de separação não lineares. Para isso, recorremos ou a funções não lineares das observações ou a *kernels*, para mapear o espaço dos dados em um espaço de dimensão maior. O separador, neste caso é o **classificador de margem não linear** (CMNL).

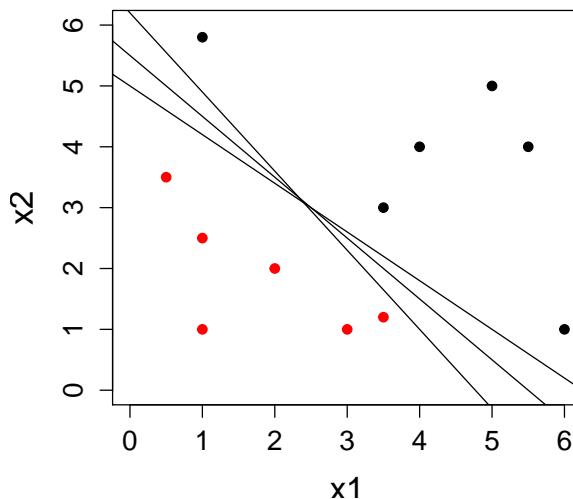


Figura 9.1: Dois conjuntos de pontos perfeitamente separáveis por um hiperplano (reta)

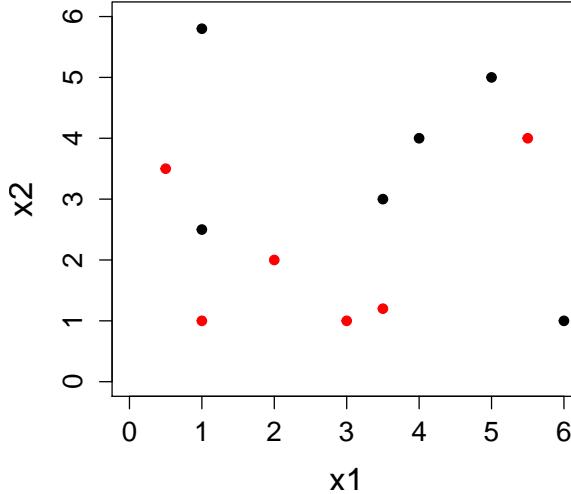


Figura 9.2: Dois conjuntos de pontos não separáveis por um hiperplano (reta)

9.3 Classificador de margem máxima

No caso de duas variáveis, o hiperplano é uma reta com equação $\alpha + \beta_1 X_1 + \beta_2 X_2 = 0$. Essa reta separa o plano em duas regiões, uma em que $\alpha + \beta_1 X_1 + \beta_2 X_2 > 0$ e outra em que $\alpha + \beta_1 X_1 + \beta_2 X_2 < 0$.

Consideremos agora o caso com n observações das variáveis X_1, \dots, X_p , dispostas na forma de uma matriz \mathbf{X} , de ordem $n \times p$. Seja $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})^\top$, o vetor correspondente à i -ésima coluna de \mathbf{X} . Além disso, sejam $y_1, \dots, y_n \in \{-1, 1\}$, variáveis respostas indicadoras de duas classes. O conjunto de dados de treinamento é $\mathcal{T} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$. Dado um vetor $\mathbf{x}_0 = (x_{10}, \dots, x_{p0})^\top$ de variáveis preditoras associada a uma unidade amostral, o objetivo é classificá-la em uma das duas classes.

Queremos desenvolver um classificador usando um hiperplano separador no espaço \mathbb{R}^p com base no conjunto de treinamento \mathcal{T} . Definindo $\boldsymbol{\beta} = (\beta_1, \dots, \beta_p)^\top$, teremos

$$\alpha + \boldsymbol{\beta}^\top \mathbf{x}_i > 0, \quad \text{se } y_i = 1, \quad (9.1)$$

$$\alpha + \boldsymbol{\beta}^\top \mathbf{x}_i < 0, \quad \text{se } y_i = -1. \quad (9.2)$$

Seja

$$f(\mathbf{x}) = \alpha + \boldsymbol{\beta}^\top \mathbf{x}. \quad (9.3)$$

Então, classificaremos \mathbf{x}_0 a partir do sinal de $f(\mathbf{x}_0) = \alpha + \boldsymbol{\beta}^\top \mathbf{x}_0$; se o sinal for positivo, \mathbf{x}_0 será classificado na Classe 1 (para a qual $y = 1$, digamos), e se o sinal for negativo, na Classe 2 (para a qual $y = -1$). Em qualquer situação, $y_i(\alpha + \boldsymbol{\beta}^\top \mathbf{x}_i) \geq 0$.

Como vimos, podem existir infinitos hiperplanos separadores, se os dados de treinamento estiverem perfeitamente separados. A sugestão de Vapnik e colaboradores é escolher um hiperplano que esteja o mais afastado das observações de treinamento, chamado de **hiperplano de margem máxima**. A **margem** é a menor distância entre o hiperplano e os pontos de treinamento.

O classificador de margem máxima (CMM) é a solução (se existir) do seguinte problema de otimização:

$$\begin{aligned} & \text{maximizar}_{(\alpha, \beta)} m(\alpha, \beta) \\ & \text{sujeito a} \\ & \sum_{i=1}^p \beta_i^2 = 1 \\ & y_i(\alpha + \beta^\top \mathbf{x}_i) \geq m(\alpha, \beta), \quad i = 1, \dots, n. \end{aligned} \tag{9.4}$$

Dizemos que $m = m(\alpha, \beta)$ é a **margem** do hiperplano e cada observação estará do lado correto do hiperplano se $m > 0$.

Os chamados **vetores suporte** são definidos pelos pontos cujas distâncias ao hiperplano separador sejam iguais à margem e se situam sobre as **fronteiras de separação** que são retas paralelas cujas distâncias ao hiperplano separador é igual à margem. O classificador depende desses vetores, mas não das demais observações.

A distância m do hiperplano separador a um ponto do conjunto de treinamento é

$$m = |f(\mathbf{x})|/\|\beta\|,$$

em que o denominador indica a norma do vetor β .

Como o interesse está nos pontos que são corretamente classificados, devemos ter $y_i f(\mathbf{x}_i) > 0$, $i = 1, \dots, n$. Então

$$\frac{y_i f(\mathbf{x}_i)}{\|\beta\|} = \frac{y_i(\alpha + \beta^\top \mathbf{x}_i)}{\|\beta\|}, \tag{9.5}$$

e queremos escolher α e β de modo a maximizar essa distância. A margem máxima é encontrada resolvendo

$$\operatorname{argmax}_{\alpha, \beta} \left\{ \frac{1}{\|\beta\|} \min_i [y_i(\alpha + \beta^\top \mathbf{x}_i)] \right\}. \tag{9.6}$$

A solução de (9.6) é complicada e sua **formulação canônica** pode ser convertida num problema mais fácil por meio do uso de multiplicadores de Lagrange. Veja a Nota de Capítulo 3 para mais detalhes sobre esse problema.

Exemplo 9.1. Consideremos os 12 pontos dispostos na Figura 9.1, sendo 6 em cada classe. Usando a função `svm` do pacote `e1071` e o comando `summary(svm.model)` obtemos o seguinte resultado

```
Call:
svm(formula = type ~ ., data = my.data, type = "C-classification",
kernel = "linear", scale = FALSE)

Parameters:
  SVM-Type: C-classification
  SVM-Kernel: linear
    cost: 1
    gamma: 0.5

Number of Support Vectors: 3
( 1 2 )

Number of Classes: 2
Levels:
-1 1
```

Observe que a função usa o kernel linear, que corresponde ao CMM. As opções `cost` e `gamma` serão explicadas adiante. Os coeficientes do hiperplano separador, que nesse caso é uma reta, podem ser obtidos por meio dos comandos

```
alpha = svm.model$rho
beta = t(svm.model$coefs) %*% svm.model$SV
```

e são

```
> alpha
[1] 5.365853
> beta
x1          x2
[1,] -0.8780489 -1.097561
```

A equação do hiperplano separador, disposto na Figura 9.3 é $5,366 - 0,878X_1 - 1,098X_2 = 0$. Na mesma figura, indicamos as fronteiras de separação e os vetores suporte, dados pela solução de (9.4).³ Neste caso há três vetores suporte (indicados por círculos azuis), um na Classe 1 (ponto em vermelho) e dois na Classe 2 (pontos em preto). Os demais pontos estão em lados separados, delimitados pelas fronteiras de separação (não há pontos entre as fronteiras). A margem é $m = 0,71$.

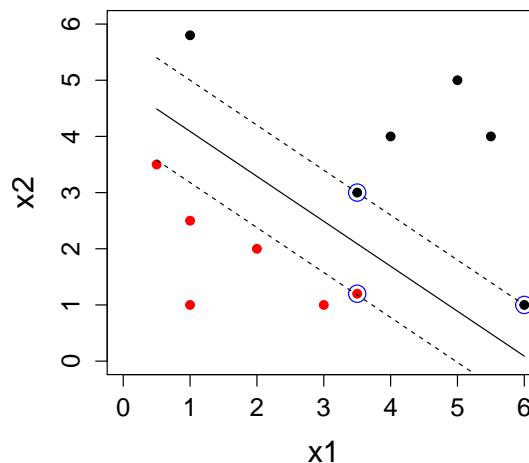


Figura 9.3: Hiperplano (reta) separador, margem, fronteiras e vetores suporte.

Consideremos agora dois novos pontos, $(\mathbf{x}_0^*, y = 1)$ e $(\mathbf{x}_1^*, y = 2)$, o primeiro na Classe 1 o segundo na Classe 2 e vamos classificá-los, usando o algoritmo. No contexto de Aprendizado com Estatística, o conjunto dos dois pontos é o chamado conjunto de dados de teste e serve para avaliar a capacidade de predição do modelo. Por meio da função `predict`, obtemos a Figura 9.4, que mostra a classificação correta de ambos os pontos (representados nas cores verde e azul).

³Note que os coeficientes $\beta_1 = 0,8780489$ e $\beta_2 = -1,097561$ não satisfazem a restrição indicada em (9.4), pois foram obtidos por meio da formulação canônica do problema em que a restrição é imposta ao numerador de (9.5). Para detalhes, consulte a Nota de Capítulo 3.

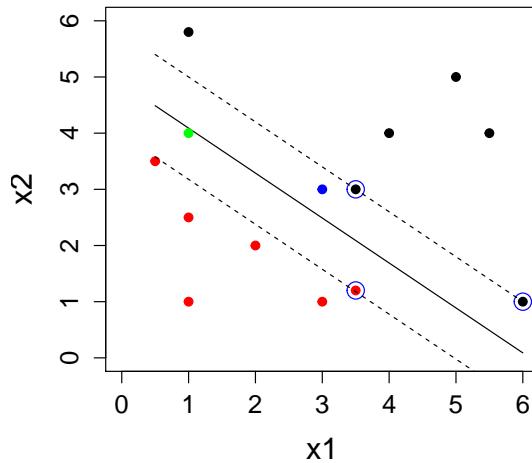


Figura 9.4: Classificação de novos pontos indicados pelas cores verde e azul.

Se o problema acima não tiver solução não existirá hiperplano separador, como é o caso apresentado na Figura 9.2. Nesse caso precisamos recorrer a um classificador que **quase** separa as duas classes. É o que veremos na próxima seção.

9.4 Classificador de margem flexível

Se não existir um hiperplano separador, como aquele do Exemplo 8.1, observações podem estar do lado errado da margem ou mesmo do hiperplano, correspondendo nesse caso a classificações erradas.

O **classificador de margem flexível** (CMF), também conhecido como **classificador baseado em suporte vetorial**⁴ é escolhido de modo a classificar corretamente a maioria das observações, o que se consegue com a introdução de **variáveis de folga**, $\xi = (\xi_1, \dots, \xi_n)^\top$, no seguinte problema de otimização:

$$\begin{aligned} & \text{maximizar}_{(\alpha, \beta, \xi)} m(\alpha, \beta, \xi) \\ & \text{sujeito a} \\ & \sum_{i=1}^p \beta_i^2 = 1 \\ & y_i(\alpha + \beta^\top \mathbf{x}_i) \geq m(\alpha, \beta, \xi)(1 - \xi_i), \\ & \xi_i \geq 0, \quad \sum_{i=1}^n \xi_i \leq C. \end{aligned} \tag{9.7}$$

em que C é uma constante positiva. Mais detalhes sobre a constante C serão apresentados posteriormente.

As variáveis de folga permitem que observações estejam do lado errado da margem ou do hiperplano. Pontos tais que $\xi_i = 0$ são corretamente classificados e estão sobre a fronteira de separação ou do lado correto da fronteira. Pontos para

⁴Embora esse tipo de classificador seja conhecido como *support vector classifier* ou *soft margin classifier*, optamos por denominá-lo “classificador de margem flexível” para diferenciá-lo do “classificador de margem máxima”, que também é baseado em vetores suporte.

os quais $0 < \xi_i \leq 1$ estão dentro da fronteira da margem, mas do lado correto do hiperplano, e pontos para os quais $\xi_i > 1$ estão do lado errado do hiperplano e serão classificados erroneamente. Veja a Figura 9.5, extraída de Bishop (2006) em que m está normalizada apropriadamente. Mais detalhes podem ser obtidos nas Notas de Capítulo 3 e 4.

Como o objetivo é maximizar a margem, podemos minimizar

$$C \sum_{i=1}^n \xi_i + \frac{1}{2} \|\beta\|^2, \quad (9.8)$$

em que $C > 0$ controla o equilíbrio entre a penalidade das variáveis de folga e a margem.

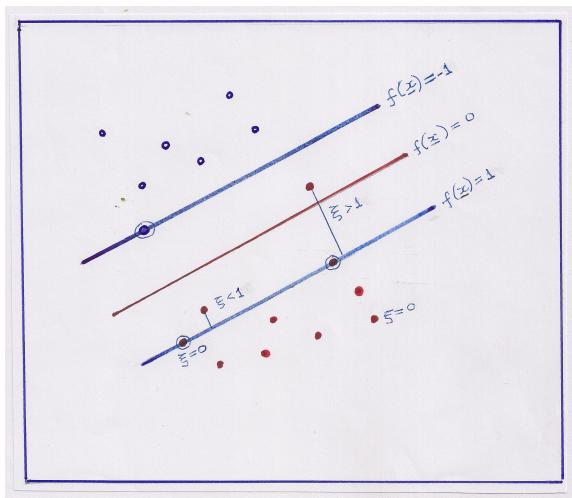


Figura 9.5: Detalhes sobre o classificador de margem flexível.

Como qualquer ponto classificado erroneamente satisfaz $\xi_i > 1$, um limite superior para o número de classificações errôneas é $\sum_{i=1}^n \xi_i$. No limite, quando $C \rightarrow \infty$, obtemos o CMM. O objetivo, então é minimizar (9.8) sujeito a (9.7). Veja a Nota de Capítulo 4.

A constante $C \geq 0$ deve ser escolhida apropriadamente e determina o número de violações (classificações erradas) permitidas pelo algoritmo. Se $C = 0$, então não há violações e $\xi_1 = \dots = \xi_n = 0$. Se C aumenta, a margem fica mais larga e o contrário ocorre se C decresce. O valor de C tem a ver com a relação viés–variância: quando a constante C é pequena, o viés é pequeno e a variância é grande; se C é grande, o viés é grande e a variância é pequena. Veja o Exercício 1. Pode-se dizer que C representa o **custo** do classificador.

A constante C normalmente é escolhida por **validação cruzada** (veja a Nota de Capítulo 2 do Capítulo 8). O pacote `e1071` tem uma função, `tune()`, que realiza esse procedimento para diferentes valores de C , com o intuito de escolher o melhor modelo. Veja o Exercício 5.

Exemplo 9.1. continuação Consideremos agora os dados dispostos na Figura 9.3 em que as duas classes não são perfeitamente separáveis. Nesse caso, a utilização da função `tune()` do pacote `e1071` gera o seguinte resultado, indicando que a melhor opção é considerar $C = 0.5$ e `gamma = 4`.

```

Parameter tuning of 'svm':
- sampling method: 10-fold cross validation
- best parameters:
  gamma cost
    0.5      4
- best performance: 0.5
- Detailed performance results:
  gamma cost error dispersion
1   0.5      4  0.50  0.4714045
2   1.0      4  0.60  0.4594683
3   2.0      4  0.70  0.4216370
4   0.5      8  0.65  0.4743416
5   1.0      8  0.65  0.4743416
6   2.0      8  0.70  0.4216370
7   0.5     16  0.65  0.4743416
8   1.0     16  0.65  0.4743416
9   2.0     16  0.70  0.4216370

```

Com esses parâmetros, as funções `svm` e `summary` geram o seguinte resultado, indicando que há 8 vetores suporte, 4 em cada classe.

```

svm(formula = type ~ ., data = my.data, type = "C-classification",
kernel = "linear", gamma = 0.5, cost = 4, scale = FALSE)
Parameters:
  SVM-Type: C-classification
  SVM-Kernel: linear
    cost: 4
    gamma: 0.5
Number of Support Vectors: 8
( 4 4 )
Number of Classes: 2
Levels:
-1 1

```

Um gráfico indicando os vetores suporte e as regiões de classificação correspondentes está apresentado na Figura 9.6.

A equação do hiperplano classificador é $3,760 - 0,676x_1 - 0,704x_2 = 0$ ou equivalentemente, $x_2 = 3,760/0,704 - 0,676/0,704x_1 = 5,339 - 0,960x_1$. A margem correspondente é $m = (0,676^2 + 0,704^2)^{1/2} = 0,976$. Para detalhes, consulte as Notas de Capítulo 3 e 4.

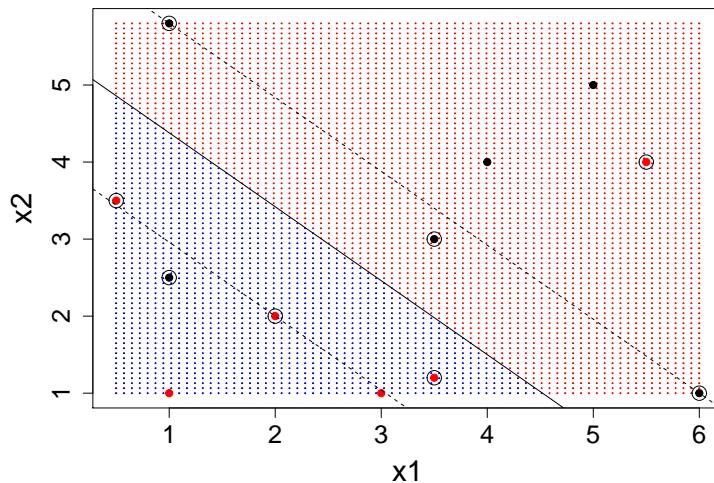


Figura 9.6: Vetores suporte para os dados da Figura 9.3

Com os comandos `svm.pred <- predict(svm.model, my.data)` e `table(svm.pred, ys)` podem-se obter uma tabela com as classificações certas e erradas assim como as classificações determinadas pelo algoritmo. No exemplo, há 2 classificações erradas conforme indicado na Tabela 9.1.

Tabela 9.1: Coordenadas e classificação dos pontos do Exemplo 8.1 com observações trocadas e classificação predita pelo algoritmo

observação	x1	x2	y	y predito
1	0.5	3.5	1	1
2	1.0	1.0	1	1
3	1.0	2.5	-1	1
4	2.0	2.0	1	1
5	3.0	1.0	1	1
6	3.5	1.2	1	1
7	1.0	5.8	-1	-1
8	3.5	3.0	-1	-1
9	4.0	4.0	-1	-1
10	5.0	5.0	-1	-1
11	5.5	4.0	1	-1
12	6.0	1.0	-1	-1

Exemplo 9.2. Os dados do arquivo `tipofacial` forma extraídos de um estudo odontológico realizado pelo Dr. Flávio Cotrim Vellini. Um dos objetivos era utilizar medidas entre diferentes pontos do crânio para caracterizar indivíduos com diferentes tipos faciais, a saber, braquicéfalos, mesocéfalos e dolicocéfalos. O conjunto de dados contém observações de 11 variáveis em 101 pacientes. Para efeitos

didáticos, utilizaremos apenas a altura facial e a profundidade facial como variáveis preditoras. A Figura 9.7 mostra os três grupos (correspondentes à classificação do tipo facial).

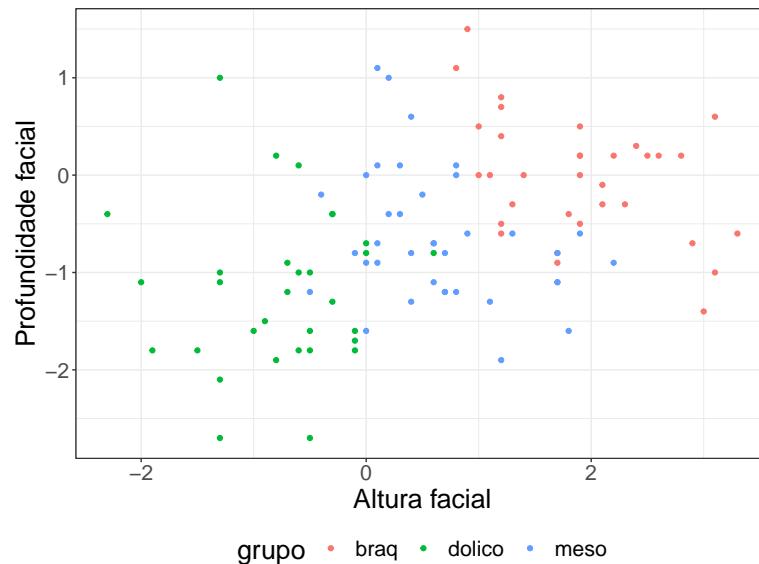


Figura 9.7: Gráfico de dispersão com identificação dos três tipos faciais.

Utilizando a função `tune.svm()` do pacote `e1071` por meio dos seguintes comandos

```
> escolhaparam <- tune.svm(grupo ~ altfac + proffac, data = face,
  gamma = 2^(-2:2), cost = 2^2:5,
  na.action(na.omit(c(1, NA))))
> summary(escolhaparam)
```

obtemos os resultados, apresentados abaixo, que indicam que as melhores opções para os parâmetros C e γ (obtidas por meio de validação cruzada de ordem 10) para o classificador de margem flexível são $C = 4$ e $\gamma = 2$.

```
Parameter tuning of 'svm':
- sampling method: 10-fold cross validation
- best parameters:
  gamma cost
    2      4
- best performance: 0.1281818
- Detailed performance results:
  gamma cost      error dispersion
1  0.25      4 0.1481818  0.1774759
2  0.50      4 0.1681818  0.1700348
3  1.00      4 0.1681818  0.1764485
4  2.00      4 0.1281818  0.1241648
5  4.00      4 0.1581818  0.1345127
6  0.25      5 0.1481818  0.1774759
7  0.50      5 0.1681818  0.1700348
8  1.00      5 0.1481818  0.1503623
```

```
9  2.00    5 0.1281818 0.1148681
10 4.00    5 0.1772727 0.1453440
```

Por intermédio da função `svm` com os parâmetros $C = 4$ e `gamma=2` obtemos o seguinte resultado com o classificador de margem flexível:

```
svm.model <- svm(grupo ~ altfac + proffac, data = face,
                  kernel = "linear", gamma=2, cost=4)
summary(svm.model)

Parameters:
  SVM-Type: C-classification
  SVM-Kernel: linear
  cost: 4
Number of Support Vectors: 43
( 12 10 21 )
Number of Classes: 3
Levels:
braq dolico meso
```

A tabela de classificação obtida com os comandos apresentados abaixo, indica o número de classificações certas e erradas.

```
svm.pred <- predict(svm.model, face)
table(pred = svm.pred, true = face$grupo)

      true
pred   braq dolico meso
braq     26      0      2
dolico    0     28      4
meso      7      3     31
```

Na Figura 9.8 apresentamos o gráfico de classificação correspondente, obtido por meio do comando

```
plot(svm.model, face, proffac ~ altfac, svSymbol = 4, dataSymbol = 4,
      cex.lab=1.8, main="", color.palette = terrain.colors)
```

Uma das características importantes dos classificadores baseados em vetores suporte é que apenas as observações que se situam sobre a margem ou do lado errado da mesma afetam o hiperplano. Observações que se situam no lado correto da margem podem ser alteradas (mantendo suas classificações) sem que o hiperplano separador seja afetado.

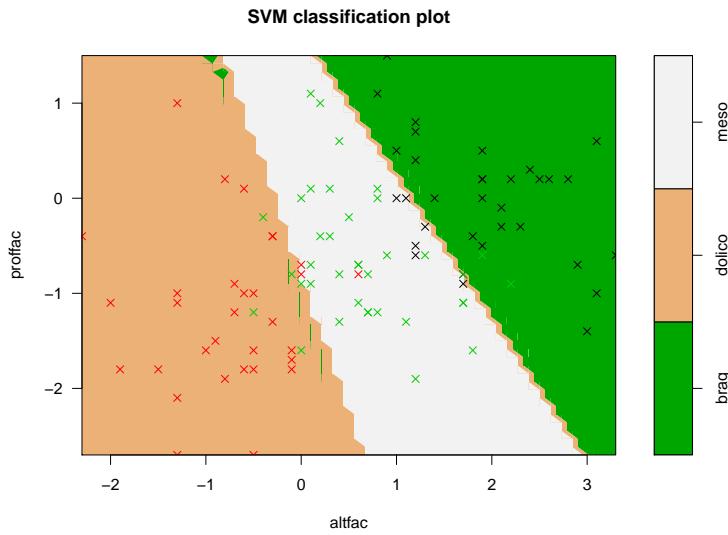


Figura 9.8: Classificação do tipo facial obtida pelo classificador de margem flexível (símbolos vermelhos = doliocéfalos, verdes = mesocéfalos, pretos = braquicéfalos).

9.5 Classificador de margem não linear

Na seção anterior apresentamos um algoritmo de classificação (CMF), usado quando as fronteiras são lineares. Para fronteiras não lineares, precisamos aumentar a dimensão do espaço de dados (ou espaço característico) por meio de outras funções, polinomiais ou não, para determinar as fronteiras de separação. No caso de duas variáveis, X_1 e X_2 , por exemplo, poderíamos considerar o espaço determinado por X_1 , X_2 , X_1^2 , X_2^3 . Uma alternativa mais conveniente e mais atrativa para aumentar a dimensão do espaço característico consiste na utilização de *kernels*.

Pode-se demonstrar que um classificador linear como aquele definido em (9.7) depende somente dos vetores suporte e pode ser escrito na forma

$$f(\mathbf{x}) = \sum_{i \in S} \gamma_i \langle \mathbf{x}, \mathbf{x}_i \rangle + \delta, \quad (9.9)$$

em que S indica o conjunto dos vetores suporte, os γ_i são funções de α e β e $\langle \mathbf{x}, \mathbf{y} \rangle$ indica o produto interno dos vetores \mathbf{x} e \mathbf{y} . Uma das vantagens de se utilizar *kernels* na construção de classificadores é que eles dependem somente dos vetores suporte e não de todas as observações o que implica uma redução considerável no custo computacional.

O classificador CMF usa um *kernel* linear, da forma

$$K(\mathbf{x}_i, \mathbf{x}_j) = \sum_{k=1}^p x_{ik} x_{jk} = \mathbf{x}_i^\top \mathbf{x}_j.$$

Se quisermos usar um CMF em um espaço característico de dimensão maior, podemos incluir polinômios de grau maior ou mesmo outras funções na definição do classificador. Os *kernels* mais utilizados na prática são:

- a) lineares: $K(\mathbf{x}_1, \mathbf{x}_2) = \mathbf{x}_1^\top \mathbf{x}_2$;
- b) polinomiais: $K(\mathbf{x}_1, \mathbf{x}_2) = (a + \mathbf{x}_1^\top \mathbf{x}_2)^d$;
- c) radiais: $K(\mathbf{x}_1, \mathbf{x}_2) = \exp(-\gamma \|\mathbf{x}_1 - \mathbf{x}_2\|^2)$, com $\gamma > 0$ constante.
- d) tangentes hiperbólicas: $K(\mathbf{x}_1, \mathbf{x}_2) = \tanh(\theta + k \mathbf{x}_1^\top \mathbf{x}_2)$.

Os **classificadores CMNL** são obtidos combinando-se CMF com *kernels* não lineares, de modo a obter

$$f(\mathbf{x}) = \alpha + \sum_{i \in S} \gamma_i K(\mathbf{x}, \mathbf{x}_i) + \delta. \quad (9.10)$$

Exemplo 9.3. Consideremos uma análise alternativa para dados do Exemplo 9.2, utilizando um *kernel* polinomial, de grau 3. Os comandos e resultados reanálise dos dados por meio do classificador de margem não linear são:

```

escolhaparam <- tune.svm(grupo ~ altfac + proffac, data = face,
                           kernel = "polynomial", degree=3,
                           gamma = 2^{(-1:2)}, cost = 2^2:6)
> summary(escolhaparam)

Parameter tuning of 'svm':
- sampling method: 10-fold cross validation

- best parameters:
  degree gamma cost
      3     0.5    4
- best performance: 0.1681818

- Detailed performance results:
  degree gamma cost      error dispersion
  1       3   0.5    4  0.1681818  0.09440257
  2       3   1.0    4  0.1772727  0.12024233
  3       3   2.0    4  0.1872727  0.11722221
  4       3   4.0    4  0.1872727  0.11722221
  5       3   0.5    5  0.1972727  0.11314439
  6       3   1.0    5  0.1772727  0.12024233
  7       3   2.0    5  0.1872727  0.11722221
  8       3   4.0    5  0.1872727  0.11722221
  9       3   0.5    6  0.1872727  0.12634583
 10      3   1.0    6  0.1772727  0.12024233
 11      3   2.0    6  0.1872727  0.11722221
 12      3   4.0    6  0.1872727  0.11722221

svm.model <- svm(grupo ~ altfac + proffac, data=face,
                  type='C-classification', kernel='polynomial',
                  degree=3, gamma=1, cost=4, coef0=1, scale=FALSE)
summary(svm.model)

Parameters:
  SVM-Type: C-classification
  SVM-Kernel: polynomial
  cost: 4

```

```

degree: 3
coef.0: 1
Number of Support Vectors: 40
( 11 10 19 )Number of Classes: 3
Levels:
braq dolico meso

```

A tabela de classificação é

		true		
pred	braq	dolico	meso	
braq	29	0	4	
dolico	0	26	3	
meso	4	5	30	

O gráfico correspondente está apresentado na Figura 9.9.

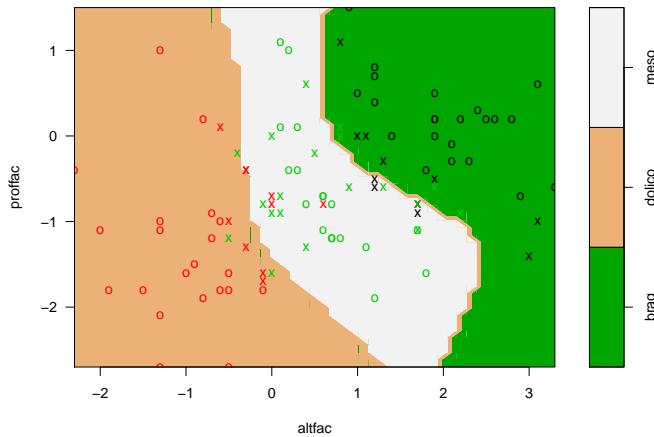


Figura 9.9: Classificação do tipo facial obtida pelo classificador de margem não linear (símbolos vermelhos = dolicocéfalos, verdes = mesocéfalos, pretos = braquicéfalos).

Neste caso, o número de classificações erradas (9) é menor do que no caso do classificador de margem flexível (16).

Com base nesses resultados, podemos classificar indivíduos para os quais dispomos apenas dos valores das variáveis preditoras. Com essa finalidade, consideremos o seguinte conjunto de previsão com 4 indivíduos:

	paciente	altfac	proffac
1	102	1.4	1.0
2	103	3.2	0.1
3	104	-2.9	-1.0
4	105	0.5	0.9

Por meio dos seguintes comandos

```

svm.model <- svm(grupo ~ altfac + proffac, data=face, type='C-classification',
                   kernel='polynomial', degree=3, gamma=1, cost=4, coef0=1,
                   scale=FALSE, probability=TRUE)
prednovos <- predict(svm.model, teste, probability=TRUE)

```

obtemos a tabela com as probabilidades de classificação de cada um dos 4 indivíduos

```

      1      2      3      4
braq    braq  dolico   meso
attr(,"probabilities")
      braq        dolico        meso
1 0.954231749 0.0193863931 0.0263818582
2 0.961362058 0.0006154201 0.0380225221
3 0.008257919 0.9910764215 0.0006656599
4 0.254247666 0.1197179567 0.6260343773
Levels: braq dolico meso

```

O processo classifica os indivíduos 102 e 103 como braquicéfalos, o indivíduo 103 como dolicocéfalo e o 104, como mesocéfalo.

9.6 Notas de Capítulo

1) Hiperplano separador

Um hiperplano definido num espaço de dimensão p é um **subespaço** de dimensão $p - 1$ definido por

$$\alpha + \beta_1 X_1 + \dots + \beta_p X_p = 0. \quad (9.11)$$

Um ponto com coordenadas (x_1, \dots, x_p) satisfazendo (9.11) situa-se no hiperplano. Se $\alpha + \beta_1 x_1 + \dots + \beta_p x_p > 0$, esse ponto situa-se num lado do hiperplano e se $\alpha + \beta_1 x_1 + \dots + \beta_p x_p < 0$, o ponto situa-se no outro lado desse hiperplano. Dessa forma, o hiperplano separa o espaço p dimensional em duas metades.

2) CMM – Classificador de margem máxima

Nesta seção, baseada em Bishop (2006), procuramos detalhar o algoritmo utilizado para obtenção do hiperplano separador

$$f(\mathbf{x}) = \alpha + \boldsymbol{\beta}^\top \mathbf{x}. \quad (9.12)$$

Consideremos o espaço característico $\mathcal{T} = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$ e as respostas y_1, \dots, y_n com $y_i \in \{-1, 1\}$, definindo o conjunto de treinamento. Novos dados \mathbf{x}_0 são classificados de acordo com o sinal de $f(\mathbf{x}_0)$.

Suponha que exista um hiperplano separador, de modo que α e $\boldsymbol{\beta}$ são tais que $f(\mathbf{x}) > 0$, para pontos com $y = +1$ e $f(\mathbf{x}) < 0$, para pontos com $y = -1$, de modo que $y f(\mathbf{x}) > 0$, para qualquer dado de treinamento.

Podem existir muitos hiperplanos que separam as classes exatamente, como na Figura 9.1. O CMM tem como objetivo maximizar a margem que é a menor distância entre o hiperplano e qualquer ponto do conjunto de treinamento.

Para entender o procedimento de otimização, considere a distância de um ponto \mathbf{x} ao hiperplano cuja equação é $f(\mathbf{x}) = 0$, nomeadamente

$$d = |f(\mathbf{x})| / \|\boldsymbol{\beta}\|,$$

em que denominador indica a norma do vetor $\boldsymbol{\beta}$. Como o interesse está nos pontos que são corretamente classificados, devemos ter $y_i f(\mathbf{x}_i) > 0$, $i = 1, \dots, n$. Logo, a distância entre qualquer ponto \mathbf{x}_i e o hiperplano é

$$\frac{y_i f(\mathbf{x}_i)}{\|\boldsymbol{\beta}\|} = \frac{y_i (\alpha + \boldsymbol{\beta}^\top \mathbf{x}_i)}{\|\boldsymbol{\beta}\|}. \quad (9.13)$$

A margem é a distância do hiperplano ao ponto \mathbf{x} mais próximo e queremos escolher α e β de modo a maximizar essa distância. A margem máxima é obtida por meio da resolução de

$$\operatorname{argmax}_{\alpha, \beta} \left\{ \frac{1}{\|\beta\|} \min \left[y_i (\alpha + \beta^\top \mathbf{x}_i) \right] \right\}. \quad (9.14)$$

A solução de (9.14) é complicada mas é possível obtê-la por meio da utilização de **multiplicadores de Lagrange**. Note que se multiplicarmos α e β por uma constante, a distância de um ponto \mathbf{x} ao hiperplano separador não se altera (veja o Exercício 1). Logo podemos considerar a transformação $\alpha^* = \alpha/f(\mathbf{x})$ e $\beta^* = \beta/f(\mathbf{x})$ e para o ponto mais próximo do hiperplano, digamos \mathbf{x}^* , obtendo

$$y^*(\alpha + \beta^\top \mathbf{x}^*) = 1, \quad (9.15)$$

e consequentemente, $d = \|\beta\|^{-1}$. Desse modo, todos os pontos do conjunto de treinamento satisfarão

$$y_i(\alpha + \beta^\top \mathbf{x}_i) \geq 1, \quad i = 1, \dots, n. \quad (9.16)$$

Esta relação é chamada **representação canônica do hiperplano separador**. Dizemos que há uma **restrição ativa** para os pontos em que há igualdade; para os pontos em que vale a desigualdade, dizemos que há uma **restrição inativa**. Como sempre haverá um ponto que está mais próximo do hiperplano, sempre haverá uma restrição ativa.

Então, o problema de otimização implica maximizar $\|\beta\|^{-1}$, que é equivalente a minimizar $\|\beta\|^2$. Na linguagem de Vapnik (1995), isso equivale a escolher $f(\mathbf{x})$ de maneira que seja a mais achatada (*flat*) possível, que por sua vez implica que β deve ser pequeno. Isso corresponde à resolução do problema de **programação quadrática**

$$\operatorname{argmin}_{\alpha, \beta} \left\{ \frac{1}{2} \|\beta\|^2 \right\}, \quad (9.17)$$

sujeito a (9.16). O fator $1/2$ é introduzido por conveniência.

Com esse objetivo, para cada restrição em (9.16), introduzimos os multiplicadores de Lagrange $\lambda_i \geq 0$, obtendo a função lagrangeana

$$L(\alpha, \beta, \lambda) = \frac{1}{2} - \sum_{i=1}^n \lambda_i [y_i(\alpha + \beta^\top \mathbf{x}_i) - 1], \quad (9.18)$$

em que $\lambda = (\lambda_1, \dots, \lambda_n)^\top$. O sinal negativo no segundo termo de (9.18) justifica-se por que queremos minimizar em relação a α e β e maximizar em relação a λ .

Derivando L em relação a β e a λ , obtemos

$$\beta = \sum_{i=1}^n \lambda_i y_i \mathbf{x}_i \quad \text{e} \quad \sum_{i=1}^n \lambda_i y_i = 0. \quad (9.19)$$

Eliminando α e β em (9.18) e usando (9.19), obtemos a chamada **representação dual** do problema da margem máxima, no qual maximizamos

$$\tilde{L}(\lambda) = \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j), \quad (9.20)$$

com respeito a λ , sujeito às restrições

$$\lambda_i \geq 0, \quad i = 1, \dots, n, \quad (9.21)$$

$$\sum_{i=1}^b \lambda_i y_i = 0. \quad (9.22)$$

Em (9.20), $K(\mathbf{x}, \mathbf{y}) = \mathbf{x}^\top \mathbf{y}$ é um *kernel* linear, que será estendido para algum *kernel* mais geral com a finalidade de ser aplicado a espaços característicos cuja dimensionalidade excede o número de dados como indicado na Seção 9.2.3,. Esse *kernel* deve ser positivo definido.

Para classificar um novo dado \mathbf{x}_0 usando o modelo treinado, avaliamos o sinal de $f(\mathbf{x}_0)$, que por meio de (9.19), pode ser escrito como

$$f(\mathbf{x}_0) = \alpha + \sum_{i=1}^n \lambda_i y_i K(\mathbf{x}_0, \mathbf{x}_i). \quad (9.23)$$

Pode-se demonstrar (veja Bishop, 2006), que esse tipo de otimização restrita satisfaz certas condições, chamadas de **condições de Karush-Kuhn-Tucker** (KKT), que implicam

$$\begin{aligned} \lambda_i &\geq 0, \\ y_i f(\mathbf{x}_i) - 1 &\geq 0, \\ \lambda_i (y_i f(\mathbf{x}_i) - 1) &= 0. \end{aligned} \quad (9.24)$$

Para cada ponto, ou $\lambda_i = 0$ ou $y_i f(\mathbf{x}_i) = 1$. Um ponto para o qual $\lambda_i = 0$ não aparece em (9.23) não tem influência na classificação de novos pontos.

Os pontos restantes são chamados **vetores suporte** e satisfazem $y_i f(\mathbf{x}_i) = 1$; logo esses pontos estão sobre as fronteiras do espaço separador, como na Figura 9.3. O valor de α pode ser encontrado a partir de

$$y_i \left(\sum_{j \in S} \lambda_j y_j K(\mathbf{x}_j, \mathbf{x}_i) + \alpha \right) = 1, \quad (9.25)$$

em que S é o conjunto dos vetores suporte. Multiplicando essa expressão por y_1 , observando que $y_1^2 = 1$ e tomindo a média de todas as equações sobre S , obtemos

$$\alpha = \frac{1}{n_S} \sum_{i \in S} \left(y_i - \sum_{j \in S} \lambda_j y_j K(\mathbf{x}_j, \mathbf{x}_i) \right), \quad (9.26)$$

em que n_S é o número de vetores suporte.

3) CMF – Classificador de margem flexível

Vamos considerar agora, o caso em que as duas classes podem se sobrepor. Precisamos modificar o CMM para permitir que alguns pontos do conjunto de treinamento sejam classificados erroneamente. Para isso introduzimos uma penalidade, que cresce com a distância ao hiperplano separador. Isso é conseguido pela introdução de **variáveis de folga** (*slack*) $\xi_i \geq 0, i = 1, \dots, n$, uma para cada dado.

Então, $\xi_i = 0$ para pontos sobre ou dentro da fronteira correta [delimitada por $f(\mathbf{x}) = -1$ e $f(\mathbf{x}) = 1$] e ξ_i dado pela distância do ponto à fronteira, para os outros pontos. Assim, um ponto que estiver sobre o hiperplano $f(\mathbf{x}) = 0$ terá $\xi_i = 1$ e pontos com $\xi_i > 1$ são classificados erroneamente. Nesse caso, a restrição (9.16) será substituída por

$$y_i(\alpha + \boldsymbol{\beta}^\top \mathbf{x}_i) \geq 1 - \xi_i, \quad i = 1, \dots, n, \quad (9.27)$$

com $\xi_i \geq 0$. Pontos para os quais $\xi_i = 0$ são corretamente classificados e estão sobre a fronteira da margem ou do lado correto da fronteira da margem. Pontos para os quais $0 < \xi_i \leq 1$ estão dentro da fronteira da margem, mas do lado correto do hiperplano, e pontos para os quais $\xi_i > 1$ estão do lado errado do hiperplano e são classificados erroneamente. Veja a Figura 9.5.

Nesse contexto, estamos diante de uma **margem flexível ou suave**. O objetivo é maximizar a margem e, para isso, minimizamos

$$C \sum_{i=1}^n \xi_i + \frac{1}{2} \|\boldsymbol{\beta}\|^2, \quad (9.28)$$

em que $C > 0$ controla o balanço entre a penalidade das variáveis de folga e a margem.

Como qualquer ponto classificado erroneamente satisfaz $\xi_i > 1$, segue-se que $\sum_{i=1}^n \xi_i$ é um limite superior do número de classificações errôneas. No limite, quando $C \rightarrow \infty$, obtemos o CMM.

Para minimizar (9.28) sujeito a (9.27) e $\xi_i > 0$ consideramos o lagrangeano

$$\begin{aligned} L(\alpha, \boldsymbol{\beta}, \boldsymbol{\xi}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = & \frac{1}{2} \|\boldsymbol{\beta}\|^2 + C \sum_{i=1}^n \xi_i \\ & - \sum_{i=1}^n \lambda_i [y_i f(\mathbf{x}_i) + \xi_i - 1] - \sum_{i=1}^n \mu_i \xi_i, \end{aligned} \quad (9.29)$$

em que $\lambda_i \geq 0, \mu_i \geq 0$ são multiplicadores de Lagrange. Derivando (9.30) com relação a $\boldsymbol{\beta}, \alpha, \boldsymbol{\xi}, \boldsymbol{\lambda}$, obtemos

$$\boldsymbol{\beta} = \sum_{i=1}^n \lambda_i y_i \mathbf{x}_i, \quad \sum_{i=1}^n \lambda_i y_i = 0 \quad (9.30)$$

e

$$\lambda_i = C - \mu_i. \quad (9.31)$$

Substituindo (9.30) - (9.31) em (9.30), temos

$$\tilde{L}(\boldsymbol{\lambda}) = \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_i \sum_j \lambda_i \lambda_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j), \quad (9.32)$$

que é uma expressão idêntica ao caso separável, com exceção das restrições, que são diferentes. Como $\lambda_i \geq 0$ são multiplicadores de Lagrange e como $\mu_i \geq 0$, de (9.31) segue que $\lambda_i \leq C$. Logo, precisamos maximizar (9.32) com respeito às variáveis duais λ_i , sujeito a

$$0 \leq \lambda_i \leq C, \quad (9.33)$$

$$\sum_{i=1}^n \lambda_i y_i = 0, \quad i = 1, \dots, n. \quad (9.34)$$

Novamente, estamos diante de um problema de programação quadrática. A previsão para um novo ponto \mathbf{x} é obtida avaliando o sinal de $f(\mathbf{x})$ em (9.12). Substituindo (9.30) em (9.12) obtemos

$$f(\mathbf{x}) = \alpha + \sum_{i=1}^n \lambda_i y_i K(\mathbf{x}, \mathbf{x}_i). \quad (9.35)$$

Dados para os quais $\lambda_i = 0$ não contribuem para (9.35). Os dados restantes formam os vetores de suporte. Para esses, $\lambda_i > 0$ e, por (9.37) abaixo, devem satisfazer

$$y_i f(\mathbf{x}_i) = 1 - \xi_i. \quad (9.36)$$

No caso de CMF, as condições de KKT são dadas por

$$\lambda_i \geq 0, \quad y_i f(\mathbf{x}_i) - 1 + \xi_i \geq 0,$$

$$\lambda_i(y_i f(\mathbf{x}_i) - 1 + \xi_i) = 0, \quad (9.37)$$

$$\mu_i \geq 0, \quad \xi_i \geq 0,$$

$$\mu_i \xi_i = 0, \quad i = 1, \dots, n. \quad (9.38)$$

Procedendo como no caso de CMM, obtemos

$$\alpha = \frac{1}{N_{\mathcal{M}}} \sum_{i \in \mathcal{M}} \left(y_i - \sum_{j \in S} \lambda_j y_j K(\mathbf{x}_i, \mathbf{x}_j) \right), \quad (9.39)$$

em que \mathcal{M} é o conjunto do pontos tais que $0 < \lambda_i < C$.

Se $\lambda_i < C$, então, por (9.31), $\mu_i > 0$ e por (9.38), temos $\xi = 0$ e tais pontos estão na fronteira de separação. Pontos com $\lambda_i = C$ estão dentro da fronteira de separação e podem ser classificados corretamente se $\xi_i \leq 1$ e erroneamente se $\xi_i > 1$.

4) Classificador de margem não linear

Seja \mathcal{X} o conjunto de dados (ou de padrões). A função $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ é um *kernel* se existir um espaço vetorial com produto interno, \mathcal{H} (usualmente um espaço de Hilbert) e uma aplicação $\Phi : \mathcal{X} \rightarrow \mathcal{H}$, tal que, para todos $x, y \in \mathcal{X}$, tivermos

$$K(x, y) = \langle \Phi(x), \Phi(y) \rangle. \quad (9.40)$$

Φ é a aplicação característica e \mathcal{H} , o espaço característico.

Por exemplo, tomemos $\mathcal{X} = \mathbb{R}^2$ e $\mathcal{H} = \mathbb{R}^3$ e definamos

$$\begin{aligned} \Phi : \mathbb{R}^2 &\rightarrow \mathbb{R}^3, \\ (x_1, x_2) &\rightarrow (x_1^2, x_2^2, \sqrt{2}x_1x_2). \end{aligned}$$

Então, se $x = (x_1, x_2)$ e $y = (y_1, y_2)$, é fácil verificar que $\langle \Phi(x), \Phi(y) \rangle = \langle x, y \rangle$; logo $K(x, y) = \langle \Phi(x), \Phi(y) \rangle = \langle x, y \rangle$ é um *kernel*.

Para tornar o algoritmo de suporte vetorial não linear, notamos que ele depende somente de produtos internos entre os vetores de \mathcal{X} ; logo, é suficiente conhecer $K(\mathbf{x}, \mathbf{x}^\top) = \langle \Phi(\mathbf{x}), \Phi(\mathbf{x}^\top) \rangle$, e não de Φ explicitamente. Isso permite formular o problema de otimização, substituindo (9.30) por

$$\beta = \sum_{i=1}^n \alpha_i \Phi(\mathbf{x}_i) \quad (9.41)$$

e $f(\mathbf{x})$ dado por (9.10). Agora, β não é mais dado explicitamente como antes. Também, o problema de otimização é agora realizado no espaço característico e não em \mathcal{X} .

Os *kernels* a serem usados têm que satisfazer certas condições de admissibilidade. Veja Smola e Schölkopf (2004) para detalhes. Os *kernels* mencionados na Seção 9.2.3 são admissíveis.

5) Classificação com mais de duas classes

Para casos em que há mais de duas classes, duas abordagens são possíveis:

a) Classificação **uma contra uma** (*one-versus-one*)

Se tivermos K classes, são construídos $\binom{K}{2}$ classificadores, cada um com duas classes. Para uma observação teste \mathbf{x} , contamos quantas vezes essa observação é associada a cada uma das K classes. O classificador final é obtido associando a observação teste à classe que recebeu mais associações dentre as $\binom{K}{2}$ classificações duas a duas.

(b) Classificação **uma contra todas** (*one-versus-all*)

Consideramos K classificadores, cada vez comparando uma classe com as restantes $K - 1$ classes. Sejam $\alpha_k, \beta_{1k}, \dots, \beta_{pk}$ os parâmetros associados ao k -ésimo classificador. Para uma observação teste \mathbf{x}^* , vamos associá-la à classe para a qual $\alpha_k + \beta_{1k}x_1^* + \dots + \beta_{pk}x_p^*$ seja a maior possível.

Os resultados obtidos podem ser inconsistentes. Veja Bishop (2006), para outras sugestões.

9.7 Exercícios

- 1) No contexto do classificador de margem máxima, mostre que se multiplicarmos os coeficientes α e β por uma constante, a distância de qualquer ponto ao hiperplano separador não se alterá.
- 2) Explique a relação entre valores de C em (9.9) e viés-variância.
- 3) Reanalise os dados do Exemplo 9.3 usando um *kernel* radial.
- 4) No Exemplo 9.3 foram usados 2 atributos. Reanalise-o o exemplo, usando 4 atributos e note que a acurácia da classificação melhora sensivelmente.
- 5) Considere os pontos da Figura 9.2. Use o CMF e o CBK.
- 6) Use função `tune()` do `e1071` para escolher o melhor modelo para os Exemplos 9.2 e 9.3.

Classificação por árvores e florestas

10.1 Introdução

Modelos baseados em árvores foram desenvolvidos na década de 1980 por Leo Breiman e associados e são bastante utilizados tanto para classificação quanto para previsão. Esses modelos são baseados numa segmentação do espaço gerado pelas variáveis explicativas (preditoras) em algumas regiões em que ou a moda (no caso de variáveis respostas categorizadas) ou a média (no caso de variáveis contínuas) é utilizada como predição. A definição dessas regiões é baseada em alguma medida de erro de previsão (ou de classificação). Em geral, as árvores são construídas a partir de um conjunto de **observações de treinamento** e testadas em um conjunto de **observações de teste**. Os modelos de árvores de decisão são conceitualmente e computacionalmente simples e bastante populares em função de sua interpretabilidade, apesar de serem menos precisos que modelos de regressão, por exemplo. Generalizações dos modelos originais, conhecidos como **florestas aleatórias** (*random forests*) costumam apresentar grande precisão, mesmo quando comparados com modelos lineares, porém pecam pela dificuldade de interpretação. A referência básica para esse tópico é Breiman et al. (1984). O texto de Hastie and Tibshirani (1990) também contém resultados sobre o tema.

Para predizer o valor de uma variável resposta Y (no caso de variáveis contínuas) ou classificar as observações em uma de suas categorias (no caso de variáveis categorizadas) a partir de um conjunto de variáveis preditoras X_1, \dots, X_p , o algoritmo usado na construção de árvores de decisão consiste essencialmente na determinação das regiões (retângulos mutuamente exclusivos) em que o espaço das variáveis preditoras é particionado. A metodologia desenvolvida em Breiman et al. (1994), conhecida como **CART** (de *Classification And Regression Trees*) é baseada na seguinte estratégia:

- a) Considere uma partição do espaço das variáveis preditoras (conjuntos dos possíveis valores de X_1, \dots, X_p) em M regiões, R_1, \dots, R_M .
- b) Para cada observação pertencente a R_j , o previsor (ou categoria) de Y (que designaremos \hat{Y}_{R_j}) será a moda (no caso discreto), a média (no caso contínuo) ou a classe de Y com maior frequência (no caso categorizado) entre os pontos com valores de X_1, \dots, X_p em R_j .

Embora a partição do espaço das variáveis preditoras seja arbitrária, usualmente ela é composta por retângulos p -dimensionais que devem ser construídos de modo a

minimizar alguma medida de erro de previsão ou de classificação (que explicitaremos posteriormente). Como esse procedimento geralmente não é computacionalmente factível dado o número de partições possíveis, mesmo com p moderado, usa-se uma **divisão binária recursiva** (*recursive binary splitting, RBS*) que é uma abordagem “de cima para baixo e gananciosa” (*top-down and greedy*) segundo James et al. (2013). A primeira locução justifica-se pelo fato de o procedimento ter início no topo da árvore (em que as observações estão todas na mesma região do espaço das variáveis preditoras) e a segunda, porque a melhor decisão é tomada em cada passo, sem avaliar se uma decisão melhor não poderia ser tomada num passo futuro.

Dado o vetor de variáveis preditoras $\mathbf{X} = (X_1, \dots, X_p)^\top$, o algoritmo consiste dos passos:

- i) Selecione uma variável preditora X_j e um limiar (ou ponto de corte) t , de modo que a divisão do espaço das variáveis preditoras nas regiões $\{\mathbf{X} : X_j < t\}$ e $\{\mathbf{X} : X_j \geq t\}$ corresponda ao menor erro de previsão (ou de classificação).
- ii) Para todos os pares (j, t) , considere as regiões

$$R_1(j, t) = \{\mathbf{X} : X_j < t\}, \quad R_2(j, t) = \{\mathbf{X} : X_j \geq t\}$$

e encontre o par (j, s) que minimiza o erro de previsão (ou de classificação) adotado.

- iii) Repita o procedimento, agora dividindo uma das duas regiões encontradas, obtendo três regiões; depois divida cada uma dessas três regiões minimizando o erro de previsão (ou de classificação).
- iv) Continue o processo até que algum critério de parada (obtenção de um número mínimo fixado de observações em cada região, por exemplo) seja satisfeito.

10.2 Classificação por árvores

Quando a variável resposta Y é categorizada, o objetivo é identificar a classe mais provável (**classe modal**) associada aos valores $\mathbf{X} = (X_1, \dots, X_p)^\top$ das variáveis preditoras. Neste caso, uma medida de erro de classificação, comumente denominada **taxa de erros de classificação** (*TEC*) é a proporção de observações do conjunto de treinamento que não pertencem à classe modal. Outras medidas de erro de classificação, como **índice de Gini** ou **entropia cruzada** também podem ser usadas. Veja a Nota de Capítulo 1.

Admitamos que a variável resposta tenha K classes e que o espaço de variáveis preditoras seja particionado em M regiões. Designando por \hat{p}_{mk} , a proporção de observações de treinamento da m -ésima região, $m = 1, \dots, M$, pertencentes à k -ésima classe $k = 1, \dots, K$, a taxa de erros de classificação dos elementos pertencentes à m -ésima região é

$$TEC_m = 1 - \max_k(\hat{p}_{mk}).$$

Utilizaremos um exemplo para descrever o processo de construção de uma árvore de decisão. Vários pacotes (`tree`, `partykit`, `rpart`) podem ser utilizados com esse propósito. Cada um desses pacotes é regido por parâmetros que controlam diferentes aspectos da construção das árvores e não pretendemos discuti-los. O leitor interessado deverá consultar os manuais correspondentes com o objetivo de nortear uma seleção adequada para problemas específicos.

Exemplo 10.1 Consideremos novamente os dados analisados no Exemplo 9.2, disponíveis no arquivo `tipofacial`, extraídos de um estudo cujo objetivo era avaliar se duas ou mais medidas ortodônticas poderiam ser utilizadas para classificar indivíduos segundo o tipo facial (braquicéfalo, mesocéfalo ou doliocéfalo). Como no Exemplo 9.2, para efeitos didáticos consideramos apenas duas variáveis preditoras, correspondentes a duas distâncias de importância ortodôntica, nomeadamente, a altura facial (`altfac`) e a profundidade facial (`proffac`). Os comandos do pacote `partykit` (com os parâmetros `default`) para a construção da árvore de classificação e do gráfico correspondente seguem juntamente com os resultados

```
> facetree <- ctree(grupo ~ altfac + proffac, data=face)

Model formula:
grupo ~ altfac + proffac

Fitted party:
[1] root
| [2] altfac <= -0.1: dolico (n = 31, err = 9.7%)
| [3] altfac > -0.1
|   | [4] altfac <= 0.8: meso (n = 28, err = 14.3%)
|   | [5] altfac > 0.8
|   |   | [6] proffac <= -0.6: meso (n = 17, err = 41.2%)
|   |   | [7] proffac > -0.6: braq (n = 25, err = 0.0%)

Number of inner nodes:    3
Number of terminal nodes: 4
> plot(facetree)
```

A variável preditora principal e o correspondente ponto de corte que minimiza a taxa de erros de classificação são `altfac` e $t = -0,1$, com $TEC_1 = 9,7\%$. Para observações com valores $altfac \leq -0,1$ (região R_1), classificamos o indivíduo como doliocéfalo. Para valores de $altfac > -0,1$, a classificação depende do valor de `proffac`. Nesse caso, se `altfac` estiver entre $-0,1$ e $0,8$, (região R_2), classificamos o indivíduo como mesocéfalo com $TEC_2 = 14,3\%$; se, por outro lado, $altfac > 0,8$ e $proffac \leq -0,6$, também classificamos o indivíduo como mesocéfalo (região R_3), com $TEC_3 = 41,2\%$; agora, se $altfac > 0,8$ e $proffac > -0,6$, o indivíduo deve ser classificado como braquicéfalo (região R_4), com $TEC_4 = 0,0\%$.

Na Figura 10.1, os símbolos ovais, que indicam divisões no espaço das variáveis preditoras são chamados de **nós internos** e os retângulos, que indicam as divisões finais são conhecidos por **nós terminais** ou **folhas** da árvore. Neste exemplo, temos 3 nós internos e 4 nós terminais. Os segmentos que unem os nós são os **galhos** da árvore. Os gráficos de barras apresentados em cada nó terminal indicam a frequência relativa com que as observações que satisfazem as restrições definidoras de cada galho são classificadas nas diferentes categorias da variável resposta.

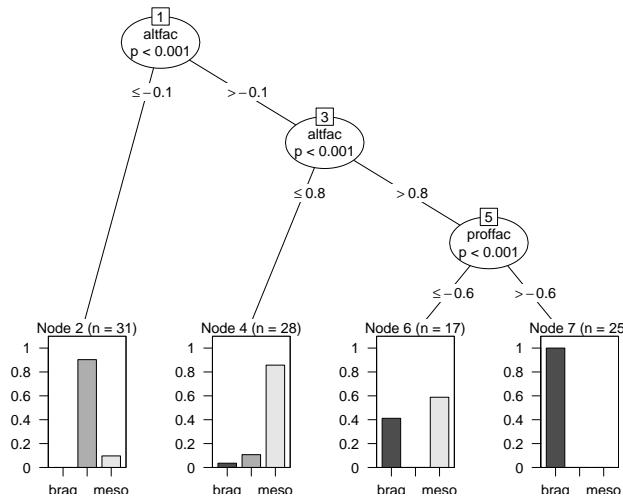


Figura 10.1: Árvore de decisão para os dados do Exemplo 10.1.

As regiões em que o espaço das variáveis preditoras foi particionado estão indicadas na Figura 10.2.

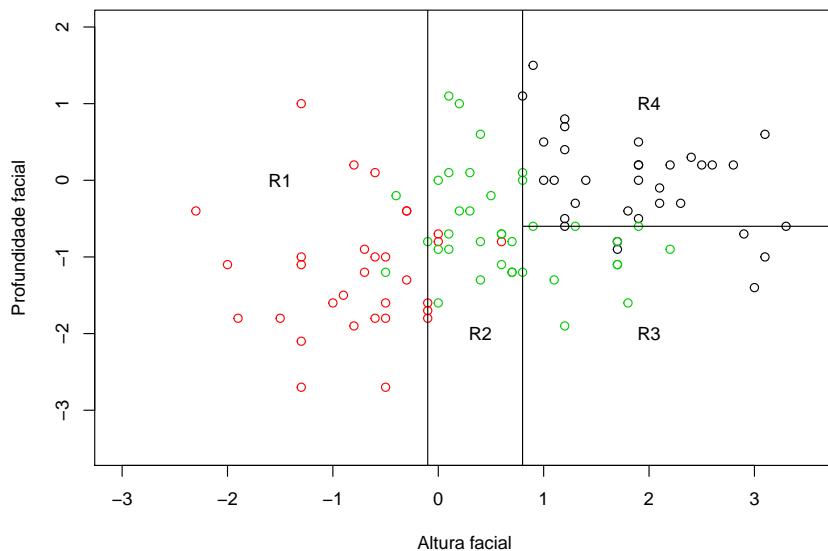


Figura 10.2: Partição do espaço das variáveis preditoras do Exemplo 10.1 (círculos vermelhos = dolicocéfalos, verdes = mesocéfalos, pretos = braquicéfalos).

Uma tabela com a classificação real (nas linhas) e predita por meio da árvore de classificação (nas colunas) é obtida por meio do comando `predict`

	braq	dolico	meso
braq	25	0	0
dolico	0	28	3
meso	8	3	34

e indica uma taxa de erros de classificação de 13,9% ($16/101 \times 100\%$).

Um dos problemas associados à construção de árvores de decisão está relacionado com o **sobreajuste** (*overfitting*). Se não impusermos uma regra de parada para a construção dos nós, o processo é de tal forma flexível que o resultado final pode ter tantos nós terminais quantas forem as observações, gerando uma árvore em que cada observação é classificada perfeitamente. Para contornar esse problema, pode-se considerar o procedimento conhecido como **poda**, que engloba técnicas para limitar o número de nós terminais das árvores. A ideia que fundamenta essas técnicas está na construção de árvores com menos nós e, consequentemente com menor variância e interpretabilidade. O preço a pagar é um pequeno aumento no viés. Para detalhes, consulte a Nota de Capítulo 2.

Exemplo 10.2 Consideremos agora os dados do arquivo **coronarias** provenientes de um estudo cujo objetivo era avaliar fatores prognósticos para lesão obstrutiva coronariana (L03) com categorias $1 : \geq 50\%$ ou $0 : < 50\%$. Embora tenham sido observadas cerca de 70 variáveis preditoras, aqui trabalharemos com **SEXO** (0=fem, 1=masc), **IDADE1** (idade), **IMC** (índice de massa corpórea), **DIAB** (diabetes: 0=não, 1=sim), **TRIG** (concentração de triglicérides) e **GLIC** (concentração de glicose). Com propósito didático eliminamos casos em que havia dados omissos em alguma dessas variáveis, de forma que 1034 pacientes foram considerados na análise.

Os comandos do pacote **rpart** para a construção da árvore de classificação por meio de validação cruzada com os resultados correspondentes seguem

```
> lesaoobs <- rpart(formula = L03 ~ GLIC + SEXO + IDADE1 + DIAB + TRIG
+ IMC, data = coronarias3, method = "class", xval = 20,
minsplit = 10, cp = 0.005)
> printcp(lesaoobs)

Variables actually used in tree construction:
[1] GLIC    IDADE1  IMC     SEXO    TRIG

Root node error: 331/1034 = 0.32012
n= 1034

      CP nsplit rel error  xerror       xstd
1 0.0453172     0  1.00000 1.00000 0.045321
2 0.0392749     3  0.85801 0.97281 0.044986
3 0.0135952     4  0.81873 0.88218 0.043733
4 0.0090634     6  0.79154 0.87915 0.043687
5 0.0075529     7  0.78248 0.88822 0.043823
6 0.0060423    11  0.75227 0.92749 0.044386
7 0.0050000    13  0.74018 0.97885 0.045062
```

O erro relativo mede o erro de classificação dos dados de treinamento obtido por intermédio do modelo. O termo rotulado **xerror** é o erro de predição obtido por validação cruzada e o correspondente erro padrão é rotulado **xstd**. Cada linha da tabela CP representa um nível diferente da árvore. O erro de classificação obtido por validação cruzada tende a aumentar, pelo menos após o nível ótimo. Uma regra de parada prática consiste em selecionar o nível para o qual **rel error + xstd < xerror**. O gráfico correspondente, obtido por intermédio do comando

```
> rpart.plot(lesaoobs, clip.right.labs = TRUE, under = FALSE,
extra = 101, type=4)
```

está disposto na Figura 10.3

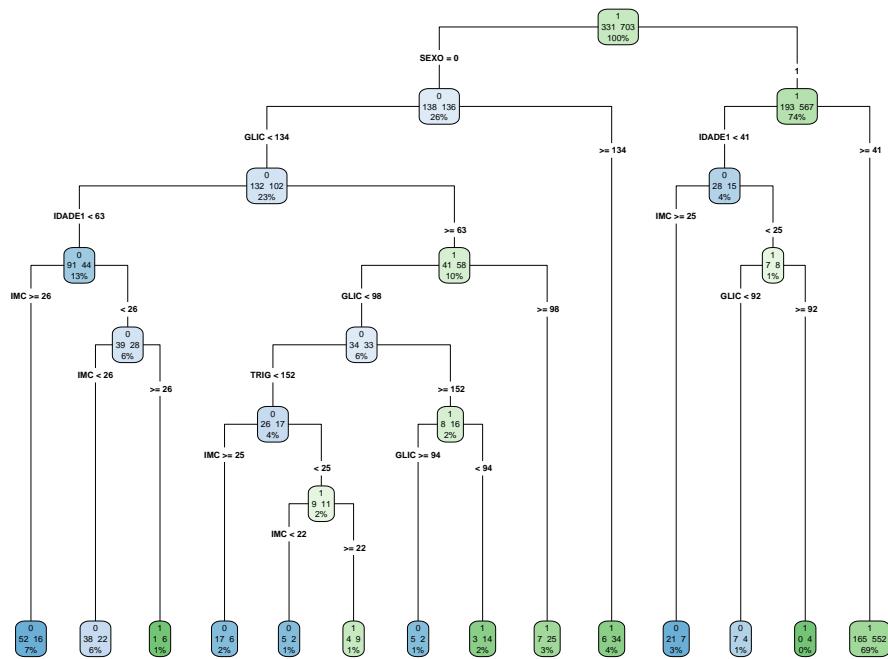


Figura 10.3: Árvore de decisão para os dados do Exemplo 10.2.

A tabela com a classificação real (nas linhas) e predita pela árvore (nas colunas) é obtida por meio do comando

```
> table(coronarias3$L03, predict(lesaoobs, type="class"))
      0    1
0 145 186
1  59 644
```

e indica um erro de classificação de $23,4\% = (186 + 59)/1034$.

O parâmetro CP (*complexity parameter*) serve para controlar o tamanho da árvore e corresponde ao menor incremento no custo do modelo necessário para a adição de uma nova variável. Em geral, quanto mais níveis a árvore apresenta, menor será o erro de classificação, mas com o risco de sobreajuste (*overfitting*). Esse parâmetro pode ser usado para controlar esse sobreajuste sugerindo que a árvore deva ser podada (ver Nota de Capítulo 2). Um gráfico em que a variação desse parâmetro é apresentada em função do número de nós, obtido com o comando `plotcp()` pode ser visto na Figura 10.4.

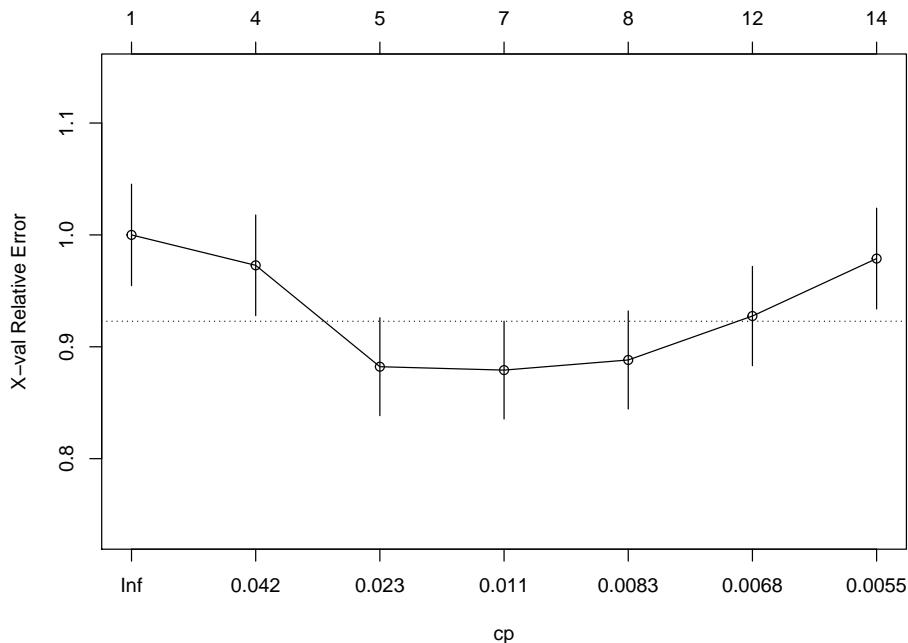


Figura 10.4: Gráfico CP para o ajuste da árvore aos dados do Exemplo 10.2.

Na Figura 10.4, procura-se o nível para o qual o erro relativo obtido por validação cruzada é mínimo. Para o exemplo, esse nível é 4, sugerindo que a árvore obtida no exemplo deve ser podada. A poda juntamente com o gráfico da árvore podada e a tabela com os correspondentes valores preditos podem ser obtidos com os comandos

```
> lesaoobspoda <- prune(lesaoobs, cp = 0.015 , "CP", minsplit=20, xval=25)
> rpart.plot(lesaoobspoda, clip.right.labs = TRUE, under = FALSE,
             extra = 101, type=4)
> rpart.rules(lesaoobspoda, cover = TRUE)
L03                                              cover
0.33 when SEXO is 0 & IDADE1 < 63 & GLIC < 134    13%
0.35 when SEXO is 1 & IDADE1 < 41                  4%
0.59 when SEXO is 0 & IDADE1 >= 63 & GLIC < 134    10%
0.77 when SEXO is 1 & IDADE1 >= 41                  69%
0.85 when SEXO is 0 & GLIC >= 134                  4%
```

A árvore podada está representada graficamente na Figura 10.5.

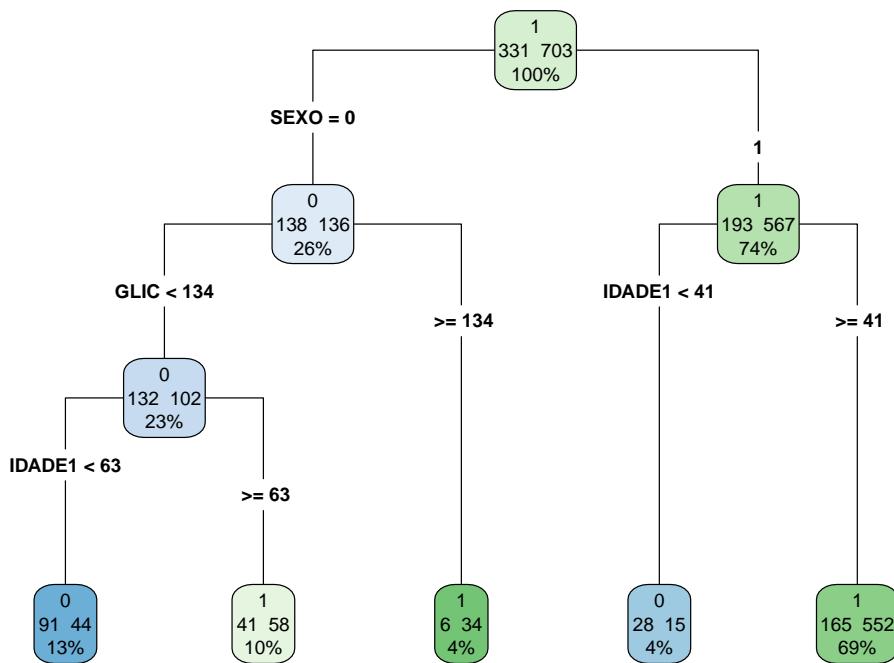


Figura 10.5: Gráfico CP para o ajuste da árvore (podada) aos dados do Exemplo 10.2.

O número indicado na parte superior de cada nó da Figura 10.5 indica a classe modal na qual são classificadas as observações; o valor à esquerda no centro do nó representa a frequência de observações do conjunto de dados pertencentes à classe $LO_3 = 0$ e o valor à direita corresponde à frequência de observações do conjunto de dados pertencentes à classe $LO_3 = 1$. Na última linha aparece a porcentagem de observações correspondentes ao nó. A tabela de classificação obtida a partir da árvore podada é

0	1
0	119 212
1	59 644

Nessa tabela, as linhas indicam a classificação real e as colunas informam a classificação predita pela árvore podada. O erro de classificação, 26,2%, é ligeiramente maior que o erro obtido com a árvore original, bem mais complexa.

10.3 Bagging, boosting e florestas

De um modo geral, árvores de decisão produzem resultados com grande variância, ou seja, dependendo de como o conjunto de dados é subdividido em conjuntos de treinamento e de teste, as árvores produzidas podem gerar resultados diferentes. As técnicas que descreveremos nesta seção têm a finalidade de reduzir essa variância.

10.3.1 Bagging

De modo geral, a técnica de **agregação bootstrap** (*bootstrap aggregating*) ou, simplesmente **bagging**, é um método para gerar múltiplas versões de um previsor (ou classificador) a partir de vários conjuntos de treinamento e, com base nessas versões, construir um previsor (ou classificador) agregado. A variância desse previsor agregado deve ser menor do que a variância de cada um dos previsores individuais, com o mesmo espírito do que observamos com a variância da média de diferentes valores de uma variável relativamente à variância de um único valor.

A ideia básica é considerar um conjunto de previsores (**classificadores fracos**) de modo a obter um **previsor (classificador) forte**. Classificadores fracos têm taxas de erro de classificação altas. No caso binário, por exemplo, isso corresponde a uma taxa próxima de 0,50, que seria obtida com uma decisão baseada num lançamento de moeda. Um classificador forte, por outro lado, tem uma taxa de erro de classificação baixa.

Como em geral não dispomos de vários conjuntos de treinamento, a alternativa é utilizar réplicas bootstrap do conjunto de treinamento acessível para a obtenção das versões do preditor (ou classificador) que serão agregadas. Detalhes sobre a técnica bootstrap podem ser obtidos na Nota de Capítulo 3.

Para facilitar a exposição, consideremos um **problema de regressão** cujo objetivo é prever uma variável resposta quantitativa y a partir de um conjunto de treinamento $(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)$. Nesse caso, a técnica consiste em obter B réplicas bootstrap desse conjunto, para cada conjunto de treinamento bootstrap, $b = 1, \dots, B$, construir uma árvore de decisão, determinar, a partir dessa árvore, o previsor de y , digamos $\hat{f}^b(\mathbf{x})$, e agregá-los obtendo o previsor

$$\hat{f}_{\text{bag}}(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B \hat{f}^b(\mathbf{x}).$$

No caso de classificação, para uma determinada observação de treinamento, \mathbf{x} , calcula-se o classificador $\hat{c}^b(\mathbf{x})$ em cada uma das B árvores geradas e adota-se como o valor do classificador agregado $\hat{c}_{\text{bag}}(\mathbf{x})$ a classe k^* correspondente àquela com maior ocorrência. Esse procedimento é conhecido como escolha pelo **voto majoritário**). Especificamente,

$$\hat{c}_{\text{bag}}(\mathbf{x}) = \text{argmax}_k [\#\{(b|\hat{c}^b(\mathbf{x}) = k)\}]$$

em que $\#\{A\}$ denota a cardinalidade do conjunto A .

Com uma ordem de grandeza de 200 réplicas bootstrap em geral se conseguem bons resultados. Veja a Nota de Capítulo 3.

Exemplo 10.3 A técnica bagging pode ser aplicada aos dados do Exemplo 10.2 por meio dos comandos

```
> set.seed(054)
>
> # train bagged model
> lesaoobsbag <- bagging(
+   formula = LO3 ~ SEXO + IDADE1+ GLIC,
+   data = coronarias3,
+   nbagg = 200,
+   coob = TRUE,
+   control = rpart.control(minsplit = 20, cp = 0.015)
```

```

+ )
>
> lesaoobsred <- predict(lesaoobsbag, coronarias3)
> table(coronarias3$L03, predict(lesaoobsbag, type="class"))

      0   1
0 117 214
1  78 625

```

Variando a semente do processo aleatório, as taxas de erros de classificação giram em torno de 27% a 28%.

Quatro das 200 árvores obtidas em cada réplica bootstrap podem ser obtidas por meio dos comandos e estão representadas na Figura 10.6

```

as.data.frame(coronarias4)
clr12 = c("#8dd3c7", "#fffffb3", "#bebada", "#fb8072")
n = nrow(coronarias4)
par(mfrow=c(2,2))
sed=c(1,10,22,345)
for(i in 1:4){
  set.seed(sed[i])
  idx = sample(1:100, size=n, replace=TRUE)
  cart = rpart(L03 ~ DIAB + IDADE1 + SEXO, data=coronarias4[idx,], model=TRUE)
  prp(cart, type=1, extra=1, box.col=clr12[i])
}

```

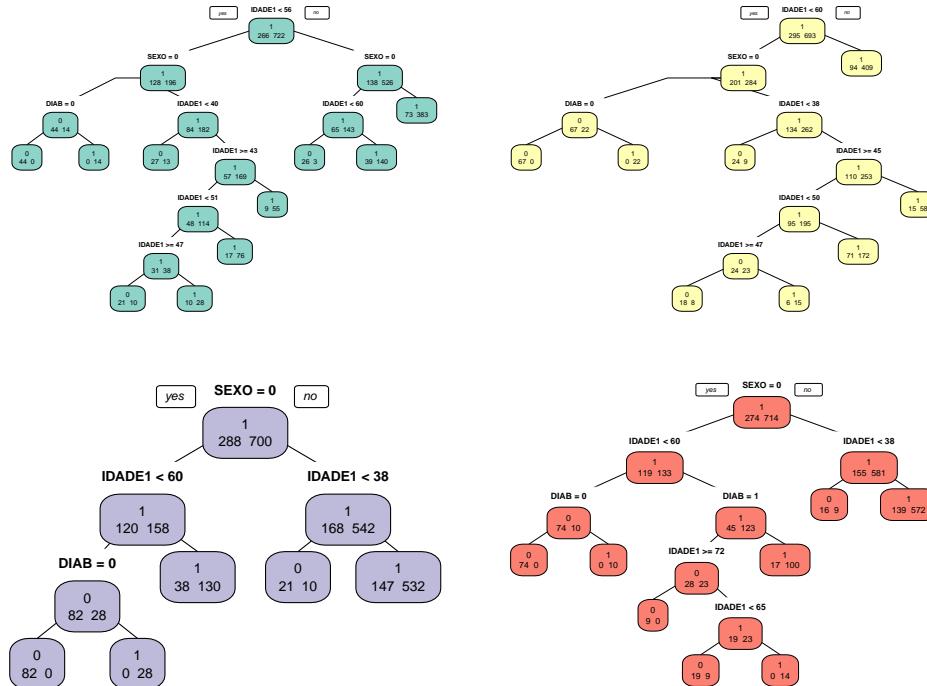


Figura 10.6: Exemplos de árvores obtidas por bagging para os dados do Exemplo 10.2.

10.3.2 Boosting

O objetivo do procedimento **boosting** é reduzir o viés e a variância em modelos utilizados para aprendizado supervisionado.

Diferentemente da técnica bagging, em que B árvores são geradas independentemente por meio de bootstrap, com cada observação tendo a mesma probabilidade de ser selecionada em cada um dos conjuntos de treinamento, no procedimento boosting, as B árvores são geradas **sequencialmente** a partir de um único conjunto de treinamento, com probabilidades de seleção (pesos) diferentes atribuídos às observações. Observações mal classificadas em uma árvore recebem pesos maiores para seleção na árvore subsequente (obtida do mesmo conjunto de treinamento), com a finalidade de dirigir a atenção aos casos em que a classificação é mais difícil.

O classificador final é obtido por meio da aplicação sequencial dos B classificadores fracos gerados com as diferentes árvores. Em cada passo, a classificação de cada observação é baseada no princípio do voto majoritário. Além dos pesos atribuídos às observações no processo de geração dos classificadores fracos, o procedimento boosting atribui pesos a cada um deles, em função das taxas de erros de classificação de cada um. Essencialmente, o classificador forte pode ser expresso como

$$\hat{c}_{\text{boost}}(\mathbf{x}) = \sum_{b=1}^B \hat{c}^b(\mathbf{x}) \alpha(b) \quad (10.1)$$

em que $\alpha(b)$ é o peso atribuído ao classificador $\hat{c}^b(\mathbf{x})$.

Se por um lado, o procedimento bagging raramente reduz o viés quando comparado com aquele obtido com uma única árvore de decisão, por outro, ele tem a característica de evitar o sobreajuste. Essas características são invertidas com o procedimento boosting.

Existem vários algoritmos para a implementação de boosting. O mais usado é o algoritmo conhecido como **AdaBoost** (de *adaptive boosting*), desenvolvido por Freund e Schapire (1997). Dada a dificuldade do processo de otimização de (10.1), esse algoritmo considera um processo iterativo de otimização que produz bons resultados embora não sejam ótimos.

Consideremos, inicialmente, um problema de classificação binária (com $Y \in \{-1, 1\}$) a partir de um conjunto de treinamento com N observações. No algoritmo **AdaBoost**, o classificador sempre parte de um único nó [conhecido como **toco** (*stump*)] em que cada observação tem peso $1/N$. O algoritmo para ajuste consiste dos seguintes passos

- 1) Atribua pesos $w_i(1) = 1/N$ às N observações do conjunto de treinamento.
- 2) Para $b = 1, \dots, B$
 - a) Ajuste o classificador $\hat{c}^b(\mathbf{x})$ às observações do conjunto de treinamento usando os pesos $w_i(b)$, $i = 1, \dots, N$.
 - b) Calcule a taxa de erros

$$\text{erro}(b) = \sum_{i=1}^N w_i(b) I[\hat{c}^b(\mathbf{x}_i) \neq y_i] / \sum_{i=1}^N w_i(b).$$

- c) Calcule o peso do classificador $\hat{c}^b(\mathbf{x})$ por meio de

$$\alpha(b) = \log\{[1 - \text{erro}(b)]/\text{erro}(b)\}.$$

Quanto menor a taxa de erros do classificador, maior será o peso atribuído a ele.

- d) Atualize os pesos das observações do conjunto de treinamento como

$$w_i(b+1) = w_i(b) \exp\{\alpha(b)I[\hat{c}^b(\mathbf{x}_i)]\}, \quad i = 1, \dots, N.$$

O peso das observações corretamente classificadas não se altera; observações mal classificadas têm o peso aumentado.

- e) Normalize os pesos para que $\sum_{i=1}^N w_i(b+1) = 1$.

- 3 Obtenha o classificador $\hat{c}_{boost}(\mathbf{x}) = \text{sign}\{\sum_{b=1}^B \alpha(b)\hat{c}^b(\mathbf{x})\}$ em que $\text{sign}(a) = 1$ se $a > 0$ ou -1 em caso contrário.

Para variáveis respostas com K categorias, podemos utilizar o algoritmo K vezes por meio dos seguintes passos

- i) A partir do conjunto original $\{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_N, y_N)\}$, gere K subconjuntos $\{(\mathbf{x}_1, y_{1k}), \dots, (\mathbf{x}_N, y_{Nk})\}$, $k = 1, \dots, N$ com

$$y_{ik} = \begin{cases} 1, & \text{se } y_i \in k, \\ -1, & \text{se } y_i \notin k. \end{cases}$$

de forma que cada um deles corresponda a um conjunto com resposta binária.

- ii) Utilize o algoritmo **AdaBoost** em cada um dos K subconjuntos, obtendo uma classificação $\hat{c}_{boost}^k(\mathbf{x}_i)$ para cada observação \mathbf{x}_i do conjunto original.
- iii) Utilize o princípio do voto majoritário para obter a classificação $\hat{c}_{boost}(\mathbf{x}_i)$.

Os algoritmos para implementação de boosting têm 3 parâmetros: i) o número de árvores, B , que pode ser determinado por validação cruzada (ver Nota de Capítulo 1 do Capítulo 8); ii) um **parâmetro de encolhimento** (*shrinkage*), $\lambda > 0$, pequeno, da ordem de 0,01 ou 0,001, que controla a velocidade do aprendizado; iii) o número de divisões em cada árvore, d ; como vimos, o AdaBoost, usa $d = 1$ e, em geral, esse valor funciona bem.

O algoritmo pode ser implementado por meio do pacote **adabag**.

Exemplo 10.4 Consideremos novamente os dados do Exemplo 10.2. A classificação por meio de boosting pode ser obtida por meio do comando

```
coronarias3boost <- boosting(L03 ~ GLIC + SEXO + IDADE1 + DIAB + TRIG
+ IMC, data=coronarias3, boos=TRUE, mfinal=100)
```

Além de detalhes sobre os passos gerados pelo algoritmo, o comando **print()** gera um índice de importância de cada variável (ver Nota de Capítulo 1) que no exemplo considerado é

```
$importance
      DIAB       GLIC      IDADE1        IMC       SEXO       TRIG
 1.297693 21.897930 16.931859 28.975228  3.593586 27.303704
```

A classificação predita pelo modelo é obtida por meio dos comandos

```
coronarias3boost.pred <- predict.boosting(coronarias3boost,
                                             newdata=coronarias3)
coronarias3boost.pred$confusion
```

		Observed Class	
		Predicted Class	0 1
		0	327 2
		1	4 701

e corresponde a um erro de classificação igual a $6/1034 = 0,6\%$, consideravelmente menor do que aquele obtido por meio de bagging.

10.3.3 Florestas aleatórias

Tanto bagging quanto boosting quanto florestas aleatórias têm o mesmo objetivo: diminuir a variância e o viés de procedimentos baseados em árvores de decisão. Enquanto os dois primeiros enfoques são baseados em um conjunto de B árvores utilizando o mesmo conjunto de p variáveis preditoras em cada um deles, o enfoque conhecido por **florestas aleatórias** utiliza diferentes conjuntos das variáveis preditoras na construção de cada árvore. Pode-se dizer que esse procedimento acrescenta bagging ao conjunto das p variáveis preditoras e nesse sentido, introduz mais aleatoriedade e diversidade no processo de construção do modelo agregado. Intuitivamente, a utilização de florestas aleatórias para tomada de decisão corresponde à síntese da opinião de indivíduos com diferentes fontes de informação sobre o problema em questão.

Considere um conjunto de n observações $(\mathbf{x}_i, y_i), i = 1, \dots, n$ em que \mathbf{x} é um vetor com os valores de p preditores. O algoritmo para classificação por meio de florestas aleatórias com base nesse conjunto envolve os seguintes passos

- i) Utilize *bagging* para selecionar amostras aleatórias do conjunto de observações, ou seja, construa novos conjuntos com base na seleção de amostras com reposição no conjunto original. Em geral, o número de observações selecionadas em cada amostra é da ordem de $2/3$ das n observações do conjunto original. As observações restantes, conhecidas como amostra **fora da caixa** (*out of bagsamples - OOB samples*) são utilizadas para cálculo da taxa de erros de classificação.
- ii) Na construção de cada nó de cada árvore, em vez de escolher a melhor variável dentre as p disponíveis no conjunto de treinamento, selecione a melhor delas dentre um conjunto de $m < p$ selecionadas ao acaso. Usualmente, escolhe-se $m \approx \sqrt{p}$.
- iii) Não pode as árvores.
- iv) Para cada árvore construída, Obtenha um classificador \hat{c}_b , $b = 1, \dots, B$ e a correspondente classificação $\hat{c}_b(\mathbf{x}) = k$ para as observações do conjunto de dados.
- v) A classificação k^* escolhida para a observação \mathbf{x} é aquela em que foi classificada pelo maior número de árvores (a escolha pelo voto majoritário).

Em geral, florestas aleatórias produzem resultados menos variáveis do que bagging. Na presença de algum preditor forte, nas amostras obtidas por bagging, ele será frequentemente selecionado nas para a divisão do nó raiz, de forma que as árvores geradas podem ser muito semelhantes o que não contribui para a redução da variabilidade das previsões. Isso não acontece com florestas aleatórios, pois esse preditor forte não tende a ser selecionado para a divisão de todos os nós, gerando resultados menos correlacionados cuja “média” (obtida pelo voto majoritário), geralmente reduz a variabilidade.

A acurácia do ajuste por árvores aleatórias é tão boa quanto a do algoritmo AdaBoost e, às vezes, melhor. O resultado obtido por intermédio do algoritmo de árvores aleatórias é, em geral, mais robusto com relação a valores atípicos e ruído além de ser mais rápido do que aqueles obtidos por meio de bagging ou boosting.

Para mais informação e resultados teóricos, veja Breiman (2001).

O pacote `texttrandomForest` pode ser empregado para implementar a técnica de florestas aleatórias.

Exemplo 10.5 Voltemos ao conjunto de dados examinado no Exemplo 10.2. Os conjuntos de treinamento e de validação podem ser obtido por meio dos comandos

```
> set.seed(100)
> train <- sample(nrow(coronarias3), 0.7*nrow(coronarias3),
+                   replace = FALSE)
> TrainSet <- coronarias3[train,]
> ValidSet <- coronarias3[-train,]

e a floresta aleatória (com os parâmetros default), por meio de

> model1 <- randomForest(L03 ~ GLIC + SEXO + IDADE1 + DIAB + TRIG +
+                           IMC + HA + COL, data = TrainSet, importance = TRUE)
```

```
Type of random forest: classification
Number of trees: 500
No. of variables tried at each split: 2

OOB estimate of error rate: 28.63%
Confusion matrix:
      0   1 class.error
0 70 158    0.6929825
1 49 446    0.0989899
```

Para um ajuste mais fino do modelo, pode-se usar

```
> model2 <- randomForest(L03 ~ GLIC + SEXO + IDADE1 + DIAB + TRIG +
+                           IMC + HA + COL, data = TrainSet, ntree = 500, mtry = 6,
+                           importance = TRUE)
```

obtendo-se o seguinte resultado

```
Type of random forest: classification
Number of trees: 500
No. of variables tried at each split: 6

OOB estimate of error rate: 30.57%
Confusion matrix:
      0   1 class.error
0 80 148    0.6491228
1 73 422    0.1474747
```

As tabelas de classificação para os conjuntos de treinamento e de validação são geradas pelos comandos

```
> predTrain <- predict(model2, TrainSet, type = "class")
> table(predTrain, TrainSet$L03)

predTrain  0   1
0 228    0
1    0 495
```

```
> predValid <- predict(model2, ValidSet, type = "class")
> table(predValid, ValidSet$L03)
```

	0	1
0	41	36
1	62	172

A classificação para o conjunto de dados original (com 1034 observações) é obtida por meio de

```
> predValid <- predict(model2, coronarias3, type = "class")
> table(predValid, coronarias3$L03)
```

	0	1
0	269	36
1	62	667

indicando um erro de previsão de $(36+62)/1034 = 9,5\%$, consideravelmente menor do que aqueles obtidos pelas demais técnicas de classificação consideradas.

10.4 Notas de Capítulo

1) Critérios para avaliação de árvores de classificação

Como alternativa para as taxas de erros de classificação, pode-se usar o **índice de Gini** definido como

$$G_m = \sum_{k=1}^K \hat{p}_{mk}(1 - \hat{p}_{mk}),$$

que, essencialmente, corresponde à soma das variâncias das proporções de classificação em cada classe. Quando o valor de \hat{p}_{mk} para um dado nó m e uma dada categoria k estiver próximo de 1 e para as demais categorias estiver próximo de zero, o índice de Gini correspondente estará próximo de zero, indicando que para esse nó, uma grande proporção das observações será classificada em uma das K categorias. Quanto mais concentradas em uma categoria forem as classificações em um dado nó tanto maior será o seu grau de **pureza**.

Nesse contexto, Breiman (1984) define a **importância relativa** de uma variável X_j no desenvolvimento da árvore. Para isso, definamos a variação da impureza do nó m correspondente à variável X_j como

$$\Delta(X_j, G_m) = G_m - p_{mE}G_{mE} - p_{mD}G_{mD}$$

em que G_{mE} e G_{mD} são respectivamente os índices de Gini associados aos nós gerados à esquerda e à direita do nó m pela variável X_j e p_{mE} e p_{mD} são as correspondentes proporções de observações classificadas nesses nós. A importância da variável X_j para o classificador $\widehat{c}(\mathbf{x})$ é

$$Imp[X_j, \widehat{c}(\mathbf{x})] = \sum_{m \in M^*} \Delta(X_j, G_m)$$

em que M^* é o conjunto de nós internos da árvores gerada pelo classificador $\hat{c}(\mathbf{x})$. A importância relativa da variável X_j é definida como

$$ImpRel[X_j, \hat{c}(\mathbf{x})] = \frac{Imp[X_j, \hat{c}(\mathbf{x})]}{\max_{X_j} Imp[X_j, \hat{c}(\mathbf{x})]}$$

Outra medida utilizada com o mesmo propósito e que tem características similares àquelas do coeficiente de Gini é a **entropia cruzada**, definida como

$$ET_m = \sum_{k=1}^K \hat{p}_{mk} \log(\hat{p}_{mk}).$$

Para detalhes, consulte James et al. (2017).

2) Poda de árvores

Normalmente, árvores com muitos nós terminais apresentam bom desempenho no conjunto de treinamento mas podem estar sujeitas a sobreajuste, e não produzir boas classificações no conjunto de teste. Nesse contexto, árvores com um número menor de regiões (ou subdivisões) constituem uma boa alternativa produzindo resultados com menor variância e melhor interpretação. O procedimento chamado **poda** (*pruning*) pode ser usado com esse fim. A poda pode ser realizada na própria construção da árvore (**pré poda**) ou após sua finalização (**pós poda**). No primeiro caso, a poda é obtida por meio da especificação de um critério de parada, como a determinação do número mínimo de observações em cada nó terminal.

A poda propriamente dita consiste na construção de uma árvore com muitos nós terminais e segundo algum critério e na eliminação de alguns deles, obtendo uma árvore menor. Essencialmente, o procedimento consiste em construir uma árvore até que o decréscimo no critério de avaliação (taxa de classificações erradas, por exemplo) gerada em cada divisão exceda algum limiar (em geral alto), obtendo-se uma **sub-árvore**.

Usar esse procedimento até se obter o menor erro de classificação pode não ser factível e o que se faz é considerar uma sequência de árvores indexada por um parâmetro de poda $\alpha \geq 0$ tal que para cada α seja construída uma subárvore A que minimize

$$\sum_{j=1}^{|A|} \sum_{i:\mathbf{x}_i \in R_j} (y_i - \hat{y}_{R_j})^2 + \alpha|A|, \quad (10.2)$$

em que $|A|$ é o número de nós terminais de A , R_j é a região (retângulo) correspondente ao j -ésimo nó terminal e \hat{y}_{R_j} é a categoria prevista associada à região R_j . O valor de α é escolhido por validação cruzada.

3) Bootstrap

Com o progresso de métodos computacionais e com capacidade cada vez maior de lidar com grandes conjuntos de dados, o cálculo de erros padrões, vieses etc. pode ser concretizado sem recorrer a uma teoria, que muitas vezes pode ser muito complicada ou simplesmente não existir. Um desses métodos é o chamado **bootstrap**, introduzido por B. Efron em 1979. A ideia que fundamenta o método bootstrap é reamostrar o conjunto de dados disponível para estimar um parâmetro θ , com a finalidade de criar dados replicados.

A partir dessas replicações, pode-se avaliar a variabilidade de um estimador proposto para θ sem recorrer a cálculos analíticos.

Considere, por exemplo, um conjunto de dados $\mathbf{x} = (x_1, \dots, x_n)$ a ser utilizado para estimar a mediana populacional, Md , por meio da mediana amostral $md(\mathbf{x}) = \text{med}(x_1, \dots, x_n)$. Seja $\mathbf{x}^* = (x_1^*, \dots, x_n^*)$ uma amostra aleatória simples, **com reposição**, de tamanho n dos dados \mathbf{x} , chamada de **amostra bootstrap**. Por exemplo, suponha que $\mathbf{x} = (x_1, x_2, x_3, x_4, x_5)$. Um amostra bootstrap é, por exemplo, $\mathbf{x}^* = (x_4, x_3, x_3, x_1, x_2)$.

Repita o processo de amostragem, gerando B amostras bootstrap independentes, denotadas $\mathbf{x}_1^*, \dots, \mathbf{x}_B^*$. Para cada amostra bootstrap, calcule uma réplica bootstrap do estimador proposto, ou seja, de $md(\mathbf{x}^*)$, obtendo

$$md(\mathbf{x}_1^*), \dots, md(\mathbf{x}_B^*). \quad (10.3)$$

O estimador bootstrap do erro padrão de $md(\mathbf{x})$ é definido como

$$\widehat{e.p.}_B(md) = \left[\frac{\sum_{b=1}^B (md(\mathbf{x}_b^*) - \overline{md})^2}{B-1} \right]^{1/2},$$

com

$$\overline{md} = \frac{\sum_{b=1}^B md(\mathbf{x}_b^*)}{B},$$

ou seja, o estimador bootstrap do erro padrão da mediana amostral é o desvio padrão amostral do conjunto (10.3).

A questão que se apresenta é: qual deve ser o valor de B , ou seja, quantas amostras bootstrap devemos gerar para estimar erros padrões de estimadores? A experiência indica que um valor razoável é $B = 200$.

No caso geral de um estimador $\hat{\theta} = t(\mathbf{x})$, o algoritmo bootstrap para estimar o erro padrão de $\hat{\theta}$ é o seguinte:

- 1) Selecione $B \approx 200$ amostras bootstrap independentes $\mathbf{x}_1^*, \dots, \mathbf{x}_B^*$, cada uma consistindo de n valores selecionados com reposição de \mathbf{x} .
- 2) Para cada amostra bootstrap \mathbf{x}_b^* calcule a réplica bootstrap

$$\hat{\theta}^*(b) = t(\mathbf{x}_b^*), \quad b = 1, \dots, B.$$

- 3) O erro padrão de $\hat{\theta}$ é estimado pelo desvio padrão das B réplicas,

$$\widehat{e.p.}_B = \left[\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}^*(b) - \bar{\theta}^*)^2 \right]^{1/2},$$

com

$$\bar{\theta}^* = \frac{1}{B} \sum_{b=1}^B \hat{\theta}^*(b).$$

Para mais detalhes, consulte Efron and Tibshirani (1993).

10.5 Exercícios

- 1) Para avaliar o desempenho de uma árvore, dividimos o conjunto de observações em dois, um de treinamento e outro de teste (ou validação) e usamos a função `predict()` e depois a função `table`. Avalie o poder preditivo para a árvore do Exemplo 10.1.
- 2) Para o conjunto de dados `iris`, use somente os comprimentos de pétalas e sépalas para construir a árvore. Obtenha as regiões e construa o seu gráfico, usando o comando `partition.tree()` do pacote `tree`.
- 3) Descreva, formalmente, as regiões determinadas na Figura ??.
- 4) Descreva, formalmente, ?? regiões que determinam as árvores das Figuras ??? e ???.
- 5) Efetue a poda do exemplo dado na Seção ???, tomando o tamanho da árvore igual a 6. Compare os resultados com aqueles apresentados no texto.
- 6) Efetue a poda das árvores das Figuras ??? e ???.
- 7) Separe o conjunto `iris` em um conjunto de treinamento (100 observações, por exemplo) e um conjunto teste (50 observações). Com as funções `predict()` e `table()`, avalie as taxas de erro de classificação quando efetuamos uma poda.
- 8) Use as técnicas bagging, boosting e floresta para os conjuntos de dados ??? e ????. Que técnica produz o menor erro de classificação para para cada conjunto?

Previsão

11.1 Introdução

O objetivo das técnicas abordadas neste capítulo é selecionar modelos que, segundo algum critério, sejam os melhores para prever valores de uma variável contínua. Assim como no caso de problemas de classificação, a estratégia do aprendizado estatístico consiste em ajustar vários modelos a um conjunto de treinamento e escolher aquele que gere as melhores previsões com dados de um conjunto de teste. Em geral, esse processo é concretizado por meio de validação cruzada (ver Nota de Capítulo 1 do Capítulo 8). Dentre os modelos considerados para previsão, abordaremos modelos de regularização, algoritmos de suporte vetorial e árvores de decisão.

Os critérios usados para a escolha do melhor modelo são o erro quadrático médio (MSE) ou sua raiz quadrada (*RMSE*) e o coeficiente de determinação (R^2) cujas definições estão na Seção 1.6.

11.2 Regularização

Consideremos um exemplo [proposto em Bishop (2006)] cujo objetivo é ajustar um modelo de regressão polinomial a um conjunto de 10 pontos gerados por meio da expressão $y_i = \sin(2\pi x_i) + e_i$ em que e_i segue um distribuição Normal com média nula e variância σ^2 . Os dados estão representados na Figura 11.1 por pontos em azul. A curva verde corresponde a $y_i = \sin(2\pi x_i)$; em vermelho estão representados os ajustes baseados em regressões polinomiais de graus, 0, 1, 3 e 9. Claramente, a curva baseada no polinômio do terceiro grau consegue reproduzir o padrão da curva geradora dos dados sem, no entanto, predizer os dados com total precisão. A curva baseada no polinômio de grau 9, por outro lado, tem um ajuste perfeito, mas não reproduz o padrão da curva utilizada para gerar os dados. Esse fenômeno é conhecido como **sobreajuste** (*overfitting*).

O termo **regularização** refere-se a um conjunto de técnicas utilizadas para especificar modelos que se ajustem a um conjunto de dados evitando o sobreajuste. Essencialmente, essas técnicas servem para ajustar modelos de regressão com uma função de perda que contém um termo de penalização. Esse termo tem a finalidade de reduzir a influência de coeficientes responsáveis por flutuações excessivas.

Embora haja várias técnicas de regularização, consideraremos apenas três: a regularização L_2 , ou **Ridge**, a regularização L_1 ou **Lasso** (*least absolute shrinkage and selection operator*) e uma mistura dessas duas, chamada de **Elastic Net**.

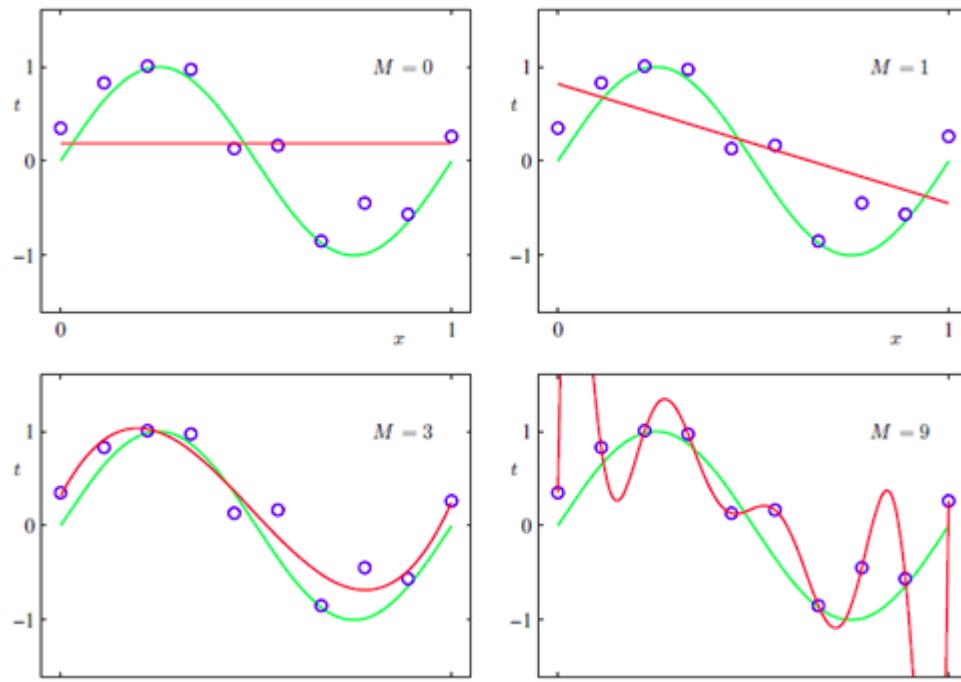


Figura 11.1: Ajuste de modelos polinomiais a um conjunto de dados hipotéticos.

O componente de regularização da técnica *Lasso* usa uma soma de valores absolutos dos parâmetros e um **coeficiente de penalização** que os encolhe para zero. Essa técnica serve para seleção de modelos porque associa pesos nulos a parâmetros que têm contribuição limitada para efeito de previsão. Isso implica uma **solução esparsa**.¹ Na regularização *Ridge*, por outro lado, o termo de regularização usa uma soma de quadrados dos parâmetros e um termo de penalização que força alguns pesos a serem pequenos, mas não os anula e consequentemente, não conduz a soluções esparsas. Essa técnica de regularização não é robusta com relação a valores atípicos, pois pode conduzir a valores muito grandes do termo de penalização.

Neste capítulo vamos nos basear em Hastie et al. (2017), James et al. (2017) e Medeiros (2019).

11.2.1 Regularização L_2 (*Ridge*)

A técnica de regressão *Ridge* foi introduzida por Hoerl e Kennard (1970) para tratar do problema da multicolinearidade mas também pode ser utilizada para corrigir outros problemas ligados ao sobreajuste. Consideremos o modelo de regressão

$$y_t = \beta_0 + \beta_1 x_{1t} + \dots + \beta_p x_{pt} + e_t, \quad t = 1, 2, \dots, n, \quad (11.1)$$

com as p variáveis preditoras reunidas no vetor $\mathbf{x}_t = (x_{1t}, \dots, x_{pt})^\top$, y_t representando a variável resposta, e_t indicando erros de média zero e $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_p)^\top$

¹Dizemos que um modelo é esparsa se a maioria dos elementos do correspondente vetor de parâmetros é nula ou desprezível.

denotando os parâmetros a serem estimados. Os **estimadores de mínimos quadrados penalizados** correspondem à solução de

$$\hat{\beta}_{Ridge}(\lambda) = \arg \min_{\beta} \left[\sum_{t=1}^n (y_t - \beta^\top \mathbf{x}_t)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right], \quad (11.2)$$

em que λ é o coeficiente de regularização, que controla a importância relativa entre a minimização da soma de quadrados dos erros [o primeiro termo do segundo membro de (11.2)] e o termo de penalização $\lambda \sum_{j=1}^p \beta_j^2$. Se $\lambda = \infty$, não há variáveis a serem incluídas no modelo e se $\lambda = 0$, obtemos os estimadores de mínimos quadrados usuais. A escolha de λ deve ser um dos componentes da estratégia para a determinação de estimadores regularizados. Dizemos que $\hat{\beta}_{Ridge}(\lambda)$ é o **estimador Ridge**. Pode-se mostrar que

$$\hat{\beta}_{Ridge}(\lambda) = (\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top \mathbf{y}, \quad (11.3)$$

em que $\mathbf{X} = (\mathbf{x}_1^\top, \dots, \mathbf{x}_n^\top)^\top$ é a matriz de especificação do modelo e $\mathbf{y} = (y_1, \dots, y_n)^\top$ é o vetor de respostas.

Algumas propriedades dessa classe de estimadores são:

- 1) Em geral, o estimador *Ridge* não é consistente. Sua consistência assintótica vale quando $\lambda = v\lambda_n \rightarrow \infty$, $\lambda_n/n \rightarrow 0$ e $p < n$.
- 2) O estimador *Ridge* é enviesado para os parâmetros não nulos.
- 3) A técnica de regularização *Ridge* não serve para a seleção de modelos.
- 4) A escolha do coeficiente de regularização λ pode ser feita via validação cruzada ou por meio de algum critério de informação. Detalhes são apresentados na Nota de Capítulo 10.

Obter o mínimo em (11.2) é equivalente a minimizar a soma de quadrados não regularizada $[\sum_{t=1}^n (y_t - \beta^\top \mathbf{x}_t)^2]$ sujeita à restrição

$$\sum_{j=1}^p \beta_j^2 \leq m, \quad (11.4)$$

para algum valor apropriado m , ou seja, é um problema de otimização com **multiplicadores de Lagrange**. Convém lembrar que o intercepto não é considerado no termo de penalização, dado que o interesse está na associação entre as variáveis explicativas e a variável resposta.

Na Figura (11.2) apresentamos um esquema com o valor ótimo do vetor β , a região circular correspondente à restrição (11.4) e os círculos representando as curvas de nível da função erro não regularizada.

11.2.2 Regularização L_1 (*Lasso*)

Consideremos, agora, o **estimador Lasso**, obtido de

$$\hat{\beta}_{Lasso}(\lambda) = \arg \min_{\beta} \left[\frac{1}{n} \sum_{t=1}^n (y_t - \beta^\top \mathbf{x}_t)^2 + \lambda \sum_{j=1}^p |\beta_j| \right], \quad (11.5)$$

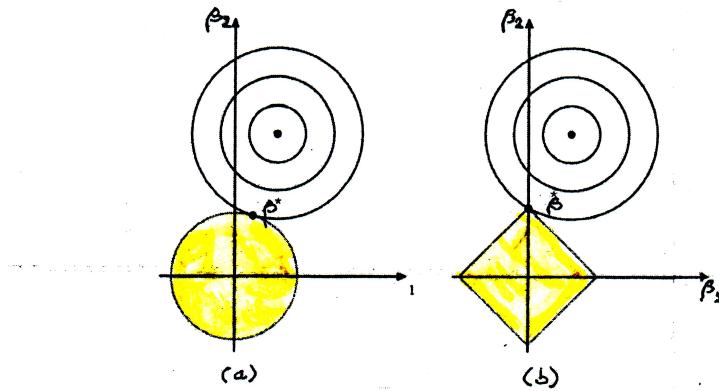


Figura 11.2: Esparsidade do modelo: (a) ridge; (b) lasso.

Neste caso, a restrição (11.4) é substituída por

$$\sum_{j=1}^p |\beta_j| \leq m. \quad (11.6)$$

No painel (b) da Figura 11.2, podemos observar que a regularização *Lasso* pode gerar uma solução esparsa, ou seja com algum elemento do vetor $\hat{\beta}_{Lasso}$ nulo. Algumas propriedades estatísticas do estimador *Lasso* são:

- 1) O estimador *Lasso* encolhe para zero os parâmetros que correspondem a preditores redundantes.
- 2) O estimador é enviesado para parâmetros não nulos.
- 3) Sob certas condições, o estimador *Lasso* seleciona as variáveis relevantes do modelo atribuindo pesos nulos aos respectivos coeficientes.
- 4) Quando $p = n$, ou seja, quando o número de variáveis preditoras é igual ao número de observações, a técnica *Lasso* corresponde à aplicação de um **limiar brando** (*soft threshold*) a $Z_j = \mathbf{x}_j^\top \mathbf{y}/n$, ou seja,

$$\hat{\beta}_j(\lambda) = \text{sinal}(Z_j) (|Z_j| - \lambda/2)_+, \quad (11.7)$$

em que $(x)_+ = \max\{x, 0\}$.

Para outras propriedades, veja Medeiros (2019) e Bühlmann and van de Geer (2011).

11.2.3 Outras propostas

O estimador *Elastic Net* (EN) é definido por

$$\hat{\beta}_{EN}(\lambda_1, \lambda_2) = \arg \min_{\boldsymbol{\beta}} \sum_{t=1}^n \frac{1}{n} (y_t - \boldsymbol{\beta}^\top \mathbf{x}_t)^2 + \lambda_1 \sum_{i=1}^p \beta_i^2 + \lambda_2 \sum_{i=1}^p |\beta_i| \quad (11.8)$$

em que λ_1 e λ_2 são coeficientes de penalização.

Na Figura 11.3 apresentamos esquematicamente uma região delimitada pela restrição $J(\beta) \leq m$, em que $J(\beta) = \alpha \sum_{j=1}^p \beta_j^2 + (1 - \alpha) \sum_{j=1}^p |\beta_j|$, para algum m , com $\alpha = \lambda_2 / (\lambda_1 + \lambda_2)$, além daquelas delimitadas pelas restrições *Ridge* e *Lasso*.

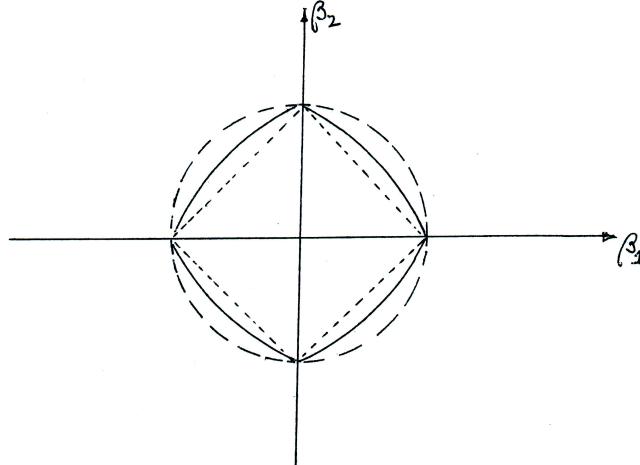


Figura 11.3: Geometria das restrições *Elastic Net* (curva contínua), *Ridge* (curva tracejada) e *Lasso* (curva pontilhada)

Pode-se mostrar que sob determinadas condições, o estimador *Elastic Net* é consistente.

O estimador ***Lasso adaptativo*** (adaLASSO) é definido por

$$\widehat{\beta}_{AL}(\lambda) = \arg \min_{\beta} \frac{1}{n} \sum_{t=1}^n (y_t - \beta^\top \mathbf{x}_t)^2 + \lambda \sum_{i=1}^p w_i |\tilde{\beta}_i|, \quad (11.9)$$

em que w_1, \dots, w_p são pesos não negativos pré definidos e $\tilde{\beta}_i$, $i = 1, \dots, p$ são estimadores iniciais (por exemplo, estimadores *Lasso*). Usualmente, toma-se $w_j = |\tilde{\beta}_j|^{-\tau}$, para $0 < \tau \leq 1$.

O estimador ***Lasso adaptativo*** é consistente sob condições não muito fortes.

A função **adalasso** do pacote **parcor** do R pode ser usada para calcular esse estimador. O pacote **glmnet** do R pode ser usado para obter estimadores *Lasso* e *Elastic Net* sob modelos de regressão linear, regressão logística e multinomial, regressão Poisson além de modelos de Cox. Para detalhes, veja Friedman et al. (2010).

Exemplo 11.1: Os dados do arquivo **antracose** foram extraídos de um estudo cuja finalidade era avaliar o efeito da idade (**idade**), tempo vivendo en São Paulo (**tmunic**), horas diárias em trânsito (**htransp**), carga tabágica (**cargatabag**), classificação sócio-econômica (**ses**), densidade de tráfego na região onde habitou (**densid**) e distância mínima entre a residência a vias com alta intensidade de tráfego (**distmin**) num índice de antracose (**antracose**) que é uma medida de fuligem (*black carbon*) depositada no pulmão. Como esse índice varia entre 0 e 1, consideramos

$$\logrc = \log[\text{índice de antracose}/(1 - \text{índice de antracose})]$$

como variável resposta. O objetivo aqui é apenas didático. Leitores interessados devem consultar Takano et al. (2019) para uma análise mais adequada.

Os estimadores de mínimos quadrados para um modelo linear com variáveis ajustadas podem ser obtidos por meio dos comandos

```
> pulmao_lm <- lm(logrc ~ idade + tmunic + htransp + cargatabag +
+ ses + densid + distmin, data=pulmao)
> summary(pulmao_lm)

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -3.977e+00 2.459e-01 -16.169 < 2e-16 ***
idade        2.554e-02 2.979e-03   8.574 < 2e-16 ***
tmunic       2.436e-04 2.191e-03   0.111 0.911485
htransp       7.505e-02 1.634e-02   4.592 5.35e-06 ***
cargatabag  6.464e-03 1.055e-03   6.128 1.61e-09 ***
ses          -4.120e-01 1.238e-01  -3.329 0.000926 ***
densid        7.570e+00 6.349e+00   1.192 0.233582
distmin      3.014e-05 2.396e-04   0.126 0.899950

Residual standard error: 1.014 on 598 degrees of freedom
Multiple R-squared:  0.1965, Adjusted R-squared:  0.1871
F-statistic: 20.89 on 7 and 598 DF,  p-value: < 2.2e-16
```

O ajuste dos modelo de regressão *Ridge*, *Lasso* ou *Elastic net* podem ser obtido com o pacote *glmnet*. Ajustamos o modelo de regressão *Ridge* por meio de validação cruzada e obtemos o gráfico da Figura 11.4 em que o erro quadrático médio (MSE) é expresso em função do logaritmo do coeficiente de regularização λ .

```
> regridgecv = cv.glmnet(X, y, alpha = 0)
> plot(regridgecv)
```

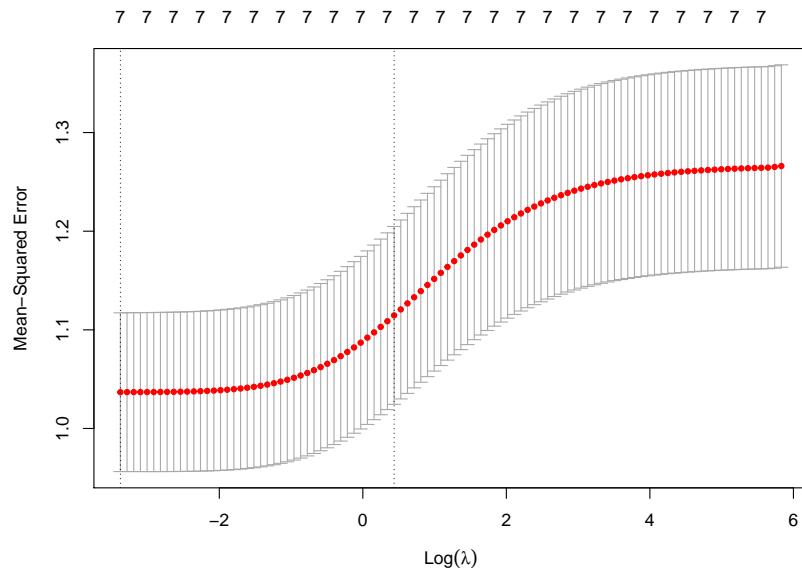


Figura 11.4: Gráfico para avaliação do efeito do coeficiente de regularização (*Ridge*).

Os coeficientes do ajuste correspondentes ao valor mínimo do coeficiente λ juntamente com esse valor são obtidos com os comandos

```
> coef(regridgecv, s = "lambda.min")
8 x 1 sparse Matrix of class "dgCMatrix"
 1
(Intercept) -3.905299e+00
idade         2.456715e-02
tmunic        4.905597e-04
htransp        7.251095e-02
cargatabag   6.265919e-03
ses           -3.953787e-01
densid        7.368120e+00
distmin       3.401372e-05
> regridgecv$lambda.min
[1] 0.03410028
```

Com exceção das estimativas dos coeficientes das variáveis `tmunic` e `distmin` as demais foram encolhidas em direção a zero relativamente àquelas obtidas por mínimos quadrados.

Os valores preditos e a correspondente raiz quadrada do MSE, usualmente denotada *RMSE* é obtida com

```
> predict(regridgecv, X, s = "lambda.min")
> sqrt(regridgecv$cvm[regridgecv$lambda == regridgecv$lambda.min])
[1] 1.050218
```

O ajuste do modelo de regressão *Lasso* juntamente com o gráfico para a escolha do coeficiente λ , disposto na Figura 11.5 são obtidos com

```
> reglassocv = cv.glmnet(X, y, alpha = 1)
> plot(reglassocv)
```

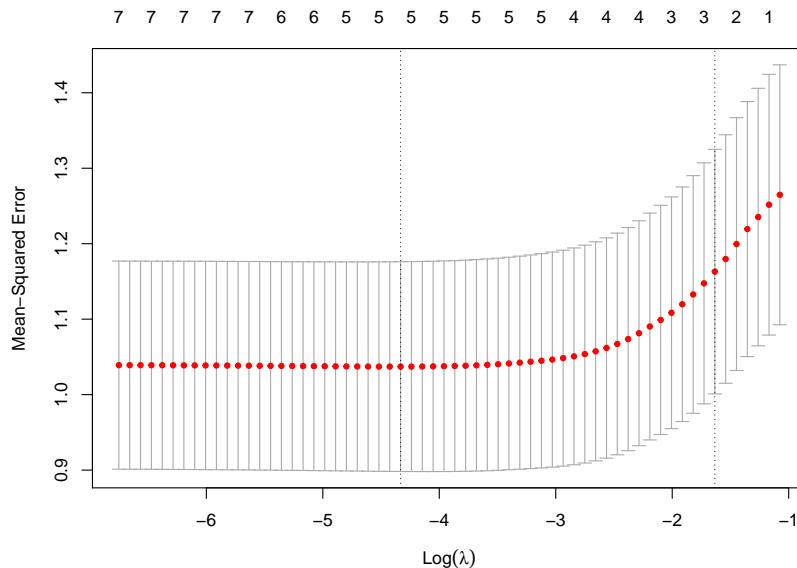


Figura 11.5: Gráfico para avaliação do efeito do coeficiente de regularização (*Lasso*).

Os coeficientes correspondentes à regularização *Lasso*, o valor mínimo do coeficiente λ e o *RMSE* são obtidos por meio de

```
> coef(reglassocv, s = "lambda.min")
8 x 1 sparse Matrix of class "dgCMatrix"
   1
(Intercept) -3.820975473
idade        0.024549358
tmunic       .
htransp      0.069750435
cargatabag  0.006177662
ses          -0.365713282
densid       5.166969594
distmin      .

> reglassocv$lambda.min
[1] 0.01314064
> sqrt(reglassocv$cvm[reglassocv$lambda == reglassocv$lambda.min])
[1] 1.018408
```

Neste caso, todos os coeficientes foram encolhidos em direção ao zero, com aqueles correspondentes às variáveis `tmunic` e `distmin` foram anulados.

Para o modelo *Elastic Net* com $\alpha = 0,5$ os resultados são

```
> regelncv = cv.glmnet(X, y, alpha = 0.5)
> regelncv$lambda.min
[1] 0.02884367
> coef(regelncv, s = "lambda.min")
8 x 1 sparse Matrix of class "dgCMatrix"
   1
(Intercept) -3.776354935
idade        0.024089256
tmunic       .
htransp      0.068289153
cargatabag  0.006070319
ses          -0.354080190
densid       4.889074555
distmin      .
> sqrt(regelncv$cvm[regelncv$lambda == regelncv$lambda.min])
[1] 1.0183
```

11.3 Regressão baseada em vetores suporte

Embora tenhamos usado problemas de classificação para ilustrar os algoritmos de suporte vetorial, eles também podem ser usados para previsão. Essencialmente, o problema tratado aqui tem a mesma natureza daqueles tratados nos Capítulos 8, 9 e 10. A diferença está na variável resposta, y , que é quantitativa e pode tomar qualquer valor real. Apresentamos as ideias da técnica por meio de exemplos, deixando os detalhes para as notas de capítulo.

Dado um conjunto de treinamento, $\mathcal{T} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$, o objetivo é obter uma função $f(\mathbf{x}_i)$, mais achatada (*flat*) possível tal que $|y_i - f(\mathbf{x}_i)| < \epsilon$, $i = 1, \dots, n$ em que $\epsilon > 0$ é o maior erro que estamos dispostos a cometer. Por

exemplo, ϵ pode ser a máxima perda que admitimos ao negociar com ações dadas certas características obtidas do balanço de um conjunto de empresas.

No caso de funções lineares, o objetivo é determinar α e β tais que $|f(\mathbf{x}_i)| = |\alpha + \beta^\top \mathbf{x}_i| \leq \epsilon$. A condição de que $f(\mathbf{x})$ seja a mais achatada possível corresponde a que β seja pequeno, ou seja o problema a resolver pode ser expresso como

$$\text{minimizar } \frac{1}{2} \|\beta\|^2 \text{ sujeito a } \begin{cases} y_i - \beta^\top \mathbf{x}_i - \alpha \leq \epsilon \\ \alpha + \beta^\top \mathbf{x}_i - y_i \leq \epsilon \end{cases} \quad (11.10)$$

Nem sempre as condições (11.10) podem ser satisfeitas e nesse caso, assim como nos modelos de classificação, podemos introduzir variáveis de folga ξ_i e ξ_i^* , $i = 1, \dots, n$, que permitem flexibilizar a restrição de que o máximo erro permitido seja ϵ . O problema a resolver nesse contexto é

$$\text{minimizar } \frac{1}{2} \|\beta\|^2 + \sum_{i=1}^n C(\xi_i + \xi_i^*) \text{ sujeito a } \begin{cases} y_i - \beta^\top \mathbf{x}_i - \alpha \leq \epsilon + \xi_i \\ \alpha + \beta^\top \mathbf{x}_i - y_i \leq \epsilon + \xi_i^* \\ \xi_i, \xi_i^* > 0 \end{cases} \quad (11.11)$$

A constante $C > 0$ determina um compromisso entre o achatamento da função f e o quanto estamos dispostos a tolerar erros com magnitude maior do que ϵ .

As soluções de (11.10) ou (11.11) podem ser encontradas mais facilmente usando a formulação dual (ver Nota de Capítulo 3). No caso linear, a previsão para um dado \mathbf{x} é obtida de

$$f(\mathbf{x}) = \sum_{i=1}^n \hat{\lambda}_i K(\mathbf{x}, \mathbf{x}_i) + \hat{\alpha}$$

em que $\hat{\lambda}_i$ são multiplicadores de Lagrange, $K(\mathbf{x}, \mathbf{x}_i)$ é um kernel, $\hat{\alpha} = y_i - \epsilon - \hat{\beta}^\top \mathbf{x}_i$, $\hat{\beta} = \sum_{i=1}^n \hat{\lambda}_i \mathbf{x}_i$. Os vetores suporte são aqueles para os quais os multiplicadores de Lagrange $\hat{\lambda}_i$ são positivos. Se optarmos por um kernel linear, $K(\mathbf{x}, \mathbf{x}_i) = \langle \mathbf{x}, \mathbf{x}_i \rangle$.

Exemplo 11.2. Consideremos os dados da Tabela 6.1 com o objetivo de estudar a relação entre a distância com que motoristas conseguem distinguir um certo objeto e sua idade. O diagrama de dispersão e a reta de mínimos quadrados ajustada ($y = 174,2 - 1,0x$) correspondentes estão apresentados na Figura 11.6.

O ajuste de uma regressão com suporte vetorial baseada num kernel linear com os parâmetros *default* pode ser obtido por meio dos comandos

```
> model1<- svm(x, y, kernel="linear")
> summary(model1)
Parameters:
  SVM-Type:  eps-regression
  SVM-Kernel:  linear
  cost: 1
  gamma: 1
  epsilon: 0.1
Number of Support Vectors:  23

> betahat <- model1$rho
[1] -0.08572489
>
> coef1 <- sum(model1$coefs*x[model1$index])
> alfahat <- coef1/model1$rho
[1] 172.8264
```

de forma que a função previsora corresponde à $f(x) = 172,9 - 0,09x$. A previsão para as distâncias segundo esse modelo pode ser obtida por meio do comando `yhat1 <- predict(model1, x)`. O *RMSE* correspondente pode ser obtido por meio do comando `rmse(yhat1, y)` é 16.51464 (maior do que o *RMSE* associado ao ajuste por meio de mínimos quadrados, que é 16,02487).

Um modelo mais flexível pode ser ajustado com um kernel radial do tipo $K(\mathbf{x}_1, \mathbf{x}_2) = \exp(-\gamma \|\mathbf{x}_1 - \mathbf{x}_2\|^2)$ com $\gamma > 0$ constante. Nesse caso, convém realizar uma análise de sensibilidade com validação cruzada para a seleção da melhor combinação dos valores do máximo erro ϵ que estamos dispostos a cometer e do custo de penalização, C . Isso pode ser concretizado por meio dos comandos

```
> sensib <- tune(svm, y ~ x, ranges = list(epsilon = seq(0,1,0.1),
  cost = 2^(2:9)))
Parameter tuning of 'svm':
- sampling method: 10-fold cross validation
- best parameters:
  epsilon cost
  0.8     8
- best performance: 275.8086
```

Com esses resultados, realizamos um ajuste por meio de um kernel radial com parâmetros $C = 8$ e $\epsilon = 0.8$, obtendo

```
> model2 <- svm(x, y, kernel="radial", cost=8, epsilon=0.8)
> summary(model2)
Parameters:
  SVM-Type:  eps-regression
  SVM-Kernel:  radial
    cost:  8
    gamma: 1
  epsilon: 0.8
Number of Support Vectors:  6
```

O *RMSE* para esse modelo é 15,84272, menor do que aqueles obtidos por meio dos demais ajustes. Um gráfico com os ajustes por mínimos quadrados (em preto) e por regressões com suporte vetorial baseadas em kernels linear (em azul) e radial (em vermelho) está apresentado na Figura 11.6.

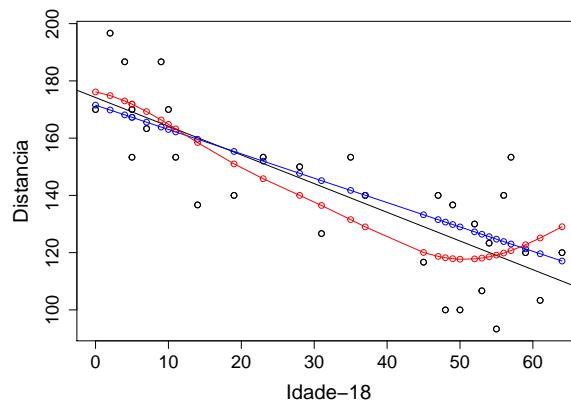


Figura 11.6: Regressão SVM para os dados da Tabela 6.1

A utilização de algoritmos de suporte vetorial no contexto de regressão também pode ser utilizada com os mesmos propósitos de suavização similares àqueles concretizado pelo método LOWESS (ver Nota de Capítulo 2 do Capítulo 5). Nesse contexto, a suavidade do ajuste deve ser modulada pela escolha do parâmetro ϵ . Valores de ϵ pequenos (próximos de zero) geram curvas mais suaves e requerem muitos vetores suporte, podendo produzir sobreajuste. Valores de ϵ grandes (próximos de 1.0, por exemplo) geram curvas menos suaves e requerem menos vetores suporte. O parâmetro C tem influência no equilíbrio entre a magnitude da margem e das variáveis de folga. Em geral, esse o valor desse parâmetro deve ser selecionado por meio de uma análise de sensibilidade concretizada por validação cruzada.

Exemplo 11.3. Para o ajuste de um modelo de regressão por vetores suporte aos mesmos dados utilizados na Figura 5.15, inicialmente avaliamos a escolha ótima do parâmetro C e γ .

```
> escolhaparam <- tune.svm(x, y, gamma = 2^(-1:1), cost = 2^(2:4))
> summary(escolhaparam)
Parameter tuning of 'svm':
- sampling method: 10-fold cross validation
- best parameters:
  gamma cost
    0.5     4
- best performance: 1447.839
```

Com base nesse resultado, ajustamos o modelo de regressão por vetores suporte com $\epsilon = 0.5$, obtendo

```
> rotarodVS1 <- svm(y~x, kernel="radial", degree=5, cost=4, gamma=0.5,
                      epsilon=0.5)
> summary(rotarodVS1)
Parameters:
  SVM-Type: eps-regression
  SVM-Kernel: radial
  cost: 4
  gamma: 0.5
  epsilon: 0.5
Number of Support Vectors: 62
```

Alternativamente, ajustamos o modelo de regressão por vetores suporte com $\epsilon = 0.5$, obtendo

```
> rotarodVS2 <- svm(y~x, kernel="radial", degree=5, cost=4, gamma=0.5,
                      epsilon=1.0)
> summary(rotarodVS2)
Parameters:
  SVM-Type: eps-regression
  SVM-Kernel: radial
  cost: 4
  gamma: 0.5
  epsilon: 1
Number of Support Vectors: 22
```

Os valores preditos pelo modelo nos dois casos podem ser obtidos por meio da função `predict()` servem para a construção da Figura 11.7,

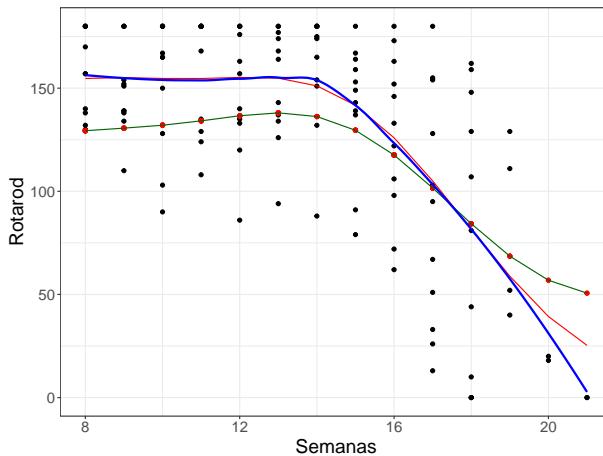


Figura 11.7: Regressão SV para o Exemplo 8.5 com $\epsilon = 0.5$ em vermelho, $\epsilon = 1.0$ em verde e LOWESS em azul.

As três curvas sugerem um modelo de regressão segmentada.

11.4 Árvores para regressão

Consideremos novamente uma situação com variáveis preditoras X_1, \dots, X_n e uma variável resposta quantitativa Y . Quando há uma dependência linear entre variáveis resposta e preditoras, o uso de regressão linear é conveniente e obtemos modelos com interpretabilidade e poder preditivo satisfatórios. Quando essa relação não é linear, o uso de árvores pode ser mais apropriado. Além disso, algumas das variáveis preditoras podem ser qualitativas e nesse caso não é necessário transformá-las em **variáveis fictícias** (*dummy variables*) como no caso de modelos de regressão. A construção de árvores de regressão pode ser concretizada por meio dos pacotes **tree** e **rpart**.

Ilustraremos a construção de uma árvore para regressão por meio de um exemplo.

Exemplo 11.4. Consideremos o problema descrito no Exemplo 11.1 baseado nos dados do arquivo **antracose**.

Inicialmente, construímos uma árvore de regressão para os dados por meio de validação cruzada com a mesma variável resposta e as mesmas variáveis explicativas consideradas no modelo linear ajustado no Exemplo 11.1. Os comandos do pacote **rpart** para gerar a árvore apresentada na Figura 11.8 são

```
> pulmaotree2 <- rpart(formula = logrc ~ idade + tmunic + htransp +
+                         cargatabag + ses + densid + distmin, data=pulmao,
+                         method="anova", xval = 30, cp=0.010)
> rpart.plot(pulmaotree2, clip.right.labs = TRUE, under = FALSE,
+             extra = 101, type=4)
```

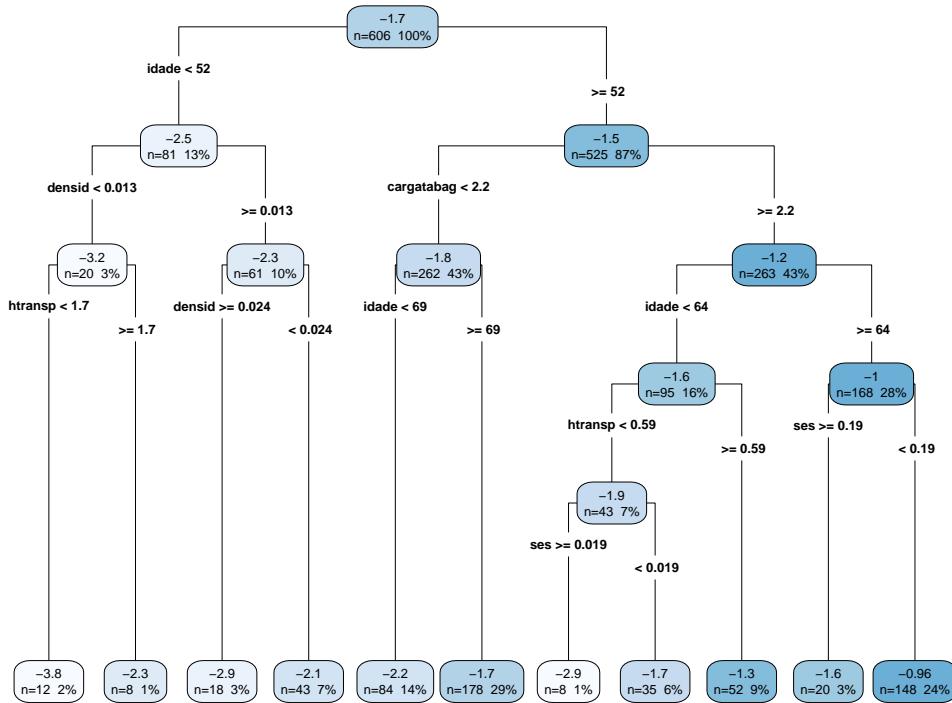


Figura 11.8: Árvore de decisão para os dados do Exemplo 11.4.

Para evitar um possível sobreajuste da árvore proposta, convém avaliar o efeito de seu tamanho segundo algum critério. No pacote `rpart` esse critério é baseado no parâmetro de complexidade (CP) que está relacionado com o número de nós terminais e na relação $1 - R^2$ em que R^2 tem a mesma interpretação do coeficiente de determinação utilizado em modelos lineares.

Com essa finalidade, podemos utilizar o comando `rsq.rpart(pulmaotree2)` que gera a tabela com os valores de CP e os gráficos apresentados na Figura 11.9.

```
Variables actually used in tree construction:
[1] cargatabag densid      htransp     idade       ses
Root node error: 765.87/606 = 1.2638
n= 606
      CP nsplit rel error xerror      xstd
1  0.087230      0  1.00000 1.00279 0.077419
2  0.062020      1  0.91277 0.96678 0.076624
3  0.025220      2  0.85075 0.91078 0.072406
4  0.024106      3  0.82553 0.91508 0.073489
5  0.015890      4  0.80142 0.85814 0.069326
6  0.014569      5  0.78553 0.87882 0.070312
7  0.011698      6  0.77097 0.89676 0.070309
8  0.011667      7  0.75927 0.90730 0.069025
9  0.011347      8  0.74760 0.91268 0.069066
10 0.010289      9  0.73625 0.91536 0.069189
11 0.010000     10  0.72596 0.91250 0.069202
```

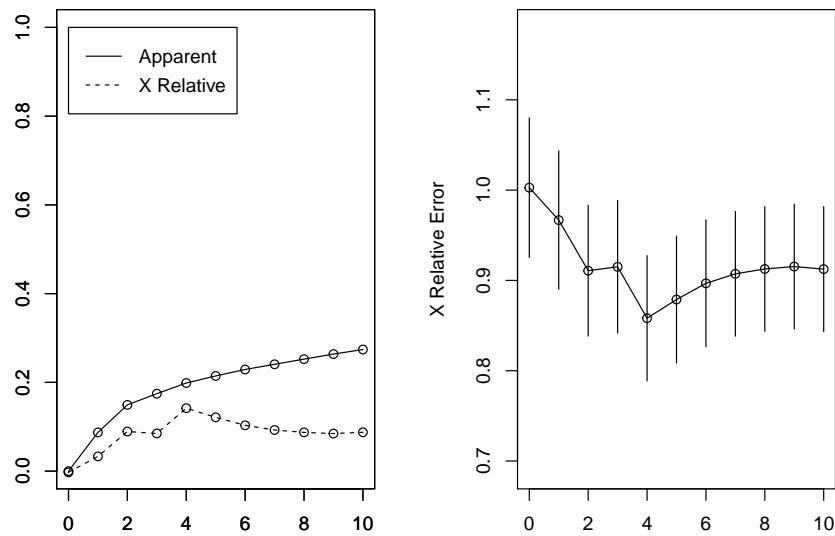


Figura 11.9: Efeito do número de nós para a árvore ajustada aos dados do Exemplo 11.4

Podemos então podar a árvore, fixando o número de nós terminais em 5 (correspondendo a 4 divisões) e obter o gráfico correspondente (disposto na Figura 11.10), além da regras de partição do espaço das variáveis explicativas. Os comandos necessários para essa finalidade são

```
> rpart.plot(pulmaotree2poda, clip.right.labs = TRUE, under = FALSE,
             extra = 101, type=4)
> pulmaotree2poda$cptable
      CP nsplit rel error      xerror      xstd
1 0.08722980      0 1.0000000 1.0027880 0.07741860
2 0.06201953      1 0.91277702 0.9667786 0.07662398
3 0.02521977      2 0.8507507 0.9107847 0.07240566
4 0.02410635      3 0.8255309 0.9150809 0.07348898
5 0.01588985      4 0.8014246 0.8581417 0.06932582
> rpart.rules(pulmaotree2poda, cover = TRUE)
logrc
-2.5 when idade < 52
-2.2 when idade is 52 to 69 & cargatabag < 2.2
-1.7 when idade >= 69 & cargatabag < 2.2
-1.6 when idade is 52 to 64 & cargatabag >= 2.2
-1.0 when idade >= 64 & cargatabag >= 2.2
      cover
          13%
          14%
          29%
          16%
          28%
```

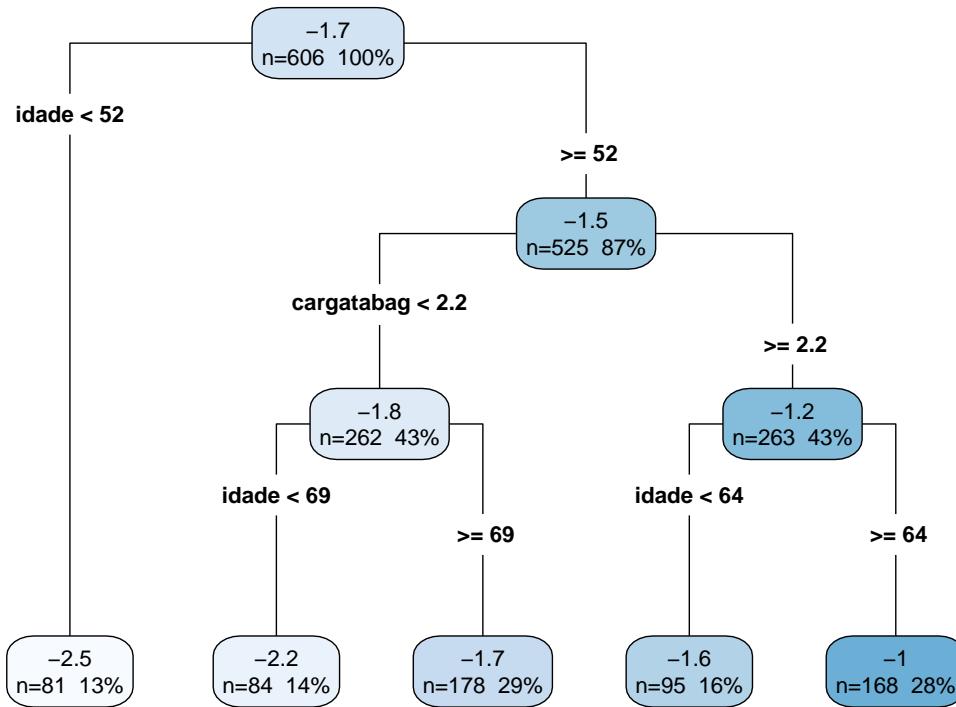


Figura 11.10: Árvore podada ajustada aos dados do Exemplo 11.4

Valores preditos para o conjunto de dados com o respectivo *RMSE* são obtidos por meio dos comandos

```

> rmse = function(actual, predicted) {
+   sqrt(mean((actual - predicted) ^ 2))
+ }
> rmse(predpulmatree2poda, pulmao$logrc)
[1] 1.006402
  
```

Convém notar que embora a utilização de árvores de decisão gere um modelo bem mais simples que aquele obtido por meio de um modelo de regressão, os objetivos da análise são bem diferentes. Nesse contexto, o modelo baseado em árvores deve ser utilizado apenas quando o objetivo é fazer previsões, pois pode deixar de incluir variáveis importantes para conclusões inferenciais. No Exemplo 11.3, uma das variáveis mais importantes para entender o processo de deposição de fuligem no pulmão é o numero de horas gastas em trânsito. Essa variável foi incluída significativamente no ajuste do modelo de regressão mas não o foi no modelo baseado em árvores.

11.5 Notas de Capítulo

- 1) Viés da regularização *Ridge*.

Fazendo $\mathbf{R} = \mathbf{X}^\top \mathbf{X}$, a expressão do estimador *Ridge* (11.2), obtemos

$$\hat{\beta}_{Ridge}(\lambda) = (\mathbf{I} + \lambda \mathbf{R}^{-1})^{-1} \hat{\beta}_{MQ}, \quad (11.12)$$

em que $\hat{\beta}_{MQ}$ denota o estimador de mínimos quadrados ordinários. A esperança condicional da expressão anterior, dada \mathbf{X} , é

$$E[\hat{\beta}_{Ridge}(\lambda)] = (\mathbf{I} + \lambda \mathbf{R}^{-1})^{-1} \boldsymbol{\beta} \neq \boldsymbol{\beta}. \quad (11.13)$$

2) Escolha do parâmetro λ

A escolha do parâmetro de regularização λ pode ser baseada em **validação cruzada**, descrita na Seção 8.4, ou em algum critério de informação.

Pode-se provar que

$$\hat{\beta}_{Ridge}(\lambda) = \mathbf{V} \text{diag} \left(\frac{d_1}{d_1^2 + \lambda}, \frac{d_2}{d_2^2 + \lambda}, \dots, \frac{d_p}{d_p^2 + \lambda} \right) \mathbf{U}^\top \mathbf{y},$$

em que $\mathbf{X} = \mathbf{UDV}^\top$ é a decomposição em valores singulares de \mathbf{X} com \mathbf{U} denotando uma matriz ortogonal de dimensão $n \times p$, \mathbf{V} uma matriz ortogonal de dimensão $p \times p$ e \mathbf{D} uma matriz diagonal com dimensão $p \times p$, contendo os correspondentes valores singulares $d_1 \geq d_2 \geq \dots \geq d_p \geq 0$ (raízes quadradas dos valores próprios de $\mathbf{X}^\top \mathbf{X}$).

Seja $\Lambda = \{\lambda_1, \dots, \lambda_M\}$ uma grade de valores para λ . Podemos usar um critério de informação do tipo

$$\hat{\lambda} = \arg \min_{\lambda \in \Lambda} [-\log \text{verossimilhança} + \text{penalização}],$$

como

$$\begin{aligned} AIC &= \log[\hat{\sigma}^2(\lambda)] + \text{gl}(\lambda) \frac{2}{n}, \\ BIC &= \log[\hat{\sigma}^2(\lambda)] + \text{gl}(\lambda) \frac{\log n}{n}, \\ HQ &= \log[\hat{\sigma}^2(\lambda)] + \text{gl}(\lambda) \frac{\log \log n}{n}, \end{aligned}$$

em que $\text{gl}(\lambda)$ é o número de graus de liberdade associado a λ , nomeadamente

$$\text{gl}(\lambda) = \text{tr} [\mathbf{X}(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1} \mathbf{X}^\top] = \sum_{j=1}^p \frac{d_j^2}{d_j^2 + \lambda},$$

e

$$\hat{\sigma}^2(\lambda) = \frac{1}{n - \text{gl}(\lambda)} \sum_{t=1}^n [y_t - \hat{\beta}_{Ridge}(\lambda)^\top \mathbf{x}_t]^2.$$

3) ASV para regressão

No problema clássico de regressão, para obter os estimadores de mínimos quadrados, minimizamos a soma de quadrados dos resíduos (6.5). Em problemas de regularização e seleção de variáveis, acrescenta-se a essa soma de quadrados de resíduos um termo de **penalização** que depende de uma norma do vetor de parâmetros, $\boldsymbol{\beta}$ digamos. Se usarmos a norma L_2 , $\|\boldsymbol{\beta}\|^2$, obtemos o que se chama de regressão **Ridge**. Com a norma L_1 , $\|\boldsymbol{\beta}\|$, obtemos o que se chama de regressão **Lasso** conforme indicado na Seção 11.2.

No lugar da soma de quadrados de resíduos, Vapnik (1995) sugere uma função dos erros chamada **ε -insensitive**, que gera um erro nulo se a diferença entre

a previsão $f(\mathbf{x})$ e o valor real y em valor absoluto for menor do que $\varepsilon > 0$. Essa função é definida por

$$E_\varepsilon[f(\mathbf{x}), y] = \begin{cases} 0, & \text{para } |f(\mathbf{x}) - y| < \varepsilon \\ |f(\mathbf{x}) - y| - \varepsilon, & \text{em caso contrário} \end{cases} \quad (11.14)$$

Um gráfico desse função está indicado no painel (a) da Figura 11.11.

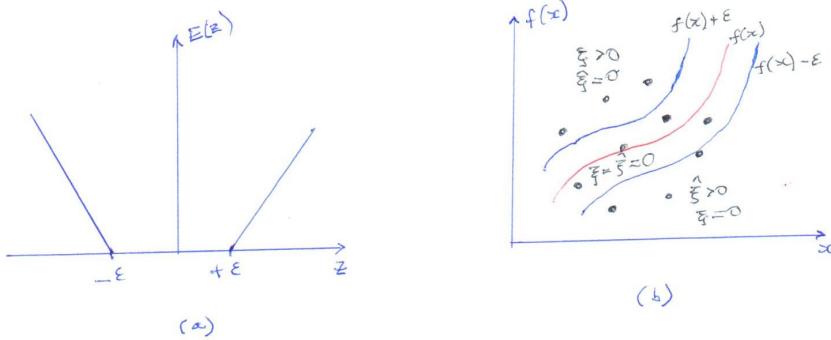


Figura 11.11: (a) Função ε -insensitive; (b) Significado das variáveis de folga.

Para funções lineares, $f(\mathbf{x}) = \alpha + \boldsymbol{\beta}^\top \mathbf{x}$ ideia é, então, minimizar

$$C \sum_{i=1}^n E_\varepsilon[f(\mathbf{x}_i) - y_i] + \frac{1}{2} \|\boldsymbol{\beta}\|^2, \quad (11.15)$$

com C indicando um parâmetro de regularização. Como mencionado no Capítulo 9, podemos introduzir variáveis de folga para cada ponto \mathbf{x}_i . Neste caso, precisamos de duas, $\xi_i \geq 0$ e $\xi_i^* \geq 0$, sendo $\xi_i > 0$ para pontos tais que $y_i > f(\mathbf{x}_i) + \varepsilon$ e $\xi_i^* > 0$ para pontos tais que $y_i < f(\mathbf{x}_i) - \varepsilon$. Veja o painel (b) da Figura 11.11. Para que um ponto \mathbf{x}_i esteja dentro das fronteiras de separação devemos ter

$$f(\mathbf{x}_i) - \varepsilon \leq y_i \leq f(\mathbf{x}_i) + \varepsilon. \quad (11.16)$$

A introdução das variáveis de folga permite que pontos estejam fora das fronteiras de separação, desde que elas sejam diferentes de zero, e então para $i = 1, \dots, n$ devem valer as condições

$$\begin{aligned} y_i &\leq f(\mathbf{x}_i) + \varepsilon + \xi_i, \\ y_i &\geq f(\mathbf{x}_i) - \varepsilon - \xi_i^*. \end{aligned}$$

A função a minimizar é

$$C \sum_{i=1}^n (\xi_i + \xi_i^*) + \frac{1}{2} \|\boldsymbol{\beta}\|^2, \quad (11.17)$$

com as restrições $\xi_i \geq 0$, $\xi_i^* \geq 0$. Usando multiplicadores de Lagrange $\lambda_i, \lambda_i^*, \mu_i, \mu_i^*$, todos não negativos, e otimizando o lagrangeano, que é função de $\alpha, \boldsymbol{\beta}$ e das variáveis de folga, obtemos

$$\boldsymbol{\beta} = \sum_{i=1}^n (\lambda_i - \lambda_i^*) \mathbf{x}_i, \quad (11.18)$$

$$\sum_{i=1}^n (\lambda_i - \lambda_i^*) = 0, \quad (11.19)$$

$$\lambda_i + \mu_i = C, \quad (11.20)$$

$$\lambda_i^* + \mu_i^* = C, \quad i = 1, \dots, n. \quad (11.21)$$

Usando essas equações na função lagrangeana obtemos o problema dual, que consiste em maximizar um lagrangeano que é função de λ_i e λ_i^* . O correspondente problema de maximização restrita maximização restrita requer $\lambda_i \leq C$, $\lambda_i^* \leq C$, com $\lambda_i \geq 0$, $\lambda_i^* \geq 0$. Substituindo β , as previsões para novos pontos são dadas por

$$f(\mathbf{x}) = \sum_{i=1}^n (\lambda_i - \lambda_i^*) K(\mathbf{x}, \mathbf{x}_i) + \alpha. \quad (11.22)$$

Os vetores suporte são aqueles que contribuem para (11.22), ou seja, são tais que $\lambda_i \neq 0$, $\lambda_i^* \neq 0$ (estão sobre ou fora das fronteiras).

As condições de KKT são, nesse caso, dadas por

$$\begin{aligned} \lambda_i [\varepsilon + \xi_i + f(\mathbf{x}_i) - y_i] &= 0, \\ \lambda_i^* [\varepsilon + \xi_i^* - y_i + f(\mathbf{x}_i)] &= 0, \\ (C - \lambda_i) \xi_i &= 0, \\ (C - \lambda_i^*) \xi_i^* &= 0, \quad i = 1, \dots, n. \end{aligned} \quad (11.23)$$

O valor de α é

$$\alpha = y_i - \varepsilon - \beta^\top \mathbf{x}_i,$$

com β dado por (11.18).

11.6 Exercícios

- 1) Considere os dados dispostos na Tabela 11.1 correspondentes a preços de ações da Telebrás e do índice da Bolsa de Valores de São Paulo (IBV), de 2 de janeiro a 24 de fevereiro de 1995, extraídos do CD-mercado.

Tabela 11.1: Preços de ações da Telebrás e Índice da Bolsa de Valores de São Paulo (2/1/1995 a 24/2/1995)

Obs	Telebrás	IBV	Obs	Telebrás	IBV
1	34,99	43,19	20	30,41	38,85
2	32,09	39,68	21	31,34	39,90
3	32,56	40,37	22	30,78	38,98
4	30,31	38,27	23	31,44	39,44
5	28,91	36,28	24	30,59	38,30
6	26,10	32,70	25	28,63	36,37
7	28,25	34,99	26	27,60	35,56
8	30,41	38,41	27	26,38	34,01
9	32,00	41,04	28	25,26	33,08
10	31,25	40,56	29	24,98	32,95
11	32,37	42,10	30	24,56	31,92
12	30,87	40,79	31	23,02	30,69
13	28,63	38,09	32	20,96	28,64
14	29,56	38,62	33	22,45	30,23
15	28,44	37,58	34	21,61	29,62
16	29,28	38,40	35	19,74	27,93
17	29,84	39,27	36	20,49	28,72
18	28,35	37,84	37	23,02	32,17
19	27,32	35,81	38	23,48	32,71

- a) Construa um gráfico de dispersão para os dados da Tabela 11.1 e identifique um modelo de regressão a ser ajustado aos dados interpretando os seus parâmetros.
- b) Ajuste o modelo identificado no item a) por meio do método de mínimos quadrados e avalie a qualidade de seu ajuste por meio de ferramentas de diagnóstico

- 2) Obtenha os estimadores *Ridge*, *Lasso* e *Elastic net* para os dados do Exemplo 6.7.
- 3 Idem, para os dados do Exemplo 6.11, agora tendo a frequência cardíaca como variável resposta.

PARTE III: APRENDIZADO NÃO SUPERVISIONADO

Na terceira parte do texto, apresentamos métodos utilizados para agrupar dados e reduzir a dimensão do conjunto de variáveis disponíveis por meio de combinações delas. Neste contexto, não há distinção entre variáveis explicativas e respostas e o objetivo é o entendimento da estrutura de associação entre elas. Com essa finalidade, consideramos análise de agrupamentos, análise de componentes principais, análise de componentes independentes e decomposição em valores singulares.

Análise de Agrupamentos

12.1 Introdução

O objetivo do conjunto de técnicas conhecido como **Análise de Agrupamentos** (*Cluster Analysis*) é agrupar “pontos” pertencentes a um determinado espaço em “grupos” de acordo com alguma medida de distância, de modo que pontos de um mesmo grupo tenham uma “pequena” distância entre eles. A Análise de Agrupamentos é, às vezes, chamada de **segmentação de dados**. O espaço mencionado acima pode ser um espaço Euclidiano, eventualmente de dimensão grande, ou pode ser um espaço não Euclidiano, por exemplo aquele que caracteriza documentos a serem agrupados segundo certas características como assunto tratado, correção gramatical etc. A Análise de Agrupamentos está inserida naquilo que chamamos anteriormente de **aprendizado não supervisionado**, ou seja, em que todas as variáveis do conjunto de dados são consideradas sem distinção entre preditoras e respostas. O objetivo é descrever associações e padrões entre essas variáveis. Com essa finalidade, podemos usar várias técnicas de agrupamento, e neste capítulo iremos discutir algumas delas.

A Análise de Agrupamentos é usada em muitas áreas e aplicações, como:

- i) Segmentação de imagens como em **fMRI** (imagens por ressonância magnética funcional), em que se pretende particionar as imagens em áreas de interesse. Veja, por exemplo, Sato et al. (2007).
- ii) Bioinformática, em que o objetivo é a análise de expressão de genes gerados de *microarrays* ou sequenciamento de DNA ou proteínas. Veja Hastie et al. (2009) ou Fujita et al. (2007), por exemplo.
- iii) Reconhecimento de padrões de objetos e caracteres, como em identificação de textos escritos a mão em Linguística.
- iv) Redução (ou compressão) de grandes conjuntos de dados, a fim de escolher grupos de dados de interesse.

Para motivar o problema, começemos com um exemplo.

Exemplo 12.1: Consideremos as medidas das variáveis altura (X_1 , em cm), peso (X_2 , em kg), idade (X_3 , em anos) e sexo (X_4 , M ou F) de 12 indivíduos, dispostas nas colunas 2, 3, 4 e 5 na Tabela 12.1.

Tabela 12.1: Dados de 12 indivíduos

Indivíduo	Altura	Peso	Idade	Sexo	Altura	Peso	Idade
					Padronizados		
A	180	75	30	M	0,53	0,72	0,38
B	170	70	28	F	-0,57	-0,13	-0,02
C	165	65	20	F	-1,12	-0,97	-1,61
D	175	72	25	M	-0,02	0,21	-0,61
E	190	78	28	M	1,63	1,23	-0,02
F	185	78	30	M	1,08	1,23	0,38
G	160	62	28	F	-1,67	-1,48	-0,02
H	170	65	19	F	-0,57	-0,97	-1,81
I	175	68	27	M	-0,02	-0,47	-0,22
J	180	78	35	M	0,53	1,23	1,38
K	185	74	35	M	1,08	0,55	1,38
L	167	64	32	F	-0,90	-1,14	0,78
μ	175,17	70,75	28,08		—	0	0
σ	9,11	5,91	5,02		—	1	1

Nessa tabela, a média de cada variável é indicada por μ e o desvio padrão por σ . Nas colunas 6, 7 e 8 dispomos os valores das variáveis padronizadas, ou seja, obtidas por meio da transformação

$$Z_i = (X_i - \mu_{X_i})/\sigma_i, \quad i = 1, 2, 3. \quad (12.1)$$

Para a variável X_4 (sexo), esta padronização, é claro, não faz sentido. Na Figura 12.1 apresentamos um gráfico de dispersão de X_3 versus X_2 .

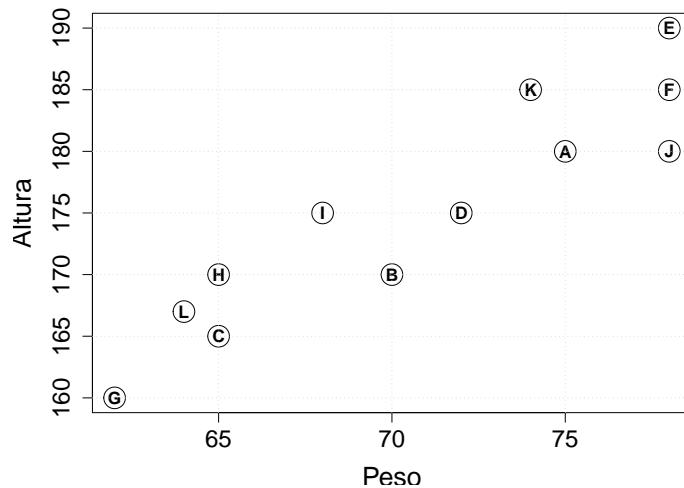


Figura 12.1: Gráfico de Altura versus Peso para os dados da Tabela 12.1, A=1, B=2 etc.

Com a finalidade de agrupar pontos que estejam próximos, precisamos escolher

uma distância. A distância euclidiana é bastante utilizada com esse propósito. Dados dois pontos num espaço de dimensão 2, $\mathbf{x} = (x_1, x_2)$ e $\mathbf{y} = (y_1, y_2)$, a distância euclideana entre eles é definida por

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2}.$$

No caso geral de um espaço euclidiano p -dimensional, a distância é definida por

$$d(\mathbf{x}, \mathbf{y}) = \sqrt{(x_1 - y_1)^2 + \dots + (x_p - y_p)^2}.$$

Além da distância euclidiana, podemos usar outras distâncias, como

$$d_1 = |x_1 - y_1| + \dots + |x_p - y_p| : \text{distância } L_1 \text{ ou Manhattan,} \quad (12.2)$$

$$d_2 = \max_{1 \leq i \leq p} |x_i - y_i| : \text{distância } L_\infty. \quad (12.3)$$

Para espaços não Euclidianos, há outras definições de distância, como a distância de Hamming, cosseno, Jaccard, edit etc. Detalhes são apresentados na Nota de Capítulo 1.

Escolhida uma distância, podemos construir a correspondente **matriz de similaridade**, que no caso de n unidades amostrais é uma matriz de dimensão $n \times n$, $D = [d(i, j)]_{i,j=1}^n$, simétrica, com os elementos da diagonal principal iguais a zero. É comum considerar uma matriz reduzida, de ordem $(n - 1) \times n$, para evitar os valores nulos da diagonal principal. A Tabela 12.2 contém a matriz de similaridade para os dados da Tabela 12.1 obtida com a distância euclidiana.

Tabela 12.2: Matriz de similaridade, distância Euclidiana

	A	B	C	D	E	F	G	H	I	J	K
B	11,18										
C	18,03	7,07									
D	5,83	5,38	12,21								
E	10,44	21,54	28,18	16,16							
F	5,83	17,00	23,85	11,66	5,00						
G	23,85	12,81	5,83	18,03	34,00	29,68					
H	14,14	5,00	5,00	8,60	23,85	19,85	10,44				
I	8,60	5,39	10,44	4,00	18,03	14,14	16,16	5,83			
J	3,00	12,81	19,85	7,81	10,00	5,00	25,61	16,40	11,18		
K	5,10	15,52	21,93	10,20	6,40	4,00	27,73	17,49	11,66	6,40	
L	17,03	6,71	2,24	11,31	26, 93	22,80	7,28	3,16	8,94	19,10	20,59

As distâncias salientadas em negrito na Tabela 12.2 em ordem crescente, nomeadamente

$$\begin{aligned} d(C, L) &= 2,24, \\ d(A, J) &= 3,00, \\ d(H, L) &= 3,16, \\ d(D, I) &= 4,00, \\ d(F, K) &= 4,00, \\ d(B, H) &= 5,00, \\ d(C, H) &= 5,00, \\ d(E, F) &= 5,00, \\ d(F, J) &= 5,00, \\ d(A, K) &= 5,10. \end{aligned}$$

nos dão uma ideia de como agrupar os indivíduos.

12.2 Estratégias de agrupamento

Segundo Hastie et al. (2009), os algoritmos de agrupamento podem ser classificados em três grupos:

- a) **combinatórios**: trabalham diretamente com os dados, não havendo referência à sua distribuição;
- b) **baseados em modelos**: supõem que os dados constituem uma amostra aleatória simples de uma população cuja densidade de probabilidade, é uma mistura de densidades componentes, cada qual descrevendo um grupo;
- c) **caçadores de corcovas** (*bump hunters*): estimam, de modo não paramétrico, as modas da densidade. As observações mais próximas a cada moda definem os grupos.

Os algoritmos combinatórios, por sua vez, podem ser classificados em dois subgrupos:

- i) **algoritmos hierárquicos**: que ainda podem ser subdivididos em **aglomerativos** e **divisivos**. No primeiro caso, o procedimento utilizado para o agrupamento inicia-se classificando cada ponto em um grupo e em seguida, combina os grupos com base em suas proximidades, usando alguma definição de proximidade (como uma distância). O processo termina quando um número pré-fixado de grupos é atingido ou quando por alguma razão (de cunho interpretativo) formam-se grupos indesejáveis. No segundo caso, todos os pontos são inicialmente considerados em um único grupo que é subdividido sucessivamente até que alguma regra de parada seja satisfeita. Neste texto, usaremos apenas o método aglomerativo.
- ii) **algoritmos de partição ou obtidos por associação de pontos**: os grupos obtidos formam uma partição do conjunto total de pontos. Os pontos são considerados em alguma ordem e cada um deles é associado ao grupo no qual ele melhor se ajusta. O método chamado de **K–médias** pertence a esse grupo de algoritmos.

Num espaço euclidiano munido de alguma distância entre pontos, os grupos podem ser caracterizados pelo seu **centróide** (média das coordenadas dos pontos). Essa noção não existe em espaços não euclidianos e precisamos outra maneira para caracterizar os grupos.

Em conjuntos de pontos muito grandes quase todos os pares de pontos têm distâncias muito parecidas entre si e quaisquer dois vetores são quase sempre ortogonais. Esse fato está relacionado com aquilo que se chama de **maldição da dimensionalidade** (*curse of dimensionality*).

Não existe um algoritmo que seja mais recomendado para todos os casos. A interpretação dos grupos resultantes deve ser levada em conta na escolha do algoritmo mais adequado a cada problema.

12.3 Algoritmos hierárquicos

Ilustraremos o funcionamento do algoritmo por meio de um exemplo.

Exemplo 12.1 (continuação). Consideremos as variáveis X_2 (peso) e X_3 (altura) representadas no diagrama de dispersão da Figura 12.1. Adotemos a distância euclidiana para avaliar a proximidade entre dois pontos no espaço euclidiano associado.

Cada grupo a ser formado será representado pelo seu centróide e a regra de agrupamento consistirá em agregar aqueles para os quais a distância entre os respectivos seja a menor possível. Os passos para a implementação do algoritmo são

- i) Considerar cada ponto como um grupo de forma que seu centróide é definido pelas próprias coordenadas.
- ii) Consultar a Tabela 12.2 e agrupar $C=(65, 165)$ e $L=(64, 167)$ que são os mais próximos com $d(C, L) = \sqrt{5,00} = 2,24$. Esses dois pontos formam o primeiro agrupamento, $\mathcal{G}_1 = \{C, L\}$ com centróide definido por $c(C, L) = (166, 64, 5)$. A distância entre esses pontos, 2,24, será chamada **nível do agrupamento ou junção**.
- iii) Em seguida, recalcular as distâncias entre os pontos, considerando agora os grupos A, B, CL, D, E, F, G, H, I, J, K. Apenas as distâncias de cada ponto ao centróide do grupo $\mathcal{G}_1 = \{C, L\}$ serão alteradas. Novamente consultar a Tabela 12.2, observando que a distância entre $A = (75, 180)$ a $J = (78, 180)$ é 3, indicando que esses pontos devem formar o novo grupo $\mathcal{G}_2 = \{A, J\}$, com centróide $c(\mathcal{G}_2) = (76, 5, 180)$ e nível de agrupamento 3,00.
- iv) Consultar novamente a Tabela 12.2, observar que a distância entre $D = (72, 175)$ e $I = (68, 175)$ é 4,00, e agregá-los no grupo $\mathcal{G}_3 = \{D, I\}$, com centróide $c(\mathcal{G}_3) = (70, 175)$ e nível de agrupamento 4,00.
- v) Observar em seguida que os pontos mais próximos são $F = (78, 185)$ e $K = (74, 185)$, com distância 4,00, e formar o grupo $\mathcal{G}_4 = \{F, K\}$ com centróide $c(\mathcal{G}_4) = (76, 185)$ e nível de agrupamento 4,00.
- vi) Notar que a distância do ponto $H = (65, 170)$ ao centróide do grupo \mathcal{G}_1 é $d(H, c(\mathcal{G}_1)) \approx 4,03$ e formar um novo grupo $\mathcal{G}_5 = \{C, H, L\}$, com centróide $c(\mathcal{G}_5) = (64, 7, 167, 3)$ e nível de agrupamento 4,03.
- vii) A seguir, agrupar $B = (70, 170)$ com $\mathcal{G}_3 = \{D, I\}$, notando que a distância entre B e o centróide desse grupo é 5,00, que é esse valor o nível da junção correspondente. O novo grupo é $\mathcal{G}_6 = \{B, D, I\}$, com centróide $c(\mathcal{G}_6) = (70, 173, 3)$.
- viii) Agrupar agora, os grupos $\mathcal{G}_2 = \{A, J\}$ e $\mathcal{G}_4 = \{F, K\}$, cuja distância entre seus centróides é 5,02, formando o grupo $\mathcal{G}_7 = \{A, F, J, K\}$, com centróide $c(\mathcal{G}_7) = (76, 25, 182, 5)$ e nível de agrupamento 5,02.
- ix) Agregar o ponto $G = (62, 160)$ ao grupo $\mathcal{G}_5 = \{C, H, L\}$, obtendo o novo grupo $\mathcal{G}_8 = \{C, G, H, L\}$, com centróide $c(\mathcal{G}_8) = (64, 165, 5)$ e nível de agrupamento 7,31.
- x) Finalmente, agregar o ponto $E = (78, 190)$ ao grupo $\mathcal{G}_7 = \{A, F, J, K\}$, obtendo o grupo $\mathcal{G}_9 = \{A, E, F, J, K\}$, com centróide $c(\mathcal{G}_9) = (76, 6, 184)$ e nível de agrupamento 7,50.

O agrupamentos formados pelo algoritmo estão representados na Figura 12.2. Podemos prosseguir, agrupando dois desses grupos (aqueles associados com a menor distância entre os respectivos centróides) e, finalmente, agregar os dois grupos restantes.

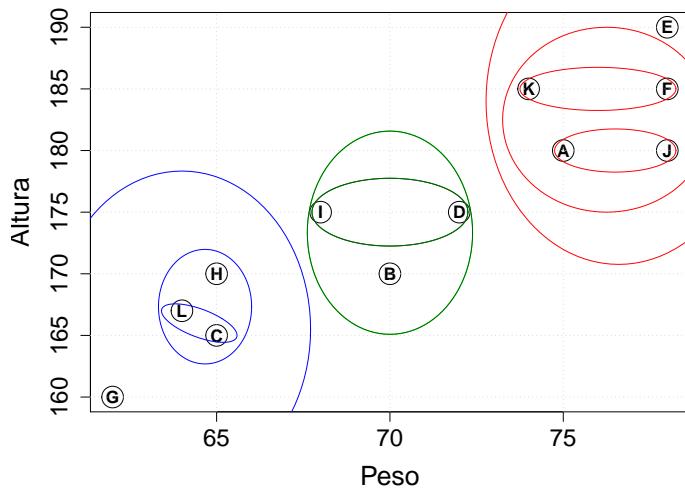


Figura 12.2: Agrupamentos obtidos para o Exemplo 12.1

Um gráfico que sumariza o procedimento (chamado *dendrograma*) está representado na Figura 12.3. No eixo vertical da figura colocamos os níveis, no horizontal, os pontos de modo conveniente. Nessa figura, usamos a distância euclidiana.

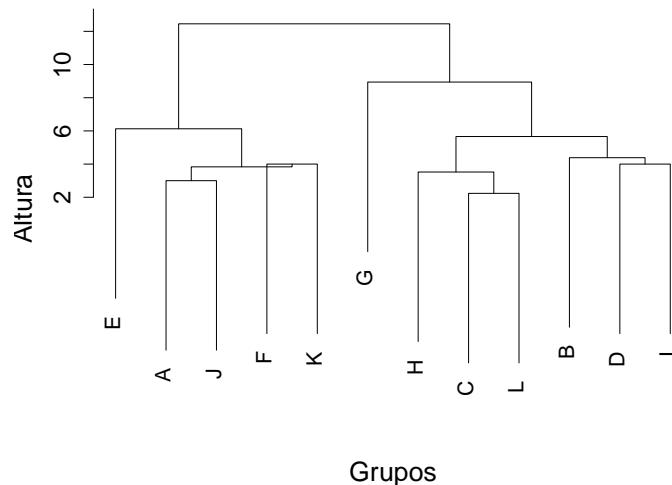


Figura 12.3: Dendrograma para o Exemplo 12.1

Na Tabela 12.3 temos um resumo do método hierárquico, usando distância Euclidiana e centróides, para agrupar os pontos, para o Exemplo 12.1.

Interpretando o resultado, com esses três grupos, vemos que o primeiro contém as pessoas menos pesadas e mais baixas (4 pessoas), depois aquele que contém pessoas com pesos e alturas intermediárias (3 pessoas) e, finalmente, o grupo que contém as pessoas mais pesadas e mais altas (5 pessoas). Se esse for objetivo,

Tabela 12.3: Resumo do procedimento de agrupamento para o Exemplo 12.1

Passo	Agrupamento	Nível
1	C, L	2,24
2	A, J	3,00
3	D, I	4,00
4	F, K	4,00
5	H, CL	4,03
6	B, DI	5,00
7	AJ, KF	5,02
8	G, CHL	7,31
9	E, AFJK	7,50

podemos parar aqui. Se o objetivo é obter dois grupos, um com pessoas mais baixas e menos pesadas e, outro, com pessoas mais altas e mais pesadas, continuamos a agrupar mais uma vez, obtendo os grupos $\mathcal{G}_{10} = \{B, C, D, G, H, I, L\}$ e \mathcal{G}_9 .

Um objetivo dos objetivos da construção de grupos é **classificar** um novo indivíduo em algum dos grupos obtidos. O problema da classificação está intimamente ligado ao problema de AA, e já foi tratado em capítulos anteriores.

Um pacote do repositório R que pode ser usado é o **cluster**. Após carregar o pacote em sua área por meio de `library(cluster)`, temos que informar a distância (`euclidean`, `maximum`, `manhattan` etc.) a usar e o método de agrupamento (`centroid`, `average`, `median` etc.). O pacote contém várias funções para mostrar em que grupo estão as unidades, obter o dendrograma, fornecer a ordem para fazer o dendrograma etc. **Os scripts para o Exemplo 12.1 estão na página do livro.**

12.4 Algoritmos de partição: K–médias

O método de K–médias tem por objetivo agregar os pontos em K grupos, de tal modo que a soma dos quadrados das distâncias dos pontos aos centros dos agrupamentos (*clusters*) seja minimizada. É um método baseado em centroídes, como vimos anteriormente, e pertence à classe de algoritmos (ii) discutida na Seção 9.1, e requer que o espaço seja euclidiano. Usualmente, o valor de K é conhecido e deve ser fornecido pelo usuário mas é possível obtê-lo por tentativa e erro.

O algoritmo mais comum foi proposto por Hartigan and Wong (1979) é bastante usado como *default* em pacotes computacionais. Outros algoritmos são os de MacQueen (1967), Lloyd (1957) e Forgy (1965). A função `kmeans` do pacote `cluster` pode ser utilizada para construir agrupamentos com base no algoritmo de Hartigan and Wong (1979).

A ideia que fundamenta o algoritmo consiste em definir grupos em que a variação interna seja minimizada. Em geral, essa variação interna corresponde à soma dos quadrados das distâncias euclidianas entre pontos de um grupo e o centroíde correspondente,

$$W(\mathcal{G}_k) = \sum_{\mathbf{x}_i \in \mathcal{G}_k} \|\mathbf{x}_i - \boldsymbol{\mu}_k\|^2, \quad (12.4)$$

em que \mathbf{x}_i é um ponto no grupo \mathcal{G}_k e $\boldsymbol{\mu}_k$ é a centróide do pontos do grupo \mathcal{G}_k .

O algoritmo consiste nos seguintes passos:

- i) Especifique K e selecione K pontos que pareçam estar em diferentes grupos.
- ii) Considere esses pontos como os centróides iniciais desses grupos.
- iii) Associe cada ponto ao centróide mais próximo com base na sua distância euclidiana ao centróide;
- iv) Para cada um dos K grupos, recalcule o centróide após a inclusão dos pontos.
- v) Minimize, iterativamente, a soma total de quadrados dentro dos grupos, até que os centróides não mudem muito (o R usa 10 iterações como *default*).

A soma total de quadrados dentro dos grupos é definida por

$$\sum_{j=1}^K W(\mathcal{G}_j) = \sum_{j=1}^K \sum_{x_i \in \mathcal{G}_j} \|\mathbf{x}_i - \boldsymbol{\mu}_j\|^2. \quad (12.5)$$

Como o algoritmo K-médias é baseado na distância euclidiana, convém padronizar as variáveis quando estão expressas com diferentes unidades de medida, especialmente no caso em que uma ou mais variáveis têm valores muito diferentes. Por exemplo, para agrupar automóveis com base no preço (R\$) e na potência do motor (CV), o preço será a variável dominante no cálculo da distância euclidiana se não houver padronização.

Ilustremos a utilização do algoritmo por meio de um exemplo simulado.

Exemplo 12.2: Consideremos 100 observações simuladas de duas variáveis com distribuições normais, com médias 0 e desvios padrões 0,3 e outras 100 de duas variáveis normais com médias 1 e com os mesmos desvios padrões 0,3. Na Figura 12.4 apresentamos os dois grupos com os respectivos centróides, resultantes da aplicação do algoritmo **K-means** com $K = 2$.

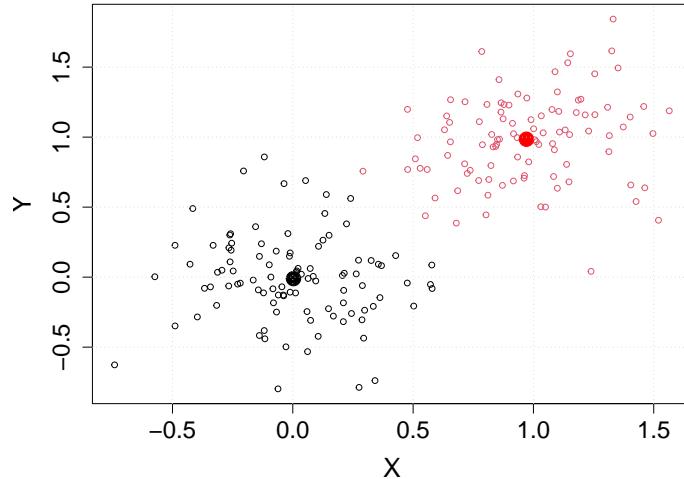


Figura 12.4: Dados e centróides obtidos por meio do pacote `kmeans` para os dados simulados (Exemplo 12.2)

Exemplo 12.3: Consideremos as variáveis Peso e Altura da Tabela 12.1. Aproveitando o resultado do procedimento hierárquico usado na primeira análise, fixemos o número de grupos $K = 3$. O gráfico da Figura 12.5 corresponde ao resultado do agrupamento realizado por meio do algoritmo K-means obtido pela função `kmeans`. Nessa figura identificamos os três grupos (com tamanhos 3,4 e 5) além dos respectivos centróides com diferentes cores. As coordenadas dos centróides, obtidas por meio da função são $(63, 67, 164)$, $(68, 75, 172, 5)$ e $(76, 60, 184, 0)$. As somas de quadrados dentro dos grupos são respectivamente, 30,67, 51,75 e 85,20. A soma de quadrados total entre grupos é 87,1.

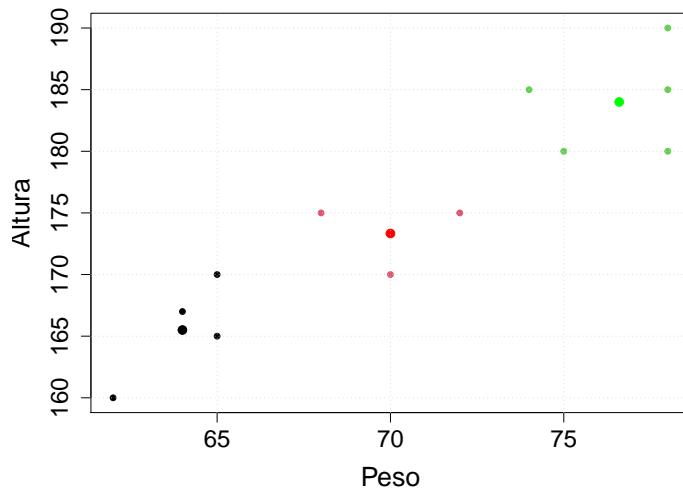


Figura 12.5: Dados e centróides dos três grupos obtidos por meio do pacote `kmeans` para o Exemplo 12.1

Exemplo 12.4: Consideremos os dados disponíveis em

https://raw.githubusercontent.com/datascienceinc/\learn-data-science/master/Introduction-to-K-means-Clustering/\Data/data_1024.csv.

correspondentes a um conjunto de 4.000 motoristas encarregados de fazer entregas de determinados produtos em setores urbano e rural. Dentre as variáveis existentes no arquivo de dados, selecionamos apenas duas, nomeadamente, X_1 : distância média percorrida por cada motorista (em milhas) e X_2 : porcentagem média do tempo em que o motorista esteve acima do limite de velocidade por mais de 5 milhas por hora. Uma análise detalhada dos dados pode ser obtida em Trevino (2016).

Os dados e os *scripts* baseados em funções do pacote R estão na página do livro.

Na Figura 12.6 apresentamos um diagrama de dispersão referente às duas variáveis que salienta claramente dois grupos: Grupo 1, contendo os motoristas que fazem entregas no setor urbano e Grupo 2, contendo motoristas que fazem entregas no setor rural.

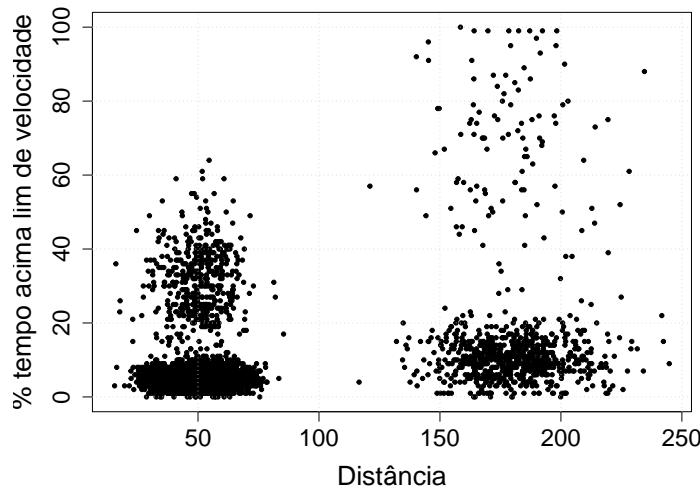


Figura 12.6: Gráfico de dispersão de X_1 versus X_2 para o Exemplo 12.4

O agrupamento obtido da aplicação do algoritmo K-médias com $K = 2$ aplicado às variáveis padronizadas determina dois grupos cujos centróides definidos em termos das variáveis originais são

Grupo 1: Centróide = $(180, 31, 18, 31)$ [motoristas do setor rural]

Grupo 2: Centróide = $(50, 07, 8, 83)$ [motoristas do setor urbano].

Os grupos estão claramente representados na Figura 12.7 e refletem a separação observada no gráfico de dispersão.

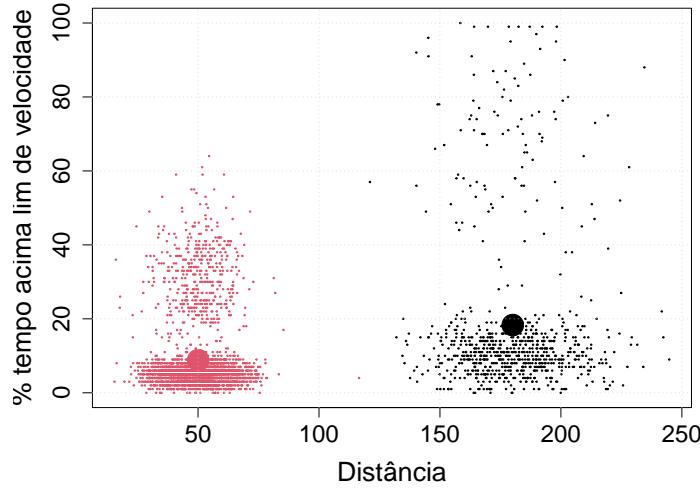


Figura 12.7: Grupos obtidos por meio do algoritmo K-médias com $K=2$ para o Exemplo 12.4.

Uma utilização do mesmo algoritmo com $K = 4$, gera 4 grupos

Grupo 1: Centróide = (177,83, 70,29) [motoristas do setor rural, acima do limite de velocidade]

Grupo 2: Centróide = (50,02, 5,20) [motoristas do setor urbano, dentro do limite de velocidade]

Grupo 3: Centróide = (50,20, 32,37) [motoristas do setor urbano, acima do limite de velocidade]

Grupo 4: Centróide = (180,43, 10,53) [motoristas do setor rural, dentro do limite de velocidade]

em que os motoristas também são separados de acordo com o respeito ao limite de velocidade além da divisão em zonas urbana ou rural. O gráfico correspondente está disposto na Figura 12.8.

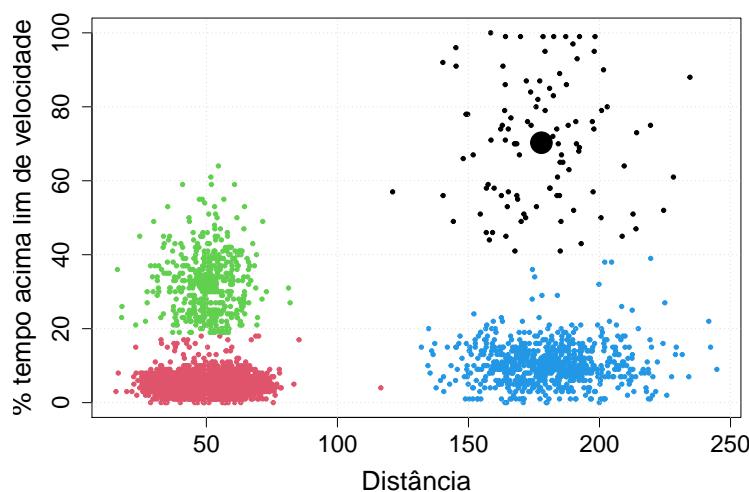


Figura 12.8: Grupos obtidos por meio do algoritmo K-médias com K=4 para o Exemplo 12.4.

Exemplo 12.5: Dados sobre tráfego de veículos em uma cidade podem ser úteis para vários propósitos: identificar horas de tráfego intenso (*rush hours*), efeito de feriados, impacto do clima, entendimento sobre circulação nas várias regiões da cidade (áreas residenciais, de escolas, negócios, estradas etc.) e pode ajudar as agências responsáveis no planejamento do tráfego. Detalhes sobre o tema podem ser obtidos de Jaiswal (2018).

Nesse contexto, consideremos dados de viagens de motoristas do **Uber** na cidade de Nova Iorque (NYC), disponíveis no sítio

[www.kaggle.com/fivethirtyeight/uber-pickups-in-new-york-city/
data](http://www.kaggle.com/fivethirtyeight/uber-pickups-in-new-york-city/data)

Esse conjunto de dados contém cerca de 4,5 milhões de viagens do Uber de abril a setembro de 2014, além de outros dados do Uber de 2015 e de outras companhias. NYC tem 5 distritos: Brooklyn, Queens, Manhattan, Bronx e Staten Island. Com finalidade didática, restringir-nos-emos aos dados de 2014, que têm informação detalhada sobre a localização do início das viagens com as seguintes colunas:

Date/Time: dia e hora do início da viagem;

Lat: a latitude da localidade correspondente;
 Lon: a longitude da localidade;
 Base: o código da base da companhia afiliada àquela corrida.

Os rótulos dos arquivos disponíveis no sítio são da forma `uber-raw-data-month.csv`, em que **month** deve ser substituído por apr14, aug14, jul14, jun14, may14, sept14. Em nosso exemplo, vamos usar somente os dados de abril de 2014. Para ler os dados usamos o comando:

```
> read.csv("https://raw.githubusercontent.com/fivethirtyeight/
uber-tlc-foil-response/master/uber-trip-data/uber-raw-data-apr14.csv")
```

Estatísticas descritivas para as variáveis do conjunto de dados podem ser obtidas com o comando `summary(apr14)`, gerando os seguintes resultados:

```
summary(apr14)
      Date.Time           Lat           Lon
 4/7/2014 20:21:00 : 97   Min.   :40.07   Min.   :-74.77
 4/7/2014 20:22:00 : 87   1st Qu.:40.72   1st Qu.:-74.00
 4/30/2014 17:45:00: 78   Median :40.74   Median :-73.98
 4/30/2014 18:43:00: 70   Mean    :40.74   Mean   :-73.98
 4/30/2014 19:00:00: 70   3rd Qu.:40.76   3rd Qu.:-73.97
 4/30/2014 16:55:00: 67   Max.    :42.12   Max.   :-72.07
 (Other)                  :564047
```

Alguns dados disponíveis no arquivo (até dia) têm a seguinte estrutura:

```
head(apr14, n=10)
      Date.Time     Lat     Lon Base Year Month Day
 1 2014-04-01 00:11:00 40.7690 -73.9549 B02512 2014    4    1
 2 2014-04-01 00:17:00 40.7267 -74.0345 B02512 2014    4    1
 3 2014-04-01 00:21:00 40.7316 -73.9873 B02512 2014    4    1
 4 2014-04-01 00:28:00 40.7588 -73.9776 B02512 2014    4    1
 5 2014-04-01 00:33:00 40.7594 -73.9722 B02512 2014    4    1
 6 2014-04-01 00:33:00 40.7383 -74.0403 B02512 2014    4    1
 7 2014-04-01 00:39:00 40.7223 -73.9887 B02512 2014    4    1
 8 2014-04-01 00:45:00 40.7620 -73.9790 B02512 2014    4    1
 9 2014-04-01 00:55:00 40.7524 -73.9960 B02512 2014    4    1
10 2014-04-01 01:01:00 40.7575 -73.9846 B02512 2014    4    1
```

Por meio dos pacotes `kmeans` e `ggmap` obtemos a Figura 12.9. *Detalhes dos scripts necessários, estão na página do livro.*

Figura 12.9: Grupos obtidos para o Exemplo 12.5

12.5 Tópicos adicionais

1) Matriz cofenética

A matriz cofenética contém as distâncias entre os objetos obtidas a partir do dendrograma. Para os dados do Exemplo 12.1, a matriz cofenética pode ser obtida por meio dos comandos

```

options(digits=3)
dados1 <- dados[,-1]
distancia <- dist(dados1, method = "euclidean")
hclust_euclid <- hclust(distancia, method = 'centroid')
> cophenetic(hclust_euclid)
      1   2   3   4   5   6   7   8   9   10  11
2 12.45
3 12.45  5.66
4 12.45  4.39  5.66
5  6.13 12.45 12.45 12.45
6  3.83 12.45 12.45 12.45  6.13
7 12.45  8.94  8.94  8.94 12.45 12.45
8 12.45  5.66  3.52  5.66 12.45 12.45  8.94
9 12.45  4.39  5.66  4.00 12.45 12.45  8.94  5.66
10 3.00 12.45 12.45 12.45  6.13  3.83 12.45 12.45 12.45
11 3.83 12.45 12.45 12.45  6.13  4.00 12.45 12.45 12.45  3.83
12 12.45  5.66  2.24  5.66 12.45 12.45  8.94  3.52  5.66 12.45 12.45

```

Por exemplo, a distância entre os pontos C e L no Exemplo 12.1 corresponde ao nível em que os dois foram agrupados, nesse caso, 2,24. Essa matriz pode ser comparada com a matriz de distâncias obtida dos dados,

```

> distancia <- dist(dados1, method = "euclidean")
      1   2   3   4   5   6   7   8   9   10  11
2 11.18
3 18.03  7.07
4  5.83  5.39 12.21
5 10.44 21.54 28.18 16.16
6  5.83 17.00 23.85 11.66  5.00
7 23.85 12.81  5.83 18.03 34.00 29.68
8 14.14  5.00  5.00  8.60 23.85 19.85 10.44
9  8.60  5.39 10.44  4.00 18.03 14.14 16.16  5.83
10 3.00 12.81 19.85  7.81 10.00  5.00 25.61 16.40 11.18
11 5.10 15.52 21.93 10.20  6.40  4.00 27.73 17.49 11.66  6.40
12 17.03  6.71  2.24 11.31 26.93 22.80  7.28  3.16  8.94 19.10 20.59

```

Uma medida da proximidade entre essas duas matrizes é o chamado **coeficiente de correlação cofenético**, que corresponde ao coeficiente de correlação entre os elementos de uma com os elementos da outra situados nas mesmas posições.. No Exemplo 12.1, esse valor é 0,80 e pode ser considerado um valor adequado. Veja o Problema 6.

2) Outros algoritmos

Vimos exemplos com duas variáveis. Podemos ter mais variáveis, mas seu número deve ser menor que o número de indivíduos. Quando temos mais do que duas dimensões, alguns algoritmos foram propostos e são, basicamente, variantes de algoritmos hierárquicos e de K -médias. Entre eles, destacamos

- Algoritmo BFR** [(Bradley, Fayyad and Reina, (1998)]. Esse algoritmo é uma variante do algoritmo K -médias para o caso de um espaço euclidiano de alta dimensão mas é baseado numa suposição muito forte: em cada dimensão, a forma dos agrupamentos deve seguir uma distribuição normal ao redor do respectivo centróide, e além disso as variáveis definidoras das dimensões devem ser independentes. Consequentemente, os grupos devem ter a forma de um elipsóide, com os eixos paralelos aos eixos da dimensão, podendo eventualmente ser um círculo. Os eixos do

elipsóide não podem ser oblíquos aos eixos da dimensão. Esse algoritmo não está contemplado no R.

- b) **Algoritmo CURE** (de *Clustering Using Representatives*). Esse algoritmo usa procedimentos hierárquicos e os grupos podem ter quaisquer formas mas também não está disponível no R. No entanto, ele pode ser obtido no pacote `pyclustering`, que usa as linguagens Python e C_{++} .
- c) **Density-based algorithms** (DBSCAN): dado um conjunto de pontos em algum espaço, esse algoritmo agrupa pontos que estão dispostos em uma vizinhança com maior densidade, identificando os pontos que estão em regiões de baixa densidade como *outliers*. Para detalhes, consulte Ester et al. (1996).

12.6 Notas de capítulo

1) Distâncias para espaços não euclidianos

Como salientamos na Seção 12.1, para espaços não euclidianos há outras formas de distância. No caso de sequências (*strings*) $x = x_1x_2 \cdots x_n$ e $y = y_1y_2 \cdots y_n$, uma distância conveniente é a distância *edit*, que corresponde ao número de inserções e exclusões de caracteres necessários para converter x em y . Consideremos, por exemplo, as sequências $x = abcd$ e $y = acde$. A distância *edit* entre essas sequências é $d_e(x, y) = 2$, pois temos que excluir b e inserir e depois do d para concretizar a conversão. Uma outra maneira de obter essa distância é considerar a subsequência mais longa comum a x e y . No exemplo, é acd . A distância *edit* é dada $d_e(x, y) = \ell(x) + \ell(y) - 2\ell(SML)$, em que ℓ indica o comprimento de cada sequência. No exemplo, $d_e(x, y) = 4 + 4 - 2 \times 3 = 2$.

Outra distância que pode ser usada para a obtenção de agrupamentos é a **distância Hamming**, que corresponde ao número de componentes em que dois vetores (de mesma dimensão) diferem. Por exemplo, se $x = 110010$ e $y = 100101$, então a distância Hamming entre eles é $d_H(x, y) = 4$.

Um problema associado a agrupamentos em espaços não euclidianos é a representação de grupos, pois não podemos, por exemplo, calcular o centróide de dois pontos. No exemplo acima, como obter uma sequência entre x e y ? Usando a distância *edit* poder-se-ia selecionar algo parecido ao centróide (o **grupóide**), escolhendo-se a sequência que minimiza, por exemplo, a soma das distâncias dessa com as outras sequências do grupo previamente selecionado.

2) Classificação de algoritmos aglomerativos

Consideremos dois grupos quaisquer, A e B , obtidos por meio de algoritmos hierárquicos e a distância entre eles, $d(A, B)$. Como vimos, comumente usamos algoritmos aglomerativos que ainda podem ser divididos em (Hastie et al., 2009):

- a) Algoritmos com ligação simples (*single linkage*), para os quais adota-se a distância mínima entre os pares, ou seja,

$$d_{SL}(A, B) = \min_{i \in A, j \in B} d(i, j). \quad (12.6)$$

Essa técnica é também conhecida como técnica do **vizinho mais próximo**.

- b) Algoritmos com ligação completa (*complete linkage*), para os quais toma-se a máxima distância entre os pares:

$$d_{CL}(A, B) = \max_{i \in A, j \in B} d(i, j). \quad (12.7)$$

- c) Algoritmos com ligação média (*group average*), em que se adota a distância média entre os grupos:

$$d_{GA}(A, B) = \frac{1}{N_A N_B} \sum_{i \in A} \sum_{j \in B} d(i, j). \quad (12.8)$$

Aqui, N_A e N_B indicam os números de observações em cada grupo.

Ligações simples produzem grupos com diâmetros grandes e ligações completas produzem grupos com diâmetros pequenos; agrupamentos por médias representam um compromisso entre esses dois extremos. Veja o Exercício 4.

12.7 Exercícios

- 1) Considere as variáveis Altura e Idade da Tabela 12.1 e obtenha os agrupamentos usando a distância euclidiana e o método do centróide. Construa o dendrograma correspondente.
- 2) Repita o exercício anterior com as variáveis Peso e Idade.
- 3) Refaça os Problemas 1 e 2 usando a distância L_1 (ou Manhattan).
- 4) O **raio** de um grupo é a distância máxima entre os seus pontos e o centróide. O **diâmetro** de um grupo é a máxima distância entre quaisquer dois pontos do grupo. Encontre o raio e o diâmetro para os problemas correspondentes aos Exercícios 1 e 2.
- 5) Considere as sequências *abcd*, *acde*, *aecdb* e *ecadb*. Obtenha o grupóide desse grupo, considerando a distância *edit* e como critério a soma das distâncias entre sequências.
- 6) Obtenha a matriz cofenética e o coeficiente de correlação cofenético para o Exemplo 12.1. Use os seguintes comandos do pacote **cluster**:

```
d$<$-dist(dados,method="euclidian")
hc$<$-hclust(d, method="centroid")
d.coph$<$- cophenetic(hc)
cor(dist(df), d.coph)
```

- 7) Considere o Exemplo 12.5 e obtenha os dados de todos os meses (abril a setembro) de 2014. Reproduza os cálculos do exemplo com esses dados. Consulte os *scripts* do capítulo.

Redução de Dimensionalidade

When the number of factors coming into play is too large, scientific methods in most cases fail.

A. Einstein

13.1 Introdução

As técnicas de Análise de Componentes Principais, Análise de Fatorial e Análise de Componentes independentes têm como objetivo reduzir a dimensionalidade de observações multivariadas com base em sua estrutura de dependência. Essas técnicas são usualmente aplicadas em conjuntos de dados com um grande número de variáveis. A ideia que as permeia é a obtenção de poucos poucos fatores, obtidos como funções das características observadas, que conservem, pelo menos aproximadamente, a estrutura de covariância das variáveis originais. Esses poucos fatores vão substituir as variáveis originais em análises subsequentes, servindo, por exemplo, como variáveis explicativas em modelos de regressão. Por esse motivo, a interpretação dessas novas variáveis é muito importante.

13.2 Componentes Principais

A técnica de Componentes Principais consiste numa transformação ortogonal dos eixos de coordenadas de um sistema multivariado. A orientação dos novos eixos é determinada por meio da partição sequencial da variância total das observações em porções cada vez menores de modo que ao primeiro eixo transformado corresponda o maior componente da partição da variância; ao segundo eixo transformado, a parcela seguinte e assim por diante. Se os primeiros eixos forem tais que uma “grande” parcela da variância seja explicada por eles, poderemos desprezar os demais e trabalhar apenas com os primeiros em análises subsequentes.

Consideremos duas variáveis X_1 e X_2 com distribuição normal bivariada com média μ e matriz de covariâncias Σ . O gráfico correspondente aos pontos em que a função densidade de probabilidade é constante é uma elipse; um exemplo está apresentado na Figura 13.1.¹

¹Admitimos dados com distribuição normal apenas para finalidade didática. Em geral, essa suposição não é necessária.

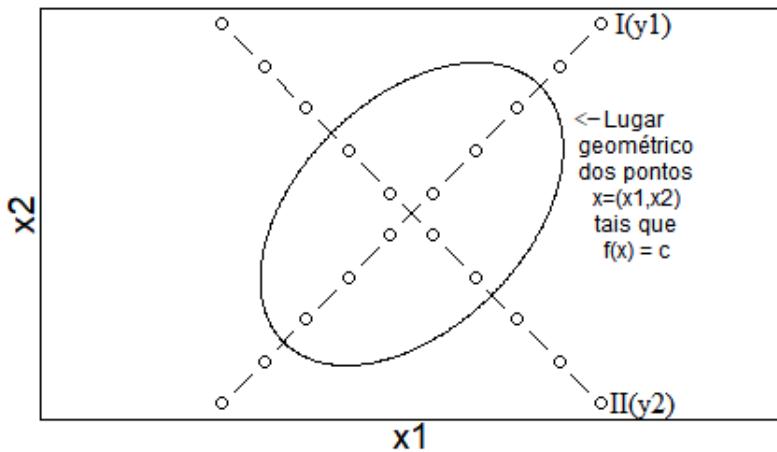


Figura 13.1: Contorno de densidade constante de uma distribuição normal bivariada.

À medida em que a correlação entre X_1 e X_2 aumenta, o comprimento do eixo maior da elipse também aumenta e o do eixo menor diminui até que a elipse se degenera em um segmento de reta no caso limite em que as variáveis são perfeitamente correlacionadas, *i.e.*, em que o correspondente coeficiente de correlação linear é igual a 1. Na Figura 13.1, o eixo I corresponde ao eixo maior e o eixo II, ao menor. O eixo I pode ser expresso por intermédio de uma combinação linear de X_1 e X_2 , ou seja

$$Y_1 = \beta_1 X_1 + \beta_2 X_2 \quad (13.1)$$

No caso extremo, em que X_1 e X_2 são perfeitamente correlacionadas, toda a variabilidade pode ser explicada por meio de Y_1 . Quando a correlação entre X_1 e X_2 não é perfeita, Y_1 explica apenas uma parcela de sua variabilidade. A outra parcela é explicada por meio de um segundo eixo, a saber

$$Y_2 = \gamma_1 X_1 + \gamma_2 X_2. \quad (13.2)$$

Na Figura 13.2 apresentamos um gráfico de dispersão correspondente a n observações (X_{1i}, X_{2i}) do par (X_1, X_2) .

A variabilidade no sistema de eixos correspondente a (X_1, X_2) pode ser expressa como

$$\sum_{i=1}^n (X_{1i} - \bar{X}_1)^2 + \sum_{i=1}^n (X_{2i} - \bar{X}_2)^2$$

em que \bar{X}_1 e \bar{X}_2 são, respectivamente, as médias dos n valores de X_{1i} e X_{2i} . No sistema de eixos correspondente a (Y_1, Y_2) , a variabilidade é expressa como

$$\sum_{i=1}^n (Y_{1i} - \bar{Y}_1)^2 + \sum_{i=1}^n (Y_{2i} - \bar{Y}_2)^2$$

em que \bar{Y}_1 e \bar{Y}_2 têm interpretações similares a \bar{X}_1 e \bar{X}_2 . Se a correlação entre X_1 e X_2 for “grande”, é possível obter valores de $\beta_1, \beta_2, \gamma_1, \gamma_2$ de tal forma que Y_1 e

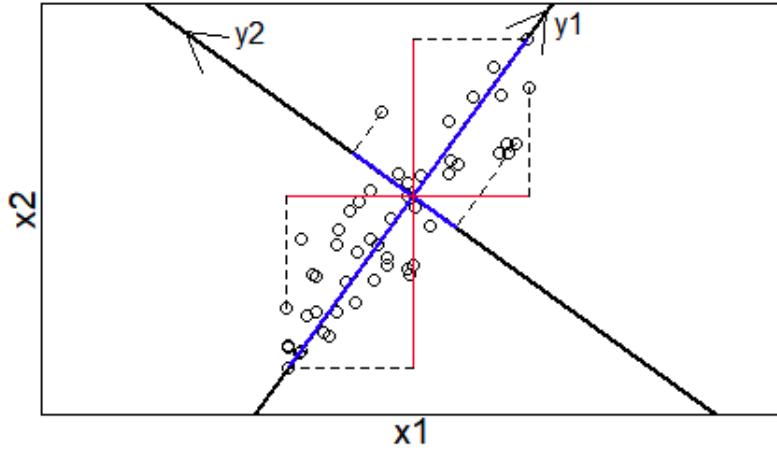


Figura 13.2: Gráfico de dispersão de n observações do par (X_1, X_2) .

Y_2 em (13.1) e (13.2) sejam tais que

$$\sum_{i=1}^n (Y_{1i} - \bar{Y}_1)^2 \gg \sum_{i=1}^n (Y_{2i} - \bar{Y}_2)^2.$$

Nesse caso, podemos utilizar apenas Y_1 como variável para explicar a variabilidade de X_1 e X_2 .

Para descrever o processo de obtenção das componentes principais, consideremos o caso geral em que $\mathbf{x}_1, \dots, \mathbf{x}_n$ corresponde a uma amostra aleatória de uma variável $\mathbf{X} = (X_1, \dots, X_p)^\top$ com p componentes e para a qual o vetor de médias é $\boldsymbol{\mu}$ e a matriz de covariâncias é $\boldsymbol{\Sigma}$. Sejam $\bar{\mathbf{x}} = n^{-1} \sum_{i=1}^n \mathbf{x}_i$ e $\mathbf{S} = (n-1)^{-1} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})(\mathbf{x}_i - \bar{\mathbf{x}})^\top$, respectivamente o vetor de médias amostrais e a matriz de covariâncias amostral. A técnica consiste em procurar sequencialmente p combinações lineares (denominadas componentes principais) de X_1, \dots, X_p tais que à primeira corresponda a maior parcela de sua variabilidade, à segunda, a segunda maior parcela e assim por diante e que, além disso, sejam independentes entre si. A primeira componente principal é a combinação linear

$$Y_1 = \boldsymbol{\beta}_1^\top \mathbf{X} = \beta_{11} X_1 + \dots + \beta_{1p} X_p$$

com $\boldsymbol{\beta}_1 = (\beta_{11}, \dots, \beta_{1p})^\top$, para a qual a variância $\text{Var}(Y_1) = \boldsymbol{\beta}_1^\top \boldsymbol{\Sigma} \boldsymbol{\beta}_1$ é máxima. Uma estimativa da primeira componente principal calculada com base na amostra é a combinação linear $\hat{Y}_1 = \hat{\boldsymbol{\beta}}_1^\top \mathbf{x}$ para a qual $\widehat{\text{Var}}(\hat{Y}_1) = \hat{\boldsymbol{\beta}}_1^\top \hat{\mathbf{S}} \hat{\boldsymbol{\beta}}_1$ é máxima. Este problema não tem solução sem uma restrição adicional, pois se tomarmos $\hat{\boldsymbol{\beta}}_1^* = c \hat{\boldsymbol{\beta}}_1$ com c denotando uma constante arbitrária, podemos tornar a variância $\widehat{\text{Var}}(\hat{Y}_1) = \text{Var}(\hat{\boldsymbol{\beta}}_1^* \mathbf{x})$ arbitrariamente grande, tomando c arbitrariamente grande. A restrição adicional mais usada consiste em padronizar $\boldsymbol{\beta}_1$ por meio de $\boldsymbol{\beta}_1^\top \boldsymbol{\beta}_1 = 1$. Consequentemente, o problema de determinação da primeira componente principal se resume a obter $\hat{\boldsymbol{\beta}}_1$ tal que

$$\text{Maximize } \boldsymbol{\beta}_1^\top \boldsymbol{\Sigma} \boldsymbol{\beta}_1 \text{ sujeito a } \boldsymbol{\beta}_1^\top \boldsymbol{\beta}_1 = 1.$$

A solução desse problema pode ser encontrada por meio da aplicação de **multiplicadores de Lagrange**. Dada a primeira componente principal, obtém-se a segunda, $\hat{\beta}_2$, por meio da maximização de $\beta_2^\top \Sigma \beta_2$ sujeito a $\beta_2^\top \beta_2 = 1$ e $\beta_1^\top \beta_2 = 0$ (para garantir a ortogonalidade). Note que a ortogonalidade das componentes principais implica que a soma de suas variâncias seja igual à variância total do sistema de variáveis. Esse procedimento é repetido até a determinação da p -ésima componente principal. Para detalhes, ver a Nota de Capítulo 1.

As componentes principais estimadas são os autovetores $\hat{\beta}_1, \dots, \hat{\beta}_p$ da matriz \mathbf{S} e suas variâncias são os autovalores $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \geq \hat{\lambda}_p$ correspondentes. Como a variância total do sistema é $\text{tr}(\mathbf{S}) = \sum_{i=1}^p \hat{\lambda}_i$, a contribuição da i -ésima componente principal é $\hat{\lambda}_i / \text{tr}(\mathbf{S})$. Lembrando que $\mathbf{S} = \sum_{i=1}^p \hat{\lambda}_i \hat{\beta}_i \hat{\beta}_i^\top$ podemos verificar quão bem ela pode ser aproximada com um menor número de componentes principais. Detalhes podem ser obtidos na Nota de Capítulo 2.

Na prática, a determinação do número de componentes principais a reter como novo conjunto de variáveis para futuras análises pode ser realizada por meio do **gráfico do cotovelo** (*elbow plot*), também conhecido como **gráfico da escarpa sedimentar** (*scree plot*), que consiste num gráfico cartesiano com os autovalores no eixo vertical e os índices correspondentes às suas magnitudes (em ordem decrescente) no eixo das abscissas. Um exemplo está apresentado na Figura 13.3.

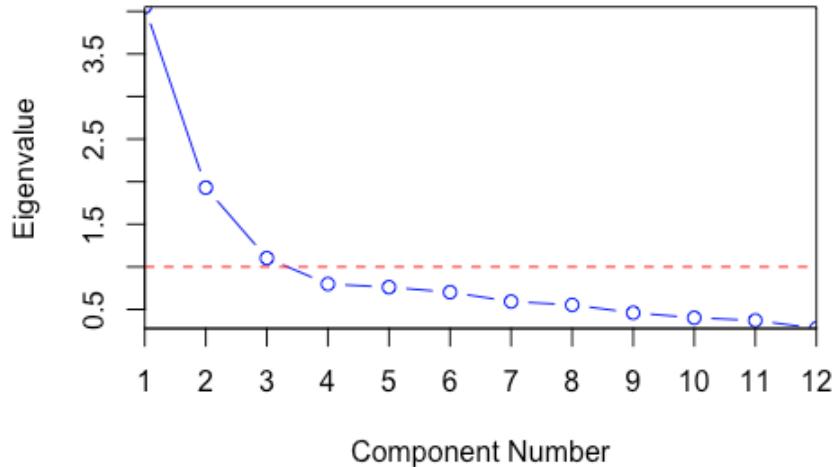


Figura 13.3: Exemplo de gráfico da escarpa sedimentar (ou do cotovelo).

A ideia é acrescentar componentes principais até que sua contribuição para a explicação da variância do sistema não apresente contribuições “relevantes”. Com base na Figura 13.3, apenas as duas primeiras componentes principais poderiam ser suficientes, pois a contribuição das seguintes é apenas marginal.

Suponhamos que r componentes principais, Y_1, \dots, Y_r explicam uma parcela “substancial” da variabilidade do sistema multivariado. Então para a k -ésima unidade amostral, podemos substituir os valores das variáveis originais $\mathbf{x}_k = (x_{1k}, \dots, x_{pk})^\top$ pelos correspondentes **escores** associados às componentes principais, nomeadamente, $\hat{Y}_{1k}, \dots, \hat{Y}_{rk}$ com $\hat{Y}_{ik} = \hat{\beta}_i^\top \mathbf{x}_k$.

Infelizmente, nem a matriz de covariâncias nem os correspondentes autovalores são invariantes relativamente a mudanças de escala. Em outras palavras, mudanças nas unidades de medida das características X_1, \dots, X_p podem acarretar mudanças

na forma e na posição dos elipsoides correspondentes a pontos em que a função densidade é constante. É difícil interpretar combinações lineares de características com unidades de medida diferentes e uma possível solução é padronizá-las por meio de transformações do tipo $Z_{ij} = (X_{ij} - \bar{X}_i)/S_i$ em que \bar{X}_i e S_i representam, respectivamente a média e o desvio padrão de X_{ij} antes da obtenção das componentes principais. A utilização da matriz de correlações \mathbf{R} obtida por meio dessa transformação pode ser utilizada na determinação das componentes principais; no entanto, os resultados são, em geral, diferentes e não é possível passar de uma solução a outra por meio de uma mudança de escala dos coeficientes. Se as características de interesse foram medidas com as mesmas unidades, é preferível extrair as componentes principais utilizando a matriz de covariâncias \mathbf{S} .

Lembrando que a i -ésima componente principal é $Y_i = \beta_{i1}X_1 + \dots + \beta_{ip}X_p$ do sistema multivariado, se as variáveis X_1, \dots, X_p tiverem variâncias similares ou forem variáveis padronizadas, os coeficientes β_{ij} indicam a importância e a direção da j -ésima variável relativamente à i -ésima componente principal. Nos casos em que as variâncias das variáveis originais são diferentes, convém avaliar sua importância relativa na definição das componentes principais por meio dos correspondentes coeficientes de correlação. O vetor de covariâncias entre as variáveis originais e a i -ésima componente principal é

$$\text{Cov}(\mathbf{I}_p \mathbf{X}, \boldsymbol{\beta}_i \mathbf{X}) = \mathbf{I}_p \boldsymbol{\Sigma} \boldsymbol{\beta}_i = \boldsymbol{\Sigma} \boldsymbol{\beta}_i = \lambda_i \boldsymbol{\beta}_i$$

pois $(\boldsymbol{\Sigma} - \lambda_i \mathbf{I}_p) \boldsymbol{\beta}_i = \mathbf{0}$ (ver Nota de Capítulo 1). Uma estimativa desse vetor de covariâncias é $\hat{\lambda}_i \boldsymbol{\beta}_i$. Consequentemente, uma estimativa do coeficiente de correlação entre a j -ésima variável original e a i -ésima componente principal é

$$\widehat{\text{Corr}}(X_j, \boldsymbol{\beta}_{ij}) = \frac{\hat{\lambda}_i \hat{\beta}_{ij}}{\sqrt{\hat{\lambda}_i s_j}} = \frac{\sqrt{\hat{\lambda}_i} \hat{\beta}_{ij}}{s_j}$$

em que s_j é o desvio padrão de X_j .

As componentes principais podem ser encaradas como um conjunto de variáveis latentes (ou fatores) não correlacionados que servem para descrever o sistema multivariado original sem as dificuldades relacionadas com sua estrutura de correlação. Os coeficientes associados a cada componente principal servem para descrevê-las em termos das variáveis originais. A comparação entre unidades realizada por meio da componente principal Y_i é independente da comparação baseada na componente Y_j . No entanto, essa comparação pode ser ilusória se essas componentes principais não tiverem uma interpretação simples. Como, em geral, isso não é a regra, costuma-se utilizar essa técnica como um passo intermediário para a obtenção de um dos possíveis conjuntos de combinações lineares ortogonais das variáveis originais passíveis de interpretação como variáveis latentes. Esses conjuntos estão relacionados entre si por meio de rotações rígidas (transformações ortogonais) e são equivalentes no sentido de aproximar as correlações entre as variáveis originais. Apesar de essas rotações rígidas implicarem uma perda da característica de ordenação das componentes principais em termos de porcentagem de explicação da variabilidade do sistema multivariado, muitas vezes produzem ganhos interpretativos. Os métodos mais utilizados para essas rotações são discutidos na Seção 10.3.

Há muitas opções computacionais para a análise de componentes principais no sistema R, dentre as quais destacamos `prcomp` (`stats`), `princomp` (`stats`) e `pca` (`FactoMineR`). Como há vários métodos tanto para a extração quanto para a rotação das componentes principais, nem sempre os resultados coincidem. A

análise deve ser realizada por tentativa e erro tendo como objetivo um sistema com interpretação adequada.

Exemplo 13.1: Num estudo em que se pretendia avaliar o efeito de variáveis climáticas na ocorrência de suicídios por enforcamento na cidade de São Paulo foram observadas X_1 = temperatura máxima, X_2 = temperatura mínima, X_3 = temperatura média, X_4 = precipitação e X_5 = nebulosidade diárias para o período de 01/07/2006 e 31/07/2006. Os dados estão disponíveis em no arquivo `suicidios`,

Para reduzir o número de variáveis a serem utilizadas como variáveis explicativas numa regressão logística tenso como variável resposta a ocorrência de suicídios por enforcamento nesse período consideramos uma análise de componentes principais. Com essa finalidade, consideramos os seguintes comandos do pacote FactoMineR:

```
pca<-principal(suicid, nfactor=5, rotate="none")
VSS.scree(suicid, main="")
```

Os coeficientes das cinco componentes bem como as porcentagem da variância total do sistema explicada por cada uma delas (além da porcentagem acumulada correspondente) estão indicados na Tabela 13.1 e o gráfico da escarpa sedimentar correspondente restá epresentado na Figura 13.4.

Tabela 13.1: Coeficientes das componentes principais e porcentagens da variância explicada: Exemplo 12.1

Variável	Componentes principais				
	CP1	CP2	CP3	CP4	CP5
Temperatura máxima	0,93	-0,25	0,05	0,26	0,06
Temperatura mínima	0,91	0,29	-0,18	-0,24	0,06
Temperatura média	0,99	-0,02	-0,03	0,00	-0,11
Precipitação	0,12	0,75	0,66	0,02	0,00
Nebulosidade	-0,12	0,85	-0,50	0,14	-0,01
% Variância	54	28	14	3	0
% Acumulada	54	82	97	100	100

Uma análise do gráfico da escarpa sedimentar correspondente representado na Figura 13.4, conjuntamente com um exame da variância acumulada na Tabela 13.1 sugere que apenas duas componentes principais podem ser empregadas como resumo, retendo 82% da variância total. A primeira componente principal pode ser interpretada como “percepção térmica” e segunda, “percepção de acinzentamento”. Valores dessas novas variáveis para cada unidade amostral são calculadas como $CP_1 = 0,93 * tempmax + 0,91 * tempmin + 0,99 * tempmed$ e $CP_2 = 0,75 * precip + 0,85 * nebul$, com as variáveis originais devidamente padronizadas.

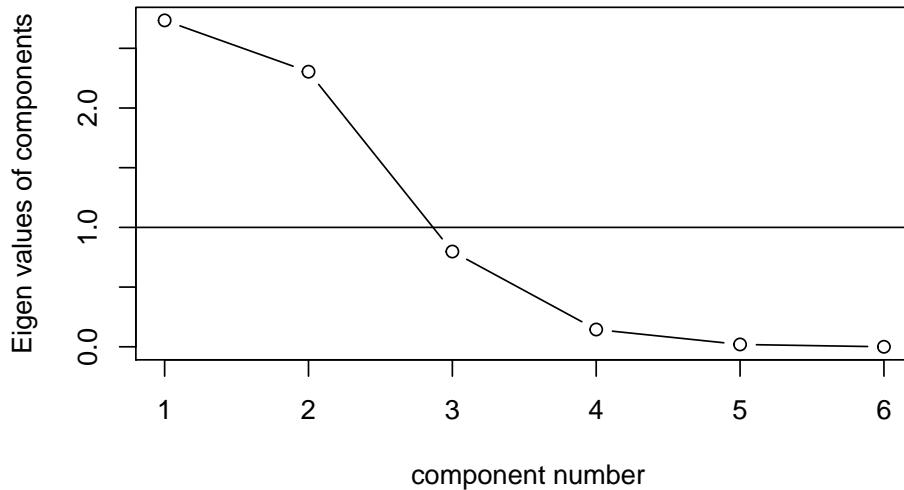


Figura 13.4: Gráfico do cotovelo para os dados do Exemplo 12.1.

O gráfico *biplot* obtido por meio dos comandos

```
> pca1<-principal(suicid, nfactor=2, rotate="none")
> biplot(pca1, main="")
```

disposto na Figura 13.5 é conveniente para representar a relação entre as duas componentes principais e as variáveis originais.

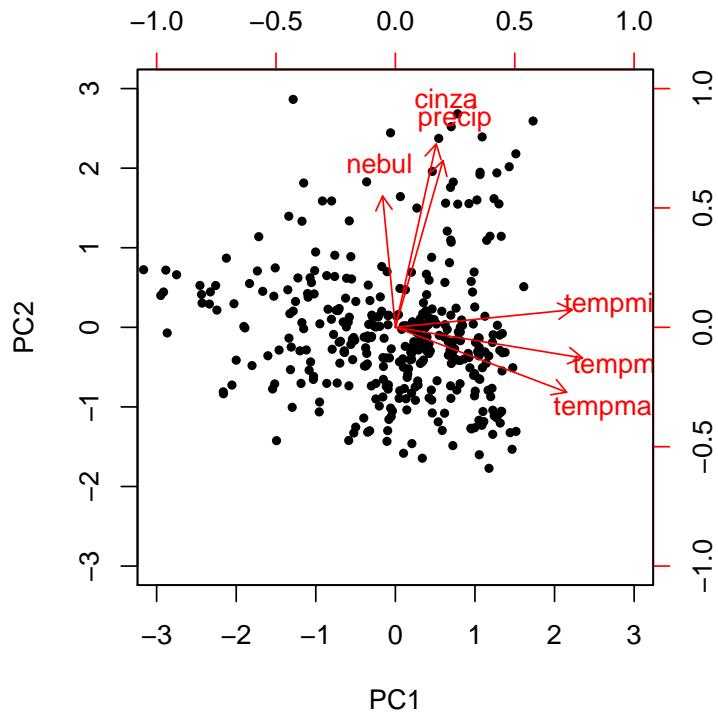


Figura 13.5: Gráfico *biplot* para os dados do Exemplo 12.1.

13.3 Análise Fatorial

Primeiramente observemos que para explicar as relações entre p variáveis são necessárias p componentes principais; por esse motivo, o modelo adotado não é o ideal. O fato de as componentes principais não serem correlacionadas e ordenadas com variâncias decrescentes e o fato de que a técnica corresponde a uma fatoração da matriz de covariâncias da variáveis originais fazem com que a aproximação obtida quando consideramos apenas as primeiras componentes principais seja razoável. No entanto, essa técnica pode introduzir um erro sistemático na reprodução das correlações originais, pois podem existir uma ou mais dessas variáveis que sejam muito correlacionadas com as componentes principais desprezadas do que com aquelas retidas na análise. Outra observação importante, é que essa técnica utiliza toda a informação sobre cada uma das variáveis originais, embora seja razoável imaginar que uma parcela de sua variabilidade seja específica, nada tendo a ver com as demais variáveis do conjunto sob investigação. Além disso, pode-se suspeitar que os “verdadeiros fatores” responsáveis pela geração das observações tenham todos a mesma importância ou que sejam correlacionados entre si.

Alguns desses problemas podem ser solucionados por meio da técnica de Análise Fatorial. A ideia que a fundamenta está baseada na partição da variância de cada variável do sistema multivariado numa **variância comum** e numa **variância específica**. Além disso, supõe-se que as correlações entre as p variáveis são geradas por um número $r < p$ de variáveis latentes (ou fatores).

A vantagem dessa técnica relativamente àquela de componentes principais está na habilidade de reprodução da estrutura de correlações originais por meio de um pequeno número de fatores sem os erros sistemáticos que podem ocorrer quando simplesmente desprezamos algumas componentes principais.

As desvantagens da Análise Fatorial estão na maior dificuldade de cálculo dos escores fatoriais e na existência de múltiplas soluções. Na realidade a estrutura de correlações das variáveis originais pode ser igualmente reproduzida por qualquer outro conjunto de variáveis latentes de mesma dimensão. A não ser que se imponham restrições adicionais, infinitas soluções equivalentes sempre existirão.

Consideremos um vetor $\mathbf{X} = (X_1, \dots, X_p)^\top$ com média $\boldsymbol{\mu} = (\mu_1, \dots, \mu_p)^\top$ e matriz de covariâncias $\boldsymbol{\Sigma}$ com elementos σ_{ij} , $i, j = 1, \dots, p$. O modelo utilizado para Análise Fatorial de dados provenientes da observação das p variáveis agrupadas X_1, \dots, X_p é

$$X_i - \mu_i = \lambda_{i1}F_1 + \dots + \lambda_{im}F_m + e_i = \sum_{j=1}^m \lambda_{ij}F_j + e_i, \quad i = 1, \dots, p \quad (13.3)$$

em que F_j é o j -ésimo **fator comum** a todas as variáveis, λ_{ij} é o parâmetro (chamado de **carga fatorial**) que indica a importância desse fator na composição da i -ésima variável e e_j é um **fator específico** para essa variável. Em notação matricial, o modelo pode ser escrito como

$$\mathbf{X} - \boldsymbol{\mu} = \boldsymbol{\Lambda}\mathbf{f} + \mathbf{e} \quad (13.4)$$

em que $\boldsymbol{\Lambda}$ é a matriz com dimensão $p \times m$ de cargas fatoriais, $\mathbf{f} = (F_1, \dots, F_m)^\top$ é o vetor cujos elementos são os fatores comuns e $\mathbf{e} = (e_1, \dots, e_p)^\top$ é um vetor cujos elementos são os fatores específicos. Adicionalmente, supomos que $E(\mathbf{f}) = \mathbf{0}$, $Cov(\mathbf{f}) = \mathbf{I}_m$, $E(\mathbf{e}) = \mathbf{0}$ e $Cov(\mathbf{e}) = \boldsymbol{\psi} = \text{diag}(\psi_1, \dots, \psi_p)$ e que $Cov(\mathbf{f}, \mathbf{e}) = \mathbf{0}$. Os elementos de $\boldsymbol{\psi}$ são as **variâncias específicas**

Para avaliar a relação entre a estrutura de covariâncias de \mathbf{X} e os fatores,

observemos que

$$\begin{aligned}
 \text{Cov}(X_i, X_k) &= \text{Cov}\left(\sum_{j=1}^m \lambda_{ij} F_j, \sum_{\ell=1}^m \lambda_{k\ell} F_\ell\right) \\
 &= \sum_{j=1}^m \sum_{\ell=1}^m \lambda_{ij} \lambda_{k\ell} \text{E}(F_j F_\ell) + \text{E}(e_i e_j) \\
 &= \sum_{j=1}^m \sum_{\ell=1}^m \lambda_{ij} \lambda_{k\ell} + \text{E}(e_i e_j)
 \end{aligned} \tag{13.5}$$

Consequentemente, $\text{Cov}(X_i, X_k) = \sigma_{ik} = \sum_{j=1}^m \lambda_{ij} \lambda_{kj}$ se $i \neq k$ e $\text{Cov}(X_i, X_i) = \sigma_{ii} = \sum_{j=1}^m \lambda_{ij}^2$. O termo $\sum_{j=1}^m \lambda_{ij}^2$ é conhecido por **comunalidade** da i -ésima variável. Em notação matricial, podemos escrever

$$\Sigma = \Lambda \Lambda^\top + \psi$$

e o objetivo é estimar os elementos de Λ e ψ .

Em Análise de Componentes Principais, consideramos o modelo linear $\mathbf{Y} = \mathbf{BX}$ em que \mathbf{Y} é o vetor cujos elementos são as componentes principais e $\mathbf{B} = (\beta_1^\top, \dots, \beta_p^\top)^\top$ é a matriz cuja i -ésima linha contém os coeficientes da i -ésima componente principal. A matriz de covariâncias de \mathbf{X} é fatorada como $\Sigma = \mathbf{LL}^\top$. Em Análise Fatorial, consideramos o modelo linear $\mathbf{X} = \mathbf{Af} + \mathbf{e}$ e a matriz de covariâncias de \mathbf{X} é fatorada como $\Sigma = \Lambda \Lambda^\top + \psi$.

Uma diferença entre os dois enfoques é que enquanto a fatoração de Σ é única em Análise de Componentes Principais, ela não o é em Análise Fatorial, pois se \mathbf{T} for uma matriz ortogonal (*i.e.*, $\mathbf{TT}^\top = \mathbf{I}_m$), obteremos

$$\Sigma = \Lambda \Lambda^\top + \psi = \Lambda \mathbf{T} \mathbf{T}^\top \Lambda^\top + \psi = \Lambda \mathbf{T} (\Lambda \mathbf{T})^\top + \psi$$

e embora as cargas fatoriais $\Lambda \mathbf{T}$ sejam diferentes das cargas fatoriais Λ , a habilidade de reproduzir a matriz de covariâncias Σ não se altera. Escolhendo matrizes ortogonais diferentes, podemos determinar cargas fatoriais diferentes. A escolha de uma transformação conveniente será discutida posteriormente.

Uma análise factorial consiste dos seguintes passos

- Estimação dos parâmetros do modelo (λ_{ij} e ψ_i) a partir de um conjunto de observações das variáveis X_1, \dots, X_p .
- Interpretação dos fatores determinados a partir das cargas fatoriais obtidas em a). Com esse objetivo considera-se a **rotação** dos fatores por meio de transformações ortogonais.
- Estimação dos valores dos fatores comuns, chamados **escores fatoriais** para cada unidade amostral a partir dos valores das cargas fatoriais e das variáveis observadas.

Existem duas classes de métodos para estimação dos parâmetros do modelo factorial. Na primeira classe consideramos o **método de máxima verossimilhança** e na segunda, métodos heurísticos como o **método do fator principal** ou o **método do centroide**.

Para o método de máxima verossimilhança, supomos adicionalmente que as variáveis X_1, \dots, X_p seguem uma distribuição normal multivariada e que o número

de fatores m é conhecido. Os estimadores são obtidos por meio da solução do sistema de equações

$$\begin{aligned}\mathbf{S}\psi^{-1}\Lambda &= \Lambda(\mathbf{I}_m + \Lambda^\top\psi^{-1}\Lambda) \\ \text{diag}(\mathbf{S}) &= \text{diag}(\Lambda\Lambda^\top + \psi)\end{aligned}\quad (13.6)$$

que deve ser resolvido por meio de métodos iterativos. A função de verossimilhança está explicitada na Nota de Capítulo 3. Mais detalhes podem ser encontrados em Morrison (1972).

Uma das vantagens desse método é que as mudanças de escala das variáveis originais alteram os estimadores apenas por uma mudança de escala. Se uma das variáveis X_1, \dots, X_p for multiplicada por uma constante, os estimadores das cargas fatoriais correspondentes ficam multiplicados pela mesma constante e o estimador da variância específica associada fica multiplicado pelo quadrado da constante. Dessa forma, podemos fazer os cálculos com as variáveis padronizadas (substituindo a matriz de covariâncias amostral \mathbf{S} pela correspondente matriz de correlações amostrais \mathbf{R} e posteriormente escrever os resultados em termos das unidades de medida originais).

O método do fator principal está intimamente relacionado com a técnica utilizada na análise de componentes principais. Segundo esse método, os fatores são escolhidos obedecendo à ordem decrescente de sua contribuição à communalidade total do sistema multivariado. Nesse contexto, o processo tem início com a determinação de um fator F_1 cuja contribuição à communalidade total é a maior possível; em seguida, um segundo fator não correlacionado com F_1 e tal que maximize a communalidade residual é obtido. O processo continua até que a communalidade total tenha sido exaurida.

Na prática, as communalidades e as variâncias específicas devem ser estimadas com base nos dados amostrais. Embora existam vários métodos idealizados para essa finalidade, nenhum se mostra superior aos demais. Dentre os estimadores mais comuns para a communalidade de uma variável X_i , destacamos:

- i) o quadrado do **coeficiente de correlação múltipla** entre a variável X_i e as demais;
- ii) o maior valor absoluto dos elementos de i -ésima linha da matriz de correlações amostrais;
- iii) estimadores obtidos de análises preliminares por meio de processos iterativos.

Outro problema prático é a determinação do número de fatores a incluir na análise. Os critérios mais utilizados para esse fim são:

- i) determinação do número de fatores por meio de algum conhecimento *a priori* sobre a estrutura dos dados;
- ii) número de componentes principais correspondentes a autovalores da matriz \mathbf{R} maiores que 1;
- iii) explicação de certa proporção (escolhida arbitrariamente) da communalidade ou da variância total.

Um algoritmo comumente utilizado para a obtenção das cargas fatoriais e das variâncias específicas é

- i) Obter as p componentes principais com base na matriz de correlações amostrais \mathbf{R} .
- ii) Escolher m fatores segundo um dos critérios mencionados.

- iii) Substituir os elementos da diagonal principal de \mathbf{R} por estimadores das comunidades correspondentes por meio de um dos métodos descritos acima, obtendo a chamada **matriz de correlações reduzida**, \mathbf{R}^* .
- iv) Extrair m fatores da matriz \mathbf{R}^* , obtendo novos estimadores das comunidades que vão substituir aqueles obtidos anteriormente na diagonal principal.
- v) Repetir o processo dos itens ii) - iv) até que a diferença entre dois conjuntos sucessivos de estimadores das comunidades seja desprezável.

O método do centroide foi desenvolvido por Thurstone (1947) para simplificar os cálculos mas não é muito utilizado em virtude das recentes facilidades computacionais; os resultados obtidos por intermédio desse método não diferem muito daqueles obtidos pelo método do fator principal.

Como a interpretação dos fatores numa análise factorial é uma característica importante em aplicações práticas, pode-se utilizar a técnica de **rotação** para obter resultados mais palatáveis. Consideremos um exemplo em que cinco variáveis A, B, C, D e E são representadas num espaço fatorial bidimensional conforme a representação da Figura 13.6.

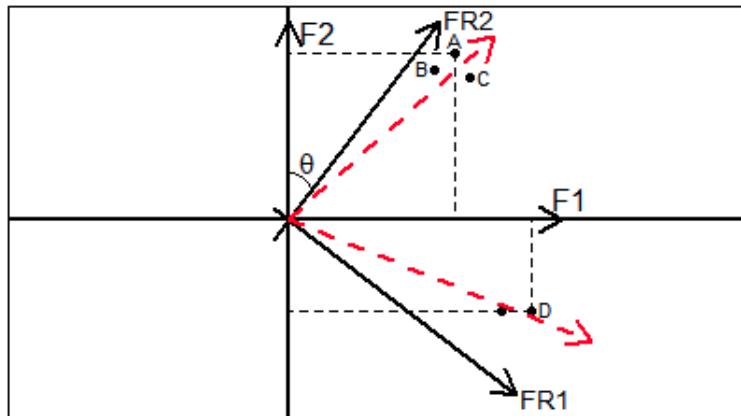


Figura 13.6: Representação de cinco variáveis num espaço vetorial bidimensional.

Como ilustrado na Tabela 13.2, as cargas fatoriais relativas ao fator F_1 são altas e positivas para todas as variáveis. Por outro lado, como apenas as variáveis A, B e C têm cargas positivas no fator F_2 ; as cargas das variáveis D e E são negativas nesse fator.

Tabela 13.2: Cargas fatoriais para as variáveis A, B, C, D e E

Variável	Fatores iniciais		Fatores rotacionados	
	F_1	F_2	FR_1	FR_2
A	0,75	0,63	0,14	0,95
B	0,69	0,57	0,14	0,90
C	0,80	0,49	0,18	0,92
D	0,85	-0,42	0,94	0,09
E	0,76	-0,42	0,92	0,07

Dois aglomerados de variáveis podem ser identificados na Figura 13.6: um formado pelas variáveis A, B e C e o outro pelas variáveis D e E . Apesar disso, esses aglomerados não são evidentes nas cargas fatoriais da Tabela 13.2. Uma rotação dos fatores (com os eixos rotulados FR_1 e FR_2) como aquela indicada na figura juntamente com as novas cargas fatoriais apresentadas na Tabela 13.2 ressaltam a separação entre os dois conjuntos de variáveis. Na solução inicial, cada variável é explicada por dois fatores enquanto que na solução obtida com a rotação dos fatores, apenas um deles é suficiente para explicar a correspondente estrutura de covariância.

Em princípio, também podemos considerar rotações oblíquas, que são bem mais flexíveis, pois os fatores não precisam ser necessariamente ortogonais. Essa característica pode até ser considerada mais realista, pois a ortogonalidade não é determinante da relação entre os fatores. Os eixos realçados em vermelho na Figura 13.6 correspondem a uma dessas rotações oblíquas.

O objetivo de qualquer rotação é obter fatores interpretáveis e com a estrutura mais simples possível. Nesse sentido, Thurstone (1947) sugere condições para se obter uma estrutura mais simples, nomeadamente

- i) Cada linha da matriz de cargas fatoriais Λ deve conter pelo menos um valor nulo.
- ii) Cada coluna da matriz de cargas fatoriais deveria ter pelo menos tantos valores nulos quantas forem as colunas.
- iii) Para cada par de colunas deve haver algumas variáveis com cargas fatoriais pequenas numa delas e altas na outra.
- iv) Para cada par de colunas uma grande porcentagem das variáveis deve ter cargas fatoriais não nulas em ambas.
- v) Para cada par de colunas deve haver somente um pequeno número de variáveis com cargas fatoriais altas em ambas.

Como consequência dessas sugestões,

- i) Muitas variáveis (representadas como vetores no espaço dos fatores) devem ficar próximas dos eixos.
- ii) Muitas variáveis devem ficar próximas da origem quando o número de fatores for grande.
- iii) Somente um pequeno número de variáveis ficam longe dos eixos.

A principal crítica às sugestões de Thurstone é que na prática poucas são as situações que admitem uma simplificação tão grande. O que se procura fazer é simplificar as linhas e colunas da matriz de cargas fatoriais e os métodos mais comumente empregados com essa finalidade são:

- **Método Varimax** em que se procura simplificar a complexidade fatorial, tentando-se obter fatores com poucos valores grandes e muitos valores nulos ou pequenos na respectiva coluna da matriz de cargas fatoriais. Após uma rotação Varimax, cada variável original tende a estar associada com poucos (preferencialmente, um) fatores e cada fator tende a se associar com poucas variáveis. Esse é o método mais utilizado na prática.
- **Método Quartimax** em que se procura maximizar o número de fatores necessários para explicar cada variável. Em geral, esse método produz um fator associado em que muitas variáveis têm cargas altas ou médias, o que nem sempre é conveniente para a interpretação.
- **Método Equimax**, uma mistura dos métodos Varimax e Quartimax.
- **Método Promax**, utilizado para rotações oblíquas.

Um dos objetivos tanto de Análise de Componentes Principais é substituir as p variáveis originais X_1, \dots, X_p por um número menor, digamos, m em análises subsequentes. No caso de componentes principais, podem-se utilizar as estimativas $\hat{Y}_{ik} = \hat{\beta}_i \mathbf{x}_k$, $i = 1, \dots, m$ para substituir os valores \mathbf{x}_k observados para a k -ésima unidade amostral. Esse processo é mais complicado quando lidamos com a obtenção dos valores dos fatores F_1, \dots, F_m (denominados **escores fatoriais**) em Análise Fatorial, que não podem ser estimados no sentido estatístico usual, pois os fatores não são observáveis.

Com esse objetivo, o **método de Bartlett** (1937) consiste em considerar (13.4) como um modelo de regressão heterocedástico em que se supõe que as matrizes de cargas fatoriais, Λ e de variâncias específicas ψ , são conhecidas e se considera o termo \mathbf{e} como um vetor de erros. Minimizando

$$Q(\mathbf{f}) = \mathbf{e}^\top \psi^{-1} \mathbf{e} = (\mathbf{x} - \boldsymbol{\mu} - \Lambda \mathbf{f})^\top \psi^{-1} (\mathbf{x} - \boldsymbol{\mu} - \Lambda \mathbf{f})$$

obtemos

$$\hat{\mathbf{f}} = [\Lambda^\top \psi^{-1} \Lambda]^{-1} \Lambda^\top \psi^{-1} (\mathbf{x} - \boldsymbol{\mu})$$

e substituindo Λ , ψ e $\boldsymbol{\mu}$, respectivamente, por estimativas $\hat{\Lambda}$, $\hat{\psi}$ e $\bar{\mathbf{x}}$, podemos construir os escores fatoriais para a k -ésima unidade amostral como

$$\hat{\mathbf{f}}_k = [\hat{\Lambda}^\top \hat{\psi}^{-1} \hat{\Lambda}]^{-1} \hat{\Lambda}^\top \hat{\psi}^{-1} (\mathbf{x}_k - \bar{\mathbf{x}})$$

Alternativamente, no **método de regressão**, supõe-se que os fatores comuns, \mathbf{f} e específicos \mathbf{e} são independentes e têm distribuições normais multivariadas com dimensões m e p , respectivamente, de forma que o par $(\mathbf{X} - \boldsymbol{\mu}, \mathbf{f})$ também tem uma distribuição normal multivariada de dimensão $p + m$ com matriz de covariâncias

$$\begin{bmatrix} \Lambda \Lambda^\top + \psi & \Lambda \\ \Lambda^\top & \mathbf{I}_m \end{bmatrix}.$$

Utilizando propriedades da distribuição normal multivariada, segue que a distribuição condicional de \mathbf{f} dado $\mathbf{X} - \boldsymbol{\mu}$ também é normal multivariada com vetor de médias

$$E(\mathbf{f} | \mathbf{X} - \boldsymbol{\mu}) = \Lambda^\top [\Lambda \Lambda^\top + \psi]^{-1} (\mathbf{X} - \boldsymbol{\mu})$$

e matriz de covariâncias

$$\text{Cov}(\mathbf{f} | \mathbf{X} - \boldsymbol{\mu}) = \mathbf{I}_m - \Lambda^\top [\Lambda \Lambda^\top + \psi]^{-1} \Lambda.$$

O termo $\boldsymbol{\Lambda}^\top [\boldsymbol{\Lambda}\boldsymbol{\Lambda}^\top + \boldsymbol{\psi}]^{-1}$ corresponde aos coeficientes de uma regressão multivariada tendo os fatores como variáveis respostas e $\mathbf{X} - \boldsymbol{\mu}$ como variáveis explicativas. Utilizando as estimativas $\widehat{\boldsymbol{\Lambda}}$, $\widehat{\boldsymbol{\psi}}$, podemos calcular os escores fatoriais para a k -ésima unidade amostral (com valores das variáveis originais \mathbf{x}_k) por meio de

$$\widehat{\mathbf{f}}_k = \widehat{\boldsymbol{\Lambda}}^\top [\widehat{\boldsymbol{\Lambda}}\widehat{\boldsymbol{\Lambda}}^\top + \widehat{\boldsymbol{\psi}}]^{-1}(\mathbf{x}_k - \bar{\mathbf{x}}).$$

Exemplo 13.2: Num estudo planejado para avaliar o nível de poluição atmosférica por meio de medidas de elementos químicos depositados em cascas de árvores, obtiveram-se observações da concentração de Al, Ba, Cu, Fe, Zn, P, Cl, Sr e Ca entre outros elementos em 193 unidades da espécie *Tipuana tipu* na cidade de São Paulo. Esses dados estão disponíveis no arquivo `arvores`. O objetivo aqui é obter um conjunto de fatores que permitam identificar características comuns a essas variáveis. Os resultados provenientes de uma análise de componentes principais concretizada por meio do comando

```
> pca<-principal(elem1, nfactor=8, rotate="none")
> VSS.scree(elem1, main="")
```

estão dispostos na Tabela 13.3.

Tabela 13.3: Coeficientes de componentes principais (CP) para os dados do Exemplo 13.2

	CP1	CP2	CP3	CP4	CP5	CP6	CP7	CP8	CP9
Al	0.90	-0.11	0.09	0.21	-0.16	0.19	-0.08	-0.17	0.17
Ba	0.88	-0.16	0.09	0.10	-0.10	0.27	0.09	0.31	-0.01
Cu	0.82	0.18	-0.05	-0.23	0.31	-0.18	-0.31	0.08	0.01
Fe	0.95	-0.10	0.07	0.10	-0.03	0.10	0.00	-0.18	-0.19
Zn	0.83	0.16	-0.13	-0.22	0.29	-0.21	0.31	-0.05	0.05
P	0.25	0.69	-0.25	0.53	-0.20	-0.28	0.00	0.05	-0.01
Cl	0.17	0.53	0.60	-0.42	-0.39	-0.07	0.01	0.00	0.00
Mg	-0.24	0.22	0.78	0.35	0.40	0.05	0.02	0.00	0.00
Ca	-0.20	0.77	-0.33	-0.12	0.15	0.47	0.00	-0.04	0.00
% Var	0.45	0.17	0.13	0.08	0.07	0.06	0.02	0.02	0.01
% Acum	0.45	0.61	0.75	0.83	0.89	0.95	0.97	0.99	1.00

Uma análise da porcentagem da variância explicada pelas componentes principais juntamente com um exame do gráfico da escarpa sedimentar correspondente, apresentado na Figura 13.7 sugere que três fatores, que explicam 75% da variância total do sistema de variáveis originais poderiam contemplar uma representação adequada.

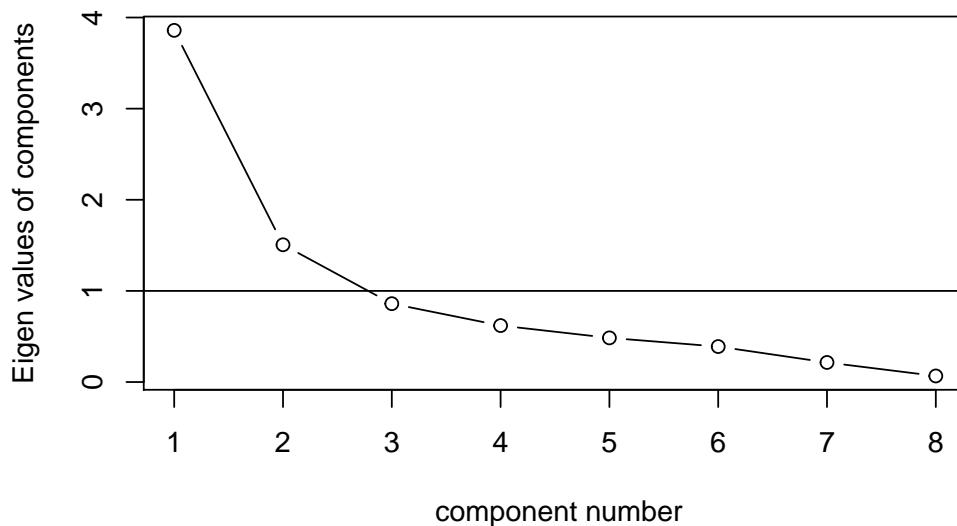


Figura 13.7: Gráfico da escarpa sedimentar para os dados do Exemplo 13.2.

As cargas fatoriais correspondentes três fatores rotacionados obliquamente juntamente com as comunidades e especificidades correspondentes estão dispostos na Tabela 13.4.

Tabela 13.4: Cargas fatoriais, comunidades e especificidades correspondentes a uma análise fatorial para os dados do Exemplo 13.2

	Fator 1	Fator 2	Fator 3	Comunidade	Especificidade
Al	0.91	-0.11	0.03	0.82	0.18
Ba	0.86	-0.13	0.00	0.75	0.25
Cu	0.75	0.27	-0.04	0.66	0.34
Fe	0.97	-0.08	0.01	0.95	0.05
Zn	0.74	0.27	-0.13	0.68	0.32
P	0.20	0.47	0.05	0.25	0.75
Cl	0.22	0.27	0.39	0.22	0.78
Mg	-0.04	0.02	0.73	0.54	0.46
Ca	-0.21	0.67	0.01	0.49	0.51

Os gráficos das Figuras 13.8 e 13.9 também podem ser utilizados para identificar os fatores.

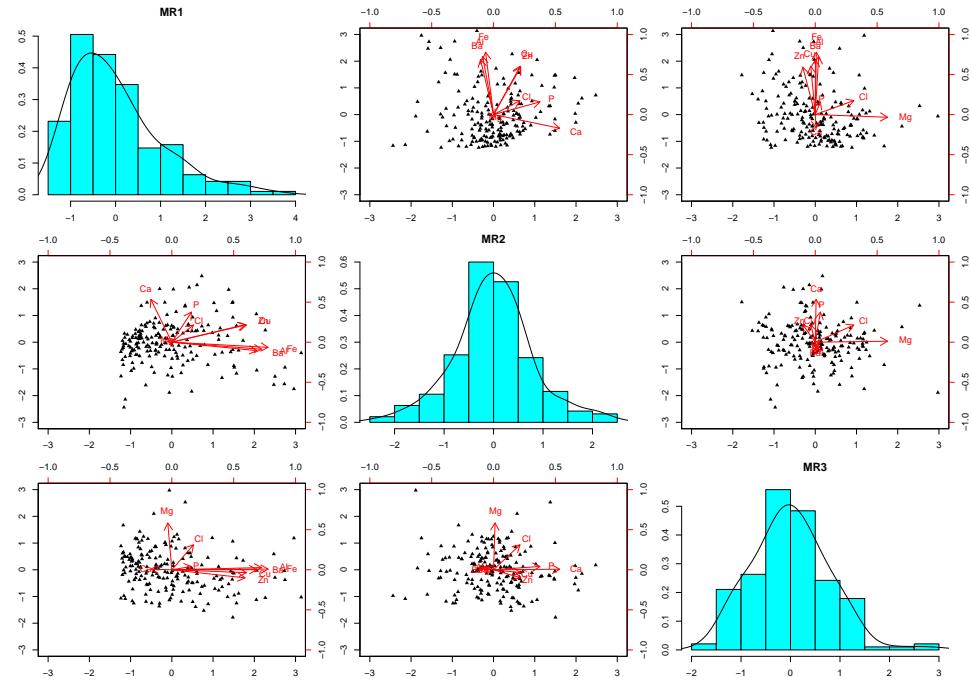


Figura 13.8: Gráfico *biplot* correspondente aos três fatores considerados para os dados do Exemplo 13.2.

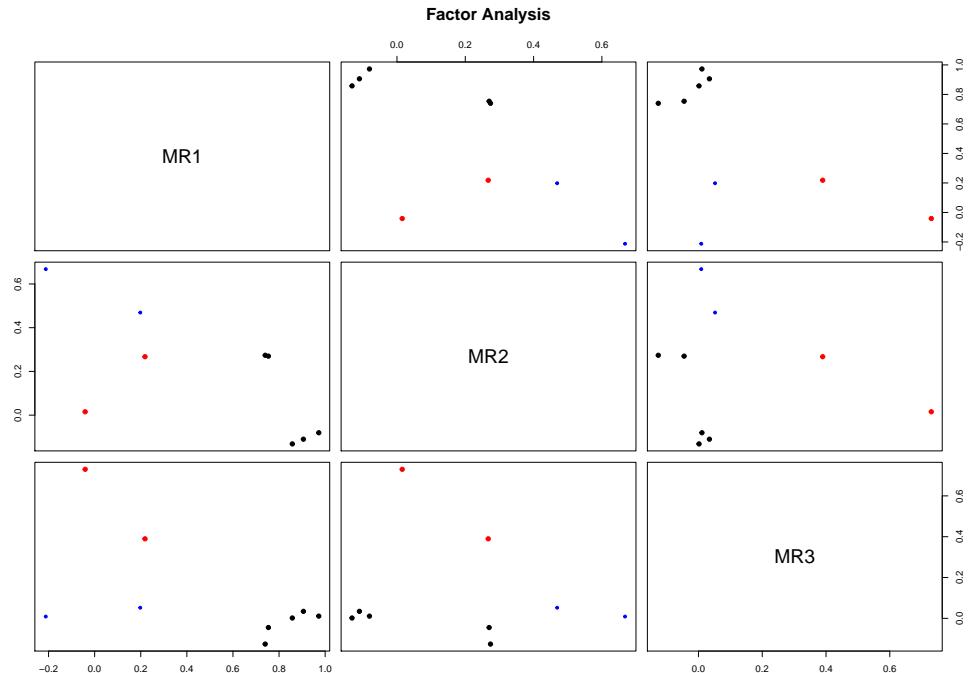


Figura 13.9: Gráfico cartesiano correspondente aos três fatores considerados para os dados do Exemplo 13.2.

O Fator 1 tem cargas fatoriais concentradas nos elementos Al, Ba, Cu, Fe e Zn, que estão associados à poluição de origem veicular gerada por desgaste de freios e ressuspensão de poeira; o Fator 2 está tem cargas fatoriais concentradas em P e Ca, características da saúde arbórea e o Fator 3 tem as cargas fatoriais concentradas em Cl e Mg (**VERIFICAR**).

13.4 Análise de componentes independentes

A **análise de componentes independentes** (*Independent Component Analysis - ICA*) é um método para obter componentes que não tenham as restrições da Análise Fatorial, ou seja, que dispensam a suposição de normalidade.

A análise de componentes independentes é relativamente recente, sendo introduzida na década de 1980 no contexto de redes neurais e encontra aplicações em processamento de sinais biomédicos, separação de sinais de áudio, séries temporais financeiras etc. As principais referências nessa área são Hyvärinen e Oja (1997), Hyvärinen (1999), Hyvärinen et al. (1999) e Stone (2004). Nesta seção baseamo-nos nas ideias de Hyvärinen and Oja (2000) e Gegembauer (2010).

13.4.1 Preliminares

Consideremos um conjunto de dados com p variáveis, $\mathbf{X} = (X_1, \dots, X_p)^\top$ e a transformação

$$Y_i = \sum_{j=1}^p w_{ij} X_j(t), \text{ para } i = 1, \dots, q, \quad (13.7)$$

em que $q < p$ e os w_{ij} são coeficientes que definem a representação. Reunindo os coeficientes w_{ij} em uma matriz \mathbf{W} , de ordem $q \times p$, e os Y_j num vetor \mathbf{Y} , de ordem $q \times 1$, obtemos

$$\mathbf{Y} = \mathbf{WX}. \quad (13.8)$$

A diferença entre análise de componentes independentes, e análise de componentes principais e análise fatorial está nos pesos \mathbf{W} , que são escolhidos de modo que as variáveis Y_i sejam independentes e não gaussianas. ICA é um caso particular da técnica conhecida por **Separação Cega de Fontes** (*Blind Source Separation*). Um exemplo muito citado é o do problema da festa de coquetéis (*cocktail party problem*), descrito na próxima seção.

13.4.2 Separação Cega de Fontes

Consideremos uma situação em que existem pessoas conversando na mesma sala emitindo sinais de fala ou um conjunto de telefones celulares emitindo suas ondas de rádio. Suponhamos que haja vários sensores ou receptores em diferentes posições, com cada mistura das fontes originais gravada com pesos um pouco diferentes.

Com o objetivo de simplificar a exposição, digamos que existem três fontes que dão origem aos sinais, e também três sinais observados, denotados por $X_1(t)$, $X_2(t)$ e $X_3(t)$, que correspondem às amplitudes dos sinais gravados no tempo t , e por $S_1(t)$, $S_2(t)$ e $S_3(t)$ os sinais originais. Os $X_i(t)$ são uma combinação linear dos $S_i(t)$ com coeficientes constantes a_{ij} , que por sua vez, indicam as misturas dos pesos e que dependem da distância entre as fontes e os sensores supostamente desconhecidos:

$$X_1(t) = a_{11}S_1(t) + a_{12}S_2(t) + a_{13}S_3(t)$$

$$\begin{aligned} X_2(t) &= a_{21}S_1(t) + a_{22}S_2(t) + a_{23}S_3(t) \\ X_3(t) &= a_{31}S_1(t) + a_{32}S_2(t) + a_{33}S_3(t). \end{aligned} \quad (13.9)$$

Em geral, não conhecemos os valores a_{ij} e a fonte do sinal $S_i(t)$ também é desconhecida. Gostaríamos de estimar os sinais originais a partir das misturas $X_i(t)$. Este é o problema conhecido como Separação Cega de Fontes . O termo “cega” significa que temos pouca ou nenhuma informação sobre as fontes.

Suponhamos que os coeficientes de mistura, a_{ij} , sejam suficientemente diferentes para a matriz que os englobam seja invertível. Então, existe uma matriz \mathbf{W} com coeficiente w_{ij} , tal que

$$S_i(t) = w_{i1}X_1(t) + w_{i2}X_2(t) + w_{i3}X_3(t), \quad i = 1, 2, 3, \quad (13.10)$$

Se conhecêssemos os pesos a_{ij} em (13.9), a matriz \mathbf{W} seria a inversa da matriz definida pelos coeficientes de mistura a_{ij} .

A questão agora é saber como os coeficientes w_{ij} em (13.10) podem ser estimados. Essencialmente, observamos os sinais X_1 , X_2 e X_3 e queremos obter uma matriz \mathbf{W} de modo que a representação seja dada pelos sinais da fonte original S_1 , S_2 e S_3 . Uma solução simples pode ser encontrada quando os sinais são estatisticamente independentes. De fato, a suposição de que os sinais são não gaussianos é suficiente para determinar os coeficientes w_{ij} , desde que

$$Y_i(t) = w_{i1}X_1(t) + w_{i2}X_2(t) + w_{i3}X_3(t), \quad i = 1, 2, 3, \quad (13.11)$$

sejam estatisticamente independentes. Se os sinais Y_i forem independentes, então eles são iguais aos sinais originais S_i , $i = 1, 2, 3$ (a menos da multiplicação por um escalar).

13.4.3 Análise de Componentes Independentes

O problema descrito na subseção anterior nos leva à seguinte definição da Análise de Componentes Independentes. Dado um vetor de variáveis aleatórias $\mathbf{X} = (X_1, \dots, X_p)^\top$, supostamente geradas como uma mistura linear de componentes independentes $\mathbf{S} = (S_1, \dots, S_p)^\top$, ou seja

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{pmatrix} = \mathbf{A} \begin{pmatrix} S_1 \\ S_2 \\ \vdots \\ S_p \end{pmatrix} = \mathbf{AS}, \quad (13.12)$$

em que $\mathbf{A} = [a_{ij}]$ é alguma matriz desconhecida. A análise de componentes independentes consiste agora em estimarmos tanto a matriz \mathbf{A} quanto os S_i apenas observando os $X_i(t)$. Neste caso, supomos que o número de componentes independentes S_i é igual ao número de variáveis observadas; na realidade esta suposição é uma simplificação não completamente necessária.

Pode-se demonstrar que este problema está bem definido, isto é, que o modelo em (13.12) pode ser estimado se e somente se os componentes S_i são não gaussianos. Isto é uma necessidade fundamental que também explica a principal diferença entre Análise de Componentes Independentes e Análise Fatorial, na qual a normalidade dos dados precisa ser levada em conta. De fato, a Análise de Componentes Independentes pode ser considerada como uma Análise Fatorial não gaussiana, visto que nesse caso também modelamos os dados como uma mistura linear de alguns fatores latentes.

O problema agora é encontrar um algoritmo para executar os cálculos. Como o princípio de estimação usa funções não-quadráticas, os cálculos necessários, usualmente não podem ser expressos usando Álgebra Linear simples, e podem ser extremamente complexos. Algoritmos numéricos são assim uma parte integral dos métodos de estimação neste contexto.

Os métodos numéricos são tipicamente baseados na otimização de algumas funções objetivo e o algoritmo de otimização mais básico é baseado no **método do gradiente**. Em particular, o algoritmo de ponto fixo chamado **FastICA** tem sido usado para explorar uma estrutura específica dos problemas de Análise de Componentes Independentes. Uma aplicação desses métodos é a determinação do nível máximo de não normalidade medido pelo valor absoluto do excesso de curtose.

Admitindo que a matriz \mathbf{A} tenha inversa $\mathbf{A}^{-1} = \mathbf{W}$, obtemos

$$\mathbf{S} = \mathbf{W}\mathbf{X}. \quad (13.13)$$

Há duas ambiguidades no procedimento da Análise de Componentes Independentes. A primeira é que não podemos determinar as variâncias dos elementos S_i , pois se os multiplicarmos por uma constante C , basta dividir as colunas correspondentes de \mathbf{A} por C . Dessa maneira, o que fazemos é centrar as componentes, isto é, considerar $E(S_i) = 0$, para todo i e fixar as magnitudes das componentes independentes de modo que $E(S_i^2) = 1$, para todo i .

A segunda ambiguidade é que, contrariamente ao que ocorre com a Análise de Componentes Principais, não podemos determinar a ordem das componentes independentes, pois como \mathbf{S} e \mathbf{A} são desconhecidas, podemos mudar livremente a ordem dos termos em (13.12).

Por quê variáveis gaussianas não são permitidas? Para responder, considere o caso particular (13.9), suponha que \mathbf{A} seja **ortogonal** e que os elementos $S_i(t)$ sejam gaussianos. Então, as variáveis $X_i(t)$ são gaussianas (combinações lineares de variáveis aleatórias independentes e gaussianas) não correlacionadas (por quê?) e de variância unitária. Sua densidade conjunta é dada por

$$f(x_1, x_2, x_3) = \frac{1}{(2\pi)^{3/2}} e^{-(x_1^2 + x_2^2 + x_3^2)/2},$$

que é simétrica e, por isso, não contém nenhuma informação sobre as direções das colunas de \mathbf{A} . Logo, \mathbf{A} não pode ser estimada, ou ainda, \mathbf{A} não é identificada para componentes gaussianas independentes.

Seja $y = \mathbf{v}^\top \mathbf{X} = \sum_{i=1}^p v_i X_i$, em que \mathbf{v} é um vetor $p \times 1$. Se \mathbf{v} fosse uma das linhas de $\mathbf{A}^{-1} = \mathbf{W}$, essa combinação linear seria uma das componentes independentes S_i . O problema reduz-se, então, a determinar um vetor \mathbf{v} que satisfaça essas condições.

Pode-se provar que maximizando-se a “não gaussianidade” de $\mathbf{v}^\top \mathbf{X}$ obtém-se uma das componentes de \mathbf{S} . Para tanto, teremos que obter $2p$ máximos locais, 2 para cada componente independente (correspondendo a S_i e $-S_i$). Como as componentes independentes são não correlacionadas, podemos restringir a busca ao espaço que fornece estimativas não correlacionadas com as anteriores e isso corresponde a **branquear (whiten)** as observações. Alguns detalhes desse processo são apresentados na Nota de Capítulo 4.

Como obter componentes independentes? Podemos escolher duas formas como *proxy* de independência, que por sua vez determinam a forma do algoritmo de Análise de Componentes Independentes a usar:

1. Minimização da informação mútua (MIM);

2. Maximização da não gaussianidade (MNG).

A família de algoritmos que usa MIM utiliza medidas como a **Divergência de Kullback-Leibler** e **Máxima Entropia**. A família que aborda a “não gaussianidade”, usa curtose e **negentropia**. Ver a Nota de Capítulo 4 para definições e detalhes.

13.4.4 Pré-processamento

Como passos de pré-processamento, os algoritmos usam centragem (subtração da média para obter um sinal de média zero), branqueamento e redução da dimensionalidade, usualmente via Análise de Componentes Principais e decomposição em valores singulares. O branqueamento assegura que todas as dimensões são tratadas igualmente antes que o algoritmo seja aplicado.

Sejam duas variáveis, X e Y . Se $Cov(X, Y) = E(XY) - E(X)E(Y) = 0$ dizemos que X e Y são não correlacionadas. Se X e Y são independentes, então elas são não correlacionadas. Porém, não correlação não implica independência, ou seja covariância zero não implica necessariamente independência, a não ser que (X, Y) tenham distribuição gaussiana bivariada.

Uma propriedade um pouco mais forte que não correlação é “brancura” (*whiteness*). Branquear um vetor de média zero, \mathbf{y} , significa tornar seus componentes não correlacionados com variâncias unitárias, ou seja, fazer com que

$$E[\mathbf{y}\mathbf{y}^\top] = \mathbf{I}. \quad (13.14)$$

Consequentemente, branquear o vetor \mathbf{x} corresponde a obter uma matriz \mathbf{V} tal que

$$\mathbf{z} = \mathbf{V}\mathbf{x}, \quad (13.15)$$

de forma que o vetor \mathbf{z} que seja “branco”. Um método bastante popular para o branqueamento é baseado na decomposição em valores singulares (*singular value decomposition*- SVD) da matriz de covariâncias da variável centrada, digamos $\tilde{\mathbf{X}}$, ou seja, considerar

$$E[\tilde{\mathbf{X}}\tilde{\mathbf{X}}^\top] = \mathbf{E}\mathbf{D}\mathbf{E}^\top, \quad (13.16)$$

em que \mathbf{E} é a matriz ortogonal de autovetores de $E[\tilde{\mathbf{X}}\tilde{\mathbf{X}}^\top]$ e \mathbf{D} é a matriz diagonal cujos elementos são os seus autovalores, ($\mathbf{D} = \text{diag}(d_1, \dots, d_p)$). O branqueamento pode agora ser feito por meio da matriz de branqueamento

$$\mathbf{V} = \mathbf{ED}^{-1/2}\mathbf{E}^\top \quad (13.17)$$

e transforma \mathbf{A} em $\tilde{\mathbf{A}}$, tal que

$$\tilde{\mathbf{X}} = \mathbf{ED}^{-1/2}\mathbf{E}^\top \mathbf{AS} = \tilde{\mathbf{A}}\mathbf{S}.$$

Esse procedimento torna $\tilde{\mathbf{A}}$ ortogonal, pois

$$E[\tilde{\mathbf{X}}\tilde{\mathbf{X}}^\top] = \tilde{\mathbf{A}}E(\mathbf{SS}^\top)\tilde{\mathbf{A}}^\top = \tilde{\mathbf{A}}\tilde{\mathbf{A}}^\top = \mathbf{I}.$$

Como consequência, o processo de branqueamento reduz o número de parâmetros a estimar, de p^2 para $p(p-1)/2$, devido à ortogonalidade da matriz $\tilde{\mathbf{A}}$.

Há vários algoritmos para a análise de componentes independentes de um conjunto de dados, dentre os quais, mencionamos: Algoritmo do Gradiente usando a Curtose, Algoritmo de Ponto Fixo usando Curtose, Algoritmo do Gradiente usando

Negentropia, Algoritmo de Ponto Fixo usando Negentropia, Algoritmos para Estimação de Máxima Verossimilhança. Veja Gegembauer (2010) para detalhes.

Algoritmos tradicionalmente utilizados para a ICA incluem `infomax`, `FastICA` e `JADE`. O pacote `ica` contempla esses algoritmos. Outros pacotes também disponíveis são: `fastICA` e `ProDenICA`. Este último foi desenvolvido por T. Hastie e R. Tibshirani e apresenta a particularidade de estimar a densidade de cada componente.

Exemplo 13.3. Consideremos novamente os dados do Exemplo 13.2, em que 9 variáveis foram observadas em 184 unidades. Por meio do pacote `ica` obteremos as 9 componentes independentes.

A matriz \mathbf{M} (*mixing*) estimada pelo algoritmo, de ordem 9×9 , correspondente à nossa matriz \mathbf{A} é

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]
[1,]	-139.3790190	-149.7021007	-325.3324853	1077.925146	155.3171887	68.243758	111.7946050	-274.782659
[2,]	-0.4866963	-0.2949352	-0.5650103	1.190811	0.3524588	0.355581	0.4229097	-0.879921
[3,]	-12.4332654	2.4281842	-25.8117720	42.551213	13.2787874	13.166554	16.9792887	-77.566097
[4,]	-42.4416295	-15.1698381	-86.3634728	405.249890	356.4777419	14.649072	-24.5665422	-99.761388
[5,]	-264.2307634	-730.1007230	224.9821643	-230.382230	38.0537401	123.889785	9.4797710	87.720764
[6,]	-109.9753576	-35.9892578	-184.6838704	661.491067	263.0009705	33.477923	308.4517253	-40.708621
[7,]	-121.4505476	21.0283928	-136.7716779	-19.803719	5.3052447	19.311117	15.3286940	2.762610
[8,]	-17.9760476	-19.9296505	2.3521578	10.763812	14.0445497	232.900590	-0.7320548	4.559599
[9,]	-7362.9405123	3856.0539441	3007.1595557	-1949.521311	-1347.9118353	1263.932257	-977.7231474	-677.758695
	[,9]							
[1,]	15.571397							
[2,]	-1.274516							
[3,]	-8.172252							
[4,]	-1.558269							
[5,]	227.872428							
[6,]	57.382165							
[7,]	14.380424							
[8,]	6.372196							
[9,]	-609.643712							

Com base nessa matriz, podemos escrever, por exemplo,

$$X_1 = -139,379S_1 - 149,702S_2 + \dots + 15,571S_9.$$

O pacote também fornece estimativas das seguintes matrizes

- i) \mathbf{S} , de ordem 193×9 , das componentes independentes, obtida pela relação $\mathbf{S} = \mathbf{WX} = \mathbf{YR}$;
- ii) \mathbf{W} , ortogonal, de ordem 9×9 , matriz *un-mixing*, tal que $\mathbf{XYW} = \mathbf{S}$ escolhida de modo a maximizar a negentropia;
- iii) \mathbf{Y} de ordem 193×9 , matriz pré-branqueada;
- iv) \mathbf{Q} de ordem 9×15 , matriz de pré-branqueamento, tal que $\mathbf{Y} = \mathbf{QX}$;
- v) \mathbf{R} , de ordem 9×9 matriz de rotação ortogonal, tal que $\mathbf{S} = \mathbf{YR}$.

Além disso, os resultados obtidos pela aplicação da função incluem

- a) vafs: variância explicada por cada componente independente;
- b) alg: algoritmo usado (parallel ou deflation);
- c) fun: função contraste (para aproximar a negentropia);
- d) alpha: parâmetro de ajuste;
- e) iter: número de iterações utilizadas pelo algoritmo.

As variâncias explicadas pelas componentes independentes são

0.600985581 0.170645639 0.102434106 0.062162898 0.022555357

0.018513146 0.011778296 0.006196794 0.004728182

e indicam que as três primeiras componentes explicam cerca de 88% da variância dos dados. As duas primeiras componentes independentes são apresentadas na Figura 13.10.

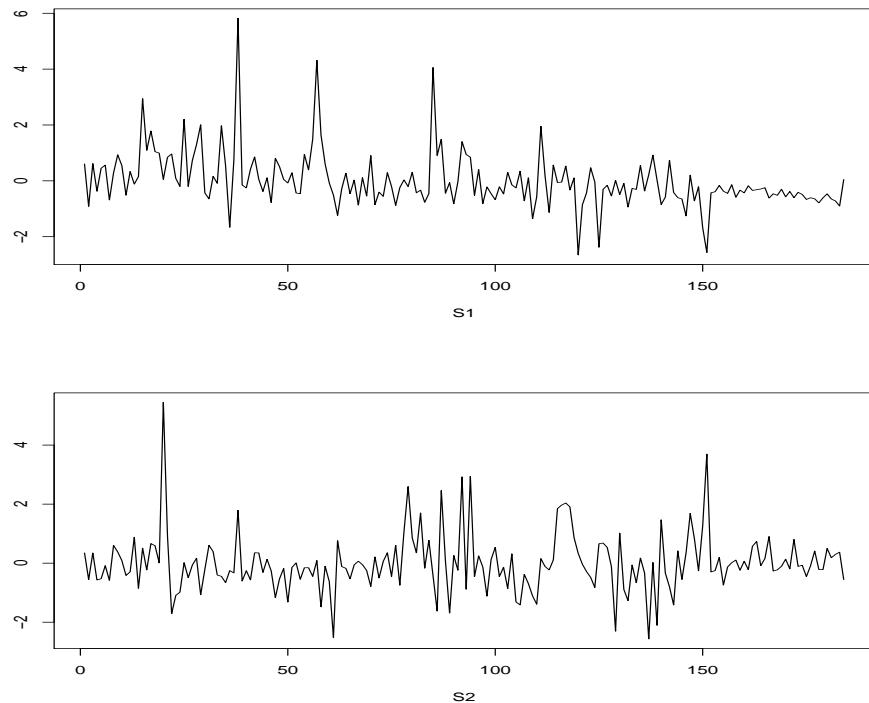


Figura 13.10: Gráficos das duas primeiras componentes independentes para o Exemplo 13.3.

A estimativa da matriz \mathbf{W} é

```
[,1] [,2] [,3] [,4] [,5] [,6] [,7] [,8]
[1,] -1.750287e-04 -0.074821293 0.0018890899 -1.219544e-04 -4.394832e-04 -9.771709e-05 -1.951470e-03 9.258294e-04
[2,] -3.688197e-04 -0.193146765 0.0014816133 1.790061e-04 -1.018530e-03 5.109103e-04 -8.073011e-05 5.379454e-04
[3,] -2.673837e-04 -0.024630937 0.0003486251 1.736989e-05 2.822484e-04 6.088192e-04 -5.353500e-03 -1.075091e-04
[4,] 1.176365e-03 -0.020637504 -0.0041025331 -1.933696e-04 -1.798993e-04 -3.679419e-05 -1.609738e-03 5.375905e-05
[5,] -1.511512e-03 0.035410750 0.0012706791 2.872724e-03 1.468919e-04 5.799778e-04 5.234842e-04 1.298423e-05
[6,] -2.234726e-05 -0.004478221 0.0004852519 -1.619936e-04 -1.281089e-04 -1.639626e-05 -1.038226e-04 4.386960e-03
[7,] -1.548268e-03 0.105156093 0.0053742429 -2.024956e-03 9.977071e-05 3.208043e-03 -9.018445e-04 -2.629357e-04
[8,] 1.119943e-04 0.110425897 -0.0148241124 -5.879721e-05 -1.557664e-04 5.604000e-04 1.003537e-03 5.855453e-04
[9,] 3.545273e-04 -0.752508234 0.0074526851 -6.531333e-05 2.558401e-04 4.482189e-04 7.568601e-04 3.558750e-04
[,9]
[1,] -8.288335e-05
[2,] 4.515382e-05
[3,] 7.534598e-05
[4,] 2.056474e-05
[5,] -1.503345e-05
[6,] -3.322196e-06
[7,] -1.102442e-05
[8,] -4.811093e-06
[9,] 1.592838e-06
```

A forma que, por exemplo,

$$S_1 = -0,000175X_1 - 0,0748X_2 + \dots + 0,0000829X_9.$$

e que as variáveis $X_3 = \text{Zn}$, e $X_4 = \text{Ba}$ são as mais importantes para explicar as componentes independentes S_i , $i = 1, \dots, 9$.

As densidades estimadas das componentes independentes obtidas por meio do pacote ProDenICA estão apresentadas na Figura 13.11.

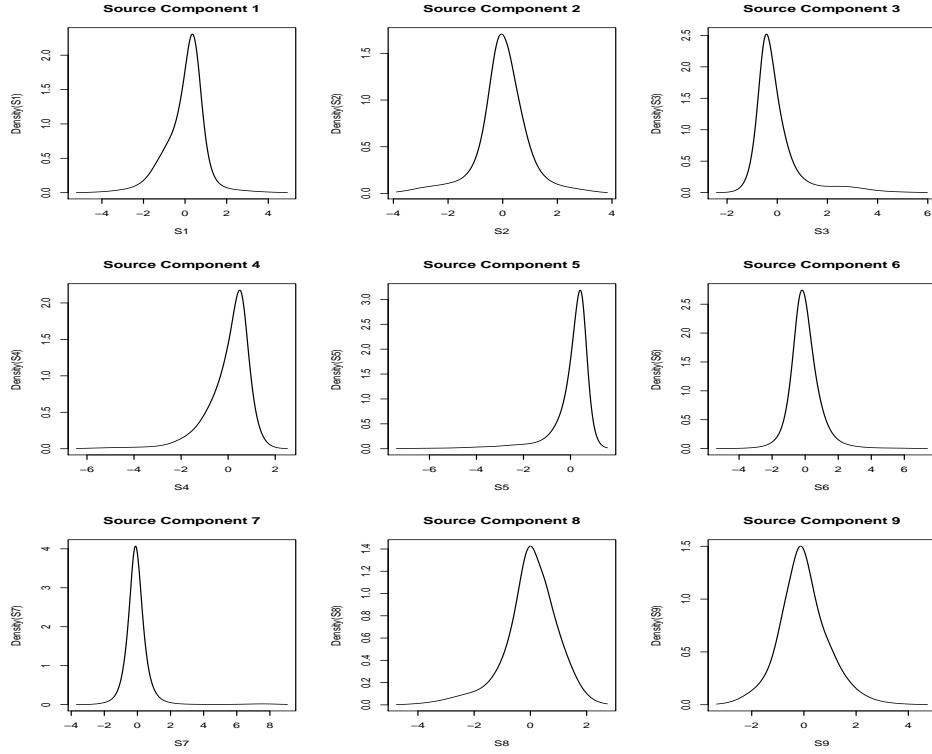


Figura 13.11: Gráficos das densidades das componentes independentes para o Exemplo 13.3.

Considerando agora apenas três componentes independentes, obtemos a seguinte matriz \mathbf{M}

	[,1]	[,2]	[,3]
[1,]	130.0588599	-1172.278514	-50.1191462
[2,]	0.4506871	-1.538268	-0.2837152
[3,]	17.7456231	-64.094123	-17.9385466
[4,]	46.0218183	-489.157909	-30.7345628
[5,]	215.8328265	141.834601	846.2085520
[6,]	85.0325691	-771.625038	-24.1875542
[7,]	76.2477919	-26.575128	-18.3258463
[8,]	61.9279843	-24.349130	49.9983656
[9,]	8353.6861764	3325.603526	-2506.6567435

e a matriz \mathbf{W}

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]	[,7]	[,8]
[1,]	0.0002104413	2.494246e-07	7.925442e-06	8.257729e-05	3.307134e-04	1.416700e-04	1.255409e-05	3.473013e-05
[2,]	-0.0005069541	-7.063526e-07	-2.903874e-05	-2.097610e-04	-8.165741e-06	-3.338968e-04	-2.364408e-05	-2.260694e-05
[3,]	0.0000287935	-1.201862e-07	-1.273793e-05	-2.839277e-06	1.091458e-03	2.931156e-05	7.179379e-06	8.385744e-05
	[,9]							
[1,]	1.056008e-04							
[2,]	1.310325e-05							
[3,]	-2.959094e-05							

As variâncias explicadas por cada uma das três componentes independentes são

```
[1] 0.77283297 0.14705258 0.07750351
```

As duas primeiras explicam 92% da variância dos dados. Usando a função `fastICA` do pacote `fastICA`, podemos obter mais alguns gráficos para ilustrar o procedimento. Os dados pré-processados, as componentes principais estimadas e as componentes independentes estimadas estão dispostos na Figura ???. Na Figura 13.13 apresentamos os gráficos das três componentes.

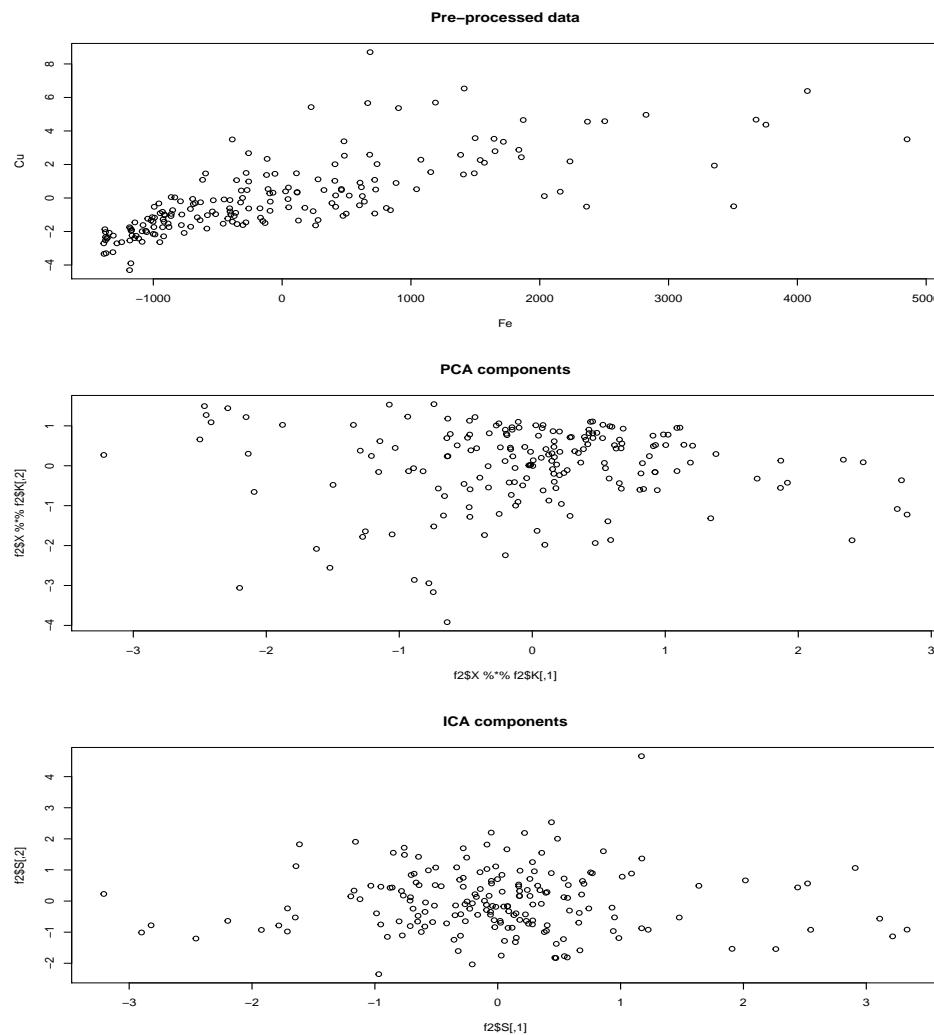


Figura 13.12: Gráficos de pré processamento para o Exemplo 13.3.

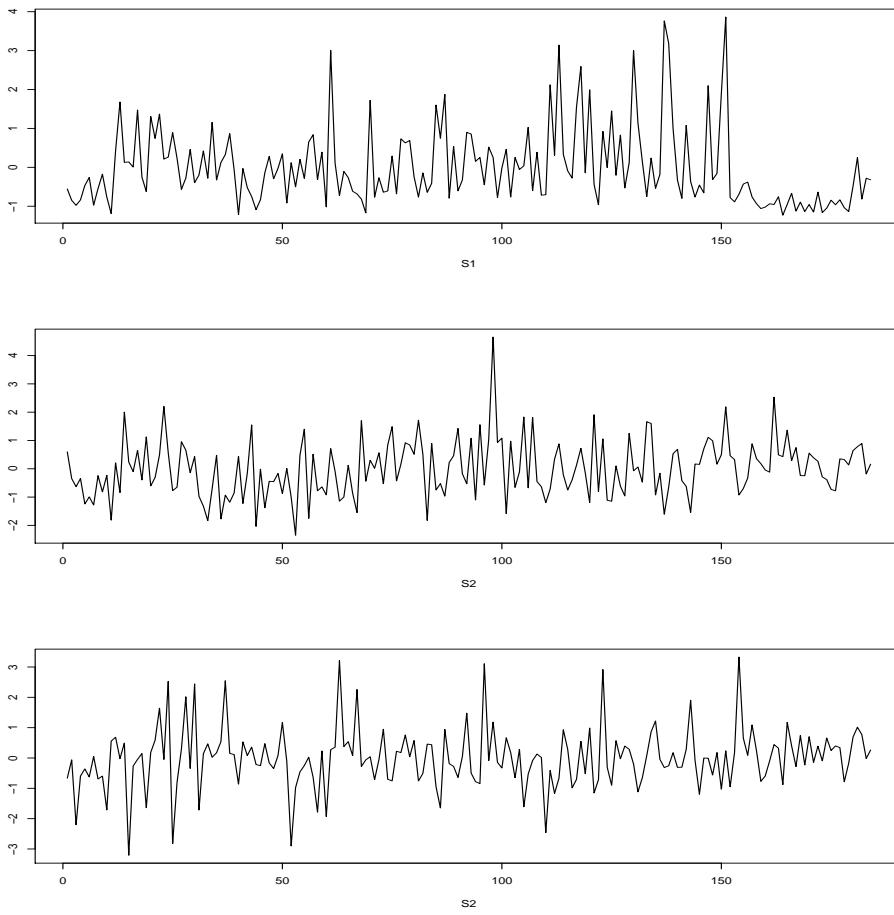


Figura 13.13: Gráficos das três componentes independentes para o Exemplo 13.3.

13.5 Notas de Capítulo

1) Obtenção das componentes principais

Para obtenção da primeira componente principal com base nos dados amostrais, considere a função

$$h(\beta_1, \lambda) = \beta_1^\top \mathbf{S} \beta_1 - \lambda(\beta_1^\top \beta_1 - 1)$$

em que λ é o multiplicador de Lagrange. A derivada de $h(\beta_1, \lambda)$ em relação a β_1 é

$$\partial h(\beta_1, \lambda)/\partial \beta_1 = 2\mathbf{S}\beta_1 - 2\lambda\beta_1.$$

Para obter a primeira componente principal devemos resolver a equação $\partial h(\beta_1, \lambda)/\partial \beta_1 = \mathbf{0}$ ou seja, determinar $\hat{\lambda}_1$ e $\hat{\beta}_1$ tais que

$$(\mathbf{S} - \hat{\lambda}\mathbf{I})\hat{\beta}_1 = \mathbf{0}. \quad (13.18)$$

Para que esse sistema tenha uma solução não nula é necessário que

$$\det(\mathbf{S} - \hat{\lambda}\mathbf{I}_p) = 0,$$

ou seja, que $\hat{\lambda}$ seja um **autovalor** de \mathbf{S} e que $\hat{\beta}_1$ seja o **autovetor** correspondente.

Sejam $\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \geq \hat{\lambda}_p$ os p autovalores de \mathbf{S} . Para determinar qual deles devemos escolher com a finalidade de maximizar $\beta_1^\top \mathbf{S} \beta_1$, basta multiplicar $(\mathbf{S} - \hat{\lambda} \mathbf{I}) \beta_1 = \mathbf{0}$ por β_1^\top , obtendo a equação

$$\beta_1^\top \mathbf{S} \beta_1 - \hat{\lambda} \beta_1^\top \beta_1 = 0.$$

Lembrando que $\beta_1^\top \beta_1 = 1$, a solução é $\hat{\lambda} = \beta_1^\top \mathbf{S} \beta_1$. Então para maximizar $\beta_1^\top \mathbf{S} \beta_1$ devemos escolher $\hat{\lambda}_1$, o maior autovalor de \mathbf{S} e $\hat{\beta}_1$, o autovetor correspondente. A primeira componente principal será $\hat{Y}_1 = \hat{\beta}_1 \mathbf{X}$ e sua variância é $\hat{\lambda}_1$.

A segunda componente principal é a combinação linear $Y_2 = \beta_2 \mathbf{X}$ tal que $\beta_2^\top \beta_2 = 1$, $\beta_2^\top \beta_1 = 0$ e $\beta_2^\top \mathbf{S} \beta_2$ seja máxima. Neste caso, devemos maximizar a função

$$h(\beta_2, \lambda, \nu) = \beta_2^\top \mathbf{S} \beta_2 - \lambda(\beta_2^\top \beta_2 - 1) - \nu(\beta_2^\top \beta_1)$$

em que os multiplicadores de Lagrange são λ e ν . Para isso, devemos resolver a equação

$$\partial h(\beta_2, \lambda, \nu) / \partial \beta_2 = 2(\mathbf{S} \beta_2 - \lambda \mathbf{I}_p) \beta_2 - \nu \beta_1 = \mathbf{0} \quad (13.19)$$

que multiplicada por β_1^\top implica

$$2\beta_1^\top \mathbf{S} \beta_2 - 2\lambda \beta_1^\top \beta_2 - \nu \beta_1^\top \beta_1 = 0;$$

como $\beta_1^\top \beta_1 = 1$, obtemos $2\beta_1^\top \mathbf{S} \beta_2 - \nu = 0$. Multiplicando (13.18) por β_2^\top , obtemos $\beta_1^\top \mathbf{S} \beta_2 = 0$, concluindo que $\nu = 0$. Consequentemente, de (13.19), segue que

$$(\mathbf{S} - \hat{\lambda} \mathbf{I}) \hat{\beta}_2 = \mathbf{0}.$$

Logo, $\hat{\beta}_2$ deve ser um autovetor de \mathbf{S} e como $\hat{\beta}_1^\top \mathbf{S} \hat{\beta}_1 \geq \hat{\beta}_2^\top \mathbf{S} \hat{\beta}_2$, a segunda componente principal corresponde ao autovetor associado ao segundo maior autovetor de \mathbf{S} . Então, a segunda componente principal será $\hat{Y}_2 = \hat{\beta}_2 \mathbf{X}$ e sua variância será $\hat{\lambda}_2$.

Repetindo esse procedimento, podemos obter as demais componentes principais.

2) Decomposição de matrizes simétricas

Toda matriz simétrica real Σ pode ser escrita como $\Sigma = \mathbf{P} \Lambda \mathbf{P}^\top$ em que \mathbf{P} é uma matriz ortogonal e Λ é uma matriz diagonal com os autovalores de Σ ao longo da diagonal principal. Então, $\Sigma = \mathbf{P} \Lambda^{1/2} \Lambda^{1/2} \mathbf{P}^\top$ em que $\Lambda^{1/2}$ é uma matriz diagonal com as raízes quadradas dos elementos não nulos de Λ ao longo da diagonal principal. Fazendo $\mathbf{L} = \mathbf{P} \Lambda^{1/2}$, obtemos

$$\Sigma = \mathbf{L} \mathbf{L}^\top = \lambda_1 \beta_1 \beta_1^\top + \dots + \lambda_p \beta_p \beta_p^\top$$

em que β_i é o autovetor de Σ correspondente ao i -ésimo autovalor.

3) Distribuição de Wishart

Quando \mathbf{X} tem distribuição normal, $(n-1)\mathbf{S}$ segue uma distribuição Wishart com $n-1$ graus de liberdade, cuja função densidade é

$$f(\mathbf{S}) = C |\mathbf{S}|^{(n-p-2)/2} |\Sigma|^{-(n-1)/2} \exp\{-[(n-1)/2] \text{tr}(\Sigma^{-1} \mathbf{S})\}.$$

Dada a fatoração $\Sigma = \Lambda\Lambda^\top + \psi$, o logaritmo da função densidade a ser maximizada é

$$\begin{aligned} L(\Lambda, \psi) = \log(C) &+ [(n-p-2)/2 \log(\mathbf{S})] \\ &- [(n-1)/2] \log |\Lambda\Lambda^\top + \psi| \\ &- [(n-1)/2] \text{tr}[\Lambda\Lambda^\top + \psi]^{-1}\mathbf{S}. \end{aligned}$$

Igualando a $\mathbf{0}$ as derivadas de $L(\Lambda, \psi)$ em relação a Λ e ψ obtemos o sistema (13.6).

4) ICA pela Maximização da Não-Normalidade

Vamos abordar um princípio simples e intuitivo baseado na maximização da não-normalidade para a estimativa sob o modelo ICA.

Consideremos a expressão (13.13), isto é, uma mistura de componentes independentes. Suponhamos que todos os componentes independentes têm a mesma distribuição. A estimativa dos componentes independentes pode ser executada por meio da determinação de combinações lineares das variáveis de mistura, desde que possamos inverter a mistura como

$$\mathbf{S} = \mathbf{A}^{-1}\mathbf{X}.$$

Para estimar um dos componentes independentes podemos considerar uma combinação linear dos X_i . Denotemos essa combinação linear por $y = \mathbf{A}^\top \mathbf{X} = \sum_{i=1}^p b_i X_i$, em que $\mathbf{b} = (b_1, \dots, b_p)^\top$ é um vetor a ser determinado. Por outro lado, $y = \mathbf{b}^\top \mathbf{A}\mathbf{S}$. Então, y é uma combinação linear dos S_i , com coeficientes dados por $\mathbf{b}^\top \mathbf{A} = \mathbf{q}$. Então

$$y = \mathbf{b}^\top \mathbf{X} = \mathbf{q}^\top \mathbf{S} = \sum_{i=1}^p q_i S_i. \quad (13.20)$$

Se \mathbf{b} for uma das linhas da inversa da matriz de mistura \mathbf{A} , esta combinação linear de (13.20) será igual a um dos componentes independentes. Neste caso, o correspondente \mathbf{q} será tal que apenas um dos seus elementos é igual a 1 e todos os outros, iguais a zero. A questão agora é verificar como o Teorema Limite Central pode ser empregado para determinar \mathbf{b} de modo que seja igual a uma das linhas da inversa de \mathbf{A} . Na prática não podemos determinar \mathbf{b} exatamente porque não temos conhecimento a respeito da matriz \mathbf{A} , mas podemos encontrar um estimador que corresponda a uma boa aproximação.

Variando os coeficientes de \mathbf{q} e observando como a distribuição de $y = \mathbf{q}^\top \mathbf{S}$ muda, usamos a ideia fundamental de que a soma de duas variáveis independentes se aproxima mais da distribuição gaussiana do que as variáveis originais e que y é usualmente mais próximo do que os S_i e se torna menos próximo quando de fato iguala um dos S_i . Devemos notar aqui que isto é estritamente verdade se os S_i têm a mesma distribuição, como supusemos anteriormente. Neste caso, claramente, apenas um dos elementos q_i de \mathbf{q} não é nulo.

Na prática não é preciso conhecer os valores de \mathbf{q} porque pela definição, $\mathbf{q}^\top \mathbf{S} = \mathbf{b}^\top \mathbf{X}$. Precisamos apenas variar \mathbf{b} e observar a distribuição de $\mathbf{b}^\top \mathbf{X}$.

Então, podemos escolher um vetor \mathbf{b} que maximiza a não normalidade de $\mathbf{b}^\top \mathbf{X}$. Tal vetor necessariamente corresponde a $\mathbf{q} = \mathbf{A}^\top \mathbf{b}$, que tem apenas um elemento diferente de zero. Isto significa que $y = \mathbf{b}^\top \mathbf{X} = \mathbf{q}^\top \mathbf{S}$ é igual a

um dos componentes independentes. Maximizar a não normalidade de $\mathbf{b}^\top \mathbf{X}$ gera um dos componentes independentes.

Sob o ponto de vista prático, precisamos saber como a não normalidade de $\mathbf{b}^\top \mathbf{X}$ pode ser medida e como podemos calcular os valores de \mathbf{b} que maximizam (localmente) tal medida.

Medindo não normalidade pela curtose

Existem variáveis aleatórias não gaussianas cujo excesso de curtose é zero, mas podem ser consideradas muito raras. Tipicamente, o excesso de curtose é zero para distribuições normais, positiva para as distribuições supergaussianas (leptocúrticas) e negativas para as distribuições subgaussianas (platocúrticas). Para ilustrar a otimização da curtose no processo de obtenção dos componentes independentes, considere o modelo bidimensional $\mathbf{X} = \mathbf{AS}$. Supondo que os componentes independentes S_1 e S_2 têm curtose igual a $curt(S_1)$ e $curt(S_2)$, respectivamente, ambas diferentes de zero, a curtose de $y = q_1 S_1 + q_2 S_2$ é

$$curt(y) = curt(q_1 S_1) + curt(q_2 S_2) = q_1^4 curt(S_1) + q_2^4 curt(S_2). \quad (13.21)$$

Por meio do pré-processamento, os cálculos são realizados para variáveis com média zero e variância unitária, logo variância de y é igual a 1. Isto implica que $E(y^2) = q_1^2 + q_2^2 = 1$, cuja interpretação geométrica indica que o vetor \mathbf{q} está restrito ao círculo unitário no plano bidimensional.

O problema de otimização agora é encontrar o máximo da função $|curt(y)| = |q_1^4 curt(S_1) + q_2^4 curt(S_2)|$ sobre o círculo unitário. Podemos verificar que o máximo ocorre exatamente onde um dos elementos do vetor \mathbf{q} é zero e o outro não. Por causa das restrições do círculo unitário, o elemento não nulo deve ser igual a 1 ou -1. Mas estes pontos são exatamente aqueles em que y é igual ao componente independente $\pm S_i$ e assim o problema está resolvido. Para mais detalhes, ver Hyvärinen e Oja (2000).

Para dados \mathbf{z} que passaram pelo pré-processamento de branqueamento procuramos por uma combinação linear $\mathbf{w}^\top \mathbf{z}$ que maximiza a não normalidade. Se $\mathbf{q} = \mathbf{VA}^\top \mathbf{w}$, então

$$\|q\|^2 = (\mathbf{w}^\top \mathbf{V}\mathbf{A})(\mathbf{A}^\top \mathbf{V}^\top \mathbf{w}) = \|\mathbf{w}\|^2. \quad (13.22)$$

Isso significa que restringir \mathbf{q} à esfera unitária é equivalente a restringir \mathbf{w} à mesma esfera. Sendo assim, basta maximizar o valor absoluto da curtose de $\mathbf{w}^\top \mathbf{z}$ sob a restrição $\|\mathbf{w}\| = 1$. Além disso, após o branqueamento, as combinações lineares $\mathbf{w}^\top \mathbf{z}$ podem ser interpretadas como projeções sobre a linha transposta pelo vetor \mathbf{w} . Cada ponto sob o círculo unitário corresponde a uma projeção, o que mostra a utilidade do branqueamento.

Medindo não normalidade pela negentropia

Uma desvantagem em usar a curtose é que ela é muito sensível a *outliers*. O valor da curtose pode depender somente de poucas observações nas caudas das distribuições, que podem ser observações erradas ou irrelevantes. Ou seja, a curtose não é uma medida robusta de não normalidade. Como alternativa, podemos considerar a negentropia, que apesar de ser computacionalmente mais complicada é uma medida robusta e em algum sentido o estimador ótimo de não normalidade. Do ponto de vista computacional, há aproximações simples e úteis da negentropia. Em Análise de Componentes Independentes,

a **teoria da informação**, juntamente com a teoria da estimativa são as duas principais ferramentas teóricas.

A **negentropia** está relacionada com o conceito de **entropia** de uma variável aleatória X . No caso discreto, a entropia é definida por

$$H(X) = - \sum_i P(X = a_i) \log P(X = a_i), \quad (13.23)$$

em que a_i são os possíveis valores de X .

A entropia é menor se as probabilidades $P(X = a_i)$ estão perto de 0 ou 1 e maior para valores intermediários. De fato, a entropia de uma variável aleatória pode ser interpretada como o grau de informação que a observação da variável fornece. Quanto mais “aleatório”, ou seja, quanto mais imprevisível e desestruturada a variável é, maior será sua entropia.

No caso de uma variável aleatória contínua X , vetorial ou não, a entropia (também chamada de **entropia diferencial**) é definida como

$$H(X) = - \int f_X(x) \log f_X(x) dx = \int f(f_X(x)) dx \quad (13.24)$$

em que $f_X(x)$ é a densidade da variável aleatória X .

Uma classe importante de métodos com diversas aplicações é baseada no método de máxima entropia. Suponha que a informação disponível da densidade $f_X(x)$ de uma variável aleatória X seja da forma

$$\int f_X(x) F_i(x) dx = c_i, \quad i = 1, \dots, m, \quad (13.25)$$

que na prática, significa que temos que estimar a esperança $E[F_i(X)]$ de m funções F_i .

A questão agora é qual é a função densidade que satisfaz restrição em (13.25) e tem a entropia máxima dentre tais densidades? O resultado básico do método de máxima entropia nos diz que sob algumas condições de regularidade, a densidade que satisfaz a restrição (13.25) e tem a máxima entropia é da forma

$$f_0(x) = A \exp \left(\sum_i a_i F_i(x) \right), \quad (13.26)$$

em que A e a_i são constantes determinadas a partir de c_i , usando as restrições em (13.25) e a restrição $\int f_0(x) dx = 1$. Isto, geralmente gera um sistema de $n+1$ equações não lineares que podem ser de difícil solução e, muitas vezes, requerem métodos numéricos para a solução.

Para o conjunto de variáveis aleatórias contínuas com média zero e variância fixa, digamos igual a 1, a distribuição de máxima entropia é a distribuição gaussiana. A propriedade de máxima entropia pode ser usada para definir uma medida de não normalidade. Um medida que seja zero para variáveis gaussianas e não negativa pode ser obtida da entropia diferencial e é chamada de negentropia J , definida como

$$J(\mathbf{x}) = H(\mathbf{x}_{normal}) - H(\mathbf{x}), \quad (13.27)$$

em que \mathbf{x}_{normal} é um vetor aleatório normal com mesma matriz de covariância Σ que \mathbf{x} . Sua entropia pode ser calculada como

$$H(\mathbf{x}_{normal}) = \frac{1}{2} \log |\det \Sigma| + \frac{n}{2} [1 + \log 2\pi],$$

em que n é a dimensão de \mathbf{x} .

A negentropia ainda tem uma propriedade adicional bastante interessante que é ser invariante por transformações lineares invertíveis. Em particular, multiplicações de uma variável aleatória por uma constante não altera a sua negentropia.

Segundo Hyvärinen e Oja (2001), na prática somente precisamos de aproximações unidimensionais da (neg)entropia. Por isso, consideraremos somente o caso escalar na sequência.

O método clássico de aproximação da negentropia consiste na utilização de **cumulantes** de ordem mais alta, obtidos por meio da expansão polinomial da densidade. O resultado produzido pela aproximação para uma variável y com média zero e variância unitária é

$$J(Y) \approx \frac{1}{12} [E(Y^3)]^2 + \frac{1}{48} [curt(Y)]^2. \quad (13.28)$$

Uma aproximação útil consiste em usar as esperanças de funções gerais não quadráticas. Em geral, podemos substituir funções polinomiais y^3 e y^4 por qualquer outra função G_i , possivelmente mais que duas. O método então fornece uma forma simples de aproximação da negentropia com base nas esperanças $E[G_i(y)]$. Como um caso especial simples, podemos utilizar quaisquer funções não quadráticas G_1 e G_2 que sejam ímpar e par, respectivamente, obtendo a seguinte aproximação:

$$J(y) \approx k_1 \left[E\{G_1(y)\} \right]^2 + k_2 \left[E\{G_2(y)\} - E\{G_2(\nu)\} \right]^2 \quad (13.29)$$

em que k_1 e k_2 são constantes positivas e ν é uma variável gaussiana de média zero e variância unitária.

No caso de uma única função não quadrática G , a aproximação se transforma em

$$J(y) \propto \left[E\{G(y)\} - E\{G(\nu)\} \right]^2, \quad (13.30)$$

para praticamente qualquer função G não quadrática. As seguintes escolhas de G são comumente usadas:

$$\begin{aligned} G_1(y) &= \frac{1}{a_1} \log \cosh(a_1 y) \\ G_2(y) &= -\exp(-y^2/2) \end{aligned}$$

em que $1 \leq a_1 \leq 2$ é alguma constante adequada, muitas vezes tendo valores iguais a 1.

5) Análise de componentes independentes por máxima verossimilhança

Não é difícil obter a verossimilhança de um modelo ICA livre de ruído. De acordo com o método do Jacobiano para transformações de variáveis, a densidade f_X do vetor de mistura $\mathbf{X} = \mathbf{AS}$ pode ser escrita como

$$f_X(x) = |\det \mathbf{B}| f_X(s) = |\det \mathbf{B}| \prod_{i=1}^p f_i(s_i) = |\det \mathbf{B}| \prod_{i=1}^p f_i(\mathbf{b}_i^\top \mathbf{X})$$

em que $\mathbf{B} = (\mathbf{b}_1, \dots, \mathbf{b}_n)^\top = \mathbf{A}^{-1}$, $s_i = \mathbf{b}_i^\top \mathbf{X}$ e f_i denota as densidade da i -ésima componente independente.

Supondo que temos n observações de \mathbf{X} , denotadas por $\{\mathbf{X}_1, \dots, \mathbf{X}_n\}$, a verossimilhança pode ser obtida pelo produto desta densidade avaliada nos n pontos. Então

$$L(\mathbf{B}) = \prod_{t=1}^n \prod_{i=1}^p f_i[\mathbf{b}_i^\top \mathbf{X}(t)] |\det \mathbf{B}|.$$

Consequentemente a log-verossimilhança é

$$\log L(\mathbf{B}) = \sum_{t=1}^n \sum_{i=1}^p \log f_i[\mathbf{b}_i^\top \mathbf{X}(t)] + n \log |\det \mathbf{B}|.$$

De modo equivalente,

$$\frac{1}{n} \log L(\mathbf{B}) = E \left[\sum_{i=1}^p \log f_i(\mathbf{b}_i^\top \mathbf{X}) \right] + \log |\det \mathbf{B}|. \quad (13.31)$$

Nessa expressão, a esperança corresponde a uma média calculada a partir da amostra observada. Desta forma, expressamos a verossimilhança como uma função dos parâmetros do modelo, que são os elementos da matriz de mistura. Essa log-verossimilhança pode ser maximizada por meio de algoritmos apropriados.

6) Minimização da Informação Mútua

Uma outra abordagem da Análise de Componentes Independentes envolve a minimização da **Informação Mútua**, definida para variáveis aleatórias $\mathbf{y} = \{y_1, \dots, y_p\}$ como

$$I(y_1, \dots, y_p) = \sum_{i=1}^p H(y_i) - H(\mathbf{y}).$$

Esta medida é equivalente à divergência de Kullback-Leibler entre a densidade conjunta $f(\mathbf{y})$ e o produtos das distribuições marginais (sendo, pois, uma medida de independência). A informação mútua é não negativa e igual a zero se as variáveis são independentes e leva em conta toda a estrutura de dependência das variáveis, diferentemente da Análise de Componentes Principais, que apenas considera a covariância entre elas.

Se $\mathbf{y} = \mathbf{W}\mathbf{X}$, então

$$I(y_1, \dots, y_p) = \sum_{i=1}^p H(y_i) - H(\mathbf{X}) - \log |\det \mathbf{W}|.$$

Supondo os y_i não correlacionados, com variância um, é fácil ver que $\det(\mathbf{W})$ é uma constante (veja o Problema 3), de modo que

$$I(y_1, \dots, y_p) = C - \sum_{i=1}^p J(y_i), \quad (13.32)$$

explicita a relação entre a informação mútua e a negrentropia. Como a informação mútua é uma medida natural de independência de variáveis aleatórias, podemos usá-la para encontrar a transformada necessária em Análise de Componentes Independentes. De fato, por (13.32), minimizar a informação mútua é equivalente a encontrar as direções segundo as quais a negrentropia é maximizada.

13.6 Exercícios

- 1) Prove a relação (13.5)
- 2) (Hyvärinen e Oja (2000)) (Suponha o caso de $p = 2$ e as c.i.'s S_1 e S_2 com densidades uniformes no intervalo $|S_i| \leq \sqrt{3}$, $i = 1, 2$.
 - (i) Determine a densidade conjunta de (S_1, S_2) .
 - (ii) Suponha $\mathbf{A} = \begin{bmatrix} 2 & 3 \\ 2 & 1 \end{bmatrix}$. Obtenha (X_1, X_2) em função de S_1 e S_2 e obtenha a distribuição conjunta de (X_1, X_2) .
- 3) Prove (12.46), calculando $E(\mathbf{y}\mathbf{y}^\top)$ e pondo seu determinante igual a 1.
- 4) Faça a análise de componentes independentes para os 498 dados e 15 variáveis do conjunto de dados do Exemplo 13.2.

Referências

- Afiune, J. Y. (2000). Avaliação ecocardiográfica evolutiva de recém-nascidos pré-termo, do nascimento até o termo. Tese de Doutorado, Faculdade de Medicina da USP.
- Anderson, T.W. (1957). Maximum likelihood estimates for a multivariate normal distribution when some observations are missing. *Journal of the American Statistical Association*, **52**, 200–203.
- Bartlett, M.S. (1937). The statistical conception of mental factors. *British Journal of Psychology*, **28**, 97-104.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. New York: Springer.
- Bland, J.M. and Altman, D.G. (1986). Statistical methods for assessing agreement between two methods of clinical measurement. *Lancet*, **327**, 307–310. doi:10.1016/S0140-6736(86)90837-8
- Blei, D. M. Smyth, P. (2017). Science and data science. *PNAS*, **114**, 8689–8692.
- Box, G.E.P. and Müller, M.E.(1958). A note on the generation of random normal deviates. *The Annals of Statistics*, **29**, 610–611.
- Box, G.E.P. and Cox, D.R. (1964). An analysis of transformations. *Journal of the Royal Statistical Society, Series B*, **26**: 211-252.
- Box, G. E. P. and Müller, M. E. (1958). A note on the generation of random normal deviates. *The Annals of Mathematical Statistics*, **29**, 610–611.
- Boyles, R. A. (1983). On the convergence of the EM algorithm. *Journal of the Royal Statistical Society. Series B*, **45**, 47–50.
- Breiman, L. (1996). Bagging predictors. *Machine Learning*, **24**, 123–140.
- Breiman, L. (2001). Statistical modeling: the two cultures. *Statistical Science*, **16**, 199–231.
- Breiman, L. (2001). Random forests. *Machine Learning*, **45**, 5–32.
- Breiman, L., Friedman, J. H., Olshen, R. A., and Stone, C. J. (1984). *Classification and Regression Trees*. Chapman & Hall/CRC.

- Bühlmann, P. and van de Geer, S. (2011). *Statistics for High-Dimensional Data*. Berlin: Springer.
- Bussab, W.O. e Morettin, P.A. (2017). *Estatística Básica, 9a Edição*. São Paulo: Saraiva.
- Casella, G. and George, E. I. (1992). Explaining the Gibbs sampler. *The American Statistician*, **46**, 167–174.
- Chambers, J.M., Cleveland, W.S., Kleiner, B and Tukey, P.A. (1983). *Graphical Methods for Data Analysis*. London: Chapman and Hall.
- Chambers, J. M. and Hastie, T. J. (eds.) (1992). *Statistical Models in S*. Wadsworth and Brooks/Cole, Pacific Grove, CA.
- Chambers, J. M. (1993). Greater or lesser Statistics: A choice for future research. *Statistics and Computing*, **3**, 182–184.
- Chen, M.-H., Shao, Q.-M. and Ibrahim, J. G. (2000). *Monte Carlo Methods in Bayesian Computation*. New York: Springer.
- Chib, S. and Greenberg, E. (1995). Understanding the Metropolis–Hastings algorithm. *The American Statistician*, bf 49, 327–335.
- Chollet, F. (2018). *Deep Learning with R*. Manning.
- Cleveland, W. M. (1979). Robust locally weighted regression and smoothing scatterplots. *Journal of the American Statistical Association*, **74**, 829–836.
- Cleveland, W. M. (1985). *The Elements of Graphing Data*. Monterey: Wadsworth.
- Cleveland, W. M. (1993). *Visualizing Data*. Summit, New Jersey: Hobart Press.
- Cleveland, W. M. (2001). Data Science: An action plan for expanding the technical areas of the field of Statistics. *International Statistical Revue*, **69**, 21–26.
- Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, **20**, 37–46. doi:10.1177/001316446002000104
- Colosimo, E.A. e Giolo, S.R. (2006). *Análise de Sobrevivência Aplicada*. São Paulo: Blücher.
- Cortes, C. and Vapnik, V. (1995). Support vector networks. *Machine Learning*, **20**, 273–297.
- Dempster, A.P., Laird, N. and Rubin, D.B. (1977). Maximum likelihood from incomplete data via the EM algorithm. *Journal of the Royal Statistical Society, Series B*, **39**, 1–38.
- Donoho, D. (2017). 50 years of Data Science. *Journal of Computational and Graphical Statistics*, **26**, 745–766.
- Durbin, J. and Watson, G.S. (1950). Testing for serial correlation in least squares regression, I. *Biometrika* , **37**, 409-428.
- Durbin, J. and Watson, G.S. (1951). Testing for serial correlation in least squares regression, II. *Biometrika* , **38**, 159-178.

- Durbin, J. and Watson, G.S. (1971). Testing for serial correlation in least squares regression, III. *Biometrika* , **58**, 1-19.
- Dzik A., Lambert-Messerlian, G., Izzo, V.M., Soares, J.B., Pinotti, J.A. and Seifer, D.B. (2000). Inhibin B response to EFORT is associated with the outcome of oocyte retrieval in the subsequent in vitro fertilization cycle. *Fertility and Sterility*,, **74**, 1114-1117.
- Efron, B. and Tibshirani, R. (1993). *An Introduction to the Bootstrap*. Chapman and Hall
- Efron, B. and Hastie, T. (2016). *Computer Age Statistical Inference*. New York: Cambridge University Press.
- Elias, F.M., Birman, E.G., Matsuda, C.K., Oliveira, I.R.S. and Jorge, W.A. (2006). Ultrasonographic findings in normal temporomandibular joints. *Brazilian Oral Research*, **20**, 25-32.
- Embrechts, P., Lindskog, F. and McNeil, A. (2003). Modelling dependence with copulas and applications to risk management. In *Handbook of Heavy Tailed Distributions in Finance*, ed. S. Rachev, Elsevier, Ch. 8, 329–384.
- Ehrenberg, A. S. C. (1981). The problem of numeracy. *The American Statistician*, **35**, 67-71.
- Ferreira, J.E., Takecian, P.L., Kamaura, L.T., Padilha, B. and Pu, C. (2017). Dependency Management with WED-flow Techniques and Tools: A Case Study. *Proceedings of the IEEE 3rd International Conference on Collaboration and Internet Computing*, 379-388. doi:10.1109/CIC.2017.00055
- Fletcher, R. (1987). *Practical Methods of Optimization, Second Edition*. New York: Wiley.
- Freedman, D. and Diaconis, P. (1981). On the histogram as a density estimator: L_2 theory. *Zeitschrift für Wahrscheinlichkeitstheorie und Verwandte Gebiete*, **57**, 453–476.
- Freund, Y. and Schapire, R.E. (1997). A decision-theoretic generalization of on-line learning and an application to boosting. *Journal of Computer and System Science*, **55**, 119–139.
- Friedman, J. H., Hastie, T. and Tibshirani, R. (2010). Regularization paths for generalized linear models via coordinate descent. *Journal of Statistical Software*, **33**, 1–22.
- Fuller, W.A. (1996). *Introduction to Statistical Time Series, Second Edition*. New York: Wiley.
- Gamerman, D. and Lopes, H. F. (2006). *Markov Chain Monte Carlo*. Boca Raton: Chapman & Hall.
- Gartner, Inc. (2005). *Gartner says more than 50 percent of data warehouse projects will have limited acceptance or will be failures through 2007*. <http://www.gartner.com>.2005.
- Gegembauer, H. V. (2010). *Análise de Componentes Independentes com Aplicações em Séries Temporais Financeiras*. Dissertação de Mestrado, IME-USP.

- Gelfand, A. E. and Smith, A. F. M. (1990). Sampling-based approaches to calculating marginal densities. *Journal of the American Statistical Association*, **85**, 398–409.
- Geman, S. and Geman, D. (1984). Stochastic relaxation, Gibbs distributions, and the Bayesian restoration of images. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, **6**, 721–741.
- Giampaoli, V., Magalhães, M.N., Fonseca, F.C. e Anorozo, N.F. (2008). Relatório de análise estatística sobre o projeto: “Avaliação e pesquisa: Investigando as dificuldades em Matemática no Ensino Fundamental da Rede Municipal da cidade de São Paulo – 2ª fase”. São Paulo, IME-USP. (RAE – CEA – 08P27).
- Gilks, W. R., Richardson, S. and Spiegelhalter, D. J. (1996). *Markov Chain Monte Carlo in Practice*. London: Chapman and Hall.
- Goldfeld, S.M., Quandt, R.E. and Trotter, H.F. (1966). Maximisation by quadratic hill-climbing. *Econometrica*, **34**, 541-551.
- Goodfellow, I., Bengio, Y. and Courville, A. (2016). *Deep Learning*. The MIT Press.
- Graedel, T. and Kleiner, B. (1985). Exploratory analysis of atmospheric data. In *Probability, Statistics and Decision Making in Atmospheric Sciences*, A.H. Murphy and R.W. Katz, eds), pp 1-43. Boulder: Westview Press.
- Hammersley, J.M. and Handscomb, D.C. (1964). *Monte Carlo Methods*. New York: Wiley.
- Hastie, T. and Tibshirani, R. (1990). *Generalized additive models*. London: Chapman & Hall.
- Hastie, T., Tibshirani, R. and Friedman, J. (2017). *The Elements of Statistical Learning*, 2nd Edition, Springer.
- Hastings, W.K. (1970). Monte Carlo sampling methods using Markov chains and their applications. *Biometrika*, **57**, 97–109.
- Hinkley, B. (1977). On quick choice of probability transformations. *Applied Statistics*, **26**, 67-69.
- Hebb, D.O. (1949). *The organization of behavior*. New York: Wiley.
- Hoerl, A. E. and Kennard, R. W. (1970). Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, **12**, 55–67.
- Hosmer, D. W. and Lemeshow, S. (1980). A goodness-of-fit test for the multiple logistic regression model. *Communications in Statistics*, **A10**, 1043–1069.
- Hosmer, D.W. and Lemeshow, S. (2013). *Applied Logistic Regression*, Third ed. New York: John Wiley.
- Hyvärinen, A. and Oja, E. (1997). A fast fixed point algorithm for independent component analysis. *Neural Computation*, **9**, 1483–1492.
- Hyvärinen, A. (1999). Fast and robust fixed-point algorithm for independent component analysis. *IEEE Transactions on Neural Network*, **10**, 626–634.

- Hyvärinen, A. and Oja, E. (2000). Independent component analysis: Algorithms and applications. *Neural Networks*, **13**, 411–430.
- Hyvärinen, A., Karhunen, J. and Oja, E. (2001). *Independent Component Analysis*. New York: Wiley.
- Jaiswal, S. (2018). K-Means Clustering in R Tutorial. Disponível em <https://www.datacamp.com/community/tutorials/k-means-clustering-r>.
- James, G., Witten, D., Hastie, T. and Tibshirani, R. (2017). *Introduction to Statistical Learning*. Springer.
- Johnson, N.L. and Leone, F.C. (1964). *Statistics and Experimental Design in Engineering and Physical Sciences, Vols 1, 2*. New York: Wiley.
- Jordan, M. I. (2019). Artificial intelligence – The revolution hasn't happened yet. *Harvard Data Science Review*, Issue 1.1.
- Kleijnen, J. and Groenendall, W. (1994). *Simulation: A Statistical Perspective*. Chichester: Wiley.
- Kutner, M.H., Neter, J., Nachtsheim, C.J. and Li, W. (2004). *Applied Linear Statistical Models. 5th ed.* New York: McGraw-Hill/Irwin. ISBN-10: 007310874X, ISBN-13: 978-0073108742.
- Lee, E.T. and Wang, J.W. (2003). *Statistical Methods for Survival Data Analysis, 3rd. Edition*. New York: Wiley
- Lemeshow, S. and Hosmer, D.W. (1982). The use of goodness-of-fit statistics in the development of logistic regression models. *American Journal of Epidemiology*, **115**, 92-106.
- Little, R.J.A. and Rubin, D.B. (1987). *Statistical Analysis with Missing Data*. New York: Wiley.
- Louis, T.A. (1982). Finding observed information using the EM algorithm. *Journal of the Royal Statistical Society, Series B*, **44**, 98-130.
- Mantel, N. and Haenszel, W. (1959). Statistical aspects of the analysis of data from retrospective studies of disease. *Journal of the National Cancer Institute*, **22**, 719-748.
- McCarthy, J., Minsky, M. L., Rochester, N. and Shannon, C.E. (1955). A Proposal for the Dartmouth Summer Research Project on Artificial Intelligence. August 31, 1955.
- McCulloch, W. S. and Pitts, W. A. (1943). Logical calculus of the ideas immanent in nervous activity. *Butt. math. Biophysics*, **S**, 115-133.
- McGill, R., Tukey, J. W. and Larsen, W. A. (1978). Variations of box plots. *The American Statistician*, **32**, 12-16.
- Medeiros, M. C. (2019). *Machine Learning Theory and Econometrics*. Lecture Notes.
- Meilijson, I. (1989). A fast improvement to the EM algorithm on its own terms. *Journal of the Royal Statistical Society. Series B*, **51**, 127–138.

- Meng, X.L. and Rubin, D.B. (1993). Maximum likelihood estimation via the ECM algorithm: A general framework. *Biometrika*, **80**, 267-278.
- Metropolis, N. and Ulam, S.(1949). The Monte Carlo method. *Journal of the American Statistical Association*, **44**, 335–341.
- Metropolis, N., Rosenbluth, A. W., Rosenbluth, M. N., Teller, A. H. and teller, E. (1953). Equation of state calculations by fast computing machines. *The Journal of Chemical Physics*, **21**, 1087–1092 .
- Meyer, D. (2018). Support vector machines. The interface to **libsvm** in package **e1071**. FH technikum Wien, Austria.
- Miller, R.G. and Halpern, J.H. (1982). Regression via censored data. *Biometrika*, **69**, 521-531.
- Morettin, P. A. (2014). *Ondas e Ondaletas: da Análise de Fourier à Análise de Ondaletas de Séries Temporais*. São Paulo: EDUSP.
- Morettin, P.A. and Tolói, C.M.C. (2018). *Análise de Séries Temporais*, 3a Edição, Volume 1. São Paulo: Blücher.
- Morrison, D.F. (1976). *Multivariate Statistical Methods*, 2nd Ed. New York: McGraw-Hill.
- Müller, P. (1992). Alternatives to the Gibbs sampling scheme. *Technical report*. Institute of Statistics and decision Sciences, Duke University, Durham.
- Nelder, J.A. and Mead, R. (1965). A simplex method for function minimization. *Computer Journal*, **7**, 308-313.
- Paulino, C.D. e Singer, J.M. (2006). *Análise de Dados Categorizados*. São Paulo: Blücher.
- Pedroso de Lima, A.C., Singer, J.M. e Fusaro, E.R. (2000). *Relatório de análise estatística sobre o projeto “Prognóstico de pacientes com insuficiência cardíaca encaminhados para tratamento cirúrgico.”* São Paulo: Centro de Estatística Aplicada do IME/USP.
- Powell, M.J.D. (1964). An efficient method for finding the minimum of a function of several variables without calculating derivatives. *Computer Journal*, **7**, 155-162.
- R Core Team (2013). R: A language and environment for statistical computing. R Foundation for Statistical Computing, Vienna, Austria. URL <http://www.R-project.org/>.
- Rainardi, V. (2008). *Building a Data Warehouse with Examples in SQL Server*. Apress (Springer). doi: 10.1007/978-1-4302-0528-9
- Robert, C. and Casella, G. (2004). *Monte Carlo Statistical Methods*. Second Edition. New York: Springer.
- Roberts, G. O. and Smith, A. F. M. (1994). Simple conditions for the convergence of the Gibbs sampler and Metropolis-Hastings algorithms. *Stochastic Processes and Their Applications*, **49**, 207–216.
- Rosenblatt, F. (1958). The perceptron: A theory of statistical separability in cog-

- nitive systems. Buffalo: Cornell Aeronautical Laboratory, Inc. Rep. No. VG-1196-G-1.
- Ross, S.(1997). *Simulation, 2nd Ed.*, New York: Academic Press.
- Rubin, D.B. (1977). Formalizing subjective notions about the effect of nonrespondents in sample surveys. *Journal of the American Statistical Association*, **72**, 538–543.
- Rubin, D.B. (1987). *Multiple Imputation for Nonresponse in Surveys*. New York: Wiley.
- Rubin, D.B. (1996). Multiple imputation after 18+ years. *Journal of the American Statistical Association*, **91**, 473-489.
- Schmee, J. and Hahn, G.J. (1979). A simple method for regression analysis with censored data. *Technometrics*, **21**, 417-432.
- Sen, P.K., Singer, J.M. and Pedroso-de-Lima, A.C. (2009), *From finite sample to asymptotic methods in Statistics*. Cambridge: Cambridge University Press.
- Singer, J.M. and Andrade, D.F. (1997). Regression models for the analysis of pretest/posttest data. *Biometrics*, **53**, 729-735.
- Singer, J.M. e Ikeda, K. (1996). Relatório de Análise Estatística sobre o projeto “Fatores de risco na doença aterosclerótica coronariana”. São Paulo, SP, IME-USP, 1996, 28p. (CEA-RAE-9608).
- Singer, J.M., Rocha, F.M.M e Nobre, J.S. (2018). *Análise de Dados Longitudinais*. Versão parcial preliminar.
- Smola, A. J. and Schölkopf, B. (2004). A tutorial on support vector regression. *Statistics and Computing*, **14**, 199–222.
- Sobol, I.M.(1976). *Método de Monte Carlo*. Moscow: Editorial MIR.
- Stone, J. V. (2004). *Independent Component Analysis: A Tutorial Introduction*. MIT Press.
- Sturges, H. A. (1926). The choice of a class interval. *Journal of the American Statistical Association*, **21**, 65–66.
- Tanner, M.A. (1996). *Tools for Statistical Inference, 3rd Ed.*. New York: Springer.
- Thurstone, L.L. (1947). *Multiple Factor Analysis: A development and expansion of vectors of the mind..* Chicago: University of Chicago Press.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society, Series B (methodological)*, **58**, 267–288.
- Trevino, A. (2016). Introduction to K-means Clustering. Disponível em <https://www.datascience.com/blog/k-means-clustering>.
- Tukey, J. W. (1962). The future of data analysis. *The Annals of Mathematical Statistics*, **33**, 1–67.
- Tukey, J. W. (1977). *Exploratory Data Analysis*. Reading: Addison-Wesley.

- Turing, A. (1950). Computing machinery and intelligence". *Mind*, LIX (236).
- Vapnik, V. and Chervonenkis, A. (1964). A note on a class of perceptrons. *Automation and Remote Control*, **25**.
- Vapnik, V. and Chervonenkis, A. (1974). *Theory of Pattern recognition* [in Russian]. Moskow: Nauka.
- Vapnik, V. (1995). *The Nature of Statistical Learning Theory*. New York: Springer.
- Vapnik, V. (1998). *Statistical Learning Theory*. New York: Wiley.
- Viera, J. and Garrett, J.M. (2005). Understanding interobserver agreement: the kappa statistic. *Family Medicine*, **37**, 360-263
- von Neumann, J.(1951). Various techniques used in connection with random digits, Monte Carlo Method. *U.S. National Bureau of Standards Applied Mathematica Series*, **12**, 36–38.
- Wayne, D.W. (1990). *Applied Nonparametric Statistics, Second Edition* . Boston: PWS-Kent. ISBN 0-534-91976-6.
- Wei, G.C.G. and Tanner, M.A. (1990). A Monte Carlo implementation of the EM algorithm and the poor man's data augmentation algorithm. *Journal of the American Statistical Association*, **85**, 699-704.
- Wilks, S.S. (1932). Moments and distributions of estimates of population parameters from fragmentary samples. *Annals of Mathematical Statistics*, **2**, 163–195
- Witzel, M.F., Grande, R.H.M. and Singer, J.M. (2000). Bonding systems used for sealing: evaluation of microleakage. *Journal of Clinical Dentistry* , **11**, 47-52.
- Wu, C.F.J. (1983). On the convergence properties of the EM algorithm. *Annals of Statistics*, **11**, 95-103.
- Zan, A.S.C.N. (2005). Ultra-sonografia tridimensional: determinação do volume do lobo hepático direito no doador para transplante intervivos. Tese de doutorado. São Paulo: Faculdade de Medicina, Universidade de São Paulo.
- Zerbini, T., Gianvecchio, V.A.P., Regina, D., Tsujimoto, T., Ritter, V. and Singer, J.M. (2018). Suicides by hanging and its association with meteorological conditions in São Paulo, Brazil. *Journal of Forensic and Legal Medicine*, **53**, 22-24. doi: dx.doi.org/10.1016/j.jflm.2017.10.010

Índice

- Odds*, 94
Accelerated failure time models, 242
Bump hunters, 332
Draftsman's display, 134
Odds ratio, 94
Proportional hazards model, 243
Splines, 268
Stem and leaf, 45
- Acurácia, 97, 256
Alavanca, 265
Algoritmo
 aglomerativo, 332
 BFR, 341
 combinatório, 332
 CURE, 342
 DBSCAN, 342
 de suporte vetorial, 249, 314
 divisivo, 332
 hierárquico, 332
Amostra, 21, 61
 aleatória simples, 63, 73
 bootstrap, 305
Amplitude, 55
ANOVA, 141
Análise
 condicional, 189
 de componentes independentes, 4, 361, 362
 de componentes principais, 4, 134
 de Confiabilidade, 233
 de regressão, 100
 de séries de tempo, 185
 de séries temporais, 185
 de Variância, 70, 141
 exploratória de dados, 21
Aprendizado
 com Estatística, 6
- Aprendizado
 automático, 4
 com estatística, 3
 não supervisionado, 4
 supervisionado, 4
- Aprendizado com Estatística, 267
- Artificial
 inteligência, 4
- Associação
 entre variáveis, 85
- Autocorrelação, 187
- Autovalor, 370
- Autovetor, 370
- Bagging, 296
- Banco de dados, 21
- Boosting, 296
- Bootstrap, 297, 304
- Capa de Cohen, 90
- Carga fatorial, 352
- Censura, 234
 intervalar, 244
 à direita, 244
 à esquerda, 244
- Centróide, 332
- Chance, 94, 209
- Ciência
 de dados, 1
- Classe modal, 52, 290
- Classificador, 251
 CMF, 273
 CMM, 270
 CMNL, 279
 de Bayes, 12, 262
 de margem flexível, 269, 273
 de margem máxima, 269
 de margem não linear, 269

- forte, 297
- fraco, 297
- Classificador KNN, 12
- Classificação, 11
 - árvores para, 290
- Coeficiente
 - de contingência, 89
 - de correlação, 117
 - de correlação cofenético, 341
 - de correlação de Pearson, 100
 - de correlação de Spearman, 100
 - de correlação linear, 346
 - de correlação múltipla, 354
 - de determinação, 175
 - de determinação ajustado, 204, 218
 - de penalização, 308
 - de Tschuprov, 89
- Comunalidade, 353
- Concordância, 90, 104
- condições de Karush-Kuhn-Tucker, 284
- Conjunto
 - de treinamento, 268
- Cook
 - gráficos de, 175
- Cumulante, 374
- Curtose, 76, 372
- Curva ROC, 255
- Dado
 - longitudinal, 26
 - omissos, 25
- Dados
 - conjuntos de, 14
 - de teste, 264
 - de treinamento, 264
 - estruturados, 8
 - longitudinais, 102, 185, 205
 - não estruturados, 8
 - para classificação, 251
- dados de treinamento, 251
- Data
 - Science, 1
- Dendrograma, 334
- Desvio
 - absoluto médio, 54
 - mediano absoluto, 54
 - médio, 54
 - padrão, 53
- Diferença significativa, 120
- Distribuição
 - conjunta, 86
 - de frequências, 42
 - de valores extremos, 243
 - normal bivariada, 345
 - Wishart, 370
- Distância
 - de Cook, 183, 199
 - edit, 342
 - Euclidianas, 331
 - Hamming, 342
 - interquartis, 54
- Divisão binária recursiva, 290
- Efeito
 - aleatório, 208
 - principal, 143
- Elastic Net, 307
- Ensaio clínico, 21
- Entropia cruzada, 290, 304
- Equação
 - de estimação, 174, 210
- Erro
 - aleatório, 195
 - de classificação, 290
 - de previsão, 290
 - padrão, 72
 - propagação de, 33
 - quadrático médio, 11, 249, 264
- Escore
 - fatorial, 357
- Espaço
 - característico, 268
 - dos dados, 268
- Especificidade, 96, 254
- Estatística, 6
 - de Durbin-Watson, 187
 - de ordem, 51, 63
 - de Pearson, 89, 220
- Estimador
 - de Kaplan Meier, 238
 - de mínimos quadrados, 174, 194
 - de mínimos quadrados penalizados, 309
 - do limite de produtos, 238
 - Lasso, 309
 - Lasso adaptativo, 311
 - não enviesado, 53
- Estruturas de dados, 8
- Estudo
 - caso-controle, 116
 - observacional, 21
 - prospectivo, 93, 116
 - retrospectivo, 94, 116

- Falso
 - negativo, 96
 - positivo, 96, 256
- fastICA, 365
- Fator, 139
 - comum, 352
 - de risco, 93
 - efeito, 141
 - específico, 352
 - interação, 141
- Floresta
 - aleatória, 289
- Florestas
 - aleatórias, 301
- Folha, 291
- Forma quadrática, 196
- Fronteira
 - de Bayes, 262
 - de decisão, 249
- Fronteira de separação, 271
- Função
 - biquadrática, 157
 - de distribuição empírica, 238
 - de probabilidade, 61
 - de risco, 236
 - de sobrevivência, 234
 - densidade de probabilidade, 61
 - discriminante, 249, 260
 - discriminante de Fisher, 250
 - distribuição acumulada, 63
 - distribuição empírica, 63
 - tricúbica, 156
- Galho, 291
- Grau
 - de liberdade, 54
- Gráfico
 - dotplot*, 44
 - da escarpa sedimentar, 348
 - da variável adicionada, 204
 - de barras, 42
 - de Bland-Altman, 106
 - de Cook, 183
 - de dispersão, 98
 - de dispersão simbólico, 134
 - de dispersão unidimensional, 44
 - de médias/diferenças, 106
 - de perfis, 206
 - de perfis individuais, 102
 - de perfis médios, 111, 139
 - de pizza, 42
 - de quantis, 56
- de resíduos, 176
- de simetria, 57
- do cotovelo, 348
- do desenhista, 134, 206
- PP, 119
- QQ, 64, 104, 183
- Ramo e Folhas, 45
- ramo-e-folhas, 45
- torta, 42
- Heteroscedasticidade, 179
- Hiperplano, 269
 - de margem máxima, 270
- Hipótese
 - de homogeneidade, 88
 - de independência, 88
- Homocedasticidade, 177
- ICA, 361
- Inferência
 - Estatística, 21, 61
- Influência
 - local, 175
- Infomax, 365
- Informação
 - mútua, 363, 375
- Informação sistemática, 9
- Interação
 - essencial, 143
 - não essencial, 143
- Intervalo
 - de confiança, 73, 216
 - de previsão, 216
- JADE, 365
- Janelamento, 139
- Kernel, 268, 286
 - baseado em ondaletas, 268
 - de base exponencial, 268
 - Gaussiano, 268
 - polinomial, 268, 280
 - radial, 280
- Kernels, 279
- Lasso, 307
- Limiar brando, 310
- LOOCV, 264
- Lowess, 138, 155
- Mantel-Haenszel, 160
- Margem de erro, 73
- Matlab, 14

- Matriz
 cofenética, 340
 de correlações, 149, 154
 de correlações reduzida, 355
 de covariâncias, 149, 153
 de dados, 133, 148
 de similaridade, 331
 ortogonal, 353
- Mediana, 51
- Medida
 de localização, 50
 de tendência central, 50
 resistente, 51
 robusta, 51
- Megadados, 1
- Meia média, 51
- Minitab, 14
- Moda, 52
- Modelo
 de regressão de Cox, 243
 de regressão linear múltipla, 193
 de regressão linear simples, 173
 de regressão polinomial, 173
 de riscos proporcionais, 243
 de tempo de falha acelerado, 242
 exponencial, 236
 hipergeométrico, 242
 linear misto, 208
 linearizável, 190
 log normal, 236
 não linear, 173
 paramétrico, 242
 probabilístico, 61
 semiparamétrico, 243
 Weibull, 236
- Momento
 centrado, 55
- Multiplicadores de Lagrange, 283, 309, 348
- Média, 51
 aparada, 51
- Método
 de Bartlett, 357
 de Mantel-Haenszel, 153
 de máxima verossimilhança, 209, 353
 de mínimos quadrados, 6, 196, 224
 de mínimos quadrados generalizados, 188, 212
 Delta, 210
 do centroide, 353
- do fator principal, 353
 do gradiente, 363
 Fisher scoring, 210
 Newton-Raphson, 210
- Método Delta, 122
- Negentropia, 372
- Nó
 interno, 291
 terminal, 291
- Observação
 de teste, 289
 de treinamento, 289
 discrepante, 180
- Paradoxo de Simpson, 162
- Parametrização
 de desvios médios, 159
 de médias de celas, 142
- parametrização, 142
- Partição, 139
- Parâmetro
 de encolhimento, 300
 de localização, 142
- Parâmetros, 171
- Percentil, 53
- Poda, 293, 304
- Poda de árvores, 304
- Ponto
 alavanca, 183
 de corte, 254
 influente, 183
- Posto, 100
- Prevalência, 97
- Previsor
 forte, 297
 fraco, 297
- Probabilidades, 6
- Processo
 estocástico, 63
- Programação quadrática, 283
- Pureza do nó, 303
- Quantil, 52
 empírico, 52
- Quartil, 53
- Razão
 de chances, 94, 209, 212
- Razão de chances
 intervalo de confiança, 122
- Redes neurais, 223

- Regra
de classificação, 260
- Regressão
baseada em vetores suporte, 314
linear, 6
linear múltipla, 174, 193
linear simples, 174
resistente, 221
segmentada, 158
árvores para, 318
- Regularização, 307
Ridge, 307
- Representação dual, 283
- Restrição
ativa, 283
inativa, 283
- Resíduo, 89, 174, 194
da desviância, 221
de Pearson, 220
padronizado, 176
studentizado, 176, 215
- Risco
atribuível, 93
de um classificador, 251
relativo, 94, 243
- Risco relativo
intervalo de confiança, 122
- Rotação de fatores, 355
- SAS, 14
- Sensibilidade, 96, 254
- Separação
cega de fontes, 361
- Separação cega de fontes, 361
- Sobreajuste, 7, 293, 307
- SPlus, 14
- Suavização, 155
- Subespaço, 282
- Série
temporal, 188
- Tabela
atuarial, 246
de contingência, 88
de dupla entrada, 88
- Teorema
de Gauss-Markov, 215
Limite Central, 196, 215
- Teoria
da informação, 373
- Teste
log rank, 242
- Toco, 299
- Transformação
ortogonal, 345
- Unidade amostral, 24
- Validação cruzada, 5, 11, 249, 264, 274, 322
de ordem k , 265
validação cruzada, 258
- Valor
atípico, 58
discrepante, 58
esperado, 89
preditivo negativo, 97
preditivo positivo, 96
- Variáveis
comonotônicas, 116
contramonomotônicas, 116
- Variável
bimodal, 52
contínua, 40
de folga, 273, 284
discreta, 40
explicativa, 86
fictícia, 318
nominal, 40
ordinal, 40
padronizada, 75
preditora, 4
qualitativa, 40
quantitativa, 40
resposta, 3, 86
valor esperado, 61
- Variância, 53
aparada, 54, 118
específica, 352
- Vetor
suporte, 268, 271
- Vizinho mais próximo, 262
- Voto majoritário, 297
- Árvores, 318
- Índice de Gini, 290, 303